



# Hardware per l'Intelligenza Artificiale

Dal PC Desktop alla Workstation Enterprise

DANIELE GENOVESE



## Indice

- Capitolo 1 - La CPU nei PC Desktop Consumer
  - 1. Cosa fa la CPU
    - 1.1 Definizione e Ruolo nel Sistema
    - 1.2 CPU vs GPU: Due Paradigmi di Calcolo (Seriale vs. Parallelo)
  - 2. Architettura Interna della CPU
    - 2.1 Core Fisici: Cosa Sono e Perché Contano
    - 2.2 Thread e SMT/Hyper-Threading: Differenza Tra Core e Thread
    - 2.3 Frequenza Base vs. Frequenza Boost
    - 2.4 Cache L1, L2, L3 e il Caso della 3D V-Cache
    - 2.5 IPC: perché la sola frequenza non basta
    - 2.6 TDP e consumo reale: PL1/PL2 e PPT
    - 2.7 Architetture ibride Intel: P-cores ed E-cores
    - 2.8 iGPU integrata: quando serve e quando no
  - 3. Il socket: compatibilità tra CPU e scheda madre
    - 3.1 Cos'è fisicamente un socket
    - 3.2 Socket AMD attuali e recenti: AM4 e AM5
    - 3.3 Socket Intel attuali e recenti: LGA1700 e LGA1851
    - 3.4 Come verificare la compatibilità: socket + chipset + BIOS
    - 3.5 Retrocompatibilità e aggiornamenti BIOS senza CPU (flashback)
  - 4. PCI Express: il trattamento completo
    - 4.1 Cos'è il PCIe: un bus seriale punto-punto
    - 4.2 Corsie (Lanes): cosa significano x1, x4, x8, x16
    - 4.3 Generazioni: PCIe 3.0, 4.0, 5.0 e un breve accenno al 6.0
    - 4.4 Compatibilità all'indietro tra generazioni e slot
    - 4.5 Chi fornisce le linee: CPU vs. chipset, e perché è importante
    - 4.6 Quante linee hanno le CPU consumer rispetto a HEDT e server
    - 4.7 Biforcazione: cos'è e quando è necessaria
    - 4.8 Impatto pratico: GPU su x8 vs x16, NVMe Gen4 vs Gen5
  - 5. Nomenclatura Commerciale: Come Leggere il Nome di una CPU
    - 5.1 Intel: Da Core i a Core Ultra
    - 5.2 AMD: La Logica Ryzen
    - 5.3 Threadripper e Xeon: solo un accenno
  - 6. Confronto tra marchi: Intel vs. AMD
    - 6.1 Punti di forza attuali
    - 6.2 Piattaforma: costo totale e longevità
    - 6.3 Casi d'Uso

- 7. Come Valutare e Scegliere una CPU
  - 7.1 Benchmark: Cosa Guardare e Cosa Non Fidarsi
  - 7.2 Bilanciamento CPU/GPU: Evitare i Colli di Bottiglia
  - 7.3 Overclocking: Cosa Serve e Se Conviene Ancora
  - 7.4 Raccomandazioni per fasce di prezzo
- 8. Errori comuni dell'acquirente
- Riepilogo Operativo — Checklist Decisionale CPU
- Capitolo 2 - La Scheda Madre
  - 1. Cosa fa la scheda madre
    - 1.1 Definizione e ruolo di hub
    - 1.2 Componenti principali sul PCB
  - 2. Il Chipset
    - 2.1 Cos'è il Chipset e Cosa Gestisce
    - 2.2 Comunicazione tra CPU e chipset
    - 2.3 La gerarchia dei chipset AMD (socket AM5)
    - 2.4 La gerarchia dei chipset Intel (LGA1700 e LGA1851)
    - 2.5 Tabella decisionale: quale chipset per quale utente
    - 2.6 Overclocking: il riassunto
  - 3. Il VRM (sezione di alimentazione)
    - 3.1 Cos'è il VRM e perché esiste
    - 3.2 Fasi di alimentazione
    - 3.3 Come riconoscere un VRM adeguato
  - 4. Il Form Factor
    - 4.1 Cos'è il form factor e perché è importante
    - 4.2 I quattro principali form factor
    - 4.3 Implicazioni pratiche
  - 5. Slot e porte
    - 5.1 Slot PCIe: numero, generazione e allocazione delle lane
    - 5.2 Slot M.2 e condivisione delle corsie
    - 5.3 Slot RAM: 2 vs 4
    - 5.4 Porte SATA
    - 5.5 Il pannello I/O posteriore
    - 5.6 Header Interni
  - 6. Nomenclatura e Marchi
    - 6.1 Perché i Nomi Contano
    - 6.2 ASUS
    - 6.3 MSI

- 6.4 Gigabyte
  - 6.5 ASRock
  - 6.6 Fasce di Prezzo e Reputazione dei Brand
- 7. Come Scegliere la Scheda Madre Ideale
  - 7.1 La Procedura Passo-Passo
  - 7.2 Verifiche di compatibilità
  - 7.3 Errori tipici dell'acquirente
- Riepilogo Operativo — Lista di Controllo per la Scelta della Scheda Madre
- Capitolo 3 - Memoria RAM
  - 1. Cos'è la RAM
    - 1.1 Definizione: memoria di lavoro volatile
    - 1.2 La differenza fondamentale dallo storage
    - 1.3 Come comunicano CPU e RAM: il memory controller integrato
  - 2. Capacità
    - 2.1 Quanta RAM è realmente necessaria, per caso d'uso
    - 2.2 Perché conta il numero di moduli: 1×16 vs 2×8 vs 4×8
  - 3. Velocità e Latenze
    - 3.1 Frequenza: MT/s vs. "MHz", cosa significa realmente
    - 3.2 Timings: CL, tRCD, tRP, tRAS e cos'è la latenza CAS
    - 3.3 Come calcolare la latenza reale in nanosecondi
    - 3.4 Frequenza contro latenza: cosa conta di più e quando
    - 3.5 XMP ed EXPO: perché la RAM va a frequenza base senza di essi
  - 4. Dual channel (e oltre)
    - 4.1 Come funziona il dual channel e il reale guadagno di banda
    - 4.2 Quali slot popolare: il caso A2/B2 ed errori di installazione
    - 4.3 Oltre il dual channel: quad e octa channel
    - 4.4 Single rank contro dual rank
  - 5. DDR4 contro DDR5
    - 5.1 Cosa cambia sotto il cofano
    - 5.2 Compatibilità: DDR4 e DDR5 non sono intercambiabili
    - 5.3 Quando la DDR4 ha ancora senso e qual è il sweet spot della DDR5
  - 6. Marche e Come Scegliere
    - 6.1 Chi Produce i Chip e Chi Assembla i Moduli: Due Lavori Diversi
    - 6.2 Perché G.Skill, Corsair e Kingston dominano
    - 6.3 Hynix A-die e M-die: perché gli appassionati li cercano
    - 6.4 RGB e dissipatori: estetica contro sostanza, e il problema dell'altezza
    - 6.5 Il metodo di selezione passo-passo

- 6.6 Fasce di budget: entry, mid, high-end
- 7. Errori Comuni dell'Acquirente
- Riepilogo Operativo — Checklist Selezione RAM
- Capitolo 4 - La Scheda Grafica (GPU Consumer)
  - 1. Cosa fa la GPU
    - Descrizione e funzione
    - I Componenti Fisici di una Scheda Grafica
    - Errori tipici a questo livello
  - 2. VRAM e bus di memoria
    - Cos'è la VRAM e perché è diversa dalla RAM di sistema
    - Il bus di memoria e la formula della banda
    - Quanta VRAM ti serve davvero
    - Il caso delle GPU "castrate" sul bus
  - 3. Nomenclatura NVIDIA: Come Leggere il Nome
    - La Struttura del Nome
    - Le Serie (Generazioni)
    - I Livelli (Tier)
    - I Suffissi: Ti e SUPER
    - Tabella Riassuntiva delle Recenti Generazioni NVIDIA
    - Errori Comuni di Nomenclatura NVIDIA
  - 4. Convenzione di Naming AMD: Come Leggere il Nome
    - La Struttura del Nome
    - Le Serie (Generazioni)
    - I suffissi: XT, XTX, GRE
    - Tabella di equivalenza approssimativa AMD ↔ NVIDIA
    - Errori tipici nella nomenclatura AMD
  - 5. NVIDIA vs AMD: Confronto Completo
    - Pura Rasterizzazione: Prezzo/Prestazioni
    - Ray Tracing: Vantaggio NVIDIA, Recupero RDNA 4
    - Upscaling: DLSS vs FSR vs XeSS
    - Encoder: NVENC vs AMF
    - CUDA vs ROCm: perché NVIDIA domina per AI e produttività
    - Driver, consumi, prezzi
    - Il terzo incomodo: Intel Arc
  - 6. Partner AIB e versioni custom
    - Founders Edition / reference vs custom
    - Partner NVIDIA e le loro gamme

- Partner AMD e "marchi di riferimento"
- Quanto vale davvero la pena pagare di più?
- Errori tipici con le versioni custom
- 7. Dimensioni fisiche e compatibilità
  - Lunghezza, spessore e spazio nel case
  - Connettori di alimentazione: 8-pin PCIe vs 12VHPWR / 12V-2x6
  - Requisiti PSU per Fascia GPU
  - GPU Sag e Supporti
- 8. In quale Slot installarla
  - Il Primo Slot PCIe x16 Collegato alla CPU
  - Cosa Succede negli Slot Secondari
- 9. Come Scegliere
  - Partire dal Monitor: Risoluzione e Refresh
  - Il Budget: La GPU Come Componente Cui Destinare la Quota Maggiore
  - Errori comuni dell'acquirente
- Riepilogo Operativo — Checklist Decisionale Scheda Video
- Capitolo 5 - Archiviazione
  - 1. Panoramica: Cos'è l'archiviazione e perché è diversa dalla memoria
    - 1.1 L'evoluzione: HDD → SATA SSD → NVMe SSD
  - 2. HDD vs. SSD: Due Architetture Fisiche Differenti
    - 2.1 Come Funziona un Hard Disk
    - 2.2 Come funziona un SSD
    - 2.3 Quando l'HDD ha ancora senso
    - 2.4 Tabella riassuntiva HDD / SATA SSD / NVMe SSD
  - 3. SATA vs. NVMe: Interfaccia e Protocollo
    - 3.1 SATA III e AHCI
    - 3.2 NVMe
    - 3.3 Confronto reale delle prestazioni: dove conta e dove no
  - 4. Fattore di forma, slot M.2 e compatibilità fisica
    - 4.1 Formati fisici
    - 4.2 La trappola numero uno: M.2 SATA vs. M.2 NVMe
    - 4.3 M.2 Keys
    - 4.4 Dimensioni: 2280 e altri
    - 4.5 Generazioni PCIe negli SSD
    - 4.6 Dissipatori e Thermal Throttling
    - 4.7 Lane sharing: quando un SSD disabilita le porte SATA
  - 5. Tecnologia NAND e componenti chiave

- 5.1 SLC, MLC, TLC, QLC: quanti bit per cella
- 5.2 Cache DRAM contro DRAM-less e HMB
- 5.3 Cache SLC dinamica e crollo della velocità
- 5.4 TBW e MTBF: come interpretare la resistenza dichiarata
- 6. Capacità e strategia di configurazione
  - 6.1 Quanta capacità
  - 6.2 La percentuale di riempimento
  - 6.3 Configurazioni sensate
- 7. Marche e Modelli di Riferimento
  - 7.1 Chi produce NAND e chi assembla
  - 7.2 Panoramica dei Marchi di SSD
  - 7.3 Tabella Orientativa SSD
  - 7.4 Hard Disk: Seagate, WD, Toshiba e la Trappola SMR
  - 7.5 Il processo di selezione, in ordine
- 8. Errori comuni dell'acquirente
- 9. Riepilogo Operativo — Lista di Controllo per la Scelta dello Storage
- Capitolo 6 - L'alimentatore (PSU)
  - Premessa: il componente invisibile
  - 1. Cosa fa la PSU
    - 1.1 Conversione AC→DC
    - 1.2 I rail: 12V, 5V, 3.3V (e i fantasmi del passato)
    - 1.3 Perché è il componente su cui NON si risparmia
    - 2.3 Tabelle Indicative e Calcolatori
    - 2.4 Sovradimensionamento: pro e contro
  - 3. La Certificazione 80 PLUS
    - 3.1 Cosa misura realmente (e cosa no)
    - 3.2 Livelli e Percentuali
    - 3.3 Cybenetics: La Certificazione che Misura Ciò che Conta
    - 3.4 Perché un Gold scadente può essere peggio di un Bronze eccellente
  - 4. Modularità
    - 4.1 Tre architetture
    - 4.2 L'avvertimento più importante di questo capitolo: i cavi non sono intercambiabili
  - 5. Standard e Connettori
    - 5.1 ATX 2.x versus ATX 3.0/3.1
    - 5.3 "PCIe Gen5 ready": cosa significa (e cosa non significa)
  - 6. Qualità Interna

- 6.1 Gli OEM: Chi costruisce davvero il tuo alimentatore
  - 6.2 Protezioni
  - 6.3 Condensatori, ventole, materiali
  - 6.4 La garanzia come indicatore
- 7. Marche e linee di riferimento
  - 7.1 Marche principali
  - 7.2 Tier List della Community
- 8. Come scegliere, passo dopo passo
  - 8.1 La Procedura
  - 8.2 Raccomandazioni basate sul budget
  - 8.3 Errori comuni, spiegati
- Riepilogo Operativo — Lista di Controllo per la Scelta dell'Alimentatore
- Capitolo 7 - Il Case e la Ventilazione
  - Premessa: Il Componente Che Tutti Sottovalutano
  - 1. Il ruolo del case
    - 1.1 Protezione meccanica ed elettrica
    - 1.2 Gestione termica: la vera funzione
    - 1.3 Acustica
    - 1.4 Estetica
    - 1.5 Ergonomia di Assemblaggio e Manutenzione
  - 2. Fattori di Forma: Chassis e Scheda Madre
    - 2.1 Fattori di Forma della Scheda Madre, Riveduti da una Prospettiva del Case
    - 2.2 Fattori di Forma dei Case
    - 2.3 Quale formato per quale esigenza
  - 3. Compatibilità e spazio interno: la checklist che ti salva l'acquisto
    - 3.1 Lunghezza massima della GPU
    - 3.2 Altezza massima dissipatore CPU
    - 3.3 Radiatori: dimensioni, posizioni, spessori
    - 3.4 Alloggiamenti per drive
    - 3.5 Alimentatore: posizione, lunghezza, shroud
    - 3.6 Gestione dei cavi (cable management)
    - 3.7 Montaggio verticale della GPU e riser PCIe
  - 4. Airflow: la discussione seria
    - 4.1 Mesh vs. vetro: quanto conta davvero
    - 4.2 Pressione Positiva, Negativa, Neutra
    - 4.3 Percorso del Flusso d'Aria



- 4.4 Configurazioni tipiche per numero di ventole
- 4.5 Filtri antipolvere
- 5. Ventole del case
  - 5.1 Dimensioni: 120, 140, 200 mm
  - 5.2 Specifiche: leggerle senza farsi ingannare
  - 5.3 PWM (4 pin) vs. DC (3 pin)
  - 5.4 Cuscinetti
  - 5.5 Marche di ventole
- 6. Marchi di Case
  - 6.1 Cosa distingue un case ben progettato
- 7. Come scegliere: la procedura
  - 7.1 Errori tipici dell'acquirente
  - 7.2 Raccomandazioni per fascia di prezzo
- 8. Riepilogo Operativo — Lista di Controllo per la Scelta del Case
  - A. Vincoli Dimensionali (obbligatorio: se uno fallisce, il case è escluso)
  - B. Flusso d'aria (obbligatorio)
  - C. Qualità e Caratteristiche
  - D. Configurazione, dopo l'acquisto
  - E. Le tre regole d'oro, se dimenticate tutto il resto
- Capitolo 8 - Il raffreddamento
  - 8.1 Perché serve il raffreddamento: la fisica prima del marketing
    - 8.1.1 Throttling: il freno d'emergenza
    - 8.1.2 TDP, PL1/PL2, PPT: decodificare i numeri di potenza
    - 8.1.3 Il concetto che conta davvero: la resistenza termica
    - 8.1.4 Temperature target: cosa è normale e cosa no
  - 8.2 Raffreddamento ad aria
    - 8.2.1 Descrizione e funzionamento: come funziona realmente una torre
    - 8.2.2 Formati: Come leggere le dimensioni
    - 8.2.4 Pro e contro del raffreddamento ad aria, senza retorica
    - 8.2.5 Compatibilità: le tre misure da controllare sempre
    - 8.2.6 Errori tipici dell'acquirente
    - 8.2.7 Raccomandazioni per fascia di prezzo (aria)
  - 8.3 Raffreddamento a Liquido AIO
    - 8.3.1 Descrizione e Funzione
    - 8.3.2 Dimensioni del radiatore: quale per quale CPU
    - 8.3.3 Posizionamento del radiatore e la regola dell'aria nella pompa
    - 8.3.4 Direzione dell'aria: radiatore come immissione o espulsione?

- 8.3.5 Marche e Modelli
- 8.3.6 Pro e Contro degli AIO
- 8.3.7 Errori tipici dell'acquirente (AIO)
- 8.3.8 Raccomandazioni di fascia economica (AIO a liquido)
- 8.4 Il Custom Loop: per completezza, e per capire perché quasi nessuno dovrebbe farlo
  - 8.4.1 I Componenti
  - 8.4.2 Marche
  - 8.4.3 Costi, manutenzione e a chi conviene davvero
- 8.5 Aria vs. Liquido: La Decisione Finale
- 8.6 Pasta Termica: Una Discussione Approfondita
  - 8.6.1 A cosa serve, e perché non è "un lubrificante"
  - 8.6.2 Tipi di TIM
  - 8.6.3 Come applicare: quantità e metodi
  - 8.6.4 Errori comuni
  - 8.6.5 Ogni quanto sostituirla, e repasting GPU
  - 8.6.6 Raccomandazioni per tier (pasta termica)
- 8.7 Ventole sui radiatori (e sui dissipatori)
  - 8.7.1 Airflow vs. pressione statica
  - 8.7.2 Push, pull, push-pull
  - 8.7.3 Orientamento: capire da che parte soffia una ventola
  - 8.7.4 Controllo: PWM, DC e curve
- 8.8 Riepilogo operativo — checklist decisionale per il raffreddamento
- Capitolo 9 - Assemblaggio PC, passo dopo passo
  - Introduzione: perché questo capitolo è diverso da tutti gli altri
  - 0. Preparazione: il novanta per cento del lavoro è fatto prima di aprire le scatole
    - 0.1 Gli attrezzi: pochi, ma quelli giusti
    - 0.2 Elettricità Statica (ESD): la Paura Giusta, nella Giusta Misura
    - 0.3 Il controllo finale di compatibilità: l'ultima uscita prima dell'autostrada
    - 0.4 La Strategia: Pre-assemblaggio "a banco"
  - 1. Installazione della CPU sulla scheda madre
    - 1.1 Le due filosofie: LGA e PGA
    - 1.2 La Procedura, Passo per Passo
    - 1.3 Errori comuni
  - 2. Installazione della RAM

- 2.1 Perché non tutti gli slot sono uguali: dual channel
- 2.2 La procedura
- 2.3 L'errore che colpisce tutti: il modulo semi-inserito
- 3. Installazione SSD M.2
  - 3.1 Cos'è e quale slot scegliere
  - 3.2 La procedura
- 4. Installazione del dissipatore
  - 4.1 Il principio: perché esiste la pasta termica (e dovrebbe SEMPRE essere applicata)
  - 4.2 CASO A — Dissipatore ad Aria
  - 4.3 CASO B — AIO (raffreddamento a liquido)
- 5. Preparazione del case
- 6. Installazione dell'alimentatore (PSU)
  - 6.1 Orientamento della ventola: la domanda che tutti sbagliano
  - 6.2 La Procedura
- 7. Installazione della Scheda Madre nel Case
- 8. Installazione del radiatore AIO (se presente)
  - 8.1 Dove metterlo, e la regola dell'aria nella pompa
  - 8.2 La procedura
- 9. Installazione della GPU
  - 9.1 Quale slot, e perché non è banale
  - 9.2 La procedura
  - 9.3 Alimentazione GPU: il paragrafo che può salvare la vostra casa
- 10. Cablaggio completo, uno per uno
  - 10.1 ATX 24-pin (alimentazione scheda madre)
  - 10.2 EPS 8-pin (alimentazione CPU) — il cavo più confuso di tutti
  - 10.3 PCIe / 12V-2×6 (alimentazione GPU)
  - 10.4 Alimentazione SATA e dati SATA
  - 10.5 Pannello frontale (F\_PANEL) — il puzzle dei pin
  - 10.6 Connettori dati del pannello frontale
  - 10.7 Ventole: PWM vs DC
  - 10.8 ARGB e RGB: il paragrafo salva-hardware
  - 10.9 Gestione dei cavi
- 11. Primo Avvio
  - 11.1 Lista di controllo pre-accensione
  - 11.2 Collegamento del Monitor: Alla GPU, Non alla Scheda Madre
  - 11.3 Il POST e Come Leggere le Diagnostiche

- 11.4 Se non si avvia: la procedura sistematica
- 12. Configurazione Iniziale
  - 12.1 Entrare nel BIOS/UEFI
  - 12.2 Attivare XMP / EXPO: cinque secondi, dieci percento di prestazioni
  - 12.3 Aggiornamento del BIOS
  - 12.4 Curve delle ventole e Resizable BAR
  - 12.5 Sistema operativo e installazione dei driver
  - 12.6 Test: controllo temperature e stabilità
- Riepilogo Operativo — la checklist di assemblaggio
- Capitolo 10 - CPU per Workstation AI e HEDT
  - Introduzione: perché esiste questo capitolo
  - 1. Perché una CPU Consumer non è Sufficiente
    - 1.1 Il Cambiamento di Prospettiva: La CPU come Nodo di Smistamento
    - 1.2 PCIe Lanes: La Vera Moneta della Workstation
    - 1.3 Tabella comparativa: linee per segmento di piattaforma
    - 1.4 Canali di memoria: perché la larghezza di banda della RAM è importante
    - 1.5 Capacità della RAM: i limiti reali e i moduli registrati
    - 1.6 ECC: Cos'è e perché è irrinunciabile in ambito professionale
    - 1.7 E se il consumer fosse sufficiente?
  - 2. AMD Threadripper: La Panoramica Completa
    - 2.1 Cos'è Threadripper e dove si colloca
    - 2.2 Threadripper non-PRO: Le Serie 7000X e 9000X
    - 2.3 Threadripper PRO: Le serie 7000WX e 9000WX
    - 2.4 Il Confronto Che Conta Davvero
    - 2.5 Decodifica della nomenclatura
    - 2.6 Socket sTR5, Chipset TRX50 e WRX90
    - 2.7 Perché Threadripper PRO è \*la\* piattaforma per le workstation AI
    - 2.8 Confronto tra marchi e fasce di prezzo (Threadripper)
  - 3. AMD EPYC e Intel Xeon: quando passare al server
    - 3.1 AMD EPYC (Genoa, Bergamo, Turin)
    - 3.2 Intel Xeon W e Xeon Scalable
    - 3.3 Perché AMD domina oggi nel conteggio dei core e nelle linee
    - 3.4 Server o HEDT? La decisione per un ricercatore o un piccolo team
  - 4. PCIe nelle Workstation: Approfondimento
    - 4.1 Ripasso ed Estensione
    - 4.2 Perché 2-4 GPU hanno bisogno di vere lane elettriche x16

- 4.3 Switch PCIe (PLX / Broadcom): cosa sono e quando usarli
- 4.4 Biforcazione: dividere uno slot x16
- 4.5 P2P (peer-to-peer) su PCIe vs NVLink
- 5. Scelta della Scheda Madre della Workstation
  - 5.1 Numero di Slot x16 Fisici E Elettrici
  - 5.2 Spaziatura degli Slot (il Criterio Più Sottovalutato)
  - 5.3 Canali e Slot RDIMM
  - 5.4 Rete: 10G Ethernet e oltre
  - 5.5 IPMI / BMC: gestione remota
  - 5.6 Marche e Modelli di Riferimento
  - 5.7 Alimentazione: EPS Multipli e PSU Server-Grade
  - 5.8 Raffreddamento del socket sTR5
- 6. Come dimensionare la CPU per il carico di lavoro AI
  - 6.1 Training GPU-bound: la CPU serve per il Data Loading
  - 6.2 Quando i Core Contano Davvero
  - 6.3 Configurazioni Tipiche per Fascia di Budget
  - 6.4 La regola di dimensionamento in tre righe
- 7. Errori comuni
  - Errore 1 — Acquistare Threadripper PRO per una singola GPU
  - Errore 2 — Ignorare la spaziatura degli slot
  - Errore 3 — RAM sbagliata
  - Errore 4 — Sottovalutare l'alimentazione
  - Errore 5 — Sottovalutare il raffreddamento sTR5
  - Errore 6 — Fidarsi della descrizione commerciale degli slot
  - Errore 7 — Sopravvalutare le esigenze di core, sottovalutare le esigenze di RAM
  - Errore 8 — Acquistare hardware quando era necessario il cloud
- Riepilogo Operativo: Lista di Controllo per la Decisione della CPU della Workstation AI
  - FASE 1 — Definire il Carico di Lavoro (prima di guardare un singolo prodotto)
  - FASE 2 — Calcolare le Corsie PCIe Necessarie
  - FASE 3 — Scegliere la Piattaforma in Base al Totale
  - FASE 4 — Scegliere la SKU della CPU all'interno della Piattaforma
  - FASE 5 — Scegliere la scheda madre
  - FASE 6 — Memoria
  - FASE 7 — Alimentazione e raffreddamento

- FASE 8 — Verifica post-assemblaggio (non saltarla mai)
- Capitolo 11 - GPU Nvidia per l'AI: Dalla Workstation al Datacenter
  - Nota metodologica preliminare
  - 1. La gerarchia completa di Nvidia
    - 1.1 Perché non esiste "la GPU Nvidia", ma tre mondi separati
    - 1.2 Le sette differenze che giustificano tre linee
    - 1.3 Come leggere le nomenclature
  - 2. Architetture: Cosa cambia veramente tra le generazioni
    - 2.1 Il concetto di "architettura" e "processo produttivo"
    - 2.2 Ampere (2020) — A100
    - 2.3 Hopper (2022) — H100 e H200
    - 2.5 Rubin (2026) — la generazione attuale
    - 2.6 Tabella riassuntiva generazionale
  - 3. Schede per data center, una per una
    - 3.1 Premessa: SXM contro PCIe
    - 3.2 A100 (40 GB / 80 GB)
    - 3.3 H100
    - 3.4 H200
    - 3.5 B100, B200, GB200
    - 3.6 GB200 NVL72: quando l'unità di calcolo diventa il rack
    - 3.7 Grace: perché ARM nel datacenter
  - 4. NVLink e Interconnessioni
    - 4.1 Perché PCIe non è sufficiente
    - 4.2 NVLink: Generazioni
    - 4.3 La rimozione di NVLink dalle schede consumer e professionali
    - 4.4 Oltre il nodo: InfiniBand ed Ethernet/RoCE
  - 5. Workstation e Sistemi Pre-assemblati
    - 5.1 La Linea DGX
    - 5.2 DGX Spark (precedentemente Project DIGITS)
    - 5.3 DGX Station (GB300)
    - 5.4 L'alternativa: costruirsi la propria workstation
  - 6. GPU consumer per AI: quando bastano
    - 6.1 RTX 4090 e RTX 5090
    - 7.2 Cosa significa in pratica quando si sceglie l'hardware
  - 8. Come valutare una GPU per l'AI: criteri espliciti
    - 8.1 Criterio #1: VRAM
    - 8.2 Criterio #2: Larghezza di banda della memoria

- 8.3 Criterio #3: Precisione numerica
- 8.4 Criterio #4: Interconnessione
- 8.5 Criterio #5: TDP, Potenza e Raffreddamento
- 8.6 Criterio #6: Costo per GB di VRAM
- 8.7 Criterio #7: Comprare o Noleggiare?
- 8.8 Tabella decisionale: carico di lavoro → GPU consigliata
- 9. Errori tipici dell'acquirente
- Riepilogo Operativo — Lista di Controllo per la Scelta di una GPU AI
- Capitolo 12 - GPU AMD Instinct per l'AI e il confronto Nvidia vs. AMD nel Datacenter
  - 1. La Linea AMD Instinct
    - 1.1 Cos'è, in termini elementari
    - 1.2 Posizionamento: Perché AMD Esiste in Questo Mercato
    - 1.3 CDNA vs. RDNA: Perché Due Architetture Separate
    - 1.4 Come leggere la nomenclatura Instinct
  - 2. Le schede, una per una
    - 2.1 MI250X (CDNA2, 2021) — il capitolo storico
    - 2.2 MI300X (CDNA3, fine 2023) — la scheda che ha cambiato la conversazione
    - 2.3 MI300A (l'APU) ed El Capitan
    - 2.4 MI325X (aggiornamento CDNA3, fine 2024/2025)
    - 2.5 MI350X / MI355X (CDNA4, metà 2025)
    - 2.6 La serie MI400 e la piattaforma Helios (2026)
  - 3. L'interconnessione AMD
    - 3.1 Il problema, prima della soluzione
    - 3.2 Infinity Fabric e la piattaforma OAM a 8 GPU
    - 3.3 NVLink: Cosa AMD deve battere
    - 3.4 UALink: lo standard aperto anti-NVLink
  - 4. Il punto debole: il software
    - 4.1 CUDA: capire il fossato prima di capire il ponte
    - 4.2 ROCm: cos'è e dove si trova realmente
    - 4.3 HIP: Il Ponte
    - 4.4 Lo "sconto ecosistema": perché l'hardware AMD costa meno
  - 5. Nvidia vs. AMD nel datacenter: battono o non battono?
    - 5.1 VRAM per GPU — **\*\*AMD vince\*\***, storicamente
    - 5.2 Larghezza di banda della memoria — **\*\*sostanzialmente alla pari, con testa a testa generazionale\*\***

- 5.3 Prestazioni di training — **\*\*Nvidia vince, e non di poco\*\***
  - 5.4 Prestazioni di inferenza — **\*\*AMD è competitiva, e in alcuni scenari vince\*\***
  - 5.5 TCO e Prezzo — **\*\*AMD vince sul prezzo di acquisto; il TCO dipende da te\*\***
  - 5.6 Software — **\*\*Nvidia vince, chiaramente\*\***
  - 5.7 Disponibilità — **\*\*la variabile impazzita\*\***
  - 5.8 Chi compra AMD, e perché
  - 5.9 Tabella Comparativa Finale
  - 6. Guida alla Decisione Finale per una Build AI (Parte Workstation)
    - 6.1 La Domanda Zero: Comprare o Noleggiare?
    - 6.2 Livello A — sotto i €3.000: il PC consumer di fascia alta
    - 6.3 Livello B — €5.000-€15.000: La Workstation Threadripper con 2 GPU
    - 6.4 Livello C — €15.000-€50.000: La Workstation Professionale
  - 7. Riepilogo Operativo — Lista di Controllo Decisionale
    - A) Scelta tra Nvidia e AMD nel datacenter
    - B) Lista di controllo della compatibilità per una workstation multi-GPU
-



## Capitolo 1 - La CPU nei PC Desktop Consumer

***Nota sugli aggiornamenti dei dati.** Questo capitolo è aggiornato a **Luglio 2026**. I concetti architetturali e i protocolli (PCIe, socket, cache, IPC) sono stabili nel tempo; ciò che cambia rapidamente sono i **prezzi**, le **ultime generazioni disponibili** e la **disponibilità**. Nel 2026, in particolare, si registra una condizione di mercato anomala: una **grave carenza di memoria DDR5**, con i prezzi delle RAM aumentati di 5-8 volte rispetto alla normalità. Questo distorce pesantemente il "costo totale della piattaforma" di cui parleremo, al punto che spesso un kit di RAM veloci costa più della CPU stessa. Tutti i prezzi indicati vanno quindi presi come ordine di grandezza indicativo e verificati al momento dell'acquisto.*

---

### 1. Cosa fa la CPU

#### 1.1 Definizione e Ruolo nel Sistema

L'acronimo **CPU** sta per *Central Processing Unit*. È il componente che esegue le istruzioni dei programmi: è, letteralmente, il "cervello" che coordina e controlla il resto del computer. Tutto ciò che il PC fa — aprire un file, calcolare una formula, muovere il cursore, decidere cosa inviare alla scheda video — passa in qualche forma attraverso la CPU, che ne orchestra il flusso.

Per capire *come* funziona una CPU, bisogna partire dal ciclo fondamentale che essa ripete miliardi di volte al secondo, chiamato **fetch-decode-execute**. Nella fase di *fetch*, la CPU recupera dalla memoria la prossima istruzione da eseguire; nella fase di *decode*, la interpreta, capendo quale operazione sia e quali dati coinvolga; nella fase di *execute*, la esegue effettivamente, ad esempio sommando due numeri o scrivendo un valore in memoria. Una volta completata l'esecuzione, il risultato viene scritto (fase di *write-back*) e il ciclo ricomincia con l'istruzione successiva. Questo processo, banale se descritto a parole, è ciò che accade miliardi di volte al secondo all'interno di ogni core, ed è il motivo per cui la frequenza ("GHz") ha un impatto così diretto sulle prestazioni: più cicli al secondo, più istruzioni elaborate.

La CPU non lavora da sola: comunica costantemente con gli altri componenti del sistema, e capire questa comunicazione è fondamentale per fare acquisti sensati. Con la **RAM** (*Random Access Memory*, la memoria di lavoro volatile), la CPU scambia i dati che sta usando in quel momento: la RAM è veloce ma si svuota allo

spegnimento, e la CPU ne dipende in modo critico perché è lì che tiene i dati "caldi" del programma in esecuzione. Con lo **storage** (l'unità di archiviazione, tipicamente oggi un SSD NVMe), la CPU interagisce per leggere e scrivere dati permanenti, ma lo storage è enormemente più lento della RAM, quindi i dati vengono caricati dallo storage alla RAM prima di essere elaborati. Con la **GPU** (*Graphics Processing Unit*, l'unità di elaborazione grafica, ovvero la scheda video), la CPU coopera nei carichi grafici: la CPU prepara la scena, calcola la logica di gioco, la fisica, l'intelligenza artificiale dei nemici e le istruzioni di disegno, poi "consegna" questo lavoro alla GPU che lo trasforma in pixel sullo schermo. In un videogioco, quindi, CPU e GPU si passano continuamente il testimone, e se una delle due è troppo lenta rispetto all'altra, si verifica il fenomeno del *bottleneck*, di cui parleremo nella sezione dedicata alla scelta.

## 1.2 CPU vs GPU: Due Paradigmi di Calcolo (Seriale vs. Parallelo)

Una delle confusioni più comuni per chi si avvicina all'hardware è pensare che CPU e GPU siano "la stessa cosa, una più potente dell'altra". In realtà, sono due filosofie di calcolo profondamente diverse, e questa differenza spiega perché siano necessarie entrambe.

La CPU è ottimizzata per il **calcolo seriale complesso**: ha pochi core molto sofisticati (tipicamente da 4 a 24 nei desktop consumer), ciascuno capace di eseguire un'ampia varietà di operazioni e di prendere decisioni complesse rapidamente, gestendo salti condizionali, eventi inattesi e dipendenze tra istruzioni. È come avere pochi ingegneri brillantissimi, ciascuno capace di risolvere problemi difficili e diversi, ma uno alla volta con grande cura.

La GPU, d'altra parte, è ottimizzata per il **calcolo massivo parallelo**: ha migliaia di unità di calcolo molto più semplici, ciascuna individualmente non molto intelligente, ma tutte insieme capaci di eseguire la stessa operazione su enormi quantità di dati simultaneamente. È come avere un esercito di migliaia di operai, ciascuno capace solo di svolgere un compito semplice, ma che insieme possono dipingere un'enorme parete in pochi secondi perché lavorano tutti in parallelo. Questo è esattamente ciò che serve per la grafica (calcolare il colore di milioni di pixel simultaneamente) e, non a caso, anche per l'addestramento di reti neurali di intelligenza artificiale, che è calcolo parallelo su matrici.

La conseguenza pratica è chiara: i compiti *sequenziali* e ricchi di decisioni (logica di gioco, compilazione di codice, apertura di un foglio di calcolo) girano meglio sulla CPU; i compiti *massivamente paralleli e ripetitivi* (rendering 3D, calcolo

grafico, deep learning) girano molto meglio sulla GPU. Nessuno dei due sostituisce l'altro, ed è per questo che un PC bilanciato ha bisogno di entrambi adeguatamente dimensionati.

---

## 2. Architettura Interna della CPU

### 2.1 Core Fisici: Cosa Sono e Perché Contano

Un **core** è un'unità di elaborazione completa e indipendente all'interno della CPU: è, in pratica, un piccolo processore autonomo, capace di eseguire il proprio ciclo fetch-decode-execute in modo indipendente. Una CPU con 8 core contiene 8 di questi motori di calcolo affiancati sullo stesso pezzo di silicio.

Il numero di core conta perché determina quante attività *veramente indipendenti* la CPU può svolgere simultaneamente. Con un singolo core, il computer può eseguire un'istruzione alla volta (e simula il multitasking passando rapidamente tra i programmi); con più core, può eseguire veramente più flussi di lavoro in parallelo. Attenzione, però, a un errore comune: *non tutti i programmi sanno usare più core*. Un software si dice "multi-threaded" quando è scritto per dividere il proprio lavoro in porzioni parallele; molti giochi, soprattutto quelli più vecchi, e molte applicazioni di uso quotidiano, rimangono però prevalentemente "single-threaded", ovvero utilizzano efficacemente solo uno o due core. Per questo, per il gaming, "più core" oltre una certa soglia (oggi 6-8 core sono più che sufficienti per la stragrande maggioranza dei titoli) offre rendimenti decrescenti, mentre per il rendering video, la compilazione, la virtualizzazione e il calcolo scientifico, i core aggiuntivi sono preziosissimi.

### 2.2 Thread e SMT/Hyper-Threading: Differenza Tra Core e Thread

Un **thread** è un singolo flusso di istruzioni ordinato. La confusione tra "core" e "thread" nasce da una tecnologia chiamata **SMT** (Simultaneous Multi-Threading), che Intel commercializza con il nome **Hyper-Threading**. Grazie all'SMT, un singolo core fisico può gestire *due thread contemporaneamente*, presentandosi al sistema operativo come se fossero due core "logici".

Il trucco funziona perché un core, mentre esegue un thread, ha spesso delle unità interne inattive: magari sta aspettando dati dalla memoria, e nel frattempo alcuni dei suoi circuiti computazionali restano oziosi. L'SMT riempie quei "buchi" con il lavoro di un secondo thread, sfruttando meglio le risorse esistenti. Il guadagno tipico è nell'ordine del 15-30% di throughput in più in carichi di lavoro ben

parallelizzati: non raddoppia le prestazioni (due thread su un core non equivalgono a due core), ma è un aumento di efficienza "gratuito".

Quando i thread aiutano e quando no? Aiutano nei carichi di lavoro pesantemente multi-threaded e paralleli (rendering, compressione, virtualizzazione, editing pesante), dove mantenere le unità del core costantemente occupate offre un vantaggio concreto. Aiutano poco o per nulla in molti giochi e carichi di lavoro single-thread, dove ciò che conta è la velocità del singolo thread. In alcuni casi estremi, in passato, l'SMT poteva persino ridurre marginalmente le prestazioni nei giochi a causa della contesa di risorse, ed è uno dei motivi per cui a volte se ne consigliava la disattivazione per specifiche competizioni e-sports. Un fatto notevole e recente: **Intel, con l'architettura Arrow Lake (Core Ultra serie 2, dal 2024), ha abbandonato l'Hyper-Threading sui desktop**, concentrandosi invece su un maggior numero di core efficienti. AMD, d'altro canto, mantiene l'SMT su tutta la sua gamma Ryzen. Di conseguenza, oggi, contare i "thread" per confrontare direttamente Intel e AMD è diventato fuorviante: bisogna guardare all'architettura complessiva e ai benchmark.

### 2.3 Frequenza Base vs. Frequenza Boost

La **frequenza di clock** misura quanti cicli al secondo il core completa, espressa in gigahertz (GHz, miliardi di cicli al secondo). Le CPU moderne non hanno una sola frequenza ma almeno due valori dichiarati. La **frequenza base** è quella garantita in condizioni di carico prolungato, entro i limiti standard di consumo energetico e temperatura: è il "minimo sindacale" che la CPU mantiene sempre. La **frequenza boost** (o *turbo*) è il massimo che la CPU raggiunge opportunisticamente quando ha margine termico ed energetico, per accelerare i picchi di lavoro.

È fondamentale distinguere tra due tipi di boost. Il **single-core boost** è la frequenza massima raggiungibile quando è impegnato un solo core (o pochissimi): è alta perché il calore è concentrato in un unico punto e c'è ampio margine, ed è il valore prominentemente pubblicizzato sulla confezione. L'**all-core boost**, d'altra parte, è la frequenza sostenuta quando *tutti* i core lavorano insieme: è sempre inferiore al picco single-core, perché il calore prodotto da tutti i core simultaneamente è molto maggiore e deve essere dissipato. Questa distinzione ha importanti conseguenze pratiche: per un gioco, che spesso sollecita pochi core, il single-core boost è importante; per un rendering che carica tutti i core al 100%, contano l'all-core boost e la capacità del dissipatore di mantenerlo. Un errore comune è lasciarsi affascinare dal "5.7 GHz" scritto sulla confezione

senza capire che questo valore si applica solo a un core, per pochi istanti, e non sotto il carico di lavoro previsto.

## 2.4 Cache L1, L2, L3 e il Caso della 3D V-Cache

La **cache** è una memoria molto piccola ma molto veloce, integrata all'interno della CPU, che memorizza i dati e le istruzioni usati frequentemente per evitare di doverli richiedere ogni volta alla RAM, che è molto più lenta. La differenza di velocità è enorme: accedere alla cache costa alla CPU pochi cicli, accedere alla RAM ne costa centinaia. Ogni volta che il dato cercato è già in cache (una situazione chiamata *cache hit*), la CPU risparmia un'enorme attesa; quando non lo è (*cache miss*), deve andarlo a prendere dalla RAM, sprecando tempo prezioso. Ottimizzare la cache è quindi uno dei modi più efficaci per aumentare le prestazioni reali.

Le cache sono organizzate in livelli, in ordine crescente di dimensione e decrescente di velocità. La **cache L1** è la più piccola (poche decine di kilobyte per core) e la più veloce, privata a ogni core. La **cache L2** è più grande (da centinaia di kilobyte a pochi megabyte per core) e leggermente più lenta, anch'essa tipicamente privata al core. La **cache L3** è la più grande (da diversi megabyte fino a oltre 100 MB) ed è normalmente *condivisa* tra tutti i core: agisce come una grande riserva comune, riducendo gli accessi alla RAM per l'intero processore.

| Livello di Cache | Dimensione Tipica      | Velocità | Scopo                |
|------------------|------------------------|----------|----------------------|
| L1               | 32–80 KB per core      | Massima  | Privata al core      |
| L2               | 512 KB – 3 MB per core | Alta     | Privata al core      |
| L3               | 16 – 128 MB e oltre    | Media    | Condivisa tra i core |

La ragione per cui una cache L3 di grandi dimensioni è così importante è esemplificata in modo più eclatante dalla tecnologia **3D V-Cache** di AMD. In sostanza, AMD "impila" verticalmente un blocco aggiuntivo di memoria cache SRAM *sopra* (o, nelle versioni più recenti, *sotto*) il die di calcolo, aumentando la cache L3 a valori enormi — per esempio, 96 MB su un Ryzen 7 con 3D V-Cache. Questo si è dimostrato un enorme vantaggio, specialmente nel gaming, perché molti giochi hanno set di dati che, se tutti rientrano nella cache, evitano continui e molto costosi viaggi alla RAM, con guadagni nel frame rate che possono essere percentuali a doppia cifra. Questo è il motivo per cui i modelli AMD con il suffisso

**X3D** (come il famoso Ryzen 7 9800X3D e il più recente 9850X3D del 2026) sono considerati tra le migliori CPU da gaming di sempre. Va notato, tuttavia, che la 3D V-Cache non aiuta *ogni* gioco allo stesso modo, e il beneficio tende a diminuire all'aumentare della risoluzione (a 4K, il collo di bottiglia si sposta sulla GPU). Inoltre, storicamente, le prime generazioni X3D dovevano ridurre leggermente la loro frequenza per gestire il calore della cache impilata, penalizzando i carichi di lavoro di produttività; con le generazioni più recenti, questo compromesso è stato notevolmente mitigato.

## 2.5 IPC: perché la sola frequenza non basta

**IPC** sta per *Instructions Per Clock*: misura quanto lavoro utile un core può compiere in un singolo ciclo. È il concetto che sfata il mito che "più GHz = più veloce". La formula intuitiva per le prestazioni di un core è infatti  $prestazioni \approx IPC \times frequenza$ : due fattori moltiplicati, non solo uno.

Questo significa che una CPU moderna a 4.5 GHz può facilmente battere una CPU di dieci anni fa a 5.0 GHz, perché la prima esegue molte più istruzioni per ciclo grazie a un'architettura più efficiente (migliore predizione di diramazioni, più unità di esecuzione, cache più grandi, pipeline ottimizzate). L'IPC è la ragione per cui non è possibile confrontare i GHz tra generazioni o tra marchi diversi: questi numeri significano cose diverse a seconda dell'architettura sottostante. Ogni nuova generazione di CPU vanta tipicamente un "+X% IPC" rispetto alla precedente, ed è quel guadagno — non i GHz — a fare la vera differenza. La lezione pratica per l'acquirente è chiara: non confrontare mai le CPU per GHz, ma per benchmark, che catturano il prodotto reale  $IPC \times frequenza$ .

## 2.6 TDP e consumo reale: PL1/PL2 e PPT

**TDP** (*Thermal Design Power*) è un valore espresso in watt che, originariamente, indicava quanto calore il dissipatore deve essere in grado di dissipare affinché la CPU operi entro le specifiche. Nella pratica moderna, è diventato una cifra ambigua e spesso fuorviante, perché **non coincide con il consumo massimo effettivo della CPU** sotto carico pesante.

Intel gestisce il consumo energetico attraverso due limiti chiamati **PL1** e **PL2** (*Power Limit 1* e *Power Limit 2*). PL1 è il limite di potenza sostenuta a lungo termine e corrisponde approssimativamente al TDP nominale. PL2 è il limite di picco molto più alto che la CPU può assorbire per brevi intervalli (governati da un timer chiamato *Tau*) durante il boost. Questo è il motivo per cui una CPU con "TDP 125 W" può effettivamente assorbire 250 W o più al picco: quel numero sulla

scatola descrive il regime sostenuto, non il picco. Molte schede madri, inoltre, impostano di default limiti "sbloccati" che permettono alla CPU di consumare quanto vuole, alterando ulteriormente il quadro.

AMD utilizza una metrica diversa e più onesta chiamata **PPT** (*Package Power Tracking*), che indica il tetto di potenza effettivo che l'intero package della CPU può assorbire dal socket. Il PPT è tipicamente circa 1,35 volte il TDP nominale: una CPU AMD con "TDP 105 W" ha generalmente un PPT intorno ai 142 W, che rappresenta il reale consumo massimo a pieno carico.

La lezione pratica è duplice. Primo: il TDP non è sufficiente per dimensionare l'alimentatore o il dissipatore; è necessario guardare il reale consumo di picco (PL2 o PPT). Secondo, e cruciale per l'acquirente: comprare una CPU potente e poi abbinarla a un dissipatore inadeguato significa buttare via le prestazioni, perché la CPU, non riuscendo a dissipare il calore, riduce automaticamente la sua frequenza (un fenomeno chiamato *thermal throttling*) e non mantiene mai il boost dichiarato.

## 2.7 Architetture ibride Intel: P-cores ed E-cores

A partire dalla dodicesima generazione, Intel ha introdotto un'architettura **ibrida**, che mescola due tipi di core sullo stesso processore. I **P-cores** (*Performance cores*) sono core grandi, potenti e avidi di energia, progettati per carichi di lavoro pesanti e sensibili alla latenza, come il thread principale di un gioco. Gli **E-cores** (*Efficient cores*) sono core più piccoli e frugali, progettati per gestire in modo efficiente molti task in background e carichi di lavoro altamente paralleli, occupando poco spazio e poca energia: molti possono essere inseriti nello spazio di un P-core.

L'idea è di affidare al sistema operativo (tramite una componente hardware chiamata *Thread Director* che suggerisce come distribuire il lavoro) il compito di assegnare i task giusti ai core giusti: task critici ai P-cores, task secondari e massivi agli E-cores. Il risultato, quando funziona bene, è un eccellente equilibrio tra prestazioni di picco ed efficienza multi-thread. Esistono tuttavia delle implicazioni pratiche. La prima è che il numero di core Intel va letto con attenzione: un "Core Ultra 9 285K" con "24 core" ha in realtà 8 P-cores e 16 E-cores, con caratteristiche prestazionali molto diverse. La seconda è che, agli inizi, alcuni software datati (in particolare certi sistemi anti-cheat di giochi e vecchi programmi) si confondevano nell'assegnazione dei thread, portando a cali di prestazioni; il problema è stato in gran parte risolto con aggiornamenti di Windows e driver, ma è utile saperlo.



AMD, dal canto suo, adotta un approccio diverso: nei desktop consumer, utilizza tutti core identici "full-size", eventualmente combinando più gruppi di core (i cosiddetti CCD, i chiplet di calcolo), il che semplifica lo scheduling ma introduce altre sottigliezze nei modelli dual-chiplet.

## 2.8 iGPU integrata: quando serve e quando no

Molte CPU integrano una **iGPU** (*integrated GPU*): una piccola scheda video integrata nel processore stesso. Non ha la potenza di una scheda video dedicata, ma è sufficiente per visualizzare il desktop, riprodurre video, navigare e giocare a giochi leggeri. La sua presenza o assenza è direttamente codificata nei suffissi commerciali, ed è fonte di costosi errori di acquisto.

Per **Intel**, il suffisso **F** (ad esempio, "Core Ultra 5 245KF") indica una CPU *senza iGPU funzionante*: costa qualche decina di euro in meno, ma richiede tassativamente una scheda video dedicata per funzionare, altrimenti non verrà visualizzato nulla a schermo. Per **AMD**, il ragionamento è inverso e più insidioso: la maggior parte delle CPU Ryzen desktop "normali" ha solo una iGPU minimale, appena sufficiente per il desktop; i modelli pensati davvero per giocare senza scheda video dedicata sono le **APU** contraddistinte dal suffisso **G** (come il Ryzen 7 8700G), che integrano una grafica Radeon molto più potente, capace di far girare dignitosamente diversi giochi a 1080p con dettagli ridotti.

Quando serve una iGPU (o una APU)? Serve per un ufficio, un media center, un PC secondario, o un PC economico da usare in attesa di comprare una scheda video, e funge da "rete di sicurezza" per diagnosticare guasti della GPU dedicata. Non serve, ed è inutile pagarla, se comunque verrà installata una potente scheda video dedicata per giocare: in quel caso, scegliere un modello con suffisso **F** (Intel) può far risparmiare qualche soldo. L'errore classico, di cui parleremo alla fine, è comprare una CPU "F" pensando di risparmiare e poi accorgersi di non avere alcuna scheda video per accendere il PC.

---

## 3. Il socket: compatibilità tra CPU e scheda madre

### 3.1 Cos'è fisicamente un socket

Il **socket** è il connettore fisico sulla scheda madre dove si inserisce la CPU: è l'interfaccia meccanica ed elettrica che collega i mille e più contatti del processore alle tracce sulla scheda. Il socket determina rigidamente *quali* CPU possono essere montate su una data scheda madre: una CPU può funzionare solo su un socket per



cui è stata progettata, punto. È la prima e più assoluta regola di compatibilità dell'intero sistema.

Esistono due principali filosofie costruttive. Nelle **LGA** (*Land Grid Array*), i pin — cioè i contatti metallici — sono *sul socket della scheda madre*, mentre la CPU ha solo dei pad piatti (le *lands*) che vi si appoggiano. Nelle **PGA** (*Pin Grid Array*), è l'opposto: i pin sono *sulla CPU*, e il socket della scheda madre ha i fori corrispondenti. La differenza ha conseguenze pratiche sulla fragilità: in PGA, se si piega un pin, si danneggia la costosa CPU; in LGA, un pin piegato è sul socket della scheda madre (comunque difficile da riparare, ma spesso è la mobo ad essere a rischio). Intel usa da anni il formato LGA; AMD ha usato a lungo PGA sulla piattaforma AM4 ma è passata a LGA con la nuova piattaforma AM5.

### 3.2 Socket AMD attuali e recenti: AM4 e AM5

AMD ha costruito un'enorme reputazione sulla **longevità delle piattaforme**, intendendo con ciò la sua capacità di supportare molte generazioni di CPU sullo stesso socket, permettendo upgrade senza cambiare la scheda madre. Il socket **AM4** (formato PGA) ne è l'esempio principe: introdotto nel 2016, ha supportato un'impressionante gamma di generazioni Ryzen, dai primi Ryzen 1000 fino ai Ryzen 5000 (e AMD ha continuato a lanciare nuovi modelli su di esso anche anni dopo, celebrandone i "10 anni" nel 2026 con edizioni speciali). Chi ha comprato una buona scheda madre AM4 nel 2017 ha potuto, anni dopo, installare una CPU molto più potente con un semplice aggiornamento firmware.

Il socket **AM5** (formato LGA, dal 2022) è l'attuale piattaforma di AMD per le serie Ryzen 7000 e 9000 (e i loro modelli X3D). Introduce il supporto obbligatorio per la memoria **DDR5** e il **PCIe 5.0**. Anche qui, AMD ha promesso e confermato una lunga longevità: **il supporto AM5 è garantito almeno fino al 2029**, il che rende una scheda madre AM5 acquistata oggi un investimento ragionevolmente a prova di futuro, in grado di ospitare anche le prossime generazioni. Vale la pena notare che le CPU di prossima generazione basate sull'architettura Zen 6 (la famiglia "Ryzen 10000", nome in codice "Olympic Ridge") sono state, secondo le indiscrezioni di metà 2026, **posticipate al 2027**, e rimarranno comunque sul socket AM5: chi acquista AM5 oggi sarà molto probabilmente aggiornabile anche a quella generazione.

### 3.3 Socket Intel attuali e recenti: LGA1700 e LGA1851

Intel ha storicamente avuto una politica opposta a quella di AMD: **cambia i socket molto più frequentemente**, tipicamente ogni una o due generazioni,

costringendo spesso chi aggiorna la propria CPU a cambiare anche la scheda madre. Il numero nel nome del socket (tutti in formato LGA) indica il numero di contatti. Il socket **LGA1700** ha ospitato le generazioni Intel dalla dodicesima alla quattordicesima (Core di 12a, 13a e 14a gen), con supporto sia per DDR4 che per DDR5 a seconda della scheda madre.

Il socket attuale è **LGA1851**, introdotto con la serie **Core Ultra 2 "Arrow Lake"** (2024) e con il loro aggiornamento **"Arrow Lake Refresh" / Core Ultra 200S Plus** a marzo 2026 (modelli come il 270K Plus e il 250K Plus). LGA1851 supporta esclusivamente DDR5. Qui, tuttavia, entra in gioco il classico avvertimento sulla politica di Intel: **LGA1851 è già a fine vita**. I chipset della serie 800 sono l'ultima generazione per questo socket, e Intel introdurrà un nuovo socket (denominato **LGA1954**) per la prossima generazione "Nova Lake" nella seconda metà del 2026. In pratica, acquistare una piattaforma Intel LGA1851 oggi significa acquisire, con ogni probabilità, un "vicolo cieco" in termini di futuri aggiornamenti della CPU: si potranno cambiare CPU solo all'interno della famiglia attuale. Questo è un fattore decisivo nella scelta tra Intel e AMD per chi pianifica aggiornamenti a distanza di anni.

| Socket  | Prodotto re | Tipo | Generazi oni CPU           | Memoria    | PCIe (dalla CPU) | Stato (Lug. 2026)                                |
|---------|-------------|------|----------------------------|------------|------------------|--------------------------------------------------|
| AM4     | AMD         | PGA  | Ryzen 1000–5000            | DDR4       | 4.0              | Legacy, ma ancora venduto (segment o budget)     |
| AM5     | AMD         | LGA  | Ryzen 7000–9000 (e futuri) | DDR5       | 5.0              | <b>Attuale</b> , supportat o almeno fino al 2029 |
| LGA1700 | Intel       | LGA  | Core 12a–14a gen           | DDR4/ DDR5 | 5.0              | Preceden te, ancora disponibi le                 |
| LGA1851 | Intel       | LGA  | Core Ultra 200S /          | DDR5       | 5.0              | <b>Attuale</b> , ma a fine ciclo (in             |

|  |  |  |           |  |  |                    |
|--|--|--|-----------|--|--|--------------------|
|  |  |  | 200S Plus |  |  | arrivo<br>LGA1954) |
|--|--|--|-----------|--|--|--------------------|

### 3.4 Come verificare la compatibilità: socket + chipset + BIOS

La verifica della compatibilità richiede il controllo di *tre* livelli, non solo del socket. Il primo livello è, ovviamente, il **socket**: CPU e scheda madre devono avere lo stesso socket. Il secondo livello è il **chipset**, che è il "controllore" sulla scheda madre che gestisce le connessioni periferiche (porte, linee PCIe del chipset, funzioni di overclock): anche con lo stesso socket, non tutte le combinazioni chipset/CPU sono valide o convenienti. Su AMD, ad esempio, i chipset di fascia alta (serie X, come X670E o X870E) abilitano più funzionalità e l'overclocking, mentre quelli di fascia media (serie B) sono più economici ma limitati; su Intel, esiste una distinzione simile, con i chipset "Z" (es. Z890) che sbloccano l'overclocking e i chipset "B" più economici che non lo fanno. Il terzo livello, spesso dimenticato, è la **versione del BIOS/UEFI** (il firmware della scheda madre): una scheda madre rilasciata prima di una certa CPU potrebbe non riconoscerla finché il suo firmware non viene aggiornato. È un errore molto comune acquistare una scheda madre che è "compatibile sulla carta" e trovarla non responsiva perché ha un BIOS troppo vecchio per la CPU appena acquistata.

Il modo corretto di procedere è consultare la **lista di supporto CPU** (l'elenco ufficiale delle CPU supportate) per quel modello specifico sul sito web del produttore della scheda madre, che indica la versione minima del BIOS richiesta per ogni CPU. È un controllo di due minuti che fa risparmiare giorni di frustrazione.

### 3.5 Retrocompatibilità e aggiornamenti BIOS senza CPU (flashback)

Il problema del "BIOS troppo vecchio" ha una soluzione elegante offerta da molte schede madri di fascia media e alta: il **BIOS Flashback** (chiamato anche *Q-Flash Plus* o simili a seconda del marchio). Questa funzione permette di **aggiornare il BIOS senza avere CPU, RAM o scheda grafica installate**: basta scaricare il file del BIOS su una chiavetta USB, inserirla in una porta specifica, premere un pulsante dedicato sulla scheda, e la scheda si aggiorna da sola usando solo l'alimentazione. È preziosissimo nel caso classico: ho comprato una nuova CPU e una scheda madre più vecchia che non la riconosce; senza flashback, sarei bloccato, perché per aggiornare il BIOS avrei bisogno di una CPU già supportata da installare temporaneamente. Con il flashback, risolvo tutto in dieci minuti. Chiunque acquisti una nuova piattaforma o pianifichi aggiornamenti dovrebbe

considerare la presenza di questa funzionalità un requisito quasi indispensabile nella scelta di una scheda madre.

---

## 4. PCI Express: il trattamento completo

Questa è la sezione più densa del capitolo, perché il **PCIe** è il "sistema nervoso" che collega la CPU alla scheda grafica, agli SSD veloci e ad altre espansioni, ed è fonte di enormi incomprensioni.

### 4.1 Cos'è il PCIe: un bus seriale punto-punto

**PCIe** sta per *Peripheral Component Interconnect Express*: è lo standard di interconnessione ad alta velocità che permette a CPU e periferiche di scambiare dati. La sua caratteristica architettonica fondamentale è che è un bus **seriale** e **punto-punto**. "Seriale" significa che i dati viaggiano in fila su percorsi stretti ma molto veloci, invece che in parallelo su molti fili come negli standard più vecchi: paradossalmente, a queste frequenze, inviare dati in serie su pochi canali molto veloci è più efficiente e affidabile che distribuirli su molti fili paralleli che rischiano di "desincronizzarsi". "Punto-punto" significa che ogni dispositivo ha la sua connessione dedicata con l'host, senza doverla condividere e senza contendere la larghezza di banda con altri, come avveniva con i bus condivisi del passato.

### 4.2 Corsie (Lanes): cosa significano x1, x4, x8, x16

L'unità base del PCIe è la **corsia** (lane). Una corsia è una singola connessione seriale bidirezionale, fisicamente composta da due coppie di fili: una coppia per la trasmissione e una per la ricezione, in modo che i dati possano fluire in entrambe le direzioni simultaneamente (*full duplex*). Le corsie possono essere aggregate per aumentare la larghezza di banda: le designazioni **x1**, **x4**, **x8**, **x16** indicano quante corsie sono raggruppate per una data connessione. Uno slot "x16" utilizza 16 corsie in parallelo e offre quindi sedici volte la larghezza di banda di una singola corsia; uno slot "x4" ne usa quattro, e così via.

Questo ha una duplice natura, *fisica* ed *elettrica*, che causa molta confusione. Uno slot può essere **fisicamente** lungo come un x16 (cioè, avere lo spazio meccanico per 16 corsie) ma essere **elettricamente** collegato solo a x4 o x8, il che significa che ha effettivamente un numero inferiore di corsie cablate. Questa è una situazione molto comune sulle schede madri economiche: il secondo slot lungo, che sembra un x16, in realtà funziona a x4. Il dispositivo si adatta e funziona

comunque, ma alla larghezza di banda ridotta delle corsie effettivamente presenti. Per questo motivo, quando si leggono le specifiche tecniche di una scheda madre, bisogna sempre distinguere la lunghezza fisica dello slot dal numero effettivo di corsie elettriche (spesso indicato con notazioni come "x16 (x8 electrical)").

#### 4.3 Generazioni: PCIe 3.0, 4.0, 5.0 e un breve accenno al 6.0

Ogni nuova generazione di PCIe **raddoppia** la larghezza di banda per corsia rispetto alla precedente, a parità di numero di corsie. Questo raddoppio generazionale è la chiave per capire tutto il resto. La seguente tabella riassume la larghezza di banda unidirezionale approssimativa per configurazione (i valori "utili" effettivi sono leggermente inferiori a causa dell'overhead di codifica, ma l'ordine di grandezza e i rapporti sono corretti):

| Generazione | Larghezza di banda per corsia (~) | x4 (NVMe tipico) | x16 (GPU tipica) | Diffusione (Lug. 2026)                               |
|-------------|-----------------------------------|------------------|------------------|------------------------------------------------------|
| PCIe 3.0    | ~1 GB/s                           | ~4 GB/s          | ~16 GB/s         | Legacy, ancora comune sui chipset                    |
| PCIe 4.0    | ~2 GB/s                           | ~8 GB/s          | ~32 GB/s         | Standard consolidato, ottimo rapporto q/p            |
| PCIe 5.0    | ~4 GB/s                           | ~16 GB/s         | ~64 GB/s         | Top consumer attuale (GPU e SSD di fascia alta)      |
| PCIe 6.0    | ~8 GB/s                           | ~32 GB/s         | ~128 GB/s        | Emergente, attualmente in ambienti server/datacenter |

Il PCIe 6.0, che raddoppia ancora, è tecnicamente definito e sta arrivando nel mondo enterprise, ma sui desktop consumer a metà 2026 non è ancora rilevante: le CPU e le schede madri consumer arrivano al PCIe 5.0. Ne parleremo più in dettaglio nel capitolo sulle workstation e i server, dove la larghezza di banda estrema conta davvero.

#### 4.4 Compatibilità all'indietro tra generazioni e slot

Una delle grandi virtù di PCIe è la **piena compatibilità all'indietro e in avanti**. Un dispositivo di generazione più recente inserito in uno slot di generazione precedente (ad esempio, una GPU PCIe 5.0 in uno slot PCIe 4.0) funziona senza problemi, semplicemente negoziando la velocità della generazione più bassa tra le due. Viceversa, un dispositivo più vecchio in uno slot più recente funziona alla sua velocità. Inoltre, un dispositivo con meno linee si adatta a uno slot più lungo: una scheda x4 funziona in uno slot x16 (utilizzando solo le linee di cui ha bisogno). Tuttavia, l'inverso meccanico non funziona: una scheda x16 non si adatta fisicamente a uno slot x1 più corto, a meno che lo slot non sia "aperto" sul retro. Il messaggio pratico è rassicurante: PCIe "si arrangia" quasi sempre, adattandosi al minimo comune denominatore, e non c'è rischio di danni mescolando le generazioni; al massimo, si perde un po' di banda.

#### 4.5 Chi fornisce le linee: CPU vs. chipset, e perché è importante

Questo è il punto più sottile e importante per fare scelte informate. Le linee PCIe in un sistema provengono da **due diverse fonti**, con caratteristiche molto diverse. Alcune linee sono fornite **direttamente dalla CPU**: queste sono le più veloci e a bassa latenza, connesse direttamente al processore senza intermediari, e sono riservate ai dispositivi più esigenti in termini di banda, tipicamente lo slot della scheda grafica principale (x16) e uno o due slot NVMe primari. Altre linee sono fornite dal **chipset** della scheda madre, che è connesso alla CPU tramite un collegamento a banda limitata (una "tubazione" chiamata *DMI* su Intel o un collegamento dedicato su AMD).

Il punto cruciale è che **tutte le linee del chipset condividono quella singola tubazione verso la CPU**. Se molti dispositivi connessi al chipset vengono caricati simultaneamente (SSD secondari, schede di rete, USB veloci), possono saturare il collegamento e contendersi la banda, cosa che non accade sulle linee dirette della CPU. Per questo una regola d'oro nell'assemblaggio è: **la scheda grafica e l'SSD NVMe principale vanno negli slot direttamente connessi alla CPU**, non negli slot del chipset. Il manuale della scheda madre indica sempre quali slot sono "CPU-attached" e quali "chipset-attached"; ignorare questa distinzione può portare, ad esempio, a installare un SSD veloce in uno slot che ne dimezza le prestazioni.

#### 4.6 Quante linee hanno le CPU consumer rispetto a HEDT e server

Le moderne CPU consumer forniscono un numero **limitato** di linee PCIe dirette: tipicamente **da 20 a 28 linee** (ad esempio, 16 per la GPU, 4–8 per gli SSD NVMe e alcune per la connessione al chipset). Questo potrebbe sembrare poco, e in effetti lo è: è una scelta di posizionamento, poiché AMD e Intel riservano un'abbondanza di linee per piattaforme di fascia più alta e più costose. Le piattaforme **HEDT** (*High-End Desktop*) e **server** — come AMD Threadripper ed EPYC, o Intel Xeon — offrono un numero enormemente maggiore di linee, nell'ordine di **64, 128 o più**. Questa abbondanza è ciò che permette a una workstation di montare simultaneamente più GPU, decine di SSD, schede di acquisizione, schede di rete da 100 gigabit e altro ancora, il tutto a piena banda e senza contese. Questo è un argomento che approfondiremo nel capitolo dedicato alle workstation; per ora, basti dire che *il numero di linee è uno dei muri invisibili che separano il mondo consumer da quello professionale*, ed è spesso la vera ragione per cui certi utenti "estremi" hanno bisogno di aggiornare la propria piattaforma.

#### 4.7 Biforcazione: cos'è e quando è necessaria

La **biforcazione** è la capacità di **dividere un singolo slot x16 in più connessioni indipendenti più piccole**, ad esempio, in due x8, o quattro x4. La CPU ha un certo numero di lane fisiche; la biforcazione permette di riallocarle in modo diverso dal raggruppamento predefinito. Il caso d'uso tipico per il consumatore è installare una scheda di espansione che ospita più SSD NVMe (una "scheda quad M.2") in un singolo slot x16, chiedendo alla scheda madre di dividere quelle 16 lane in quattro gruppi x4, uno per ogni SSD. È utile anche per chi vuole due schede grafiche a x8/x8 invece di una sola a x16. La biforcazione non è obbligatoria, e non tutte le schede madri la supportano (va verificata nel BIOS e nelle specifiche): è una funzionalità da controllare *prima* dell'acquisto se si ha in mente uno di questi scenari. Per l'utente medio, che installa una GPU e uno o due SSD nei rispettivi slot, non è un fattore rilevante.

#### 4.8 Impatto pratico: GPU su x8 vs x16, NVMe Gen4 vs Gen5

Concludiamo con le domande pratiche più frequenti. La prima: **una scheda grafica su x8 perde prestazioni rispetto a x16?** La risposta, sorprendente per molti, è: quasi sempre no, o molto poco. Le schede grafiche moderne, anche di fascia alta, raramente saturano la banda di uno slot x16 di generazione recente; se lo slot è di una generazione moderna (PCIe 4.0 o 5.0), farlo funzionare a x8 di quella generazione lascia comunque una banda enorme, e la perdita effettiva di frame rate è tipicamente nell'ordine di pochi punti percentuali, spesso

impercettibile. Diventa più significativa solo su generazioni molto vecchie o con schede al limite della loro banda. Questo rassicura chi, per installare più dispositivi, si ritrova la GPU a funzionare a x8.

La seconda: **vale la pena un SSD NVMe PCIe 5.0 (Gen5) rispetto a un Gen4?**

Sulla carta, il Gen5 raddoppia la banda sequenziale, e nei benchmark che coinvolgono trasferimenti enormi, la differenza è notevole. Nell'uso quotidiano reale, tuttavia, il vantaggio è molto meno percepibile di quanto i numeri suggeriscano, perché la maggior parte delle operazioni comuni (avvio del sistema, apertura programmi, caricamento giochi) dipendono più dalle prestazioni casuali su piccoli file che dalla banda sequenziale di picco. Inoltre, gli SSD Gen5 tendono a costare di più, scaldano di più e richiedono dissipatori più seri. Per l'utente tipico, un buon Gen4 offre attualmente il miglior rapporto qualità-prezzo; il Gen5 ha senso per specifici carichi di lavoro professionali di editing video con file giganteschi o per chi semplicemente vuole il massimo assoluto a prescindere.

---

## 5. Nomenclatura Commerciale: Come Leggere il Nome di una CPU

Saper "decodificare" il nome di una CPU è un'abilità pratica che previene molti errori. Vediamo i due produttori.

### 5.1 Intel: Da Core i a Core Ultra

Per quasi quindici anni, Intel ha usato lo schema **Core i3 / i5 / i7 / i9**, dove il numero indica il livello di prestazioni crescente: i3 entry, i5 fascia media, i7 fascia alta, i9 enthusiast. Il modello si leggeva così: dopo la designazione veniva la **generazione** (ad esempio, "14" in "i7-14700K" indicava la quattordicesima generazione), seguita dal numero di identificazione del modello e da un **suffisso** letterale.

Dal 2023–2024, Intel ha cambiato il suo branding: è stata introdotta la nomenclatura **Core Ultra**, con i livelli **Core Ultra 5 / 7 / 9** (e "Core" senza Ultra per i livelli inferiori), abbandonando il vecchio "i". Sui desktop, questa nuova famiglia è la serie **Core Ultra 200S "Arrow Lake"** (ad esempio, "Core Ultra 9 285K"), con il refresh del 2026 identificato dal suffisso **"Plus"** (ad esempio, "Core Ultra 7 270K Plus"). La logica di lettura rimane simile: livello (5/7/9), poi il numero di modello, poi i suffissi.

I **suffissi Intel** sono la parte che più spesso causa confusione. Ecco il loro significato:



| Suffisso Intel           | Significato                                                                                                          |
|--------------------------|----------------------------------------------------------------------------------------------------------------------|
| <b>K</b>                 | Moltiplicatore sbloccato: <b>overclockabile</b> . Frequenze più alte, richiede chipset "Z" e buon raffreddamento.    |
| <b>KF</b>                | Come K (sbloccato) ma <b>senza iGPU</b> : richiede una scheda grafica dedicata.                                      |
| <b>F</b>                 | <b>Senza iGPU funzionante</b> : richiede una scheda grafica dedicata. Costa un po' meno.                             |
| <b>T</b>                 | Versione a <b>basso consumo</b> (TDP ridotto), per sistemi compatti/silenziosi; prestazioni inferiori.               |
| <b>(nessun suffisso)</b> | Modello standard, con iGPU, non overclockabile ma efficiente.                                                        |
| <b>S</b>                 | Storicamente indicava versioni "special edition"; oggi "S" identifica principalmente la <i>serie desktop</i> (200S). |

Un "Core Ultra 5 245KF" si legge quindi come: fascia media (5), modello 245, **K**=overclockabile, **F**=senza grafica integrata (richiede una GPU dedicata).

## 5.2 AMD: La Logica Ryzen

AMD utilizza lo schema **Ryzen 3 / 5 / 7 / 9**, con lo stesso principio di livelli crescenti: Ryzen 3 entry-level, Ryzen 5 fascia media, Ryzen 7 fascia alta, Ryzen 9 enthusiast. Dopo il livello segue un numero a **quattro cifre** dove la prima cifra indica la **serie/generazione**: 5000, 7000, 9000. Attenzione a una trappola: la serie 8000 per desktop (APU 8700G, ecc.) è, a livello architetturale, un po' fuori sequenza rispetto alle 7000/9000, ed è dedicata principalmente alle APU con grafica potente. Anche nel caso di AMD, i suffissi finali sono cruciali:

| Suffisso AMD | Significato                                                                                                       |
|--------------|-------------------------------------------------------------------------------------------------------------------|
| <b>X</b>     | Frequenze più alte e boost migliore rispetto al modello base; tutti i Ryzen desktop sono comunque overclockabili. |
| <b>X3D</b>   | Dotato di <b>3D V-Cache</b> : enorme cache L3, il top per il <b>gaming</b> (es. 9800X3D, 9850X3D).                |
| <b>G</b>     | <b>APU</b> : grafica integrata Radeon potente,                                                                    |

|                          |                                                                                                         |
|--------------------------|---------------------------------------------------------------------------------------------------------|
|                          | gioca a 1080p senza scheda grafica dedicata (es. 8700G).                                                |
| <b>GE</b>                | Come G ma a <b>basso consumo</b> (versione efficiente delle APU).                                       |
| <b>F</b>                 | <b>Nessuna grafica integrata</b> (raro nei desktop AMD; es. 8700F), richiede una GPU dedicata.          |
| <b>(nessun suffisso)</b> | Modello standard "non-X", frequenze leggermente inferiori ma spesso ottimo rapporto prezzo/prestazioni. |

Un "Ryzen 7 9800X3D" si legge quindi come: fascia alta (7), serie 9000, **X3D**=con 3D V-Cache progettata per il gaming. Nota importante e a volte controintuitiva: nei desktop AMD, *tutte* le CPU hanno il moltiplicatore sbloccato e sono in linea di principio overclockabili (a differenza di Intel, dove serve una "K"); la "X" indica solo un migliore binning e boost out of the box, non lo "sblocco".

### 5.3 Threadripper e Xeon: solo un accenno

Oltre alle linee consumer, esistono linee professionali: **Ryzen Threadripper** (AMD) e **Xeon** (Intel) sono processori HEDT e server con molti core e molte linee PCIe, socket dedicati, supporto per grandi quantità di RAM (spesso con correzione errori ECC) e prezzi di tutt'altra entità. Non sono pensati per il gaming o l'uso domestico, ma per workstation professionali, calcolo e datacenter. Li tratteremo ampiamente nel capitolo dedicato alle workstation; qui basti sapere che esistono e rappresentano un mondo a parte rispetto a quanto descritto in questo capitolo.

---

## 6. Confronto tra marchi: Intel vs. AMD

Va premesso che "chi è meglio" cambia costantemente ad ogni generazione, e le seguenti considerazioni riflettono la situazione a metà 2026: andranno riverificate al momento dell'acquisto.

### 6.1 Punti di forza attuali

Nel **gaming puro**, AMD ha attualmente un vantaggio piuttosto netto grazie ai modelli **X3D** con 3D V-Cache, che sono considerati le CPU da gaming più veloci sul mercato (il Ryzen 7 9800X3D e il più recente 9850X3D del 2026 dominano le classifiche di frame rate). Intel, dopo un debutto deludente di Arrow Lake nel gaming, ha recuperato terreno con il refresh "200S Plus" nel 2026 e con ottimizzazioni software (come lo strumento di ottimizzazione del codice di gioco

introdotto con il refresh), ma nel gaming di fascia alta AMD rimane il punto di riferimento.

Nella **produttività multi-thread** (rendering, compilazione, calcolo), i due marchi sono paragonabili a seconda del modello e del prezzo: i Ryzen 9 ad alto numero di core e le CPU Intel con abbondanza di E-core sono entrambi molto validi, ed è consigliabile guardare benchmark specifici per il proprio software. Sul fronte dell'**efficienza energetica**, Intel ha fatto notevoli progressi con Arrow Lake, che consuma e scalda molto meno rispetto alle disastrose generazioni precedenti (le CPU Core di 13a/14a gen erano note per gli alti consumi e i problemi di degrado); AMD rimane molto competitiva, e i suoi modelli X3D in particolare offrono prestazioni gaming elevatissime a consumi contenuti.

Sul **rapporto prezzo/prestazioni**, il refresh 2026 di Intel ha rimesso in gioco modelli molto aggressivi: il Core Ultra 5 250K Plus a circa \$199 e il 270K Plus a circa \$299 sono stati accolti come ottimi affari per la produttività. AMD risponde con la sua lineup consolidata e, soprattutto, con il valore della piattaforma a lungo termine, di cui parleremo subito.

## 6.2 Piattaforma: costo totale e longevità

Il confronto non va fatto solo sulla CPU, ma sul **costo totale della piattaforma**, che include CPU + scheda madre + RAM. Qui, il tema della **longevità del socket** gioca un ruolo determinante. Acquistare AMD **AM5** oggi significa acquistare una piattaforma con supporto garantito almeno fino al 2029: una scheda madre AM5 potrà ospitare anche le future CPU (Zen 6/Ryzen 10000, attese nel 2027), permettendo un futuro upgrade della sola CPU senza cambiare scheda madre e RAM. Acquistare Intel **LGA1851** oggi, invece, significa acquistare un socket già a fine vita, che verrà sostituito da LGA1954 nella seconda metà del 2026: i futuri upgrade della CPU saranno limitati all'attuale famiglia, e per passare di generazione sarà necessario un cambio di scheda madre. Questo è, per molti, il singolo argomento più forte a favore di AMD per chi ragiona a lungo termine.

Tuttavia, c'è un enorme fattore contingente da considerare nel 2026: la già citata **crisi dei prezzi delle memorie DDR5**. Con prezzi delle RAM che sono multipli del normale, il "costo della piattaforma" è attualmente dominato dalla memoria più che dalla CPU o dalla scheda madre. In alcuni casi, un buon kit di RAM veloce costa più della CPU stessa. Questo consiglia, in questo particolare momento storico, di non sovradimensionare la RAM oltre il necessario e di dare un peso

ancora maggiore alla scelta di una piattaforma longeva, in modo da diluire nel tempo un investimento che oggi è particolarmente oneroso.

### 6.3 Casi d'Uso

Per il **gaming puro**, specialmente ad alti frame rate e a 1080p/1440p, la scelta più sensata oggi è una CPU AMD **X3D** (spesso anche un modello di generazione precedente rappresenta un buon affare). Per lo **streaming e gaming insieme**, dove servono core extra per l'encoding oltre che per il gioco, sono adatte sia le CPU Ryzen 7/9 che le Intel con molti E-core, a patto di avere un buon numero di thread. Per **editing e rendering**, contano i core e i thread: si cerca il miglior punteggio multi-thread per euro, e qui entrambi i marchi hanno proposte valide a seconda del budget. Per la **virtualizzazione**, contano core, thread e la quantità di RAM supportata (e, se possibile, il supporto ECC, più facile da trovare su AMD consumer): sono preferibili CPU multi-core. Per una **build economica**, oggi ci sono ottime opzioni da entrambi i lati, incluse le APU "G" di AMD che permettono di partire senza scheda grafica, e Intel di fascia bassa con un buon rapporto q/p; qui la scelta dipende molto dai prezzi locali attuali.

---

## 7. Come Valutare e Scegliere una CPU

### 7.1 Benchmark: Cosa Guardare e Cosa Non Fidarsi

I **benchmark** sono test standardizzati che misurano le prestazioni. Vanno interpretati con attenzione, scegliendo quelli rilevanti per il *vostro* specifico utilizzo. **Cinebench** misura le prestazioni di rendering ed è un buon indicatore per carichi di lavoro produttivi multi-threaded, fornendo punteggi sia single-core che multi-core. **Geekbench** è un benchmark sintetico più generale, utile per una rapida panoramica ma meno rappresentativo di carichi di lavoro specifici del mondo reale. Per il gaming, il test più significativo sono i **benchmark di gaming a 1080p** con una scheda grafica molto potente: a bassa risoluzione, la GPU non è il collo di bottiglia, quindi le differenze misurate riflettono davvero la potenza della CPU. Potrebbe sembrare controintuitivo testare le CPU da gaming a 1080p invece che a 4K, ma è proprio così che si isola il contributo della CPU: a 4K, molte CPU diverse producono lo stesso frame rate perché la GPU è il fattore limitante.

Di cosa non fidarsi? Non fidarsi dei **benchmark forniti dai produttori** senza verifica indipendente, poiché sono scelti per evidenziare i loro punti di forza. Non fidarsi di un **singolo numero sintetico** come metrica universale: una CPU

potrebbe brillare in un test e deludere nel software che usate realmente. Non fidarsi dei **GHz** come già ampiamente spiegato. L'approccio giusto è consultare recensioni indipendenti che testano le applicazioni e i giochi a cui siete interessati, guardando le medie su più titoli e i valori di *frame time* (la consistenza, non solo la media), che riflettono meglio la fluidità reale rispetto al frame rate medio.

## 7.2 Bilanciamento CPU/GPU: Evitare i Colli di Bottiglia

Un **collo di bottiglia** si verifica quando un componente è troppo lento rispetto a un altro e ne limita le prestazioni: la catena è forte solo quanto il suo anello più debole. In un PC da gaming, un **collo di bottiglia della CPU** significa che la scheda grafica potrebbe produrre più fotogrammi, ma la CPU non le fornisce dati abbastanza velocemente (tipico a frame rate elevati e bassa risoluzione, o con CPU deboli e GPU potenti); un **collo di bottiglia della GPU** è l'opposto, con la CPU in attesa della scheda grafica (tipico ad alte risoluzioni). Un certo grado di collo di bottiglia della GPU è in realtà desiderabile nel gaming ad alta risoluzione, poiché significa che si sta utilizzando appieno la scheda grafica.

Evitare un collo di bottiglia significa **bilanciare** CPU e GPU in base all'uso previsto. Un errore comune è spendere quasi l'intero budget per la GPU, abbinandola a una CPU economica (o viceversa): il componente costoso sarà limitato dall'altro. La regola pratica è dimensionare i due componenti allo stesso livello di "tier", considerando la risoluzione a cui si giocherà: a 1080p con refresh rate elevati, è necessaria una CPU potente; a 4K, si può optare per una CPU leggermente più modesta, concentrando il budget sulla GPU.

## 7.3 Overclocking: Cosa Serve e Se Conviene Ancora

L'**overclocking** (OC) è la pratica di far funzionare la CPU a frequenze superiori a quelle di fabbrica per estrarre maggiori prestazioni. Per farlo su Intel, è necessaria una CPU con suffisso **K** (moltiplicatore sbloccato) e una scheda madre con chipset **Z**; su AMD, tutte le CPU desktop sono sbloccate, ma è comunque necessario un chipset adeguato (generalmente serie B o X) e, in entrambi i casi, un **raffreddamento robusto** e un buon alimentatore, perché l'OC aumenta il consumo energetico e il calore.

Conviene ancora? Molto meno che in passato. Le CPU moderne eseguono già un "auto-overclocking" intelligente e aggressivo tramite algoritmi di boost, spingendosi al limite del margine termico disponibile: il guadagno manuale residuo è spesso modesto e comporta un costo in termini di consumo energetico e

calore significativamente maggiori, oltre a rischi per la stabilità. Oggi, ha più senso investire in un buon dissipatore (che permette alla CPU di *sostenere* i suoi boost automatici più a lungo) e, sul fronte della memoria, attivare i profili **XMP/EXPO** della RAM (che sono un "overclock certificato" della memoria, semplice e sicuro) piuttosto che dedicarsi all'overclocking manuale della CPU. Per la stragrande maggioranza degli utenti, l'overclocking estremo è diventato un hobby per appassionati piuttosto che una necessità.

#### 7.4 Raccomandazioni per fasce di prezzo

I prezzi seguenti sono ordini di grandezza indicativi per la sola CPU (mercato europeo, luglio 2026) e **devono essere verificati**, specialmente nell'attuale contesto di elevata volatilità. Ricordate inoltre di aggiungere sempre scheda madre e RAM per il costo reale della piattaforma.

| Livello  | Budget CPU (indicativo) | Caso d'uso                                                             | Approccio consigliato                                                                                                                           |
|----------|-------------------------|------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------|
| Entry    | ~100–150 €              | Ufficio, studio, gaming leggero, PC secondario                         | CPU recente 6-core; considerare APU AMD "G" per iniziare senza GPU dedicata; chipset economico (B), dissipatore stock spesso sufficiente.       |
| Mid      | ~200–350 €              | Gaming solido, produttività quotidiana, streaming leggero              | 6–8 core performanti; per il gaming, un AMD X3D è spesso il miglior investimento; scheda madre B di buona qualità, dissipatore ad aria decente. |
| High-end | 400 €+                  | Gaming di alto livello, editing/rendering pesanti, workstation leggera | Modelli top (X3D per gaming, molti core per produttività); scheda madre di fascia alta se                                                       |

|  |  |  |                                                                         |
|--|--|--|-------------------------------------------------------------------------|
|  |  |  | servono espansioni; raffreddamento a liquido o ad aria di alto livello. |
|--|--|--|-------------------------------------------------------------------------|

Un consiglio trasversale: per il *gaming*, spesso il miglior impiego del denaro è prendere una CPU X3D di fascia medio-alta e concentrare il resto del budget sulla scheda grafica, perché la GPU la fa da padrona nei frame rate ad alte risoluzioni. Per la *produttività*, al contrario, investire nei core della CPU rende di più.

---

## 8. Errori comuni dell'acquirente

Concludiamo con gli errori che, in pratica, rovinano il maggior numero di build e fanno sprecare più denaro.

Il primo, quasi un classico, è **acquistare una CPU con suffisso "F" (o "KF") senza avere una scheda grafica dedicata**. Attratti dal piccolo risparmio, ci si ritrova con un PC che non dà segnale video, perché la CPU è sprovvista di grafica integrata. Se non è prevista una GPU dedicata, questo suffisso va assolutamente evitato.

Il secondo è l'**errore di compatibilità socket o BIOS**: acquistare una CPU e una scheda madre con socket diversi, oppure una scheda madre "compatibile sulla carta" ma con un BIOS troppo vecchio per riconoscere la CPU, senza la funzione di flashback per aggiornarlo a freddo. Si evita controllando il socket, il chipset e la lista ufficiale di supporto CPU della scheda madre, con la versione minima del BIOS richiesta.

Il terzo è **abbinare una CPU potente a un dissipatore inadeguato** (o affidarsi al dissipatore "stock" incluso quando non è all'altezza). Il risultato è il thermal throttling: la CPU si surriscalda, taglia le frequenze e non mantiene mai il boost per cui si è pagato. Le CPU di fascia alta, specialmente in overclock o sotto pieno carico, richiedono un raffreddamento serio; risparmiare qui significa buttare via prestazioni pagate altrove.

Il quarto è **trascurare la RAM in relazione all'IMC**. L'IMC (*Integrated Memory Controller*) è la parte della CPU che comunica con la RAM, e le prestazioni del sistema dipendono pesantemente dall'accoppiata CPU-memoria. Installare RAM

lenta, in single channel (un solo modulo invece di due, perdendo il *dual channel* che raddoppia la banda), o dimenticare di attivare il profilo **XMP/EXPO** nel BIOS (lasciando quindi la RAM a frequenze base molto basse) sono errori che strozzano una CPU altrimenti capace. Le architetture AMD, in particolare, sono storicamente sensibili alla velocità e latenza della RAM. Nel 2026, però, va aggiunta la controfaccia: con i prezzi delle DDR5 alle stelle, esagerare con RAM ultra-veloci e ultra-capienti può costare più della CPU stessa; il giusto equilibrio è puntare a un buon kit dual-channel a una frequenza sensata, attivare il suo profilo XMP/EXPO e non sovradimensionare inutilmente.

Il quinto errore è lo **squilibrio CPU/GPU** già discusso: spendere tutto su un componente e strozzarlo con l'altro. Il sesto, più sottile, è **pagare per linee PCIe o funzionalità che non verranno usate** (schede madri costosissime comprate per semplice gaming) o, al contrario, **installare l'SSD o la GPU veloci negli slot sbagliati** (slot del chipset invece di quelli direttamente collegati alla CPU), perdendo banda senza accorgersene. Infine, un errore di prospettiva: **inseguire a tutti i costi l'ultima generazione**, quando spesso il modello della generazione precedente, ora scontato, offre il 90% delle prestazioni a una frazione del prezzo — una considerazione particolarmente valida oggi, con le nuove generazioni AMD posticipate al 2027 e l'attuale socket Intel già a fine vita.

---

## Riepilogo Operativo — Checklist Decisionale CPU

Prima dell'acquisto, rispondi a queste domande in ordine:

1. **Definisci l'uso primario.** Gaming puro, produttività/rendering, uso misto, o ufficio/budget? Questa domanda guida tutto il resto (per il gaming, guarda AMD X3D; per la produttività, conta i core).
2. **Stabilisci il budget per l'intera piattaforma, non solo per la CPU.** Somma CPU + scheda madre + RAM. Nel 2026, controlla attentamente il prezzo delle DDR5, che può essere la voce più significativa.
3. **Scegli la piattaforma pensando alla longevità.** AM5 (AMD) è supportato almeno fino al 2029 e ospiterà CPU future; LGA1851 (Intel) è a fine ciclo. Se prevedi futuri upgrade solo della CPU, questo pesa molto.
4. **Verifica la compatibilità su tre livelli:** socket identico, chipset adeguato all'uso (Z/X per overclock, B per risparmiare), e versione del BIOS supportata



(controlla la lista ufficiale di supporto CPU della scheda madre). Preferisci schede madri con BIOS Flashback.

**5. Controlla il suffisso della CPU.** Eviti "F/KF" se non hai una GPU dedicata? Ti serve una APU "G" per partire senza scheda grafica? Vuoi una "X3D" per il gaming?

**6. Dimensiona la soluzione di raffreddamento per il consumo energetico reale (PL2/PPT), non il TDP.** Accoppia la CPU scelta con un dissipatore adeguato, o perderai prestazioni a causa del throttling.

**7. Bilancia CPU e GPU** in base alla risoluzione di gioco per evitare colli di bottiglia. Non concentrare tutto il budget su un singolo componente.

**8. Pianifica RAM e PCIe correttamente:** RAM in dual channel con profilo XMP/EXPO attivo, senza sovradimensionare nel 2026; SSD NVMe principale e GPU negli slot direttamente collegati alla CPU, non al chipset.

**9. Affidati a benchmark indipendenti** per i carichi che userai realmente (gaming 1080p per isolare la CPU, Cinebench per la produttività), non ai GHz o alle slide dei produttori.

**10. Considera le generazioni precedenti scontate.** Spesso offrono gran parte delle prestazioni a molto meno, specialmente in una fase di mercato come quella attuale.

---

*Nota finale: i riferimenti a modelli, socket e prezzi riflettono lo stato del mercato a luglio 2026 (Arrow Lake Refresh "200S Plus", Ryzen 9850X3D, AM5 fino al 2029, Intel LGA1954/Nova Lake socket in arrivo, Zen 6/Ryzen 10000 attesi nel 2027, crisi dei prezzi DDR5). Controlla sempre disponibilità e listini aggiornati prima dell'acquisto.*

## Capitolo 2 - La Scheda Madre

***Nota sugli aggiornamenti dei dati.** Le informazioni architetturelle contenute in questo capitolo (funzione del chipset, gerarchia dei socket, principi dei VRM, fattore di forma, standard PCIe e USB) sono stabili e cambiano lentamente. I **prezzi**, tuttavia, sono estremamente volatili e variano in base a paese, valuta, disponibilità e promozioni: qualsiasi cifra qui indicata è da intendersi come un **ordine di grandezza indicativo** e andrà verificata al momento dell'acquisto. Anche l'elenco delle **ultime generazioni** (in particolare i chipset serie 800 di AMD e la piattaforma Intel LGA1851) è quello disponibile al momento della stesura: quando incontrerete un punto in cui i dati potrebbero essere già cambiati, lo troverete esplicitamente contrassegnato con la dicitura **[VERIFICARE]**.*

---

### 1. Cosa fa la scheda madre

#### 1.1 Definizione e ruolo di hub

La **scheda madre** (spesso abbreviata in *mobo*) è la grande scheda a circuito stampato che costituisce la spina dorsale di ogni computer. Se volessimo usare una metafora, non è il "cervello" (quello è la CPU) né i "muscoli" (la GPU): è piuttosto il **sistema nervoso e circolatorio combinato**, ovvero l'infrastruttura fisica ed elettrica su cui tutti gli altri componenti sono montati e attraverso la quale comunicano tra loro e ricevono alimentazione.

Prima di entrare nel dettaglio, è utile chiarire una sigla che comparirà frequentemente: **PCB** (*Printed Circuit Board*) è la lastra rigida, solitamente verde o nera, composta da più strati di fibra di vetro alternati a sottilissime tracce di rame. Queste tracce sono i "fili" microscopici che trasportano segnali e corrente da un capo all'altro della scheda. Una scheda madre di qualità utilizza più strati di rame (spesso da 4 a 8, a volte di più nei modelli premium) e uno spessore maggiore del rame, il che migliora l'integrità dei segnali ad alta frequenza e la capacità di trasportare corrente senza surriscaldarsi.

Il ruolo della scheda madre è quello di **hub centrale**: essa connette la CPU, la RAM, la scheda grafica (GPU), le altre schede di espansione, i dispositivi di archiviazione (SSD e hard disk), l'alimentatore (PSU) e tutte le periferiche esterne (tastiera, mouse, monitor, rete, audio). Nessuno di questi componenti "parla" direttamente con gli altri: tutto passa attraverso la scheda madre, che funge da

centralino e da rete stradale. La qualità e le caratteristiche della scheda madre determinano quindi non tanto la potenza bruta del sistema (che è fornita da CPU e GPU), quanto piuttosto **quanto e cosa si può connettere, a che velocità, con quale stabilità e con quali possibilità di espansione futura.**

## 1.2 Componenti principali sul PCB

Osservando una scheda madre dall'alto, si possono riconoscere diverse aree distinte. Le descriveremo qui in via introduttiva, per poi approfondirle in sezioni dedicate.

Il **socket della CPU** è l'alloggiamento, generalmente nella parte superiore-centrale della scheda, dove viene installato il processore. È un rettangolo pieno di minuscoli contatti; la sua forma, il numero di pin e il meccanismo di fissaggio determinano quali CPU sono compatibili. Il socket è il primo vincolo di compatibilità in assoluto: una CPU progettata per un socket non si adatterà fisicamente a un socket diverso.

Gli **slot RAM** (chiamati anche *slot DIMM*, dove **DIMM** sta per *Dual In-line Memory Module*, il formato dei moduli di memoria per desktop) sono gli slot lunghi e verticali accanto al socket, tipicamente due o quattro. Qui vengono inseriti i moduli di memoria.

Gli **slot PCIe** (*Peripheral Component Interconnect Express*) sono gli slot orizzontali nella parte inferiore della scheda. È qui che vengono installate la scheda grafica e altre schede di espansione (schede audio, schede di rete, schede di acquisizione, controller aggiuntivi). Sono disponibili in diverse lunghezze a seconda del numero di "lane" elettriche disponibili.

Il **chipset** è un piccolo microchip, spesso nascosto sotto un dissipatore di calore metallico nella metà inferiore della scheda. È il "co-processore" che gestisce le comunicazioni con le periferiche e fornisce connettività aggiuntiva. È così importante che gli dedicheremo la sezione più lunga del capitolo.

Il **VRM** (*Voltage Regulator Module*) è la fila di componenti elettronici, spesso coperta da un robusto dissipatore di calore, che circonda il socket della CPU su uno o due lati. Il suo compito è trasformare l'energia fornita dall'alimentatore in una tensione pulita e stabile adatta alla CPU.

Gli **slot M.2** sono piccoli slot orizzontali, solitamente coperti da piastre metalliche, dove vengono installati i moderni SSD in formato "gum stick". Le **porte SATA**

(*Serial ATA*) sono i connettori a forma di "L" per il collegamento di hard disk e SSD tradizionali da 2.5 o 3.5 pollici.

Infine, ci sono i **connettori di alimentazione** (il grande connettore a 24 pin per la scheda madre e uno o due connettori a 8 pin, chiamati *EPS*, per la CPU), il **pannello I/O posteriore** (l'insieme di porte che sporgono dal retro del case) e una moltitudine di **header interni**, che sono piccoli connettori a pin dove vengono collegati ventole, illuminazione RGB, porte USB frontali del case e pulsanti di accensione. Tutti questi elementi verranno ripresi in dettaglio in seguito.

---

## 2. Il Chipset

### 2.1 Cos'è il Chipset e Cosa Gestisce

Il **chipset** è, storicamente, l'insieme dei circuiti logici che governano il flusso di dati tra la CPU e il resto del sistema. Nei computer di venti-trent'anni fa, il chipset era diviso in due parti fisiche distinte: un **Northbridge**, vicino alla CPU, che gestiva le connessioni veloci (memoria e scheda grafica), e un **Southbridge**, più lontano, che gestiva le connessioni lente (dischi, USB, audio, rete). Con l'evoluzione tecnologica, il Northbridge è stato progressivamente **integrato nella CPU stessa**: oggi, il controller di memoria (**IMC**, *Integrated Memory Controller*, il circuito che pilota la RAM) e il controller per le principali lane PCIe per la scheda grafica vivono direttamente nel processore. Quello che chiamiamo "chipset" nelle moderne schede madri è, quindi, essenzialmente l'erede del vecchio Southbridge: un singolo chip dedicato alla connettività secondaria.

Cosa gestisce effettivamente il chipset di una scheda madre attuale?

Fondamentalmente, **fornisce lane di connettività aggiuntive** rispetto a quelle che la CPU offre da sola. La CPU, per ragioni di costo e spazio fisico, espone un numero limitato di lane PCIe (tipicamente 16 lane riservate alla scheda grafica più 4 o 8 lane per uno o due SSD NVMe) e poche altre risorse. Tutto il resto — le numerose porte USB, le porte SATA per i dischi, la scheda di rete, le lane PCIe per gli slot secondari, spesso il chip audio e il Wi-Fi — è gestito o abilitato dal chipset. In pratica, il chipset è un **moltiplicatore e distributore di connettività**: prende una singola connessione veloce dalla CPU e la "espande" in decine di porte e slot.

Ciò significa che la scelta del chipset determina direttamente **quante periferiche si possono collegare e con quali capacità avanzate** (overclocking, USB4, PCIe 5.0), mentre **non** determina la potenza di calcolo del sistema. Due schede con

chipset diversi ma stessa CPU e RAM offrono, a parità di configurazione, prestazioni quasi identiche nei carichi di lavoro normali: la differenza sta nelle funzionalità e nell'espandibilità, non nei "fotogrammi al secondo".

## 2.2 Comunicazione tra CPU e chipset

Il chipset deve comunicare costantemente con la CPU, e questa comunicazione avviene tramite un collegamento dedicato ad alta velocità. È importante capire questo perché tale collegamento è un **potenziale collo di bottiglia**: tutto il traffico proveniente dalle periferiche gestite dal chipset (dischi, USB, slot secondari) deve passare attraverso di esso per raggiungere la CPU.

In **Intel**, questo collegamento è chiamato **DMI** (*Direct Media Interface*). Il DMI è, tecnicamente, un bus derivato dalla tecnologia PCIe. Nelle piattaforme recenti, viene utilizzato il DMI 4.0 con un numero variabile di linee a seconda del livello del chipset: i chipset di fascia bassa utilizzano un DMI più stretto (ad esempio, l'equivalente di 4 linee PCIe 4.0), mentre i chipset di fascia alta utilizzano un DMI più ampio (l'equivalente di 8 linee PCIe 4.0), che raddoppia la larghezza di banda disponibile tra il chipset e la CPU. Questo spiega perché un chipset di fascia alta non solo offre più porte, ma permette anche che queste lavorino insieme senza saturazione.

Nei sistemi **AMD**, sulla piattaforma AM5, la connessione tra la CPU e il chipset è semplicemente un **collegamento PCIe 4.0 a 4 linee**. Un dettaglio architettonico importante riguarda i chipset "dual" di AMD: nelle schede madri X670/X670E e X870E, AMD utilizza **due chip identici** (nome in codice Promontory 21) collegati **in cascata** (daisy chain), ovvero uno attaccato all'altro. Il primo chip comunica con la CPU, il secondo comunica con il primo. Questo raddoppia il numero totale di porte e linee disponibili ma introduce un piccolo aumento di latenza per i dispositivi collegati al secondo chip, e mantiene comunque quel collegamento a 4 linee come collo di bottiglia complessivo verso la CPU. Questo è il compromesso che AMD ha scelto per offrire un'ampia connettività riutilizzando un singolo chip prodotto in grandi volumi.

## 2.3 La gerarchia dei chipset AMD (socket AM5)

Il socket **AM5** è l'attuale piattaforma desktop di AMD, introdotta con i processori della serie Ryzen 7000 e utilizzata anche dalle serie successive (8000 con grafica integrata e 9000). Una delle caratteristiche più apprezzate di AMD è la **longevità del socket**: AM5 è stato dichiarato supportato per diversi anni, il che generalmente consente futuri aggiornamenti della CPU mantenendo la stessa

scheda madre (dopo un aggiornamento del BIOS, di cui parleremo). Tutti i chipset AM5 utilizzano memoria **DDR5** (non esiste una variante DDR4 su AM5) e forniscono PCIe 5.0 dal lato CPU.

Prima di leggere la tabella, tre fondamentali chiavi interpretative. La lettera "E" alla fine del nome (come in B650E o X670E) sta per *Extreme* e indica che le **lane PCIe 5.0 sono garantite sia per la scheda grafica che per almeno un SSD**; nelle versioni senza "E", la PCIe 5.0 per la scheda grafica è spesso opzionale o assente, mentre per lo storage può essere presente. La **serie 800** (B850, X870, X870E), più recente della serie 600, si distingue principalmente per la maggiore disponibilità di **USB4** (una porta ad altissima velocità, fino a 40 Gbps, compatibile con Thunderbolt): è **obbligatoria su X870/X870E**, mentre su B850 rimane opzionale ma comune sulla maggior parte delle schede. Infine, su AM5, **l'overclock della CPU è abilitato quasi ovunque tranne che sul chipset entry-level A620**, e questa è una delle differenze storiche più significative rispetto a Intel.

| Chipset AMD (AM5) | Livello     | Overclock CPU | PCIe 5.0 GPU                | PCIe 5.0 storage  | USB4           | Note                                                                                            |
|-------------------|-------------|---------------|-----------------------------|-------------------|----------------|-------------------------------------------------------------------------------------------------|
| <b>A620</b>       | Entry       | No            | No (GPU a PCIe 4.0)         | No/limitato       | No             | Meno lane e porte; ideale per build economiche. Su alcune schede, limiti sul TDP delle CPU top. |
| <b>B650</b>       | Mainstream  | Sì            | Opzionale (spesso PCIe 4.0) | Sì (almeno 1 M.2) | Opzionale/raro | Il chipset "sensato" per la maggior parte degli utenti.                                         |
| <b>B650E</b>      | Mainstream+ | Sì            | Sì (garantito)              | Sì                | Opzionale      | Come B650 ma con PCIe                                                                           |

|              |                            |    |                                      |    |                        |                                                                                    |
|--------------|----------------------------|----|--------------------------------------|----|------------------------|------------------------------------------------------------------------------------|
|              |                            |    |                                      |    |                        | 5.0 anche per la GPU.                                                              |
| <b>X670</b>  | High (dual chip)           | Sì | Opzionale                            | Sì | Opzionale              | Molte più porte USB/SATA e lane PCIe.                                              |
| <b>X670E</b> | High (dual chip)           | Sì | Sì                                   | Sì | Opzionale              | Massima connettività per la serie 600, PCIe 5.0 completo.                          |
| <b>B850</b>  | Mainstream+ (serie 800)    | Sì | Opzionale                            | Sì | Opzionale ma frequente | Aggiornamento di B650E; USB4 più diffuso. <b>[VERIFICARE]</b> disponibilità/prezzo |
| <b>X870</b>  | High (serie 800)           | Sì | Frequente/ garantito su molte schede | Sì | <b>Obbligatorio</b>    | Single chip ma con USB4 di serie. <b>[VERIFICARE]</b>                              |
| <b>X870E</b> | Top (serie 800, dual chip) | Sì | Sì                                   | Sì | <b>Obbligatorio</b>    | Il massimo dell'espandibilità AM5. <b>[VERIFICARE]</b>                             |

**[VERIFICARE]** Le esatte garanzie PCIe 5.0 sulla scheda video per X870 (non-E) variano da modello a modello: alcune schede lo implementano, altre no. Se c'è

*un requisito stringente (ad esempio, una GPU o un SSD PCIe 5.0 da sfruttare appieno), controllare sempre le specifiche tecniche del **singolo modello**, non solo il nome del chipset.*

Una ricorrente precisazione pratica: la differenza tra un B650 e un X670E **non riguarda quanto sarà veloce il vostro gioco**. Riguarda quanti SSD NVMe potrete installare, quante porte USB veloci avrete, se potrete usare due schede video o schede di espansione contemporaneamente a piena banda, e quanto margine avrete per l'overclock estremo. Per un normale PC da gioco con una singola scheda video, un buon B650/B650E è più che sufficiente.

## 2.4 La gerarchia dei chipset Intel (LGA1700 e LGA1851)

Intel ha recentemente subito un cambio di socket, quindi è necessario distinguere tra due piattaforme.

Il socket **LGA1700** ospita i processori di 12a, 13a e 14a generazione (nomi in codice Alder Lake, Raptor Lake e Raptor Lake Refresh). È una piattaforma "matura", ampiamente diffusa e spesso disponibile a prezzi convenienti. Una peculiarità storica di LGA1700 è che, a seconda della scheda, può utilizzare memoria **DDR4 o DDR5** (mai entrambe sulla stessa scheda): questo la rende interessante per chi vuole riutilizzare RAM DDR4 esistente e risparmiare, con una piccola penalità prestazionale rispetto alla DDR5.

Il socket **LGA1851** è la piattaforma più recente, introdotta con i processori della **serie Core Ultra 200S** (nome in codice Arrow Lake). Supporta **solo DDR5** e introduce una diversa organizzazione delle linee (la CPU offre PCIe 5.0 per la scheda video e per lo storage, con un supporto nativo migliorato per Thunderbolt/USB4). Attenzione a un vincolo chiaro: **LGA1851 non è retrocompatibile con le CPU LGA1700 e viceversa**; il numero (1700 vs 1851) indica proprio il numero di contatti sul socket.

La regola d'oro di Intel sull'overclocking è diametralmente opposta a quella di AMD: **solo i chipset della serie "Z" (Z690, Z790, Z890) consentono l'overclock della CPU**. Tutti gli altri chipset Intel consentono al massimo l'overclock della memoria (tramite i profili **XMP** di Intel, *Extreme Memory Profile* — l'equivalente degli EXPO di AMD), e su questo punto c'è stata un'evoluzione: mentre i chipset entry-level storici come l'H610 non abilitano nemmeno l'XMP, i chipset di fascia media più recenti (B760, B860) lo fanno.

| Chipset | Piattafor | Livello | OC CPU | OC | DMI alla | Note |
|---------|-----------|---------|--------|----|----------|------|
|---------|-----------|---------|--------|----|----------|------|



| <b>Intel</b> | <b>ma</b> |            |    | <b>Memoria<br/>(XMP)</b> | <b>CPU</b> |                                                             |
|--------------|-----------|------------|----|--------------------------|------------|-------------------------------------------------------------|
| <b>H610</b>  | LGA1700   | Entry      | No | No                       | x4         | Spesso 2 slot RAM; poche USB/SATA; no PCIe 5.0 dal chipset. |
| <b>B660</b>  | LGA1700   | Mainstream | No | Sì                       | x4         | Ottimo punto di equilibrio o 12a/13a gen.                   |
| <b>B760</b>  | LGA1700   | Mainstream | No | Sì                       | x4         | Refresh B660, migliore connettività out of the box.         |
| <b>H670</b>  | LGA1700   | Mid-range  | No | Sì                       | x8         | Più linee rispetto a B660, no OC CPU.                       |
| <b>H770</b>  | LGA1700   | Mid-range  | No | Sì                       | x8         | Refresh H670, più USB veloci.                               |
| <b>Z690</b>  | LGA1700   | High-end   | Sì | Sì                       | x8         | OC completo, massimo numero di linee (12a/13a gen).         |
| <b>Z790</b>  | LGA1700   | High-end   | Sì | Sì                       | x8         | Refresh Z690, più USB 3.2 Gen2x2.                           |
| <b>B860</b>  | LGA1851   | Mainstream | No | Sì                       | x8         | Mainstream                                                  |

|             |         |     |    |    |                     |                                                                                                |
|-------------|---------|-----|----|----|---------------------|------------------------------------------------------------------------------------------------|
|             |         | am  |    |    | <b>[VERIFICARE]</b> | am Arrow Lake; USB4/Thunderbolt più comuni. <b>[VERIFICARE]</b>                                |
| <b>Z890</b> | LGA1851 | Top | Sì | Sì | x8                  | Flagship Arrow Lake: OC completo, molte linee PCIe 4.0 dal chipset, Thunderbolt 4/USB4 nativo. |

***[VERIFICARE]** I dettagli precisi della serie 800 di Intel (B860, e l'entry H810 non elencato ma esistente) e l'esatta larghezza del loro DMI potrebbero differire dai valori "tradizionali"; controllare la scheda tecnica del modello specifico, specialmente per il numero di slot M.2 e il supporto USB4/Thunderbolt.*

## 2.5 Tabella decisionale: quale chipset per quale utente

Questa tabella riassume pragmaticamente l'abbinamento tra tipo di utente e chipset consigliato. È intenzionalmente semplificata: serve da guida, non da sostituto per la verifica dei singoli modelli.

| Profilo utente                            | AMD consigliato (AM5) | Intel consigliato |
|-------------------------------------------|-----------------------|-------------------|
| Ufficio/multimedia, budget minimo, no OC  | A620                  | H610 / B660       |
| Gaming entry-mid, GPU singola, 1–2 SSD    | B650                  | B760              |
| Gaming/creator mid-high, overclocking, 2+ | B650E / B850          | Z790 / Z890       |

|                                                      |                                           |                         |
|------------------------------------------------------|-------------------------------------------|-------------------------|
| SSD veloci                                           |                                           |                         |
| Workstation, massima connettività, molti drive, USB4 | X670E / X870E                             | Z890                    |
| Chi vuole riutilizzare RAM DDR4 e spendere poco      | <i>(non disponibile: AM5 è solo DDR5)</i> | LGA1700 con scheda DDR4 |

## 2.6 Overclocking: il riassunto

Riassumendo la logica dell'overclocking, perché è una delle prime scelte che influenza il chipset: su **AMD AM5, l'overclock della CPU è permesso su tutti i chipset tranne l'A620**, quindi anche un economico B650 permette di spingere un processore sbloccato. Su **Intel, l'overclock della CPU richiede tassativamente un chipset "Z"** (Z690, Z790, Z890); con qualsiasi altro chipset, la CPU gira alle sue frequenze di fabbrica (inclusi i turbo automatici, che non sono considerati overclock manuale). L'overclock della **memoria**, invece, è più permissivo: quasi tutti i chipset moderni lo permettono tramite EXPO (AMD) o XMP (Intel), con l'eccezione dei chipset Intel più economici come l'H610. Dato che su molte piattaforme il maggiore guadagno prestazionale, a parità di costo, viene proprio dall'attivazione del profilo di memoria ad alta velocità, controllare che il chipset lo permetta è spesso più importante che poter overclockare la CPU.

---

## 3. Il VRM (sezione di alimentazione)

### 3.1 Cos'è il VRM e perché esiste

Il **VRM** (*Voltage Regulator Module*) è il circuito che converte i **12 volt** forniti dall'alimentatore nella tensione molto più bassa e precisa richiesta dalla CPU, tipicamente tra circa **1.0 e 1.4 volt**. Questo può sembrare un compito banale, ma non lo è affatto: una CPU moderna ad alte prestazioni può assorbire **oltre 200-250 watt** a pieno carico, e poiché la potenza è il prodotto di tensione e corrente, a bassa tensione questo significa correnti enormi, nell'ordine di **150-250 ampere**. Il VRM deve fornire questa corrente in modo stabile, pulito e reattivo: se la CPU passa da idle a massimo carico in pochi microsecondi, il VRM deve seguire quella richiesta senza far crollare la tensione o sovraccaricarla, altrimenti il sistema diventa instabile (crash, riavvii) o la CPU riduce la sua frequenza per proteggersi (*throttling*).

### 3.2 Fasi di alimentazione

Per gestire correnti così elevate, il VRM è diviso in più **fasi**. Una fase di alimentazione è un piccolo circuito completo essenzialmente composto da diversi elementi. Ci sono i **MOSFET** (*Metal-Oxide-Semiconductor Field-Effect Transistor*), interruttori elettronici che si accendono e spengono migliaia di volte al secondo; i VRM moderni spesso usano componenti integrati chiamati **DrMOS** o *power stages*, che racchiudono MOSFET e la loro logica di pilotaggio in un unico package, migliorando efficienza e temperatura. Poi c'è l'**induttore** (o *choke*), quel piccolo blocco quadrato che immagazzina energia e "liscia" la corrente. Ci sono i **condensatori**, che stabilizzano la tensione filtrando i disturbi. E infine, c'è un **controller PWM** (*Pulse Width Modulation*), il "direttore d'orchestra" che coordina l'accensione scaglionata delle varie fasi.

Il vantaggio di avere più fasi è duplice. In primo luogo, la corrente totale è **distribuita**: se dieci fasi condividono 200 ampere, ciascuna gestisce solo 20 ampere, rimanendo fresca e affidabile. In secondo luogo, facendo lavorare le fasi in modo **sfalsato** nel tempo, la tensione risultante è più continua e pulita. Tuttavia, attenzione a un mito comune: **il numero di fasi non è di per sé una misura di qualità**. Una scheda madre pubblicizzata con "16 fasi" ma costruita con componenti economici e dissipazione inadeguata può avere prestazioni peggiori di una con "8 fasi" ma componenti ad alta corrente e un buon dissipatore. Va anche detto che molte schede madri utilizzano **doubler**, circuiti che fanno apparire una fase come due: la scheda dichiara "12+2 fasi" ma il controller ne pilota in realtà la metà. Questo non è necessariamente un difetto, ma è il motivo per cui il semplice conteggio delle fasi è una metrica di marketing inaffidabile.

### 3.3 Come riconoscere un VRM adeguato

Dato che i dati di targa sono ambigui, il modo migliore per valutare un VRM è **incrociare tre segnali**. Il primo è la **presenza e la massa dei dissipatori**: un VRM serio è coperto da robusti blocchi di alluminio (a volte collegati da una *heatpipe*, un piccolo tubo che trasferisce il calore) con un'ampia superficie e alette; un VRM "nudo", con chip esposti, è quasi sempre un indicatore di una scheda economica destinata a CPU a bassa potenza. Il secondo segnale è il **rating in ampere delle singole fasi**, un dato che i recensori tecnici spesso riportano (ad esempio, "power stage da 50A o 70A"): fasi da 60-90A ciascuna sono un ottimo segno. Il terzo, e in pratica il più affidabile per i non ingegneri, è **leggere recensioni tecniche specializzate**, che misurano direttamente le temperature del VRM sotto carico prolungato con una CPU impegnativa. Se una recensione mostra

che il VRM di una certa scheda rimane sotto i 70-80 °C con la CPU che si intende utilizzare al massimo carico, quella scheda è adeguata; se supera i 100-110 °C o va in throttling, non lo è.

La regola pratica è semplice: **più la CPU è potente e più si intende overcloccharla, più il VRM è importante**. Per una CPU entry-level in un PC da ufficio, quasi ogni VRM andrà bene. Per una CPU multi-core di fascia alta spinta al limite, un VRM debole diventa il fattore limitante per l'intero sistema e può persino ridurne la durata a causa del calore eccessivo.

---

## 4. Il Form Factor

### 4.1 Cos'è il form factor e perché è importante

Il **form factor** è lo standard dimensionale della scheda madre: definisce le misure fisiche, la posizione dei fori di montaggio e il layout generale dei componenti. È un parametro cruciale perché deve essere **coerente con il case**: un case dichiara quali form factor accetta, e non è possibile montare una scheda più grande di quanto il case consenta. Il form factor influenza anche l'espandibilità (numero di slot disponibili), la facilità di raffreddamento e, in parte, il prezzo.

### 4.2 I quattro principali form factor

**ATX** (*Advanced Technology eXtended*) è lo standard di riferimento nel mondo desktop, con dimensioni di **305 × 244 mm** (circa 30.5 × 24.4 cm). È il formato "completo": offre tipicamente quattro slot RAM, molteplici slot PCIe, ampio spazio per il VRM e i dissipatori, e massima connettività. È la scelta più equilibrata per la maggior parte delle build fisse perché non impone compromessi sull'espandibilità.

**Micro-ATX** (spesso abbreviato in *mATX* o *μATX*) misura **244 × 244 mm**, quindi è un quadrato più corto verso il basso rispetto all'ATX. Di solito mantiene quattro slot RAM ma riduce il numero di slot PCIe (tipicamente uno o due utilizzabili). È il formato con il **miglior rapporto prezzo/prestazioni**: le schede mATX costano spesso meno delle equivalenti ATX pur offrendo tutto il necessario per un PC normale con una singola scheda grafica. È un'ottima scelta per chi vuole risparmiare senza rinunciare a quattro slot RAM.

Il **Mini-ITX** misura appena **170 × 170 mm**: è il formato compatto per eccellenza, pensato per PC piccoli e portatili. Tuttavia, impone compromessi significativi: ha

**un solo slot PCIe** (quindi una sola scheda video, niente schede aggiuntive) e, soprattutto, **solo due slot RAM**. A parità di funzionalità, le schede Mini-ITX tendono anche a costare **di più** delle schede ATX, perché concentrare tutto in uno spazio così piccolo è ingegneristicamente costoso. Si sceglie per il fattore di forma, non per risparmiare.

L'**E-ATX** (*Extended ATX*) è il formato più grande, con una larghezza che arriva fino a **305 × 330 mm** (le misure esatte variano leggermente tra i produttori, ed è un punto da verificare attentamente con le specifiche del case). È riservato a workstation e sistemi di fascia altissima che richiedono VRM enormi, molti slot e connettività estrema. Richiede case grandi e specificamente compatibili, e ha un costo elevato.

| Fattore di forma | Dimensioni (mm)  | Slot PCIe tipici | Slot RAM tipici       | Pro                                 | Contro                                               |
|------------------|------------------|------------------|-----------------------|-------------------------------------|------------------------------------------------------|
| <b>E-ATX</b>     | fino a 305 × 330 | Molti            | 4 (a volte 8 su HEDT) | Massima espandibilità e VRM         | Costoso, richiede case grandi e compatibili          |
| <b>ATX</b>       | 305 × 244        | 3–4              | 4                     | Equilibrio ideale, standard diffuso | Ingombro maggiore rispetto a mATX                    |
| <b>Micro-ATX</b> | 244 × 244        | 1–2              | 4                     | Ottimo prezzo, compatto ma spazioso | Meno slot PCIe                                       |
| <b>Mini-ITX</b>  | 170 × 170        | 1                | 2                     | Compattezza estrema, portabilità    | Espandibilità limitata, prezzo elevato, RAM limitata |

### 4.3 Implicazioni pratiche

La scelta del fattore di forma si intreccia con la scelta del case e con gli obiettivi della build. Per un PC "normale" da gaming o lavoro, **ATX o Micro-ATX** coprono la stragrande maggioranza delle esigenze; Micro-ATX in particolare è spesso la

scelta più intelligente in termini di rapporto qualità-prezzo. **Mini-ITX** ha senso quando la compattezza è una priorità (un PC da salotto, uno da portare agli eventi), accettandone le limitazioni e il prezzo premium. **E-ATX** è appropriato solo per configurazioni professionali ad altissima espandibilità, dove servono davvero molte lane, molti drive e un VRM sovradimensionato. Un errore comune è comprare un case elegante ma piccolo e poi scoprire che la scheda ATX desiderata non ci sta, o che non c'è spazio per il dissipatore della CPU: **il fattore di forma va deciso assieme al case, non separatamente.**

---

## 5. Slot e porte

### 5.1 Slot PCIe: numero, generazione e allocazione delle lane

Come anticipato, gli slot **PCIe** ospitano la scheda video e le altre schede di espansione. Per comprenderli, vanno introdotti due concetti: **generazione** e **lane**.

**Generazione** (PCIe 3.0, 4.0, 5.0) determina la larghezza di banda per corsia: ogni generazione raddoppia la precedente. Una corsia PCIe 3.0 offre circa 1 GB/s, una 4.0 circa 2 GB/s, una 5.0 circa 4 GB/s. Le **corsie** sono i percorsi elettrici paralleli: uno slot "x16" ha sedici corsie, un "x4" ne ha quattro, e così via. La larghezza di banda totale è il prodotto delle corsie e della larghezza di banda per corsia: uno **slot x16 in PCIe 4.0** offre quindi circa 32 GB/s, un **x16 in PCIe 5.0** circa 64 GB/s.

Un punto che confonde molti principianti è la differenza tra la **lunghezza fisica** e le **corsie elettriche** di uno slot. Uno slot può essere fisicamente lungo quanto un x16 (per ospitare una scheda grafica, che richiede il connettore lungo) ma essere cablato elettricamente solo come x4 o x1. Sulle specifiche tecniche, questo è scritto, per esempio, come "PCIe x16 (in modalità x4)": ciò significa che la scheda grafica si adatta fisicamente, ma riceve solo un quarto della larghezza di banda. Questo è un dettaglio importante quando si vogliono usare più slot contemporaneamente.

La distinzione più importante, tuttavia, è tra gli **slot collegati direttamente alla CPU** e gli **slot collegati al chipset**. Il **primo slot x16**, destinato alla scheda grafica principale, è quasi sempre collegato **direttamente alla CPU**: è il più veloce, con piena larghezza di banda e latenza minima, ed è quello che si dovrebbe usare per la GPU. Gli slot secondari, d'altra parte, sono generalmente collegati **al chipset**, il che significa che la loro larghezza di banda condivide il link DMI/PCIe verso la CPU di cui abbiamo discusso: se li si usa intensivamente insieme ad altre

periferiche del chipset, potrebbero contendersi la larghezza di banda. Per un normale PC con una singola scheda grafica, questo è completamente irrilevante; diventa rilevante solo in configurazioni con più schede di espansione ad alta larghezza di banda.

## 5.2 Slot M.2 e condivisione delle corsie

Gli slot **M.2** ospitano gli SSD moderni. Un SSD NVMe (*Non-Volatile Memory Express*, il protocollo veloce usato dagli SSD M.2 ad alte prestazioni) tipicamente usa **quattro corsie PCIe** per raggiungere le sue alte velocità. Le schede madri offrono da uno a quattro (o più, sui modelli top) slot M.2, di diverse generazioni: il primo slot M.2 è spesso collegato direttamente alla CPU e può essere PCIe 5.0 o 4.0, mentre gli altri sono collegati al chipset e possono essere di una generazione inferiore.

Qui entra in gioco un concetto tanto importante quanto sottovalutato: la **condivisione delle corsie**. Poiché le corsie PCIe totali sono una risorsa finita, i produttori spesso **condividono** le stesse corsie tra più connettori, con la regola che **non possono essere tutti usati contemporaneamente**. Il caso classico: un certo slot M.2 **condivide le corsie con alcune porte SATA**, quindi l'installazione di un SSD in quello slot **disabilita automaticamente due o quattro porte SATA**. Un altro caso: un secondo slot M.2 condivide le corsie con uno slot PCIe secondario, quindi popolare uno riduce o disabilita l'altro. Inoltre: su alcune schede, popolare tutti gli slot M.2 fa sì che lo slot della scheda grafica scenda da x16 a x8.

Questo è uno degli **errori più costosi** commessi dagli acquirenti inesperti: comprano una scheda con "quattro slot M.2 e sei porte SATA" convinti di poterli usare tutti, per poi scoprire che riempire gli M.2 disattiva metà delle porte SATA, o che l'aggiunta di un'unità rimuove corsie altrove. La soluzione è **leggere sempre il manuale della scheda (o la sezione "specifiche dettagliate") prima dell'acquisto**, identificando la tabella di condivisione delle corsie, che elenca esattamente quali connettori sono mutuamente esclusivi. Su piattaforme con poche corsie (ad esempio, chipset di fascia bassa), la condivisione delle corsie è più stringente; su chipset di fascia alta, con molte più corsie dal chipset, è meno frequente ma comunque possibile.

## 5.3 Slot RAM: 2 vs 4

Il numero di slot RAM ha due implicazioni. La prima riguarda il **dual channel**: le moderne piattaforme desktop raggiungono la piena larghezza di banda della



memoria utilizzando **due canali**, il che significa installare i moduli **a coppie**. Con quattro slot, si può iniziare con due moduli e aggiungerne altri due in seguito; con due slot (tipici dei Mini-ITX), si è già "pieni" se si vuole il dual channel, e per aumentare la capacità si dovrà **sostituire** i moduli anziché aggiungerli. La seconda implicazione riguarda l'**aggiornamento**: quattro slot offrono maggiore flessibilità futura, mentre due slot costringono a scartare i moduli esistenti per aumentare la RAM.

Un dettaglio tecnico spesso trascurato: **riempire tutti e quattro gli slot rende più difficile raggiungere frequenze di memoria molto elevate**, perché il controller di memoria integrato (IMC) nella CPU deve gestire più moduli e il segnale è più complesso da gestire. Per questo motivo, chi punta alla massima velocità della RAM spesso preferisce **due moduli ad alta capacità** piuttosto che quattro di capacità inferiore, anche se dispone di quattro slot.

#### 5.4 Porte SATA

Le porte **SATA** sono utilizzate per collegare dischi rigidi meccanici e SSD "tradizionali" da 2,5 pollici. Sono ancora utili per l'archiviazione di grandi dimensioni e a basso costo (i dischi rigidi di grandi dimensioni utilizzano SATA). Il numero di porte SATA varia da quattro a otto a seconda della scheda madre; come già visto, alcune di queste porte possono essere condivise con gli slot M.2 tramite la condivisione delle corsie. Chi prevede di collegare molti dischi meccanici (ad esempio, per un piccolo server domestico o per l'archiviazione multimediale) deve contare attentamente le porte SATA **effettivamente utilizzabili contemporaneamente con gli SSD M.2** che intende installare.

#### 5.5 Il pannello I/O posteriore

Il **pannello I/O** (Input/Output) è la fila di porte che sporge dal retro del case. È una delle differenze più tangibili tra le fasce di prezzo, ed è bene decifrarne gli acronimi.

Le porte **USB** seguono una nomenclatura confusa a causa di continui rinominazioni. Le **USB 2.0** sono lente (480 Mbps) e adatte solo per tastiere, mouse e periferiche poco esigenti. Le **USB 3.2 Gen 1** (precedentemente chiamate USB 3.0 o USB 3.1 Gen 1) offrono 5 Gbps; le **USB 3.2 Gen 2** offrono 10 Gbps; le **USB 3.2 Gen 2x2** raggiungono i 20 Gbps utilizzando due corsie. Al vertice ci sono **USB4** e **Thunderbolt**, che raggiungono i **40 Gbps** e supportano funzioni avanzate come la connessione di monitor e enclosure esterne ad alta velocità; USB4 e Thunderbolt 4 sono ampiamente interoperabili. Il **connettore Type-C** è la forma fisica

reversibile ormai standard per le porte più veloci, mentre il classico **Type-A** rettangolare rimane comune per le velocità intermedie.

Sul pannello troverete anche le uscite **video** (HDMI, DisplayPort): queste servono solo **se usate la grafica integrata (iGPU)** della CPU, cioè senza una scheda grafica dedicata; se avete una scheda grafica, collegherete il monitor ad essa e le uscite della scheda madre rimarranno inutilizzate. Poi c'è la **rete**: le schede madri moderne offrono almeno una porta Ethernet **2.5G** (2.5 Gbps), mentre i modelli di fascia alta possono avere **10G** (10 Gbps); spesso è presente anche il **Wi-Fi** con la sua antenna. La sezione **audio** include jack analogici e, sulle schede madri migliori, un'uscita ottica e chip audio di qualità superiore.

Due funzioni molto pratiche, presenti per lo più nelle schede madri di fascia media e superiore, meritano una menzione. Il **BIOS Flashback** (chiamato anche *Q-Flash Plus*, *Flash BIOS Button* a seconda del produttore) è un pulsante che permette di **aggiornare il BIOS senza CPU, RAM o scheda grafica installate**: è essenziale quando si acquista una scheda madre "new old stock" con un BIOS troppo obsoleto per riconoscere la nuova CPU. Il **Clear CMOS** è un pulsante (o un jumper) che **resetta le impostazioni del BIOS** ai valori di fabbrica: indispensabile per ripristinare l'avvio dopo un overclock fallito.

## 5.6 Header Interni

Gli **header** sono connettori a pin presenti sul PCB a cui vengono collegati i cavi interni. I principali sono gli **header USB frontali**, che alimentano le porte USB del case (Type-A e Type-C sul frontale); gli **header ARGB e RGB** (*Addressable RGB*, illuminazione LED indirizzabile individualmente), per collegare ventole e strisce luminose; i **connettori per ventole** (solitamente PWM a 4 pin, che permettono il controllo della velocità); e l'header dedicato alla **pompa AIO** (*All-In-One*, il sistema di raffreddamento a liquido preassemblato), che fornisce alimentazione stabile e completa alla pompa. Contare gli header disponibili è importante per chi ha molte ventole o un sistema di illuminazione elaborato: una scheda economica potrebbe offrirne troppo pochi, costringendo all'acquisto di *splitter* o *hub* aggiuntivi.

---

## 6. Nomenclatura e Marchi

### 6.1 Perché i Nomi Contano

I produttori organizzano le loro schede in **linee** (o *serie*), che rappresentano livelli crescenti di prezzo e funzionalità. Imparare a leggere queste linee permette di

collocare immediatamente una scheda nel giusto livello senza dover analizzare ogni specifica. Attenzione, però: **la stessa linea può contenere modelli di prezzo diverso** a seconda del chipset (una "Strix B650" costa meno di una "Strix X670E"), quindi la linea indica un *posizionamento relativo*, non un prezzo assoluto.

## 6.2 ASUS

ASUS struttura la sua gamma in modo piuttosto lineare. La linea **Prime** è l'entry/mainstream, essenziale ed economica. **TUF Gaming** è la fascia media, con un'enfasi sulla robustezza e componenti affidabili, offrendo un ottimo compromesso qualità/prezzo. **ROG Strix** (*Republic of Gamers*) è la fascia medio-alta, con VRM più robusti, maggiore connettività e un'estetica più curata. Al vertice ci sono **ROG Maximus** (per piattaforme Intel) e **ROG Crosshair** (per piattaforme AMD), le schede ammiraglie progettate per l'overclock estremo e il massimo delle funzionalità. Infine, c'è la linea **ProArt**, rivolta ai creatori di contenuti, con un'estetica sobria e connettività (Thunderbolt, rete veloce) pensata per le workstation.

## 6.3 MSI

MSI utilizza acronimi di quattro lettere in ordine crescente di livello. **PRO** è la linea entry/business, sobria e funzionale. **MAG** (*MSI Arsenal Gaming*) è il livello gaming di fascia media, dove rientrano modelli molto popolari come il "Tomahawk". **MPG** (*MSI Performance Gaming*) è la fascia medio-alta. **MEG** (*MSI Enthusiast Gaming*) è il top, con le schede ammiraglie. La regola mnemonica è che, salendo, la seconda lettera indica la progressione: da PRO ad Arsenal, Performance, Enthusiast.

## 6.4 Gigabyte

Gigabyte separa le linee entry-level da quelle gaming. **UD** (*Ultra Durable*) è l'entry-level essenziale. Le schede etichettate semplicemente **Gaming** occupano la fascia media. Il brand premium è **Aorus**, strutturato su livelli crescenti: **Aorus Elite** (fascia media), **Aorus Pro** (fascia medio-alta), **Aorus Master** (fascia alta) e **Aorus Xtreme** (ammiraglia). Esiste anche la linea **Aero** per i content creator. Salendo nella scala Aorus, migliorano VRM, raffreddamento, connettività e qualità costruttiva.

## 6.5 ASRock

ASRock ha storicamente offerto prezzi aggressivi. Le schede entry-level portano nomi essenziali o la designazione **Pro**. **Steel Legend** è la fascia media con un'estetica distintiva. **Phantom Gaming** (spesso abbreviato in *PG*) è la linea

gaming di fascia media, mentre nomi come **Riptide**, **Lightning** o **Nova** identificano varianti specifiche. Al top si trova **Taichi**, la linea ammiraglia riconoscibile per l'estetica a ingranaggi, con un set di funzionalità completo e VRM robusti.

## 6.6 Fasce di Prezzo e Reputazione dei Brand

Come linea guida generale (con l'avvertenza che i **prezzi sono volatili** e vanno sempre verificati), le linee entry-level si collocano nella fascia di prezzo più economica, le linee di fascia media nell'intermedia, e le linee ammiraglie nell'alta, con le schede top di gamma che possono costare quanto una scheda grafica di fascia media. Il consiglio pratico più importante è: **non pagare per un livello che non userai**. Una scheda ammiraglia ha senso solo se si utilizzano realmente le sue funzionalità (overclock estremo, connettività esotica, molti drive); altrimenti, quel denaro è meglio investito nella CPU, GPU o RAM.

Per quanto riguarda la **reputazione dei brand**, tre fattori contano più dell'estetica. Il primo è la **qualità e usabilità del BIOS/UEFI** (l'interfaccia firmware usata per configurare la scheda): un BIOS ben fatto, stabile e ricco di funzionalità semplifica molto la vita, specialmente per l'overclock e la gestione della memoria. Il secondo è la qualità del supporto e la procedura di **RMA** (*Return Merchandise Authorization*), che varia in velocità ed efficienza a seconda della regione. Il terzo è la **qualità effettiva dei componenti** (VRM, dissipatori, rete, audio) al di là del marketing. Poiché tutti i maggiori brand (ASUS, MSI, Gigabyte, ASRock) producono sia schede eccellenti che modelli mediocri, la regola d'oro è **non fidarsi solo del brand, ma valutare ogni singolo modello specifico tramite recensioni tecniche indipendenti**.

---

## 7. Come Scegliere la Scheda Madre Ideale

### 7.1 La Procedura Passo-Passo

La scelta di una scheda madre non inizia mai dalla scheda madre stessa: inizia dalla **CPU**, e procede a cascata. Questo è il metodo corretto, ordinato per priorità.

Il primo passo è **decidere la CPU**, perché la CPU determina tutto il resto. Dalla CPU discende immediatamente il **socket** (AM5 per i Ryzen recenti, LGA1700 o LGA1851 per Intel a seconda della generazione): questo è un vincolo rigido e non negoziabile. Scelto il socket, si passa al **chipset**, valutando quali funzioni servono davvero: overclock sì o no, quante linee e porte, PCIe 5.0 o USB4 necessari o

superflui. Poi si definisce il **form factor** in coordinamento con il case (ATX, Micro-ATX, Mini-ITX): questa scelta va fatta assieme al case, non dopo. A questo punto si verifica la **connettività necessaria** confrontando quante porte USB, quanti slot M.2, quante porte SATA e che rete servono per il proprio uso effettivo. Solo allora si verifica il **VRM**, dimensionandolo alla CPU scelta (più la CPU è potente e overclocata, più il VRM deve essere robusto). Infine, si applica il **budget**, scegliendo fra i modelli che rispettano i requisiti quello con il miglior rapporto qualità/prezzo, senza pagare per funzionalità inutili.

## 7.2 Verifiche di compatibilità

Una volta individuata una candidata, va verificata la sua compatibilità su cinque fronti, perché un errore qui può rendere il sistema inutilizzabile.

La compatibilità con la **CPU** non si limita al socket: occorre verificare che la scheda supporti quella specifica CPU **con la versione del BIOS installata**. Schede vendute prima dell'uscita di una nuova CPU potrebbero avere un BIOS troppo vecchio per riconoscerla, rendendo necessario un aggiornamento tramite la funzione **BIOS Flashback** (che, come visto, funziona anche senza una CPU compatibile). I produttori pubblicano una **lista di CPU supportate** per ogni scheda: va sempre consultata quando si accoppia una CPU molto nuova con una scheda che potrebbe essere stata in magazzino per qualche tempo.

La compatibilità con la **RAM** si verifica sulla **QVL** (*Qualified Vendor List*, la lista dei moduli di memoria testati e certificati dal produttore per quella scheda) e sulle velocità di memoria supportate. La QVL non è un vincolo assoluto (spesso moduli non elencati funzionano), ma scegliere uno presente in lista riduce il rischio di problemi di stabilità, specialmente ad alte frequenze.

La compatibilità con la **GPU** riguarda principalmente lo spazio fisico (*clearance*): le schede video moderne sono grandi e pesanti, e occorre assicurarsi che, una volta installata, la GPU non copra slot M.2 o porte SATA che servono, e che ci sia spazio nel case. Nei form factor compatti, questo aspetto diventa critico.

La compatibilità con il **case** è la coerenza del form factor già discussa: il case deve accettare le dimensioni della scheda. La compatibilità con il **cooler** (dissipatore della CPU) riguarda l'ingombro: dissipatori ad aria molto alti o radiatori liquidi grandi devono trovare spazio senza interferire con i dissipatori del VRM, moduli RAM alti o il pannello del case.

### 7.3 Errori tipici dell'acquirente

Alcuni errori si verificano con una tale frequenza da giustificare un avvertimento esplicito. Il primo è **pagare per un chipset di fascia alta senza usarne le funzionalità**: comprare una X670E o una Z890 e poi installare una CPU di fascia media, una singola scheda grafica e un singolo SSD significa buttare via soldi che avrebbero fruttato molto di più in CPU, GPU o RAM. Il secondo, già discusso, è **ignorare la condivisione delle linee M.2 e SATA**, ritrovandosi con porte che si disabilitano a vicenda dopo l'acquisto. Il terzo è **accoppiare un VRM debole con una CPU di fascia alta**: una scheda economica con un VRM sottodimensionato limiterà una CPU potente e può surriscaldarsi sotto carico prolungato. A questi si aggiungono errori più banali ma frequenti: dimenticare di controllare il supporto BIOS per una nuova CPU, scegliere un fattore di forma incompatibile con il case, sottovalutare le dimensioni del dissipatore ed essere guidati unicamente dal numero di fasi VRM o dall'estetica invece che dalle recensioni tecniche.

---

### Riepilogo Operativo — Lista di Controllo per la Scelta della Scheda Madre

Usa questa lista di controllo in ordine, dall'alto verso il basso. Ogni punto deve essere verificato prima di passare al successivo.

- 1. CPU e socket (vincolo rigido).** Ho già scelto la CPU? Da essa deriva il socket: AM5 (Ryzens recenti, solo DDR5), LGA1700 (Intel 12a–14a gen, DDR4 o DDR5) o LGA1851 (Intel Core Ultra 200S, solo DDR5). La scheda deve avere esattamente quel socket.
- 2. Supporto BIOS.** La scheda supporta la mia specifica CPU con il BIOS di fabbrica? Se la CPU è molto recente, la scheda ha il **BIOS Flashback** per aggiornarlo senza una CPU compatibile? Ho controllato la lista delle CPU supportate?
- 3. Chipset e funzionalità effettive.** Ho bisogno di **overclock della CPU**? Se sì: per Intel serve un chipset **Z**; per AMD, qualsiasi chipset tranne A620 è sufficiente. Ho bisogno di **overclock della RAM** (EXPO/XMP)? Quasi tutte lo permettono, tranne Intel H610. Ho davvero bisogno di **PCIe 5.0** (GPU/SSD) o **USB4**, o sto pagando per funzionalità che non userò?
- 4. Fattore di forma e case.** Ho scelto il formato (ATX / Micro-ATX / Mini-ITX / E-ATX) **insieme al case**? Il case accetta queste dimensioni? Ricorda che Mini-ITX ha

solo 2 slot RAM e 1 slot PCIe, e che Micro-ATX offre spesso il miglior rapporto qualità-prezzo.

**5. Connettività e condivisione linee.** Ho contato quanti **slot M.2**, quante **porte SATA** e quante **porte USB** mi servono? Ho letto la tabella di **condivisione delle linee** per verificare che gli M.2 e SATA che voglio usare **non si disabilitino a vicenda**? Ho abbastanza **slot RAM** (2 vs 4) per futuri upgrade che prevedo? La **rete** (2.5G/10G/Wi-Fi) è adeguata?

**6. VRM.** La CPU scelta è potente e/o la overcloccherò? Se sì, la scheda ha un **VRM robusto** (dissipatori sostanziosi, fasi ad alta corrente) confermato da **recensioni tecniche** (temperature sotto carico prolungato)? Ricorda che il solo numero di fasi non è indicatore di qualità.

**7. Compatibilità fisica.** La **GPU** ci sta e non copre porte/slot che mi servono? Il **dissipatore della CPU** (ad aria alto o radiatore a liquido) trova spazio senza interferire con VRM, RAM e case? La **RAM** scelta è nella QVL o comunque compatibile con le velocità dichiarate?

**8. Marca e modello.** Ho inquadrato la scheda nel tier corretto leggendo la riga (Prime/TUF/Strix/Maximus-Crosshair per ASUS; PRO/MAG/MPG/MEG per MSI; UD/Gaming/Aorus per Gigabyte; Pro/Steel Legend/Phantom Gaming/Taichi per ASRock)? Ho valutato il **singolo modello** con recensioni indipendenti, invece di fidarmi solo della marca o dell'estetica?

**9. Budget finale.** Tra i modelli che superano tutti i punti precedenti, sto scegliendo quello con il **miglior rapporto qualità-prezzo**, evitando di pagare per un chipset o un tier le cui funzionalità non userò? Quei soldi sarebbero spesi meglio altrove (CPU/GPU/RAM)?

**Regola d'oro finale.** La scheda madre non aumenta gli "fps": abilita, connette e alimenta. Compra la **scheda più economica che soddisfa tutti i tuoi requisiti reali** con un VRM adeguato alla CPU — né più, né meno.

---

\*Fine capitolo. I dati architetturali sono aggiornati al meglio delle conoscenze disponibili al momento della stesura; prezzi, disponibilità e dettagli degli ultimi chipset (AMD serie 800, Intel piattaforma LGA1851) contrassegnati con **[VERIFICARE]** vanno confermati sulle specifiche tecniche ufficiali dei singoli modelli al momento dell'acquisto.\*





## Capitolo 3 - Memoria RAM

***Nota sull'aggiornamento dei dati.** Questo capitolo è scritto con conoscenze aggiornate a inizio 2026. I concetti tecnici (come funziona la RAM, cos'è la latenza CAS, perché il dual channel raddoppia i bus) sono stabili nel tempo e non invecchiano. Viceversa, tre categorie di informazioni cambiano rapidamente e sono esplicitamente indicate nel testo con l'etichetta **[dati volatili]**: (1) i prezzi, (2) qual è "l'ultima generazione" sul mercato e le frequenze massime raggiunte, (3) i kit specifici consigliati e le liste di compatibilità delle schede madri (QVL). Prima dell'acquisto, verificare sempre questi tre punti da fonti recenti.*

---

### 1. Cos'è la RAM

#### 1.1 Definizione: memoria di lavoro volatile

RAM è l'acronimo di *Random Access Memory* (memoria ad accesso casuale). Il termine "casuale" non ha nulla a che fare con il caso o la fortuna: significa semplicemente che il processore può leggere o scrivere qualsiasi cella di memoria in un tempo quasi costante, indipendentemente dalla sua posizione fisica. Questo la distingue dalle memorie ad accesso sequenziale (come i vecchi nastri magnetici), dove per raggiungere un dato alla fine bisognava scorrere tutto ciò che lo precedeva. Nella RAM, invece, ogni indirizzo è direttamente accessibile, come se ogni casella di una scacchiera gigante avesse il suo indirizzo postale e il postino potesse teletrasportarsi ovunque in un colpo solo.

La caratteristica più importante da comprendere, e quella che più spesso confonde chi si avvicina all'hardware, è che la RAM è una memoria **volatile**. Volatile significa che conserva i dati solo finché è alimentata elettricamente: nell'istante in cui il computer viene spento, o anche solo riavviato, tutti i contenuti della RAM svaniscono. Questo non è un difetto; è una scelta di design. La RAM non serve a *conservare* i dati nel tempo; serve a *lavorarci su* nel presente. È il banco da lavoro, non l'archivio.

#### 1.2 La differenza fondamentale dallo storage

Per comprendere appieno lo scopo della RAM, è essenziale contrapporla allo **storage**, ovvero la memoria di massa: hard disk meccanici (HDD) e unità a stato solido (SSD). Lo storage è **non volatile**: conserva i dati anche quando il computer è spento. È qui che risiedono il sistema operativo, i programmi installati, i

documenti, le foto e i giochi. Quando compriamo "un computer con 1 TB", quel terabyte è quasi sempre storage.

La metafora più efficace, e non a caso più usata, è quella della scrivania e dell'archivio. Immaginiamo un impiegato che deve sbrigare delle pratiche. L'**archivio** (storage) contiene tutte le pratiche dell'ufficio, migliaia di faldoni, organizzati e conservati per sempre, ma scomodi da consultare: per recuperare un documento bisogna alzarsi, camminare, aprire un cassetto, cercare. La **scrivania** (RAM), invece, è il piano dove l'impiegato appoggia solo i documenti su cui sta lavorando in quel momento: sono a portata di mano, immediatamente accessibili, ma lo spazio è limitato e a fine giornata la scrivania viene sgomberata.

Questa metafora spiega tre cose in un colpo solo. Primo, perché la RAM è molto più veloce dello storage: recuperare un foglio già sulla scrivania è enormemente più rapido che andarlo a cercare nell'archivio. Numericamente, la RAM opera con latenze nell'ordine dei nanosecondi (miliardesimi di secondo) e larghezze di banda di decine di gigabyte al secondo, mentre anche un veloce SSD NVMe ha latenze migliaia di volte superiori. Secondo, perché la RAM è più costosa per gigabyte: è una tecnologia intrinsecamente più raffinata e veloce, quindi 32 GB di RAM e 32 GB di SSD hanno prezzi molto diversi. Terzo, perché ne serve molta meno: sulla scrivania tengo cinque faldoni, nell'archivio ne ripongo cinquemila.

Quando si avvia un programma, il sistema operativo **copia** il codice e i dati necessari dallo storage (archivio) alla RAM (scrivania). La CPU lavora leggendo e scrivendo sulla RAM, non direttamente sullo storage, perché altrimenti sarebbe drammaticamente rallentata. Quando si salva un file, il processo è inverso: i dati vengono scritti dalla RAM allo storage per essere resi permanenti. È proprio per questo che, se va via la corrente prima di aver salvato, il lavoro non salvato viene perso: era solo sulla scrivania, mai riposto nell'archivio.

Un errore concettuale comune è confondere "poca RAM" con "poco spazio". Se lo storage è pieno, il computer segnala che non c'è più spazio per salvare i file. Se la RAM è insufficiente, invece, il computer non si blocca subito: ricorre a un trucco chiamato **swap** (o *file di paging*), che usa una porzione dello storage come RAM di emergenza. Poiché lo storage è ordini di grandezza più lento, il risultato è un rallentamento avvertibile, con l'HDD o l'SSD che lavorano costantemente e l'interfaccia che diventa scattosa. Molti utenti che lamentano un computer "lento" hanno in realtà un problema di RAM insufficiente che costringe a un continuo ricorso allo swap.

### 1.3 Come comunicano CPU e RAM: il memory controller integrato

Affinché la CPU possa usare la RAM, qualcuno deve fare da intermediario: tradurre le richieste del processore ("dammi il contenuto dell'indirizzo X", "scrivi questo valore all'indirizzo Y") in precisi segnali elettrici sui bus di memoria, rispettando tempistiche molto stringenti. Questo compito spetta al **memory controller**.

Fino a circa vent'anni fa, sulla piattaforma PC, il controller della memoria risiedeva in un chip separato sulla scheda madre chiamato **northbridge**, parte del cosiddetto chipset. La CPU comunicava con il northbridge tramite un bus (il Front Side Bus), e il northbridge comunicava con la RAM. Questo introduceva un intermediario extra, con la sua latenza. La svolta è avvenuta quando i progettisti hanno spostato il controller della memoria **all'interno della CPU stessa**: da qui l'acronimo **IMC**, *Integrated Memory Controller*. AMD lo ha introdotto nei processori Athlon 64 (2003), e Intel lo ha generalizzato con l'architettura Nehalem (2008); da allora, è lo standard assoluto.

L'integrazione ha due importanti conseguenze pratiche. La prima è la riduzione della latenza: eliminando il passaggio attraverso un chip esterno, la CPU accede alla RAM più velocemente. La seconda, meno intuitiva ma cruciale per gli acquirenti, è che **la compatibilità e i limiti della RAM dipendono in gran parte dalla CPU**, non solo dalla scheda madre. È l'IMC del processore a determinare quali tipi di memoria supporta (DDR4 o DDR5), quante frequenze può gestire stabilmente e quanti canali gestisce. Due CPU montate sulla stessa scheda madre possono avere limiti di memoria diversi perché hanno IMC diversi. La scheda madre definisce i confini (numero di slot, layout del bus, qualità del segnale), ma il controller nella CPU fa il lavoro. Terremo a mente questo principio per tutto il capitolo: **RAM, CPU e scheda madre formano un sistema a tre parti; nessuna delle tre viene scelta in isolamento.**

---

## 2. Capacità

### 2.1 Quanta RAM è realmente necessaria, per caso d'uso

La domanda "di quanta RAM ho bisogno?" non ha una risposta univoca, perché dipende da cosa deve fare il computer. La logica sottostante è semplice: serve abbastanza RAM per tenere tutto ciò su cui si sta lavorando contemporaneamente sulla propria "scrivania" (RAM), senza costringere il sistema a continui swapping.

Vediamo gli intervalli, tenendo presente che i valori indicati sono approssimativi e che i requisiti software crescono nel tempo **[dati volatili]**: una quantità "generosa" oggi diventa "il minimo indispensabile" in pochi anni.

Con **8 GB**, un sistema può ancora funzionare per compiti leggeri: navigazione con poche schede aperte, elaborazione testi, email, streaming video. Va detto chiaramente, però, che 8 GB nel panorama attuale sono il pavimento assoluto e spesso già insufficienti: i browser moderni consumano molta memoria, il sistema operativo si riserva una fetta, e bastano poche applicazioni aperte insieme per iniziare a usare lo swap. Per un nuovo PC destinato a durare, 8 GB non sono consigliabili se non per macchine con un ruolo molto limitato.

Con **16 GB**, l'uso d'ufficio avanzato e il gaming sono coperti comodamente. Questa quantità è stata il "sweet spot" per anni, e rimane un'ottima base per un utente che gioca, tiene molte schede aperte, usa applicazioni di produttività e magari qualche strumento creativo leggero. Nel gaming, la maggior parte dei titoli attuali gira bene con 16 GB, anche se i giochi più recenti e ambiziosi stanno iniziando a beneficiare di più memoria, specialmente se si gioca mentre browser, chat vocale e software di registrazione sono in esecuzione in background.

Con **32 GB** si entra nel territorio del "a posto per anni" per un utente esigente. È la scelta consigliata per i giocatori seri che si dedicano anche a multitasking pesante, coloro che lavorano con fotoritocco di file di grandi dimensioni, editing video Full HD amatoriale o semi-professionale, virtualizzazione leggera e sviluppo software con IDE e container. Nel 2026, 32 GB è diventato il "sweet spot" per PC di fascia medio-alta, anche perché i prezzi della RAM, pur fluttuando, hanno spesso reso il salto da 16 a 32 GB meno doloroso **[dato volatile: verificare prezzo attuale]**.

Con **64 GB e oltre**, si risponde a carichi di lavoro professionali pesanti: editing video 4K/8K con molte tracce ed effetti, rendering 3D, fotografia ad altissima risoluzione con molti livelli, esecuzione simultanea di più macchine virtuali (VM), database locali e compilazione di enormi progetti software. Un caso d'uso in rapida crescita è l'**AI locale**: l'esecuzione di modelli linguistici di grandi dimensioni (LLM) sulla propria macchina richiede memoria abbondante. Qui va fatta una distinzione: i modelli girano principalmente sulla **VRAM** della scheda grafica (la memoria dedicata della GPU, argomento di un altro capitolo), ma la RAM di sistema è comunque necessaria per caricare i modelli, gestire il contesto, eseguire inferenze sulla CPU quando la VRAM è insufficiente e preparare i dati. Per un lavoro serio con modelli di medie dimensioni, 64 GB sono un buon punto

di partenza, e 128 GB non sono affatto eccessivi. Chi fa fine-tuning, elaborazione di dataset o gestisce pipeline complesse può facilmente giustificare quantità ancora maggiori.

La seguente tabella riassume le raccomandazioni. Va letta come una bussola, non come un dogma: le esigenze reali si misurano osservando l'utilizzo della memoria durante l'uso tipico (in Windows con Task Manager, in Linux con `htop` o `free -h`), e se il sistema si avvicina costantemente alla saturazione o usa molto swap, significa che serve più RAM.

| Capacità | Uso Tipico<br>Raccomandato                                           | Note                                                   |
|----------|----------------------------------------------------------------------|--------------------------------------------------------|
| 8 GB     | Office base, navigazione, uso molto leggero                          | Minimo assoluto, spesso già stretto su un PC nuovo     |
| 16 GB    | Office avanzato, gaming, multitasking moderato                       | Ottima base "sicura" per la maggior parte degli utenti |
| 32 GB    | Gaming + streaming, editing foto/video, dev, VM leggere              | Sweet spot attuale medio-alto                          |
| 64 GB    | Video 4K, 3D, molte VM, AI locale (modelli medi)                     | Territorio professionale/prosumer                      |
| 128 GB+  | Rendering pesante, dataset, AI/fine-tuning, virtualizzazione intensa | Workstation/creator, spesso su piattaforme HEDT        |

## 2.2 Perché conta il numero di moduli: 1×16 vs 2×8 vs 4×8

Un errore molto comune è considerare solo il totale ("mi servono 16 GB") ignorando **come** quei 16 GB sono divisi in moduli fisici. Un modulo RAM, la piccola schedina rettangolare che si inserisce in uno slot, è tecnicamente chiamato **DIMM** (*Dual In-line Memory Module*). La stessa capacità totale può essere raggiunta con diverse configurazioni, e queste non sono equivalenti.

Prendiamo 16 GB. Posso averli con **1x16** (un singolo modulo da 16 GB) o con **2x8** (due moduli da 8 GB). Dal punto di vista della capacità sono identici, ma da quello delle **prestazioni** no, e la differenza è tutt'altro che trascurabile. Il motivo si chiama **dual channel**, e lo approfondiremo nella sezione dedicata; qui basti anticipare il principio. Le moderne piattaforme desktop hanno un controller di memoria capace di comunicare con la RAM su **due canali** in parallelo, come se

avessero due corsie autostradali invece di una. Per utilizzare entrambe le corsie, servono almeno **due moduli**. Con un singolo modulo (1x16) si viaggia su una sola corsia: la RAM si dice che opera in **single channel**, e la banda disponibile è dimezzata. Con due moduli (2x8) si attivano entrambe le corsie, operando in **dual channel**, e la banda raddoppia.

L'impatto pratico è significativo, specialmente in due scenari. Il primo è il gaming con grafica integrata (APU, cioè processori con GPU inclusa): lì la RAM di sistema funge anche da memoria grafica, e il passaggio da single a dual channel può migliorare il frame rate anche del 30-70%. Il secondo è qualunque carico di lavoro limitato dalla banda di memoria, dalla compressione al calcolo scientifico. Anche nel gaming con GPU dedicata il dual channel fornisce un vantaggio misurabile, seppur meno eclatante. La regola pratica che ne deriva è tra le più importanti del capitolo: **a parità di capacità, preferire sempre due moduli a uno**. Comprare 1x16 "per lasciare uno slot libero e aggiungere RAM in futuro" è quasi sempre un falso risparmio, perché nel frattempo si rinuncia al dual channel.

Se due moduli sono meglio di uno, quattro non sono meglio di due? Qui il ragionamento si fa più complesso, ed è il motivo per cui la configurazione **4x8** esiste e va trattata con cautela. Aggiungere un terzo e un quarto modulo **non** aggiunge canali: le piattaforme desktop mainstream rimangono a due canali anche riempiendo quattro slot. I quattro moduli vengono distribuiti due per canale. Il problema è elettrico: popolare tutti gli slot significa mettere più "carico" sul controller di memoria integrato nella CPU, che deve pilotare più chip. Questo rende più difficile mantenere alte frequenze in modo stabile. In pratica, un kit da 2 moduli spesso raggiunge alte frequenze senza problemi, mentre gli stessi identici 4 moduli potrebbero costringere a una riduzione della frequenza per rimanere stabili. Il fenomeno è particolarmente marcato sulle **DDR5**, la cui gestione del segnale ad alta frequenza è più delicata: molte schede madri, con quattro moduli DDR5 popolati, vedono la frequenza massima garantita scendere in modo significativo. Ne riparleremo negli errori comuni. Il riassunto operativo: **a parità di capacità, un kit da due moduli è quasi sempre preferibile a un kit da quattro moduli**. Se servono 32 GB, un kit 2x16 batte quasi sempre un 4x8; se servono 64 GB, un 2x32 è più gestibile di un 4x16.

C'è un'ulteriore ragione, spesso trascurata, per acquistare la RAM in un **singolo kit**: i moduli all'interno dello stesso kit sono stati testati e selezionati (il termine tecnico è *binned*) per lavorare insieme a una specifica frequenza e latenza.

Acquistare due moduli oggi e altri due dello stesso modello tra un anno non garantisce che tutti e quattro opereranno alla frequenza pubblicizzata, anche se il codice prodotto è identico, perché i chip di silicio potrebbero provenire da lotti diversi con caratteristiche leggermente diverse. Se si prevede di raggiungere una certa capacità, è meglio acquistarla tutta in una volta in un singolo kit con il numero di moduli desiderato.

---

### 3. Velocità e Latenze

Questa è la sezione più tecnica e più incompresa. La velocità della RAM non è solo un numero: è una combinazione di due quantità che tirano in direzioni opposte, la **frequenza** (quanto spesso avvengono le operazioni) e le **latenze** (quanto tempo passa prima che un'operazione produca il suo risultato). Capire come si combinano è ciò che separa l'acquirente informato da chi guarda solo il numero più grande sulla scatola.

#### 3.1 Frequenza: MT/s vs. "MHz", cosa significa realmente

Sulle confezioni di RAM DDR, c'è un numero grande, come 3200, 6000, 6400. Storicamente, questo numero è stato chiamato "MHz" (megahertz), ma è un uso improprio che causa enorme confusione, e vale la pena chiarirlo una volta per tutte.

L'unità corretta è **MT/s**, che sta per *Mega Transfers per second*, milioni di trasferimenti di dati al secondo. L'acronimo **DDR** significa *Double Data Rate*, e descrive il trucco fondamentale di questa tecnologia: la memoria trasferisce dati **due volte** per ogni ciclo del suo segnale di clock, una volta sul fronte di salita del segnale e una volta sul fronte di discesa. È come un metronomo che, invece di segnare un battito per ticchettio, ne segna due, uno quando la lancetta sale e uno quando scende.

La conseguenza è che la **velocità di clock reale** della memoria è la metà del numero pubblicizzato. Una RAM "DDR5-6000" ha una velocità di clock effettiva di 3000 MHz, ma poiché trasferisce dati due volte per ciclo, esegue 6000 milioni di trasferimenti al secondo, cioè 6000 MT/s. Chiamarla "6000 MHz" è tecnicamente scorretto (la velocità di clock è 3000 MHz), ma è diventato gergo comune. La forma corretta è **6000 MT/s**. Nel resto del capitolo, useremo MT/s, ma sappiate che quando leggete "6000 MHz" su un forum o una scatola, si riferisce alla stessa cosa.

Perché la frequenza è importante? Perché determina, insieme alla larghezza del bus e al numero di canali, la **larghezza di banda**, ovvero quanti dati al secondo la RAM può riversare nella CPU. Più MT/s significano più larghezza di banda. Un modo semplice per stimarla su un canale a 64 bit (8 byte) è: larghezza di banda  $\approx$  MT/s  $\times$  8 byte. Una DDR5-6000 su un singolo canale fornisce quindi circa 48 GB/s, che raddoppia in dual channel. I carichi di lavoro che richiedono molta larghezza di banda (grafica integrata, alcune elaborazioni AI, compressione, streaming di grandi set di dati) beneficiano direttamente di una frequenza più elevata.

### 3.2 Timings: CL, tRCD, tRP, tRAS e cos'è la latenza CAS

Mentre la frequenza indica **quanto spesso** la RAM lavora, i **timings** indicano **quanto rapidamente** risponde a una singola richiesta. Sono una serie di numeri, solitamente riportati come una sequenza tipo "36-38-38-96" o evidenziando il primo, "CL36". Rappresentano ritardi, misurati in **cicli di clock**, che la memoria deve attendere tra un'operazione interna e la successiva. Poiché sono ritardi, qui **più basso è meglio**: è l'opposto della frequenza.

Per comprenderli, è necessaria un po' di anatomia. Internamente, un chip RAM è organizzato come una griglia di celle disposte in **righe** e **colonne** (come un foglio di calcolo). Per leggere i dati, il controller deve prima "attivare" la riga corretta e poi indicare la colonna. Ciascuno di questi passaggi richiede tempo, e i timings quantificano precisamente quei tempi.

Il primo e più citato è **CL**, *CAS Latency*, dove CAS sta per *Column Address Strobe*. È il numero di cicli di clock che intercorrono tra il momento in cui il controller richiede una specifica colonna (di una riga già attiva) e il momento in cui il primo dato è disponibile in uscita. In parole semplici: se la riga è già aperta, quanto tempo aspetto per avere il dato? È la latenza più frequente nell'operatività reale, motivo per cui viene evidenziata (il "CL36" sulla confezione).

Gli altri tre principali completano il quadro. **tRCD**, *RAS to CAS Delay* (dove RAS è *Row Address Strobe*), è il ritardo tra l'attivazione di una riga e la possibilità di richiedere una colonna al suo interno: in pratica, quanto tempo ci vuole per "aprire" una nuova riga prima di poter leggere. **tRP**, *Row Precharge time*, è il tempo necessario per "chiudere" la riga attualmente attiva (precaricarla) prima di poterne aprire un'altra: quando il dato che cerco è in una riga diversa da quella aperta, pago tRP per chiudere più tRCD per aprire la nuova. **tRAS**, *Row Active time*, è il tempo minimo in cui una riga deve rimanere attiva prima di poter essere chiusa, un vincolo che assicura il corretto refresh delle celle. Esistono decine di



altri timings secondari e terziari (tRC, tRFC, tFAW, e molti altri) che gli appassionati di overclock regolano manualmente, ma per le decisioni di acquisto, i quattro principali, e in particolare il CL, sono più che sufficienti.

### 3.3 Come calcolare la latenza reale in nanosecondi

Questo è il punto che smaschera il marketing e che ogni acquirente dovrebbe padroneggiare. Un CL basso, di per sé, non ti dice quanto è veloce la RAM, perché il CL è espresso in **cicli di clock**, e la durata di un ciclo dipende dalla frequenza. Un ciclo di clock ad alta frequenza dura meno di un ciclo a bassa frequenza. Quindi lo stesso CL "pesa" tempi reali diversi a frequenze diverse.

La latenza reale, quella che conta veramente perché misurata in tempo assoluto, si calcola così:

$$\text{Latenza (ns)} = (\text{CL} \times 2000) \div (\text{frequenza in MT/s})$$

Il 2000 deriva dal fatto che il clock reale è la metà degli MT/s (fattore 2) e che convertiamo in nanosecondi (fattore 1000):  $2 \times 1000 = 2000$ . Vediamo la formula in azione confrontando kit apparentemente molto diversi.

| Kit  | Frequenza | CL | Latenza Reale (ns)                            |
|------|-----------|----|-----------------------------------------------|
| DDR4 | 3200 MT/s | 16 | $(16 \times 2000) / 3200 =$<br><b>10.0 ns</b> |
| DDR4 | 3600 MT/s | 18 | $(18 \times 2000) / 3600 =$<br><b>10.0 ns</b> |
| DDR5 | 6000 MT/s | 30 | $(30 \times 2000) / 6000 =$<br><b>10.0 ns</b> |
| DDR5 | 6000 MT/s | 36 | $(36 \times 2000) / 6000 =$<br><b>12.0 ns</b> |
| DDR5 | 6400 MT/s | 32 | $(32 \times 2000) / 6400 =$<br><b>10.0 ns</b> |
| DDR5 | 7200 MT/s | 34 | $(34 \times 2000) / 7200 =$<br><b>9.4 ns</b>  |

La tabella insegna diverse cose contemporaneamente. Primo: un CL apparentemente "peggiore" (CL30 contro CL16) non significa affatto RAM più lenta, perché a frequenza doppia, quel CL30 produce la **stessa** latenza reale di 10 ns. Questo è esattamente il caso per DDR4-3200 CL16 e DDR5-6000 CL30: latenza identica, ma DDR5 ha il doppio della banda. Secondo: a parità di frequenza (6000

MT/s), la differenza tra CL30 e CL36 è reale, 10 ns contro 12 ns, e per questo motivo, un kit "6000 CL30" è considerato migliore di un kit "6000 CL36". Terzo: la latenza in ns è il **grande equalizzatore** che permette di confrontare kit di diverse generazioni e frequenze su un terreno comune. Quando qualcuno ti chiede se una RAM è "veloce", la risposta seria non è la sola frequenza o il solo CL, ma la combinazione: banda (frequenza × canali) e latenza reale (ns).

### 3.4 Frequenza contro latenza: cosa conta di più e quando

Dato che frequenza e latenza tirano in direzioni opposte (all'aumentare della frequenza, spesso aumenta il CL, e viceversa), la domanda pratica è: su quale delle due conviene investire? La risposta dipende dal carico di lavoro, e capire il perché aiuta a evitare spese inutili.

I carichi di lavoro **sensibili alla banda** beneficiano maggiormente della frequenza. Questo include la grafica integrata, che, come detto, usa la RAM come memoria video ed è affamata di banda; alcuni processi paralleli; e la copia di grandi blocchi di dati. Qui, tra RAM veloce con timing rilassati e RAM più lenta con timing stretti, la prima tende a vincere.

I carichi di lavoro **sensibili alla latenza** beneficiano maggiormente di timing bassi. Il caso emblematico è il **gaming**, specialmente quando la CPU è il collo di bottiglia (basse risoluzioni, frame rate elevati, giochi con logica complessa e molti accessi alla memoria sparsi). I motori di gioco fanno molti accessi piccoli e imprevedibili: ciò che conta non è tanto quanta banda al secondo, ma quanto velocemente arriva il singolo dato richiesto. Per questo, nel gaming, a parità di banda, un kit con latenza reale inferiore si comporta meglio. Un kit "6000 CL30" (10 ns) è spesso preferibile a un kit "6400 CL36" (11.25 ns) anche se il secondo ha una frequenza più alta, perché nel gaming la latenza ha un peso maggiore.

La regola pratica: per uso generale e gaming, punta a **bassa latenza reale** a una frequenza bilanciata; per grafica integrata o carichi di pura banda, privilegia la **frequenza**. E in ogni caso, non farti ammaliare dal grande numero di MT/s ignorando il CL.

### 3.5 XMP ed EXPO: perché la RAM va a frequenza base senza di essi

Ecco uno dei punti che genera più delusione nei neofiti: **compri una RAM "6000 MT/s CL30", la installi, e il computer la fa andare a 4800 MT/s con timing altissimi**. Questo non è un difetto, non è una truffa: è il comportamento atteso, e per correggerlo, devi attivare un profilo. Cerchiamo di capire perché.

Le specifiche ufficiali della memoria sono definite da un ente chiamato **JEDEC** (*Joint Electron Device Engineering Council*), che standardizza frequenze e timing "sicuri" e garantiti per funzionare su qualsiasi sistema conforme. Questi valori JEDEC sono volutamente conservativi. Quando accendi il PC, la RAM comunica le sue caratteristiche alla scheda madre tramite un piccolo chip a bordo chiamato **SPD** (*Serial Presence Detect*), e di default, il sistema imposta i valori JEDEC, che sono quelli sicuri e bassi. Per questo quel "6000" parte a 4800: 4800 è la specifica JEDEC di base, 6000 è la velocità "potenziata" per cui il kit è stato selezionato.

Per far funzionare la RAM alla frequenza e ai timing pubblicizzati sulla scatola, è necessario attivare un **profilo di overclock precaricato**, anch'esso memorizzato nell'SPD. Sulla piattaforma **Intel**, questo profilo si chiama **XMP** (*Extreme Memory Profile*); sulla piattaforma **AMD**, per le CPU Ryzen di recente generazione su socket AM5, si chiama **EXPO** (*EXtended Profiles for Overclocking*). Si tratta di due nomi commerciali per lo stesso concetto: un set di impostazioni ottimizzate che, con un singolo click nel BIOS, portano la RAM alle prestazioni per cui avete pagato. Molti kit di fascia alta includono **entrambi** i profili per coprire entrambe le piattaforme; alcuni ne includono solo uno, ed è bene verificare prima dell'acquisto, specialmente per una build AMD (in assenza di EXPO, un profilo XMP può quasi sempre essere comunque utilizzato, ma la compatibilità dei timing non è garantita al 100%).

Attivarli è semplice ma richiede di entrare nel **BIOS/UEFI**, il firmware della scheda madre (solitamente premendo `Canc` o `F2` all'avvio). Lì, si cerca la voce XMP o EXPO (spesso nella pagina principale o in una sezione "OC"/"Tweaker"/"Ai Overclock"), la si abilita selezionando il profilo desiderato, si salva e si riavvia. Il sistema si riavvierà alla frequenza corretta. Questo è un passaggio che molti utenti dimenticano, ritrovandosi con RAM costosa che rende come RAM economica. **Se avete comprato RAM ad alta frequenza e non avete attivato XMP/EXPO, non la state usando come dovrete.** Ci tornerà utile negli errori comuni perché è, statisticamente, l'errore numero uno.

Una onesta precisazione tecnica: XMP ed EXPO sono, a tutti gli effetti, forme di **overclock della memoria**, ovvero un funzionamento oltre le specifiche standard JEDEC. Questi profili sono validati dal produttore del kit e nella stragrande maggioranza dei casi sono estremamente stabili, ma proprio perché "spingono" oltre lo standard, è possibile, in rari casi, incorrere in instabilità legate al fatto che il memory controller della *vostra* specifica CPU non gradisce quella frequenza. In

quei casi, si scende di una tacca di frequenza o si rilassano leggermente i timing. Anche per questo esistono le liste di compatibilità (QVL), di cui parleremo a breve.

---

## 4. Dual channel (e oltre)

### 4.1 Come funziona il dual channel e il reale guadagno di banda

Abbiamo già anticipato il concetto quando abbiamo parlato del numero di moduli; ora lo approfondiremo. Il **dual channel** è la capacità del controller di memoria di comunicare con la RAM su **due bus paralleli indipendenti**, raddoppiando di fatto la banda complessiva dell'interfaccia verso la memoria. Se un singolo canale DDR trasferisce dati 64 bit alla volta, due canali ne trasferiscono 128. Riusando la metafora dell'autostrada: due corsie invece di una, con il doppio del traffico che può scorrere nello stesso istante.

Il guadagno teorico di banda è, sulla carta, del 100%: raddoppiare i canali raddoppia la banda teorica. In pratica, il beneficio prestazionale non è sempre del 100% perché non tutti i carichi di lavoro sono limitati dalla banda di memoria, ma in tutti gli scenari in cui lo sono, l'aumento è reale e spesso percettibile. Il caso più eclatante, già citato, è quello della **grafica integrata**: una APU che passa da singolo a doppio canale può guadagnare decine di punti percentuali nel frame rate, perché la sua GPU era letteralmente soffocata per mancanza di banda. Anche con una GPU dedicata, e in compiti di produttività, il dual channel fornisce un vantaggio misurabile. La conclusione operativa è la stessa: **il dual channel non è un lusso; è la configurazione normale e va sempre assicurata.**

### 4.2 Quali slot popolare: il caso A2/B2 ed errori di installazione

Un errore fisico sorprendentemente frequente si annida qui. Le schede madri mainstream hanno tipicamente **quattro slot di memoria**, ma per attivare il dual channel con **due** moduli, non basta inserirli in due slot qualsiasi: vanno posizionati negli slot corretti. I quattro slot sono divisi tra i due canali in maniera alternata, e il produttore specifica una configurazione precisa per il dual channel con due moduli.

Nella stragrande maggioranza delle schede madri, gli slot, numerati a partire dalla CPU, corrispondono a due canali (A e B) con due slot ciascuno, disposti come **A1, A2, B1, B2** o indicati come DIMM\_A1, DIMM\_A2, DIMM\_B1, DIMM\_B2. La configurazione consigliata per due moduli è quasi sempre il **secondo slot di ciascun canale**, ovvero **A2 e B2**, che fisicamente sono il **secondo e il quarto slot**

**a partire dalla CPU** (lasciando quindi un vuoto tra i due moduli). Questa disposizione, che a prima vista sembra strana perché lascia uno slot vuoto in mezzo, è quella che offre la migliore qualità del segnale ad alta frequenza, un aspetto diventato critico con le DDR5. Alcuni produttori usano lo schema opposto (A1/B1), ma il principio è sempre lo stesso: **due moduli vanno inseriti in due slot dello stesso "colore" o secondo lo schema del manuale, mai a caso.**

L'errore tipico è inserire i due moduli nei primi due slot adiacenti (slot 1 e 2), che spesso appartengono allo **stesso** canale: il risultato è che la RAM opera in **single channel** pur avendo due moduli, dimezzando la banda senza che appaia alcun messaggio di errore. Il computer si accende, funziona, e l'utente non si accorge di nulla, se non di un calo prestazionale che difficilmente collegherà alla causa. La regola d'oro: **consultare sempre il manuale della scheda madre per la disposizione corretta**, e nel dubbio, la configurazione A2/B2 (secondo e quarto slot) è quella corretta nella stragrande maggioranza dei casi. Dopo l'assemblaggio, verificare in Windows con Task Manager (scheda Prestazioni → Memoria, dove la dicitura sull'utilizzo dei canali compare con alcuni strumenti) o, ancora meglio, con utility come CPU-Z, che riporta esplicitamente "Channel #: Dual" nella scheda Memory.

#### 4.3 Oltre il dual channel: quad e octa channel

Le piattaforme desktop consumer si fermano al dual channel, ma esistono piattaforme superiori. Workstation e server basati su piattaforme **HEDT** (*High-End Desktop*) e socket dedicati (come le linee AMD Threadripper e Threadripper PRO, o le controparti Intel Xeon) offrono **quad channel** (quattro canali), **hexa/octa channel** (sei o otto canali) e, nelle generazioni di server più recenti, anche più di otto. Ogni canale aggiuntivo aumenta la sua larghezza di banda: un sistema octa channel ha una larghezza di banda della memoria che surclassa qualsiasi desktop consumer, ed è ciò che serve per alimentare CPU con decine di core affamati di dati, per dataset massicci, per la virtualizzazione massiccia e per carichi di lavoro AI/HPC.

Su queste piattaforme, cambiano anche le regole di installazione (i canali devono essere popolati in gruppi precisi per attivarli tutti) e spesso il tipo di RAM (memoria **registrata** con **ECC**, che menzioneremo brevemente). Poiché l'argomento è vasto e riguarda una nicchia specifica, lo tratteremo in profondità nel **capitolo dedicato alle workstation e ai server**. Qui è sufficiente sapere che se un giorno costruirete una macchina per il calcolo pesante, il numero di canali

di memoria sarà uno dei parametri chiave, e che il salto dai due canali del desktop ai quattro/otto delle piattaforme professionali è una delle principali ragioni tecniche per cui quelle piattaforme esistono.

#### 4.4 Single rank contro dual rank

Un concetto finale, sottile ma influente sulle prestazioni, è il **rank** del modulo. Un *rank* è un insieme di chip di memoria sul modulo che vengono acceduti insieme come un singolo blocco a 64 bit (o 72 con ECC). Un modulo può essere **single rank** (un solo blocco) o **dual rank** (due blocchi indipendenti sullo stesso modulo), e più raramente quad rank.

La differenza pratica è che il controller, con più rank disponibili, può "interlacciare" gli accessi: mentre un rank sta completando un'operazione interna, il controller può avviarne un'altra sull'altro rank, nascondendo parte delle latenze. Questo fenomeno, chiamato **rank interleaving**, significa che la stessa capacità e frequenza si comportano leggermente meglio in una configurazione dual rank. In molti test di gioco e produttività, un sistema con RAM dual rank (ad esempio, due moduli dual rank, quindi quattro rank totali) mostra un guadagno di qualche punto percentuale rispetto al single rank, a parità di condizioni.

Tuttavia, c'è uno svantaggio: più rank significano più carico elettrico sul controller di memoria, quindi la RAM dual rank è tipicamente più difficile da far funzionare a frequenze estreme rispetto al single rank. È un altro esempio del costante compromesso in questo campo tra prestazioni e stabilità del segnale. Per l'acquirente medio, la questione è secondaria e in gran parte al di fuori del loro controllo diretto (spesso i moduli di maggiore capacità sono dual rank per design), ma è utile saperlo per interpretare recensioni e benchmark che lo menzionano. Un'indicazione pratica, tuttavia, emerge chiaramente: **due moduli sono spesso preferibili a uno anche per questo motivo**, perché due moduli single rank offrono al controller due rank con cui interlacciare, mentre un singolo modulo single rank ne offre solo uno.

---

## 5. DDR4 contro DDR5

### 5.1 Cosa cambia sotto il cofano

DDR4 e DDR5 sono due **generazioni** successive dello standard DDR. DDR5 è la più recente delle due nel mondo mainstream (il prossimo standard è già in fase di definizione, ma al momento della stesura di questo documento non è ancora

presente nei PC consumer [**dati volatili: verificare la generazione attuale**]). Il salto generazionale non è solo un semplice aumento numerico: frequenze, tensioni, architettura interna e gestione dell'alimentazione cambiano. Vediamo i punti chiave.

Le **frequenze** fanno un netto balzo. La DDR4 su desktop opera principalmente nell'intervallo 2133–3600 MT/s, con picchi in overclock oltre; la DDR5 parte da 4800 MT/s e scala facilmente a 6000, 6400 e oltre, con kit estremi molto più veloci. La larghezza di banda disponibile con DDR5 è quindi molto maggiore fin dall'inizio.

La **tensione** operativa standard scende da 1,2 V per DDR4 a 1,1 V per DDR5, un vantaggio in termini di efficienza a parità di prestazioni. Ma il cambiamento più interessante riguarda **dove** avviene la regolazione della tensione. Su DDR4, la gestione dell'alimentazione della RAM è sulla scheda madre; su DDR5, invece, ogni modulo integra il proprio **PMIC** (*Power Management Integrated Circuit*) on-module. Spostare la regolazione della tensione sul modulo migliora la qualità e la stabilità dell'erogazione di potenza locale, un requisito diventato necessario alle alte frequenze di DDR5. È anche uno dei motivi per cui i moduli DDR5 costano di più a parità di capacità.

DDR5 introduce anche l'**ECC on-die**. ECC (*Error Correcting Code*) è un meccanismo che rileva e corregge gli errori nei bit di memoria. Attenzione a non confondersi: l'ECC **on-die** di DDR5 corregge gli errori che si verificano *all'interno del chip* ed è progettato per garantire l'affidabilità di chip sempre più densi; **non** è lo stesso dell'ECC "completo" della memoria server, che protegge anche i dati mentre viaggiano tra RAM e CPU e richiede un supporto specifico di CPU e scheda madre. In altre parole: un modulo DDR5 desktop ha ECC on-die ma non è "memoria ECC" nel senso enterprise del termine. Questa è una distinzione che confonde molti e che vale la pena tenere a mente.

Infine, ogni modulo DDR5 è internamente diviso in **due sottocanali indipendenti da 32 bit** (più i bit ECC), invece del singolo canale a 64 bit di DDR4. Un singolo modulo DDR5 offre quindi al controller due sottocanali paralleli, migliorando l'efficienza di accesso e la capacità di gestire più richieste contemporaneamente. Questa è una delle ragioni architettureali per cui DDR5 offre prestazioni migliori anche a parità di larghezza di banda teorica.

La tabella riassume il confronto generazionale. I valori tipici di frequenza sono indicativi, e la fascia "alta" di DDR5 aumenterà nel tempo **[dati volatili]**.

| Caratteristica              | DDR4               | DDR5                                   |
|-----------------------------|--------------------|----------------------------------------|
| Frequenze desktop tipiche   | 2133–3600 MT/s     | 4800–6400+ MT/s                        |
| Tensione standard           | 1,2 V              | 1,1 V                                  |
| Gestione dell'alimentazione | Sulla scheda madre | PMIC on-module                         |
| ECC on-die                  | No                 | Sì (interno al chip, non ECC "server") |
| Struttura del modulo        | 1 canale da 64 bit | 2 sottocanali da 32 bit                |
| Chiave elettrica (notch)    | Posizione DDR4     | Posizione DDR5 (diversa)               |

### 5.2 Compatibilità: DDR4 e DDR5 non sono intercambiabili

Questo è il punto in cui non si possono commettere errori, o si rischia di acquistare componenti inutilizzabili. **DDR4 e DDR5 sono fisicamente ed elettricamente incompatibili.** Hanno lo stesso numero di pin ma disposti diversamente, e soprattutto la **notch** (la tacca sul bordo dorato dei contatti che impedisce l'inserimento errato) è in posizione diversa: un modulo DDR5 non entrerà in uno slot DDR4 e viceversa. Questa è una protezione fisica deliberata, proprio per impedire inserimenti errati.

Ma la questione va oltre lo slot: dipende dalla **combinazione CPU + scheda madre**. Ogni scheda madre supporta o DDR4 o DDR5, mai entrambe sullo stesso slot (ci sono stati rarissimi casi ibridi con slot separati, ma sono eccezioni trascurabili). E siccome il controller di memoria è integrato nella CPU, anche il processore deve supportare lo standard corretto. In pratica: quando si sceglie la piattaforma, si decide contemporaneamente CPU, scheda madre e tipo di RAM come un unico blocco. Non si può comprare RAM DDR5 e poi installarla su una scheda madre DDR4, né "aggiornare" da DDR4 a DDR5 senza cambiare scheda madre (e spesso CPU). Questo è esattamente il principio del "sistema a tre" enunciato all'inizio: **RAM, CPU e scheda madre si scelgono insieme**. L'errore di acquistare il tipo di RAM sbagliato per la propria piattaforma è tra i più costosi e frustranti, e purtroppo tra i più comuni tra chi assembla senza verificare.

### 5.3 Quando la DDR4 ha ancora senso e qual è il sweet spot della DDR5

Con la DDR5 ormai matura e con prezzi molto più ragionevoli rispetto al lancio, **per una nuova build, la scelta predefinita è la DDR5 [dato volatile: verificare**



**rapporto prezzi attuale].** Le ultime piattaforme Intel e AMD sono nate DDR5, offrendo più banda e una migliore prospettiva di longevità.

Tuttavia, ci sono ancora scenari in cui la **DDR4 ha ancora senso**. Il primo è l'**aggiornamento di un sistema esistente** già su piattaforma DDR4: se si ha una buona scheda madre e CPU DDR4, aggiungere o sostituire RAM DDR4 è molto più economico che rifare l'intera piattaforma per passare a DDR5. Il secondo è una **build entry-level con budget molto ristretto**, dove una piattaforma DDR4 di generazione precedente (CPU + scheda madre + RAM) può costare significativamente meno di una equivalente DDR5, con una differenza prestazionale non decisiva per usi leggeri. Il terzo è il **recupero di componenti**: se si ha già RAM DDR4 di qualità, riutilizzarla ha senso. Al di fuori di questi casi, però, guardare al futuro significa DDR5.

Sul fronte DDR5, esiste un **sweet spot** consolidato, che è il punto di miglior rapporto prestazioni-prezzo-stabilità. Questo merita una spiegazione tecnica perché è uno degli esempi più istruttivi di come RAM e CPU siano collegate. Per le piattaforme **AMD AM5** (serie Ryzen 7000 e successive), il kit di riferimento è **DDR5-6000 CL30**. La ragione non è arbitraria: dipende dalla relazione con l'**Infinity Fabric**, il bus interno che collega i vari blocchi del processore (cluster di core, controller di memoria, cache) nelle CPU Ryzen. Su queste CPU, le migliori prestazioni si ottengono quando il controller di memoria (chiamato **UCLK**), l'Infinity Fabric (**FCLK**) e il clock della memoria (**MCLK**) operano in un rapporto sincrono, in particolare un rapporto **1:1** tra il clock della memoria e il clock del controller. A 6000 MT/s, la RAM opera con un clock effettivo di 3000 MHz, e il controller di memoria può mantenere il rapporto 1:1 stabilmente sulla maggior parte dei processori. Andando più in alto (es. 6400 o 6800 MT/s), molte CPU Ryzen non riescono più a mantenere il rapporto 1:1, e il controller è costretto a passare a un rapporto **2:1**, introducendo un divisore che **aumenta la latenza** e spesso annulla, o addirittura inverte, il vantaggio della frequenza più alta. Questo è il motivo per cui "6000 CL30" è considerato il punto d'oro sulla piattaforma AM5: massimizza la frequenza mantenendo la sincronia, con una latenza reale di 10 ns. Aumentare la frequenza si traduce paradossalmente in prestazioni *peggiori* nella maggior parte dei casi, a meno che non si sia fortunati con il silicio e si sappia come modificare le impostazioni avanzate.

Sulle recenti piattaforme **Intel**, il controller di memoria è più tollerante e scala meglio con frequenze più alte, quindi ha senso puntare più in alto (es. 6400, 7200

MT/s e oltre) se il budget lo consente, sempre considerando la latenza reale. Ma il concetto generale rimane: **la frequenza "migliore" non è la più alta in assoluto, è la più alta che la tua specifica CPU può gestire mantenendo sincronia e stabilità.** Controlla sempre le raccomandazioni aggiornate per la piattaforma esatta che stai acquistando, poiché questi sweet spot si evolvono con le nuove generazioni **[dati volatili]**.

---

## 6. Marche e Come Scegliere

### 6.1 Chi Produce i Chip e Chi Assembla i Moduli: Due Lavori Diversi

Uno dei malintesi più radicati è pensare che marchi come Corsair o G.Skill "producano" RAM. In realtà, nel mondo della memoria, ci sono **due livelli distinti**, e comprenderli chiarisce molto sul perché alcuni kit costano e performano più di altri.

Al primo livello ci sono i veri e propri **produttori di chip di memoria**, il silicio dove i dati sono fisicamente immagazzinati. Sono pochissimi al mondo, perché costruire fabbriche di semiconduttori (fab) costa miliardi: essenzialmente **Samsung, SK Hynix e Micron**. Questi tre giganti producono i chip DRAM che finiscono, in un modo o nell'altro, sulla stragrande maggioranza dei moduli in commercio, indipendentemente dal marchio stampato su di essi.

Al secondo livello ci sono i **produttori di moduli**: aziende che acquistano i chip dai tre produttori, li montano su un circuito stampato (il PCB del modulo) insieme a PMIC, SPD ed eventuale dissipatore, li testano, li selezionano, definiscono i profili XMP/EXPO e poi li commercializzano con la propria garanzia e il proprio marchio. L'elenco qui è più lungo: **Corsair, G.Skill, Kingston, Crucial, TeamGroup, Patriot, ADATA** e altri. Una precisazione: **Crucial** è il marchio consumer di **Micron**, quindi è sia un produttore di chip che un assemblatore, un caso speciale che garantisce una filiera integrata. Anche **Samsung** e **SK Hynix** vendono moduli con il proprio marchio, ma sono meno presenti nella vendita al dettaglio consumer rispetto agli assemblatori specializzati.

La conseguenza pratica è che **il marchio sulla scatola non racconta tutta la storia**: due kit di marche diverse potrebbero usare gli stessi identici chip Hynix, e due kit della stessa marca potrebbero usare chip di produttori diversi a seconda del lotto. Ciò che distingue veramente i kit è la **selezione (binning)** dei chip, la qualità del PCB, l'efficacia dei profili XMP/EXPO e il supporto/garanzia.

## 6.2 Perché G.Skill, Corsair e Kingston dominano

Se questi tre marchi (con Crucial e TeamGroup subito dietro) sono i più consigliati, ci sono ragioni concrete che vanno oltre la semplice popolarità.

La prima è il **binning**, ovvero la selezione dei chip migliori. Non tutti i chip che escono da una fabbrica sono uguali: alcuni possono gestire frequenze più elevate con timing più bassi, altri meno. Gli assemblatori più seri acquistano grandi volumi, li testano e allocano i chip migliori ai kit di fascia alta (che vendono a un prezzo maggiore) e i chip standard ai kit economici. Un kit "premium" G.Skill o Corsair con alta frequenza e bassa latenza è tale perché utilizza chip selezionati in grado di raggiungere quelle prestazioni con margine. Questo è esattamente ciò per cui si paga il sovrapprezzo.

La seconda è la **garanzia** e il supporto. Questi marchi offrono tipicamente garanzie lunghe, spesso a vita entro i limiti specificati, e un servizio di sostituzione affidabile: un aspetto non banale per un componente che ci si aspetta duri quanto il PC.

La terza, cruciale in fase di acquisto, è la **compatibilità QVL**. QVL sta per *Qualified Vendor List*: è l'elenco, pubblicato dai produttori di schede madri, dei kit RAM specifici che sono stati **testati e validati** su quella scheda a una certa frequenza. I marchi dominanti appaiono ampiamente nelle QVL proprio perché sono i più diffusi e i più testati, il che riduce drasticamente il rischio di incompatibilità o instabilità con XMP/EXPO. Acquistare un kit presente nella QVL della propria scheda madre è il modo più semplice per stare tranquilli.

## 6.3 Hynix A-die e M-die: perché gli appassionati li cercano

Tra gli appassionati di overclock, i chip "**Hynix A-die**" o "**M-die**" sono pronunciati con riverenza. Cosa sono e perché sono importanti? Come accennato, i chip provengono da pochi produttori, e ognuno produce diverse "revisioni" di silicio nel tempo, identificate da codici. Nel mondo DDR5, i chip **SK Hynix** si sono guadagnati la reputazione di essere i migliori per l'overclocking, e tra le loro revisioni, l'**A-die** è considerato l'élite: gestisce frequenze molto elevate e timing molto stretti con ampio margine, mentre l'**M-die** è un gradino sotto ma comunque eccellente. In pratica, un kit equipaggiato con chip Hynix A-die ha il potenziale per essere spinto ben oltre le sue specifiche dichiarate, il che attrae coloro che eseguono la messa a punto manuale.

Per l'acquirente medio, la caccia a un "die" specifico è un dettaglio da nerd: se si abilita semplicemente XMP/EXPO senza l'intenzione di overclockare manualmente, la revisione del chip conta poco, perché il kit funzionerà come pubblicizzato a prescindere. L'argomento diventa rilevante solo se si intende **spingere la RAM oltre le specifiche** regolando manualmente i timing: in quel caso, cercare kit noti per utilizzare Hynix A-die (informazioni disponibili in database e comunità di overlocking, poiché i produttori non sempre lo dichiarano) massimizza le possibilità di ottenere risultati record. È un esempio di come lo stesso prodotto abbia un diverso "livello di lettura" a seconda di quanto si voglia approfondire.

#### 6.4 RGB e dissipatori: estetica contro sostanza, e il problema dell'altezza

La maggior parte dei kit di fascia medio-alta oggi presenta illuminazione **RGB** (LED colorati e programmabili) e vistosi **dissipatori** metallici (*heatspreaders*). È importante distinguere ciò che è funzionale da ciò che è puramente estetico.

L'**RGB** è, dal punto di vista delle prestazioni, completamente irrilevante: è pura estetica. Non c'è nulla di male nel volere una build che si illumini in modo coordinato, ma dovrebbe essere acquistato con la consapevolezza che si sta pagando un premio per l'aspetto, non per la velocità. Infatti, i kit RGB tendono ad essere più alti (per ospitare la barra LED) e più costosi a parità di specifiche rispetto alle versioni senza. Chi cerca il miglior rapporto prestazioni/prezzo può risparmiare scegliendo modelli semplici, che spesso hanno chip identici.

I **dissipatori** hanno una funzione reale ma sono spesso sopravvalutati sui kit consumer: dissipano il calore dai chip, il che è utile a frequenze elevate e in overlocking aggressivo, ma per la RAM a specifiche standard (anche con XMP/EXPO a 6000 MT/s), un modesto dissipatore è più che sufficiente, e i grandi heatspreaders su alcuni kit sono in gran parte per lo spettacolo. Il calore della RAM è modesto rispetto a CPU e GPU.

Tuttavia, c'è un aspetto della dimensione dei moduli che è tutt'altro che estetico e spesso porta a un errore fisico comune: lo **spazio rispetto al dissipatore ad aria della CPU**. I grandi dissipatori ad aria per CPU, con le loro ventole ingombranti, spesso sporgono sopra gli slot RAM. Se i moduli sono molto alti (a causa di elaborati dissipatori di calore o barre RGB), possono **entrare fisicamente in collisione** con il dissipatore della CPU, impedendone l'installazione o costringendo a spostare la ventola verso l'alto (peggiorando il raffreddamento) o addirittura rendendo impossibile chiudere il case. Questo è un problema molto

reale che rovina molti assemblaggi dell'ultimo minuto. Contromisure: controllare sempre l'**altezza del modulo** (in millimetri, indicata nelle specifiche) e la **compatibilità RAM del dissipatore della CPU** (molti produttori di dissipatori pubblicano l'altezza massima della RAM supportata sotto la ventola), oppure optare per kit **low-profile** quando si utilizza un dissipatore ad aria ingombrante. Con il raffreddamento a liquido AIO, questo problema è quasi inesistente, perché sopra la CPU c'è solo la pompa/waterblock, che non invade gli slot RAM.

### 6.5 Il metodo di selezione passo-passo

Mettendo insieme l'intero capitolo, ecco l'ordine logico per la scelta della RAM, un processo che evita tutti gli errori tipici se seguito correttamente.

Iniziare sempre dalla **piattaforma**: quale CPU e quale scheda madre? Questo determina se la RAM sarà **DDR4 o DDR5** (questo non è negoziabile, dipende dal socket e dal chipset) e quali frequenze ha senso puntare (ricordando il sweet spot 6000 CL30 su AM5 e la maggiore scalabilità di Intel). Una volta definita la piattaforma, decidere la **capacità** in base al caso d'uso (16/32/64 GB secondo la sezione 2). Quindi scegliere un **kit di due moduli** per garantire il dual channel, evitando moduli singoli e, quando possibile, evitando quattro moduli a favore di due più grandi. A questo punto, identificare il giusto **sweet spot frequenza/latenza** per la piattaforma, pensando in termini di **latenza reale (ns)** e non solo al numero grande in MT/s. Dopodiché, verificare la presenza del kit (o di uno equivalente) nella **QVL** della scheda madre, o almeno che il profilo corretto (XMP per Intel, EXPO per AMD) sia supportato. Solo alla fine entra in gioco il **budget**, scegliendo tra i kit che hanno superato i filtri precedenti quello con il miglior rapporto qualità/prezzo, tenendo conto dell'altezza dei moduli se si utilizza un dissipatore ad aria e decidendo se pagare l'eventuale premium estetico per l'RGB. Questo ordine, **piattaforma → capacità → kit 2 moduli → sweet spot frequenza/latenza → QVL → budget/estetica**, è il nucleo operativo dell'intero capitolo.

### 6.6 Fasce di budget: entry, mid, high-end

Traducendo il metodo in raccomandazioni per fascia, con l'avvertenza che kit e prezzi specifici sono in costante cambiamento **[dati volatili: controllare modelli e prezzi attuali prima dell'acquisto]**.

Per la fascia **entry-level** (budget minimo), l'obiettivo è avere dual channel e capacità sufficiente senza spese inutili. Per una build DDR5 economica, questo significa un kit **2x8 GB (16 GB)** con specifiche JEDEC o leggermente superiori, di

un marchio affidabile come Crucial, Kingston o TeamGroup, senza RGB. Per una build che riutilizza o sfrutta parti usate a prezzi accessibili, una piattaforma **DDR4** con un buon kit 2x8 3200 CL16 rimane perfettamente valida per gaming leggero e lavoro. La priorità qui è: due moduli, marchio affidabile, XMP/EXPO abilitato.

Per il livello **mid-range** (utente medio), la scelta predefinita è un kit **DDR5 2x16 GB (32 GB)** al "sweet spot" della piattaforma: per AM5, il famoso **6000 CL30 EXPO**; per Intel, un 6000 CL30 o un gradino superiore se il budget lo permette. Marche come G.Skill, Corsair, Kingston, con o senza RGB a seconda delle preferenze, e idealmente presenti nella QVL. Questa configurazione offre il miglior equilibrio tra costo, prestazioni e longevità per la maggior parte dei nuovi PC odierni.

Per il livello **high-end** (prestazioni senza compromessi, creatori e professionisti), la capacità e/o la qualità aumentano. Per il gaming di alto livello e la produttività seria, **2x16 GB o 2x32 GB (64 GB)** di un kit selezionato a bassa latenza; per workstation, editing 4K, molte VM o AI locale, **64 o 128 GB**, considerando, sulle piattaforme che lo permettono, anche kit da 4 moduli o soluzioni HEDT con più canali (fare riferimento al capitolo workstation). Qui ha senso investire in chip Hynix A-die se l'overclock è un obiettivo, in kit ad alta frequenza su piattaforme Intel che ne beneficino, e prestare attenzione all'estetica se fa parte degli obiettivi. Il principio, però, rimane invariato: anche in high-end, **la latenza reale e la sincronizzazione con la CPU contano più del numerone sulla scatola.**

---

## 7. Errori Comuni dell'Acquirente

Qui raccogliamo e spieghiamo gli errori più comuni, molti dei quali già incontrati nel corso del capitolo. Conoscerli in anticipo è il modo migliore per evitarli.

Il primo, e statisticamente più comune, è **non abilitare XMP o EXPO**. Si spendono soldi per RAM ad alta frequenza e la si lascia girare alla velocità base JEDEC perché non si è entrati nel BIOS ad abilitare il profilo. Il risultato è aver pagato per prestazioni che non si stanno usando. Rimedio: entrare nel BIOS/UEFI, abilitare XMP (Intel) o EXPO (AMD), salvare e verificare la frequenza con CPU-Z. È un click che vale decine di euro di RAM.

Il secondo è **acquistare il tipo di RAM sbagliato per la piattaforma**, ovvero DDR4 quando serve DDR5 o viceversa. Questo deriva dal non comprendere che il tipo di memoria dipende da CPU e scheda madre e non è interscambiabile. Rimedio: verificare *sempre*, prima di ordinare, quale standard supporta la propria

scheda madre (e CPU), perché il modulo sbagliato semplicemente non entrerà nello slot.

Il terzo è **mischiare kit diversi**. Comprare due moduli oggi e altri due un anno dopo, magari dello stesso modello ma di un batch diverso, o peggio, mischiare marche, capacità e frequenze diverse. Non essendo stati selezionati insieme, la coesistenza alla frequenza dichiarata non è garantita: si rischia instabilità, mancata attivazione di XMP/EXPO, o funzionamento alla frequenza del modulo più lento. Rimedio: acquistare la capacità target in un **unico kit** del numero di moduli desiderato fin da subito.

Il quarto è **installare i moduli negli slot sbagliati**, tipicamente i primi due adiacenti, risultando in single channel anche con due moduli. Nessun messaggio di errore avvisa: il PC funziona, ma con metà della banda. Rimedio: seguire il manuale della scheda madre; in caso di dubbio, usare **A2 e B2** (secondo e quarto slot dalla CPU) e verificare la dicitura "Dual" in CPU-Z.

Il quinto è **installare quattro moduli su piattaforme che li gestiscono male**, specialmente su DDR5, dove riempire tutti e quattro gli slot spesso costringe il controller ad abbassare la sua frequenza per rimanere stabile. Si finisce con più capacità ma frequenza effettiva inferiore, a volte faticando persino ad abilitare XMP/EXPO. Rimedio: preferire **due moduli di capacità maggiore** (2x16 invece di 4x8, 2x32 invece di 4x16) e, se quattro moduli sono assolutamente necessari, mettere in conto una possibile riduzione di frequenza e verificare il supporto nella QVL.

Il sesto è **scegliere RAM troppo alte sotto un dissipatore CPU ad aria ingombrante**, con conseguente collisione fisica che impedisce l'installazione o compromette il raffreddamento. Rimedio: verificare l'altezza dei moduli in mm e il clearance dichiarato dal produttore del dissipatore, oppure scegliere moduli **low-profile**.

Il settimo, più concettuale, è **farsi ipnotizzare dalla frequenza ignorando la latenza reale**, comprando un kit con MT/s altissimi e timing pessimi, magari su una piattaforma (come AM5) dove quella frequenza costringe anche il controller fuori dal rapporto 1:1, risultando in prestazioni peggiori di un kit "più lento" ma bilanciato. Rimedio: ragionare in termini di **latenza reale (ns)** e rispettare lo sweet spot della propria piattaforma.

Infine, l'ottavo è **sovradimensionare o sottodimensionare la capacità** senza considerare l'uso effettivo: comprare 64 GB per navigare (spreco) o 8 GB per editing video (frustrazione continua da swapping). Rimedio: misurare l'utilizzo della memoria nel proprio uso tipico e dimensionare di conseguenza, con un margine ragionevole per il futuro.

---

## Riepilogo Operativo — Checklist Selezione RAM

Usa questa checklist nell'ordine indicato: ogni passo dipende dai precedenti.

- 1. Determina la piattaforma.** Identifica CPU e scheda madre. Controlla se supportano **DDR4 o DDR5** (non sono intercambiabili). Questo è il vincolo di partenza, prima di ogni altra scelta.
- 2. Definisci la capacità in base all'uso.** Ufficio leggero: 16 GB.  
Gaming/multitasking: 16–32 GB. Editing, dev, VM leggere, gaming serio: 32 GB.  
Video 4K/3D/molte VM/AI locale: 64 GB o più. Nel dubbio e per il futuro, 32 GB è la base sicura oggi.
- 3. Scegli un kit da DUE moduli.** Mai un modulo singolo (perderesti il dual channel). Evita quattro moduli quando puoi ottenere la stessa capacità con due di taglio maggiore, specialmente su DDR5.
- 4. Identifica lo sweet spot di frequenza/latenza della piattaforma.** Su **AMD AM5: DDR5-6000 CL30 EXPO** (rapporto 1:1 con l'Infinity Fabric). Su **Intel: 6000 CL30** come base, con possibilità di frequenze superiori dove la piattaforma scala bene. Ragiona sempre in termini di **latenza reale (ns) = CL × 2000 ÷ MT/s**, non solo il numero di MT/s.
- 5. Verifica la QVL e i profili.** Controlla che il kit (o uno equivalente) sia nella **Qualified Vendor List** della scheda madre, o almeno che offra il profilo corretto: **XMP** per Intel, **EXPO** per AMD.
- 6. Controlla i vincoli fisici.** Se usi un dissipatore CPU **ad aria** ingombrante, verifica l'**altezza dei moduli** (clearance) o scegli kit **low-profile**. Con AIO a liquido, questo non è quasi mai un problema.
- 7. Scegli brand e budget.** Preferisci assemblatori affidabili (**G.Skill, Corsair, Kingston, Crucial, TeamGroup**). Decidi se l'**RGB** vale il sovrapprezzo estetico



(non dà prestazioni). A parità di specifiche, punta al miglior rapporto qualità-prezzo.

**8. Dopo l'installazione: attivare XMP/EXPO.** Entrate nel BIOS/UEFI, abilitate il profilo, salvate, riavviate. **Verificate** frequenza e canali con **CPU-Z** (tab Memory: frequenza corretta e "Dual Channel"). Senza questo passaggio, la RAM veloce che avete pagato non renderà come dovrebbe.

**9. Non mescolate i kit.** Se prevedete di raggiungere una certa capacità, acquistate tutto **in una volta in un unico kit**. Aggiungere moduli di lotti diversi in futuro è una comune fonte di instabilità.

***Promemoria dati volatili.** Prima dell'acquisto, aggiornate sempre: (1) i **prezzi** e il rapporto costo-efficacia di DDR4/DDR5; (2) qual è la **generazione corrente** e le massime frequenze disponibili; (3) i **kit specifici** consigliati e la **QVL** aggiornata per la vostra scheda madre. I concetti di questo capitolo restano validi; prodotti e listini cambiano rapidamente.*

## Capitolo 4 - La Scheda Grafica (GPU Consumer)

***Nota su dati e periodo di riferimento.** Questo capitolo è aggiornato a metà 2026. Questo è un momento anomalo per il mercato delle schede grafiche: dall'ultimo trimestre del 2025 si è verificata una grave **carenza di memoria** (DRAM e GDDR), causata dalla domanda dei data center per l'intelligenza artificiale, che ha spinto i prezzi di listino ben al di sopra degli **MSRP** (Manufacturer's Suggested Retail Price). Per questo motivo, ogni volta che in questo capitolo citerò un prezzo, mi riferirò ad esso come "prezzo di listino/MSRP" e avvertirò che il prezzo effettivo al dettaglio, specialmente in Italia ed Europa (dove si aggiungono IVA e logistica), può essere significativamente più alto e cambiare di settimana in settimana. I dati su generazioni, modelli e prezzi vanno quindi verificati al momento dell'acquisto: sono la parte di questo capitolo che invecchia più rapidamente. I principi tecnici, invece, rimangono validi nel tempo.*

---

### 1. Cosa fa la GPU

#### Descrizione e funzione

La **GPU** (*Graphics Processing Unit*) è il componente del computer specializzato nel **calcolo massivo parallelo**. Per capire cosa significhi, è utile contrapporla alla **CPU** (*Central Processing Unit*). La CPU è progettata per eseguire poche istruzioni molto complesse in rapida successione: ha un numero relativamente basso di "core" (unità di elaborazione), ognuno molto potente e flessibile, adatto a compiti che richiedono continue e imprevedibili decisioni logiche, come l'esecuzione del sistema operativo o la logica di un programma. La GPU segue la filosofia opposta: contiene migliaia di core piccoli e semplici, ognuno singolarmente meno potente, ma capaci di lavorare tutti insieme nello stesso istante sullo stesso tipo di operazione. Questa è l'architettura ideale quando lo stesso calcolo deve essere applicato contemporaneamente a milioni di punti dati distinti.

Il caso d'uso storico che ha dato origine alla GPU è il **rendering 3D**, ovvero la trasformazione di una scena tridimensionale descritta matematicamente (vertici, triangoli, texture, luci) in un'immagine bidimensionale di pixel da visualizzare su uno schermo. Un monitor da 1920×1080 pixel contiene poco più di due milioni di pixel; a 3840×2160 (il cosiddetto 4K), si superano gli otto milioni. Se ogni fotogramma deve essere ricalcolato sessanta, centoventi o più volte al secondo, il numero di operazioni al secondo diventa astronomico. Nessuna CPU potrebbe

gestirlo: serve un'architettura che calcoli milioni di pixel in parallelo, ed è esattamente ciò che fa la GPU.

Tuttavia, con il tempo ci si è resi conto che questo stesso motore di calcolo parallelo è utile anche al di fuori del gaming. Oggi la GPU è usata per la **codifica e decodifica video** (comprimere e decomprimere flussi video, fondamentale per lo streaming e l'editing), per il **calcolo scientifico**, e soprattutto per l'**intelligenza artificiale locale**: addestrare e soprattutto eseguire (fare *inference*) reti neurali, dai modelli di generazione di immagini come Stable Diffusion ai modelli linguistici di grandi dimensioni (**LLM**) eseguiti sul proprio PC. La ragione è la stessa del rendering: le reti neurali si riducono a enormi moltiplicazioni di matrici, che è lo stesso calcolo ripetuto milioni di volte su dati diversi. È questa convergenza tra grafica e IA che ha reso la GPU il componente più strategico — e più conteso — dell'intero settore hardware.

## I Componenti Fisici di una Scheda Grafica

Quando parliamo di "scheda grafica" in senso stretto, intendiamo l'intero prodotto: una scheda a circuito stampato con vari componenti su di essa, che viene inserita nel computer. Il chip grafico vero e proprio è solo una parte. Vediamoli uno per uno.

Il **die della GPU** è il chip di silicio vero e proprio: il processore grafico. È qui che risiedono i core di calcolo (che NVIDIA chiama *CUDA core* e *Tensor core*, AMD *Stream Processors* e *AI Accelerators*), le unità dedicate al ray tracing e i controller di memoria. È il cuore del prodotto e ne determina la potenza di calcolo grezza.

La **VRAM** (*Video RAM*) è la memoria dedicata della scheda, fisicamente separata dalla RAM di sistema. Contiene texture, modelli 3D, buffer di rendering e — nel caso dell'IA — i pesi del modello neurale. È un elemento così centrale che le dedichiamo l'intera prossima sezione.

Il **VRM** (*Voltage Regulator Module*) è il sistema di alimentazione della scheda. La GPU riceve un'alimentazione a 12 volt dall'alimentatore, ma il chip opera a tensioni molto più basse (circa 1 volt) e amperaggi molto elevati. Il VRM converte e stabilizza questa energia, distribuendola in modo pulito al die. Un VRM di buona qualità, con molte "fasi" di alimentazione, consente clock più elevati, temperature più basse e una maggiore durata; un VRM economico è spesso il vero limite delle schede di fascia bassa e delle versioni più povere.

Il **PCB** (*Printed Circuit Board*) è la scheda verde (o nera) su cui è montato tutto. La sua qualità, il numero di strati di rame e il layout delle tracce influenzano la stabilità elettrica e la capacità di overclock.

Il **sistema di dissipazione** dissipa il calore prodotto dal die e dai VRM. È tipicamente composto da una *vapor chamber* o *heat pipes* che trasportano il calore a una pila di alette di alluminio, raffreddate da una o più ventole. Nelle schede più potenti, la dissipazione è la parte più voluminosa e pesante del prodotto, e questo spiega perché due schede con lo stesso chip possono avere dimensioni, livelli di rumore e prezzi molto diversi.

### Errori tipici a questo livello

L'errore più comune del principiante è confondere la **GPU die** (il chip) con la **scheda video** (il prodotto completo). Questo porta a un secondo fraintendimento: pensare che due schede con lo stesso nome (ad esempio, due "RTX 5070") siano identiche. Non lo sono: condividono il chip, ma il produttore di terze parti che le assembla sceglie il dissipatore, i VRM, le frequenze di fabbrica e l'alimentazione. Questa è la differenza tra versioni *reference* e versioni *custom*, di cui parleremo ampiamente nella sezione 6.

---

## 2. VRAM e bus di memoria

### Cos'è la VRAM e perché è diversa dalla RAM di sistema

La **VRAM** è la memoria ad altissima velocità saldata direttamente sulla scheda video, attorno alla GPU die. Serve a immagazzinare tutti i dati su cui il chip grafico deve lavorare in un dato momento: le texture (le "pelli" applicate ai modelli 3D), la geometria della scena, i vari buffer di rendering intermedi e, nelle applicazioni AI, i pesi della rete neurale. La differenza rispetto alla RAM di sistema (moduli DDR4 o DDR5 inseriti nella scheda madre e usati dalla CPU) è duplice. In primo luogo, la VRAM è enormemente più veloce in termini di banda: una scheda video di fascia media muove centinaia di gigabyte al secondo, mentre un kit di RAM di sistema si ferma a poche decine. In secondo luogo, la VRAM è *dedicata* e locale: si trova a pochi millimetri dal chip che la usa, evitando il collo di bottiglia del bus **PCIe** (*Peripheral Component Interconnect Express*, il canale che collega la scheda video al resto del computer). Se la GPU dovesse leggere le texture dalla RAM di sistema passando ogni volta per il PCIe, le prestazioni crollerebbero.

Le generazioni di VRAM che si incontrano oggi sono principalmente tre. La **GDDR6** (*Graphics Double Data Rate 6*) è lo standard maturo ed economico, usato ancora oggi da AMD su tutta la serie RX 9000 e da NVIDIA sui tier inferiori delle passate generazioni. La **GDDR6X** è una variante più veloce sviluppata da NVIDIA con Micron, presente sulle RTX serie 30 e 40 di fascia alta. La **GDDR7** è la generazione più recente, adottata da NVIDIA su tutta la serie RTX 50: offre maggiore banda a parità di ampiezza del bus ed è più efficiente. Al momento della stesura, AMD sulla serie RX 9000 (RDNA 4) ha scelto di rimanere con la GDDR6, affidandosi a bus più ampi e a cache interne per compensare — una scelta che ha anche il vantaggio di costi inferiori, non indifferente durante la crisi delle memorie.

### Il bus di memoria e la formula della banda

Il **bus di memoria** è l'ampiezza del canale che collega la GPU die alla VRAM, misurata in bit. Valori tipici sono 128, 192, 256 e 384 bit (con casi estremi come i 512 bit della RTX 5090). Va immaginato come la larghezza di un'autostrada: più corsie (più bit) permettono di far passare più dati contemporaneamente. Da solo, però, il bus non dice nulla: conta anche la velocità a cui viaggia ogni corsia, ovvero la frequenza effettiva dei chip di memoria.

La metrica che riassume il tutto è la **banda** (memory bandwidth), ovvero quanti gigabyte al secondo la GPU può scambiare con la sua VRAM. La formula concettuale è:

$$\text{Banda (GB/s)} = (\text{velocità effettiva della memoria in Gbps} \times \text{ampiezza del bus in bit}) \div 8$$

Dividiamo per 8 perché un byte è composto da 8 bit. Prendiamo un esempio concreto: una scheda con memoria GDDR6 a 20 Gbps su un bus a 256 bit ha una larghezza di banda di  $(20 \times 256) \div 8 = \mathbf{640 \text{ GB/s}}$ . Una scheda con lo stesso tipo di memoria ma un bus a 128 bit si ferma a  $(20 \times 128) \div 8 = \mathbf{320 \text{ GB/s}}$ , che è la metà. Ecco perché il bus è un fattore importante quanto la quantità di VRAM.

La seguente tabella mostra come, a parità di velocità di memoria, la larghezza del bus determini la larghezza di banda finale. I valori sono indicativi e servono a stabilire ordini di grandezza.

| Larghezza Bus | Memoria 18 Gbps (GDDR6) | Memoria 20 Gbps (GDDR6) | Memoria 28 Gbps (GDDR7) |
|---------------|-------------------------|-------------------------|-------------------------|
| 128 bit       | 288 GB/s                | 320 GB/s                | 448 GB/s                |

|         |          |          |           |
|---------|----------|----------|-----------|
| 192 bit | 432 GB/s | 480 GB/s | 672 GB/s  |
| 256 bit | 576 GB/s | 640 GB/s | 896 GB/s  |
| 384 bit | 864 GB/s | 960 GB/s | 1344 GB/s |

È subito chiaro perché la GDDR7 sia interessante: permette di ottenere elevate larghezze di banda anche con bus più stretti, il che consente ai produttori di risparmiare sul numero di chip e sulla complessità del PCB. Ed è anche il motivo per cui non si può confrontare la larghezza di banda di due schede guardando solo i bit del bus senza considerare il tipo di memoria.

**Quanta VRAM ti serve davvero**

La quantità di VRAM necessaria dipende da tre fattori interconnessi: la **risoluzione** a cui si gioca o si lavora, la **qualità delle texture** e degli effetti, e la presenza o assenza di funzionalità esigenti come il **ray tracing** (calcolo fisico realistico di luci, ombre e riflessi). Vale una regola generale: maggiore è la risoluzione, più texture ad alta definizione devono risiedere contemporaneamente in memoria, quindi più VRAM è necessaria. A ciò si aggiunge il fatto che il ray tracing richiede strutture dati aggiuntive in memoria, e alcune tecnologie di *frame generation* (generazione di frame intermedi guidata dall'AI) consumano VRAM aggiuntiva.

Come riferimento pratico, valido a metà 2026 e destinato a crescere nel tempo man mano che i giochi diventeranno più esigenti:

| Scenario d'uso                                     | VRAM Minima Raccomandata | VRAM Confortevole |
|----------------------------------------------------|--------------------------|-------------------|
| Gaming 1080p, dettagli medio-alti                  | 8 GB                     | 12 GB             |
| Gaming 1440p, dettagli alti + ray tracing          | 12 GB                    | 16 GB             |
| Gaming 4K, dettagli massimi + ray tracing          | 16 GB                    | 20–24 GB          |
| Stable Diffusion / generazione immagini            | 8–12 GB                  | 16 GB+            |
| LLM locali quantizzati (7–8 miliardi di parametri) | 8–12 GB                  | 16 GB             |
| LLM locali di medie dimensioni (13–34 miliardi)    | 24 GB                    | 24–48 GB          |

Nel campo dell'**AI locale**, la VRAM è ancora più critica che nel gaming, e per una ragione chiara: un modello neurale deve stare *interamente* nella memoria della scheda grafica per funzionare a piena velocità. Se il modello non ci sta, o non si avvia affatto, o viene "spalmato" tra VRAM e RAM di sistema, portando a un crollo delle prestazioni. Per questo motivo, per chi lavora con l'AI, la quantità di VRAM diventa spesso il criterio di selezione numero uno, ancora più della potenza bruta del chip. Un modello linguistico da 7–8 miliardi di parametri quantizzato a 4 bit occupa circa 5–6 GB e sta comodamente su una scheda da 12 GB; un modello da 70 miliardi, invece, richiede decine di gigabyte e rimane appannaggio di schede professionali o configurazioni multi-GPU.

### Il caso delle GPU "castrate" sul bus

C'è una ricorrente trappola commerciale che questo capitolo deve esplicitare: la scheda con **tanta VRAM ma un bus stretto**. Un produttore, per rendere appetibile un modello di fascia bassa, potrebbe equipaggiarlo con 16 GB di memoria — un numero che fa un'ottima figura sulla scatola — ma collegarla con un bus di soli 128 bit. Il risultato è che la scheda ha lo spazio per ospitare texture abbondanti, ma l'insufficiente banda passante non le permette di *muoverle* abbastanza velocemente. È come avere un enorme magazzino con una sola porta stretta: la merce c'è, ma non può entrare e uscire alla velocità richiesta.

Questo scenario è particolarmente deludente in due casi: ad alte risoluzioni, dove la banda passante è il fattore limitante, e nei giochi con streaming continuo di texture. L'acquirente inesperto compra "16 GB" convinto di aver fatto un affare a prova di futuro, solo per scoprire che una scheda con "soli" 12 GB ma un bus più largo la surclassa nelle prestazioni reali. La lezione è chiara: **la VRAM non va mai valutata in isolamento, ma sempre in congiunzione con il bus e il tipo di memoria**, ovvero guardando alla banda passante complessiva. Una buona abitudine è controllare sempre tre numeri insieme — capacità (GB), ampiezza del bus (bit) e tipo di memoria (GDDR6/6X/7) — prima di farsi influenzare dalla sola capacità.

---

### 3. Nomenclatura NVIDIA: Come Leggere il Nome

#### La Struttura del Nome

NVIDIA vende le sue schede consumer sotto il marchio **GeForce RTX**. L'acronimo **RTX** (*Ray Tracing eXtension*) indica, dalla serie 20 in poi, la presenza di unità hardware dedicate al ray tracing e ai calcoli AI; il vecchio acronimo **GTX** identificava schede prive di tali unità. Il nome vero e proprio è un numero a quattro cifre che segue uno schema molto regolare, del tipo **RTX [serie][tier]**.

Prendiamo l'esempio della **RTX 4070**. Le prime due cifre, "40", indicano la **generazione** (in questo caso, la serie 40, architettura Ada Lovelace). Le successive due cifre, "70", indicano il **tier** all'interno di quella generazione. Quindi "RTX 4070" si legge come "scheda di tier 70 della quarta generazione RTX". Con lo stesso criterio, una RTX 5080 è il tier 80 della quinta generazione, una RTX 3060 è il tier 60 della terza generazione, e così via. Una volta compreso questo schema, il nome di qualsiasi scheda NVIDIA diventa immediatamente leggibile.

#### Le Serie (Generazioni)

Ogni generazione corrisponde a un'**architettura** diversa, ovvero a un design interno del chip. Le tre più rilevanti per gli acquirenti odierni sono:

La **serie 30 (Ampere)**, rilasciata nel 2020, è ormai datata ma ancora molto popolare nel mercato dell'usato. Ha introdotto la seconda generazione di RT core e il primo DLSS veramente utilizzabile.

La **serie 40 (Ada Lovelace)**, rilasciata a fine 2022, ha portato un grande salto di efficienza e le tecnologie DLSS 3 con frame generation. Non è più in produzione, quindi si trova principalmente usata o come scorte residue, ma rimane interessante nel rapporto prezzo/prestazioni proprio perché è stata costruita con memorie meno costose di quelle attuali.

La **serie 50 (Blackwell)**, l'attuale generazione consumer al momento della stesura, annunciata al CES di gennaio 2025 e lanciata nei mesi successivi. Introduce la quarta generazione di RT core, la quinta generazione di Tensor core, memorie GDDR7 su tutta la gamma e le tecnologie DLSS 4 con **Multi-Frame Generation** (generazione di più frame intermedi invece di uno solo).

***Attenzione — dati in evoluzione.** A metà 2026, si parla con insistenza di un aggiornamento di metà generazione chiamato **RTX 50 SUPER** (con più VRAM: le voci suggeriscono 18 GB sulla 5070, 24 GB sulla 5070 Ti e 5080, e una 5060*



da 12 GB). Al momento della stesura, tuttavia, questi modelli **non sono ancora stati lanciati** e il loro debutto è stato posticipato più volte proprio a causa della carenza di memoria, con alcune fonti che lo spostano al 2027 o lo considerano incerto. Dovrebbero quindi essere trattati come voci non confermate, da verificare al momento dell'acquisto.

### I Livelli (Tier)

Le ultime due cifre codificano il posizionamento e, con esso, ciò che ci si può aspettare in termini di prestazioni e prezzo. Lo schema, valido come regola generale tra le generazioni, è il seguente:

Il **livello 50** è l'assoluto entry-level, progettato per il gaming leggero a 1080p e l'uso multimediale. Il **livello 60** rappresenta il grande volume del mercato: la scheda "popolare" per il 1080p di alta qualità e per il 1440p con alcuni compromessi. Il **livello 70** è il cuore del segmento di fascia media, dedicato al 1440p ad alto refresh e al 4K con l'aiuto dell'upscaling. Il **livello 80** è la fascia alta, progettato per il gaming 4K con dettagli elevati. Il **livello 90** è l'entusiasta, il top assoluto della gamma consumer, con massima VRAM e potenza, orientato al 4K esigente, alla creazione di contenuti e all'IA — e con prezzi che sconfinano nel territorio professionale.

### I Suffissi: Ti e SUPER

Oltre al numero base, NVIDIA utilizza due suffissi per creare varianti intermedie. Il suffisso **Ti** (storicamente *Titanium*) indica una versione potenziata del livello a cui è associato: una RTX 4070 Ti si posiziona tra la 4070 e la 4080, ed è più veloce della semplice 4070. Il suffisso **SUPER** svolge un ruolo simile, tipico degli aggiornamenti di metà generazione: indica una revisione migliorata di un modello esistente, spesso con più core, più VRAM o più larghezza di banda. In alcuni casi, entrambi coesistono (ad esempio, "RTX 4070 Ti SUPER"). La regola pratica da tenere a mente è che, all'interno della stessa generazione, l'ordine crescente di prestazioni tende ad essere: modello base → SUPER → Ti → Ti SUPER, per poi salire di livello numerico.

### Tabella Riassuntiva delle Recenti Generazioni NVIDIA

La tabella mostra i modelli principali, con VRAM, bus e MSRP al lancio. **Si prega di notare che, a causa della carenza di memoria, i prezzi effettivi a metà 2026 sono spesso molto più alti degli MSRP indicati**, specialmente nei livelli di fascia alta.

| <b>Modello</b>    | <b>Gen. / Architettura</b> | <b>VRAM</b> | <b>Tipo Mem.</b> | <b>Bus</b> | <b>MSRP al Lancio (USD)</b> |
|-------------------|----------------------------|-------------|------------------|------------|-----------------------------|
| RTX 3060          | 30 / Ampere                | 12 GB       | GDDR6            | 192 bit    | ~329                        |
| RTX 3070          | 30 / Ampere                | 8 GB        | GDDR6            | 256 bit    | ~499                        |
| RTX 3080          | 30 / Ampere                | 10 GB       | GDDR6X           | 320 bit    | ~699                        |
| RTX 4060          | 40 / Ada                   | 8 GB        | GDDR6            | 128 bit    | ~299                        |
| RTX 4070          | 40 / Ada                   | 12 GB       | GDDR6X           | 192 bit    | ~549                        |
| RTX 4070 Ti SUPER | 40 / Ada                   | 16 GB       | GDDR6X           | 256 bit    | ~799                        |
| RTX 4080 SUPER    | 40 / Ada                   | 16 GB       | GDDR6X           | 256 bit    | ~999                        |
| RTX 4090          | 40 / Ada                   | 24 GB       | GDDR6X           | 384 bit    | ~1599                       |
| RTX 5060          | 50 / Blackwell             | 8 GB        | GDDR7            | 128 bit    | ~299                        |
| RTX 5060 Ti       | 50 / Blackwell             | 8 / 16 GB   | GDDR7            | 128 bit    | ~379–429                    |
| RTX 5070          | 50 / Blackwell             | 12 GB       | GDDR7            | 192 bit    | ~549                        |
| RTX 5070 Ti       | 50 / Blackwell             | 16 GB       | GDDR7            | 256 bit    | ~749                        |
| RTX 5080          | 50 / Blackwell             | 16 GB       | GDDR7            | 256 bit    | ~999                        |
| RTX 5090          | 50 / Blackwell             | 32 GB       | GDDR7            | 512 bit    | ~1999                       |

### **Errori Comuni di Nomenclatura NVIDIA**

L'errore più comune è confrontare due schede basandosi solo sul tier, ignorando la generazione: una RTX 4070 di nuova generazione può superare o eguagliare una RTX 3080 più vecchia e di tier superiore, grazie a un'architettura più efficiente e a nuove tecnologie di upscaling. Il secondo errore riguarda la RTX 5060 Ti, venduta in due versioni, 8 GB e 16 GB, con lo stesso nome: la versione da 8 GB è penalizzata nei giochi moderni e a risoluzioni più elevate, e per pochi euro in più, la versione da 16 GB è quasi sempre la scelta migliore. Il terzo errore è farsi ingannare dal tier 90 pensando che sia "il doppio" dell'80: le schede di tier 90 offrono prestazioni superiori, ma con un rapporto prezzo/prestazioni che peggiora significativamente man mano che si sale, perché a quel tier si paga

anche l'esclusività e l'abbondante VRAM, più utile per i professionisti che per i giocatori.

---

## 4. Convenzione di Naming AMD: Come Leggere il Nome

### La Struttura del Nome

AMD vende le sue schede grafiche consumer sotto il marchio **Radeon RX**. Lo schema di denominazione assomiglia a quello di NVIDIA: **RX [serie][tier]**. Prendiamo la **RX 7800 XT**. Le prime due cifre, "78", vanno lette come "serie 7000, tier 800": la serie 7000 è la generazione, e 800 è il suo posizionamento all'interno di quella generazione. Il suffisso "XT" indica, come vedremo, la variante più potente di quel modello. Come per NVIDIA, il tier aumenta con il numero: una RX 7600 è entry-level, una RX 7900 è high-end.

### Le Serie (Generazioni)

Esistono tre generazioni AMD rilevanti oggi, tutte basate sull'architettura **RDNA** (*Radeon DNA*):

La **serie RX 6000 (RDNA 2)**, del 2020, è ormai datata ma ancora disponibile sul mercato dell'usato, offrendo un buon rapporto prezzo/prestazioni nella pura rasterizzazione, ma con un ray tracing più debole rispetto alle controparti NVIDIA contemporanee.

La **serie RX 7000 (RDNA 3)**, di fine 2022, ha introdotto un design a *chiplet* (il chip diviso in più die separati) e la tecnologia FSR 3 con frame generation. Include ancora i modelli di fascia alta RX 7900 XT e XTX, poiché la generazione successiva ha abbandonato il segmento *enthusiast*.

La **serie RX 9000 (RDNA 4)**, l'attuale generazione al momento della scrittura, lanciata a marzo 2025. Il salto nella numerazione (da 7000 a 9000, saltando 8000) allinea il branding delle GPU con quello dei processori Ryzen. RDNA 4 ha migliorato significativamente il ray tracing (acceleratori di terza generazione) e ha introdotto **FSR 4**, la prima versione dell'upscaling di AMD basata sul machine learning. È importante notare che questa generazione **non ha un modello di tier enthusiast**: AMD ha scelto di concentrarsi sul segmento *mid-range*, con la RX 9070 XT al vertice della lineup.

I suffissi: XT, XTX, GRE

AMD utilizza suffissi per distinguere le varianti di potenza con lo stesso numero. Il modello **senza suffisso** è la versione base. Il suffisso **XT** indica una versione più potente, con più unità di calcolo o clock più elevati: la RX 9070 XT è più veloce della semplice RX 9070. Il suffisso **XTX**, apparso sulla serie 7000, indica la variante massima, un passo sopra la XT (come nella RX 7900 XTX rispetto alla 7900 XT). Il suffisso **GRE** (*Golden Rabbit Edition*, un nome inizialmente creato per il mercato cinese per l'Anno del Coniglio) identifica una versione leggermente depotenziata con un bus più stretto, posizionata tra due modelli della stessa serie per coprire una fascia di prezzo intermedia; la RX 9070 GRE, ad esempio, ha 12 GB su un bus a 192 bit rispetto ai 16 GB su un bus a 256 bit della semplice 9070, e nel 2026 è stata resa disponibile a livello globale dopo un debutto iniziale esclusivo per la Cina.

Tabella di equivalenza approssimativa AMD ↔ NVIDIA

Questa tabella abbina i modelli per **fascia di prezzo e prestazioni indicative**, non per esatta equivalenza tecnica. Le prestazioni relative variano da gioco a gioco e, cosa più importante, cambiano a seconda che si consideri la pura rasterizzazione (dove AMD è competitiva) o il ray tracing (dove NVIDIA mantiene un vantaggio). Va quindi letta come una bussola, non come una legge.

| Livello / Prezzo indicativo   | AMD (RDNA 4)       | NVIDIA (Blackwell)   |
|-------------------------------|--------------------|----------------------|
| Entry (~\$300)                | RX 9060 XT 8 GB    | RTX 5060             |
| Entry-mid (~\$350)            | RX 9060 XT 16 GB   | RTX 5060 Ti 16 GB    |
| Mid (~\$550)                  | RX 9070            | RTX 5070             |
| Mid-high (~\$600)             | RX 9070 XT         | (tra 5070 e 5070 Ti) |
| High (~\$750)                 | — (nessun modello) | RTX 5070 Ti          |
| High / enthusiast (\$900+)    | — (nessun modello) | RTX 5080             |
| Absolute enthusiast (\$2000+) | — (nessun modello) | RTX 5090             |

Il dato più eloquente della tabella è la riga dei trattini: nella generazione attuale, AMD **non compete affatto** nei segmenti di fascia alta e enthusiast, avendoli lasciati scoperti. Chiunque cerchi una scheda oltre la potenza della RX 9070 XT oggi si rivolge effettivamente solo a NVIDIA.

Errori tipici nella nomenclatura AMD

Un errore ricorrente è confondere XT e XTX, o supporre che il suffisso GRE indichi qualcosa di migliore quando in realtà indica una variante ridotta. Un secondo

errore, che rispecchia quello visto per NVIDIA, riguarda la RX 9060 XT venduta nelle versioni da 8 GB e 16 GB: la versione da 8 GB è meno consigliabile per i giochi moderni, e la differenza di prezzo con la 16 GB è spesso esigua. Un terzo errore è supporre che AMD sia sempre più economica: questo è vero in molti segmenti, ma le condizioni di mercato nel 2026 hanno reso i prezzi volatili anche per AMD, sebbene i modelli Radeon abbiano mantenuto meglio il loro MSRP rispetto alle controparti NVIDIA, grazie a forniture di memoria assicurate in anticipo.

---

## 5. NVIDIA vs AMD: Confronto Completo

Questa è la sezione definitiva per prendere decisioni. Confronto i due produttori sui piani che contano davvero, in modo che il lettore possa capire *quando* uno è conveniente e *quando* l'altro, senza pregiudizi.

### Pura Rasterizzazione: Prezzo/Prestazioni

La **rasterizzazione** è la tecnica tradizionale per la generazione di immagini, senza il calcolo fisico realistico della luce. Determina ancora la maggior parte delle prestazioni nei giochi. In quest'ambito, **AMD è storicamente molto competitiva**, offrendo spesso più frame al secondo per euro speso rispetto a NVIDIA nella stessa fascia. Nell'attuale generazione, la RX 9070 XT offre prestazioni in rasterizzazione vicine a quelle della più costosa RTX 5070 Ti, a un prezzo di listino inferiore: è il classico esempio del vantaggio AMD nel rapporto prezzo/prestazioni nel gaming puro.

### Ray Tracing: Vantaggio NVIDIA, Recupero RDNA 4

Il **ray tracing** simula il comportamento fisico della luce per ottenere riflessi, ombre e illuminazione realistici. È molto più pesante da calcolare rispetto alla rasterizzazione e richiede unità hardware dedicate (gli *RT core* di NVIDIA e i *Ray Accelerators* di AMD). Storicamente, **NVIDIA ha avuto un netto vantaggio** in questo campo: le sue schede perdono meno prestazioni quando il ray tracing viene attivato. Con RDNA 4, tuttavia, **AMD ha recuperato molto terreno**, riducendo significativamente il divario grazie agli acceleratori di terza generazione. Il vantaggio NVIDIA rimane, specialmente nei giochi con *path tracing* (la forma più estrema e realistica di ray tracing), ma il divario non è più abissale come nelle generazioni precedenti.

### Upscaling: DLSS vs FSR vs XeSS

L'**upsampling** è una tecnologia che permette di renderizzare un gioco a una risoluzione inferiore (es. 1080p) e poi ingrandirlo a una risoluzione superiore (es. 4K) tramite algoritmi intelligenti, guadagnando frame con una minima perdita di qualità. È diventato un fattore competitivo centrale, tanto quanto la potenza bruta. Le tre principali tecnologie sono:

Il **DLSS** (*Deep Learning Super Sampling*) di NVIDIA è considerato il punto di riferimento per qualità e diffusione. Si basa su reti neurali eseguite su Tensor core ed è esclusivo delle schede NVIDIA. Il DLSS 4, esclusivo della serie 50, introduce la **Multi-Frame Generation**, capace di generare più frame intermedi via AI per moltiplicare il frame rate; va però ricordato che la frame generation aggiunge latenza e non sostituisce le prestazioni "vere".

L'**FSR** (*FidelityFX Super Resolution*) di AMD è la risposta al DLSS. Fino alla versione 3, era *vendor-agnostic*, cioè funzionava anche su schede NVIDIA e Intel, ma con qualità inferiore. Con **FSR 4**, AMD è passata a un approccio basato su machine learning che ha migliorato molto la qualità, avvicinandola al DLSS, ma al costo di limitarlo alle schede RDNA 4 dotate degli acceleratori AI necessari.

Lo **XeSS** (*Xe Super Sampling*) di Intel è la terza opzione, creata per le schede Intel Arc ma utilizzabile in forma ridotta anche su altre marche. Offre una buona qualità ed è la "terza incomoda" del settore.

### Encoder: NVENC vs AMF

L'**encoder** è l'unità hardware che comprime video in tempo reale, essenziale per lo **streaming** (Twitch, YouTube) e per l'esportazione in **video editing**. NVIDIA dispone di **NVENC** (*NVIDIA Encoder*), universalmente considerato il migliore per qualità e stabilità, tanto da essere un motivo ricorrente per cui streamer e videomaker scelgono NVIDIA. AMD utilizza **AMF** (*Advanced Media Framework*): storicamente inferiore, è migliorato nelle ultime generazioni, ma NVENC mantiene un riconosciuto vantaggio, specialmente nella codifica ad alta efficienza (HEVC e AV1) a bassi bitrate.

### CUDA vs ROCm: perché NVIDIA domina per AI e produttività

Questo è forse il punto più importante per un lettore che, oltre al gaming, guarda all'**intelligenza artificiale e alla produttività**, ed è la base su cui pogerà l'intera sezione dedicata alle workstation. **CUDA** (*Compute Unified Device Architecture*) è la piattaforma software proprietaria di NVIDIA per il calcolo generico su GPU.

Non è solo un'API: è un intero ecosistema, maturo da oltre quindici anni, su cui è costruito quasi tutto il software di IA — da PyTorch a TensorFlow, dai framework di generazione di immagini agli strumenti per LLM locali. La controparte AMD si chiama **ROCm** (*Radeon Open Compute*): è open e in continuo miglioramento, ma rimane meno matura, meno diffusa e con un supporto software più frammentato. Il risultato pratico è chiaro: **per l'IA, la produttività creativa accelerata e il calcolo scientifico, NVIDIA domina** non tanto per l'hardware quanto per il software. Chi acquista una scheda pensando di usarla per addestrare o eseguire modelli, editare video con effetti AI o lavorare con applicazioni professionali, nella maggior parte dei casi troverà molte meno frizioni con NVIDIA. Questa è una considerazione che, per certi profili di utilizzo, ribalta completamente il vantaggio prezzo/prestazioni di AMD nel gaming puro.

### Driver, consumi, prezzi

Sul fronte **driver**, entrambi i marchi offrono oggi software stabili, ma NVIDIA ha storicamente goduto di una reputazione di maggiore affidabilità al lancio di nuovi giochi, mentre AMD ha talvolta sofferto di problemi nelle prime settimane dopo l'uscita di una scheda, poi risolti con aggiornamenti. In termini di **consumi**, i due marchi si equivalgono nei rispettivi segmenti, con fluttuazioni modello per modello. Per quanto riguarda i **prezzi**, come già accennato, AMD tende a offrire di più a parità di denaro in rasterizzazione, mentre NVIDIA fa pagare l'ecosistema (DLSS, NVENC, CUDA); nel contesto del 2026, inoltre, i prezzi reali sono governati più dalla disponibilità di memoria che dai listini ufficiali.

### Il terzo incomodo: Intel Arc

Come terzo incomodo, va menzionata **Intel Arc**, la linea di schede grafiche di Intel. La serie **Battlemage** (schede come la Arc B580 12 GB) ha conquistato un'ottima reputazione nel segmento entry-level, offrendo più VRAM della concorrenza a prezzi aggressivi e encoder AV1 di qualità. I limiti storici di Arc sono i driver, meno maturi, specialmente nei giochi più datati, e un ecosistema software per l'IA che arranca rispetto a CUDA. Inoltre, a metà 2026, il futuro della linea gaming di Intel appare incerto: alcune voci suggeriscono un ridimensionamento dei modelli di fascia alta, dirottati verso il mercato professionale. Per l'acquirente attento al budget, tuttavia, una scheda Arc entry-level rimane una delle migliori opzioni VRAM/prezzo oggi, a patto di accettare qualche compromesso sui driver.

---



## 6. Partner AIB e versioni custom

### Founders Edition / reference vs custom

Quando NVIDIA e AMD progettano una scheda, ne producono anche una versione "ufficiale": NVIDIA la chiama **Founders Edition** (FE), AMD la chiama versione **reference**. Si tratta delle schede con il design di riferimento del produttore del chip. Accanto a queste, esiste un gran numero di **partner AIB** (*Add-In Board partners*, produttori di terze parti che acquistano i chip e assemblano le proprie schede): ASUS, MSI, Gigabyte, Sapphire, PowerColor e molti altri. Ognuno produce le proprie versioni **custom**, con dissipatori, PCB, VRM, clock ed estetica diversi. La stessa RTX 5070, quindi, esiste in decine di varianti fisicamente diverse, tutte con lo stesso chip ma con qualità costruttiva, temperature, rumorosità e prezzo che possono variare considerevolmente.

### Partner NVIDIA e le loro gamme

Ogni partner AIB organizza le proprie schede in linee di prodotti ordinate per qualità crescente. Conoscere questi nomi commerciali è essenziale per evitare di pagare troppo o troppo poco. I principali marchi partner NVIDIA, con le rispettive gamme dal basso all'alto, sono:

**ASUS** offre la linea **Dual** (entry, semplice dissipatore a doppia ventola), la **TUF Gaming** (fascia media robusta, ottimo equilibrio qualità/prezzo) e la **ROG Strix** (fascia alta, raffreddamento e VRM di prim'ordine, prezzi elevati). **MSI** offre la **Ventus** (entry), la **Gaming / Gaming Trio** (fascia media, con dissipatore a tripla ventola) e la **Suprim** (top di gamma, costruzione premium). **Gigabyte** ha la linea **Windforce / Gaming** (entry e fascia media) e la **Aorus** (fascia alta). Il quadro è completato da marchi come **Zotac** (spesso aggressiva sul prezzo, con modelli molto compatti), **Palit** e **Gainward** (buon rapporto qualità/prezzo, generalmente più economiche), **PNY** (diffusa e affidabile, senza fronzoli) e **INNO3D**.

### Partner AMD e "marchi di riferimento"

Il panorama AMD presenta alcune peculiarità. **Sapphire** è considerata il partner AMD di riferimento per eccellenza — l'equivalente di ciò che i migliori partner premium sono per NVIDIA — con la linea **Pulse** (fascia media, ottimo equilibrio) e la **Nitro+** (top di gamma, molto apprezzata). **PowerColor** è l'altro grande nome storico associato ad AMD, con le linee **Fighter** (entry), **Hellhound** (fascia media, silenziosa e ben bilanciata) e **Red Devil** (fascia alta). Completano il quadro **XFX**, partner storico esclusivo AMD, e **ASRock**, che più recentemente è entrata nel mercato delle schede grafiche con buoni risultati. Sapphire, PowerColor e XFX



sono spesso definite "marchi di riferimento" di AMD perché lavorano quasi esclusivamente con Radeon, a differenza di ASUS, MSI e Gigabyte, che producono per entrambi i marchi.

### Quanto vale davvero la pena pagare di più?

La domanda pratica è: vale la pena spendere di più per una versione premium? La differenza tra una scheda base e una top di gamma si concentra su quattro aspetti. Il **dissipatore**, più grande e con più heat pipe, mantiene le temperature più basse. Le **frequenze di fabbrica**, leggermente più alte nelle versioni premium (le sigle "OC" indicano un *overclock* di fabbrica), portano tipicamente a modesti guadagni prestazionali, nell'ordine di pochi punti percentuali. La **rumorosità**, spesso inferiore nelle versioni premium a parità di temperatura, grazie a ventole migliori e curve più raffinate. L'**estetica**, con illuminazione RGB e finiture più curate. La ragionevole regola pratica è questa: **le versioni di fascia media (TUF, Pulse, Hellhound, Gaming) offrono il miglior compromesso** e sono quelle da consigliare nella stragrande maggioranza dei casi; le versioni top di gamma (ROG Strix, Suprim, Nitro+, Red Devil, Aorus) hanno senso solo per chi cerca il silenzio assoluto, l'overclock estremo o l'estetica, ed è disposto a pagare un sovrapprezzo che raramente si traduce in prestazioni significativamente superiori. Attenzione, però, alle versioni più economiche e spartane di ogni brand sulle schede di fascia alta: un dissipatore sottodimensionato su un chip potente porta a temperature elevate, throttling (riduzione automatica delle prestazioni per protezione dal calore) e rumore.

### Errori tipici con le versioni custom

L'errore più costoso è pagare il sovrapprezzo per una versione top pensando di ottenere un salto prestazionale che in realtà non c'è: tra la versione base e la versione premium della *stessa* scheda, la differenza di frame rate è quasi sempre trascurabile. L'errore opposto è comprare la versione più economica di una scheda potente per risparmiare, ritrovandosi con una dissipazione inadeguata e ventole rumorose. Un terzo errore è farsi guidare solo da RGB ed estetica, ignorando i parametri che contano davvero: temperature, rumorosità e qualità dei VRM.

---

## 7. Dimensioni fisiche e compatibilità

### Lunghezza, spessore e spazio nel case

Una scheda video è un componente ingombrante, e uno degli errori da principiante più frustranti è acquistarne una senza verificare che entri nel proprio **case**. Due dimensioni principali vanno controllate. La **lunghezza**, espressa in millimetri, deve essere inferiore al massimo *clearance* (spazio disponibile) dichiarato dal produttore del case: le schede di fascia alta possono superare i 320–350 mm, e non tutti i case le ospitano. Lo **spessore**, misurato in "slot", indica quanti slot di espansione la scheda occupa sul retro del case: le schede si dividono in modelli da **2-slot**, **2.5-slot**, **3-slot** e persino **4-slot**. Più grande è il dissipatore — e quindi più potente o premium è la scheda — più slot occupa, e maggiore è il rischio che vada a coprire altri connettori della scheda madre o che non entri in un case compatto. La regola operativa è annotare lunghezza e spessore della scheda desiderata, confrontarli con le specifiche del case e lasciare qualche millimetro di margine per i cavi.

### Connettori di alimentazione: 8-pin PCIe vs 12VHPWR / 12V-2x6

La scheda video riceve alimentazione dall'**alimentatore** (PSU) tramite connettori dedicati. Storicamente sono stati usati connettori **PCIe a 8 pin**, di cui una scheda ne può richiedere uno, due o tre a seconda del suo consumo. Con la serie RTX 40, NVIDIA ha introdotto un nuovo connettore singolo ad alta densità chiamato **12VHPWR** (*12-pin High Power*), successivamente rivisto in una versione migliorata chiamata **12V-2x6**, capace di erogare fino a 600 watt tramite un singolo cavo. Tuttavia, questo connettore ha una **storia problematica** ben nota: su schede di fascia molto alta (specialmente RTX 4090 e 5090) si sono verificati casi di surriscaldamento e fusione del connettore, spesso legati a un inserimento imperfetto o a una distribuzione non uniforme della corrente tra i pin. Le contromisure pratiche includono l'inserimento fermo e completo del connettore, l'evitare pieghe strette del cavo subito dietro la spina e il preferire i cavi nativi dell'alimentatore rispetto agli **adattatori** multi-8-pin inclusi, che sono più ingombranti e considerati meno affidabili. Chi acquista una scheda di fascia alta con questo connettore dovrebbe idealmente dotarsi di un alimentatore moderno **ATX 3.0 / ATX 3.1** con cavo 12V-2x6 nativo.

### Requisiti PSU per Fascia GPU

Ogni scheda ha un consumo tipico, spesso indicato come **TDP** (*Thermal Design Power*), la potenza di progetto termico, usata come approssimazione del consumo

elettrico sotto carico) o come TBP (*Total Board Power*, il consumo dell'intera scheda). L'alimentatore deve avere potenza sufficiente non solo per la scheda ma per l'intero sistema, con un margine di sicurezza. La seguente tabella fornisce raccomandazioni conservative per il wattaggio consigliato del PSU in base alla fascia della GPU, considerando un sistema completo con una CPU comparabile.

| Fascia GPU (esempi)                 | Consumo tipico GPU | PSU consigliato (sistema completo) |
|-------------------------------------|--------------------|------------------------------------|
| Entry (RTX 5060 / RX 9060 XT)       | 130–180 W          | 550–650 W                          |
| Mid (RTX 5070 / RX 9070)            | 200–250 W          | 650–750 W                          |
| Mid-high (RTX 5070 Ti / RX 9070 XT) | 260–320 W          | 750–850 W                          |
| High (RTX 5080)                     | ~360 W             | 850 W                              |
| Enthusiast (RTX 5090)               | ~575 W             | 1000–1200 W                        |

Il consiglio pratico è di non lesinare sull'alimentatore e di non prenderne uno appena sufficiente: un margine del 30-40% sopra il consumo di picco stimato migliora l'efficienza, riduce la rumorosità della ventola del PSU e allunga la vita del componente. È anche preferibile scegliere unità di marchi affidabili con certificazione **80 Plus** (Gold o superiore), perché un alimentatore scadente è una delle cause più insidiose di instabilità e, nei casi peggiori, di danni all'hardware.

### GPU Sag e Supporti

Le schede grafiche moderne sono pesanti e, col tempo, tendono a piegarsi verso il basso sotto il loro stesso peso: questo fenomeno è chiamato **GPU sag**. Oltre a essere antiestetico, un sag significativo sollecita lo slot PCIe e il connettore. La soluzione è un **supporto anti-sag** (un piccolo puntello, spesso incluso con schede premium o disponibile separatamente) che sostiene l'estremità libera della scheda. È un accessorio economico e consigliato per tutte le schede di fascia media e alta, specialmente in configurazioni con case verticali o con la scheda montata orizzontalmente.

---

## 8. In quale Slot installarla

### Il Primo Slot PCIe x16 Collegato alla CPU

La scheda madre ha diversi slot di espansione **PCIe**, ma non sono tutti uguali e la scheda grafica deve essere installata in quello corretto. Lo slot corretto è il **primo**

**slot PCIe x16 direttamente collegato alla CPU.** La designazione "x16" indica il numero di *lane* (percorsi dati) fisiche ed elettriche disponibili: sedici lane sono il massimo per una scheda grafica consumer e assicurano la piena larghezza di banda. Il fatto che sia collegato *direttamente alla CPU*, e non al chipset, è cruciale: significa che i dati viaggiano tra la scheda grafica e il processore tramite il percorso più breve e veloce, senza passaggi intermedi che aggiungono latenza. Questo slot è quasi sempre il primo dall'alto, il più vicino al socket della CPU, ed è tipicamente rinforzato in metallo proprio per sostenere il peso della scheda grafica.

### Cosa Succede negli Slot Secondari

Gli **slot secondari**, più in basso sulla scheda madre, hanno caratteristiche inferiori. Anche quando sono fisicamente lunghi come uno slot x16, elettricamente offrono spesso solo 4 lane (**x4**) e — dettaglio decisivo — sono collegati al **chipset** anziché direttamente alla CPU. Questo significa due penalità combinate: minore larghezza di banda (un quarto delle lane) e un percorso più lungo e condiviso verso il processore, passando attraverso la connessione tra chipset e CPU, dove transita anche il traffico di altri dispositivi. Installare una scheda grafica potente in uno slot secondario può quindi limitarne le prestazioni, in modo trascurabile per il gaming a risoluzioni normali ma evidente in scenari di AI e trasferimento dati intenso. Gli slot secondari sono pensati per altre schede di espansione (schede di rete, schede di acquisizione video, controller aggiuntivi), non per la scheda grafica principale. L'errore da evitare, tipico di chi assembla per la prima volta o non consulta le istruzioni della scheda madre, è inserire la scheda grafica nel primo slot fisico x16 che si trova senza verificare che sia quello collegato alla CPU: lo slot corretto è sempre indicato chiaramente nel manuale della scheda madre.

---

## 9. Come Scegliere

### Partire dal Monitor: Risoluzione e Refresh

Il punto di partenza corretto per la scelta di una scheda video **non è il budget o il brand, ma il monitor**. La risoluzione e la frequenza di aggiornamento (misurata in hertz) del display definiscono quanta potenza sia realmente necessaria. Comprare una scheda enthusiast per un monitor 1080p 60 Hz è uno spreco: la scheda produrrebbe molti più fotogrammi di quanti il monitor possa visualizzare. Viceversa, installare una scheda entry-level su un monitor 4K ad alto refresh

porta a frame rate deludenti. La logica è: prima si stabilisce l'obiettivo (ad esempio, "1440p a 144 Hz con dettagli alti"), poi si sceglie la scheda che lo raggiunge, con un piccolo margine per i giochi futuri. Come guida generale: per il 1080p ad alto refresh, una scheda serie 60 è sufficiente; per il 1440p ad alto refresh, una scheda serie 70 è l'ideale; per il 4K con dettagli alti, sono necessarie almeno schede serie 70 Ti / 80 o equivalenti schede AMD di fascia alta.

### Il Budget: La GPU Come Componente Cui Destinare la Quota Maggiore

In un PC pensato principalmente per il **gaming**, la scheda video è il componente che più influenza le prestazioni percepite, ed è quindi corretto destinarle la fetta più grande del budget — tipicamente tra il 35% e il 45% del costo totale della configurazione. Questo non significa comprare la scheda più costosa possibile sacrificando tutto il resto: significa bilanciare. Una sana regola è che scheda video e processore debbano essere in un range coerente tra loro, perché uno squilibrio eccessivo crea un **collo di bottiglia**, una situazione in cui un componente troppo debole rallenta l'altro, impedendogli di esprimere il suo potenziale ottimale.

### Errori comuni dell'acquirente

Concludiamo con le insidie più frequenti, che riassumono in negativo tutto quanto abbiamo visto. La prima è una **GPU top con una CPU entry-level**: abbinare una scheda potentissima a un processore economico che non riesce a "nutrirla" di dati abbastanza velocemente, sprecando buona parte del potenziale della scheda, specialmente a risoluzioni più basse. La seconda è **VRAM insufficiente per l'uso previsto**: acquistare una scheda con poca memoria per la risoluzione o il carico di lavoro AI che si intende affrontare, con conseguenti cali di prestazioni e stuttering non appena giochi o modelli superano la capacità disponibile. La terza è un **case troppo piccolo**: innamorarsi di una scheda senza verificarne lunghezza e spessore rispetto allo spazio interno del cabinet, e scoprire all'ultimo che non ci sta. La quarta è un **PSU sottodimensionato**: abbinare un alimentatore appena sufficiente o di bassa qualità a una scheda esigente, causando spegnimenti improvvisi sotto carico o instabilità difficili da diagnosticare. La quinta, più sottile, è **inseguire solo la quantità di VRAM** ignorando bus e tipo di memoria, come già discusso nella sezione 2. Ognuno di questi errori deriva dallo stesso difetto fondamentale: valutare un componente in isolamento, dimenticando che una scheda video vive all'interno di un sistema e va scelta in armonia con tutto il resto — monitor, CPU, case e alimentatore.

---

## Riepilogo Operativo — Checklist Decisionale Scheda Video

Questa checklist condensa l'intero capitolo in una sequenza di decisioni da prendere nel giusto ordine, dal primo all'ultimo passo.

1. **Definisci il tuo obiettivo in base al monitor.** Stabilisci risoluzione e refresh rate del tuo display (o del display che intendi acquistare): 1080p, 1440p, o 4K, e a quanti hertz. Questo, non il budget, è il vero punto di partenza.
2. **Identifica il tuo profilo d'uso.** Solo gaming? Anche streaming e video editing? Intelligenza artificiale, generazione di immagini o LLM locali? Se ricadi nelle ultime due categorie, l'ecosistema software (CUDA di NVIDIA) e la quantità di VRAM pesano più del puro prezzo/prestazioni.
3. **Scegli il tier coerente con il tuo obiettivo.** Serie 60/9060 per 1080p, serie 70/9070 per 1440p, serie 70 Ti-80 per 4K. Non sovradimensionare per il tuo monitor o sottodimensionare per il tuo target.
4. **Verifica la VRAM insieme a bus e tipo di memoria.** Controlla sempre tre numeri insieme: capacità in GB, larghezza del bus in bit, tipo di memoria (GDDR6/6X/7). Diffida di schede con tanta VRAM ma un bus stretto. Per l'AI, punta a quanta più VRAM possibile nel tuo range di prezzo.
5. **Decidi tra NVIDIA e AMD in base al tuo profilo.** Solo gaming in rasterizzazione e budget risicato → AMD è spesso un valore migliore. Ray tracing pesante, streaming di qualità, AI e produttività → NVIDIA è la scelta più solida. Budget minimo assoluto → considera anche Intel Arc.
6. **Scegli la versione custom giusta.** Preferisci le linee di fascia media (TUF, Pulse, Hellhound, Gaming, Windforce). Passa alle top di gamma (ROG Strix, Nitro+, Suprim, Red Devil) solo se hai bisogno di silenzio assoluto, overclock o estetica, sapendo che il guadagno prestazionale è minimo.
7. **Controlla la compatibilità fisica.** Misura la lunghezza e lo spessore (numero di slot) della scheda e confrontali con lo spazio disponibile nel tuo case, lasciando spazio per i cavi.
8. **Dimensiona l'alimentatore con margine.** Scegli un PSU di marca affidabile, certificato 80 Plus Gold o superiore, con un margine del 30-40% rispetto al consumo di picco stimato del sistema. Per schede con connettore 12V-2x6, preferisci un alimentatore ATX 3.0/3.1 con cavo nativo.

**9. Verifica l'equilibrio con la CPU.** Assicurati che il processore sia di una fascia coerente con la scheda grafica per evitare colli di bottiglia. Meglio due componenti bilanciati che uno eccellente e uno mediocre.

**10. Installa nello slot PCIe x16 primario collegato alla CPU.** Questo è indicato nel manuale della scheda madre, solitamente il primo dall'alto e rinforzato. Aggiungi una staffa anti-sag se la scheda è pesante.

**11. Controlla i prezzi al momento dell'acquisto.** Data la carenza di memoria in corso nel 2026, ignora gli MSRP teorici e controlla i prezzi al dettaglio effettivi, confrontando più rivenditori. Se il tuo budget è limitato, considera anche una scheda di generazione precedente ben mantenuta, che durante una crisi di memoria può offrire un rapporto prezzo/prestazioni migliore rispetto alle nuove.

---

*Nota finale sull'attualità dei dati: modelli, VRAM, prezzi e disponibilità in questo capitolo riflettono la situazione a metà 2026, un periodo caratterizzato da una carenza di memoria che rende i prezzi particolarmente volatili. Le sezioni concettuali (funzionamento GPU, formula della banda, criteri di selezione, compatibilità) rimangono valide nel tempo; le tabelle di modelli e prezzi andranno riverificate al momento dell'acquisto.*

## Capitolo 5 - Archiviazione

### 1. Panoramica: Cos'è l'archiviazione e perché è diversa dalla memoria

Ogni volta che accendi un computer, succede qualcosa che diamo per scontato: la macchina "ricorda" se stessa. Trova il sistema operativo, i programmi installati, i documenti scritti il giorno prima, le foto di dieci anni fa. Questa capacità di ricordare oltre lo spegnimento è il compito dello **storage**, ovvero la memoria di massa, e per capire veramente cosa fa, bisogna prima capire cosa la RAM *non* fa.

La RAM (Random Access Memory) è **volatile**: conserva i dati solo finché è alimentata. Nel momento esatto in cui togliamo l'alimentazione, il contenuto delle celle DRAM svanisce, perché ogni bit è memorizzato come una minuscola carica elettrica in un condensatore che si scarica in millisecondi se non viene continuamente "rinfrescato". La RAM è estremamente veloce e completamente amnesica. Lo storage è l'esatto opposto: è **non volatile**, cioè conserva le informazioni anche senza alimentazione, per mesi o anni, ma paga questa persistenza con latenze che, rispetto alla RAM, sono astronomiche. Per dare una scala mentale: un accesso alla RAM costa circa 80-100 nanosecondi; un accesso a un buon SSD NVMe costa 50.000-80.000 nanosecondi (cioè 50-80 microsecondi); un accesso a un hard disk meccanico costa 8.000.000-15.000.000 nanosecondi (8-15 millisecondi). Tra RAM e hard disk ci sono cinque ordini di grandezza: è la differenza tra prendere un libro dalla propria scrivania e ordinarlo per posta.

Il computer è quindi costruito come una **gerarchia di memoria**, dove ogni livello diminuisce in velocità e aumenta in capacità e persistenza: registri della CPU → cache L1/L2/L3 → RAM → storage → (eventualmente) archiviazione remota o backup offline. Lo storage è il gradino dove la piramide diventa permanente. Tutto quello che vogliamo ritrovare domani deve, prima o poi, atterrare lì.

Il ruolo dello storage nel sistema è duplice. Da un lato, è l'**archivio**: contiene il sistema operativo, gli eseguibili e i dati utente. Dall'altro lato, è il **collo di bottiglia della reattività percepita**. Questo secondo punto è quello che gli utenti sottovalutano di più. Quando un PC viene acceso, quando un programma pesante viene aperto, quando un videogioco carica un livello, o quando un progetto di sviluppo compila migliaia di file sorgente, ciò che determina i secondi di attesa non è quasi mai la potenza bruta della CPU: è la velocità con cui i dati viaggiano dallo storage alla RAM. Un processore di fascia alta accoppiato a un disco



meccanico dà una sensazione di lentezza che nessuna quantità di core può compensare, perché la CPU passa la maggior parte del tempo in attesa (in gergo, in *I/O wait*, input/output wait). Per questo, nella scala di priorità di un assemblaggio, il passaggio da HDD a SSD è storicamente l'upgrade con il miglior rapporto costo-miglioramento percepito di sempre nella storia dei personal computer.

### 1.1 L'evoluzione: HDD → SATA SSD → NVMe SSD

La storia dello storage consumer negli ultimi vent'anni è la storia di due rivoluzioni successive, ed è utile ripercorrerla perché spiega perché il mercato odierno ha la forma che ha, con i suoi retaggi e le sue insidie.

**Fase Uno: Il Regno dell'HDD (fino al ~2010).** Per decenni, l'unico storage di massa economicamente sensato era l'hard disk drive magnetico, un dispositivo elettromeccanico con parti in movimento. Tutta l'architettura software dei PC — il modo in cui i sistemi operativi ordinano le richieste di lettura, il concetto stesso di "deframmentazione", le strategie di caching — era progettata attorno alle limitazioni fisiche di un braccio meccanico che si muove su un piatto rotante.

**Fase Due: L'Arrivo degli SSD SATA (2008–2015).** Gli SSD (Solid State Drive) sostituiscono le parti in movimento con la memoria flash. Ma i primi SSD consumer emersero in un mondo dove l'interfaccia standard era **SATA** (Serial ATA, Serial Advanced Technology Attachment), un'interfaccia progettata *per gli hard disk*. Gli SSD entrarono così nel PC travestiti da hard disk: stesso cavo, stesso connettore, stesso fattore di forma da 2.5 pollici, stesso protocollo software (AHCI, di cui parleremo). Il risultato fu comunque una rivoluzione percepita — i tempi di avvio crollarono da un minuto a dieci secondi — ma fu una mezza rivoluzione, perché l'SSD parlava una lingua pensata per un dispositivo meccanico. Il limite di banda del SATA III, circa 550 MB/s reali, fu saturato quasi subito dalle prime generazioni di SSD decenti, e da lì in poi tutti gli SSD SATA del mondo — dal più economico al più costoso — riportarono più o meno gli stessi numeri sequenziali. Il collo di bottiglia si era spostato dal drive all'interfaccia.

**Fase Tre: NVMe e PCIe (2015-oggi).** La soluzione è rimuovere l'interfaccia legacy e connettere la memoria flash direttamente al bus più veloce disponibile nel sistema, il **PCIe** (Peripheral Component Interconnect Express), lo stesso bus a cui è connessa la scheda grafica. Un nuovo protocollo, **NVMe** (Non-Volatile Memory Express), è definito sopra PCIe, progettato da zero per la memoria flash: parallelismo massivo, code multiple, latenze ridotte, nessun retaggio meccanico. Il risultato, nel giro di pochi anni, è un salto di banda da 550 MB/s a 3.500 MB/s (PCIe

3.0), poi 7.400 MB/s (PCIe 4.0), poi 14.000 MB/s (PCIe 5.0), con latenze che diminuiscono di conseguenza.

Oggi, nel 2026, il panorama consumer è questo: gli SSD NVMe sono lo standard de facto per i drive di sistema, gli SSD SATA sopravvivono come storage secondario economico e nelle macchine più vecchie, e gli HDD si sono ritirati in una nicchia precisa ma ancora molto importante — l'archiviazione ad alta capacità e basso costo per terabyte. Nessuna di queste tre tecnologie è "morta". Sono semplicemente specializzate.

***[dati volatili]** Dalla fine del 2025, il mercato dello storage sta vivendo una fase anomala di forti rincari. La domanda di memoria generata dalle infrastrutture di intelligenza artificiale ha dirottato la capacità produttiva di NAND e DRAM verso il segmento enterprise, con conseguenti aumenti di prezzo percentuali a doppia cifra per gli SSD consumer e ridotta disponibilità per alcune linee di prodotto. Nello stesso periodo, Micron ha annunciato l'uscita dal mercato consumer con il marchio Crucial, per concentrarsi su datacenter e clienti OEM: i modelli Crucial citati in questo capitolo rimangono validi come riferimento tecnico e potrebbero essere ancora disponibili come scorte residue, ma non devono più essere considerati una linea di prodotti in evoluzione. Tutti i prezzi indicati di seguito devono quindi essere presi come ordini di grandezza da verificare al momento dell'acquisto, non come valori affidabili.*

---

## 2. HDD vs. SSD: Due Architetture Fisiche Differenti

### 2.1 Come Funziona un Hard Disk

Un **HDD** (Hard Disk Drive) è, letteralmente, un giradischi di precisione sigillato in una scatola di alluminio. All'interno, ci sono uno o più **piatti**, dischi rigidi di alluminio o vetro rivestiti con un sottilissimo strato di materiale ferromagnetico. I piatti sono montati su un singolo perno collegato a un motore che li fa ruotare a velocità costante: tipicamente 5.400 giri al minuto (RPM) nei modelli per archiviazione e laptop, 7.200 RPM nei modelli desktop e NAS, fino a 10.000 o 15.000 RPM nei drive enterprise più vecchi e ormai obsoleti.

Le informazioni sono memorizzate orientando la magnetizzazione di minuscole regioni del rivestimento: una direzione è "0", l'altra è "1". Le **testine**, montate all'estremità di bracci meccanici che si muovono radialmente sulla superficie dei

piatti, come il braccio di un giradischi, leggono e scrivono questi orientamenti. Ogni superficie di ogni piatto ha la sua testina, e tutti i bracci si muovono insieme, all'unisono. Le testine non toccano mai il piatto: "volano" a poche decine di nanometri dalla superficie, sostenute dal cuscino d'aria generato dalla rotazione. Se una testina tocca il piatto in movimento — a causa di un urto, per esempio — si verifica un famigerato *head crash*, che raschia via il rivestimento magnetico e distrugge i dati in quell'area.

I dati sono organizzati in cerchi concentrici chiamati **tracce**, divise in **settori** (storicamente 512 byte, ora 4096 byte fisici nello standard *Advanced Format*). L'insieme delle tracce che si trovano alla stessa distanza dal centro su tutti i piatti forma un **cilindro**.

La lentezza dell'HDD deriva direttamente da questa architettura. Per leggere i dati, il disco deve eseguire due movimenti fisici in sequenza:

1. **Tempo di ricerca (Seek time)**: il braccio deve spostare la testina sulla traccia corretta. Questo costa tipicamente 8-12 millisecondi su un drive desktop. 2.

**Latenza rotazionale (Rotational latency)**: una volta sulla traccia corretta, si deve attendere che il settore desiderato passi sotto la testina a causa della rotazione del piatto. In media, si attende mezza rotazione. A 7.200 RPM, una rotazione impiega circa 8,3 ms, quindi la latenza media è di circa 4,2 ms; a 5.400 RPM, sale a circa 5,6 ms.

Sommando, un accesso "a freddo" a una posizione casuale del disco costa nell'ordine di **10 millisecondi**. Ed ecco il punto cruciale: quel tempo è **fisico**, dettato dalla meccanica, e non può essere ridotto da alcun miglioramento elettronico. Un moderno HDD da 24 TB legge dati sequenziali a 280 MB/s, una velocità tutt'altro che trascurabile — è la metà di un SSD SATA. Ma se gli chiediamo di leggere quattromila piccoli file sparsi sul disco, come fa un sistema operativo all'avvio, deve pagare 10 ms per ciascuno: il throughput scende a valori nell'ordine di **1-2 MB/s**, ed è per questo che un PC con un hard disk sembra impantanato nella melassa. Non è lento a leggere: è lento a *cercare*.

Le prestazioni di accesso casuale sono misurate in **IOPS** (Input/Output Operations Per Second). Un HDD da 7.200 RPM esegue 75-120 IOPS. Un SSD NVMe di fascia media ne esegue **un milione**. Il rapporto è di circa 1 a 10.000, e nessun numero in questo capitolo è più importante di questo.

## 2.2 Come funziona un SSD

Un **SSD** (Solid State Drive) non ha parti in movimento. È un piccolo computer specializzato, composto da tre elementi fondamentali.

Il primo è la **memoria flash NAND**, i chip che contengono fisicamente i dati. La NAND memorizza le informazioni intrappolando elettroni in una struttura isolata chiamata *floating gate* (o, in implementazioni più moderne, una *charge trap*) all'interno di una cella a transistor. La presenza o assenza di carica — o, più precisamente, il *livello* di carica — determina il valore memorizzato. Poiché l'isolante trattiene gli elettroni anche senza alimentazione, la memoria è non volatile. Questa è una proprietà notevole ma non eterna: un SSD lasciato scollegato per anni perde lentamente la carica e, alla fine, i dati. Per un uso normale, questo è irrilevante; per l'archiviazione a lungo termine in un cassetto, non lo è (torneremo su questo).

Le celle sono organizzate in **pagine** (tipicamente 4-16 KB), e le pagine in **blocchi** (centinaia di pagine, per qualche megabyte). Qui risiede l'asimmetria fondamentale del flash, che spiega quasi tutto ciò che di strano fa un SSD: **i dati vengono letti e scritti per pagine, ma cancellati solo per blocchi interi**. Non si può sovrascrivere una pagina già scritta: bisogna prima cancellare l'intero blocco che la contiene. Di conseguenza, quando il sistema operativo "modifica" un file, l'SSD in realtà scrive la nuova versione in una pagina libera altrove, marca quella vecchia come obsoleta, e prima o poi dovrà fare pulizia consolidando i dati validi e cancellando i blocchi ormai pieni di spazzatura. Questa pulizia si chiama **garbage collection**, e insieme al comando **TRIM** (con cui il sistema operativo comunica all'SSD quali blocchi appartengono a file cancellati e quindi non devono più essere conservati) è ciò che permette all'unità di mantenere prestazioni decenti nel tempo.

Il secondo elemento è il **controller**, il processore dell'SSD. Gestisce tutto: la traduzione tra gli indirizzi logici visti dal sistema operativo e le effettive posizioni fisiche nella NAND (una tabella chiamata *mapping table*, gestita dal firmware **FTL** (Flash Translation Layer)), la garbage collection, la correzione degli errori tramite **ECC** (Error Correcting Code), e il **wear leveling**, ovvero la distribuzione uniforme delle scritture su tutte le celle in modo che nessuna si usuri prima delle altre. Il controller è, non meno della NAND, ciò che determina la qualità di un SSD: due unità con gli stessi chip di memoria ma controller diversi possono comportarsi in modo radicalmente diverso sotto carico.

Il terzo elemento — presente solo nei modelli di fascia medio-alta — è la **cache DRAM**: un chip DRAM (spesso 1 GB per 1 TB di capacità) che il controller usa per tenere la mapping table in memoria veloce. Ne parleremo in dettaglio nella sezione 5, perché è uno dei più importanti discriminanti tra un buon SSD e uno mediocre.

Ne consegue che l'accesso ai dati su un SSD non richiede alcun movimento fisico: il controller consulta la tabella, identifica il chip e la pagina, e li interroga elettricamente. La latenza è nell'ordine delle decine di microsecondi ed è **sostanzialmente identica** sia che il dato sia "all'inizio" o "alla fine" del disco, e sia che si stia leggendo un file grande o mille file piccoli. È la scomparsa del costo di seek, non una maggiore banda passante, la vera ragione per cui gli SSD hanno cambiato l'esperienza d'uso del computer. Da questo deriva anche il fatto che **defragmentare un SSD è inutile** e persino dannoso, perché la frammentazione è un problema solo per chi deve muovere una testina di lettura/scrittura, e le scritture inutili consumano le celle.

### 2.3 Quando l'HDD ha ancora senso

Detto tutto questo, sarebbe un errore concludere che l'hard disk sia obsoleto. L'HDD ha ancora un robusto vantaggio e un vantaggio secondario.

Il robusto vantaggio è il **costo per terabyte**. Un hard disk da 20 TB oggi costa, come ordine di grandezza, meno di un terzo di quanto costerebbe la stessa capacità in SSD (*dato variabile, e reso più favorevole all'HDD dall'aumento in corso dei prezzi delle NAND*). Per una libreria di 40 TB di video, backup e archivi, la differenza non è un dettaglio: è la differenza tra un progetto fattibile e uno irrealizzabile.

Il vantaggio secondario è la **conservazione dei dati a lungo termine senza alimentazione**. Un disco rigido correttamente conservato mantiene i dati per anni senza essere alimentato; un SSD, che si basa su cariche elettriche intrappolate in un isolante, tende a degradarsi più rapidamente se lasciato scollegato per periodi molto lunghi, specialmente se le celle sono già usurate e se le temperature di conservazione sono elevate. Per un backup "a freddo" da mettere in un cassetto e dimenticare, un HDD è ancora la scelta più sensata — a condizione, ovviamente, che venga collegato e controllato periodicamente, e che non ci si affidi mai a una singola copia.

Gli scenari in cui l'HDD è ancora la risposta giusta sono quindi:

- **\*\*Archiviazione a freddo\*\***: collezioni multimediali, archivi fotografici, materiale raramente acceduto e consultato sequenzialmente.
- **\*\*Backup\*\***: unità di destinazione per backup periodici, dove la capacità conta più della latenza.
- **\*\*NAS domestici e piccoli server\*\*** (Network Attached Storage): qui, gli HDD regnano, sia per il costo che perché il collo di bottiglia è spesso la rete stessa. Una rete gigabit trasferisce al massimo circa 110 MB/s: un HDD la satura senza sforzo, e mettere costosi SSD dietro una tale connessione non porta alcun beneficio in termini di larghezza di banda (porta, tuttavia, un beneficio in latenza e IOPS, il che conta se il NAS ospita macchine virtuali o database, non se ospita film).
- **\*\*Videosorveglianza\*\***: registrazione continua e sequenziale di flussi video 24/7, per i quali esistono unità specifiche.

Ciò che l'HDD **non** dovrebbe più fare, nel 2026, è ospitare il sistema operativo. Su questo non c'è dibattito né margine di budget: anche il PC più economico deve avviarsi da un SSD.

## 2.4 Tabella riassuntiva HDD / SATA SSD / NVMe SSD

| Caratteristica            | HDD 7.200 RPM         | SATA SSD                  | NVMe PCIe 4.0 SSD        |
|---------------------------|-----------------------|---------------------------|--------------------------|
| Lettura Sequenziale       | 150–280 MB/s          | ~550 MB/s                 | 5.000–7.400 MB/s         |
| Scrittura Sequenziale     | 150–280 MB/s          | ~520 MB/s                 | 4.000–7.000 MB/s         |
| Lettura Casuale 4K IOPS   | 75–120                | 80.000–100.000            | 600.000–1.500.000        |
| Latenza Tipica            | 8–15 ms               | ~100 µs                   | 40–80 µs                 |
| Parti in Movimento        | Sì                    | No                        | No                       |
| Resistenza agli Urti      | Bassa                 | Alta                      | Alta                     |
| Livello di Rumore         | Udibile               | Silenzioso                | Silenzioso               |
| Consumo Energetico Tipico | 5–9 W                 | 2–4 W                     | 4–9 W (picchi)           |
| Capacità Massima Consumer | 24–30 TB              | 8 TB                      | 8 TB (raro), 4 TB comune |
| Costo per TB              | Più basso             | Intermedio                | Più alto                 |
| Uso Ideale                | Archivio, backup, NAS | Archiviazione secondaria, | OS, giochi, lavoro       |

|  |  |                    |  |
|--|--|--------------------|--|
|  |  | upgrade PC vecchio |  |
|--|--|--------------------|--|

### 3. SATA vs. NVMe: Interfaccia e Protocollo

Qui è fondamentale una distinzione che molti acquirenti confondono. Un'unità di archiviazione è caratterizzata da **due cose diverse**:

- l'**interfaccia fisica ed elettrica**: i fili su cui viaggiano i bit (SATA, PCIe);
- il **protocollo logico**: il linguaggio con cui il sistema operativo e l'unità comunicano su quei fili (AHCI, NVMe).

Storicamente, le due cose andavano di pari passo — SATA usava AHCI — e così si è diffusa l'abitudine di trattarle come sinonimi. Ma, come vedremo con M.2, oggi non lo sono affatto, ed è proprio lì che risiedono gli errori di acquisto.

#### 3.1 SATA III e AHCI

**SATA** (Serial ATA) è l'interfaccia introdotta nei primi anni 2000 per sostituire la vecchia ATA parallela con i suoi cavi a nastro. Nella sua terza revisione, **SATA III** (o SATA 6 Gb/s), offre una larghezza di banda grezza di 6 gigabit al secondo su un singolo canale seriale. Sei gigabit sembrano molti, ma la codifica di linea utilizzata (8b/10b: per ogni 8 bit di dati, ne vengono trasmessi 10, per ragioni di sincronizzazione) occupa il 20% della larghezza di banda, e l'overhead del protocollo si mangia il resto. Il risultato pratico è un tetto di circa **550–560 MB/s** in lettura sequenziale. Questo numero è **il muro**: qualsiasi SSD SATA, oggi come dieci anni fa, si ferma lì. Non esiste un SSD SATA "più veloce" in sequenziale, perché il limite non è nell'unità ma nel canale.

Fisicamente, SATA utilizza **due cavi separati**: un sottile cavo dati a sette contatti che va dall'unità a una porta SATA sulla scheda madre, e un connettore di alimentazione a quindici contatti che proviene dall'alimentatore. Questo è un dettaglio banale ma è la causa principale di panico per i costruttori inesperti che collegano solo il cavo dati e non capiscono perché l'unità non venga rilevata.

Logicamente, SATA utilizza **AHCI** (Advanced Host Controller Interface), un protocollo progettato nell'era degli hard disk. AHCI ha una caratteristica che oggi sembra grottesca: gestisce **una sola coda di comandi**, con una profondità massima di **32 comandi** (una funzionalità nota come NCQ, Native Command

Queuing). La ragione storica è ovvia: che senso aveva inviare mille richieste simultanee a un dispositivo che ha una sola testina di lettura/scrittura e può servirne una alla volta? La singola coda serviva a riordinare le richieste per minimizzare i movimenti del braccio, non per sfruttare un parallelismo che non esisteva. Ma la memoria flash è intrinsecamente parallela: un SSD ha decine di chip NAND collegati al controller su più canali indipendenti, e potrebbe servire molte richieste simultaneamente. Costringerlo in AHCI significa strozzarlo. Inoltre, AHCI richiede alla CPU di eseguire compiti di gestione (accessi ai registri, gestione degli interrupt) che introducono una latenza software non trascurabile quando le operazioni al secondo raggiungono le centinaia di migliaia.

### 3.2 NVMe

**NVMe** (Non-Volatile Memory Express) è il protocollo nato per risolvere esattamente questi problemi. Funziona **direttamente sul bus PCIe**, bypassando completamente il controller SATA della scheda madre, e a livello logico, è costruito attorno a tre idee.

La prima è il **parallelismo massivo**: NVMe supporta fino a **65.535 code**, ciascuna profonda fino a **65.535 comandi**. Questi sono numeri iperbolici che nessun uso consumer si avvicina nemmeno lontanamente, ma il punto non è il numero: è che il protocollo non è più un collo di bottiglia. Un SSD può ricevere migliaia di richieste in sospeso e riordinarle internamente per distribuirle sui suoi canali NAND.

La seconda è l'**affinità di core**: ogni core della CPU può avere la propria coda dedicata, senza dover contendere i lock con altri core. Questo elimina un punto di serializzazione che, ad alte frequenze di I/O, era diventato dominante.

La terza è il **percorso software ridotto**: NVMe richiede molti meno accessi ai registri per comando rispetto ad AHCI, supporta gli interrupt MSI-X e riduce drasticamente l'overhead per operazione.

Il risultato combinato è che un SSD NVMe non è solo "più veloce in larghezza di banda": è **più veloce in latenza** e, soprattutto, gestisce molto meglio i carichi con code profonde, cioè quando arrivano molte richieste insieme.

### 3.3 Confronto reale delle prestazioni: dove conta e dove no

Ora arriviamo alla parte che merita la massima onestà, perché è qui che il marketing mente per omissione.



I numeri stampati sulla scatola sono quelli **sequenziali**: "fino a 7.400 MB/s in lettura". Questi si ottengono leggendo un enorme flusso continuo, con code profonde, in condizioni ideali, su un'unità vuota e fredda. Corrispondono all'uso nel mondo reale in pochissimi casi: copiare un file gigantesco da un NVMe veloce a un altro NVMe veloce, lavorare con flussi video non compressi ad altissima risoluzione, caricare enormi set di dati in memoria.

Il carico di lavoro che **domina l'uso quotidiano**, tuttavia, è completamente diverso: **piccole letture e scritture casuali** (le famose "random 4K"), spesso con **poche richieste in sospeso alla volta** (bassa queue depth, QD1–QD4). Aprire un'applicazione, avviare il sistema operativo, caricare le texture di un gioco, compilare un progetto, aprire un progetto in un IDE: queste sono tutte sequenze di migliaia di piccole letture sparse.

Ed ecco la scomoda verità: nelle **random 4K a bassa queue depth**, la differenza tra un buon SSD SATA e un eccellente NVMe PCIe 5.0 non è dieci volte, come i numeri sequenziali potrebbero suggerire. È tipicamente **due o tre volte** – significativa, ma non miracolosa. E la differenza tra un NVMe PCIe 4.0 di fascia media e un PCIe 5.0 di fascia alta, sotto lo stesso carico, è spesso **solo di pochi punti percentuali**, completamente invisibile a occhio nudo.

Per riassumere brutalmente, ma utilmente:

| Transizione                           | Miglioramento percepito                                                                                                                                          |
|---------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| HDD → SSD SATA                        | <b>Enorme.</b> Il PC sembra un computer diverso.                                                                                                                 |
| SSD SATA → NVMe PCIe 3.0/4.0          | <b>Modesto ma reale.</b> Tempi di avvio e caricamento leggermente più veloci, copie di file molto più veloci, molto più margine di manovra sotto carico pesante. |
| NVMe Gen4 → NVMe Gen5                 | <b>Quasi trascurabile per l'utente medio.</b> Misurabile nei benchmark, invisibile nell'uso, eccetto per specifici carichi di lavoro professionali.              |
| SSD QLC senza DRAM → SSD TLC con DRAM | <b>Evidente quando conta</b> (scritture prolungate, disco pieno, multitasking pesante).                                                                          |

Quest'ultimo punto merita enfasi perché è il fulcro del capitolo: **la classe di un SSD conta più della sua generazione PCIe**. Un buon Gen3 con DRAM e NAND TLC supererà, nell'uso reale, un economico Gen4 senza DRAM con NAND QLC quasi ogni volta che il carico di lavoro diventa serio, nonostante quest'ultimo abbia il doppio dei numeri sequenziali sulla scatola.

La tecnologia **DirectStorage** su Windows e i suoi equivalenti su console meritano una menzione a parte. Questa tecnologia consente ai giochi di caricare asset compressi dall'SSD direttamente nella memoria della GPU, riducendo la necessità di passare attraverso la CPU. Sulla carta, è la tecnologia che giustificherebbe finalmente NVMe più veloci nel gaming. In pratica, l'adozione è stata molto più lenta del previsto e i benefici misurati sui pochi titoli che la implementano rimangono modesti su sistemi con CPU decenti. È un motivo per non comprare un HDD o un SATA per i giochi; **non** è un motivo per pagare un Gen5.

---

## 4. Fattore di forma, slot M.2 e compatibilità fisica

### 4.1 Formati fisici

Le unità di archiviazione consumer oggi sono disponibili in tre forme fisiche principali.

Il formato da **3,5 pollici** è per gli hard disk desktop: un "mattone" di alluminio di circa  $147 \times 102 \times 26$  mm, che si avvita in un alloggiamento del case, alimentato tramite SATA power e collegato tramite SATA data. È l'unico formato in cui si trovano capacità enormi (12, 16, 20, 24 TB).

Il formato da **2,5 pollici** è per gli SSD SATA e gli hard disk dei portatili: circa  $100 \times 70$  mm, con uno spessore di 7 mm (a volte 9,5 mm sugli HDD). Anche qui, due cavi SATA. È il formato per gli upgrade classici su macchine di qualche anno fa.

Il formato **M.2** è una schedina piatta che si inserisce direttamente in uno slot sulla scheda madre e si fissa con una vite (o, sulle schede recenti, con un fermo a scatto senza attrezzi). Non ha cavi: alimentazione e dati passano attraverso lo slot. È il formato dominante per gli SSD moderni ed è anche la principale fonte di confusione, per il motivo che segue.

### 4.2 La trappola numero uno: M.2 SATA vs. M.2 NVMe

**Lo slot M.2 è un fattore di forma fisico, non un protocollo.** Esistono SSD M.2 che, pur avendo una forma identica, parlano **SATA** e non **NVMe**: internamente,

hanno un controller SATA, sono limitati ai soliti 550 MB/s e usano il protocollo AHCI. Sono apparsi negli anni di transizione e si trovano ancora nei marketplace e nelle offerte "troppo belle per essere vere".

Il risultato è che un acquirente inesperto potrebbe acquistare un "SSD M.2", installarlo e ritrovarsi con le prestazioni di un disco SATA di dieci anni fa, senza capirne il motivo. Peggio: molte schede madri hanno slot M.2 che supportano **solo NVMe** e non SATA. In quel caso, l'unità M.2 SATA semplicemente non viene rilevata, e l'utente passa un pomeriggio a cercare guasti inesistenti.

La regola pratica: **quando si acquista un SSD M.2, bisogna leggere esplicitamente "NVMe" e "PCIe" nella descrizione**. Se non c'è scritto, si presume che non lo sia. E quando si sceglie una scheda madre, si dovrebbe leggere il manuale per vedere cosa supporta ogni slot M.2, perché su molte schede, lo slot primario è solo NVMe, mentre uno secondario accetta entrambi.

#### 4.3 M.2 Keys

Il connettore M.2 ha delle **tacche** (keys) che impediscono di inserirlo in slot incompatibili. Ce ne sono tre che sono rilevanti per lo storage.

La **B key** ha la tacca in una posizione che, elettricamente, corrisponde a un massimo di **due linee PCIe** più segnali SATA. Di per sé, è ormai rara negli SSD moderni.

La **M key** ha la tacca in un'altra posizione e corrisponde a **quattro linee PCIe**. È quella che usano gli SSD NVMe veloci: se un'unità ha una sola tacca, ed è a destra guardando il connettore, è una M key.

La **B+M key** ha **due tacche** ed è quindi meccanicamente compatibile sia con slot B che M. Le unità B+M sono per lo più M.2 SATA o NVMe limitati a due linee PCIe, perché la doppia tacca implica il minimo comune denominatore elettrico. **Un SSD con due tacche non è mai un NVMe x4 di fascia alta**. Questo è un indizio visivo molto utile: se vedete due tacche nella foto del prodotto, state guardando un'unità lenta o comunque limitata.

Va aggiunto, per completezza, che il fattore di forma M.2 non ospita solo SSD: schede Wi-Fi (solitamente A o E key, più corte), moduli 5G e altro. Questi slot sono fisicamente simili ma elettricamente diversi, e le chiavi servono proprio a evitare di inserire la cosa sbagliata nel posto sbagliato.

#### 4.4 Dimensioni: 2280 e altri

La designazione numerica di un M.2 codifica larghezza e lunghezza in millimetri: **2280** significa 22 mm di larghezza e 80 mm di lunghezza. È di gran lunga il formato più comune e, salvo casi particolari, è quello che dovreste acquistare.

| Designazione | Dimensioni        | Uso Tipico                                          |
|--------------|-------------------|-----------------------------------------------------|
| 2230         | 22 × 30 mm        | Console portatili (Steam Deck, ROG Ally), ultrabook |
| 2242         | 22 × 42 mm        | Laptop compatti, alcuni mini-PC                     |
| 2260         | 22 × 60 mm        | Raro, alcuni laptop                                 |
| <b>2280</b>  | <b>22 × 80 mm</b> | <b>Standard desktop e laptop: 95% del mercato</b>   |
| 22110        | 22 × 110 mm       | Enterprise/workstation, spesso con PLP              |

Il formato **22110** (110 mm di lunghezza) si trova quasi esclusivamente in ambito enterprise, dove lo spazio extra serve ad alloggiare i condensatori del **PLP** (Power Loss Protection): una batteria di condensatori che, in caso di improvvisa interruzione di corrente, fornisce l'energia necessaria a scrivere sulla NAND i dati che erano ancora nella cache volatile, prevenendo la corruzione. È una caratteristica preziosa nei server e praticamente assente nei prodotti consumer, dove al massimo si trova un PLP "parziale" che protegge solo i metadati.

Attenzione: gli slot delle schede madri desktop hanno solitamente i fori di montaggio per il 2280 e talvolta per lunghezze inferiori, ma quasi mai per il 22110. Se si vuole riutilizzare un SSD enterprise da 110 mm, occorre verificare che la scheda madre possa fisicamente ospitarlo.

#### 4.5 Generazioni PCIe negli SSD

Ogni generazione **PCIe** raddoppia la banda passante per linea. Un SSD NVMe consumer usa quasi sempre **quattro linee** (x4).

| Generazione | Banda per Linea | Banda x4 (Teorica) | Velocità Sequenziale Reale Tipica |
|-------------|-----------------|--------------------|-----------------------------------|
| PCIe 3.0    | ~985 MB/s       | ~3.9 GB/s          | 3.000–3.500 MB/s                  |
| PCIe 4.0    | ~1.97 GB/s      | ~7.9 GB/s          | 5.000–7.400 MB/s                  |

|          |            |            |                                                         |
|----------|------------|------------|---------------------------------------------------------|
| PCIe 5.0 | ~3.94 GB/s | ~15.8 GB/s | 10.000–14.900 MB/s                                      |
| PCIe 6.0 | ~7.88 GB/s | ~31.5 GB/s | Non ancora in ambito consumer<br><i>[dati volatili]</i> |

Il PCIe è **retrocompatibile in entrambe le direzioni**: un SSD Gen4 inserito in uno slot Gen3 funzionerà, limitato alla velocità Gen3; un SSD Gen3 in uno slot Gen5 funzionerà, alla velocità Gen3. Nulla si rompe, nulla si perde se non banda che non sarebbe stata comunque utilizzata. Questo è importante da sapere perché permette di acquistare oggi un drive Gen4 anche su una piattaforma Gen3, in ottica di un futuro cambio di scheda madre.

**Chi ha davvero bisogno del Gen5?** La risposta onesta è: pochissimi utenti consumer. Benefici concreti si vedono in scenari di trasferimento di file molto grandi tra due drive Gen5, nell'editing video ad altissima risoluzione con codec poco compressi, in carichi di lavoro professionali di analisi dati dove si leggono decine di gigabyte in streaming, e in alcuni carichi di lavoro AI (caricamento pesi modello, dataset). Per il gaming, la navigazione, la produttività d'ufficio, la programmazione, la differenza rispetto a un buon Gen4 è nel margine di errore.

Il Gen5 ha anche due svantaggi concreti. Il primo è il **prezzo**, sensibilmente più alto a parità di capacità. Il secondo è il **calore**: i controller Gen5 di prima e seconda generazione consumano molto (si sono visti picchi di 10–12 W contro i 6–8 W di un Gen4), scaldano moltissimo e richiedono **assolutamente** un dissipatore serio, talvolta ingombrante al punto da interferire con la scheda grafica o il dissipatore della CPU. Alcuni modelli Gen5 con controller più efficienti hanno migliorato la situazione, ma il problema rimane.

#### 4.6 Dissipatori e Thermal Throttling

Il **thermal throttling** è la riduzione automatica delle prestazioni che un dispositivo applica a sé stesso quando supera una certa temperatura, per prevenire danni. Negli SSD NVMe, questo riguarda principalmente il **controller**, che è il componente che scalda davvero.

C'è una sottigliezza contro-intuitiva: mentre il controller vuole stare fresco, la **NAND performa meglio quando è calda** (le celle scrivono più facilmente ad alte temperature) ma soffre nel *mantenere* i dati quando è calda e spenta. Per questo motivo, i sensori e le soglie sono calibrate principalmente per il controller.

Quando serve un dissipatore?

- Un SSD **\*\*Gen3\*\*** non ne ha praticamente mai bisogno in un case con un minimo di airflow.
- Un SSD **\*\*Gen4\*\*** ne beneficia sotto carichi prolungati; molte schede madri di fascia medio-alta ne includono uno integrato, più che sufficiente. Raramente è necessario acquistarne uno aftermarket.
- Un SSD **\*\*Gen5\*\*** ne ha **\*\*sempre\*\*** bisogno. Senza adeguata dissipazione, andrà in throttling nel giro di pochi secondi di scrittura sostenuta e finirà per essere più lento di un Gen4 ben raffreddato: uno degli spettacoli più tristi dell'informatica moderna.

Due avvertenze pratiche. Primo: se la scheda madre include un proprio dissipatore M.2, **non c'è bisogno** di comprare un SSD con dissipatore preinstallato — anzi, i due andranno in conflitto e uno dovrà essere rimosso. Secondo: se l'SSD è destinato a una **PlayStation 5**, il dissipatore è obbligatorio ma deve rispettare i limiti di altezza imposti dallo slot (circa 11.25 mm totali), quindi bisogna acquistare modelli esplicitamente dichiarati compatibili, non un dissipatore desktop qualsiasi.

Infine, un dettaglio sull'installazione: i dissipatori aftermarket richiedono la rimozione dell'etichetta dell'SSD? **No**. L'etichetta di molti SSD contiene uno strato di rame o alluminio che aiuta nella dissipazione, e rimuoverla può, in alcuni casi, invalidare la garanzia. Il thermal pad va applicato sopra l'etichetta.

#### 4.7 Lane sharing: quando un SSD disabilita le porte SATA

Qui il capitolo storage si intreccia con il capitolo schede madri, e va letto con attenzione perché è la fonte degli errori di assemblaggio più insidiosi.

Le **lane PCIe** sono una risorsa finita. La CPU ne fornisce un certo numero (tipicamente 20–28 utilizzabili sulle moderne piattaforme consumer: 16 per la scheda grafica, 4 o 8 per uno o due slot M.2 diretti, più il link al chipset). Il **chipset** (il "southbridge", il chip di supporto sulla scheda madre) ne fornisce altre, ma tutte queste devono passare attraverso il collegamento tra chipset e CPU, che è esso stesso limitato e condiviso con USB, rete, audio e il resto.

Dato che le lane non bastano mai, i progettisti di schede madri le **multiplexano**: certe risorse sono alternative tra loro. Configurazioni tipiche che si trovano nei manuali sono:

- Popolando il secondo o terzo slot M.2 si **\*\*disabilitano due o quattro porte SATA\*\*** (perché quelle lane erano condivise).
- Popolando un certo slot M.2 si **\*\*riduce lo slot PCIe della scheda grafica da x16 a x8\*\*** (impatto sulle prestazioni della GPU: nella maggior parte dei casi trascurabile su Gen4/Gen5, ma non su Gen3).
- Popolando un secondo slot PCIe si **\*\*disabilita\*\*** un M.2.

La conseguenza pratica: installi il nuovo NVMe nello slot sbagliato, e di colpo il vecchio SSD SATA o l'hard disk di archivio **scompare dal BIOS**. Il PC funziona, ma metà dello storage è sparito. Chi non ha familiarità con il fenomeno passa ore a dare la colpa ai cavi, all'alimentatore o al drive stesso.

La regola: **prima di acquistare, apri il PDF del manuale della scheda madre e cerca la tabella "M.2 and SATA configuration" (o simile)**. C'è sempre, di solito in una pagina che nessuno legge, e chiarisce esattamente quale slot divide cosa. Un secondo criterio pratico: lo slot M.2 **direttamente connesso alla CPU** (di solito il primo, immediatamente sotto lo slot della scheda video) è il più veloce e tipicamente **non** ruba porte SATA; è lì che va il disco di sistema.

## 5. Tecnologia NAND e componenti chiave

### 5.1 SLC, MLC, TLC, QLC: quanti bit per cella

Abbiamo detto che una cella NAND memorizza informazioni come un livello di carica elettrica intrappolata. La domanda cruciale è: **quanti livelli distinti possiamo distinguere in una cella?** Perché più livelli distinguiamo, più bit possiamo memorizzare nella stessa cella fisica, e quindi meno costa ogni gigabyte.

- **\*\*SLC\*\*** (Single-Level Cell): 2 livelli, **\*\*1 bit\*\*** per cella.
- **\*\*MLC\*\*** (Multi-Level Cell): 4 livelli, **\*\*2 bit\*\*** per cella.
- **\*\*TLC\*\*** (Triple-Level Cell): 8 livelli, **\*\*3 bit\*\*** per cella.
- **\*\*QLC\*\*** (Quad-Level Cell): 16 livelli, **\*\*4 bit\*\*** per cella.
- **\*\*PLC\*\*** (Penta-Level Cell): 32 livelli, 5 bit — annunciata da anni, non ancora un prodotto consumer significativo.

Il guadagno di densità è ovvio. Il costo, meno. Immaginate di dover distinguere il livello dell'acqua in un bicchiere: se dovete solo dire "vuoto o pieno" (SLC), potete sbagliare di parecchio ed essere comunque nel giusto. Se dovete distinguere sedici livelli diversi (QLC) nello stesso bicchiere, ogni goccia in più o in meno conta, la

misurazione richiede più tempo, e la minima evaporazione (cioè perdita di carica dovuta all'usura o al tempo) vi fa scivolare nel livello sbagliato.

Ci sono tre importanti conseguenze:

1. **Durata.** Ogni ciclo di scrittura/cancellazione danneggia leggermente l'isolante della cella. Più livelli devono essere distinti, meno degrado può essere tollerato prima che i livelli diventino ambigui. Da qui l'ordine di grandezza dei cicli tollerabili: SLC ~100.000, MLC ~10.000, TLC ~1.000–3.000, QLC ~300–1.000. 2.

**Velocità di scrittura.** La scrittura richiede di portare la carica al livello esatto, con successive verifiche. Più livelli significano una programmazione della cella più lenta. La scrittura QLC "nativa" (cioè non assistita da cache) è drammaticamente lenta: si vedono valori nell'ordine di **80–150 MB/s**, che è peggio di un hard disk. 3. **Prezzo.** Nella direzione opposta: QLC è la più economica per gigabyte, ed è per questo che esiste.

| Tipo | Bit/cella | Cicli P/E<br>indicativi | Velocità di<br>scrittura<br>nativa | Uso tipico<br>oggi                             |
|------|-----------|-------------------------|------------------------------------|------------------------------------------------|
| SLC  | 1         | ~100.000                | Molto alta                         | Solo<br>enterprise,<br>cache                   |
| MLC  | 2         | ~10.000                 | Alta                               | Praticamente<br>scomparsa<br>dal consumer      |
| TLC  | 3         | ~1.000–3.000            | Media                              | <b>Lo standard<br/>di qualità<br/>consumer</b> |
| QLC  | 4         | ~300–1.000              | Bassa                              | SSD budget ad<br>alta capacità                 |

La conclusione operativa è chiara: **per il disco di sistema, acquistate TLC.** La QLC ha il suo posto — un grande disco secondario da 4 TB destinato a ospitare una libreria di giochi che viene letta molto e scritta poco è un uso perfettamente legittimo della QLC, e in quello scenario il risparmio è reale. Ma un disco QLC come unità principale di un PC che scrive continuamente (aggiornamenti, cache del browser, file temporanei, compilazioni, editing video) è una scelta che si paga in termini di prestazioni e longevità.



Una nota tecnica va aggiunta per completezza: oggi, tutto il NAND consumer è **NAND 3D** (o V-NAND, nella terminologia Samsung), ovvero le celle non sono più disposte su un unico piano ma impilate in torri verticali di decine o centinaia di strati (si è passati da 32 strati a oltre 200-300 strati nelle generazioni recenti). Questo ha permesso di aumentare la densità senza rimpicciolire ulteriormente le celle, il che paradossalmente ha *migliorato* l'affidabilità rispetto ai vecchi NAND planari con nodi minuscoli. È per questo che i moderni TLC sono più affidabili degli MLC di dieci anni fa.

## 5.2 Cache DRAM contro DRAM-less e HMB

Un controller SSD deve mantenere la **tabella di mappatura**: la tabella che associa ogni indirizzo logico (quello che vede il sistema operativo) alla sua effettiva posizione fisica nel NAND. Questa tabella è grande: come regola generale, circa **1 MB di tabella per ogni GB di capacità**, quindi un SSD da 1 TB ha una tabella di mappatura di circa 1 GB.

Dove viene memorizzata?

Un SSD **con cache DRAM** monta un chip DRAM dedicato (tipicamente 1 GB per 1 TB) e vi memorizza l'intera tabella. Ogni volta che il controller deve tradurre un indirizzo, consulta la DRAM: latenza nell'ordine dei nanosecondi. Immediato.

Un SSD **DRAM-less** non ha quel chip. La tabella vive nel NAND stesso e viene consultata da lì. Consultare il NAND per *trovare* dove sono i dati, prima di leggere i dati, significa fare due accessi al NAND invece di uno: la latenza raddoppia, o peggio.

Per mitigare il problema, è stato introdotto **HMB** (Host Memory Buffer): una funzionalità del protocollo NVMe che consente all'SSD di **prendere in prestito una piccola porzione di RAM di sistema** (tipicamente 32-64 MB, in alcuni casi qualche centinaio) per memorizzare parte della tabella di mappatura. Funziona, ed è per questo che i migliori SSD DRAM-less moderni (WD SN770, per esempio) sono sorprendentemente buoni. Ma ha tre limitazioni: (a) 64 MB non sono 1 GB, quindi solo la parte "calda" della tabella può essere messa in cache, e su un disco usato in modo disorganizzato, i miss aumentano; (b) l'accesso alla RAM di sistema passa comunque attraverso il bus PCIe, quindi è più lento della DRAM onboard; (c) HMB richiede il supporto del sistema operativo — è presente nei moderni Windows e Linux, ma in particolari ambienti o vecchie installazioni, potrebbe non esserlo, e in quel caso, l'SSD torna a prestazioni molto scarse.

Quando la differenza diventa evidente? Non nei benchmark sequenziali, dove un'unità DRAM-less può brillare. È evidente nei **carichi di lavoro con molte richieste casuali su un disco pieno e frammentato**, che è esattamente la condizione di un disco di sistema dopo due anni di utilizzo. È evidente nella latenza sotto carico misto. È evidente nella consistenza delle prestazioni.

**Regola pratica: per il disco di sistema, è preferibile un SSD con cache DRAM. Se il budget non lo consente, scegliere almeno un SSD DRAM-less affidabile con HMB (SN770, non qualche sconosciuto), e in ogni caso con NAND TLC.** La combinazione da evitare come disco primario è **DRAM-less + QLC**: è il fondo del barile, ed è esattamente ciò che molti "affari" da 1 TB offrono a prezzi stracciati.

### 5.3 Cache SLC dinamica e crollo della velocità

C'è un fenomeno che confonde molti utenti: copiano un file da 200 GB su un nuovo SSD, vedono 5.000 MB/s per i primi trenta secondi, poi improvvisamente la velocità **scende** a 900 MB/s, o 200, o 90. L'SSD è difettoso? No. Funziona esattamente come progettato.

Il meccanismo è la **cache SLC dinamica** (*pseudo-SLC cache*, o SLC caching). Il controller prende una porzione della NAND TLC o QLC e la fa operare **in modalità SLC**, ovvero scrive un solo bit per cella invece di tre o quattro. In modalità SLC, la scrittura è molto veloce perché non c'è bisogno di posizionare precisamente la carica fra otto o sedici livelli, ma solo di distinguere fra "carico" e "non carico". Tutte le scritture in arrivo vengono quindi riversate in quest'area veloce. Poi, nei momenti di inattività, il controller **rielabora** i dati in background, riscrivendoli in modalità nativa TLC/QLC e liberando la cache.

Il problema è che la cache SLC è **dinamica**: la sua dimensione dipende dallo spazio libero. Un SSD da 2 TB vuoto può avere una cache SLC di 200–600 GB; lo stesso SSD pieno all'85% potrebbe averne solo 20–30 GB, o quasi nulla. E quando la cache si esaurisce, si scrive **direttamente** sulla NAND nativa, alla sua velocità reale. Per una buona TLC, questo significa 900–1.500 MB/s (ancora buono), ma per una QLC significa **80–150 MB/s**: peggio di un hard disk, per ore, con il sistema apparentemente bloccato.

Da questo, seguono tre lezioni operative:

**1. I test di scrittura sostenuta contano più dei numeri di picco.** Le recensioni serie mostrano un grafico della velocità di scrittura su un trasferimento di centinaia di gigabyte: si vede subito dove il pavimento cede e a quale altezza. 2.

**Non riempire l'SSD.** Ne parleremo nella prossima sezione, ma è qui che si vede l'effetto più drammatico. 3. **La QLC dovrebbe essere evitata per carichi di scrittura pesanti e continui.** Un utente che scarica, edita video, sposta archivi di grandi dimensioni, con una QLC quasi piena avrà un'esperienza terribile.

#### 5.4 TBW e MTBF: come interpretare la resistenza dichiarata

Due acronimi compaiono nelle specifiche e vengono regolarmente fraintesi.

**TBW** (Terabytes Written) è la quantità totale di dati che il produttore garantisce possano essere scritti sull'unità entro il periodo di garanzia. Un SSD da 1 TB di fascia media dichiara tipicamente 600 TBW; uno di fascia alta 1.200 TBW; una QLC economica potrebbe fermarsi a 200–400 TBW. Il TBW aumenta proporzionalmente con la capacità, perché più celle ci sono, più scritture possono essere distribuite.

La domanda che tutti si pongono è: **è tanto o poco?** Facciamo due conti. Un utente domestico normale scrive tra 10 e 30 GB al giorno sul disco di sistema (aggiornamenti, cache, documenti, download). Prendiamo il caso peggiore, 30 GB al giorno: sono circa 11 TB all'anno. Con 600 TBW dichiarati, l'unità durerebbe **oltre cinquant'anni**. Anche uno sviluppatore che compila continuamente, o un videomaker che scrive 200 GB al giorno, rimane nell'ordine di **otto-dieci anni**.

La conclusione, che va detta chiaramente perché contrasta con un'ansia diffusa, è che **per l'utente consumer, il TBW non è quasi mai il fattore limitante**. Un SSD moderno, nella stragrande maggioranza dei casi, diventa obsoleto o viene sostituito molto prima che le sue celle si usurino. Le vere eccezioni sono i carichi di lavoro enterprise (database con scritture continue, cache di server, nodi di storage) e alcuni carichi di lavoro professionali estremi. Se rientrate in quelle categorie, il TBW è il primo numero da guardare — e probabilmente avete bisogno di un'unità enterprise, non consumer.

Va ricordato che il TBW ha anche un ruolo **contrattuale**: la garanzia scade al raggiungimento del TBW o del numero di anni dichiarato, a seconda di quale evento si verifichi per primo. È un limite legale ancor prima che fisico: una volta superato il TBW, l'unità di solito continua a funzionare normalmente.

Un indicatore correlato è il **DWPD** (Drive Writes Per Day), più comunemente usato in ambito enterprise: indica quante volte al giorno l'intera capacità del disco può essere riscritta per l'intera durata della garanzia. Un SSD consumer si aggira

intorno a 0,3 DWPD; uno enterprise "write intensive" può raggiungere 3 o 10 DWPD.

**MTBF** (Mean Time Between Failures) è un numero che va interpretato con grande cautela, perché trae in inganno quasi tutti. Un SSD dichiara tipicamente 1.500.000 ore di MTBF. Divise per 8.760 ore in un anno, fanno **171 anni**. Nessuno crede seriamente che un SSD durerà 171 anni, e in effetti non è quello che il numero significa.

MTBF è una **misura statistica di popolazione**, non di longevità individuale. A grandi linee, significa: se metto in funzione 1.500.000 unità per un'ora ciascuna, mi aspetto un guasto. Oppure: se ne metto in funzione 1.000 per un anno, mi aspetto circa 5-6 guasti ( $8.760.000 \text{ ore-unità} / 1.500.000 \approx 5,8$ ). Questo dato è utile a chi gestisce flotte di migliaia di dischi per dimensionare i ricambi. Non **dice assolutamente nulla** su quanto durerà *il vostro* disco, e non tiene conto dell'usura da invecchiamento, perché è misurato durante la fase di vita "utile" del prodotto, escludendo la mortalità infantile e l'usura finale.

Il consiglio: guardate il TBW e gli **anni di garanzia** (5 anni è lo standard per una buona qualità; 3 anni indica un prodotto entry-level). Ignorate l'MTBF come criterio d'acquisto.

Un'ultima cosa, che è la più importante di tutta questa sezione: **nessun numero di durabilità è un sostituto del backup**. Gli SSD, a differenza degli hard disk, tendono a guastarsi **improvvisamente e totalmente**, spesso per un problema al controller o al firmware, senza i rumori e i settori danneggiati progressivi che davano avvisaglie sugli HDD. Un SSD morente spesso diventa un mattone illeggibile, e il recupero dati professionale da NAND è enormemente più difficile e costoso che da un piatto magnetico. La **regola del 3-2-1** (tre copie dei dati, su due supporti diversi, di cui uno off-site) non è una raccomandazione per paranoici: è il minimo indispensabile per chiunque tenga ai propri dati.

---

## 6. Capacità e strategia di configurazione

### 6.1 Quanta capacità

La domanda "di quanto spazio ho bisogno?" ha una risposta che è cambiata rapidamente negli ultimi anni, principalmente per una ragione: **le dimensioni dei giochi sono esplose**. I moderni titoli AAA occupano regolarmente 100-150 GB,

e alcuni superano i 200 GB con i pacchetti texture ad alta risoluzione. Un solo di questi giochi consuma un decimo di un drive da 1 TB.

Il minimo assoluto accettabile per un drive di sistema oggi è **500 GB**, e va detto che è già stretto: Windows 11 con i suoi file di paging, ibernazione e aggiornamenti occupa da solo 60-80 GB, e i programmi comuni ne consumano un'altra centinaia. Con 500 GB ci si può arrangiare, se disciplinati e avendo un secondo drive per i dati.

La **capacità di riferimento sensata nel 2026 è 1 TB** per un PC generico, e **2 TB** per un PC da gaming o per lavori creativi. Sotto 1 TB si fanno continui compromessi; sopra 2 TB il costo aumenta, e vale la pena valutare se sia meglio aggiungere un secondo drive (anche più lento ed economico) piuttosto che raddoppiare la capacità di quello primario.

Esiste anche una ragione tecnica poco nota per cui **le capacità maggiori sono spesso più veloci**: un SSD da 2 TB ha più chip NAND di uno da 500 GB, e il controller può quindi distribuire le operazioni su più canali in parallelo. È tipico che il modello da 250 GB o 500 GB di una linea abbia velocità di scrittura dichiarate significativamente inferiori rispetto al modello da 1 o 2 TB della stessa identica linea. Acquistare la dimensione più piccola di una serie significa spesso acquistare la versione peggiore in termini di prestazioni, non solo di spazio.

## 6.2 La percentuale di riempimento

Questo è uno dei fatti più utili e meno conosciuti dell'intero capitolo: **un SSD pieno è un SSD lento**, e non di poco.

Ci sono tre ragioni concorrenti.

La prima è la **cache SLC dinamica** menzionata sopra: meno spazio libero significa meno cache veloce, e l'unità torna alla velocità nativa della NAND prima.

La seconda è la **garbage collection**. Il controller ha bisogno di blocchi liberi per consolidare i dati ed eliminare quelli obsoleti. Se c'è pochissimo spazio libero, deve eseguire acrobazie: leggere un blocco quasi pieno, copiare le pagine valide altrove, cancellare, riscrivere. Il numero di scritture fisiche per ogni scrittura logica — un parametro chiamato **write amplification** — sale alle stelle. Questo significa non solo lentezza ma anche **usura accelerata**: un'unità mantenuta costantemente piena si usura più velocemente.

La terza è l'**over-provisioning**. Ogni SSD riserva una porzione di NAND dalla fabbrica che non è visibile all'utente (questo è il motivo per cui un SSD da "1 TB" mostra 931 GB: in parte è la differenza tra TB decimale e TiB binario, in parte è spazio riservato). Questo margine serve proprio per la garbage collection e la sostituzione dei blocchi difettosi. Lasciare spazio libero equivale ad aumentare l'over-provisioning, e migliora tutto.

**La regola pratica: non superare l'80% di riempimento, e cercare di rimanere sotto il 75% sull'unità di sistema.** Un SSD da 1 TB dovrebbe essere praticamente considerato un SSD utilizzabile da 750 GB. Questo è, incidentalmente, un ottimo argomento per acquistare la dimensione successiva: 2 TB utilizzati all'80% offrono un comodo 1,6 TB, con prestazioni intatte.

### 6.3 Configurazioni sensate

Vediamo le architetture di archiviazione che hanno senso, per profilo d'uso.

**Configurazione minima (PC da ufficio, navigazione, studio).** Un singolo NVMe da 1 TB, TLC, con o senza DRAM. Nessun secondo disco. Semplice, silenzioso, efficiente. Se il budget è davvero minimo, anche un SATA da 1 TB è meglio di un NVMe da 256 GB: **lo spazio conta più della velocità marginale.**

**Configurazione standard (PC da gaming, uso generale).** Un NVMe da 2 TB, TLC con DRAM, come unico disco. Questa è la soluzione più elegante: niente da gestire, niente da spostare, prestazioni eccellenti ovunque. È ciò che consiglieri di default alla maggior parte delle persone.

**Configurazione a due livelli (gaming con ampia libreria, creator).** Un NVMe TLC da 1 TB con DRAM per il sistema operativo e le applicazioni di lavoro, più un secondo NVMe da 2–4 TB (qui QLC diventa accettabile, e a volte è la scelta razionale) per la libreria di giochi e i dati. Il vantaggio è che le scritture di sistema pesanti e continue avvengono sul disco buono, mentre il disco grande serve prevalentemente carichi di lettura, dove QLC si comporta bene.

**Configurazione completa (professionale, archivio locale).** NVMe da 1–2 TB per sistema operativo e applicazioni, NVMe o SATA da 2–4 TB per progetti attivi, HDD da 8–20 TB per archivio e backup locali. Questa è la classica configurazione a tre livelli — hot, warm, cold — e ha ancora perfettamente senso. Deve essere accompagnata da un **backup off-machine**: un'unità esterna o un NAS, perché un HDD interno non protegge contro furto, incendio, sbalzi di tensione o ransomware.

Una nota sul **RAID** (Redundant Array of Independent Disks) in ambiente domestico: il RAID 0 (striping, due dischi che lavorano in parallelo) è quasi sempre una cattiva idea sui moderni SSD — raddoppia il rischio di perdita totale dei dati per una banda sequenziale che nessuno usa — e il RAID 1 (mirroring) è un meccanismo di alta disponibilità, **non un backup**: se si cancella accidentalmente un file, o se il ransomware lo cripta, viene cancellato o criptato su entrambi i dischi istantaneamente. Il RAID protegge dal guasto hardware di un disco, e nient'altro.

---

## 7. Marche e Modelli di Riferimento

### 7.1 Chi produce NAND e chi assembla

Questa distinzione è fondamentale per orientarsi in un mercato altrimenti caotico, ed è la stessa logica già incontrata nel capitolo sulla RAM.

Esistono **pochissimi produttori di memorie NAND** al mondo: Samsung, SK Hynix (che ha assorbito la divisione NAND di Intel per creare **Solidigm**), Kioxia (ex divisione memorie di Toshiba), Western Digital/SanDisk (storicamente in joint venture produttiva con Kioxia), Micron (marchio consumer Crucial) e YMTC in Cina. Tutti gli altri marchi che si vedono sugli scaffali — Kingston, Corsair, Sabrent, Teamgroup, Adata, Silicon Power, Lexar, Patriot, PNY e decine di altri — **non producono NAND**. Acquistano chip di memoria e controller sul mercato, li assemblano su un PCB e ci mettono sopra un firmware e un'etichetta.

Questo non è un difetto in sé. Alcuni assemblatori realizzano prodotti eccellenti (i Kingston KC3000 e i Sabrent Rocket sono stati SSD eccellenti, costruiti su controller Phison di fascia alta e buone NAND). Ma ha una conseguenza precisa e pericolosa: **l'assemblatore può cambiare i componenti interni senza cambiare il nome del prodotto**.

È il fenomeno noto come **lotteria dei componenti** o *revisione silenziosa*: un SSD viene lanciato con NAND TLC e controller X, ottiene recensioni eccellenti, e sei mesi dopo lo stesso identico numero di modello viene prodotto con NAND QLC e un controller diverso, con prestazioni sostenute molto peggiori. L'acquirente legge le entusiastiche recensioni di lancio e riceve a casa un prodotto diverso. Il caso più citato in ambito consumer è quello dei **Kingston NV1/NV2**, dichiaratamente soggetti a variazione di componenti, con unità trovate sul mercato in configurazioni radicalmente diverse; ma il fenomeno ha colpito, in misura



variabile, molti marchi, incluso il famoso caso della revisione silenziosa del Samsung 970 EVO Plus e le variazioni sul WD Blue SN550.

La difesa è duplice. Primo: **preferire, a parità di prezzo, i marchi che producono le proprie NAND** (Samsung, WD/SanDisk, Solidigm, Micron/Crucial finché disponibili, Kioxia), perché la filiera è verticale e le revisioni silenziose sono più rare e documentate. Secondo: **diffidare dei modelli le cui specifiche non dichiarano il tipo di NAND**. Se una scheda tecnica non dice se è TLC o QLC, se ha DRAM o meno, è quasi sempre perché la risposta non piacerebbe, o perché il produttore vuole tenersi aperte le opzioni.

## 7.2 Panoramica dei Marchi di SSD

**Samsung.** È il riferimento storico, per una semplice ragione: produce NAND, controller e DRAM in-house. Le serie **970 EVO/Pro** (PCIe 3.0) sono state per anni il gold standard; la serie **980** ha introdotto una fastidiosa ambiguità (il semplice "980" è un Gen3 **DRAM-less**, mentre il "980 Pro" è un Gen4 con DRAM: nomi quasi identici, prodotti in categorie diverse — un caso da manuale di nomenclatura fuorviante). La serie **990 PRO** è oggi un riferimento Gen4, veloce, efficiente, con ottima consistenza sotto carico; la variante **990 EVO Plus** è più economica e usa una configurazione ibrida di linee PCIe. Samsung tende a costare più della media: si paga il brand, ma anche una reale consistenza. Nota storica: le prime unità 990 PRO e 980 PRO hanno avuto problemi di degrado della salute risolti via aggiornamento firmware — un promemoria che **aggiornare il firmware degli SSD** (con gli strumenti ufficiali: Samsung Magician, WD Dashboard, Crucial Storage Executive) è una buona abitudine, non un'operazione da power user.

**Western Digital / SanDisk.** L'altro grande nome verticale. Il **WD Black SN850X** è probabilmente l'SSD Gen4 con DRAM più consigliato: prestazioni eccellenti, ottima gestione termica, prezzo competitivo, e in molte configurazioni è la scelta razionale per un drive di sistema. Il **WD Black SN770** è il campione della categoria DRAM-less: usa l'HMB in modo intelligente, ha NAND TLC, ed è sorprendentemente vicino agli SSD con DRAM nell'uso reale, a un prezzo inferiore. È l'eccezione che dimostra che "DRAM-less" non significa automaticamente "scarsa qualità", a patto che il resto sia fatto bene. L'**SN850X** è disponibile anche in versione con dissipatore e in versione compatibile con PS5. La linea **WD Blue** (SN580 e simili) è l'onesto entry-level. Il gruppo ha recentemente separato le sue attività flash sotto il marchio **SanDisk**, quindi ci si può aspettare di vedere gli stessi prodotti sotto nomi in transizione *[variable data]*.



**Crucial (Micron).** Storicamente il campione del rapporto prezzo-prestazioni. I **P3** e **P3 Plus** sono drive QLC economici (buoni come drive secondari, sconsigliati come primari); il **P5 Plus** è stato un eccellente Gen4 con DRAM; il **T500** è un ottimo e molto competitivo Gen4 con DRAM; i **T700** e **T705** sono stati tra i primi drive Gen5 di fascia alta, molto veloci e molto caldi, richiedendo dissipatori sostanziosi. **[volatile data]** Come accennato all'inizio, Micron ha annunciato la sua uscita dal mercato consumer con il marchio Crucial: questi prodotti rimangono tecnicamente validi ma non dovrebbero più essere considerati una linea con un futuro, e la disponibilità deve essere verificata caso per caso. Chi acquista oggi scorte residue Crucial fa un affare tecnico ma deve tenere conto di un supporto e una sostituzione meno garantiti nel tempo.

**Kingston.** Un assemblatore, non un produttore di NAND. Il **KC3000** è stato un eccellente Gen4 (controller Phison E18, NAND TLC, DRAM) e il **Fury Renegade** è la sua controparte gaming. All'estremo opposto, la serie **NV2** (e in precedenza l'**NV1**) è l'esempio da manuale della lotteria dei componenti: stesso nome, componenti variabili, prestazioni imprevedibili. Non è un prodotto "cattivo" in termini assoluti, ma è un prodotto in cui **non si può sapere cosa si sta comprando**, il che nel 2026 è una ragione sufficiente per starne alla larga se esistono alternative allo stesso prezzo.

**Solidigm.** È l'ex divisione NAND di Intel, ora sotto SK Hynix. Produce NAND proprie. È diventata particolarmente interessante nella nicchia degli **SSD a capacità molto elevata e basso costo per TB**: la serie **P44 Pro** è un ottimo Gen4 con DRAM (tecnicamente un parente stretto dell'**SK Hynix Platinum P41**), mentre le serie QLC ad alta capacità (**P41 Plus**, e le linee da 4 TB in su) sono tra le più sensate quando serve tanto spazio a basso prezzo per carichi prevalentemente in lettura.

**Seagate.** Nota principalmente per gli hard disk, ha una buona linea di SSD **FireCuda** (530, 540), basati su controller Phison e NAND TLC, con TBW dichiarati molto elevati e garanzia lunga. Sono prodotti validi, spesso posizionati a prezzi premium.

**Sabrent.** Assemblatore americano che si è costruito un'ottima reputazione con la sua linea **Rocket** (Rocket 4 Plus, Rocket 5), basata su controller Phison di fascia alta. Spesso è il primo a commercializzare le nuove generazioni. Buoni prodotti, ma vale sempre la regola: verificare la revisione e i componenti effettivi.

**SK Hynix.** Meno diffusa in Europa ma tecnicamente eccellente: il **Platinum P41** e il successivo **P51** sono drive con NAND e controller proprietari, tra i più efficienti sul mercato (bassi consumi, poco calore, ottime prestazioni). Se trovati a buon prezzo, è una scelta molto solida.

### 7.3 Tabella Orientativa SSD

| Livello                        | Modelli di Riferimento                                                                     | Caratteristiche                           | Uso Consigliato                                         |
|--------------------------------|--------------------------------------------------------------------------------------------|-------------------------------------------|---------------------------------------------------------|
| Entry / Secondo Drive          | Crucial P3 Plus, WD Blue SN580, Solidigm P41 Plus                                          | Gen3/Gen4, DRAM-less, spesso QLC          | Archiviazione secondaria, librerie di giochi            |
| Entry di Qualità               | <b>WD Black SN770</b> , Kingston NV3 (con riserve)                                         | Gen4, DRAM-less HMB, TLC                  | Drive di sistema con budget limitato                    |
| Fascia Media (il "sweet spot") | <b>WD Black SN850X</b> , Samsung 990 EVO Plus, Crucial T500, SK Hynix P41/Solidigm P44 Pro | Gen4, DRAM, TLC                           | <b>Drive di sistema: la scelta consigliata</b>          |
| Fascia Alta Gen4               | Samsung 990 PRO, Seagate FireCuda 530/540                                                  | Max Gen4, DRAM, TLC                       | Workstation, per chi vuole il massimo senza il Gen5     |
| Gen5                           | Crucial T705, Samsung 9100 PRO, Sabrent Rocket 5, Corsair MP700 Pro                        | Gen5, DRAM, TLC, dissipatore obbligatorio | Solo per carichi di trasferimento professionali massivi |

*I modelli specifici e la loro disponibilità cambiano rapidamente; questa tabella va usata per capire le categorie, non come lista della spesa definitiva. [dati volatili]*

### 7.4 Hard Disk: Seagate, WD, Toshiba e la Trappola SMR

Nel mercato degli hard disk, sono rimasti **solo tre produttori** al mondo: **Seagate**, **Western Digital** (con i marchi WD e HGST) e **Toshiba**. Tutto ciò che comprate, sotto qualsiasi etichetta, proviene da loro.

WD usa storicamente un codice colore per le sue linee, utile da conoscere:

| Linea WD                    | Colore | Scopo                                        |
|-----------------------------|--------|----------------------------------------------|
| WD Blue                     | Blu    | Desktop generico, uso leggero                |
| WD Black                    | Nero   | Desktop performance, 7.200 RPM, cache grande |
| WD Red / Red Plus / Red Pro | Rosso  | NAS (attenzione: il "Red" liscio è SMR!)     |
| WD Purple                   | Viola  | Videosorveglianza, scrittura continua        |
| WD Gold                     | Oro    | Enterprise, datacenter                       |

Seagate ha una struttura simile: **BarraCuda** (desktop), **IronWolf** e **IronWolf Pro** (NAS), **SkyHawk** (sorveglianza), **Exos** (enterprise). Toshiba usa designazioni alfanumeriche (serie **N300** per NAS, **X300** per desktop performance, **MG** per enterprise).

E ora, la trappola più importante di questa sezione.

**CMR contro SMR.** Questi sono due modi di scrivere le tracce magnetiche sul piatto.

**CMR** (Conventional Magnetic Recording — a volte chiamato PMR) scrive le tracce affiancate e non sovrapposte. Ogni traccia può essere riscritta indipendentemente dalle altre. Questo è il comportamento "normale" atteso da un drive.

**SMR** (Shingled Magnetic Recording) sfrutta un'asimmetria fisica: la testina di **scrittura** è più larga di quella di **lettura**. Se le tracce vengono scritte parzialmente sovrapposte, come le tegole di un tetto, se ne possono impacchettare di più sullo stesso piatto, guadagnando il 10–25% di capacità a parità di hardware. La lettura funziona perfettamente, perché la testina di lettura più stretta può leggere la porzione scoperta della traccia.

Il problema è la **riscrittura**. Poiché le tracce si sovrappongono, una singola traccia non può essere riscritta senza distruggere quelle adiacenti: l'intera "banda" di tracce shingled deve essere letta, modificata in memoria, e poi riscritta per intero. Il drive maschera questo fenomeno con una zona di cache CMR, ma quando la cache si esaurisce — cioè, sotto scrittura casuale prolungata — le prestazioni **crollano**, e non di poco: scendono a **10–20 MB/s**, con latenze di secondi. Il drive sembra rotto.

Dove diventa un disastro? In un **NAS con RAID**. Quando un drive guasto viene sostituito, l'array deve **ricostruire** i dati sul nuovo drive: questo è un carico di scrittura pesante e continuo, che dura ore o giorni. Un drive SMR, in queste condizioni, rallenta così tanto che il controller RAID può considerarlo non responsivo ed **espellerlo dall'array**, rovinando la ricostruzione. In un array già degradato, con un solo drive di ridondanza rimanente, questo può significare la **perdita totale dei dati**.

Ciò che rende la situazione ancora più grave è che, nel 2020, WD, Seagate e Toshiba sono stati scoperti a vendere drive SMR **senza dichiararlo**, includendoli in linee esplicitamente destinate ai NAS (in particolare alcuni WD Red da 2–6 TB). Questo ha portato a class action, scuse pubbliche e una chiarificazione delle linee di prodotto: da allora, WD ha creato "Red **Plus**" per indicare i CMR, lasciando il semplice "Red" per gli SMR. Ma la lezione rimane: **le etichette non bastano; bisogna verificare il modello specifico**.

**Regola operativa: per un NAS, per un RAID, o per qualsiasi uso che preveda scritture significative, si deve acquistare solo CMR.** Prima di acquistare un hard drive, cercate il numero di modello esatto (es. WD60EFPX, ST8000VN004) insieme alla parola "CMR" o "SMR": i tre produttori pubblicano ora liste ufficiali, e le comunità di appassionati ne mantengono di aggiornate. L'SMR ha senso solo per l'archiviazione write-once, read-many, tipicamente in drive USB esterni destinati al backup di grandi archivi che vengono raramente riscritti.

Un'ultima nota: alcuni hard drive enterprise ad altissima capacità sono **riempiti di elio** invece che di aria. L'elio, essendo meno denso, riduce la turbolenza attorno ai piatti, permettendo di impilare più piatti (9, 10, 11) e riducendo il consumo energetico e le temperature. Si tratta di drive eccellenti, sigillati ermeticamente, ma costosi e spesso rumorosi (i modelli enterprise a 7.200 RPM non sono progettati per stare sotto la scrivania del salotto).

## 7.5 Il processo di selezione, in ordine

Riassumendo il metodo per scegliere lo storage in una sequenza logica, si procede come segue:

1. **Utilizzo.** Cosa dovrebbe fare questa unità? Sistema operativo? Libreria di giochi? Archivio? Backup? Tutto il resto ne consegue.
2. **Interfaccia.** Sistema operativo e applicazioni → NVMe, sempre. Archiviazione dati secondaria → NVMe se ci sono slot liberi, SATA altrimenti. Archivio di massa → HDD.
3. **Capacità.**

Stima l'occupazione effettiva, aggiungi un margine per il futuro e **dividi per 0.8** per aderire alla regola del riempimento. Hai bisogno di 1 TB di roba? Compra 1.5–2 TB. 4. **Tipo di NAND e DRAM.** Unità di sistema → **TLC**, preferibilmente **con DRAM**. Unità secondaria prevalentemente per la lettura → QLC accettabile. 5. **TBW e Garanzia.** Verifica che il TBW sia coerente con il carico previsto (per uso consumer, lo è quasi sempre) e preferisci garanzie di 5 anni. 6. **Marca.** A parità di specifiche, preferisci i produttori che producono le proprie NAND e non fanno revisioni silenziose. 7. **Prezzo.** Solo a questo punto guarda il prezzo e confronta il **costo per gigabyte** tra i candidati rimanenti. Il prezzo è l'ultimo filtro, non il primo, perché un'unità economica che fallisce ai punti 4 e 6 non è un affare: è un problema rimandato.

---

## 8. Errori comuni dell'acquirente

Qui elenchiamo esplicitamente gli errori più comuni riscontrati — molti già anticipati, ma vale la pena elencarli perché ognuno costa denaro, tempo o dati.

**Acquistare un SSD QLC DRAM-less come unità primaria.** Questo è l'errore numero uno, ed è guidato dal marketing: la scatola dice "PCIe 4.0, fino a 5.000 MB/s", il prezzo è ottimo, sembra un affare. Poi scopri che quei 5.000 MB/s durano solo finché la cache SLC regge, e che quando l'unità si riempie — il che avviene dopo un anno di uso normale — le velocità di scrittura scendono sotto i 200 MB/s e il sistema diventa lento sotto carico. **L'unità di sistema è l'ultimo posto dove risparmiare 20 euro.**

**Montare l'NVMe nello slot sbagliato e disabilitare le porte SATA.** Già ampiamente discusso: il manuale della scheda madre ha la tabella di condivisione delle linee, e dovrebbe essere letto **prima** di acquistare, non dopo che le unità sono scomparse dal BIOS.

**Pagare per un SSD Gen5 senza averne bisogno.** Un Gen5 costa significativamente di più di un Gen4 della stessa capacità, scalda molto di più, richiede un dissipatore ingombrante, e nell'uso consumer — incluso il gaming — offre un miglioramento percepito che va da "nessuno" a "impercettibile". Quella differenza di prezzo, spesa invece in **capacità** (2 TB Gen4 invece di 1 TB Gen5) produce un beneficio reale e quotidiano. Il Gen5 ha senso per chi sposta abitualmente decine o centinaia di gigabyte tra unità veloci, e per pochi altri.

**Acquistare un M.2 SATA credendo di acquistare un NVMe.** Stesso slot, protocollo diverso, un decimo delle prestazioni. Controlla che "NVMe" e "PCIe" appaiano nelle specifiche tecniche, e diffida delle unità con due tacche.

**Prendere un HDD SMR per un NAS.** Rischio concreto di perdita totale dei dati durante una ricostruzione RAID. Verifica il modello esatto rispetto agli elenchi ufficiali CMR/SMR.

**Acquistare la dimensione più piccola di una serie.** Il modello da 250 o 500 GB di una linea è spesso più lento in scrittura rispetto al modello da 1 o 2 TB della stessa linea, perché ha meno chip da parallelizzare. Paghi poco e ottieni poco, in due sensi.

**Riempire l'unità al 95% e poi lamentarsi che il PC è lento.** Il rimedio è gratuito: libera spazio, o acquista più capacità.

**Deframmentare un SSD.** Inutile e dannoso. I Windows moderni lo fanno e, quando "ottimizzano" un SSD, in realtà inviano comandi TRIM — che è una cosa completamente diversa e legittima. Non installare utility di deframmentazione di terze parti su un SSD.

**Credere che RAID 1 sia un backup.** Non lo è. Protegge da un singolo guasto del disco. Non protegge da cancellazioni accidentali, ransomware, sbalzi di tensione, furti o incendi.

**Ignorare gli aggiornamenti firmware.** Diversi seri problemi di affidabilità su SSD di marca sono stati risolti tramite aggiornamenti firmware. Vale la pena installare l'utility ufficiale del produttore e controllare di tanto in tanto.

**Non controllare mai lo stato S.M.A.R.T. S.M.A.R.T.** (Self-Monitoring, Analysis and Reporting Technology) è il sistema di autodiagnosi integrato in tutti i dischi: espone contatori come le ore di accensione, i terabyte scritti, i settori riallocati e la percentuale di vita rimanente. Strumenti gratuiti come CrystalDiskInfo (Windows) o `smartctl` (Linux) consentono di leggerli in pochi secondi. Un rapido sguardo di tanto in tanto, e specialmente **prima di acquistare usato**, evita spiacevoli sorprese: un SSD usato con l'80% della sua vita consumata non è un affare a nessun prezzo.

**Fidarsi di un singolo supporto di archiviazione.** Vale la pena ripeterlo un'ultima volta: gli SSD muoiono senza preavviso e il recupero è costoso, se non

impossibile. Qualsiasi configurazione di archiviazione senza una strategia di backup è, semplicemente, incompleta.

---

## 9. Riepilogo Operativo — Lista di Controllo per la Scelta dello Storage

### Passo 1 — Definire il ruolo di ogni unità.

- ☐ Sistema operativo e applicazioni → **NVMe SSD**, senza eccezioni.
- ☐ Giochi e progetti attivi → NVMe (o SATA se non ci sono slot disponibili).
- ☐ Archivio e backup locale → **HDD CMR ad alta capacità**.
- ☐ Backup remoto/esterno → pianificato? (regola 3-2-1)

### Passo 2 — Verificare la compatibilità della scheda madre.

- ☐ Quanti slot M.2 ci sono e quale generazione PCIe supportano?
- ☐ Aprire il manuale, leggere la tabella di **lane sharing**: quale slot M.2 disabilita quali porte SATA o riduce lo slot GPU?
- ☐ Lo slot scelto per il disco di sistema è **direttamente collegato alla CPU**?
- ☐ La scheda madre include già un **dissipatore M.2**? (Se sì, non acquistare un SSD con dissipatore integrato.)
- ☐ Il formato è **2280**? (Controllare i fori di montaggio se si usano formati diversi.)

### Passo 3 — Scegliere le specifiche dell'SSD.

- ☐ È **NVMe** e non M.2 SATA? (Cercare "NVMe" e "PCIe" nelle specifiche tecniche; diffidare dei dischi con due tacche.)
- ☐ La NAND è **TLC**? (QLC consentito solo per dischi secondari con operazioni prevalentemente di lettura.)
- ☐ Ha **cache DRAM**? (Se senza DRAM, è un modello affidabile con HMB come l'SN770?)
- ☐ Il **TBW** è coerente con il carico di lavoro previsto? (Per uso consumer, quasi sempre sì.)
- ☐ La **garanzia** è di 5 anni?
- ☐ Ci sono test di **scrittura sostenuta** nelle recensioni? Dove cala la velocità?
- ☐ La generazione PCIe è adeguata: **Gen4 è il punto ottimale**; Gen5 solo se il carico di lavoro lo giustifica davvero.

#### **Passo 4 — Dimensionare la capacità.**

- ☐ Stimare l'utilizzo effettivo previsto.
- ☐ Aggiungere un margine e dividere per **0.8** (non superare l'80% di riempimento).
- ☐ Minimo 1 TB per uso generale, **2 TB** consigliati per giochi o lavoro creativo.
- ☐ Verificare che la capacità scelta non sia una versione depotenziata della serie.

#### **Fase 5 — Scegliere la marca.**

- ☐ A parità di specifiche, preferire un produttore di NAND verticali (Samsung, WD/SanDisk, SK Hynix/Solidigm, Kioxia, Micron).
- ☐ Verificare che il modello non sia noto per **revisioni silenziose** dei componenti.
- ☐ Controllare che le specifiche tecniche dichiarino esplicitamente il tipo di NAND e la presenza di DRAM.

#### **Fase 6 — Se si acquista un HDD.**

- ☐ Verificare che sia **CMR** (obbligatorio per NAS e RAID), controllando il numero di modello esatto.
- ☐ Scegliere la linea giusta per l'utilizzo (NAS / sorveglianza / desktop / enterprise).
- ☐ Considerare rumore e vibrazioni se il PC si trova in un ambiente silenzioso.

#### **Fase 7 — Dopo l'installazione.**

- ☐ Tutti i drive sono visibili nel BIOS/UEFI? (Se no → sospettare lane sharing.)
- ☐ Il drive NVMe è riconosciuto alla corretta generazione PCIe? (Verificabile con CrystalDiskInfo o utility del produttore.)
- ☐ Il **TRIM** è attivo? (Su Windows e Linux moderni, lo è di default.)
- ☐ Firmware aggiornato con l'utility ufficiale?
- ☐ Temperature sotto carico controllate? (Sopra i 70 °C sostenuti sul controller, serve migliore dissipazione.)
- ☐ **Backup configurato.** Nessuna configurazione di storage è completa senza questo punto.

**Consigli rapidi per fascia di budget** (*prezzi indicativi e attualmente molto instabili — [dati volatili]*)



| Fascia   | Configurazione consigliata                                                                                    | Logica                                                                                  |
|----------|---------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------|
| Entry    | 1× 1TB Gen4 TLC NVMe, anche DRAM-less di qualità (es. WD Black SN770)                                         | Un singolo, buon drive. Meglio un discreto 1TB che un "premium" 500GB o un pessimo 2TB. |
| Mid      | 1× 2TB Gen4 TLC NVMe con DRAM (es. WD Black SN850X, Samsung 990 EVO Plus, Crucial T500)                       | <b>La scelta giusta per la maggior parte delle persone.</b> Semplice, veloce, capiente. |
| High-end | 1× 2TB Gen4/Gen5 NVMe con DRAM per OS + 1× 4TB NVMe (anche QLC) per librerie + 1× 8–20TB CMR HDD per archivio | Tre livelli: hot, warm, cold. Gen5 solo se il carico di lavoro lo giustifica.           |

---

**Nota finale.** Se dovessi riassumere l'intero capitolo in una frase, sarebbe questa: *la qualità di un SSD si misura da TLC, DRAM e prestazioni di scrittura sostenute, non dal numerone stampato sulla scatola.* Chi interiorizza questo principio comprenderà bene anche senza sapere altro; chi lo ignora continuerà a pagare per banda sequenziale che non userà mai, e si chiederà perché il suo nuovo computer sembra impantanato dopo un anno.

## Capitolo 6 - L'alimentatore (PSU)

### Premessa: il componente invisibile

Di tutte le parti che compongono un personal computer, l'alimentatore è quella che riceve meno attenzioni e, statisticamente, causa più danni. È un oggetto che non compare nei benchmark, non produce frame per secondo, non ha un punteggio Cinebench, non è esposto in nessuna vetrinetta illuminata a RGB (o meglio: alcuni produttori ci hanno provato, con risultati discutibili). Sta in fondo al case, spesso in un vano separato, coperto da una paratia metallica, e l'utente medio se ne dimentica il giorno stesso in cui chiude il pannello laterale.

Eppure, ogni singolo elettrone che alimenta CPU, GPU, RAM, SSD e ventole passa attraverso di esso. L'alimentatore — in inglese, *Power Supply Unit*, da cui l'acronimo **PSU** che useremo d'ora in poi — è l'unico componente che, guastandosi male, può trascinare con sé il resto del sistema. Una scheda grafica che si rompe, si rompe da sola. Una PSU che si rompe male può portare con sé la scheda madre, la CPU, la memoria e i dischi in una frazione di secondo, perché è l'unica cosa nel case fisicamente connessa a un muro che eroga 230 volt di corrente alternata.

Questo capitolo tratta la PSU come merita: partendo da cosa fa fisicamente, passando a come dimensionarla, come leggere un'etichetta, come distinguere un buon prodotto da un cattivo prodotto mascherato da buono, e terminando con una procedura di acquisto ripetibile. Come per i capitoli precedenti, i dati che possono diventare obsoleti (prezzi, modelli sul mercato, generazioni di schede grafiche) sono esplicitamente contrassegnati con il tag **[dati volatili]**: l'hardware si muove velocemente, i principi fisici molto meno.

---

## 1. Cosa fa la PSU

### 1.1 Conversione AC→DC

La presa elettrica di casa, in Italia e in tutta Europa, eroga corrente alternata (**AC**) a una tensione nominale di 230 volt e una frequenza di 50 hertz. "Alternata" significa che la tensione non è costante: oscilla sinusoidalmente, passando cinquanta volte al secondo da un valore di picco positivo a un valore di picco negativo. Questo è ottimo per trasportare energia su lunghe distanze — motivo per cui l'intera rete elettrica globale funziona così — ma è totalmente inutilizzabile da un circuito digitale.

I componenti del computer vogliono corrente continua (**DC**): una tensione stabile e costante che non oscilla. Un transistor all'interno di una CPU non ha idea di cosa fare con un'onda sinusoidale a 50 Hz. Vuole 12 volt fissi, o 5, o 3.3, e li vuole stabili entro pochi punti percentuali, sempre, senza interruzioni.

La PSU è la macchina che esegue questa traduzione. Il processo, semplificando enormemente una catena che in realtà ha decine di stadi, funziona così. La corrente alternata entra e incontra per prima cosa un **filtro EMI** (*ElectroMagnetic Interference*): un gruppo di condensatori e induttori il cui compito è duplice: impedire che i disturbi dalla rete elettrica entrino nell'alimentatore e — altrettanto importante e spesso dimenticato — impedire che i disturbi generati dall'alimentatore stesso (che è un circuito che commuta decine di migliaia di volte al secondo) tornino alla rete e disturbino altri apparecchi. Negli alimentatori economici, questo stadio è il primo a essere sacrificato: vengono rimossi componenti, lasciati pad vuoti sul circuito stampato, e il risultato è un dispositivo che, per legge, non dovrebbe nemmeno poter recare la marcatura CE.

Dopo aver superato il filtro, l'onda sinusoidale incontra un **ponte raddrizzatore**, un gruppo di quattro diodi che "ribalta" le semionde negative, rendendole positive. A questo punto abbiamo una tensione sempre positiva ma che pulsa violentemente: non è ancora corrente continua, è una specie di gobba di cammello ripetuta un centinaio di volte al secondo. Interviene quindi lo stadio di **PFC** (*Power Factor Correction*), che negli alimentatori moderni è quasi sempre **attivo** e non passivo. Il compito del PFC è far sì che la corrente prelevata dalla rete sia in fase con la tensione e abbia una forma d'onda il più possibile sinusoidale: senza di esso, un alimentatore preleverrebbe corrente a impulsi stretti e violenti, inquinando la rete e costringendo il fornitore di energia a dimensionare tutto per una potenza apparente ben maggiore di quella effettivamente consumata. Un PFC attivo ben progettato porta il fattore di potenza sopra 0.95; è anche lo stadio che carica il grosso condensatore elettrolitico primario, quello grande e cilindrico che è subito visibile aprendo un alimentatore e che tipicamente opera attorno ai 400 volt in continua.

Da quei 400 volt in continua, dobbiamo scendere ai 12 volt richiesti dal computer, e questo deve avvenire con un completo isolamento galvanico tra la rete elettrica e il PC — altrimenti toccare il case significherebbe toccare la rete elettrica. Questo compito spetta allo **stadio di switching primario**, che trita i 400 V continui in un'onda quadra ad alta frequenza (decine o centinaia di kilohertz), la invia

attraverso un trasformatore e ne raccoglie una versione a bassa tensione sull'altro lato. Lavorare ad alta frequenza è il trucco che permette agli alimentatori moderni di essere piccoli: un trasformatore che lavorasse a 50 Hz per erogare 850 watt sarebbe un mattone di diversi chilogrammi, mentre uno che lavora a 100 kHz sta nel palmo di una mano. Le topologie usate hanno nomi che il lettore incontrerà nelle recensioni tecniche — half-bridge, full-bridge, e soprattutto **LLC risonante**, oggi lo standard de facto nella fascia media e alta perché permette ai transistor di commutare quando la corrente che li attraversa è prossima allo zero, riducendo drasticamente le perdite.

Infine, sul lato secondario, la corrente a bassa tensione ma ancora alternata viene raddrizzata. Negli alimentatori di qualità, questo avviene con la **rettifica sincrona**: invece di diodi (che dissipano una tensione di soglia, circa 0.4-0.7 V, moltiplicata per decine di ampere, cioè decine di watt sprecati in calore), si usano MOSFET pilotati attivamente, che si comportano come interruttori quasi ideali. Questa è una delle ragioni principali per cui un alimentatore Gold o Platinum è più efficiente di uno Bronze.

### 1.2 I rail: 12V, 5V, 3.3V (e i fantasmi del passato)

Il termine **rail** indica una linea di alimentazione a una specifica tensione. Un alimentatore ATX moderno fornisce al computer le seguenti tensioni:

| Rail  | Tensione | Uso Corrente                                                                        | Percentuale del Totale |
|-------|----------|-------------------------------------------------------------------------------------|------------------------|
| +12V  | 12 volt  | CPU (tramite VRM), GPU, ventole, motori hard disk, praticamente tutto               | 90-99%                 |
| +5V   | 5 volt   | Elettronica di controllo dischi SATA, porte USB, alcuni circuiti della scheda madre | Pochi watt             |
| +3.3V | 3.3 volt | Slot DIMM (tramite regolatori), slot M.2 e PCIe (parzialmente),                     | Pochi watt             |

|       |                |                                                                                           |              |
|-------|----------------|-------------------------------------------------------------------------------------------|--------------|
|       |                | logiche varie                                                                             |              |
| +5VSB | 5 volt standby | Mantiene il sistema "vivo" a PC spento: Wake-on-LAN, pulsante di accensione, ricarica USB | 1-3 A        |
| -12V  | -12 volt       | Retaggio storico delle porte seriali RS-232. Praticamente inutilizzato oggi               | 0.3 A o meno |

La domanda naturale è: perché 12V domina in modo così schiacciante? La risposta sta nella legge di Ohm e nella potenza. La potenza è la tensione moltiplicata per la corrente ( $P = V \times I$ ); a parità di potenza, maggiore è la tensione, minore è la corrente. Ed è la corrente che costa: le perdite in un conduttore sono proporzionali al *quadrato* della corrente ( $P_{\text{persa}} = R \times I^2$ ). Trasportare 600 watt a 12 volt richiede 50 ampere; trasportarli a 5 volt ne richiederebbe 120, con perdite quasi sei volte maggiori e cavi molto più spessi. 12 volt è il compromesso storico tra "abbastanza alto da limitare la corrente" e "abbastanza basso da rimanere in tensione di sicurezza extra-bassa".

C'è, tuttavia, una seconda ragione, più moderna e più importante. Nessun componente del PC utilizza effettivamente 12 volt come tali. La CPU oggi opera a circa 1.0-1.3 volt; la GPU è nello stesso intervallo; la memoria DDR5 opera a 1.1 volt. Quei 12 volt vengono ulteriormente convertiti *in loco* dai **VRM** (*Voltage Regulator Modules*, i moduli di regolazione della tensione di cui abbiamo parlato ampiamente nel capitolo della scheda madre) presenti sulla scheda madre e sulla scheda grafica. Il VRM è un convertitore DC-DC multifase che prende l'ingresso a 12 volt e lo riduce alla tensione richiesta dal chip, con una precisione e una velocità di risposta che nessun cavo lungo mezzo metro potrebbe garantire. In altre parole: l'alimentatore non alimenta la CPU. L'alimentatore alimenta il VRM, che alimenta la CPU. L'alimentatore fornisce potenza "grezza" a 12 volt il più vicino possibile al punto di utilizzo, e la conversione fine avviene lì.

Questa architettura ha una conseguenza pratica su come gli alimentatori sono costruiti internamente. Negli alimentatori più vecchi, progettati negli anni 2000, le tre tensioni principali erano tutte generate dal trasformatore con avvolgimenti

separati e "regolate in gruppo" (**group regulation**): il circuito di controllo guardava una media ponderata di 12V e 5V e cercava di mantenerla entro i limiti. Il difetto è evidente: se il carico è fortemente sbilanciato — e nel 2026 lo è sempre, perché i 12V assorbono il 95% della potenza mentre i 5V e i 3.3V sono quasi scarichi — le tensioni divergono. I 12V tendono a scendere sotto carico, i 3.3V tendono a salire, e in casi patologici, escono dalla tolleranza ATX  $\pm 5\%$ . La soluzione moderna, adottata da qualsiasi alimentatore decente, è **DC-DC**: il trasformatore genera *solo* 12 volt, e i 5V e i 3.3V sono derivati da essi tramite piccoli convertitori buck posti su schede dedicate. Il risultato è una regolazione della tensione che rimane entro l'1-2% in qualsiasi condizione di carico. Se leggete in una recensione tecnica che un alimentatore "utilizza una piattaforma group-regulated", state leggendo — nel 2026 — che si tratta di un design obsoleto, quasi sempre appartenente alla fascia di prezzo più bassa.

Un ultimo concetto: **single rail** contro **multi rail**. Alcuni alimentatori dividono virtualmente il loro 12V in diverse "rail" separate, ognuna con la propria protezione da sovracorrente. Queste non sono quasi mai rail fisicamente distinte (c'è un solo trasformatore): si tratta di una suddivisione fatta a valle, con sensori di corrente separati sui vari gruppi di cavi. Il vantaggio teorico è la sicurezza: se un cavo va in corto, la protezione per quel singolo ramo scatta a una soglia bassa, invece di aspettare che l'intero alimentatore raggiunga la sua soglia globale. Lo svantaggio è che con schede grafiche molto esigenti in termini di potenza, c'è il rischio di far scattare la protezione di una singola rail pur rimanendo all'interno della potenza totale. In pratica: entrambe le architetture sono valide se ben implementate, un single rail ben protetto va perfettamente bene per un PC casalingo, e questa è una discussione che negli anni 2010 ha consumato molta più energia nei forum che nei casi reali.

### 1.3 Perché è il componente su cui **NON** si risparmia

Arriviamo al punto che rende l'intero capitolo degno di nota. Un alimentatore scadente non è "un alimentatore leggermente peggiore". È un dispositivo che può fallire in modi qualitativamente diversi da qualsiasi altro componente.

Il primo rischio è l'eccessivo **ripple**. Il ripple è la tensione AC residua che rimane sull'uscita DC: invece di essere una linea piatta a 12 volt, la tensione oscilla continuamente sopra e sotto quel valore. Lo standard ATX impone che il ripple non superi i 120 millivolt picco-picco sulla rail da 12V e 50 mV sulle rail da 5V e 3.3V. Un buon alimentatore rimane ben al di sotto di questo — 20-40 mV sui 12V e

tipico per un prodotto di fascia alta. Un alimentatore scadente può raggiungere 150-200 mV o più, specialmente sotto carico pesante. Le conseguenze non sono né immediate né spettacolari: il PC funziona, ma i VRM sulla scheda madre e sulla scheda grafica ricevono una tensione "sporca", devono lavorare di più per pulirla, i condensatori a valle si scaldano e invecchiano più rapidamente, e in casi estremi si verificano instabilità apparentemente inspiegabili — crash sotto carico, errori di memoria, riavvii casuali — che l'utente passa mesi ad attribuire alla RAM, ai driver video o a Windows. Il ripple è un killer lento e silenzioso, e non compare in nessuna specifica pubblicizzata.

Il secondo rischio è la **regolazione fuori tolleranza**. Se sotto carico transitorio i 12V scendono a 11.2 volt, il VRM della scheda grafica può andare in modalità di protezione o il sistema potrebbe semplicemente spegnersi. Il sintomo classico — "il PC si riavvia solo quando gioco" — è, nella stragrande maggioranza dei casi, un alimentatore inadeguato, non una GPU difettosa.

Il terzo rischio è catastrofico: la **mancaanza di protezioni funzionali**. Un alimentatore ben progettato ha una serie di circuiti di monitoraggio (che esamineremo in dettaglio nella sezione 6) che, in caso di anomalia, spengono tutto in millisecondi. Un alimentatore economico spesso ha queste protezioni solo sulla carta: il circuito integrato di supervisione potrebbe essere un modello che le supporta, ma i componenti passivi che le abilitano non sono stati installati per risparmiare pochi centesimi. In quel caso, un guasto interno può inviare tensioni errate ai componenti — 12 volt sulla linea da 5V, per esempio — portando alla distruzione istantanea e irreversibile di tutto ciò che è collegato. Questo non è un rischio teorico: i laboratori indipendenti che testano alimentatori economici distruggendoli deliberatamente producono regolarmente questo tipo di risultato, e nel mondo reale, ci sono infinite discussioni di utenti che hanno perso la scheda madre, la CPU e le unità a causa di un PSU da trenta euro acquistato su un marketplace.

Il quarto rischio è il più banale e il più concreto: l'**incendio**. Un alimentatore funziona con un ingresso di 230 volt, con condensatori caricati a 400 volt, e dissipa decine di watt sotto forma di calore. I componenti che separano il primario dal secondario, i filtri, i fusibili e le distanze di isolamento sulla scheda a circuito stampato sono elementi di sicurezza. Negli alimentatori privi di certificazioni reali — e un marchio CE apposto unilateralmente da un produttore asiatico non è una certificazione, è un'autodichiarazione — questi elementi sono i primi a fallire.

Infine, c'è una considerazione economica che dovrebbe convincere anche coloro che non sono influenzati dagli argomenti tecnici. L'alimentatore è il componente con la vita utile più lunga nell'intero sistema. Una CPU

Un numero illustra il punto. Una scheda con un TBP di 350 watt può mostrare picchi di 600-700 watt su una finestra di misurazione di un decimo di millisecondo. Nessuno strumento domestico li vede: un misuratore da presa aggiorna la sua lettura una o due volte al secondo, e su quella scala, il picco è invisibile, completamente perso nella media. Ma l'alimentatore lo vede assolutamente, e — cosa cruciale — anche il suo circuito di protezione da sovracorrente lo vede. Se l'**OCP** (*Over Current Protection*) è impostato troppo strettamente e la sua risposta è veloce, l'alimentatore interpreta il picco come un guasto e si spegne. Questo ha portato al fenomeno, diventato famoso con le schede NVIDIA RTX serie 30 nel 2020-2021 **[dati volatili]**, di alimentatori da 750 watt perfettamente onesti che spegnevano PC con schede il cui consumo medio era ben al di sotto di quella soglia.

Questo è precisamente il problema che lo standard ATX 3.0 (sezione 5) è stato creato per risolvere. Ed è per questo che la regola pratica corretta è: **prendere il consumo di picco realistico calcolato in precedenza e aggiungere un margine del 30-40%**. Non perché il sistema consumi effettivamente il 40% in più, ma perché quel margine assorbe i transitori senza far scattare le protezioni, e perché posiziona il punto di funzionamento tipico dell'alimentatore nella zona in cui è più efficiente e silenzioso.

### 2.3 Tabelle Indicative e Calcolatori

I calcolatori online — quelli seri, come il calcolatore di be quiet!, di Seasonic, o il classico di Cooler Master **[dato volatile: gli strumenti cambiano URL e vengono dismessi]** — sono utili per un riscontro, non come oracolo. Vanno usati con la consapevolezza che tendono a essere conservativi (il produttore ha interesse a vendervi un alimentatore più grande) e che spesso si basano sui TDP nominali piuttosto che sul consumo effettivo. Il calcolatore di OuterVision è storicamente il più dettagliato perché permette di specificare overclock e carichi personalizzati.

La seguente tabella offre un punto di partenza per configurazioni tipiche nel 2025-2026. I valori di TBP per le schede sono quelli dichiarati al lancio del prodotto e andrebbero verificati **[dato volatile: la gamma delle schede video cambia ogni 18-24 mesi]**.



| Tipo di Configurazione                    | GPU (TBP Indicativo) | CPU (Picco) | Picco Stimato Sistema | PSU Raccomandato              |
|-------------------------------------------|----------------------|-------------|-----------------------|-------------------------------|
| Ufficio / HTPC, grafica integrata         | —                    | 65-90 W     | ~150 W                | 400-450 W                     |
| Gaming entry (es. RTX 5060 / RX 9060 XT)  | ~150-180 W           | ~120 W      | ~350 W                | 550-600 W                     |
| Gaming medio (es. RTX 5070 / RX 9070)     | ~250 W               | ~150 W      | ~450 W                | 650-750 W                     |
| Medio-alto (es. RTX 5070 Ti / RX 9070 XT) | ~300 W               | ~180 W      | ~530 W                | 750-850 W                     |
| Fascia alta (es. RTX 5080)                | ~360 W               | ~200 W      | ~600 W                | 850-1000 W                    |
| Enthusiast (es. RTX 5090)                 | ~575 W               | ~250 W      | ~900 W                | 1000-1200 W                   |
| Workstation / dual GPU                    | 2× 300-575 W         | 250-350 W   | 1200-1600 W           | 1600 W+ (e verifica impianto) |

Riguardo all'ultima riga, una nota specifica per chi vive in Italia: il contratto residenziale standard prevede 3 kW di potenza impegnata, con una tolleranza fino a circa 3,3 kW prima che scatti il limitatore. Un sistema con due schede video di fascia alta, a pieno carico, può avvicinarsi pericolosamente a metà di quel budget da solo, e va considerato assieme a tutto il resto della casa. Non è un problema per il 99% delle configurazioni, ma è un vincolo reale per chi costruisce macchine da inferenza o rendering.

## 2.4 Sovradimensionamento: pro e contro

Il principale **pro** è l'efficienza. La curva di efficienza di un alimentatore non è piatta: è bassa a carichi molto leggeri (sotto il 10-15%), sale rapidamente, raggiunge il picco attorno al 40-60% del carico nominale, e scende leggermente man mano che si avvicina al 100%. Dimensionare l'alimentatore in modo che il consumo tipico del sistema — non il picco, ma il consumo *tipico*, cioè quello che si

ha giocando o lavorando — cada in quella finestra centrale significa operare nel punto di massima efficienza.

Il secondo pro è la rumorosità, ed è quello che si nota di più nella pratica quotidiana. Praticamente tutti gli alimentatori decenti oggi hanno una modalità **zero-RPM** o semi-passiva: sotto una certa soglia di carico (tipicamente il 30-40%), la ventola rimane spenta, e l'alimentatore si raffredda per convezione. Un alimentatore da 850 W in un sistema che tipicamente assorbe 300 W sarà assolutamente silenzioso per la maggior parte del tempo. Lo stesso sistema con un alimentatore da 550 W avrà la ventola costantemente in funzione.

Il terzo pro è la longevità: un alimentatore che opera costantemente al 90% del suo carico nominale lavora con condensatori più caldi, e la vita di un condensatore elettrolitico si dimezza circa per ogni 10 °C di aumento della temperatura. Il quarto è la possibilità di aggiornare la scheda grafica fra tre anni senza dover cambiare anche l'alimentatore.

Ci sono due **contro**. Il primo è ovvio: il costo. Il secondo è il calo di efficienza a carichi molto bassi. Un sistema che consuma 60 watt in idle, alimentato da un'unità da 1200 W, sta operando al 5% del carico, ben al di sotto del punto in cui la certificazione 80 PLUS misura qualcosa. Le unità moderne di alta qualità si comportano comunque bene lì — questo è precisamente ciò che misura la certificazione Cybenetics, come vedremo — ma le unità economiche vacillano. Il consiglio pratico è di non esagerare: installare un'unità da 1000 W su un sistema che consuma 300 W di picco non porta benefici, costa di più e non migliora nulla. Il punto ottimale è come descritto sopra: picco realistico + 30-40%.

---

### 3. La Certificazione 80 PLUS

#### 3.1 Cosa misura realmente (e cosa no)

**80 PLUS** è un programma di certificazione volontario, nato nel 2004 negli Stati Uniti, che misura **una sola cosa**: l'efficienza della conversione da AC a DC, espressa come rapporto tra la potenza erogata in uscita e la potenza prelevata dalla presa a muro. Un alimentatore che eroga 500 watt al PC prelevandone 555 dalla presa ha un'efficienza del 90%: i 55 watt di differenza sono stati convertiti in calore all'interno del case.

È fondamentale capire cosa 80 PLUS **non** misura, perché la confusione su questo punto è la fonte della maggior parte degli acquisti errati:

Non misura il ripple. Non misura la regolazione della tensione. Non misura la risposta ai transitori. Non misura la presenza o la calibrazione delle protezioni. Non misura la qualità dei condensatori. Non misura la rumorosità della ventola. Non misura l'*hold-up time* (il tempo, minimo 17 millisecondi secondo lo standard ATX, per cui l'alimentatore deve continuare a erogare tensioni valide dopo un'interruzione di corrente, per dare tempo al sistema di gestire uno spegnimento ordinato). Non misura la durata.

Un'etichetta 80 PLUS Gold certifica che l'alimentatore è efficiente. Non dice assolutamente nulla sul fatto che sia *buono*. Questi sono due assi ortogonali, e sul mercato ci sono alimentatori Gold mal costruiti e alimentatori Bronze molto ben costruiti. Ci torneremo tra un attimo.

Va aggiunta una nota storica per aiutare a calibrare la fiducia: per anni, il programma è stato gestito da un'organizzazione (Clearesult/Ecova) che testava un solo campione fornito dal produttore, senza controlli a campione sulla produzione di serie. Vari test indipendenti hanno trovato prodotti sul mercato che non raggiungevano l'efficienza dichiarata sulle loro etichette. Non è un programma fraudolento, ma è un programma con capacità di controllo limitate.

### 3.2 Livelli e Percentuali

Le soglie di efficienza sono definite a tre (o quattro) punti di carico. Un punto molto importante, quasi sempre ignorato: **le soglie variano a seconda della tensione di rete**. La tabella "americana" a 115 volt, quella che circola nei forum, non è quella che si applica in Italia. Noi operiamo a 230 volt, e per la stessa potenza in uscita, la corrente in ingresso è la metà, quindi le perdite sono minori e i requisiti sono più stringenti. La tabella corretta per l'Europa è quella "230V EU internal".

#### Efficienza Minima Richiesta — 230V EU (la tabella che conta in Italia)

| Livello         | Carico 10% | Carico 20% | Carico 50% | Carico 100% |
|-----------------|------------|------------|------------|-------------|
| 80 PLUS (White) | —          | 82%        | 85%        | 82%         |
| 80 PLUS Bronze  | —          | 85%        | 88%        | 85%         |
| 80 PLUS         | —          | 87%        | 90%        | 87%         |

|                  |     |     |     |     |
|------------------|-----|-----|-----|-----|
| Silver           |     |     |     |     |
| 80 PLUS Gold     | —   | 90% | 92% | 89% |
| 80 PLUS Platinum | —   | 92% | 94% | 90% |
| 80 PLUS Titanium | 90% | 94% | 96% | 91% |

**Efficienza minima richiesta — 115V (per confronto, non applicabile alla rete italiana)**

| Livello         | 10% | 20% | 50% | 100% |
|-----------------|-----|-----|-----|------|
| 80 PLUS (White) | —   | 80% | 80% | 80%  |
| Bronze          | —   | 82% | 85% | 82%  |
| Silver          | —   | 85% | 88% | 85%  |
| Gold            | —   | 87% | 90% | 87%  |
| Platinum        | —   | 90% | 92% | 89%  |
| Titanium        | 90% | 92% | 94% | 90%  |

Si noti che Titanium è l'unico livello che impone un requisito al 10% di carico. Questa è una scelta significativa: riconosce che un PC moderno trascorre la maggior parte della sua vita in idle o quasi idle, e che l'efficienza a basso carico ha un impatto reale sulle bollette elettriche e sul calore.

Quanto vale, in termini monetari, salire di livello? Facciamo un calcolo onesto. Supponiamo un PC che consuma in media 300 watt in uscita, usato quattro ore al giorno per 365 giorni. Con un alimentatore Bronze all'88% di efficienza, assorbe 341 W dalla presa; con un Gold al 92%, assorbe 326 W. La differenza è di 15 watt, per 1460 ore all'anno, che sono circa 22 kWh. A un prezzo dell'energia di 0,25 €/kWh **[dato volatile]**, stiamo parlando di circa 5,50 euro all'anno. Il sovrapprezzo di un Gold rispetto a un Bronze si ripaga in tre o quattro anni, non in sei mesi. La conclusione corretta non è "il Gold non vale la pena": è che **non si compra un Gold per l'efficienza in sé**, lo si compra perché i Gold e i livelli superiori concentrano i migliori progetti, con componenti migliori e garanzie più lunghe. L'efficienza è un indicatore correlato alla qualità, non la ragione d'acquisto.

### 3.3 Cybenetics: La Certificazione che Misura Ciò che Conta

**Cybenetics** è un ente di certificazione indipendente, fondato da Aris Mpitziopoulos (uno dei più rigorosi revisori tecnici del settore), creato proprio per colmare le lacune di 80 PLUS. Rilascia due distinte certificazioni.

La prima è **ETA**, che misura l'efficienza. La differenza metodologica rispetto a 80 PLUS è sostanziale: invece di misurare in tre punti fissi, Cybenetics calcola una **media ponderata sull'intero intervallo di carico**, dal 10% al 100%, includendo esplicitamente i carichi leggeri; misura anche l'efficienza del rail di standby a 5 volt e il consumo di "potenza vampiro" (cioè, con il PC spento ma l'alimentatore collegato alla rete). I livelli vanno da ETA-A+++ (il più alto) a scendere attraverso A++, A+, A, B, C, D, E. Un'unità Cybenetics ETA-A corrisponde all'incirca a un 80 PLUS Gold/Platinum, ma i dati sono molto più rappresentativi del comportamento nel mondo reale.

La seconda, e per molti utenti la più preziosa, è **LAMBDA**: misura il **rumore** in una camera anecoica sull'intero intervallo di carico, con livelli che vanno da LAMBDA-A++ (media inferiore a 15 dB(A), il che significa un alimentatore praticamente inudibile) fino a LAMBDA-E. È l'unica certificazione al mondo che quantifica il rumore dell'alimentatore con un metodo ripetibile, e per chi costruisce un PC silenzioso, vale più di qualsiasi altro dato.

Cybenetics pubblica anche **rapporti di prova completi** sul proprio sito web: ripple, regolazione della tensione, risposta ai transitori, tempo di hold-up, efficienza a ogni carico e verifica delle protezioni. Si tratta di documenti PDF gratuiti, lunghi venti o trenta pagine, che ti dicono tutto ciò che c'è da sapere su un alimentatore. Consultare il database Cybenetics prima di un acquisto è, oggi, l'azione più utile che un acquirente possa intraprendere.

### 3.4 Perché un Gold scadente può essere peggio di un Bronze eccellente

Ora possiamo chiudere il cerchio con un esempio concreto e illustrativo. Immaginiamo due alimentatori da 650 watt.

Il primo è un Gold di un marchio meno conosciuto, costruito da un OEM di terzo livello. Raggiunge il 90% di efficienza — lo ha fatto usando componenti a basso costo ma con una topologia efficiente, il che è perfettamente possibile — ma ha condensatori cinesi da 85 °C sul secondario, un ripple di 90 mV sul 12V (entro le specifiche ATX, ma al limite), una protezione OCP mal calibrata che interviene sui

transitori della GPU, una ventola con cuscinetto a manicotto rumorosa senza modalità zero-RPM e una garanzia di tre anni.

Il secondo è un Bronze di Seasonic o be quiet!, costruito su una piattaforma matura. Raggiunge l'88% di efficienza. Ha condensatori giapponesi da 105 °C, un ripple di 30 mV, protezioni correttamente calibrate e verificate, una ventola FDB con zero-RPM e una garanzia di cinque o sette anni.

Il secondo alimentatore è, per ogni metrica che conta — stabilità, silenziosità, longevità, sicurezza — un prodotto migliore. Consuma 15 watt in più a 650. La lezione, ripetuta perché è la più importante del capitolo: **80 PLUS è un filtro grossolano, non un criterio di selezione.** Serve a escludere la spazzatura (non comprare mai sotto il Bronze, e praticamente mai sotto il Gold nel 2026 perché non c'è motivo), non a scegliere tra due candidati.

---

## 4. Modularità

### 4.1 Tre architetture

**Non modulare:** Tutti i cavi escono dall'alimentatore, saldati o crimpati in modo permanente. Sono tutti lì, sempre, inclusi i quattro connettori SATA che non userai mai e i due connettori Molex che nessuno usa dal 2012. Ciò che non viene utilizzato deve essere nascosto da qualche parte nel case — tipicamente in un vano per hard disk vuoto o dietro il pannello posteriore, dove ostruisce il flusso d'aria e complica l'assemblaggio. Il vantaggio è il costo: a parità di piattaforma, un PSU non modulare costa 10-20 euro in meno di uno completamente modulare, perché elimina i connettori, il PCB dei connettori e le resistenze di contatto associate. È una scelta ragionevole solo nella fascia di budget assoluto o in build dove la gestione dei cavi non è importante.

**Semi-modulare:** I cavi che sono *sempre* necessari, in qualsiasi configurazione — il cavo a 24 pin della scheda madre e il cavo EPS a 8 pin della CPU — sono fissi; tutto il resto (PCIe, SATA, Molex) è staccabile. Questo è un compromesso intelligente ed è la scelta dominante nella fascia media. Il risparmio rispetto al full modulare è modesto (5-15 euro), e lo svantaggio pratico è quasi nullo, tranne in casi molto piccoli dove anche instradare due cavi fissi della lunghezza sbagliata è un fastidio.

**Completamente modulare:** Ogni singolo cavo, incluso il 24-pin, è staccabile. I vantaggi sono tre. Il primo è la gestione dei cavi: si collegano solo i cavi necessari.

Il secondo, meno ovvio e molto apprezzato da chi ha costruito PC in case compatti, è che si può **installare l'alimentatore nudo nel case e poi collegare i cavi**, invece di dover infilare nel vano un blocco di metallo con un metro e mezzo di spaghetti penzolanti. Il terzo è la possibilità di usare cavi personalizzati o "sleeved", per ragioni estetiche o per avere lunghezze su misura.

#### 4.2 L'avvertimento più importante di questo capitolo: i cavi non sono intercambiabili

Questo andrebbe scritto in grassetto e letto due volte, perché è l'errore che distrugge più hardware legato all'alimentazione.

**I cavi modulari NON sono intercambiabili tra marche diverse, e spesso nemmeno tra modelli diversi dello stesso produttore.**

Le regole operative che ne conseguono sono tre, e non ammettono eccezioni. Primo: **usare solo i cavi forniti nella scatola dell'alimentatore che si sta usando**. Secondo: quando si sostituisce un alimentatore, **sostituire anche tutti i cavi**, anche quelli che "sembrano uguali" e anche se il nuovo alimentatore è della stessa marca del vecchio. Terzo: se si acquistano cavi di terze parti (CableMod, Corsair Premium Kit, e simili), **verificare che siano dichiarati compatibili con quello specifico modello**, e non con quella marca genericamente. I produttori seri di cavi custom hanno configuratori che chiedono il modello esatto dell'alimentatore proprio per questo.

Una nota su un ambito adiacente: nel 2023, CableMod ha dovuto ritirare dal mercato i suoi adattatori angolati per il connettore 12VHPWR, dopo un numero significativo di casi di surriscaldamento e fusione **[dato volatile: episodio storico, ma il principio resta]**. La morale non è che i cavi di terze parti siano sempre pericolosi, ma che non ci si improvvisa sul percorso delle alte correnti, e che un adattatore in più significa due contatti elettrici in più dove possono formarsi resistenze parassite.

---

## 5. Standard e Connettori

### 5.1 ATX 2.x versus ATX 3.0/3.1

Lo standard **ATX** (*Advanced Technology eXtended*), introdotto da Intel nel 1995, definisce, tra le altre cose, la "Power Supply Design Guide": il documento che stabilisce quali tensioni un alimentatore deve fornire, con quali tolleranze, con

quali connettori, e con quale comportamento in condizioni anomale. La revisione **ATX 2.x**, nelle sue varie sottovarianti, ha governato il mercato per quasi vent'anni.

La revisione **ATX 3.0**, pubblicata da Intel nel 2022, nasce da un problema ben preciso: i transistori delle moderne schede video di cui abbiamo discusso nella sezione 2.2. La novità centrale è che ATX 3.0 impone requisiti espliciti sulla capacità di sostenere **escursioni di potenza** ben oltre la potenza nominale per intervalli brevissimi, senza che intervengano le protezioni e senza che le tensioni vadano fuori tolleranza. In termini pratici, un alimentatore ATX 3.0 deve reggere escursioni fino a circa il **200% della sua potenza nominale** per durate nell'ordine dei 100 microsecondi, con requisiti scalari per durate più lunghe, e deve tollerare che una singola scheda video connessa al connettore 12 volt ad alta potenza richieda fino a **tre volte** la sua potenza nominale per un istante. È un requisito severo, che di fatto costringe il progettista a sovradimensionare i componenti di potenza e, soprattutto, a **tarare le protezioni con una risposta temporizzata** invece che istantanea: la protezione deve distinguere tra un picco legittimo di 80 microsecondi e un vero cortocircuito.

Il secondo grande contributo di ATX 3.0 è l'introduzione del connettore a 16 pin **12VHPWR** (*12 Volt High Power*), progettato per veicolare fino a 600 watt su un singolo cavo.

La revisione **ATX 3.1**, del 2024, non rivoluziona nulla ma corregge il problema che il 12VHPWR aveva rivelato sul campo. Sostituisce quel connettore con la variante **12V-2x6** (detta anche H++), rende obbligatorio che l'alimentatore sia in grado di erogare la potenza dichiarata attraverso di esso, e stringe alcuni requisiti sui transistori. Nel 2026, un nuovo alimentatore di fascia media o alta dovrebbe essere **ATX 3.1 [volatile data: lo standard evolve]**.

Il **12VHPWR / 12V-2x6** è il connettore a 16 pin: dodici pin di potenza (sei 12V e sei di massa) e quattro pin laterali di segnale, i **sense pin**. I sense pin sono la parte concettualmente interessante: due di essi (Sense0 e Sense1) formano un codice a due bit che l'alimentatore usa per comunicare alla scheda grafica **quanta potenza è autorizzata a prelevare** attraverso quel cavo — 150, 300, 450 o 600 watt. Una scheda che rileva un codice da 150 W limiterà di conseguenza il suo consumo. Il connettore, nella sua prima incarnazione 12VHPWR, ha avuto una storia travagliata: numerosi casi documentati di fusione dell'alloggiamento, prima con le RTX 4090 nel 2022-2023 e successivamente con le RTX 5090 nel 2025 **[volatile**



**data]**. Le cause individuate sono state essenzialmente due: inserzioni incomplete (il connettore non veniva spinto fino in fondo, i contatti toccavano solo parzialmente, la resistenza di contatto aumentava, il calore fondeva la plastica) e squilibri di corrente tra i sei conduttori da 12 volt, con un singolo filo costretto a portare corrente ben oltre la sua capacità. La revisione **12V-2x6** affronta la prima causa in modo elegante: **accorcia i sense pin e allunga i contatti di potenza**, in modo che se il connettore non è completamente inserito, i sense pin non fanno contatto, e la scheda — non ricevendo autorizzazione — si limita a pochi watt invece di tentare di prelevarne 600 attraverso contatti parziali. Non risolve la seconda causa, che è un problema di progettazione lato scheda grafica (bilanciamento delle correnti), ma è un sostanziale miglioramento della sicurezza.

La regola operativa per il 12V-2x6 è chiara: **usare il cavo di alimentazione nativo, inserirlo fino allo scatto, controllare che non ci siano spazi visibili tra il connettore e il corpo della scheda, non piegare bruscamente il cavo nei primi 3-4 centimetri dal connettore e non usare l'adattatore a quattro connettori PCIe incluso nella scatola della scheda grafica se si può evitare.**

Questi adattatori funzionano, ma introducono contatti aggiuntivi e sono la configurazione in cui si sono verificati la maggior parte degli incidenti.

I connettori di alimentazione **SATA** (15 pin, piatti, con l'inconfondibile forma a L) alimentano dischi meccanici e SSD da 2.5". Trasportano 12V, 5V e 3.3V. I connettori **Molex** a 4 pin sono un artefatto degli anni ottanta, sopravvissuti per alimentare vecchi accessori, hub per ventole e pompe: trasportano 12V e 5V, sono scomodi da inserire ed estrarre, e entro il 2026 il loro uso sarà residuale.

### 5.3 "PCIe Gen5 ready": cosa significa (e cosa non significa)

Questo è un termine di marketing, non uno standard formale, e deve essere decodificato. Sulle scatole degli alimentatori, di solito significa due cose insieme: che l'unità è conforme ad ATX 3.0 o 3.1 (gestendo quindi i transitori secondo le specifiche) e che ha almeno un **connettore 12V-2x6 nativo** cablato direttamente all'alimentatore, senza adattatori.

Ciò che *non* significa è altrettanto importante: non ha nulla a che fare con la versione dello slot PCI Express della scheda madre. Un alimentatore non "sa" se lo slot è Gen4 o Gen5 e non gli importa: fornisce 12 volt, punto. Il termine si riferisce al connettore di alimentazione (a volte impropriamente chiamato "connettore di alimentazione PCIe 5.0") e alla sua capacità di sostenere picchi di potenza. Un

alimentatore non "Gen5 ready" alimenterà perfettamente una scheda grafica PCIe 5.0 che utilizza connettori tradizionali a 8 pin.

---

## 6. Qualità Interna

### 6.1 Gli OEM: Chi costruisce davvero il tuo alimentatore

Questa è la sezione che separa l'acquirente informato da tutti gli altri, e il concetto da afferrare è che **la stragrande maggioranza dei marchi che vendono alimentatori non li produce**. Corsair non ha fabbriche di alimentatori. Nemmeno be quiet!, né NZXT, né Cooler Master, né MSI, né — con alcune sfumature — EVGA. Quello che fanno è progettare o commissionare un prodotto, definirne le specifiche, testarlo e apporvi il proprio marchio, mentre la progettazione elettronica dettagliata e la produzione fisica sono affidate a un **OEM** (*Original Equipment Manufacturer*).

Gli OEM significativi nel mercato consumer sono relativamente pochi. **Seasonic** è l'unico che è contemporaneamente un OEM di alto livello e un marchio che vende con il proprio nome; produce anche per altri (storicamente per NZXT, Antec e altri). **Super Flower** è taiwanese, ha un'ottima reputazione ed è la piattaforma dietro molte unità EVGA di fascia alta e il marchio Leadex. **CWT** (*Channel Well Technology*) è enorme e produce per Corsair e molti altri; la sua qualità dipende interamente dal livello della piattaforma, che va da molto buona a mediocre. **FSP** (*Fortron Source Power*) è un altro gigante, con un catalogo che va dall'economico all'eccellente, e produce anche con il proprio marchio. **HEC, Andyson, Sirfa/High Power, Solytech, Great Wall, Gspower, Enhance, Delta** completano il panorama con livelli di qualità molto diversi. Nella fascia bassa del mercato, produttori come **Sama** o vari OEM cinesi minori forniscono le piattaforme per prodotti senza marchio.

La conseguenza diretta e controintuitiva di questa struttura è la seguente: **lo stesso marchio può vendere contemporaneamente alimentatori eccellenti e alimentatori pessimi**, perché prodotti da OEM diversi su piattaforme diverse. La serie di fascia alta di un marchio potrebbe essere costruita da Seasonic, e la serie economica dello stesso marchio da un OEM di terz'ordine, con la stessa etichetta e lo stesso logo. **Comprare "un Corsair" o "un Cooler Master" non significa nulla. Bisogna comprare un modello specifico.**

Questo, incidentalmente, è esattamente il motivo per cui esistono e sono così utili le *community tier list* (sezione 7.2): esse elencano i *modelli*, non i marchi.

## 6.2 Protezioni

Un alimentatore ben progettato include un circuito supervisore integrato che monitora continuamente le uscite e interviene spegnendo tutto in caso di anomalia. Le protezioni che devono essere presenti — e la cui presenza è dichiarata nelle specifiche tecniche, ma la cui *corretta calibrazione* è verificata solo in test indipendenti — sono le seguenti.

**OVP** (*Over Voltage Protection*) interviene se una tensione di uscita sale al di sopra di una soglia preimpostata (tipicamente intorno ai 13.5-14 volt sul rail da 12V). Questa protezione salva letteralmente il computer: senza di essa, un guasto nel circuito di regolazione può inviare tensioni distruttive ai componenti.

**UVP** (*Under Voltage Protection*) fa l'opposto: spegne l'alimentatore se una tensione scende al di sotto di una soglia (intorno ai 10-10.5 volt sui 12V). Questo impedisce ai componenti di operare in condizioni di *brownout*, che possono causare corruzione dei dati sui drive.

**OCP** (*Over Current Protection*) monitora la corrente erogata su ogni rail (o su ogni rail virtuale, negli alimentatori multi-rail) e interviene se supera la soglia. È la protezione più delicata da calibrare, per i motivi visti riguardo ai transistori: troppo stretta e l'alimentatore spegne il PC ogni volta che la scheda video ha un picco, troppo lasca e non protegge.

**OPP** (*Over Power Protection*) guarda la potenza *totale* erogata, non la corrente di un singolo rail, e interviene se il sistema richiede più di quanto l'alimentatore possa fornire. È la rete di sicurezza globale.

**SCP** (*Short Circuit Protection*) è la più fondamentale: rileva un cortocircuito netto tra un rail e la massa e spegne immediatamente. Deve essere sempre presente, senza eccezioni.

**OTP** (*Over Temperature Protection*) usa un sensore interno, solitamente sul dissipatore secondario, e spegne l'alimentatore se la temperatura interna supera una soglia critica. È l'unica protezione che spesso *manca* anche in unità altrimenti decenti, ed è quella che conta di più se l'alimentatore è montato con la ventola verso il basso in un case con poco spazio, o se una ventola si guasta.

Infine, ci sono protezioni "ancillari" ma non banali: **SIP** (*Surge and Inrush Protection*) protegge contro i picchi di corrente all'avvio e i transitori di rete, e **NLO** (*No Load Operation*) permette all'alimentatore di funzionare in sicurezza senza un carico collegato, utile durante i test.

Il punto pratico: quasi tutti i datasheet dichiarano tutte queste sigle. La dichiarazione non costa nulla. Quello che conta è che siano *implementate e calibrate*, e questo si può scoprire solo leggendo un test indipendente (Cybenetics, HWBusters, TechPowerUp, Tom's Hardware) dove il recensore cerca deliberatamente di attivarle.

### 6.3 Condensatori, ventole, materiali

I **condensatori**, assieme alla ventola, sono l'elemento che invecchia. Il condensatore elettrolitico primario (quello grande, sui 400 V) e i condensatori secondari lavorano in ambiente caldo e devono mantenere la propria capacità per anni. Il discriminante classico è la provenienza: i condensatori giapponesi — i marchi da cercare nelle recensioni sono **Nippon Chemi-Con**, **Rubycon**, **Nichicon**, **Panasonic** — hanno tolleranze migliori, minore resistenza serie equivalente e, soprattutto, una vita utile dichiarata molto più lunga rispetto ai condensatori taiwanesi o cinesi di fascia bassa (Teapo, CapXon, Elite, Su'scon). L'altro parametro è la **temperatura nominale**: i condensatori da 105 °C sono lo standard di qualità, mentre quelli da 85 °C sono un segno di risparmio. Nel secondario, gli alimentatori moderni di qualità usano diffusamente i **condensatori a polimeri solidi**, che non hanno elettrolita liquido, non si seccano e tollerano meglio il calore.

La **ventola** merita attenzione perché è il componente che si sente. Il tipo di cuscinetto determina rumorosità e durata: un **cuscinetto a manicotto** (sleeve bearing) è il più economico, diventa più rumoroso con l'età e ha vita ridotta se montato in orizzontale; un **rifle bearing** è un miglioramento dello sleeve bearing, ed è migliore; un **ball bearing** dura a lungo ma è più rumoroso; un **FDB** (Fluid Dynamic Bearing) è ormai lo standard di qualità: silenzioso, con vita utile dichiarata di decine di migliaia di ore e insensibile all'orientamento di montaggio. Le ventole a **levitazione magnetica** (maglev) sono un'ulteriore evoluzione, presente nel segmento premium.

Merita una menzione la **modalità Zero-RPM** (o semi-fanless, o "hybrid mode"). Si tratta della funzione per cui la ventola rimane completamente ferma sotto una certa soglia di carico e di temperatura. Il vantaggio è ovvio: un alimentatore che

non gira è un alimentatore che non fa rumore e non aspira polvere. Lo svantaggio potenziale è che, rimanendo fermo a lungo, l'alimentatore accumula calore, e quando la ventola si accende si può percepire un fastidioso ciclo on/off se l'isteresi è mal progettata. Le unità di qualità gestiscono questo con un'ampia isteresi. Molti alimentatori hanno un interruttore fisico sul retro per disabilitare la modalità zero-RPM: se il vostro alimentatore opera in un case caldo o vicino al suo limite, disabilitarla è una scelta prudente.

#### 6.4 La garanzia come indicatore

Ecco un criterio semplice e quantitativo, che non richiede di leggere una sola recensione tecnica: **la lunghezza della garanzia è il miglior indicatore singolo della fiducia del produttore nel proprio prodotto**. Un produttore che offre dieci o dodici anni sta dichiarando, con un impegno contrattuale che gli costa soldi veri, che si aspetta che quell'unità funzioni per un decennio. Nessuno regala dodici anni di garanzia su un prodotto costruito con condensatori scadenti.

| Garanzia | Cosa suggerisce                                   | Range tipico                       |
|----------|---------------------------------------------------|------------------------------------|
| 2-3 anni | Prodotto economico, componenti basilari           | Entry / da evitare per build serie |
| 5 anni   | Prodotto decente, fascia media                    | Mid, accettabile                   |
| 7 anni   | Buon prodotto, componenti di qualità              | Mid-high                           |
| 10 anni  | Prodotto di alta qualità, condensatori giapponesi | High-end                           |
| 12 anni  | Top del mercato consumer                          | Flagship                           |

Prestate attenzione a un dettaglio non banale: in Italia e in Europa vige una garanzia legale di conformità di due anni verso il venditore, che è diversa dalla **garanzia commerciale del produttore**. Quest'ultima è quella che conta qui, ed è offerta direttamente dal produttore, spesso richiedendo la registrazione del prodotto. Conservate la fattura e, se il produttore lo richiede, registrate l'alimentatore al momento dell'acquisto.

---

## 7. Marche e linee di riferimento

Questa sezione va letta con una avvertenza: **le gamme dei produttori cambiano ogni 18-24 mesi**, e un modello eccellente può essere rimpiazzato da un successore

costruito da un OEM diverso e di qualità inferiore, pur mantenendo lo stesso nome commerciale. Quanto segue è quindi una mappa delle *tendenze storiche* e della *reputazione delle linee*, non un listino prezzi. **[dato volatile: verificare sempre il modello esatto su una tier list aggiornata prima dell'acquisto]**

### 7.1 Marche principali

**Seasonic** è il punto di riferimento assoluto per reputazione, essendo sia OEM che brand. La linea **Prime** (nelle varianti Gold, Platinum, Titanium, e più recentemente le versioni PX/TX con connettore 12V-2x6) rappresenta l'apice del mercato consumer, con dodici anni di garanzia. La linea **Focus** (GX, PX) è la fascia medio-alta, offrendo un eccellente rapporto qualità/prezzo, con dieci anni di garanzia. Le linee più economiche di Seasonic (Core, S12) sono più ordinarie e non godono della stessa reputazione: anche con Seasonic, il nome sulla scatola non basta.

**Corsair** ha una gamma ampia e stratificata, ed è l'esempio perfetto del perché sia necessario guardare il modello. La linea **CX** è la fascia economica, storicamente costruita da CWT su piattaforme basilari: accettabile ma non entusiasmante, con garanzia più breve. La linea **RM**, e soprattutto **RMx**, è il cuore della loro offerta: unità Gold, silenziose, ben costruite, con dieci anni di garanzia; sono tra le più frequentemente consigliate per un build di fascia media-alta. Le linee **HX** e **HXi** sono un gradino superiore (Platinum, monitoraggio digitale nella variante "i"), e **AX/AXi** rappresenta l'apice (Titanium). La linea **SF** copre il formato SFX per case compatti ed è considerata eccellente.

**be quiet!** è un marchio tedesco che, come suggerisce il nome, si concentra sul silenzio. La linea **Pure Power** è l'entry-mid: onesta, funzionale, senza fuochi d'artificio. La linea **Straight Power** è la fascia medio-alta ed è molto apprezzata. Le linee **Dark Power** e **Dark Power Pro** sono il top di gamma: prestazioni eccellenti, silenzio quasi assoluto, prezzo elevato. La forza trasversale del marchio risiede nelle ventole, che sono di produzione propria e tra le migliori del settore.

**EVGA** ha una storia peculiare: le sue unità di fascia alta, costruite su piattaforme Super Flower (le serie **G**, **P**, **T**, e in particolare le SuperNOVA G2/G3/G5/G6/G7 e P2/T2), sono state per anni tra le più consigliate. Le sue unità economiche (serie **N1**, **W1**, **BQ**, **BR**) erano costruite da OEM di livello inferiore e vanno dal mediocre al decisamente da evitare. Va notato che EVGA ha annunciato l'uscita dal mercato delle schede grafiche nel 2022 e ha progressivamente ridotto la sua presenza sul

mercato **[dato volatile: verificare la disponibilità attuale dei prodotti e il supporto post-vendita]**.

**Cooler Master** è un brand con una gamma molto eterogenea. La linea **V** (V Gold, V Platinum, V SFX) è di ottima qualità. Le linee **MWE** sono entry-level, e la loro qualità è variata significativamente tra le revisioni: alcune sono accettabili, altre no. Questo è un caso da manuale in cui il nome della serie non basta, e va conosciuta la revisione esatta.

Anche **Thermaltake** ha una gamma altrettanto eterogenea. La linea di fascia medio-alta **Toughpower GF/PF/GT** è generalmente buona; le linee economiche (Smart, Litepower) sono da evitare per qualsiasi sistema con una scheda grafica seria.

**NZXT** ha adottato negli anni un approccio semplice: la serie **C** (C750, C850, C1000 Gold e Platinum) è costruita su piattaforme Seasonic e gode di un'ottima reputazione. È un esempio di brand che, non avendo una fascia economica di ripiego, ha una qualità costantemente omogenea.

**MSI** è entrata nel mercato degli alimentatori relativamente tardi. La linea **MPG A-GF** (e quelle successive) è di buona qualità. Alcune linee economiche **MAG** hanno ricevuto in passato recensioni molto critiche, con casi di unità che fallivano i test di sicurezza **[volatile data]**. È un altro brand che va valutato modello per modello.

Ci sono poi brand che hanno guadagnato terreno di recente nel mercato di fascia alta, come **ASUS** con le linee ROG Thor e Loki, **Super Flower** che vende anche con il proprio marchio (Leadex), **XPG/ADATA**, **Lian Li**, **Phanteks**, **FSP** con il proprio marchio, e **Antec** (la cui linea Signature è molto apprezzata). E dall'altra parte, c'è l'intero universo di marchi che non andrebbero nemmeno presi in considerazione: le unità da 30-40 euro con wattaggi fantasiosi stampati sulla scatola, vendute sui marketplace generici, spesso con nomi che cambiano ogni sei mesi. Il criterio è brutale ma efficace: **se non riuscite a trovare una singola recensione tecnica indipendente di quel modello, non compratelo.**

## 7.2 Tier List della Community

Dato che nessun acquirente può leggere una recensione tecnica per ognuno dei trecento modelli in commercio, la community ha prodotto uno strumento eccezionalmente utile: le **PSU tier list**. Storicamente, la più nota è quella mantenuta dal **Cultists Network** (la successora della vecchia tier list di



LinusTechTips, che è stata ritirata) **[volatile data: le tier list cambiano manutentori e posizioni nel tempo; cercate la versione attuale]**.

Il funzionamento è semplice: gli alimentatori vengono catalogati per modello esatto e wattaggio, e assegnati a un tier (Tier A, B, C, D... o schemi simili) in base ai test indipendenti disponibili, ai dati di reso in garanzia e alla piattaforma OEM. La regola pratica è: **per un sistema con scheda grafica dedicata, non scendere sotto i tier medio-alti; per un sistema con scheda di fascia alta, rimanere nei tier più alti**. Le liste indicano anche esplicitamente i modelli pericolosi, quelli da non comprare a nessun prezzo.

Altre risorse da conoscere sono il **database Cybenetics** (che offre i report completi menzionati), le recensioni di **HWBusters**, **TechPowerUp**, **Tom's Hardware**, e i test distruttivi di **GamersNexus**. Sono tutti gratuiti, e coprono collettivamente quasi tutti i modelli degni di considerazione.

---

## 8. Come scegliere, passo dopo passo

### 8.1 La Procedura

**Primo passo: calcolare il wattaggio.** Sommare il TBP della GPU, il consumo di picco della CPU (PL2 o PPT), e 80-100 watt per tutto il resto. Aggiungere un margine del 30-40%. Arrotondare per eccesso al successivo incremento commerciale (gli incrementi tipici sono 550, 650, 750, 850, 1000, 1200, 1600 W).

**Secondo passo: decidere lo standard.** Se la scheda grafica usa un connettore a 16 pin, esigere ATX 3.0 o 3.1 con **12V-2x6 nativo**. Se usa connettori PCIe a 8 pin, ATX 3.x è comunque preferibile ma non un requisito assoluto.

**Terzo passo: fissare la soglia di efficienza.** Nel 2026, con l'attuale disponibilità e prezzi **[dati volatili]**, non c'è motivo di scendere sotto l'**80 PLUS Gold** per un sistema con scheda grafica dedicata. Il Bronze è accettabile solo in un PC da ufficio a basso consumo. Platinum e Titanium hanno senso per chi tiene il PC acceso molte ore al giorno o cerca la massima silenziosità.

**Quarto passo — quello che nessuno fa e che fa tutta la differenza: verificare il modello specifico.** Cercare il modello esatto (non la serie, il *modello con il suo wattaggio*) su una tier list aggiornata e, se possibile, leggere il report Cybenetics o una recensione tecnica. Cinque minuti di ricerca a questo punto valgono più di tutti i passi precedenti messi insieme.



**Quinto passo: scegliere la modularità.** Full modular se il budget lo permette e il case è compatto o ha una finestra. Semi-modular come ragionevole compromesso. Non-modular solo per build economiche in case grandi.

**Sesto passo: controllare la garanzia.** Sotto i cinque anni, in una build seria, è una bandiera rossa. Dieci anni è quello che ci si aspetta da un prodotto di fascia medio-alta.

**Settimo passo: verificare i dettagli fisici.** La lunghezza dell'alimentatore (le unità da 1000W e oltre possono essere più lunghe di 160-180mm e potrebbero non entrare in tutti i case), il fattore di forma (ATX standard contro **SFX** o **SFX-L** per case Mini-ITX), il numero di connettori PCIe e SATA effettivamente disponibili, e la lunghezza dei cavi (nei case con PSU montato in basso e connettore EPS montato in alto, un cavo CPU corto è un problema serio: sono necessari almeno 60-65cm, e in molti case full tower è consigliabile un cavo di estensione).

## 8.2 Raccomandazioni basate sul budget

**[dati volatili: i prezzi indicati sono ordini di grandezza per il mercato italiano e cambiano frequentemente]**

Nella **fascia entry-level** (circa 60-90 euro, per sistemi da 450-650W), l'obiettivo è comprare un prodotto decente senza inseguire il meglio assoluto. Questa fascia include linee come Corsair RM (wattaggi minori), be quiet! Pure Power, Seasonic Focus GX nei wattaggi inferiori, MSI MPG A-GF. Il consiglio: puntare a un'unità Gold semi-modulare da 650W di un marchio conosciuto, con almeno cinque anni di garanzia. Questo è già sufficiente per una scheda grafica di fascia media, e si può aggiornare la GPU in seguito senza cambiare tutto.

Nella **fascia media** (circa 100-150 euro, per sistemi da 750-850W), il mercato è affollato e la scelta è ampia. Corsair RMx, be quiet! Straight Power, Seasonic Focus GX/PX, NZXT serie C, Cooler Master V Gold, ASUS TUF Gaming: sono tutti prodotti competenti. Il consiglio: **850W Gold, full modular, ATX 3.1 con 12V-2x6 nativo, dieci anni di garanzia.** Questa configurazione copre il 90% delle build gaming serie entro il 2026, con spazio per un futuro aggiornamento della scheda grafica.

Nella **fascia alta** (circa 180-350 euro, per sistemi da 1000-1200W e oltre), si sta comprando qualcosa che deve gestire una scheda grafica di fascia alta con transienti brutali, e si sta comprando silenziosità e longevità. Seasonic Prime PX/TX, be quiet! Dark Power Pro, Corsair HX/AX, ASUS ROG Thor. Il consiglio: **1000-1200W Platinum o Titanium, full modular, ATX 3.1, dodici anni di**

**garanzia se possibile.** Se la macchina è una workstation che gira ore al giorno sotto carico, il Titanium ripaga davvero.

Una nota per chi assembla in **SFF** (*Small Form Factor*, case compatti): i formati **SFX** e **SFX-L** hanno un mercato più piccolo e prezzi più alti a parità di potenza erogata. Corsair SF, Cooler Master V SFX, Lian Li SP, FSP Dagger sono i riferimenti usuali. Non usate mai un adattatore SFX→ATX come scusa per infilare un'unità economica in un case piccolo: le unità SFX di qualità hanno una densità di potenza e un dimensionamento termico superiori, progettati per quel volume, e quelle economiche in quel formato sono particolarmente pericolose.

### 8.3 Errori comuni, spiegati

**L'alimentatore no-name da 30 euro.** Questo è l'errore cardinale. Un alimentatore da 30 euro pubblicizzato come "700W" non eroga 700 watt: tipicamente ne eroga 300-400 reali prima di andare in protezione o guastarsi, ha ripple fuori specifica, protezioni assenti o non funzionanti, condensatori di bassa qualità, e nei test distruttivi non è raro che si guasti prendendo fuoco. La logica dell'acquirente — "ho speso 1500 euro in componenti, risparmio sull'alimentatore" — è esattamente l'opposto della razionalità economica. Regola: l'alimentatore dovrebbe rappresentare tra il 7% e il 12% del budget totale del PC.

**Tagliare troppo corto con il wattaggio.** Comprare un PSU da 650W per un sistema che consuma 620W di picco è tecnicamente possibile ma praticamente sbagliato: l'alimentatore opererà al 95% del carico, con la ventola sempre al massimo, i condensatori al loro limite termico, e zero margine per i transienti della GPU. Il primo spegnimento improvviso sotto carico avverrà entro poche settimane.

**Fidarsi solo dell'etichetta 80 PLUS.** Ne abbiamo discusso a lungo. L'efficienza non è qualità.

**Riutilizzare i cavi modulari del vecchio alimentatore.** L'errore più distruttivo. Vale la pena rileggere la sezione 4.2. Quando si cambia alimentatore, si cambiano *tutti* i cavi.

**Daisy-chaining su schede grafiche potenti.** Molti alimentatori forniscono cavi PCIe con **due connettori sullo stesso cavo** (uno 6+2 a metà e un altro 6+2 in fondo). La ragione è economica: serve un solo connettore lato PSU per alimentare due connettori lato GPU. Il problema è che quei due connettori condividono gli stessi tre conduttori da 12 volt del cavo, e un conduttore da 18 AWG è

dimensionato ragionevolmente per 7-8 ampere. Due connettori PCIe a 8 pin dovrebbero portare fino a 300 watt combinati, che sono 25 ampere a 12 volt, distribuiti su soli tre fili invece di sei: questo porta a oltre 8 ampere per filo, con riscaldamento del conduttore e caduta di tensione. Per una scheda che consuma poco (150-180 W), non succede nulla. Per una scheda che consuma 300 W o più, il daisy-chaining è una cattiva idea, e le raccomandazioni dei produttori sono unanimi: **un cavo PCIe fisicamente separato per ogni connettore sulla scheda grafica**, prelevato da un'uscita diversa dell'alimentatore. Se l'alimentatore non ha abbastanza uscite PCIe per farlo, è un segno che è sottodimensionato per quella scheda.

**Usare l'adattatore incluso con la GPU invece del cavo nativo.** Gli adattatori da 3× o 4× PCIe a 12VHPWR funzionano, ma aggiungono un punto di contatto e un punto di cedimento meccanico su un percorso che porta fino a 600 watt. Se l'alimentatore ha un cavo 12V-2x6 nativo, usatelo. Se non lo ha, questo è un buon argomento per cambiare l'alimentatore.

**Ignorare le specifiche tecniche dell'etichetta.** Su un alimentatore serio, l'etichetta laterale mostra la distribuzione della potenza tra i rail. Il numero da cercare è la **potenza combinata sul rail da 12V**: su un'unità onesta da 850W, solo il 12V dovrebbe essere in grado di erogare 830-840W (cioè circa 70 ampere). Se un alimentatore da "700W" dichiara solo 400-500W sul 12V, con il resto della potenza attribuito a 5V e 3.3V (che non useranno mai più di 30-50W), quell'alimentatore è, funzionalmente, un'unità da 450-550W venduta come 700W. Questo è un trucco di marketing tipico delle unità economiche e delle generazioni più vecchie, e leggere l'etichetta lo smaschera in dieci secondi.

**Acquistare un alimentatore usato.** I condensatori invecchiano, la ventola si usura, la garanzia non è trasferibile e non si conoscono le condizioni in cui ha operato. È l'unico componente del PC per il quale il mercato dell'usato è categoricamente sconsigliabile.

**Dimenticare la protezione a monte.** Un alimentatore, per quanto buono, non è un protettore di sovratensioni per la rete elettrica. In aree con una rete elettrica instabile — e in molte parti d'Italia lo è — una **ciabatta con protezione da sovratensioni** costa venti euro, e un **UPS** (Uninterruptible Power Supply) con AVR costa circa cento euro e protegge da cali di tensione e interruzioni. Per una build da duemila euro, è un'assicurazione ragionevole. Attenzione a un dettaglio tecnico: gli alimentatori con PFC attivo possono avere problemi con gli UPS

economici che emettono un'onda quadra approssimata durante un blackout; per un PC moderno, è necessario un UPS con uscita a **onda sinusoidale pura**.

---

## Riepilogo Operativo — Lista di Controllo per la Scelta dell'Alimentatore

**A. Dimensionamento** 1. Recuperare il **TBP della GPU** dal sito del produttore (non dalla scatola del rivenditore). 2. Recuperare il **consumo di picco della CPU** (PL2 per Intel, PPT per AMD), non il TDP nominale. 3. Aggiungere **80-100W** per scheda madre, RAM, unità, ventole, pompa. 4. Sommare e aggiungere un **marginale del 30-40%** per i transitori e per operare alla massima efficienza. 5. Arrotondare alla dimensione commerciale successiva. Verificare con un calcolatore online come controllo incrociato, non come oracolo.

**B. Standard e Connettori** 6. Scheda grafica con **connettore a 16 pin?** → Richiedere **ATX 3.1 con 12V-2x6 nativo**. Nessun adattatore. 7. Contare i **connettori PCIe/12V-2x6 effettivamente disponibili**: uno per ogni connettore della scheda grafica, su cavi separati. 8. Verificare che ci siano abbastanza **connettori SATA** per le unità previste e un **EPS 8+8** se la scheda madre lo richiede.

**C. Qualità** 9. Certificazione minima: **80 PLUS Gold** per qualsiasi sistema con GPU dedicata (tabella EU 230V, non 115V). 10. Cercare il **modello esatto** su una tier list aggiornata (Cultists Network o equivalente). Se il modello non compare da nessuna parte, non acquistarlo. 11. Se disponibile, leggere il **rapporto Cybenetics**: controllare ripple, regolazione, risposta ai transitori, protezioni e il livello **LAMBDA** se il silenzio è importante. 12. Verificare la presenza (e nei test, la funzionalità) di **OVP, UVP, OCP, OPP, SCP, OTP**. 13. Verificare che l'etichetta dichiari una **potenza sul rail da 12V pari ad almeno il 95% della potenza nominale totale**.

**D. Ergonomia e Fisica** 14. Scegliere la **modularità**: full modular se il budget e il case lo giustificano. 15. Controllare la **lunghezza dell'unità** rispetto allo spazio disponibile nel case e il **fattore di forma** (ATX / SFX / SFX-L). 16. Controllare la **lunghezza dei cavi**, specialmente l'EPS della CPU nei case grandi. 17. Preferire ventola **FDB** con **modalità zero-RPM**.

**E. Garanzia e Protezione** 18. **Minimo 5 anni**; 10 anni è lo standard atteso nella fascia medio-alta. Registrare il prodotto se richiesto. 19. Fornire **protezione a**

**monte:** ciabatta con protezione da sovratensioni o, meglio, un **UPS a onda sinusoidale pura**.

**F. Cose da Non Fare, Mai** 20. Non riutilizzare mai i **cavi modulari** di un altro alimentatore, nemmeno della stessa marca. 21. Non usare mai il **collegamento a margherita** (daisy-chaining) dei connettori PCIe su schede grafiche oltre i ~200 W. 22. Non comprare mai un alimentatore **senza marca** o senza recensioni tecniche indipendenti. 23. Non comprare mai un alimentatore **usato**. 24. Non inserire mai il connettore a 16 pin **parzialmente**: deve fare click, senza spazi visibili, e il cavo non deve essere piegato bruscamente nei primi centimetri.

---

*Nota finale sui dati: i modelli, i prezzi, le fasce di produttori e le generazioni di schede grafiche citati in questo capitolo riflettono lo stato del mercato al momento della scrittura e sono intrinsecamente soggetti a rapida obsolescenza. I principi fisici e di progettazione — la conversione AC/DC, il predominio del rail da 12V, il ruolo dei transistori, la distinzione tra efficienza e qualità, la non intercambiabilità dei cavi modulari — non cambiano.*

## Capitolo 7 - Il Case e la Ventilazione

### Premessa: Il Componente Che Tutti Sottovalutano

Esiste una gerarchia implicita nella mente di chiunque assembla il suo primo computer. In cima ci sono la CPU (Central Processing Unit) e la GPU (Graphics Processing Unit), perché sono le parti di cui si parla nelle recensioni e che compaiono nei benchmark. Poi viene la RAM (Random Access Memory, memoria di lavoro volatile) e lo storage, perché almeno hanno un numero che cresce e si può confrontare. Poi la scheda madre, scelta per il suo socket e il prezzo. Poi l'alimentatore, spesso scelto male. E infine, come un ripensamento, quasi un accessorio estetico, il case: il "mobiletto", lo "chassis", quella scatola di lamiera e vetro che tiene tutto insieme.

Questa gerarchia è sbagliata, e per una ragione molto concreta: il case è l'unico componente che influenza **tutti gli altri contemporaneamente**. Non calcola nulla, non produce frame, non immagazzina dati, ma determina la temperatura a cui operano CPU e GPU, il rumore che il sistema produce nella stanza, la quantità di polvere che si accumula sui dissipatori, la vita utile dei componenti, e — cosa che si scopre solo quando si inizia l'assemblaggio — quanto sarà dolorosa o piacevole l'esperienza di montaggio e manutenzione.

Un case sbagliato non farà esplodere il vostro computer. Fa qualcosa di più insidioso: lo rallenta silenziosamente. Una GPU che in uno chassis ben ventilato opera a 68 °C, mantenendo il suo boost massimo, può raggiungere gli 84 °C all'interno di un "acquario" chiuso da tre pannelli di vetro. A quel punto, l'algoritmo di boost — che è dinamico e sensibile alla temperatura — abbassa le frequenze per rientrare nei limiti termici. Il risultato è un 5-10% di prestazioni in meno che l'utente non vede perché non ha mai visto il "prima". Ha semplicemente comprato una scheda grafica da 800 euro e ne sta usando solo 730 euro di prestazioni.

Questo capitolo copre il case e tutto ciò che lo circonda — formati, compatibilità, flusso d'aria, ventole, filtri, marche — con lo stesso livello di dettaglio riservato ai componenti "nobili". Alla fine, avrete gli strumenti per aprire le specifiche tecniche di uno chassis su un sito di e-commerce e capire, in novanta secondi, se è adatto alla vostra configurazione o se è una trappola.

***Nota sui dati volatili.** Modelli, prezzi e disponibilità di case e ventole cambiano rapidamente e variano molto tra i mercati. Ogni cifra in euro*

*riportata in questo capitolo è indicativa del mercato italiano e andrebbe verificata al momento dell'acquisto. I dati marcati **[dati volatili]** sono i più soggetti a invecchiamento.*

---

## 1. Il ruolo del case

### 1.1 Protezione meccanica ed elettrica

La funzione più antica e ovvia del case è quella di contenitore strutturale. I componenti del PC sono fragili in modo non intuitivo: la scheda madre è un sandwich di fibra di vetro e rame con centinaia di saldature che si crepano se il PCB (Printed Circuit Board) viene flessato; un dissipatore ad aria di grandi dimensioni può pesare 1,5 kg e, se il sistema viene trasportato in verticale in auto, esercita un'enorme leva sui quattro punti di montaggio del socket; una moderna scheda grafica a triplo slot pesa fino a 2 kg ed è sospesa a un connettore PCIe (Peripheral Component Interconnect Express, il bus di espansione ad alta velocità) e a due viti sulla staffa posteriore.

Il case fornisce il telaio rigido che assorbe queste sollecitazioni. Lo fa tramite il **vassoio della scheda madre** (motherboard tray), la lamiera verticale a cui la scheda madre è avvitata tramite gli **standoff**: piccoli cilindri filettati che sollevano il PCB di qualche millimetro dalla lamiera, impedendo il contatto elettrico tra le tracce di rame sul retro della scheda e il metallo dello chassis. È bene ricordarlo subito, perché è uno dei classici errori da principiante: **montare la scheda madre senza standoff, o lasciare uno standoff in una posizione in cui la scheda non ha un foro, provoca un cortocircuito** che, nel migliore dei casi, impedisce l'accensione e, nel peggiore, danneggia permanentemente la scheda.

C'è poi una funzione elettromagnetica meno visibile. Un PC è una sorgente di EMI (Electromagnetic Interference): all'interno del case ci sono segnali che commutano miliardi di volte al secondo, e un contenitore metallico chiuso e messo a terra agisce come una **gabbia di Faraday** imperfetta ma efficace, riducendo sia le emissioni verso l'esterno sia la suscettibilità a disturbi esterni. Per questo i case hanno gli slot di espansione chiusi da staffe metalliche e per questo esistono normative (FCC negli Stati Uniti, marcatura CE in Europa) a cui gli chassis devono conformarsi. In pratica, per l'utente domestico, questo si traduce in una semplice regola: **le staffe degli slot PCIe inutilizzati vanno reinstallate**, non

perché lo detti la fluidodinamica, ma perché servono a chiudere il guscio e — secondariamente — a impedire all'aria di entrare o uscire da percorsi non voluti.

## 1.2 Gestione termica: la vera funzione

Questo è il cuore del capitolo. Da un punto di vista termodinamico, un computer è un **convertitore di energia elettrica in calore**. Praticamente il 100% della potenza prelevata dalla presa (meno una quantità trascurabile che esce come luce LED e onde radio Wi-Fi) finisce per diventare calore nell'aria della stanza. Un sistema che preleva 500 W dalla presa è, dal punto di vista del riscaldamento ambientale, indistinguibile da una stufetta elettrica da 500 W.

Il problema non è il calore in sé: è la **densità di potenza**. La CPU dissipa il suo TDP (Thermal Design Power, la potenza termica di progetto, cioè il calore che il sistema di raffreddamento deve essere in grado di dissipare in condizioni sostenute) da una superficie di pochi centimetri quadrati; la GPU fa lo stesso da un die grande come un francobollo. Il dissipatore della CPU e quello della scheda grafica hanno il compito di prendere quel calore concentrato e trasferirlo all'aria che li attraversa. Ma l'aria che li attraversa è **l'aria all'interno del case**.

Questa è l'idea centrale, e merita di essere ripetuta perché è la fonte del 90% degli errori: il dissipatore della CPU e quello della GPU non raffreddano con l'aria della stanza. Raffreddano con l'aria del case. Il compito del case è rendere l'aria del case il più simile possibile all'aria della stanza, il che significa che dovrebbe essere continuamente sostituita prima che si riscaldi. Se il case non scambia aria, si verifica una condizione di **ricircolo**: la GPU espelle aria a 55 °C, quell'aria non trova via d'uscita, viene ri-aspirata dalle ventole della GPU stessa e dal dissipatore della CPU, e il sistema si stabilizza a un equilibrio termico molto più elevato. I dissipatori funzionano ancora perfettamente — semplicemente lavorano con aria in ingresso a 45 °C invece di 24 °C, e quei 21 gradi di differenza sono quasi interamente trasferiti alle temperature dei chip.

Il parametro che descrive questo fenomeno si chiama **delta T ambiente-case**: la differenza tra la temperatura dell'aria all'interno del case (misurabile con sensori, o stimabile dai sensori di temperatura della scheda madre) e la temperatura ambiente. In un case ben ventilato sotto carico, questo delta è di 3-6 °C. In un case chiuso e mal configurato, può superare i 15-20 °C. **Ogni grado di delta T è un grado in più su CPU e GPU**, aggiunto a tutto il resto.



### 1.3 Acustica

Il secondo asse su cui lavora il case è il rumore. Qui c'è un compromesso fondamentale che va capito subito, perché nessun marketing lo dichiarerà mai esplicitamente: **flusso d'aria e silenzio sono in tensione**. Il rumore del PC ha tre origini:

1. **Rumore aerodinamico** delle ventole, generato dalla turbolenza dell'aria che attraversa pale, griglie e alette del dissipatore; 2. **Rumore meccanico** dei cuscinetti delle ventole, delle pompe dei sistemi di raffreddamento a liquido e degli hard disk meccanici; 3. **Vibrazioni strutturali** trasmesse dal telaio, che funge da cassa di risonanza se le lamiere sono sottili.

Un case "silenzioso" tradizionale — si pensi ai modelli storici di be quiet! o al Fractal Design Define — affronta il problema con l'**isolamento**: pannelli laterali e frontali rivestiti internamente con materiale fonoassorbente (bituminoso o schiuma poliuretanica), un frontale chiuso con uno sportello solido e aperture ridotte. Questo agisce sul rumore che fuoriesce, ma peggiora il flusso d'aria, quindi le ventole devono girare più velocemente per compensare, e ventole più veloci fanno più rumore. Il guadagno netto esiste, ma è molto più piccolo di quanto comunemente si creda.

La scuola moderna — che ha dominato il mercato dal 2019-2020 in poi — ha invertito il ragionamento: **si preferisce un case molto aperto (mesh) con ventole grandi e lente**. Il ragionamento è che il rumore aerodinamico cresce in modo fortemente non lineare con la velocità di rotazione (in prima approssimazione, la potenza acustica scala come la quinta potenza della velocità periferica delle pale: raddoppiare gli RPM significa un aumento del rumore di circa 15 dB, che è "molto più del doppio" per la percezione umana). Se il case offre poca resistenza, le ventole possono girare a 700-900 RPM invece di 1400-1600 per spostare la stessa quantità d'aria, e il risultato netto è **più fresco E più silenzioso**, anche se il rumore residuo è meno "schermato". Questa è attualmente la strategia vincente per la stragrande maggioranza degli utenti, e i test indipendenti lo confermano costantemente.

Esistono ancora casi limite in cui l'isolamento ha senso: sistemi a bassissima potenza (un PC da ufficio con una CPU da 65W e nessuna scheda grafica dedicata) collocati in stanze molto silenziose, dove il rumore residuo delle ventole a bassa velocità è ancora percepibile e la barriera acustica fa la differenza. Ma un sistema

da gaming con una GPU da 300W non può essere reso silenzioso racchiudendolo: può solo essere reso caldo.

#### 1.4 Estetica

Va detto onestamente: per un'enorme fetta del mercato, il case è **l'unico componente visibile**, ed è quindi legittimo che l'estetica pesi sulla scelta. Il punto non è negare questa esigenza, ma ordinarla correttamente rispetto alle altre. La regola pratica che propongo, e su cui tornerò nella procedura di selezione, è: **l'estetica è un criterio di selezione all'interno dell'insieme dei case che funzionano, non un criterio che definisce l'insieme**. Per prima cosa, filtra per compatibilità e flusso d'aria, poi scegli il più esteticamente gradevole tra quelli rimasti. L'insieme è piuttosto ampio: nel 2025-2026, ci sono decine di case belli e ben ventilati, quindi non è più necessario scendere a compromessi. Chi sceglie il case "acquario" prima di guardare le temperature sta semplicemente invertendo l'ordine dei fattori, e lo pagherà in gradi.

#### 1.5 Ergonomia di Assemblaggio e Manutenzione

L'ultimo ruolo, quello che si apprezza solo dopo il secondo o terzo assemblaggio: un buon case permette un assemblaggio facile. Le caratteristiche che fanno la differenza sono concrete e verificabili nelle recensioni video:

- **\*\*spazio dietro il vassoio della scheda madre\*\*** per la gestione dei cavi (dai miseri 20 mm dei case economici ai 30-35 mm dei modelli ben progettati);
- **\*\*pannelli laterali tool-less\*\***, a scatto o con chiusura magnetica;
- **\*\*bordi arrotondati\*\*** sulla lamiera, che impediscono di tagliarsi le dita — un dettaglio che distingue immediatamente uno chassis ben fatto da uno costruito al risparmio;
- **\*\*coperture degli slot di espansione riutilizzabili\*\***, non a strappo: alcuni case economici hanno le coperture degli slot PCIe fissate con un ponte metallico da rompere, e una volta rotte non possono essere riattaccate;
- **\*\*filtri antipolvere rimovibili senza smontare il PC\*\***, idealmente dalla parte anteriore o superiore, non da sotto richiedendo di sollevare il case;
- **\*\*vassei per unità rimovibili\*\*** e accesso alla parte posteriore senza dover coricare la macchina.

Niente di tutto questo appare in una tabella delle specifiche, e tutto ciò determina se lavorare di nuovo sul computer tra due anni sarà un compito pomeridiano o un incubo.

---

## 2. Fattori di Forma: Chassis e Scheda Madre

### 2.1 Fattori di Forma della Scheda Madre, Riveduti da una Prospettiva del Case

Il fattore di forma della scheda madre — trattato nel capitolo dedicato — è il vincolo primario che determina il case, perché lo chassis deve avere i distanziatori nelle posizioni corrette e lo spazio fisico per contenerla. Esistono quattro fattori di forma rilevanti per il mercato consumer, definiti dallo standard **ATX** (Advanced Technology eXtended, lo standard introdotto da Intel nel 1995 che governa dimensioni, fori di montaggio e posizionamento dei connettori):

| Fattore di Forma       | Dimensioni (mm)                    | Slot di Espansione | Uso Tipico                                |
|------------------------|------------------------------------|--------------------|-------------------------------------------|
| E-ATX ("Extended ATX") | 305 × 330 (nominale, ma variabile) | 7                  | Workstation, HEDT, schede di fascia alta  |
| ATX                    | 305 × 244                          | 7                  | Standard di riferimento, desktop completo |
| Micro-ATX (mATX)       | 244 × 244                          | 4                  | Budget compatto, uffici                   |
| Mini-ITX (ITX)         | 170 × 170                          | 1                  | Sistemi SFF (Small Form Factor)           |

Un'importante precisazione e fonte di veri guai: **"E-ATX" non è uno standard rigoroso**. Formalmente, indica 305 × 330 mm, ma i produttori usano l'etichetta anche per schede che misurano 305 × 277 mm o 305 × 267 mm (i cosiddetti formati "EE-ATX" o semplicemente ATX allargati). Un case dichiarato "compatibile E-ATX fino a 280 mm" accetterà una scheda da 277 mm ma non una da 330 mm.

**Controllate sempre la larghezza effettiva della scheda in millimetri**, non la sigla. Questo è uno degli errori più costosi perché il problema si scopre solo quando si ha già tutto in mano.

La compatibilità è **discendente**: un case che accetta ATX accetta anche mATX e ITX, perché i fori per i distanziatori sono un sottoinsieme. Il contrario non è vero. Montare un ITX in un case ATX è perfettamente legittimo (ci sarà molto spazio vuoto, il che non è un difetto termico, semmai il contrario), ma è uno spreco di volume e denaro.

## 2.2 Fattori di Forma dei Case

I nomi commerciali degli chassis sono meno standardizzati di quanto si possa pensare. Non esiste una definizione ufficiale di "mid tower". Si usa una convenzione, e il parametro più onesto per confrontare gli chassis è il **volume in litri**, che molti produttori e siti specializzati ormai dichiarano.

| Categoria               | Altezza Tipica | Volume Tipico | Mobo Max                     | Ventole Tipiche | Note                                   |
|-------------------------|----------------|---------------|------------------------------|-----------------|----------------------------------------|
| Full tower              | 500-650 mm     | 60-100+ L     | E-ATX / SSI-EEB              | 8-12            | Custom loop, molti drive, workstation  |
| Mid tower               | 420-500 mm     | 40-60 L       | ATX (spesso E-ATX "stretto") | 5-9             | <b>Il formato di riferimento</b>       |
| Mini tower / mATX       | 350-420 mm     | 25-40 L       | mATX                         | 3-5             | Compromesso spazio/costo               |
| SFF (Small Form Factor) | variabile      | 8-25 L        | Mini-ITX                     | 1-4             | Compattezza estrema, molti compromessi |
| Cube / "dual chamber"   | variabile      | 30-60 L       | ITX → E-ATX                  | variabile       | Layout a doppia camera, estetica       |

**Full tower.** Ha senso in tre casi: raffreddamento a liquido custom (con più radiatori da 360/420 mm montati contemporaneamente), un gran numero di drive meccanici (NAS casalingo, archivi video), o vere schede madri workstation E-ATX. Al di fuori di questi scenari, è spazio e denaro sprecati: un full tower non è automaticamente più fresco di un buon mid tower, perché il volume di per sé non raffredda — raffredda l'**airflow**. Un full tower con tre ventole è peggio di un mid tower con sei.

**Mid tower.** Questo formato risolve il 90% dei casi d'uso. Accetta schede madri ATX, radiatori da 360 mm, schede grafiche lunghe 340-400 mm e dissipatori ad aria alti 160-175 mm. È qui che si concentra la ricerca e sviluppo dei produttori, dove c'è la maggiore concorrenza, e quindi il miglior rapporto qualità/prezzo. **Se non hai una ragione esplicita e articolabile per uscire da questa categoria, restaci.**

**Mini tower / mATX.** Ha senso quando il vincolo è lo spazio sulla scrivania o il budget. Una scheda madre mATX costa meno di una ATX equivalente, e i quattro slot di espansione sono più che sufficienti per chiunque non abbia esigenze particolari (nel 2026, gli slot di espansione sono quasi esclusivamente per la GPU: audio, rete e USB sono integrati). Il compromesso è termico: meno spazio per le ventole, spesso solo 2-3 posizioni, e spazi più ristretti.

**SFF (Small Form Factor).** Questa è una disciplina a sé stante, quasi uno sport. Sotto i 15 litri, ogni millimetro è conteso: la scheda grafica deve essere corta o "2.5 slot", il dissipatore della CPU è spesso un low-profile alto 47-67 mm, l'alimentatore è un **SFX** o **SFX-L** (formato compatto, 100 × 63.5 mm contro 150 × 86 mm per l'ATX standard) che costa il 40-60% in più di un ATX di pari potenza, i cavi devono essere accorciati o sostituiti con set personalizzati. Il risultato può essere splendido — un sistema da 12 litri con prestazioni desktop complete — ma il percorso è costoso, richiede una ricerca approfondita e non perdona errori di pianificazione. **È il formato sbagliato per una prima build.** I telai di riferimento del settore includono il Fractal Design Terra e Ridge, il Cooler Master NR200P (il più accessibile e "indulgente"), il Lian Li A4-H2O e Q58, e la scena boutique (SSUPD, Formd, Dan Cases) **[dati volatili]**.

### 2.3 Quale formato per quale esigenza

- **\*\*PC da ufficio / HTPC / navigazione\*\*:** mATX o ITX. Poco calore, poco spazio, basso costo.
- **\*\*PC da gaming entry/mid-range (GPU singola, dissipatore ad aria o AIO 240)\*\*:** mid-tower mesh. Non esiste alternativa razionale.
- **\*\*PC da gaming high-end (GPU top-tier, AIO 360, molte ventole)\*\*:** mid-tower di qualità o dual-chamber come Lian Li O11. Nota: i case dual-chamber spesso **\*\*mancano di aspirazione frontale\*\*** e devono essere configurati con aspirazione dell'aria dal basso e/o dal lato, come vedremo.
- **\*\*Workstation AI/ML o rendering (GPU multiple, molte linee PCIe, molta RAM)\*\*:** full tower, e qui il vincolo diventa **\*\*la larghezza per ospitare due**

schede grafiche a 3 slot con spazio d'aria in mezzo\*\*, oltre alla capacità dell'alimentatore. Va detto chiaramente che due GPU flagship affiancate in un case consumer sono una configurazione termicamente problematica: la scheda superiore aspira aria calda dalla scheda inferiore. Le soluzioni includono modelli blower (rari nel consumer), raffreddamento a liquido o chassis con spaziatura degli slot aumentata.

- \*\*NAS / server domestico\*\*: chassis specifici con gabbie per 6-12 dischi da 3.5", ventole a medio flusso davanti alle gabbie, o formati rack se si dispone di un armadio.

---

### 3. Compatibilità e spazio interno: la checklist che ti salva l'acquisto

Questa è la sezione operativa più importante del capitolo. Tutti i numeri qui elencati sono pubblicati nelle specifiche del case; il problema è che quasi nessuno li legge **prima** di ordinare. Prendi un foglio (o un file) e compila questi campi per la tua configurazione.

#### 3.1 Lunghezza massima della GPU

Questa è la misura, in millimetri, dalla staffa posteriore all'estremità anteriore della scheda grafica. Il case dichiara una "**GPU clearance**" o "max VGA length".

**Regola operativa: prendi la lunghezza effettiva del modello specifico che acquisti — non il chip, il modello.** Una ASUS RTX 5070 può essere lunga 305 mm, e la stessa RTX 5070 di un altro produttore può essere 240 mm. La lunghezza è una caratteristica del dissipatore, non della GPU.

Attenzione a tre insidie:

##### 1. Il valore dichiarato dal case è spesso "**senza ventole frontali installate**".

Molti chassis dichiarano due numeri: ad esempio, "400 mm, 360 mm con radiatore frontale". Se monti un radiatore o ventole spesse nella parte anteriore, perdi 25-55 mm. 2. **Cavi di alimentazione.** Il connettore **12V-2×6** (l'evoluzione del 12VHPWR, il connettore a 16 pin delle moderne schede ad alta potenza) esce dal lato superiore della scheda e richiede un raggio di curvatura minimo: lo standard impone di non piegare il cavo entro 35 mm dal connettore. Se il pannello laterale è a 15 mm dalla scheda, il cavo verrà schiacciato — ed è esattamente questo il meccanismo che ha causato gli incidenti di fusione dei connettori. Alcune schede hanno il connettore ruotato o posizionato diversamente proprio per questo

motivo. **Verifica l'ingombro in larghezza, non solo in lunghezza.** 3. **Spessore slot.** Le schede moderne occupano 2, 2.5, 3 o anche 4 slot in altezza. Un case con 7 slot PCIe accoglie fisicamente qualsiasi scheda, ma se hai una scheda di espansione (una scheda audio, un adattatore 10 Gbit, una scheda di acquisizione), potresti scoprire che la GPU copre il suo slot.

### 3.2 Altezza massima dissipatore CPU

Misura in millimetri dalla superficie della scheda madre alla parte superiore del dissipatore. Valori tipici:

| Categoria Dissipatore                                  | Altezza    | Case Richiesto            |
|--------------------------------------------------------|------------|---------------------------|
| Low-profile (Noctua NH-L9, Thermalright AXP)           | 37-67 mm   | SFF, HTPC                 |
| Compact single tower                                   | 120-140 mm | mATX, mid tower           |
| Standard single tower (es. Peerless Assassin, NH-U12A) | 155-160 mm | mid tower (quasi tutti)   |
| Dual tower (Noctua NH-D15, Thermalright FA/PA)         | 160-168 mm | wide mid tower            |
| "Large" dual tower                                     | 170-175 mm | verificare esplicitamente |

La regola: **lascia almeno 5 mm di spazio** rispetto al valore dichiarato dal case. Tolleranze di fabbricazione, spessore delle guarnizioni, altezza degli stand-off e la bombatura del pannello laterale in vetro possono mangiarsi quei pochi millimetri. Un dissipatore che tocca il pannello laterale non solo non si chiuderà: trasmette vibrazioni al vetro e trasforma l'intero lato del case in un altoparlante.

### 3.3 Radiatori: dimensioni, posizioni, spessori

Il **radiatore** è lo scambiatore di calore di un sistema di raffreddamento a liquido (AIO, All-In-One, sistemi chiusi e pre-riempiti, o custom loop). Si misura in base al numero e alla dimensione delle ventole che ospita:

| Abbreviazione | Ventole    | Lunghezza Approssimativa | Capacità di Raffreddamento Approssimativa |
|---------------|------------|--------------------------|-------------------------------------------|
| 120           | 1 × 120 mm | ~155 mm                  | scarsa, sconsigliata                      |
| 240           | 2 × 120 mm | ~275 mm                  | CPU fino a ~180 W                         |
| 280           | 2 × 140 mm | ~315 mm                  | ~15-20% migliore                          |

|     |            |         |                                       |
|-----|------------|---------|---------------------------------------|
|     |            |         | di un 240                             |
| 360 | 3 × 120 mm | ~395 mm | CPU di fascia alta (fino a 250-300 W) |
| 420 | 3 × 140 mm | ~455 mm | massimo consumer, case grandi         |

**Posizioni di montaggio** possibili e le loro implicazioni:

- **\*\*Superiore (alto), scarico.\*\*** Questa è la posizione canonica per un AIO. L'aria calda sale, il radiatore la espelle verso l'alto, la pompa rimane più in basso del punto più alto del circuito (importante: **\*\*la pompa non deve mai essere il punto più alto\*\***, altrimenti l'aria che inevitabilmente si accumula nel circuito si raccoglie nella pompa e produce il classico gorgoglio e usura prematura). Il compromesso: il radiatore scalda leggermente l'aria che... esce, quindi nessun problema; però occupa spazio alle VRM (Voltage Regulator Module, lo stadio di alimentazione della CPU sulla scheda madre) e può interferire con i dissipatori stessi delle VRM o con moduli RAM alti. **\*\*Verificare il "CPU cooler to top" clearance del case e lo spessore radiatore + ventola\*\*** (tipicamente 27 + 25 = 52 mm, ma esistono radiatori da 38 e 45 mm di spessore).
- **\*\*Frontale (fronte), immissione.\*\*** Massime prestazioni per la CPU, perché il radiatore riceve aria fresca dall'esterno. Il costo è che tutta l'aria che entra nel case è stata preriscaldata dal radiatore (di 3-8 °C sotto carico), e questo penalizza la GPU. È una scelta legittima se la priorità è la CPU. Riduce la lunghezza GPU disponibile.
- **\*\*Laterale / inferiore.\*\*** Tipico dei case dual-chamber. Da valutare caso per caso.

Un'ultima nota onesta: **per la stragrande maggioranza delle CPU consumer, un buon dissipatore ad aria da 40-60 euro (Thermalright Peerless Assassin, Phantom Spirit, DeepCool AK620) è a 2-4 °C da un AIO 360 da 130 euro**, non ha una pompa che può guastarsi, non ha liquido che può evaporare nel tempo, e non ha un singolo punto di fallimento. Un AIO ha senso per estetica, per liberare spazio attorno al socket, per CPU veramente estreme, o quando l'altezza del case non permette una torre. Non compratelo pensando che sia automaticamente superiore.

### 3.4 Alloggiamenti per drive

Distinguiamo tre famiglie:



- **\*\*3.5"** (HDD meccanici).**\*\*** Richiedono una gabbia per drive con vassoi, idealmente ammortizzati (gommini antivibrazione). La tendenza negli ultimi anni è di ridurre il numero: molti case moderni ne offrono 2, alcuni "airflow-first" solo 1, alcuni SFF zero. Se avete un archivio di drive meccanici, **\*\*contateli prima\*\***.
- **\*\*2.5"** (SSD SATA e vecchi HDD da laptop).**\*\*** Occupano poco spazio e si montano su vassoi dietro il vassoio della scheda madre o sullo shroud dell'alimentatore. Tipicamente 2-4 posizioni.
- **\*\*M.2** (SSD NVMe).**\*\*** Questi non riguardano il case: si montano direttamente sulla scheda madre. Per questo i case moderni hanno sempre meno alloggiamenti — la maggior parte dei nuovi sistemi non ha drive fisici oltre agli NVMe.

Vale la pena notare che le gabbie per drive da 3.5" frontali, quando presenti, **sono un ostacolo all'airflow**: sono posizionate esattamente dietro le ventole di immissione. I case moderni le rendono rimovibili proprio per questo motivo. Se non vi servono, rimuovetele.

### 3.5 Alimentatore: posizione, lunghezza, shroud

Praticamente tutti i case moderni montano l'unità di alimentazione (**PSU**) in **basso**, con la sua ventola rivolta verso il basso e un filtro antipolvere sotto. Questo isola termicamente la PSU dal resto del sistema: aspira aria fresca da sotto il case e la espelle direttamente sul retro, senza scambiare calore con l'aria interna. Questo è un enorme miglioramento rispetto ai case degli anni 2000, dove la PSU montata in alto aspirava aria calda dalla CPU.

Due implicazioni pratiche:

**1. Il case deve avere piedini sufficientemente alti** (almeno 20-25 mm) perché l'alimentatore possa respirare. Su una moquette a pelo lungo, anche 25 mm potrebbero non bastare: la moquette ostruisce e l'alimentatore si scalda. **Non appoggiare il PC su una moquette.** **2. La lunghezza massima dell'alimentatore** è dichiarata dal case (tipicamente 160-200 mm). Gli alimentatori ATX standard sono profondi 140-160 mm; quelli ad alta potenza (1200 W+) possono arrivare a 180-200 mm. Se il case dichiara 180 mm "senza gabbia dischi frontale" e voi volete la gabbia, il numero effettivo diminuisce.

Lo **shroud dell'alimentatore** (o "basement cover") è la copertura orizzontale in lamiera che nasconde l'alimentatore e i cavi. È estetica ma anche funzionale: crea

un compartimento separato per l'intrico di cavi. Alcuni case hanno uno shroud **perforato**, che permette di montare ventole sopra di esso; altri ne hanno uno solido, il che può essere un problema in un caso specifico: se avete una ventola frontale in immissione bassa e lo shroud la separa dal resto, quell'aria non raggiungerà la GPU.

### 3.6 Gestione dei cavi (cable management)

Lo spazio dietro il vassoio della scheda madre è dove passano tutti i cavi: il 24-pin ATX, gli 8-pin EPS della CPU che devono salire in alto a sinistra, i cavi PCIe/12V-2×6 della GPU, SATA, cavi delle ventole e cavi del pannello frontale.

- **\*\*Spazio dietro il vassoio\*\***: sotto i 20 mm è stretto, 25 mm è accettabile, 30+ mm è comodo. Qui è dove i case economici tagliano gli angoli.
- **\*\*Gommini passacavo (rubber grommets)\*\***: anelli di gomma nei fori del vassoio che nascondono i bordi e tengono fermi i cavi. La loro assenza non è un difetto funzionale, ma estetico e pratico.
- **\*\*Canali e fascette in velcro\*\***: i case moderni ben progettati (Lian Li, Fractal, Phanteks) integrano canali con coperture a scatto e fascette in velcro pre-montate. Fanno una vera differenza nel tempo di assemblaggio.
- Una gestione ordinata dei cavi **\*\*non migliora drasticamente le temperature\*\*** in un case moderno (la maggior parte dei cavi è dietro il vassoio, fuori dal flusso d'aria), ma un fascio di cavi lasciato penzolare davanti alle ventole in immissione le peggiora sicuramente. E soprattutto: il PC dovrà essere riaperto, e trovarlo organizzato è una benedizione.

### 3.7 Montaggio verticale della GPU e riser PCIe

Il montaggio verticale — la scheda grafica ruotata di 90° e rivolta verso il pannello in vetro — è puramente estetico e richiede due cose: una staffa verticale (a volte inclusa, spesso acquistata separatamente) e un **cavo riser PCIe**, che è una prolunga flessibile che porta il segnale dallo slot della scheda madre alla scheda grafica ruotata.

Ci sono due avvertenze serie, e vanno prese sul serio:

**1. La generazione PCIe del riser deve corrispondere.** I riser sono venduti come "PCIe 3.0", "PCIe 4.0" o "PCIe 5.0". Il bus PCIe raddoppia la sua frequenza di segnalazione ad ogni generazione, e l'integrità del segnale su un cavo flessibile diventa progressivamente più difficile. **Un riser PCIe 3.0 usato con una scheda PCIe 4.0/5.0 causa errori di trasmissione**, che si manifestano come crash,

artefatti, schermate nere, o — più insidiosamente — come un downgrade automatico del link a una velocità inferiore che vi costa prestazioni senza dirvelo. Controllate sempre nel BIOS/UEFI o con GPU-Z che il link sia negoziato alla generazione e larghezza (x16) attese. Un riser PCIe 5.0 di qualità costa 60-100 euro **[dato volatile]**; se il budget non lo permette, non montate in verticale.

**2. Il montaggio verticale soffoca la scheda.** Ruotata contro il pannello laterale, la GPU si trova a 15-30 mm dal vetro e le sue ventole aspirano aria da lì. In molti casi, questo significa +8/+15 °C rispetto al montaggio orizzontale. I case progettati per il montaggio verticale (alcuni Lian Li, HYTE Y60/Y70) lasciano più spazio o usano il pannello laterale come presa d'aria. **Se il vostro case non è progettato per questo, il montaggio verticale è un peggioramento termico pagato a caro prezzo.**

---

## 4. Airflow: la discussione seria

### 4.1 Mesh vs. vetro: quanto conta davvero

La domanda più frequente è quella con la risposta più chiara. Il **pannello frontale** è il punto da cui, nella maggior parte dei layout, entra aria fresca. Se il frontale è un pannello in vetro temperato o acrilico solido, l'aria non passa **attraverso** di esso: deve infilarsi nelle fessure laterali (tipicamente 10-20 mm per lato) o superiori. Le ventole in immissione, che sono progettate per lavorare con bassa pressione statica, incontrano un ostacolo e vedono la loro portata effettiva crollare: test in camera anecoica mostrano riduzioni di flusso nell'ordine del 40-70% rispetto alla stessa ventola in aria libera.

L'effetto sui componenti, in test comparativi tra la variante mesh e la variante vetro **dello stesso identico case** (un esperimento eseguito più volte dalla stampa specializzata, ad esempio sui vecchi NZXT H510 vs H510 Flow, o sui Corsair 4000D vs 4000D Airflow), è tipicamente:

- **\*\*GPU: 8-15 °C più alta\*\*** con un pannello frontale chiuso, con conseguente calo del boost sostenuto;
- **\*\*CPU: 3-8 °C più alta\*\***, meno drammatico perché il dissipatore della CPU è più in alto e più vicino alla ventola di scarico posteriore;
- **\*\*Rumore: uguale o superiore\*\*** con un pannello frontale chiuso, perché le ventole devono girare più velocemente e perché l'aria strozzata nelle fessure genera turbolenza.

La conclusione operativa è brutale e non ammette sfumature: **il pannello frontale deve essere in mesh, o almeno avere una superficie aperta significativa e diretta davanti alle ventole**. Il vetro sul frontale è un difetto di progettazione mascherato da caratteristica estetica. Il vetro **laterale**, invece, è quasi sempre innocuo, perché nella stragrande maggioranza dei layout, il lato non è un percorso primario di airflow.

Una piccola nota tecnica per evitare ingenuità: non tutte le "mesh" sono uguali. Una griglia con fori rotondi piccoli e densi e molto materiale tra i fori può avere un'**area aperta** del 40%, mentre una mesh a nido d'ape ben progettata può raggiungere il 65-75%. E i pannelli perforati con motivi decorativi "a maglie strette" per l'estetica sono spesso peggio di quanto sembri. Se una recensione menziona "mesh restrittiva", è un avvertimento.

#### 4.2 Pressione Positiva, Negativa, Neutra

Definiamo con precisione. In uno stato stazionario, la massa d'aria che entra nel case deve essere uguale alla massa che esce — questa è la conservazione della massa, non c'è scelta. Ciò che cambia è **da dove** esce.

- **\*\*Pressione positiva\*\***: Il flusso d'aria delle ventole in immissione è maggiore di quello delle ventole in estrazione. L'aria in eccesso esce attraverso fessure, fori delle staffe e interstizi. Il case è "gonfiato".
- **\*\*Pressione negativa\*\***: Il flusso d'aria in estrazione supera quello in immissione. L'aria mancante viene aspirata attraverso ogni fessura, ogni foro non filtrato, il retro del case, il vano delle staffe PCIe.
- **\*\*Pressione neutra\*\***: Essenzialmente in equilibrio.

Perché ci interessa? **Per la polvere**. In pressione positiva, tutta l'aria in ingresso passa attraverso le ventole di aspirazione, e queste sono l'unico punto dove esistono i **filtri antipolvere**. Entra aria filtrata, e l'aria che esce dalle fessure spinge fuori le particelle di polvere. Il case rimane ragionevolmente pulito, e la polvere si accumula sui filtri, dove può essere rimossa in trenta secondi.

In pressione negativa, l'aria entra dappertutto, e "dappertutto" è non filtrato. La polvere si deposita su dissipatori, alette, schede — dove la pulizia è molto più laboriosa.

**Raccomandazione: leggera pressione positiva**. In pratica, questo significa avere un flusso d'aria in ingresso superiore del 10-30% rispetto a quello in uscita. Attenzione a non confondere però il numero di ventole con il flusso d'aria: tre

ventole in ingresso dietro un filtro denso possono muovere meno aria di due ventole in uscita in aria libera. Il filtro è resistenza, e la resistenza riduce il flusso d'aria.

Va anche detto onestamente, perché online è trattata come una religione: **la differenza termica tra le tre configurazioni è di 1-3 °C**, quasi irrilevante. È la manutenzione, non la temperatura, l'argomento serio per la pressione positiva. Un case in pressione negativa ben ventilato è più fresco di uno in pressione positiva mal ventilato. La priorità rimane il **volume d'aria scambiato**, non il segno del differenziale.


#### 4.3 Percorso del Flusso d'Aria

Due principi guidano la disposizione:

**Principio 1: L'aria calda sale.** Per convezione naturale, l'aria riscaldata si espande, diminuisce di densità e sale. Questo effetto, da solo, è debole rispetto alla ventilazione forzata, ma dà la direzione corretta: **ingresso basso e frontale, uscita alta e posteriore** significa lavorare con la fisica piuttosto che contro di essa.

**Principio 2: Il percorso deve essere breve e diretto.** L'aria fresca deve raggiungere i dissipatori (GPU in basso, CPU a metà-superiore) senza mescolarsi con aria calda già utilizzata.

Il layout canonico, valido per il 90% dei mid tower:



- **\*\*Ingresso frontale (2-3 ventole)\*\*:** aria fresca che colpisce direttamente la scheda grafica, che è il componente che dissipa più calore.
- **\*\*Ingresso inferiore (opzionale, 1-2 ventole)\*\*:** se il case lo permette, le ventole sul fondo davanti alla GPU sono estremamente efficaci, poiché soffiano aria

fresca direttamente nelle ventole della scheda grafica. È una delle configurazioni più sottovalutate e più efficaci in assoluto. Richiede piedini alti e un filtro.

- **\*\*Uscita posteriore (1 ventola, 120 o 140 mm)\*\*:** immediatamente dietro il dissipatore della CPU, espellendo l'aria che vi è appena passata prima che ricircoli.
- **\*\*Uscita superiore (1-3 ventole)\*\*:** raccoglie l'aria calda che sale. Se si monta un radiatore AIO, questa è la sua posizione naturale.

Alcune note controintuitive ma verificate:

- **\*\*Non posizionare ventole di aspirazione in alto.\*\*** Contrastano la convezione e riciclano aria calda dall'AIO.
- **\*\*Il pannello laterale in vetro non è un problema termico\*\*** purché il frontale sia aperto. Chi vuole un lato in vetro può averlo senza sensi di colpa.
- **\*\*In un case a doppia camera come il Lian Li O11\*\***, il frontale è spesso chiuso, e le prese d'aria sono **\*\*il fondo e il lato\*\***. Questi case funzionano molto bene, ma **\*\*solo se li si configura come progettato\*\***: aspirazione dal basso + lato, scarico dall'alto + posteriore. Chi monta tutte le ventole in alto per lo scarico e nessuna presa d'aria crea un vuoto e ottiene temperature pessime.

#### 4.4 Configurazioni tipiche per numero di ventole

| Ventole | Configurazione                                     | Note                                                                                         |
|---------|----------------------------------------------------|----------------------------------------------------------------------------------------------|
| 2       | 1 frontale IN + 1 posteriore OUT                   | Il minimo indispensabile. Accettabile solo per sistemi a bassa potenza (< 250 W totali).     |
| 3       | 2 frontali IN + 1 posteriore OUT                   | Configurazione base sensata. Leggera pressione positiva. La più comune nei case entry-level. |
| 4       | 3 frontali IN + 1 posteriore OUT                   | Ottimo compromesso. Ancora pressione positiva. Standard per case "airflow" di fascia media.  |
| 5       | 3 frontali IN + 1 posteriore OUT + 1 superiore OUT | Bilanciata. Buona per sistemi high-end raffreddati ad aria.                                  |

|    |                                                                       |                                                                                   |
|----|-----------------------------------------------------------------------|-----------------------------------------------------------------------------------|
| 6  | 3 frontali IN + 1 posteriore OUT + 2 superiori OUT                    | Bilanciata/neutra. Configurazione tipica con un AIO da 240/280 in alto.           |
| 7+ | 3 frontali IN + 2/3 inferiori IN + 1 posteriore OUT + 3 superiori OUT | Configurazione da entusiasti. Pressione positiva marcata, ottime temperature GPU. |

**I rendimenti marginali diminuiscono rapidamente.** Il salto da 2 a 4 ventole vale molti gradi. Il salto da 6 a 9 vale 1-2 °C e aggiunge rumore. La quarta ventola è un ottimo investimento; la nona è una decorazione.

#### 4.5 Filtri antipolvere

Un filtro è una rete fine (nylon o acciaio) posta davanti alle prese d'aria. Fa due cose: intrappola la polvere e **resiste al flusso d'aria**. La resistenza costa flusso, tipicamente 10-20% con un filtro pulito e molto di più con un filtro sporco.

Dove sono realmente necessari:

- **\*\*Sotto l'alimentatore\*\***: obbligatorio, e deve essere **\*\*rimovibile da dietro o di lato\*\***, non da sotto (altrimenti bisogna sollevare il PC ogni volta).
- **\*\*Frontale (davanti alle ventole di aspirazione)\*\***: sì, ed è la difesa principale.
- **\*\*Inferiore (se ci sono ventole di aspirazione)\*\***: sì.
- **\*\*Superiore (se le ventole sono in estrazione)\*\***: **\*\*no**, o solo magnetico e rimovibile\*\*. Un filtro su una superficie di estrazione non filtra nulla — l'aria esce — e aggiunge solo resistenza. Serve solo a impedire che la polvere si depositi all'interno **\*\*quando il PC è spento\*\***. Se il vostro case ha un filtro magnetico in alto e il PC è quasi sempre acceso, potete toglierlo e guadagnare qualche punto percentuale di estrazione.

**Manutenzione:** i filtri vanno puliti ogni 1-3 mesi a seconda dell'ambiente (case a terra + animali domestici + fumo = ogni mese). Aria compressa o un semplice risciacquo, con la precauzione di **asciugarli completamente** prima di rimontarli.

---

## 5. Ventole del case

### 5.1 Dimensioni: 120, 140, 200 mm

Una ventola è, fisicamente, un'elica che muove un volume d'aria. A parità di **flusso d'aria** (volume d'aria al secondo), una ventola più grande può ruotare più lentamente, perché ogni rotazione sposta più aria. E poiché il rumore aerodinamico dipende fortemente dalla **velocità periferica delle pale**, ruotare più lentamente significa fare meno rumore.

Ecco perché, **a parità di flusso d'aria, una ventola da 140 mm è più silenziosa di una da 120 mm, e una da 200 mm è più silenziosa di entrambe**. È un principio semplice e affidabile.

Tuttavia, ci sono contro-argomenti pratici:

- Le **\*\*ventole da 140mm hanno meno posizioni di montaggio\*\***. Molti case accettano 3 x 120mm ma solo 2 x 140mm sul frontale, e in quel caso, **\*\*3 x 120mm spostano più aria di 2 x 140mm\*\***, annullando il vantaggio.
- Le **\*\*ventole da 200mm hanno una selezione di modelli molto limitata\*\***, ruotano lentamente (600-800 RPM), hanno una **\*\*pressione statica molto bassa\*\***, e sono quindi inutilizzabili su radiatori o dietro filtri densi. Sono eccellenti per l'immissione libera in case progettati per esse, ma sono una nicchia.
- I **\*\*radiatori da 140mm\*\*** (280, 420) sono leggermente più efficienti delle loro controparti da 120mm (240, 360) a parità di lunghezza, ma sono supportati da meno case.

**Regola generale: usa ventole da 140mm quando il case ne accetta lo stesso numero delle ventole da 120mm; altrimenti, usa ventole da 120mm e sii felice.**

### 5.2 Specifiche: leggerle senza farsi ingannare

Ogni ventola ha una scheda tecnica con quattro numeri chiave. Devono essere letti insieme, mai isolatamente.

**CFM (Cubic Feet per Minute)**. Questo è il **flusso d'aria**, ovvero quanta aria sposta la ventola *in condizioni di resistenza zero*, in aria libera. Valori tipici: 50-80 CFM per una ventola da 120mm, 60-100 per una ventola da 140mm. In Europa, può essere espresso anche in m<sup>3</sup>/h (1 CFM ≈ 1.7 m<sup>3</sup>/h). **Il numero dichiarato è il**



**massimo teorico e non lo vedrai mai nella realtà**, perché c'è sempre resistenza all'interno del case.

**Pressione statica (mmH<sub>2</sub>O, millimetri di colonna d'acqua).** Questa è la capacità della ventola di **spingere l'aria contro la resistenza**. Valori tipici: 1.0-1.5 mmH<sub>2</sub>O per una ventola "airflow", 2.0-3.5 mmH<sub>2</sub>O per una ventola "static pressure" ad alta velocità. Questo è il parametro che conta quando la ventola deve spingere l'aria attraverso:

- le fitte alette di un **\*\*radiatore\*\***;
- le alette di un **\*\*dissipatore ad aria\*\***;
- un **\*\*filtro antipolvere\*\*** denso;
- una griglia frontale restrittiva.

**Quando dare priorità all'uno o all'altro:** una ventola in **immissione libera o scarico libero** (davanti a un buco, essenzialmente) beneficia del flusso d'aria. Una ventola su un **radiatore o dissipatore** beneficia della pressione statica. Una ventola davanti a un filtro è una via di mezzo. Nella realtà del 2026, le migliori ventole "ibride" (Arctic P12/P14, Noctua NF-A12x25, Phanteks T30) sono buone in entrambi i regimi, e la distinzione è meno drammatica di quanto non fosse in passato — tuttavia, è ancora vero che una ventola esplicitamente dichiarata "high airflow" con pale sottili e larghe (come Noctua NF-S12, o le vecchie Corsair AF "airflow") si comporta male su un radiatore.

**RPM (Revolutions Per Minute).** La velocità di rotazione. Insieme al diametro, determina la velocità periferica e quindi il rumore. Una ventola con un range di 200-2000 RPM è molto più versatile di una con un range di 800-1200: la prima può essere resa quasi inudibile a bassi carichi e spinta al massimo sotto stress.

**dBA (decibel A-weighted).** Rumore, misurato con una ponderazione che riflette la sensibilità dell'orecchio umano. **Questo è il numero meno affidabile sulla scheda tecnica**, perché le condizioni di misurazione (distanza, camera anecoica, carico) non sono standardizzate tra i produttori, e perché il dBA non cattura la **qualità** del rumore. Una ventola da 30 dBA con un ronzio a bassa frequenza è più tollerabile di una ventola da 28 dBA con un fischio acuto o un ticchettio del cuscinetto. **I valori dBA dichiarati sono utili solo per confrontare ventole dello stesso produttore.** Per confronti tra marche diverse, fidati di misurazioni indipendenti che normalizzano il rumore (ad esempio, "a 35 dBA, quanti CFM sposta?", che è il modo corretto di confrontare).

Un'ultima insidia: le curve **PQ** (pressione-flusso). Un produttore serio pubblica un grafico che mostra quanta aria eroga la ventola a ogni livello di contropressione. Questo è l'unico dato completo. Noctua, Arctic e Phanteks lo fanno; molti altri no.

### 5.3 PWM (4 pin) vs. DC (3 pin)

Il connettore per le ventole di sistema è **standardizzato**:

| Pin | Funzione                           |
|-----|------------------------------------|
| 1   | GND (Massa)                        |
| 2   | +12 V                              |
| 3   | Sense / Tachometer (legge gli RPM) |
| 4   | <b>PWM</b> (segnale di controllo)  |

Una **ventola a 3 pin** è regolata in **DC (Direct Current)**: la scheda madre abbassa la tensione di alimentazione, da 12 V in giù, e la ventola rallenta. Questo è semplice, ma ha una limitazione: sotto una certa tensione (tipicamente 5-6 V), il motore non ha abbastanza coppia per avviarsi o mantenere la rotazione, quindi la velocità minima è relativamente alta (spesso non scende sotto il 40-50% della velocità nominale).

Una **ventola a 4 pin** usa la **PWM** (Pulse Width Modulation): la tensione rimane sempre a 12 V, ma un segnale a onda quadra (25 kHz per lo standard Intel) accende e spegne rapidamente il circuito di pilotaggio del motore. Variando il **duty cycle** (la percentuale di tempo in cui il segnale è alto), si controlla la velocità. Il vantaggio è enorme: la **coppia di spunto rimane piena**, quindi può scendere a velocità molto basse (10-20%, cioè 200-300 RPM) con avvio affidabile, e il controllo è molto più preciso e lineare.

**Raccomandazione: comprare ventole PWM.** Il costo aggiuntivo è di pochi euro ed è denaro ben speso. Se la vostra scheda madre ha un header a 4 pin (tutte quelle moderne lo hanno), potete comunque impostarlo in modalità DC per pilotare ventole a 3 pin — la maggior parte dei BIOS/UEFI lo permette, e alcuni rilevano automaticamente il tipo.

**Controllo da BIOS/UEFI.** Ogni scheda madre moderna ha una sezione (Q-Fan su ASUS, Smart Fan su Gigabyte/MSI, Fan Xpert, ecc.) dove si definisce una **curva della ventola**: una funzione che lega la velocità della ventola a una temperatura di riferimento. Tre consigli non banali:

1. **Scegliere la giusta sorgente di temperatura.** Se si collegano le ventole del case alla temperatura del **package della CPU**, si avranno ventole che accelerano e rallentano costantemente, perché la temperatura di una CPU moderna fluttua di 20 °C in mezzo secondo a ogni micro-carico. Il risultato è il famigerato **fan surging**, il "rantolo" del PC, ed è molto più fastidioso di un rumore costante. Invece, collegarle alla temperatura della **scheda madre / VRM / chipset** (una grande massa termica che cambia lentamente) o, se il BIOS lo permette, alla GPU.

2. **Usare lo "smoothing" / "step up-down time":** quasi tutti i BIOS permettono di impostare un ritardo (in secondi) prima che la ventola reagisca a un cambiamento. Impostatelo a 3-6 secondi. Questo elimina quasi completamente il surging.

3. **Non puntare allo zero-RPM sul case.** Alcune ventole si fermano completamente sotto una certa soglia. Questo va bene per la GPU; per le ventole del case, un flusso minimo permanente a 400-500 RPM è inudibile e mantiene l'aria in movimento.

**Hub e daisy-chain.** Le schede madri hanno tipicamente 4-7 header per ventole, e un case ben popolato può averne 8-9. Soluzioni:

- **\*\*Hub / splitter passivo\*\*:** uno splitter che collega più ventole a un singolo connettore. Attenzione: **\*\*ogni connettore ha un limite di corrente\*\***, tipicamente 1 A (12 W). Una ventola PWM consuma 0,1-0,3 A, quindi 3-4 ventole per connettore è il limite prudente. Inoltre, solo **\*\*una\*\*** ventola può riportare il segnale del tachimetro; le altre vengono ignorate (quindi il BIOS mostrerà un solo valore di RPM).
- **\*\*Hub attivo\*\*:** alimentato direttamente dall'alimentatore (con un connettore SATA o Molex) e riceve solo il segnale PWM dalla scheda madre. Può gestire 6-10 ventole senza problemi. Questa è la soluzione corretta per un sistema con molte ventole, e molti case di fascia media/alta ne includono uno.
- **\*\*Daisy-chain\*\*:** alcune serie di ventole (Lian Li Uni Fan, Corsair iCUE Link, Phanteks D30) si agganciano fisicamente l'una all'altra e trasmettono alimentazione e dati tramite contatti, eliminando quasi tutti i cavi. Questa è una soluzione molto elegante per la gestione dei cavi ed è una delle ragioni per cui questi prodotti sono costosi. Lo svantaggio: **\*\*ti legano a un ecosistema proprietario\*\***, con un controller dedicato e un software dedicato.

## 5.4 Cuscinetti

Il cuscinetto è ciò che supporta l'albero rotante. Determina **il rumore meccanico, la durata e l'orientamento di montaggio consentito**.

| <b>Tipo</b>                           | <b>Descrizione</b>                                                | <b>Durata tipica (MTBF)</b> | <b>Rumore</b>                   | <b>Note</b>                                                                                                                     |
|---------------------------------------|-------------------------------------------------------------------|-----------------------------|---------------------------------|---------------------------------------------------------------------------------------------------------------------------------|
| <b>A strisciamento</b> (Sleeve)       | Boccola cilindrica lubrificata a olio                             | 20.000-30.000 h             | Silenzioso da nuovo             | Il lubrificante fuoriesce se montato <b>orizzontalmente</b> ; si usura e diventa rumoroso. Economico.                           |
| <b>A sfera</b> (Ball bearing)         | Sfere in gabbia                                                   | 50.000-75.000 h             | Più rumoroso (ronzio/ticchetto) | Durevole, tollera il calore e qualsiasi orientamento. Utilizzato in ambienti server.                                            |
| <b>FDB</b> (Fluid Dynamic Bearing)    | A strisciamento con film d'olio a pressione idrodinamica e tenuta | 60.000-150.000 h            | Molto silenzioso                | <b>Il miglior compromesso</b> . Standard de facto nelle ventole di qualità. Nomi commerciali: SSO2 (Noctua), Rifle, Hydro, HDB. |
| <b>Maglev / Levitazione magnetica</b> | Albero supportato da campo magnetico, quasi senza attrito         | 100.000+ h                  | Estremamente silenzioso         | Costoso, marketing pesante, benefici reali ma marginali rispetto a un buon FDB.                                                 |

**Regola d'acquisto: cerca FDB (o equivalenti commerciali) e ignora tutto il resto.** I cuscinetti a strisciamento sono accettabili solo nelle ventole preinstallate in case economiche e solo se montati verticalmente. Maglev è un lusso.

Un'ultima osservazione onesta: le durate MTBF (Mean Time Between Failures) dichiarate—150.000 ore sono 17 anni—sono estrapolazioni statistiche da test accelerati, non promesse. Servono per confronto, non per pianificazione.

### 5.5 Marche di ventole

| Marchio         | Modelli di riferimento                           | Prezzo indicativo (ciascuno) | Posizionamento                                                                                                                                                                                                                                            |
|-----------------|--------------------------------------------------|------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Arctic</b>   | P12 / P14 (PWM PST), P12 Max                     | 6-13 €                       | <b>Il re assoluto del rapporto qualità/prezzo.</b><br>Prestazioni 3-5% inferiori ai top, un quinto del prezzo. Estetica spartana, cavo leggermente rigido. Se il budget conta, questa è la risposta.                                                      |
| <b>Noctua</b>   | NF-A12x25 (il riferimento), NF-A14, NF-P12 redux | 20-35 €                      | Lo standard tecnico aureo. Tolleranze minime (0.5 mm di distanza dalla pala), eccellente pressione statica e flusso d'aria, silenziosità esemplare, 6 anni di garanzia. Colore marrone-beige divisivo (esiste la linea "chromax" nera, che costa di più). |
| <b>Phanteks</b> | T30-120                                          | 25-35 €                      | Ventola spessa 30 mm, tre modalità di velocità, prestazioni fuori scala sui radiatori. Ingombro non standard.                                                                                                                                             |

|                     |                           |                             |                                                                                             |
|---------------------|---------------------------|-----------------------------|---------------------------------------------------------------------------------------------|
| <b>be quiet!</b>    | Silent Wings 4 / Pro 4    | 20-30 €                     | Focalizzate sul silenzio. Eccellenti, un gradino sotto Noctua nella pressione statica.      |
| <b>Lian Li</b>      | Uni Fan SL/TL/SL-Infinity | 20-30 € (kit da 3: 60-90 €) | Daisy-chain, RGB spettacolare, buone prestazioni. Ecosistema chiuso.                        |
| <b>Corsair</b>      | RS/QX, iCUE Link LX/RX    | 20-35 €                     | Buone, ma il valore è nel software iCUE e nell'ecosistema Link. Costose.                    |
| <b>Thermalright</b> | TL-C12 / TL-B12           | 5-9 €                       | Alternativa cinese molto economica, sorprendentemente buona. Qualità costruttiva variabile. |

**[dati volatili: i prezzi cambiano frequentemente e i modelli vengono aggiornati ogni 18-24 mesi.]**

**Quando ha senso spendere.** Il salto da una ventola generica preinstallata a una Arctic P12 vale molto: migliori temperature, minor rumore, 8 euro. Il salto da una Arctic P12 a una Noctua NF-A12x25 vale 25 euro in più per **2-4 °C e un paio di dB**. Ne vale la pena se: (a) il PC è a mezzo metro dalla testa in una stanza silenziosa; (b) la ventola è su un radiatore o un dissipatore, dove si esprime la superiorità di Noctua nella pressione statica; (c) si è già ottimizzato tutto il resto. **Non ne vale la pena** se si ha ancora una GPU asfittica in un case chiuso: prima si sistema il case.

## 6. Marchi di Case

Non esiste un "migliore assoluto": ci sono aziende con filosofie e livelli di raffinatezza diversi. Ecco la panoramica, con l'avvertenza che **i modelli specifici invecchiano rapidamente** e vanno verificati **[dati volatili]**.

**Lian Li.** Storicamente produttore di alluminio premium, oggi il nome più forte nel segmento enthusiast grazie alla famiglia **O11** (O11 Dynamic, O11 Dynamic EVO, EVO XL e derivati). Si tratta di case a doppia camera: la camera principale ospita la scheda madre e la GPU, mentre la camera laterale nasconde l'alimentatore e i cavi. Offrono un enorme supporto per i radiatori (fino a tre radiatori da 360mm). Ottima costruzione, ergonomia superba. **Nota: il pannello frontale è chiuso.** Vanno configurati con immissione dal basso e dal lato. L'O11 Vision e le versioni "acquario" con tre pannelli in vetro richiedono ancora più cura. Ottima anche la linea **Lancool** (203/216/207); è la loro offerta "airflow-first" a prezzi molto più contenuti e spesso offre il miglior rapporto qualità-prezzo dell'intero mercato.

**Fractal Design.** L'azienda svedese con la migliore reputazione per design e finiture. Tre linee da conoscere: **Meshify** (airflow-first, frontale in mesh angolare, archetipo del case ben ventilato), **North** (estetica scandinava con frontale in legno di noce — e, notevole, con una vera mesh dietro il legno, rendendolo bello e funzionale), **Torrent** (il case da airflow estremo, con due enormi ventole frontali da 180mm, prestazioni termiche di riferimento, e un layout molto particolare). Inoltre, la linea **Define** per chi vuole ancora la insonorizzazione. Costruzione, tolleranze e accessori sono sempre di prim'ordine. Prezzi medio-alti.

**be quiet!** Azienda tedesca. Storicamente focalizzata sul silenzio (le linee **Silent Base**, **Dark Base**), ma con un deciso spostamento verso l'airflow con le linee **Pure Base 500DX / 500FX** e **Shadow Base**. Le ventole incluse sono di ottima qualità (le loro ventole sono un vero punto di forza). Costruzione solida, estetica sobria e "adulta".

**Corsair.** Ampia gamma di prodotti, dal **4000D Airflow** (per anni la scelta predefinita per un mid-tower economico e ben ventilato) alla serie **iCUE** con il suo ecosistema RGB e sensori integrati. Software iCUE potente ma pesante. Qualità solida, prezzi medi. La versione "Airflow" di ogni modello è quella da comprare; la versione semplice con pannello frontale chiuso no.

**NZXT.** Estetica minimalista molto riconoscibile (la linea **H**). Storicamente, hanno sbagliato l'airflow (l'H510 con il suo pannello frontale chiuso è un esempio da manuale di questo errore) e poi lo hanno corretto con le versioni **Flow**. Buona costruzione, prezzi un po' alti per quello che offrono, ottima ergonomia interna. Se comprate NZXT, comprate un modello Flow.

**Phanteks.** Molto apprezzata dagli appassionati. Linee **Eclipse** (P400/P500 e derivati) e **NV** (case in vetro a doppia camera). Ottima ingegnerizzazione interna, molte soluzioni intelligenti per il cable management, spesso configurazioni di ventole generose.

**Cooler Master.** Gamma molto ampia, qualità variabile. L'**NR200 / NR200P** è il punto di riferimento negli SFF accessibili. La vecchia serie **MasterBox** è stata per anni la scelta economica. Verificare modello per modello: la coerenza qualitativa non è il loro forte.

**Montech, DeepCool, Antec, Thermaltake.** Il segmento budget aggressivo.

**Montech** in particolare (serie AIR, King, XR) si è guadagnata una notevole reputazione offrendo case con 3-6 ventole ARGB incluse a prezzi che vanno dai 60-90 euro, con una costruzione onesta. **DeepCool** (serie CH e Morpheus) è simile. Sono la scelta razionale per chi ha un budget limitato: **si accetta lamiera più sottile e finiture meno raffinate in cambio di un ottimo airflow e ventole incluse.** Questo è un compromesso molto più intelligente che comprare un case "premium" chiuso.

## 6.1 Cosa distingue un case ben progettato

Al di là del marchio, ecco i segni concreti di qualità, che potete verificare in una video recensione:

1. **Spessore della lamiera** (0,8-1,0 mm nei casi ben fatti, 0,55-0,6 mm in quelli economici). La lamiera sottile flette, vibra e risuona.
2. **Bordi arrotondati**, senza tagli netti.
3. **Tolleranze**: i pannelli si incastrano, le viti entrano senza forzare, il vetro non "sfrega".
4. **Ergonomia di montaggio**: canali per i cavi, fascette in velcro preinstallate, punti di ancoraggio, fan hub incluso, staffa PSU rimovibile, filtri rimovibili senza smontare nulla.
5. **Dotazione ventole**: quante sono incluse e di che qualità. Un case da 90 euro con 4 ventole PWM decenti costa meno di un case da 80 euro con zero ventole (a cui vanno aggiunti 40 euro di Arctic P12).
6. **Front I/O**: numero e tipo di porte USB. Nel 2026, pretendete almeno **una USB-C** (idealmente USB 3.2 Gen 2 a 10 Gbps o superiore) e verificate che la scheda madre abbia l'header interno corrispondente — è un classico errore comprare un case con USB-C frontale e una scheda madre economica che non ha l'header per collegarla.
7. **Documentazione e ricambi**: i produttori seri vendono ricambi (viti, filtri, pannelli, piedini). Fractal, Lian Li, be quiet! lo fanno.

---



## 7. Come scegliere: la procedura

Seguite quest'ordine. **L'ordine è il punto:** invertirlo è la causa di quasi tutti i cattivi acquisti.

**Passo 1 — Formato scheda madre.** Avete già scelto la scheda madre (o almeno il suo formato). Questo definisce il minimo: ITX → tutto; mATX → mid/mini tower; ATX → mid tower o più grande; E-ATX → controllate la **larghezza in millimetri**, non la sigla.

**Passo 2 — Spazi di ingombro (clearance).** Segnatevi i tre numeri della vostra configurazione e confrontateli con le specifiche tecniche del case, con un margine:

- lunghezza **\*\*GPU\*\*** (modello specifico) + 15 mm di margine per i cavi;
- altezza **\*\*dissipatore CPU\*\*** + 5 mm;
- dimensioni e spessore **\*\*radiatore\*\*** (se AIO) e sua posizione;
- lunghezza **\*\*PSU\*\***;
- numero di **\*\*drive da 3.5"\*\*\***.

**Passo 3 — Airflow.** Il frontale **deve** essere a mesh o comunque avere un percorso diretto per l'aria. Se non lo è, il case è escluso — a meno che non sia un dual-chamber pensato per prendere aria dal basso e dal lato, in quel caso va bene ma va configurato correttamente. Controllate quante posizioni per ventole ci sono e dove.

**Passo 4 — Qualità e dotazioni.** Quante ventole sono incluse? Di che tipo (PWM o 3-pin)? C'è un hub? Qual è lo spessore della lamiera? Quanto spazio c'è dietro il tray? **Calcolate il costo totale reale:** prezzo case + ventole aggiuntive necessarie.

**Passo 5 — Estetica.** Ora, e solo ora, scegliete quello che vi piace di più tra quelli che sono sopravvissuti ai passi 1-4.

**Passo 6 — Budget.** Se la vostra scelta preferita supera il budget, tornate al passo 5 e scegliete la seconda. Non tornate al passo 3.

### 7.1 Errori tipici dell'acquirente

**1. Il case "acquario".** Tre pannelli di vetro, illuminazione RGB, zero prese d'aria. Fa un figurone in foto e cuoce i componenti. Se proprio lo volete, sappiate che state pagando 10-15 °C sulla GPU, e almeno configuratelo con robuste ventole in estrazione e in immissione dal basso, se possibile.

**2. Comprare il case prima della GPU.** La scheda grafica è il componente più ingombrante e variabile. Sceglierla prima, o almeno decidete il tier e prendete un case con clearance generosa (350+ mm).

**3. Fidarsi della designazione del chip invece che del modello.** "Ci sta una RTX 5080?" non è una domanda con una sola risposta. La domanda giusta è: "Ci sta questa specifica RTX 5080, che è lunga 336 mm e spessa 3.2 slot?".

**4. Case senza ventole incluse.** Alcuni case, specialmente quelli "minimalisti premium", sono venduti con zero o una sola ventola. Il prezzo sembra competitivo finché non aggiungi 40-70 € di ventole. **Fai il conto del costo totale.**

**5. Ignorare la rumorosità dei pannelli.** Un pannello laterale sottile che vibra a una certa frequenza può rendere insopportabile un sistema altrimenti silenzioso. Questo difetto non compare in nessuna scheda tecnica: lo scopri solo nelle recensioni.

**6. Mettere tutte le ventole in estrazione.** "Più aria esce, più è fresco" è un ragionamento fallace. Il case va in depressione, l'aria entra da ogni fessura (non filtrata) e il flusso d'aria effettivo cala perché le ventole lavorano contro un'enorme resistenza. Serve un percorso: **l'aria entra da qualche parte, esce da qualche altra.**

**7. Montare le ventole al contrario.** Ogni ventola ha una direzione. Il flusso d'aria va **dal lato con la griglia di supporto del motore verso il lato con le pale** — o, più semplicemente: guarda le **frecce stampate sul telaio della ventola** (una indica il flusso d'aria, l'altra la direzione di rotazione). In assenza di frecce: l'aria esce dal lato dove si trovano i quattro/sette montanti che sorreggono l'hub.

**8. Il PC per terra su tappeto.** Ostruisce la presa d'aria dell'alimentatore e trasforma il fondo in un aspirapolvere. Almeno una superficie rigida, preferibilmente rialzata.

**9. Scegliere SFF come prima build.** Porta a un costoso vicolo cieco.

**10. Trascurare l'header USB-C.** Verifica che la scheda madre abbia il connettore interno "USB 3.2 Gen 2 Type-C" (20-1 pin) se il case ha una USB-C frontale. Altrimenti, quella porta resterà un buco decorativo.

## 7.2 Raccomandazioni per fascia di prezzo

**[Dati volatili: prezzi e modelli. Verificare prima dell'acquisto.]**

**Entry (50-90 €).** L'obiettivo è massimizzare il flusso d'aria e le ventole incluse, accettando lamierino sottile e finiture semplici. Guarda **Montech** (serie AIR / XR), **DeepCool** (serie CH), **Cooler Master** (MasterBox), **Lian Li Lancool 207/216** se il prezzo scende in questa fascia. Cerca: frontale mesh, 3-4 ventole incluse (idealmente PWM), supporto GPU  $\geq 330$  mm, cooler  $\geq 160$  mm. Non cercare: vetro su tre lati, RGB elaborato.

**Mid (90-160 €).** Questa è la fascia con il miglior rapporto qualità-prezzo dell'intero mercato. **Fractal Design North / Pop Air / Meshify**, **Lian Li Lancool 216/207**, **Corsair 4000D Airflow**, **be quiet! Pure Base 500DX**, **Phanteks Eclipse**, **NZXT H7 Flow**. Aspettati: lamierino dignitoso, ottima ergonomia, 3-4 ventole di qualità incluse, supporto AIO da 360, cable management curato, USB-C frontale. **Se non hai esigenze particolari, il tuo case è qui.**

**High-end (160-300+ €).** Si paga la qualità costruttiva, l'alluminio, la modularità, gli ecosistemi di ventole, il supporto multi-radiatore. **Lian Li O11 Dynamic EVO / EVO XL**, **Fractal Design Torrent** (il campione delle temperature) o **Define/Meshify 2 XL**, **be quiet! Dark Base**, **Hyte Y70**. Compra per un motivo specifico: custom loop, doppio radiatore da 360mm, GPU verticale ben progettata, forte esigenza estetica. **Non comprarlo aspettandoti temperature drasticamente migliori di un buon case da 120 euro: la differenza c'è ma è piccola.**

**Nota sugli SFF.** In questo formato, non esiste un entry-level sensato. Il biglietto d'ingresso serio parte dal Cooler Master NR200P (~100 €) e sale rapidamente, ma va aggiunto al premium per un alimentatore SFX (+40-70 €) e spesso un cooler low-profile e una GPU corta. **Il costo reale di un SFF è 150-300 € più alto di un mid-tower equivalente.**

---

## 8. Riepilogo Operativo — Lista di Controllo per la Scelta del Case

Stampalo, o copialo in un file, e compilalo prima di ordinare.

### A. Vincoli Dimensionali (obbligatorio: se uno fallisce, il case è escluso)

- [ ] **\*\*Formato scheda madre\*\***: la mia mobo è \_\_\_\_ (ITX / mATX / ATX / E-ATX di \_\_\_\_ mm di larghezza). Il case la supporta? **\*\*Sì / No\*\***
- [ ] **\*\*Lunghezza GPU\*\***: il mio modello specifico è lungo \_\_\_\_ mm. Il case dichiara \_\_\_\_ mm **\*\*nella configurazione che userò\*\*** (con radiatore/ventole frontali installate). Margine  $\geq 15$  mm? **\*\*Sì / No\*\***

- ☐ **\*\*Spessore GPU\*\***: \_\_\_\_\_ slot. Il case ha abbastanza slot liberi sotto? **\*\*Sì / No\*\***
- ☐ **\*\*Spazio per il cavo 12V-2×6\*\*** (se la GPU lo usa): il pannello laterale è a  $\geq 30$  mm dal connettore? **\*\*Sì / No\*\***
- ☐ **\*\*Altezza dissipatore CPU\*\***: il mio è alto \_\_\_\_\_ mm. Il case dichiara \_\_\_\_\_ mm. Margine  $\geq 5$  mm? **\*\*Sì / No\*\***
- ☐ **\*\*Radiatore\*\*** (se AIO): dimensione \_\_\_\_\_ (240/280/360/420), spessore radiatore + ventola \_\_\_\_\_ mm. Il case lo supporta nella posizione \_\_\_\_\_ (superiore/frontale)? Interferisce con RAM o dissipatori VRM? **\*\*Sì / No\*\***
- ☐ **\*\*Lunghezza PSU\*\***: il mio è profondo \_\_\_\_\_ mm. Il case dichiara \_\_\_\_\_ mm (con le gabbie che intendo mantenere). **\*\*OK / KO\*\***
- ☐ **\*\*Drive da 3.5"\*\*\***: me ne servono \_\_\_\_\_. Il case ne accetta \_\_\_\_\_. **\*\*OK / KO\*\***

## B. Flusso d'aria (obbligatorio)

- ☐ Il **\*\*frontale è a mesh\*\*** o ha un percorso diretto per il flusso d'aria davanti alle ventole? Se è chiuso, è un design a doppia camera progettato per aspirare aria dal basso/lato? **\*\*Sì / No — se No, scartare.\*\***
- ☐ Quante **\*\*posizioni per ventole\*\*** ci sono? Frontali \_\_\_\_ / Superiori \_\_\_\_ / Posteriori \_\_\_\_ / Inferiori \_\_\_\_ / Laterali \_\_\_\_
- ☐ Posso ottenere almeno la configurazione minima **\*\*3 IN (frontali) + 1 OUT (posteriore)\*\***? **\*\*Sì / No\*\***
- ☐ Ci sono **\*\*filtri antipolvere\*\*** su tutte le prese d'aria, e sono **\*\*rimovibili senza smontare il PC\*\***? **\*\*Sì / No\*\***
- ☐ I **\*\*piedini\*\*** sono alti  $\geq 20$  mm per l'aspirazione dell'aria della PSU? **\*\*Sì / No\*\***

## C. Qualità e Caratteristiche

- ☐ **\*\*Quante ventole sono incluse?\*\*\*** \_\_\_\_\_ — di che tipo? (PWM 4-pin / DC 3-pin) — di che qualità?
- ☐ **\*\*Costo totale reale\*\*** = prezzo case (\_\_\_\_\_ €) + ventole aggiuntive (\_\_\_\_\_ €) = \_\_\_\_\_ €
- ☐ È incluso un **\*\*hub per ventole\*\***? **\*\*Sì / No\*\*** — La mia mobo ha abbastanza connettori? \_\_\_\_\_
- ☐ Lo **\*\*spazio dietro il vassoio della scheda madre\*\*** è  $\geq 25$  mm? **\*\*Sì / No\*\***
- ☐ Ci sono **\*\*gommini passacavo, canali per cavi, fascette in velcro\*\***? **\*\*Sì / No\*\***

- [ ] Le recensioni riportano **lamiera sottile, vibrazioni, tolleranze scadenti, bordi taglienti**? **Sì / No**
- [ ] Il **pannello I/O frontale** ha una **USB-C**? E la mia scheda madre ha l'apposito **header interno**? **Sì / No**

#### D. Configurazione, dopo l'acquisto

- [ ] **Ventole frontali/inferiori come immissione**, **ventole posteriori/superiori come estrazione**. Frecce di direzione controllate su ogni ventola.
- [ ] **Leggera pressione positiva**: flusso d'aria in ingresso  $\geq$  flusso d'aria in uscita.
- [ ] Curve delle ventole nel BIOS/UEFI **legate a una sorgente lenta** (mobo/VRM/GPU), **non al package della CPU**, con smussatura di 3-6 secondi.
- [ ] **Gabbie da 3.5" rimosse** se non necessarie, per liberare il flusso d'aria frontale.
- [ ] **Staffette degli slot PCIe inutilizzati reinstallate** al loro posto.
- [ ] **Filtro superiore** rimosso se il PC è quasi sempre acceso e la parte superiore è tutta in estrazione (opzionale).
- [ ] **Standoff** controllati: uno per ogni foro della scheda madre, **nessun extra**.
- [ ] Test di validazione: dopo 20 minuti di stress test combinato CPU+GPU, la temperatura della GPU è **inferiore a 80 °C** e la CPU non va in throttling termico. Se no, il problema è il case o la configurazione delle ventole, non il dissipatore.
- [ ] **Promemoria manutenzione**: pulire i filtri ogni **1-3 mesi**.

#### E. Le tre regole d'oro, se dimenticate tutto il resto

**1. Il frontale deve respirare.** Mesh, non vetro. **2. Misurate la GPU prima di comprare il case.** Il modello specifico, in millimetri. **3. Quattro buone ventole in un case da 100 euro battono due ventole in un case da 250 euro.** Il volume di aria scambiata è ciò che raffredda; tutto il resto è secondario.

---

*Fine capitolo. Il prossimo capitolo — la periferica di visualizzazione (il monitor) — conclude la parte consumer prima di passare all'hardware professionale e workstation.*

## Capitolo 8 - Il raffreddamento

### 8.1 Perché serve il raffreddamento: la fisica prima del marketing

Ogni componente elettronico attivo in un computer è, dal punto di vista termodinamico, un convertitore di energia elettrica in energia termica. Questa affermazione suona brutale ma è letteralmente vera: un processore non "consuma" corrente per produrre computazione e poi dissipa un po' di calore come effetto collaterale. Un processore assorbe potenza elettrica e la restituisce interamente all'ambiente sotto forma di calore. La computazione — l'informazione, il risultato dell'operazione — non porta via energia. Se una CPU (Central Processing Unit) assorbe 200 watt dalla linea a 12 volt della scheda madre, quei 200 watt diventano 200 watt termici da dissipare. Non 180, non 150: duecento. Il sistema di raffreddamento non è quindi un accessorio che "aiuta" il processore: è l'unica via d'uscita per l'energia che vi entra, e la sua efficacia determina direttamente la frequenza operativa, la stabilità e la durata del componente.

La ragione per cui questo calore è un problema risiede nella fisica del silicio. Un MOSFET (Metal-Oxide-Semiconductor Field-Effect Transistor, il blocco elementare di ogni circuito digitale moderno) commuta tra uno stato di acceso e uno di spento; ad ogni commutazione, dissipa energia per caricare e scaricare le capacità parassite del circuito, e inoltre perde continuamente energia a causa delle correnti di leakage che fluiscono attraverso il dispositivo anche quando dovrebbe essere spento. La corrente di leakage aumenta in modo fortemente non lineare con la temperatura. È qui che inizia il circolo vizioso termico: un chip caldo dissipa più potenza a parità di lavoro, e dissipando più potenza, si scalda ancora di più. Contemporaneamente, la mobilità dei portatori di carica nel silicio diminuisce all'aumentare della temperatura, il che significa che i transistor commutano più lentamente, e per mantenere la stessa frequenza sarebbe necessaria più tensione — il che a sua volta produce più calore. Da qui il fatto osservabile, verificabile su qualsiasi banco di prova, che una CPU ben raffreddata consuma *meno* watt della stessa unità mal raffreddata, pur svolgendo esattamente lo stesso lavoro.

La seconda ragione per cui il calore deve essere controllato è la degradazione a lungo termine. Fenomeni come l'elettromigrazione (la migrazione fisica di atomi metallici nelle tracce di interconnessione, spinta dal flusso di elettroni) e il NBTI (Negative Bias Temperature Instability, uno spostamento progressivo della

tensione di soglia dei transistor) hanno una dipendenza esponenziale dalla temperatura, tipicamente descritta da un'equazione di Arrhenius. In termini pratici: un chip che opera a 90 °C invecchia significativamente più velocemente di uno che opera a 70 °C. Questo non significa che una CPU a 90 °C si romperà domani — i produttori dimensionano i limiti proprio per garantire la vita utile attesa anche al limite — ma significa che il margine termico è un margine di longevità e di silenziosità, non solo di prestazioni.

### 8.1.1 Throttling: il freno d'emergenza

Poiché il chip non può fisicamente impedire a sé stesso di scaldarsi, i produttori hanno integrato nel silicio sensori di temperatura distribuiti (DTS, Digital Thermal Sensor) e logiche di protezione. Quando la temperatura del die raggiunge una soglia chiamata  **$T_{jmax}$**  (maximum junction temperature, ovvero la massima temperatura consentita alla giunzione del transistor), il processore riduce automaticamente frequenza e voltaggio per rientrare nei limiti. Questo fenomeno si chiama **thermal throttling**. Se, nonostante il throttling, la temperatura continua a salire fino a una seconda soglia critica, interviene **THERMTRIP**, un segnale hardware che spegne immediatamente la macchina per prevenire danni permanenti.

Il throttling non è un malfunzionamento: è il sistema che lavora come previsto. Ma è anche un segno inequivocabile che il sistema di raffreddamento è sottodimensionato per il carico. L'utente lo percepisce come improvvisi cali di frame rate nei giochi, tempi di rendering che peggiorano man mano che il lavoro procede (i primi minuti sono veloci, poi rallenta), e benchmark che restituiscono punteggi inferiori alla seconda esecuzione rispetto alla prima.

È importante capire che i processori moderni non hanno più una frequenza "di targa" garantita in ogni condizione. Dal 2015 circa, sia Intel che AMD hanno adottato algoritmi di boost opportunistici — Intel Turbo Boost / Thermal Velocity Boost, AMD Precision Boost 2 e PBO (Precision Boost Overdrive) — che aumentano la frequenza finché non viene raggiunto *uno qualsiasi* dei limiti: limite di corrente, limite di potenza, limite di temperatura. Il primo limite raggiunto è quello che governa. Di conseguenza, il dissipatore non si limita a "impedire il throttling": il dissipatore *determina la frequenza operativa*. Un Ryzen 9 o un Core i9 con un dissipatore mediocre non si romperà; semplicemente, andrà più lento e sarà più rumoroso. Il dissipatore, in questa architettura, è a tutti gli effetti una componente prestazionale.

### 8.1.2 TDP, PL1/PL2, PPT: decodificare i numeri di potenza

Qui dobbiamo essere chirurgici, perché il marketing ha reso questi acronimi quasi inutili se presi alla lettera.

**TDP** sta per *Thermal Design Power*. Storicamente, era la potenza termica, espressa in watt, che il sistema di raffreddamento doveva essere in grado di dissipare affinché il processore operasse alle sue specifiche nominali. Il problema è che nessuno dei due maggiori produttori oggi usa TDP come sinonimo di "consumo massimo".

Per **Intel**, la nomenclatura moderna distingue:

- **\*\*PBP\*\*** (Processor Base Power), che ha sostituito la vecchia denominazione TDP: è la potenza dissipata quando il processore opera alla sua *\*frequenza base\** con tutti i core attivi. È un valore conservativo e, nell'uso reale, quasi mai rappresentativo.
- **\*\*MTP\*\*** (Maximum Turbo Power): la potenza massima in condizioni di boost. È questo il dato che conta per il dimensionamento del dissipatore.
- **\*\*PL1\*\*** e **\*\*PL2\*\*** (Power Limit 1 e Power Limit 2): PL1 è il limite di potenza sostenuta a lungo termine, PL2 è il limite di picco consentito per un intervallo di tempo chiamato **\*\*Tau\*\***. Nelle configurazioni desktop di fascia alta, molti produttori di schede madri impostano di default PL1 = PL2 e Tau infinito, il che significa che il processore opera *\*sempre\** al suo limite di picco. È proprio per questo che un processore dichiarato "125 W" può assorbire 250 W in un rendering, senza che nulla si rompa.

Per **AMD**, sulle piattaforme AM4 e AM5, l'acronimo chiave è **PPT** (Package Power Tracking), il limite di potenza complessiva assorbita dal package. La relazione approssimativa storicamente usata è  $PPT \approx TDP \times 1,35$ : un processore dichiarato 105 W ha un PPT attorno ai 142 W, uno dichiarato 170 W arriva a circa 230 W. AMD affianca al PPT altri due limiti, **TDC** (Thermal Design Current, corrente sostenuta erogabile dal VRM in condizioni termiche stabilizzate) ed **EDC** (Electrical Design Current, corrente di picco istantanea); il VRM (Voltage Regulator Module, il modulo di regolazione della tensione della scheda madre, trattato nel capitolo sulle schede madri) è il circuito che eroga fisicamente questa corrente.

La conseguenza pratica è una sola, e andrebbe scolpita nella pietra: **non si sceglie un dissipatore guardando il TDP della CPU; lo si sceglie guardando il consumo reale sotto carico pesante** (MTP per Intel, PPT per AMD, o ancora



meglio, le misurazioni indipendenti nelle recensioni). Un utente che compra un dissipatore "adatto fino a 150 W" per un processore "con TDP di 125 W" che in Cinebench assorbe 250 W ha fatto un errore di dimensionamento del 60%.

### 8.1.3 Il concetto che conta davvero: la resistenza termica

Se c'è una grandezza che vale la pena imparare, è questa. Un sistema di raffreddamento può essere descritto da una **resistenza termica**, misurata in gradi Celsius per watt (°C/W). Essa lega la potenza dissipata alla differenza di temperatura tra il chip e l'aria ambiente:

$$\Delta T = P \times R_{th}$$

$$\text{oppure: } T_{CPU} = T_{ambiente} + (Potenza \text{ in watt} \times \text{Resistenza termica in } ^\circ\text{C/W})$$

Un buon dissipatore a torre a doppia ventola ha una resistenza termica complessiva (dal die all'aria) nell'ordine di 0,10–0,15 °C/W a velocità media delle ventole. Facciamo i conti: con 200 W dissipati e una  $R_{th}$  di 0,13 °C/W, la differenza termica è di 26 °C. Se l'aria all'interno del case è a 35 °C (non 22, perché all'interno del case fa più caldo che nella stanza), la CPU si assesterà attorno ai 61 °C. Con lo stesso dissipatore e un processore da 280 W, la differenza diventa 36 °C, arrivando a 71 °C. Con un dissipatore economico a 0,25 °C/W e 280 W, la differenza sarebbe di 70 °C, portando a 105 °C, il che significa throttling permanente.

Questo modello, per quanto semplificato, spiega quasi tutto ciò che si osserva nella realtà: spiega perché raddoppiare la superficie del dissipatore non dimezza le temperature (perché la resistenza termica totale è la somma di più resistenze in serie, e quella della pasta termica e dell'IHS non cambia), spiega perché la temperatura ambiente conta uno a uno (ogni grado in più nella stanza è un grado in più sulla CPU), e spiega perché il confronto tra dissipatori va sempre fatto a parità di potenza dissipata e temperatura ambiente.

La catena delle resistenze termiche, dall'hot spot all'aria, è la seguente: die → TIM interno (il materiale che unisce il die all'IHS, saldatura o pasta) → **IHS** (Integrated Heat Spreader, il coperchio metallico saldato sopra il die che vediamo esternamente) → pasta termica esterna → base del dissipatore → heatpipes → alette → aria. Il progettista può migliorare solo gli ultimi anelli; i primi sono decisi da Intel e AMD. Per questo motivo, oltre un certo punto, aggiungere massa e

ventole porta a rendimenti decrescenti: si sta ottimizzando un anello della catena mentre il collo di bottiglia è altrove.

#### 8.1.4 Temperature target: cosa è normale e cosa no

Uno degli argomenti con più disinformazione. Stabiliamo alcuni punti di riferimento, notando che questi sono valori tipici al momento della scrittura e che i limiti esatti dovrebbero sempre essere verificati nelle specifiche tecniche del proprio modello specifico, poiché cambiano di generazione in generazione.

| <b>Componente</b>                                         | <b>Inattivo<br/>(desktop,<br/>nessun<br/>carico)</b> | <b>Carico di<br/>gioco</b> | <b>Carico<br/>pesante<br/>prolungato<br/>(rendering,<br/>compilazione<br/>)</b> | <b>Limite di<br/>intervento<br/>(<math>T_{jmax}</math>)</b>                         |
|-----------------------------------------------------------|------------------------------------------------------|----------------------------|---------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|
| CPU desktop<br>Intel Core<br>(12a–14a gen,<br>Core Ultra) | 30–45 °C                                             | 55–75 °C                   | 75–95 °C                                                                        | ~100 °C                                                                             |
| CPU AMD<br>Ryzen 5000<br>(AM4)                            | 35–45 °C                                             | 60–75 °C                   | 75–90 °C                                                                        | ~90 °C                                                                              |
| CPU AMD<br>Ryzen<br>7000/9000<br>(AM5)                    | 35–50 °C                                             | 60–80 °C                   | 85–95 °C                                                                        | ~95 °C (serie<br>7000 X3D<br>inferiore, ~89<br>°C; 9800X3D<br>di nuovo a<br>~95 °C) |
| GPU (die/core,<br>recenti<br>GeForce e<br>Radeon)         | 30–45 °C                                             | 65–80 °C                   | 70–85 °C                                                                        | ~90 °C core                                                                         |
| GPU —<br>memoria<br>GDDR6/GDDR<br>6X<br>( $T_{mem}$ )     | —                                                    | 70–95 °C                   | fino a 100–105<br>°C                                                            | ~105 °C<br>(throttling)                                                             |
| GPU —<br>hotspot /<br>junction                            | —                                                    | 75–95 °C                   | 85–100 °C                                                                       | ~105–110 °C                                                                         |

*Nota sui dati volatili: i valori di  $T_{jmax}$  e le soglie di throttling cambiano con le generazioni e talvolta con gli aggiornamenti del microcodice. I dati in tabella sono indicativi e validi al meglio delle conoscenze disponibili; i dati autorevoli sono quelli forniti dal produttore per la specifica SKU.*

Ci sono due idee sbagliate ricorrenti da sfatare immediatamente.

**Prima idea sbagliata: "la mia CPU è a 90 °C, sta per rompersi."** No. I processori AMD Ryzen serie 7000 e 9000, in particolare, sono progettati per *utilizzare* tutto il budget termico disponibile: l'algoritmo di boost alza la frequenza finché non raggiunge i 95 °C, e poi rimane lì. Un Ryzen 9 che opera costantemente a 95 °C sotto pieno carico con un buon dissipatore non è un sistema malato; è un sistema che fa esattamente ciò per cui è stato progettato. La differenza tra un dissipatore mediocre e uno eccellente, su questi chip, non si riflette nella temperatura (che è sempre 95 °C) ma nella *frequenza sostenuta* e nel *punteggio del benchmark*. Chiunque valuti il proprio dissipatore guardando solo il termometro, su queste piattaforme, sta guardando lo strumento sbagliato.

**Seconda idea sbagliata: "la temperatura inattiva è ciò che conta."** Anche no. La temperatura a riposo è la meno informativa di tutte, perché dipende in modo anomalo dai transienti di boost del sistema operativo (basta un servizio in background che si risveglia per far schizzare la lettura di 15 °C per mezzo secondo) e perché a potenze molto basse, la resistenza termica del sistema è quasi irrilevante. Un dissipatore viene valutato sotto carico costante e prolungato, con almeno 10-15 minuti di stress test, misurando *simultaneamente* temperatura, consumo energetico e frequenza. Senza tutti e tre i numeri, il confronto è privo di significato.

Un terzo elemento deve essere introdotto: la **temperatura dell'aria in ingresso**. Nessun dissipatore ad aria o AIO può portare la CPU al di sotto della temperatura dell'aria che vi entra; questo è un limite termodinamico, non un difetto. Se l'aria all'interno del case è a 40 °C perché il flusso d'aria è mal progettato, il dissipatore parte da 40 °C e aggiunge il suo  $\Delta T$ . Questo è il motivo per cui il capitolo sul case e la ventilazione e questo capitolo sono, in realtà, un unico capitolo diviso in due: **un eccellente dissipatore in un case soffocato si comporta come un dissipatore mediocre in un case ben ventilato.**

---

## 8.2 Raffreddamento ad aria

### 8.2.1 Descrizione e funzionamento: come funziona realmente una torre

Un dissipatore ad aria moderno è composto da quattro elementi funzionali, e vale la pena capirli uno ad uno perché la qualità del prodotto sta tutta nei dettagli di come sono realizzati.

**La base (cold plate).** È la piastra, quasi sempre in rame (a volte nichelata per estetica e resistenza all'ossidazione), che poggia sull'IHS della CPU. Il suo compito è raccogliere il calore da una zona piccola e concentrata. Due filosofie costruttive si contendono questo campo: la **base solida** (un blocco di rame lavorato, in cui vengono inserite e saldate le heatpipe) e il **direct-touch** (le heatpipe sono appiattite e toccano direttamente l'IHS, senza piastra intermedia). Il direct-touch elimina un'interfaccia termica ma lascia scanalature di alluminio o rame tra i tubi, con una distribuzione del calore meno uniforme; la base solida aggiunge un'interfaccia ma distribuisce meglio il calore. In pratica, entrambe le soluzioni ben eseguite danno risultati equivalenti, mentre entrambe le soluzioni mal eseguite (base concava, saldatura scadente, finitura grezza) danno risultati pessimi. Un dettaglio spesso trascurato è la **planarità e convessità** della base: molti produttori realizzano la base leggermente convessa per compensare la deformazione dell'IHS sotto la pressione del sistema di montaggio.

**Le heatpipe.** Sono il cuore tecnologico e la ragione per cui una torre da 1 kg dissipa più calore di un blocco di rame massiccio da 3 kg. Una heatpipe è un tubo di rame sigillato, parzialmente sottovuoto, e contenente una piccola quantità di fluido di lavoro (tipicamente acqua). All'interno della parete, c'è una struttura capillare (**wick**): polvere di rame sinterizzata, rete metallica, o scanalature longitudinali. Il funzionamento è un ciclo chiuso di cambiamento di fase. All'estremità calda (a contatto con la CPU), il fluido evapora, assorbendo il **calore latente di vaporizzazione** — una quantità enorme di energia rispetto a quella necessaria per scaldare lo stesso fluido di pochi gradi. Il vapore, che occupa un volume molto maggiore, si espande e si muove molto velocemente verso l'estremità fredda (immersa nelle alette), dove condensa, rilasciando il calore latente. Il liquido condensato viene poi riportato indietro dall'azione capillare del wick. Dato che il vuoto parziale abbassa il punto di ebollizione dell'acqua a poche decine di gradi, il ciclo funziona anche a normali temperature operative.

Il risultato è che una heatpipe ha una **conduttività termica effettiva** ordini di grandezza superiore a quella del rame solido (parliamo di migliaia di W/m·K

equivalenti, contro circa 400 W/m·K per il rame). Questo spiega perché: (a) i dissipatori seri hanno 6, 7 o 8 heatpipe e non una sola; (b) il numero di heatpipe è un indicatore grezzo ma reale della capacità di trasporto; (c) esiste un limite oltre il quale la heatpipe "si prosciuga": se la potenza è troppo alta, il liquido evapora più velocemente di quanto il wick riesca a riportarlo indietro, e la conduttività crolla improvvisamente. Questa è una delle ragioni per cui i dissipatori ad aria hanno un tetto di potenza abbastanza chiaro.

Un corollario poco noto: **l'orientamento conta**, anche se meno di quanto si tema. Un buon heatpipe a wick sinterizzato funziona in qualsiasi posizione, anche contro gravità, ma nella posizione "peggiore" (evaporatore in alto, condensatore in basso, con la gravità che si oppone al ritorno del liquido) può perdere qualche punto percentuale di efficienza. Nei case standard con scheda madre verticale, la torre lavora in orizzontale, che è una posizione neutra; nei case con scheda madre orizzontale (alcuni HTPC, alcuni bench case), è consigliabile controllare le istruzioni del produttore.

**Il pacco alettato.** È la superficie di scambio termico con l'aria: decine di sottili alette in alluminio (raramente rame, più efficiente ma molto più pesante e costoso), infilate sugli heatpipe. Qui, il parametro chiave è la **densità delle alette**, spesso espressa in FPI (Fins Per Inch). Alette dense offrono più superficie ma creano più resistenza al flusso d'aria: richiedono ventole ad alta **pressione statica** e rendono male con ventole lente. Alette sparse offrono meno superficie ma respirano bene anche a basse velocità: sono la scelta per i dissipatori orientati al silenzio. Non esiste una singola impostazione "migliore": esiste un accoppiamento coerente tra densità delle alette e curva della ventola. Un ottimo dissipatore ha un pacco alettato *progettato insieme* alla sua ventola.

Il modo in cui le alette sono attaccate agli heatpipe è un differenziatore di qualità sottovalutato: nei buoni prodotti, sono **saldate** o comunque unite con un legame metallurgico; nei prodotti economici, sono solo pressate meccanicamente, con un'interfaccia aria-metallo che introduce resistenza termica.

**La ventola.** Fornisce il flusso d'aria che allontana il calore dalle alette. I due parametri fondamentali sono la **portata d'aria** (CFM, Cubic Feet per Minute — o m<sup>3</sup>/h) e la **pressione statica** (mm H<sub>2</sub>O, millimetri di colonna d'acqua). La portata d'aria indica quanta aria muove in assenza di ostacoli; la pressione statica indica quanto bene riesce a spingere l'aria *attraverso* un ostacolo. Un pacco alettato è un

ostacolo. Discuteremo questo in dettaglio nella sezione 8.7, poiché l'argomento è comune sia al raffreddamento ad aria che a liquido.

### 8.2.2 Formati: Come leggere le dimensioni

I dissipatori ad aria si dividono in tre famiglie principali, distinte dalla geometria del flusso.

**Low profile.** Il pacco alettato è orizzontale, sopra il socket, e la ventola soffia verso il basso (**top-flow**). Le altezze tipiche vanno da 25 a 70 mm. Sono stati progettati per case Mini-ITX, HTPC, sistemi office compatti e workstation slim. Un vantaggio collaterale è che il flusso verso il basso raffredda anche i VRM della scheda madre e i moduli RAM, cosa che un dissipatore a torre non fa. Lo svantaggio è che la superficie disponibile è piccola e la ventola, essendo sottile e piccola, deve girare velocemente: questi dissipatori sono rumorosi in proporzione alla potenza dissipata. Riferimenti tipici: la serie **Noctua NH-L9** (circa 37 mm, adatta a CPU fino a circa 65 W), il **Noctua NH-L12S** (circa 70 mm, molto più capace), la famiglia **Thermalright AXP90** e **AXP120**, i dissipatori **ID-Cooling IS** per Mini-ITX.

**Single tower.** Un singolo pacco alettato verticale, con una ventola davanti (configurazione push) e talvolta una seconda dietro (push-pull). Altezze tipiche 120–160 mm. Questo è il formato dominante nella fascia media: un buon compromesso tra ingombro, prestazioni e prezzo. Riferimenti: **Thermalright Assassin X120 Refined**, **Arctic Freezer 36**, **DeepCool AK400**, **be quiet! Pure Rock 2**, **Noctua NH-U12S / NH-U12A**

In termini di posizionamento del marchio, si possono tracciare alcune linee chiare. **Thermalright** ha stravolto il mercato negli ultimi anni offrendo prestazioni di fascia alta a prezzi di fascia bassa; il compromesso è una minore qualità percepita dei materiali e dei kit di montaggio, e un supporto post-vendita meno strutturato in Europa. **Noctua** rappresenta l'estremo opposto: prezzi elevati, ma sistemi di montaggio eccellenti (SecuFirm2), alcune delle migliori ventole sul mercato (NF-A e NF-P), documentazione impeccabile, una lunga garanzia e — un dettaglio che vale il suo peso in oro — **kit di adattamento gratuiti o quasi gratuiti per i nuovi socket**, il che significa che un dissipatore Noctua può sopravvivere a più generazioni di piattaforme. **be quiet!** punta sul silenzio, con soluzioni acusticamente raffinate e un'estetica nero opaco molto sobria. **DeepCool** e **Arctic** occupano la fascia media con prodotti solidi e prezzi competitivi; Arctic, in particolare, è aggressiva sul prezzo e generosa con la sua garanzia.

*Nota di contesto commerciale, potenzialmente volatile: la disponibilità di alcuni marchi può variare a causa di ragioni normative o di distribuzione regionale. Prima di ordinare, verificare disponibilità e supporto nel proprio mercato.*

#### 8.2.4 Pro e contro del raffreddamento ad aria, senza retorica

**Pro.** L'affidabilità è il punto decisivo: un dissipatore ad aria non ha parti soggette a usura eccetto il cuscinetto della ventola, che si sostituisce in due minuti e costa 15-20 euro. Non c'è liquido, non ci sono guarnizioni, nulla che possa evaporare, gelificare o perdere. La vita utile pratica è quella del cuscinetto, e con buoni cuscinetti (rifile bearing, FDB — Fluid Dynamic Bearing, SSO2 di Noctua) parliamo di 100.000-150.000 ore MTTF (Mean Time To Failure). In concreto: un buon dissipatore ad aria può accompagnare tre o quattro build successive. Il costo è imbattibile: 40 euro oggi comprano prestazioni che dieci anni fa richiedevano 100 euro. La manutenzione è zero, esclusa la periodica rimozione della polvere. E il **rumore**: a parità di prestazioni, una torre ben progettata è quasi sempre più silenziosa di un AIO, perché non ha la pompa — che è una fonte di rumore continuo, spesso a frequenze fastidiose (ronzio a bassa frequenza, gorgoglii).

**Contro.** L'ingombro è il tallone d'Achille. Un dissipatore a doppia torre alto 165 mm e pesante 1,5 kg crea tre categorie di problemi: (1) potrebbe non entrare nel case; (2) potrebbe interferire con i moduli RAM, specialmente quelli con dissipatori alti; (3) potrebbe interferire con il primo slot PCIe (Peripheral Component Interconnect Express, il bus di espansione di cui si è parlato nel capitolo sulla scheda madre) o con i dissipatori degli SSD M.2. Il peso, inoltre, esercita una coppia sulla scheda madre: durante il trasporto, è consigliabile rimuovere i dissipatori più pesanti o trasportare il case in orizzontale. Infine, l'estetica: una torre nera copre metà della scheda madre e nasconde la RAM; per chi costruisce un sistema con fianco in vetro e illuminazione, è un sacrificio. Va detto onestamente che è un sacrificio *estetico*, non tecnico.

#### 8.2.5 Compatibilità: le tre misure da controllare sempre

È qui che si annidano la maggior parte degli errori di acquisto. Prima di comprare un dissipatore ad aria, tre controlli sono obbligatori.

**1. Il socket.** Il kit del dissipatore deve includere il sistema di montaggio per il socket della vostra scheda madre. Socket rilevanti oggi: **LGA1700** (Intel 12a/13a/14a generazione), **LGA1851** (Intel Core Ultra 200 series desktop), **LGA1200** (10a/11a gen, legacy), **AM4** (Ryzen 1000–5000), **AM5** (Ryzen 7000/8000/9000). Due note pratiche estremamente preziose: AM5 ha mantenuto lo **stesso schema di**

**fori di montaggio di AM4**, quindi quasi tutti i dissipatori AM4 sono meccanicamente compatibili con AM5. E LGA1851 ha mantenuto lo schema di fori  $78 \times 78$  mm di LGA1700, quindi anche lì la compatibilità è ampia — ma è **comunque obbligatorio controllare il sito web del produttore del dissipatore**, perché l'altezza dell'ILM (Independent Loading Mechanism, il meccanismo di ritenzione del processore) e lo spessore dell'IHS possono cambiare, e alcuni kit richiedono comunque un backplate diverso.

**2. L'altezza massima del dissipatore consentita dal case.** Ogni case specifica "CPU cooler clearance" o "max CPU cooler height", tipicamente 155–175 mm nei mid-tower. Questo dovrebbe essere confrontato con l'altezza dichiarata del dissipatore. **Non lasciare margini di 1–2 mm:** le tolleranze di fabbricazione, gli spessori dei backplate e la posizione del socket sulla scheda madre introducono variazioni. Se il case dichiara 165 mm e il dissipatore misura 165 mm, è un azzardo. Se il case dichiara 170 e il dissipatore 165, siete al sicuro.

**3. La distanza dalla RAM.** Questo è il vero killer silenzioso. Nei dissipatori a torre, la ventola anteriore sporge verso gli slot di memoria. Il produttore di solito dichiara due valori: l'altezza massima dei moduli RAM con la ventola in posizione standard (spesso 32–35 mm), e l'altezza consentita alzando la ventola (a costo di aumentare l'altezza complessiva del dissipatore, ricadendo al punto 2). I moduli di memoria "nudi" (senza dissipatori, o con dissipatori a basso profilo) misurano circa 31–33 mm; molti moduli gaming con dissipatori prominenti e RGB (Red-Green-Blue, illuminazione LED indirizzabile) raggiungono i 42–50 mm. Un Noctua NH-D15 con RAM alta 48 mm semplicemente non ci starà, o vi costringerà ad alzare la ventola oltre i limiti del case, o a rimuoverla del tutto, perdendo prestazioni. **La regola pratica è: se avete già scelto un grande dissipatore a torre, acquistate RAM a basso profilo.**

Un quarto controllo, meno frequente ma reale: alcuni dissipatori a torre molto larghi possono coprire parzialmente il primo slot PCIe x16 (dove va la scheda grafica) o i dissipatori M.2 sopra il primo slot. Questo problema si verifica spesso con i case Mini-ITX e le schede mATX compatte. Tutti i produttori seri pubblicano liste di compatibilità e persino modelli 3D scaricabili; usarli non è essere pedanti, è buona pratica.

#### 8.2.6 Errori tipici dell'acquirente

Il primo e più costoso: **dimensionare il dissipatore in base al TDP dichiarato invece del consumo energetico effettivo.** Ne abbiamo discusso in 8.1.2; è l'errore



che porta ad acquistare un dissipatore da 40 euro per un Core i7 K che assorbe 250W sotto carico.

Il secondo: **ignorare la distanza dalla RAM**, acquistando prima una memoria "bella" e poi scoprendo che il dissipatore non ci sta.

Il terzo: **credere che il numero di heatpipe da solo determini le prestazioni**. Sei heatpipe ben saldate a una fitta pila di alette e ben ventilate battono otto heatpipe mal fatte. Il numero è un'indicazione, non una prova.

Il quarto: **usare il dissipatore stock su una CPU di fascia alta**. I dissipatori inclusi nella confezione (AMD Wraith Stealth/Spire, Intel Laminar coolers) sono progettati per il minimo indispensabile, ovvero per far funzionare la CPU senza guasti. Su un Ryzen 5 o un Core i5 non-K sono accettabili; su qualsiasi cosa al di sopra, sono un collo di bottiglia. Va anche notato che, alla data di scrittura, **la maggior parte dei processori di fascia alta viene venduta senza alcun dissipatore incluso**: non è un'opzione, è un componente obbligatorio da mettere in conto.

Il quinto: **non montare correttamente la piastra posteriore (backplate)**, o stringere le viti in modo non uniforme. Torneremo sulla stretta nella sezione dedicata alla pasta termica.

Il sesto, specifico di Intel: **ignorare il problema della flessione dell'ILM su LGA1700**. Il meccanismo di ritenzione di questo socket esercita una pressione che tende a piegare leggermente l'IHS del processore, creando una concavità al centro e riducendo il contatto con la base del dissipatore. Questo fenomeno costa tipicamente 3–8 °C. Esistono dei **contact frame** aftermarket (Thermalright, Thermal Grizzly, e in alcuni casi kit dei produttori di schede madri) che sostituiscono l'ILM originale e distribuiscono la pressione in modo più uniforme. È una modifica da 15–20 euro che recupera diversi gradi, ma richiede la rimozione del meccanismo originale — un'operazione reversibile che va fatta con attenzione. *Verificare l'applicabilità al proprio socket e generazione, in quanto il problema è specifico e non universale.*

### 8.2.7 Raccomandazioni per fascia di prezzo (aria)

**Entry (CPU fino a ~100W reali: Ryzen 5 non-X, Core i5 non-K, APU)**. Una singola torre da 30–40 euro è più che sufficiente. Arctic Freezer 36, Thermalright Assassin X120, DeepCool AK400. In molti casi, il dissipatore incluso nella scatola è

sufficiente, ma spendere 30 euro compra un enorme guadagno acustico: è probabilmente il miglior rapporto qualità-prezzo dell'intero PC.

**Mid (CPU fino a ~180–220W reali: Ryzen 7, Ryzen 9 non overcloccati, Core i5 K, Core i7).** Doppia torre economica: **Thermalright Peerless Assassin 120 SE o Phantom Spirit 120 SE**. Sono, senza esagerare, il consiglio più solido che si possa dare a chiunque nel 2025–2026: prestazioni entro 2–4 °C dai modelli di punta a un terzo del prezzo. Alternativa di maggiore qualità costruttiva: DeepCool AK620.

**High-end (CPU oltre 250W: Ryzen 9 in PBO, Core i9 K, workstation).** Qui l'aria raggiunge il suo limite fisico. Le opzioni serie sono Noctua NH-D15 G2, be quiet! Dark Rock Elite, DeepCool Assassin IV. Questi vanno scelti sapendo che su un Core i9 top di gamma sotto pieno carico, anche il miglior dissipatore ad aria lascerà la CPU parzialmente in throttling: questo non è un difetto del dissipatore, è che la CPU dissipa più calore di quanto l'aria possa portare via in quello spazio. La scelta consapevole a questo punto è: accettare qualche punto percentuale in meno di prestazioni in cambio di affidabilità e silenzio (aria), oppure passare al raffreddamento a liquido.

---

## 8.3 Raffreddamento a Liquido AIO

### 8.3.1 Descrizione e Funzione

**AIO** sta per *All-In-One*: un sistema di raffreddamento a liquido pre-assemblato, pre-riempito e sigillato in fabbrica. L'utente si limita a montarlo; non viene aperto, ricaricato o mantenuto.

Il circuito è concettualmente semplice. Un **waterblock** (o cold plate) poggia sull'IHS della CPU: è un blocco di rame la cui superficie inferiore è liscia (a contatto con la pasta termica) e la cui superficie superiore è intagliata in una fitta griglia di micro-alette, attraverso le quali il liquido è costretto a passare. Il liquido assorbe calore, viene spinto da una **pompa** (nella stragrande maggioranza degli AIO, la pompa è integrata nel blocco stesso, sopra il waterblock; in alcuni modelli, è integrata nel radiatore) attraverso un **tubo** flessibile al **radiatore**, che è uno scambiatore di calore liquido-aria: canali piatti attraverso cui scorre il liquido, attraversati da una pila di alette di alluminio. Una o più **ventole** soffiano aria attraverso il radiatore, che dissipa il calore nell'ambiente. Il liquido raffreddato ritorna al waterblock attraverso il secondo tubo. È un circuito chiuso.

Il punto che quasi tutti fraintendono è **cosa fa effettivamente il liquido**. Il liquido non "raffredda" nel senso che non produce freddo: è semplicemente un *mezzo di trasporto del calore* molto efficace perché l'acqua ha una capacità termica specifica molto elevata (circa 4,18 kJ/kg·K) e perché una pompa può muoverla continuamente. In un dissipatore ad aria, il calore deve essere trasportato dalla base alle alette tramite heatpipe, e le alette devono essere fisicamente lì, sopra il socket, in uno spazio limitato. In un AIO, il calore viene *portato altrove*, in un punto del case dove c'è spazio per una superficie di scambio molto più grande e più ventole. **Il vantaggio di un AIO non è il liquido: è che il liquido permette di posizionare la superficie di scambio dove c'è spazio.**

C'è un secondo vantaggio, meno ovvio ma prezioso: la **massa termica**. Il liquido nel circuito (circa 150-400 ml) agisce come un volano termico: assorbe brevi picchi di potenza senza che la temperatura salga immediatamente. Nei carichi a raffica (gaming, dove la CPU alterna picchi e pause), questo si traduce in temperature di picco più basse e ventole che accelerano più lentamente, con un comportamento acustico più stabile. Questo è uno dei motivi per cui un AIO "sembra" più silenzioso nel gaming anche quando non è sotto carico costante.

### 8.3.2 Dimensioni del radiatore: quale per quale CPU

La capacità di dissipazione di un AIO è determinata quasi interamente dalla **superficie del radiatore** e dal flusso d'aria attraverso di essa. La pompa e il waterblock contano molto meno di quanto suggerisca il marketing: le differenze tra pompe di buona qualità sono nell'ordine di 1-2 °C, mentre tra un radiatore da 240 mm e uno da 360 mm ci sono 5-10 °C.

Le dimensioni sono espresse dalla lunghezza approssimativa: **120** (una ventola da 120 mm), **240** (due ventole da 120 mm), **280** (due ventole da 140 mm), **360** (tre ventole da 120 mm), **420** (tre ventole da 140 mm). Esistono anche 140, 320 e 480 in mercati di nicchia. Nota: un 280 ha una superficie *maggiore* di un 240 (le ventole da 140 mm hanno circa il 36% in più di area frontale), ed è spesso paragonabile a un 360 pur essendo più corto, il che lo rende una scelta intelligente nei case che lo supportano — ma i case compatibili con radiatori da 280 mm sono meno numerosi.

Una **spessore** del radiatore che conta: lo standard è 27 mm, ma alcuni produttori (Arctic con la serie Liquid Freezer, in particolare) usano radiatori da 38 mm, che offrono più massa e superficie a parità di lunghezza. Il rovescio della medaglia: maggiore spessore richiede più pressione statica dalle ventole e può causare

problemi di spazio con lo stack di alette VRM sulla scheda madre o con la RAM, se montato sopra un case stretto. **Controllare sempre lo spessore massimo supportato dal case, sommando radiatore + ventole.**

| Radiatore | Superficie Relativa | CPU adatte (consumo energetico reale sotto carico) | Note                                                                                                     |
|-----------|---------------------|----------------------------------------------------|----------------------------------------------------------------------------------------------------------|
| 120 mm    | 1×                  | fino a ~100 W                                      | Spesso peggio di una torre da 40€ allo stesso prezzo. Sconsigliato a meno che lo spazio non sia limitato |
| 240 mm    | 2×                  | fino a ~180 W                                      | Fascia media. Adatto per Ryzen 7, Core i5 K/i7                                                           |
| 280 mm    | ~2.7×               | fino a ~230 W                                      | Ottimo compromesso, se il case lo accetta                                                                |
| 360 mm    | 3×                  | fino a ~280 W                                      | Lo standard de facto per l'alta gamma                                                                    |
| 420 mm    | ~4×                 | oltre 300 W                                        | Per Core i9 di fascia alta, Ryzen 9 in PBO, Threadripper. Case grandi obbligatori                        |

**Scomoda verità da dire ad alta voce:** un AIO economico da 120 o 240 mm è quasi sempre una scelta peggiore di un dissipatore a doppia torre da 40€, sotto ogni aspetto — prestazioni, rumore, affidabilità, prezzo. Ha senso solo se lo spazio impedisce fisicamente una torre (case sottili, alcuni ITX) o se l'estetica è la priorità. Il raffreddamento a liquido diventa oggettivamente superiore all'aria **da 280 mm in su, e su CPU che dissipano molto calore.**

### 8.3.3 Posizionamento del radiatore e la regola dell'aria nella pompa

Questo è il paragrafo che, se ignorato, porta ad AIO rumorosi e AIO prematuramente morti. Va capito, non memorizzato.

**Il fatto fisico.** Un AIO, per quanto sigillato, non è ermetico indefinitamente. I tubi di gomma sono *permeabili* al vapore acqueo: molecola per molecola, anno dopo anno, una piccola quantità di liquido evapora attraverso la parete del tubo. Inoltre, alcune reazioni chimiche interne (e il fatto che il riempimento non è mai al 100% durante la produzione) generano una piccola quantità di gas. Il risultato è che **in ogni AIO, prima o poi, si forma una bolla d'aria**. È inevitabile e anticipato dai progettisti.

**La conseguenza.** L'aria, essendo meno densa del liquido, si raccoglie sempre nel **punto più alto del circuito**. Se il punto più alto del circuito è la pompa, la pompa aspira aria invece di liquido. Questo produce tre effetti, in ordine di gravità crescente: (1) un rumore evidente e fastidioso, un gorgoglio o un ronzio ("gurgling"); (2) una perdita di efficienza di pompaggio, perché l'aria non trasporta calore; (3) **cavitazione a secco** e usura accelerata del cuscinetto e della girante, perché la pompa funziona senza il liquido che la lubrifica e la raffredda. Una pompa che funziona a secco per settimane morirà.

**La regola pratica.** Il punto più alto del circuito **non deve mai essere la pompa** (cioè il blocco sulla CPU). Da questo, seguono le configurazioni corrette:

- **\*\*Radiatore sulla parte superiore del case\*\*** (in alto), con i tubi che escono verso il basso o lateralmente: configurazione ideale. Il punto più alto è la parte superiore del radiatore, che è progettata per contenere l'aria (spesso il canale superiore del radiatore funge da piccola camera d'aria). Il liquido raggiunge sempre la pompa pieno.
- **\*\*Radiatore sulla parte anteriore del case, con i tubi in basso\*\***: configurazione corretta. Se il radiatore è nella parte anteriore e i tubi escono dalla *\*parte inferiore\** del radiatore, l'aria si raccoglie nella parte superiore del radiatore, lontano dalla pompa. Questa è la configurazione da scegliere quando si monta un AIO nella parte anteriore.
- **\*\*Radiatore sulla parte anteriore con i tubi in alto\*\***: configurazione **\*\*sbagliata e da evitare\*\***, perché è qui che l'aria dal radiatore può migrare nei tubi e finire nella pompa. È l'errore di installazione più comune ed è ciò che genera la famosa lamentela "il mio AIO fa un rumore di gorgoglio".
- **\*\*Radiatore nella parte inferiore del case\*\***: il peggior in assoluto. Il punto più basso del circuito diventa il radiatore, e il punto più alto diventa la pompa. Tutta l'aria nel circuito finisce nella pompa. Non farlo mai, anche se il case lo consente meccanicamente.

Se la geometria del case impone un montaggio non ideale, c'è un palliativo: dopo l'assemblaggio, **inclinare il case in varie posizioni per un paio di minuti con il sistema acceso**, per far migrare la bolla d'aria verso il radiatore. Questa non è una soluzione permanente ma spesso risolve il rumore iniziale.

**Una nota finale sull'orientamento:** alcuni produttori (Arctic, Corsair, Lian Li) offrono blocchi con loghi o display ruotabili, in modo che l'estetica non imponga un montaggio termicamente scorretto. Se il tuo AIO non lo consente e desideri comunque un orientamento preciso dei tubi, è meglio scegliere un altro modello piuttosto che compromettere la fisica per un logo dritto.

#### 8.3.4 Direzione dell'aria: radiatore come immissione o espulsione?

Una domanda posta continuamente e quasi sempre a cui si risponde in modo errato. Le due opzioni:

**Radiatore come immissione:** le ventole soffiano aria fresca *dall'esterno* attraverso il radiatore, all'interno del case. Vantaggio: il radiatore riceve l'aria più fredda disponibile (temperatura ambiente), quindi la CPU è più fresca — tipicamente 3-6 °C in meno. Svantaggio: l'aria che entra nel case dopo essere passata attraverso il radiatore è preriscaldata, quindi GPU, VRM, SSD e RAM funzionano qualche grado più caldi.

**Radiatore come espulsione:** le ventole aspirano aria dal case attraverso il radiatore e la espellono. Vantaggio: il resto del case respira aria fresca. Svantaggio: il radiatore riceve aria già riscaldata dalla GPU, quindi la CPU è più calda.

Non esiste una risposta universale; esiste un criterio: **dare priorità al componente più critico**. Se hai un Core i9 in un sistema di rendering e una GPU modesta, ha senso posizionare il radiatore come immissione nella parte anteriore. Se hai una GPU di fascia alta da 400 W e una CPU media in un sistema di gioco, ha senso posizionare il radiatore come espulsione in alto e lasciare che la parte anteriore porti aria fresca alla GPU. La configurazione più comune e bilanciata nei case moderni è: **radiatore in alto come espulsione, ventole anteriori come immissione**. Con un avvertimento: se il radiatore è un'immissione dalla parte anteriore, deve essere posizionato un filtro antipolvere davanti ad esso, perché un radiatore intasato di polvere perde drasticamente efficienza, e pulirlo è molto più difficile che pulire una pila di alette di un dissipatore a torre.

### 8.3.5 Marche e Modelli

*Panoramica basata sulle migliori conoscenze disponibili; il segmento AIO è in rapida evoluzione e le revisioni cambiano spesso, quindi controlla sempre le recensioni per la revisione specifica in vendita.*

**Arctic Liquid Freezer (serie II e III).** Il benchmark de facto per il rapporto prezzo/prestazioni, e per diverse revisioni, anche il benchmark di prestazioni assolute. Caratteristiche distintive: radiatore da 38 mm (più spesso dello standard), **una ventola VRM da 40 mm integrata nel blocco** che raffredda i regolatori di tensione della scheda madre (cosa che nessun altro AIO fa e che gli AIO tradizionali, a differenza dei dissipatori a basso profilo, rimuovono), pompa PWM regolabile, prezzi aggressivi. Contro: estetica spartana, cavo singolo un po' scomodo, lo spessore del radiatore può causare problemi di spazio in alcuni casi.

**Corsair (iCUE Link Titan, serie H).** Ecosistema molto raffinato, software esteso, alta qualità costruttiva, prezzi elevati. Il sistema iCUE Link riduce il cablaggio con un singolo connettore a margherita, che è un vero vantaggio pratico ma ti blocca nell'ecosistema.

**Lian Li Galahad II.** Prestazioni molto competitive, estetica di fascia alta, illuminazione raffinata, prezzi medio-alti. Una buona alternativa a Corsair per chi desidera l'estetica senza il blocco software.

**NZXT Kraken (ed Elite).** Il punto di forza è l'ampio display LCD personalizzabile sul blocco; le prestazioni termiche sono buone ma raramente di prim'ordine, e si paga un premio per l'estetica e il software (CAM).

**DeepCool (serie LT, LE, Mystique).** Ottimo rapporto qualità-prezzo, buone prestazioni, estetica raffinata. *Nota: la disponibilità di questo marchio può variare a seconda del mercato; verifica la disponibilità locale.*

**be quiet! (Silent Loop, Pure Loop).** Focalizzati sul funzionamento silenzioso, con pompe particolarmente discrete. Le prestazioni sono raramente di prim'ordine, ma acusticamente eccellenti.

Tecnologicamente, vale la pena notare che per molti anni, gran parte degli AIO sul mercato, indipendentemente dal marchio, utilizzava pompe prodotte da **Asetek** su licenza (o da CoolIT, l'altro grande OEM). Ciò significa che il "cuore" di AIO apparentemente diversi era spesso identico, e le vere differenze risiedevano nel radiatore, nelle ventole, nei tubi e nel software. Questo è un motivo aggiuntivo per

non pagare un premio eccessivo per il marchio e per concentrarsi sui dati misurati: dimensioni del radiatore, prestazioni certificate da recensioni indipendenti e rumore misurato allo stesso livello di dissipazione.

### 8.3.6 Pro e Contro degli AIO

**Pro.** Per le CPU di fascia alta, un AIO da 360/420 mm supera il raffreddamento ad aria: non di poco, in alcuni casi di 8-12 °C sotto carico pesante, con conseguente maggiore frequenza sostenuta. Libera spazio intorno al socket: nessun conflitto con la RAM (qualsiasi memoria può essere installata, anche con i dissipatori più alti), nessun conflitto con il primo slot PCIe, nessun peso appeso alla scheda madre. Consente build compatte con CPU potenti, poiché il radiatore va ovunque ci sia spazio. E, francamente, è esteticamente più pulito: la scheda madre rimane visibile, l'illuminazione è visibile e i sistemi con pannello laterale in vetro hanno senso.

**Contro.** Innanzitutto, il costo: un AIO da 360mm decente parte da 90-110 euro e sale rapidamente. La **pompa è un singolo punto di guasto**: se si ferma, la temperatura della CPU sale verticalmente in pochi secondi e il sistema va in throttling o si spegne; a differenza di una ventola, non c'è degradazione graduale e nessuna ridondanza. Quando si installa un AIO, è buona norma collegare la pompa al connettore **AIO\_PUMP** o **CPU\_FAN** della scheda madre e impostare l'allarme di velocità zero, in modo che il BIOS blocchi l'avvio se la pompa non è in funzione. La **durata** è limitata: è tipicamente stimata in **5-7 anni**, vincolata dall'evaporazione del liquido attraverso i tubi, dall'usura del cuscinetto della pompa e dal potenziale accumulo di detriti nei microcanali del waterblock. Un dissipatore ad aria, nello stesso periodo, necessita solo di una nuova ventola da 20 euro. Infine, il rumore: la pompa aggiunge una fonte acustica continua che non esiste nel raffreddamento ad aria, e non tutte le pompe sono silenziose a basse velocità.

### 8.3.7 Errori tipici dell'acquirente (AIO)

Acquistare un **AIO da 240mm economico invece di un dissipatore a torre da 40 euro**, credendo che "liquido = migliore". Non è così: si paga di più per prestazioni uguali o inferiori, con una pompa aggiuntiva che può rompersi.

**Montare il radiatore nella parte inferiore del case o nella parte anteriore con i tubi in alto**, per motivi di cablaggio o estetici. Vedere 8.3.3.



**Non controllare lo spazio disponibile:** radiatore + ventole possono superare i 55-65 mm di spessore. Sulla parte superiore di molti case, questo interferisce con i dissipatori VRM della scheda madre o con la RAM. La specifica del case di solito indica un "clearance" massimo per la parte superiore; deve essere rispettato.

**Collegare la pompa a un connettore generico per ventole con una curva PWM aggressiva.** La pompa non è una ventola: farla funzionare al 40% per "silenziare" riduce il flusso e le prestazioni. La maggior parte delle pompe dovrebbe essere mantenuta a una velocità fissa ed elevata (spesso 100%); alcune moderne accettano PWM, e il produttore specifica come. Leggere il manuale.

**Trascurare il periodo di rodaggio.** Nei primi giorni, un AIO può produrre un leggero gorgoglio che si attenua man mano che le bolle d'aria si depositano. Se il rumore persiste dopo una settimana, l'installazione è errata.

#### 8.3.8 Raccomandazioni di fascia economica (AIO a liquido)

**Entry.** Nessuno. Se il budget è basso, prendete un dissipatore a torre. Un AIO economico è un cattivo affare.

**Mid (CPU fino a ~200W, si desidera estetica o si hanno vincoli di RAM alta).** Un buon marchio da 240 o 280mm. Arctic Liquid Freezer III 240/280 è la scelta razionale.

**High-end (CPU oltre 250W).** Un 360mm di fascia alta, o un 420mm se il case lo consente. Arctic Liquid Freezer III 360/420, Corsair, Lian Li Galahad II 360. Per un Core i9 o un Threadripper, qui il raffreddamento a liquido non è una scelta estetica ma una necessità tecnica.

---

### 8.4 Il Custom Loop: per completezza, e per capire perché quasi nessuno dovrebbe farlo

Un **custom loop** è un circuito di raffreddamento a liquido assemblato dall'utente componente per componente. Nasce dal desiderio di superare i limiti degli AIO (radiatori più grandi, radiatori multipli e soprattutto la possibilità di raffreddare a liquido anche la GPU), e dalla passione per l'oggetto stesso.

#### 8.4.1 I Componenti

**Pompa e Serbatoio.** La pompa muove il liquido; il serbatoio è un contenitore che facilita il riempimento, raccoglie l'aria e fornisce un margine di liquido. Nella

pratica moderna, pompe e serbatoi sono quasi sempre acquistati come un **combo** integrato. Le due piattaforme di pompe dominanti sono la **D5** e la **DDC**, entrambe derivate da design industriali (rispettivamente Laing/Xylem e Laing). La **D5** ha un'alta portata e una pressione di prevalenza media (la capacità di superare la resistenza del circuito), è più grande, molto silenziosa e affidabile. La **DDC** ha una pressione di prevalenza più alta e una portata inferiore, è più compatta ma funziona più calda ed è tipicamente più rumorosa. In un loop lungo, con più radiatori e blocchi molto restrittivi, la DDC ha un vantaggio; nella maggior parte dei loop domestici, la D5 è la scelta sensata.

**Waterblock CPU.** Un blocco di rame nichelato con una base a microcanali (larghezza dei canali dell'ordine dei decimi di millimetro), una parte superiore in acrilico o acetale e raccordi filettati. Le differenze di prestazioni tra buoni waterblock CPU sono modeste (2–4 °C); la qualità del montaggio e la pressione uniforme sono più importanti.

**Waterblock GPU — questo deve essere spiegato bene, perché è qui che le persone si mettono nei guai.**

Una scheda grafica standard viene venduta con un dissipatore ad aria proprietario, avvitato al **PCB** (Printed Circuit Board, la scheda circuitale della scheda) e collegato ai componenti caldi tramite pasta termica sulla GPU e **thermal pad** (fogli di materiale conduttivo morbido) su memoria e VRM. Per raffreddare a liquido la GPU, è necessario:

1. **Smontare completamente il dissipatore di serie**, il che significa rimuovere la piastra posteriore, svitare la piastra, scollegare i cavi delle ventole e separare il pacco alettato dal PCB — un'operazione che richiede cura perché il dissipatore aderisce al chip tramite pasta termica indurita. 2. **Pulire perfettamente il PCB** da residui di pasta e pad. 3. **Installare un waterblock full-cover**, ovvero una piastra che copre non solo la GPU ma anche la memoria GDDR e i VRM. Ecco il punto cruciale: **il waterblock è specifico per quel PCB**, non per quel modello di GPU. Una GeForce di una certa serie prodotta da diversi produttori ha PCB diversi, con componenti posizionati in modo diverso. Un waterblock progettato per il PCB "reference" (il design di riferimento del produttore del chip) **non è compatibile** con una scheda con PCB personalizzato. Esistono elenchi di compatibilità dettagliati (EK, Alphacool e Bykski li pubblicano) e dovrebbero essere consultati **prima** di acquistare la scheda grafica, non dopo. 4. **Applicare thermal pad dello spessore corretto** alla memoria e ai VRM: qui il margine di errore è piccolo. Un

pad troppo sottile non farà contatto (e la memoria si brucerà o andrà in throttling); un pad troppo spesso impedirà al blocco di appoggiarsi sul die della GPU (e la GPU andrà in throttling). Gli spessori sono misurati in decimi di millimetro, e il kit del waterblock li fornisce pretagliati e dimensionati — usate quelli, non improvvisate.

**Sulla garanzia.** Questo è un argomento delicato e va esposto con precisione. In molti paesi extra-UE i produttori dichiarano che la rimozione del dissipatore invalida la garanzia, punto. Nell'Unione Europea la situazione è più sfumata: la **garanzia legale di conformità** (due anni, prevista dalla direttiva UE recepita nel diritto italiano dal Codice del Consumo) copre i difetti di conformità presenti al momento della consegna, e il venditore non può escluderla del tutto per il semplice fatto che il prodotto sia stato aperto. Tuttavia, il venditore **non è tenuto a coprire danni causati dall'utente**, e l'onere di dimostrare che il guasto non è dovuto alla modifica ricade, dopo i primi mesi, sul consumatore. In pratica: smontare il dissipatore di una GPU da 1.500 euro è un rischio che si assume l'utente, e in caso di guasto la discussione con il venditore sarà lunga e l'esito incerto. Alcuni produttori (storicamente pochi, e le policy cambiano nel tempo — *verificare caso per caso, il dato è volatile*) dichiarano esplicitamente di tollerare la sostituzione del dissipatore. **Il consiglio onesto è: non fatelo su una scheda che non potete permettervi di ricomprare.**

**Radiatori.** I custom loop usano radiatori a moduli standard da 120/140 mm, in lunghezze 240/280/360/420/480, e in tre spessori tipici: **30 mm** (slim), **45 mm** (standard, il più comune), **60 mm** (thick, per ventole ad alta pressione statica). La regola empirica per il dimensionamento, cauta ma affidabile: **circa 120 mm di radiatore ogni 150–200 W da dissipare**, con ventole a velocità moderata. Un loop con CPU (250 W) e GPU (400 W) richiede quindi almeno un 360 + un 240, ed è più comodo con due 360.

**Fittings.** Sono i connettori che uniscono tubi e componenti. Lo standard universale è la filettatura **G1/4"**. I tipi principali sono i **compression fittings** (con ghiera, per soft tubing: il tubo viene spinto sul barb e si avvita una ghiera che lo comprime — sicuri e reversibili) e i fittings per **hard tubing** (con O-ring che sigillano contro la parete esterna del tubo). Esistono poi fittings angolati, valvole di scarico (indispensabili, e troppo spesso omesse), passaparete e adattatori vari.

**Tubing.** Due mondi: il **soft tubing** (tubo flessibile, in PVC o silicone, tipicamente 10/13 mm o 10/16 mm — diametro interno/esterno) è flessibile, perdona gli errori,

si taglia con le forbici, ed è la scelta razionale per i principianti. L'**hard tubing** (tubo rigido, in PETG, acrilico o metallo) va misurato, tagliato, piegato a caldo con appositi inserti, sbavato e lucidato: il risultato estetico è superiore, i tempi di realizzazione si moltiplicano, e ogni errore costa un pezzo di tubo. È artigianato, e come tale va affrontato.

**Liquido.** Acqua distillata (mai acqua di rubinetto: i sali minerali depositano e conducono) con additivi biocidi e anticorrosione, oppure un **premix** commerciale già pronto (EK CryoFuel, Mayhems, Aquacomputer). Il liquido colorato opaco (pastel) è bello e problematico: tende a sedimentare e a intasare i microcanali; i liquidi trasparenti o leggermente colorati sono molto più affidabili. **Regola chimica aurea: mai mescolare rame e alluminio nello stesso circuito.** Il contatto tra due metalli diversi in presenza di un elettrolita innesca la **corrosione galvanica**: l'alluminio (meno nobile) si corrode rapidamente, i detriti intasano i canali, il loop muore. Dato che quasi tutti i waterblock sono in rame e alcuni radiatori economici sono in alluminio, questo è un errore reale e frequente. Verificare i materiali di ogni singolo componente.

#### 8.4.2 Marche

**EK Water Blocks** è storicamente il marchio più popolare, con il più ampio catalogo di waterblock per GPU e un ecosistema completo; *va notato che la stabilità dell'azienda ha affrontato difficoltà negli ultimi anni, con impatti su consegne e supporto — un dato volatile da verificare al momento dell'acquisto.*

**Alphacool** offre un eccellente rapporto qualità-prezzo, radiatori tutti in rame e una gamma molto ampia. **Watercool** (marchio tedesco, serie Heatkiller) è il riferimento per la qualità costruttiva assoluta, a prezzi elevati. **Corsair Hydro X** è la soluzione "chiavi in mano" per chi rimane nell'ecosistema Corsair, ben fatta ma costosa. **Bykski** e **Barrow** sono marchi cinesi che offrono componenti a una frazione del prezzo occidentale, con qualità variabile ma spesso sorprendentemente buona: sono il punto di ingresso economico ai custom loop, a patto di verificare attentamente la compatibilità.

#### 8.4.3 Costi, manutenzione e a chi conviene davvero

**Costi.** Un loop decente solo CPU parte da 350–450 euro. Un loop CPU + GPU costa realisticamente tra 700 e 1.200 euro, e sale facilmente. Questo va confrontato con un AIO da 360 mm a 130 euro che, per la CPU, offre l'85–90% del beneficio.

**Manutenzione.** Non è opzionale. Il liquido va **sostituito circa ogni 12 mesi** (alcuni si spingono a 18–24 con premix di qualità), il circuito va flussato, e filtri e

trappole vanno controllati. Ogni intervento richiede lo svuotamento del loop, il che significa mezza giornata di lavoro. E c'è il rischio sempre presente di una **perdita**: un raccordo non stretto bene, un O-ring danneggiato, un tubo rigido tagliato male. Una perdita su una scheda madre alimentata distrugge componenti da centinaia o migliaia di euro. Per questo, il **leak test** — riempire il loop e metterlo in pressione (o alimentare solo la pompa con un jumper sul connettore 24 pin, tenendo il resto del sistema spento) per almeno 12–24 ore prima di accendere il PC — non è una precauzione consigliata, è una procedura obbligatoria.

**A chi conviene?** Con brutale onestà: **quasi a nessuno, da un punto di vista razionale**. Le prestazioni della CPU di un custom loop superano solo di poco quelle di un buon AIO da 360. Il vero vantaggio tecnico è il raffreddamento della GPU, che può abbassare le temperature di 25–30 °C, eliminare il rumore delle ventole dalla scheda e consentire overclock significativi. Ma è un vantaggio che costa 800 euro, dieci ore di lavoro, un rischio per la garanzia e una manutenzione annuale.

Il custom loop è adatto a tre categorie: chi cerca il **silenzio assoluto** in un sistema molto potente (un loop grande con ventole a 500 RPM è praticamente inudibile, e nessuna altra tecnologia lo permette); chi realizza sistemi **estremi** con più GPU o overclock aggressivi; e chi lo fa **per il piacere di farlo**, come hobby, esattamente come restaurare una moto d'epoca. Quest'ultima è una motivazione perfettamente legittima, purché dichiarata come tale e non mascherata da razionalità tecnica.

---

## 8.5 Aria vs. Liquido: La Decisione Finale

| Criterio                        | Aria (Dual Tower)          | AIO 240–280   | AIO 360–420 | Custom Loop                   |
|---------------------------------|----------------------------|---------------|-------------|-------------------------------|
| Prestazioni su CPU $\leq 150$ W | Eccellente                 | Equivalente   | Eccessivo   | Eccessivo                     |
| Prestazioni su CPU 200–250 W    | Buono                      | Buono         | Molto Buono | Molto Buono                   |
| Prestazioni su CPU $> 280$ W    | Insufficiente (throttling) | Insufficiente | Molto Buono | Eccellente                    |
| Rumore a parità di dissipazione | Eccellente (no pompa)      | Decente       | Buono       | Eccellente (a bassa velocità) |

|                                |                      |             |           |                              |
|--------------------------------|----------------------|-------------|-----------|------------------------------|
| Costo                          | 30–150 €             | 80–130 €    | 110–220 € | 400–1.200+ €                 |
| Affidabilità / Punti di guasto | Solo ventola         | Pompa       | Pompa     | Pompa, raccordi, perdite     |
| Durata prevista                | 10+ anni             | 5–7 anni    | 5–7 anni  | Indefinita, con manutenzione |
| Manutenzione                   | Spolverata           | Nessuna     | Nessuna   | Annuale, obbligatoria        |
| Spazio intorno al socket       | Alto (conflitti RAM) | Nessuno     | Nessuno   | Nessuno                      |
| Estetica                       | Ingombrante          | Pulita      | Pulita    | Massima                      |
| Raffredda anche GPU            | No                   | No          | No        | Sì                           |
| Complessità di assemblaggio    | Bassa                | Bassa/Media | Media     | Molto Alta                   |

### Raccomandazioni inequivocabili per fascia di CPU:

- **\*\*CPU Entry (fino a 100 W effettivi)\*\***: Single tower economico. Nessun motivo per il liquido.
- **\*\*CPU Mid (100–200 W)\*\***: Dual tower economico (Peerless Assassin e simili). L'AIO ha senso solo per vincoli di ingombro RAM elevati o estetica.
- **\*\*CPU High (200–280 W)\*\***: Dual tower di fascia alta *\*oppure\** AIO 280/360. Entrambe le scelte sono difendibili; l'aria vince su affidabilità e costo, il liquido su temperature e spazio.
- **\*\*CPU Flagship (oltre 280 W: Core i9 di fascia alta, Ryzen 9 in PBO, HEDT/Threadripper)\*\***: AIO 360/420 obbligatorio, o custom loop. L'aria qui non basta, e insistere significa lasciare prestazioni sul tavolo.

Un'ultima osservazione, che vale come principio generale per questo capitolo: **è quasi sempre più intelligente spendere di più sulla CPU e meno sul dissipatore, che il contrario**. Il dissipatore migliora le prestazioni di pochi punti percentuali; una CPU superiore le migliora di decine di punti percentuali. Un budget mal allocato è quello in cui si mette un AIO da 250 euro su un processore da 250 euro.

---

## 8.6 Pasta Termica: Una Discussione Approfondita

### 8.6.1 A cosa serve, e perché non è "un lubrificante"

Se si osservassero al microscopio la superficie superiore dell'IHS della CPU e quella inferiore della base del dissipatore — entrambe apparentemente lisce e specchiate — si vedrebbero due paesaggi montuosi. Nessun processo meccanico produce una superficie perfettamente piana: rimangono micro-asperità, ondulazioni, e a volte una leggera concavità o convessità dovuta alla produzione o alla pressione di montaggio.

Quando queste due superfici vengono pressate l'una contro l'altra, il contatto metallo-metallo **effettivo** avviene solo su una frazione minima dell'area apparente: tipicamente **meno dell'1-2%**. Tutto il resto è aria intrappolata in micro-cavità. E l'aria è un cattivo conduttore termico: circa **0,026 W/m·K**, rispetto a circa 400 W/m·K per il rame. Uno strato d'aria spesso pochi micrometri, che si estende su oltre il 98% dell'area di contatto, costituisce una barriera termica devastante.

Il compito del **TIM** (Thermal Interface Material — questo è il nome tecnico corretto per "pasta termica") è quello di **espellere l'aria e riempire quelle micro-cavità con un materiale che conduca il calore molto meglio dell'aria**. Ecco il punto che deve essere compreso una volta per tutte: la pasta termica **non è un buon conduttore in termini assoluti** — un'ottima pasta ha 8–13 W/m·K, che è trenta o quaranta volte peggio del rame. La pasta è un **compromesso necessario**: è molto peggio del metallo, ma centinaia di volte meglio dell'aria che sostituisce.

Da questa osservazione deriva immediatamente la regola operativa più importante dell'intera sezione: **lo strato di pasta deve essere il più sottile possibile**. La pasta non deve creare spessore: deve solo riempire gli spazi. Ogni micrometro extra di pasta tra i due metalli aggiunge resistenza termica. Chiunque spalmi un millimetro di pasta "per sicurezza" sta letteralmente costruendo un isolante.

### 8.6.2 Tipi di TIM

**Paste tradizionali a base di silicone.** Si tratta di una matrice polimerica (silicone o simile) caricata con particelle conduttive: ossidi metallici (zinco, alluminio), ceramiche, nitrato di boro, particelle metalliche elettricamente non conduttive. Sono **elettricamente non conduttive** (con alcune eccezioni per carichi metallici

elevati — leggere il datasheet), il che le rende sicure: una piccola quantità che trabocca sul socket non causerà cortocircuiti. La conduttività dichiarata è tipicamente tra 5 e 14 W/m·K.

Una nota metodologica molto importante: **i valori di conduttività dichiarati dai produttori non sono confrontabili tra diverse marche**, perché non esiste uno standard di misurazione universalmente adottato e ogni produttore utilizza il metodo che lo favorisce. Una pasta che dichiara 13 W/m·K non è necessariamente migliore di una che dichiara 8,5 W/m·K. **Gli unici dati affidabili sono i confronti empirici in test comparativi indipendenti**, dove la differenza tra buone paste risulta essere di 1–3 °C — quasi irrilevante rispetto alla scelta del dissipatore. Chi spende 60 euro per un dissipatore mediocre e poi cerca una pasta miracolosa sta ottimizzando la variabile sbagliata.

Riferimenti concreti:

- **\*\*Arctic MX-4\*\*** e **\*\*MX-6\*\***: economiche, molto facili da applicare (viscosità perfetta), non conduttive, prestazioni eccellenti, longevità dichiarata di anni. Sono la scelta predefinita per il 90% degli utenti e sono difficili da battere per rapporto prezzo/prestazioni.
- **\*\*Noctua NT-H1\*\*** e **\*\*NT-H2\*\***: eccellenti, molto stabili nel tempo, facili da applicare e pulire. Un po' più costose. La NT-H2 è la versione migliorata.
- **\*\*Thermal Grizzly Kryonaut\*\***: storicamente tra le migliori in termini di prestazioni pure, con un serio avvertimento: soffre di **\*\*pump-out\*\*** (vedi sotto) e si degrada relativamente in fretta con i cicli termici, specialmente sopra gli 80 °C. È buona per i benchmark e per chi riapplica spesso la pasta; è una scelta discutibile per un sistema "monta e dimentica". Esistono varianti (Kryonaut Extreme) e formulazioni più stabili nella stessa famiglia.

La **pompa-via** merita una spiegazione, perché è il principale meccanismo di degrado. Ogni volta che il sistema si scalda e si raffredda, i metalli si espandono e si contraggono in misura diversa; questo produce un micro-movimento tra l'IHS e la base del dissipatore che, ciclo dopo ciclo, **"pompa" la pasta fuori dall'interfaccia**, verso i bordi. Col tempo, al centro (dove il calore è maggiore) restano dei vuoti. Il risultato è un peggioramento graduale delle temperature nell'arco di mesi o anni. Le paste più fluide e con matrici meno stabili sono più suscettibili al fenomeno.



**Metallo liquido.** È una lega di gallio, indio e stagno (a volte genericamente chiamata galinstan), liquida a temperatura ambiente. La sua conduttività è su un altro pianeta: **circa 70–80 W/m·K**, quasi dieci volte quella di un'ottima pasta. Il guadagno reale sull'IHS è tipicamente di **5–12 °C**, e su un die nudo (CPU delidded, laptop, console) può essere anche maggiore. Il riferimento commerciale è **Thermal Grizzly Conductonaut** (ed Extreme).

I rischi, però, sono seri e vanno elencati senza indorare la pillola: 1. È **elettricamente conduttivo**. Una goccia che cade su un socket LGA, su un componente SMD della scheda madre, o sui contatti della CPU può causare un cortocircuito e distruggere l'hardware. In posizione verticale, la CPU è verticale: il metallo liquido, se in eccesso, può gocciolare. 2. **Corrode e amalgama l'alluminio**. Il gallio dissolve letteralmente l'alluminio: crea un amalgama fragile e distrugge il metallo. **Non usarlo mai su una base di alluminio**, né vicino a componenti in alluminio. Va usato solo su rame nichelato o superfici compatibili. 3. **Col tempo può essere "assorbito" nel rame** (diffusione), macchiando permanentemente l'IHS e la base, e perdendo efficacia. 4. È **difficile da applicare**: va steso in uno strato sottilissimo con un cotton fioc, sia sull'IHS che sulla base, e l'area circostante va schermata con nastro isolante o conformal coating.

**In sintesi: il metallo liquido non è per l'utente medio.** Ha senso su una CPU delidded, su un laptop che throttla, su un die nudo. In un normale build desktop, il rapporto rischio/beneficio non lo giustifica.

**PTM7950 e materiali a cambiamento di fase.** Questa è l'innovazione che ha cambiato le carte in tavola negli ultimi anni. Il **PTM7950** (Honeywell) è un **PCM** (Phase Change Material): a temperatura ambiente, si presenta come un sottile foglio semi-solido, non appiccicoso, che può essere tagliato e applicato. Al primo riscaldamento (transizione intorno ai 45 °C), si ammorbidisce, "bagna" perfettamente le due superfici riempiendo le micro-cavità, per poi ri-solidificarsi parzialmente al raffreddamento. Questo ciclo si ripete ad ogni accensione.

Il vantaggio decisivo non è la sua conduttività di picco (che è paragonabile a una buona pasta, intorno agli 8 W/m·K) ma **l'assenza quasi totale di pompa-via**: dato che il materiale si ri-solidifica, non viene espulso dai cicli termici. Il risultato è una stabilità eccezionale a lungo termine: dove la pasta tradizionale degrada di 5–10 °C in tre anni, il PTM7950 resta sostanzialmente invariato. È diventato **lo standard de facto per GPU e laptop**, proprio le applicazioni dove il repaste è difficile e i cicli termici sono aggressivi. Il piccolo prezzo da pagare: nei primi

minuti da freddo, prima che il materiale abbia raggiunto la temperatura di transizione, le prestazioni sono leggermente peggiori. Questo è irrilevante nell'uso reale.

*Nota su un rischio pratico: essendo un prodotto molto ricercato, il PTM7950 è ampiamente contraffatto sui marketplace. Acquistare da venditori affidabili.*

**Pad in grafite.** Fogli di grafite riutilizzabili (il riferimento è **Innovation Cooling Graphite**), con alta conduttività nel piano ma modesta attraverso lo spessore. Non seccano mai, non pompano fuori e possono essere rimossi e reinstallati. Le prestazioni sono tipicamente 2–4 °C peggiori di una buona pasta. Sono una soluzione "monta e dimentica" per chi smonta frequentemente, o per chi vuole zero manutenzione. Una nicchia legittima.

**Thermal pad (per memorie e VRM).** Questi sono diversi e servono a un altro scopo: riempire **gap** di vario spessore (da 0.5 a 3 mm) tra un componente e il dissipatore. Hanno bassa conduttività (1–15 W/m·K) ma sono comprimibili e mantengono il contatto. Si usano su VRAM, VRM e chip SSD. **Non si usano sotto un IHS al posto della pasta:** lì il gap è di micrometri, e serve un materiale che si assottigli, non un pad.

### 8.6.3 Come applicare: quantità e metodi

**La quantità.** La regola tradizionale è "un chicco di riso" o "un pisello". Sono approssimazioni utili ma vanno calibrate sulla dimensione dell'IHS:

- **\*\*AM4\*\*** (IHS piccolo, quadrato con smussi): una quantità equivalente a un chicco di riso grande o un pisello piccolo, al centro.
- **\*\*AM5\*\*** (IHS con caratteristiche aperture sui lati): un pisello al centro. Alcuni preferiscono cinque puntini perché la superficie utilizzabile è di forma "ottagonale".
- **\*\*LGA1700 / LGA1851\*\*** (IHS rettangolare e allungato): un singolo puntino al centro tende a non raggiungere le estremità corte. Meglio una **\*\*linea sottile lungo l'asse maggiore\*\***, o una **\*\*X\*\***, o cinque puntini.

#### **I metodi.**

- **\*\*Puntino centrale (pea method)\*\***: Una singola goccia viene posta al centro e si lascia che la pressione di montaggio la sparga. È il metodo raccomandato dalla maggior parte dei produttori, funziona bene, non introduce bolle e non

richiede abilità. **\*\*Per la maggior parte degli utenti, questo è il metodo giusto.\*\***

- **\*\*X / croce / cinque puntini\*\***: Distribuisce meglio su IHS grandi o rettangolari. Ottimo su LGA1700.
- **\*\*Linea\*\***: Due o tre linee parallele all'asse lungo dell'IHS, per socket rettangolari.
- **\*\*Spalmatura\*\***: La pasta viene spalmata con una spatola o una tessera plastificata prima di posizionare il dissipatore. Dà il massimo controllo sullo spessore, ma **\*\*rischia di intrappolare microbolle d'aria\*\*** se fatto in modo scorretto, ed è il metodo con il maggior margine di errore. Ha senso quando si usa metallo liquido (obbligatorio) o su un die nudo (dove la superficie è piccola e la pressione di montaggio è bassa).

**Pressione di montaggio.** Non è un dettaglio minore: è ciò che espelle la pasta in eccesso e riduce lo spessore residuo. **Le viti del dissipatore vanno serrate a croce, un poco alla volta, alternando**, esattamente come i dadi di una ruota dell'auto: mai serrare completamente una vite e poi passare alla successiva, perché questo inclinerà la base e creerà un contatto non uniforme. Serrare fino al raggiungimento del finecorsa meccanico (i buoni sistemi, come il SecuFirm2 di Noctua, hanno un finecorsa che impedisce il serraggio eccessivo).

**Non sollevare e riposizionare il dissipatore** dopo averlo montato: se viene rimosso, la pasta è compromessa (si sono formate bolle e vuoti) e **deve essere rifatta da capo**, pulendo entrambe le superfici. È tentante "controllare" dopo il montaggio: non fatelo, o se lo fate, siate pronti a pulire e riapplicare.

#### 8.6.4 Errori comuni

**Troppa pasta.** L'errore più comune. Un eccesso non "isola" come vorrebbe la leggenda (perché la pressione ne espelle la maggior parte), ma sborda ai lati, sporca il socket e, nel caso di paste ad alto carico metallico, può causare problemi. Soprattutto, se è troppa e la pressione non è sufficiente a espellerla, lascia uno strato spesso e quindi resistivo.

**Troppa poca pasta.** Un errore più insidioso perché invisibile: aree dell'IHS restano senza contatto, dove l'aria fa da isolante. Ne conseguono temperature elevate e spesso asimmetriche (un core molto più caldo degli altri).

**Bolle d'aria.** Nascono da una stesura malfatta, o dal sollevare e riposizionare il dissipatore.

**Non pulire la vecchia pasta.** Pasta indurita mescolata a pasta nuova dà scarsi risultati. La pulizia si fa con **alcool isopropilico al 99%** (non alcool rosa denaturato, che lascia residui) e un panno che non lasci pelucchi (microfibra o carta da laboratorio; la carta da cucina lascia fibre). Pulire **entrambe** le superfici: IHS e base del dissipatore.

**Dimenticare di togliere la pellicola protettiva dal dissipatore nuovo.** Questo merita una riga in grassetto a sé, perché è un errore reale, frequente, che produce sintomi drammatici (throttling immediato, temperature di 100 °C entro pochi secondi dall'accensione). **Quasi tutti i dissipatori nuovi hanno la pasta termica preapplicata sulla base, e con una pellicola di plastica trasparente o colorata a protezione.** La pellicola va **rimossa** prima del montaggio. Il fatto che sia trasparente e ben aderente la rende facile da non notare. Se un PC nuovo va in throttling istantaneamente, questa è la prima cosa da controllare.

**Applicare la pasta E usare quella preapplicata insieme.** No: o si usa la pasta preapplicata (che è di discreta qualità su quasi tutti i dissipatori di marca) *oppure* la si rimuove completamente con alcool isopropilico e si applica la propria. Mai sovrapporle.

#### 8.6.5 Ogni quanto sostituirla, e repasting GPU

**Sulla CPU.** Con una pasta di qualità (MX-4, NT-H2) e un uso normale, un intervallo di **3–5 anni** è ragionevole. Con una pasta soggetta a pump-out (come la Kryonaut) e carichi termici pesanti, si può scendere a **1–2 anni**. Il segnale che è ora di intervenire è un peggioramento progressivo delle temperature a parità di carico e ambiente: se il PC che due anni fa stava a 75 °C in rendering ora sta a 88 °C, e la polvere è già stata rimossa, la pasta è la principale indiziata.

**Sulla GPU.** Qui la sostituzione dà i risultati più spettacolari, ed è anche la più delicata. Le schede grafiche sono assemblate in fabbrica con paste di qualità variabile e, soprattutto, sono soggette a cicli termici molto violenti. Su una GPU di 3–5 anni, non è raro guadagnare **10–20 °C** con un repaste, e anche di più sull'hotspot (il punto più caldo del die, misurato separatamente sulle schede recenti: se il delta tra temperatura media del core e hotspot supera i 20–25 °C, è un forte indizio di pasta degradata o montaggio non uniforme).

La procedura richiede: smontaggio di backplate e plate, scollegamento dei cavi delle ventole, **fotografare tutto prima di smontare** (posizione e spessore dei thermal pad!), pulizia di GPU e base, applicazione della nuova pasta (**PTM7950** è

la scelta ideale qui, proprio per la sua resistenza al pump-out), **sostituzione dei thermal pad solo se necessario e con spessore identico** — ed è qui la trappola: un pad da 1.5 mm sostituito con uno da 2.0 mm impedisce al plate di appoggiarsi sul die, e la GPU va in throttling severo. Serrare le viti **a croce e progressivamente**, seguendo la numerazione spesso stampata sul backplate.

Per quanto riguarda la garanzia, valgono le stesse considerazioni fatte per il waterblock GPU nella sezione 8.4: aprire una scheda in garanzia è un rischio che va valutato consapevolmente.

#### 8.6.6 Raccomandazioni per tier (pasta termica)

**Entry / uso normale:** Arctic MX-4. Economica, ottima, semplice, sicura. Fine della storia. **Mid / per chi vuole il massimo senza rischi:** Noctua NT-H2 o Arctic MX-6. **High-end / GPU e portatili:** PTM7950, per la stabilità a lungo termine. **Overclock estremo, bare die, CPU deliddate:** metallo liquido, con tutte le dovute precauzioni e piena consapevolezza dei rischi.

---

## 8.7 Ventole sui radiatori (e sui dissipatori)

### 8.7.1 Airflow vs. pressione statica

Una ventola è definita da una **curva caratteristica** che lega portata d'aria a pressione: a pressione zero (nessuna ostruzione), la portata è massima; all'aumentare dell'ostruzione e della pressione richiesta, la portata diminuisce, fino al punto di **massima pressione statica** (mm H<sub>2</sub>O), dove la ventola gira ma non sposta più aria.

Le ventole sono progettate privilegiando un estremo o l'altro della curva:

- Una **\*\*ventola da airflow\*\*** ha pale larghe, spaziate, poche e un motore piccolo: sposta molta aria in spazio libero, ma "affoga" davanti a un ostacolo. È la ventola giusta per un pannello frontale libero o per l'estrazione posteriore non ostruita.
- Una **\*\*ventola da pressione statica\*\*** ha pale numerose, ravvicinate, con un profilo più aggressivo e un hub più grande: sposta meno aria libera ma spinge molto meglio attraverso una resistenza. **\*\*È la ventola obbligatoria per un radiatore o una fitta pila di alette.\*\***

Montare una ventola da airflow su un radiatore da 38 mm con alette fitte significa buttare via una parte significativa delle prestazioni del radiatore. È un errore

comune, spesso fatto per ragioni estetiche (la "bella" ventola RGB è quasi sempre una ventola da airflow).

Nella pratica moderna, molte ventole di qualità sono ibride e lavorano bene in entrambi i regimi (Arctic P12/P14, Noctua NF-A12x25, Phanteks T30, be quiet! Silent Wings): il modo più affidabile per scegliere è leggere le **specifiche di pressione statica** (un valore superiore a 2.0–2.5 mm H<sub>2</sub>O è indicativo di una ventola adatta ai radiatori) e le recensioni con misurazioni a parità di rumore.

### 8.7.2 Push, pull, push-pull

Sono i tre modi di disporre le ventole rispetto al radiatore.

**Push:** le ventole sono davanti al radiatore rispetto alla direzione del flusso, e **spingono** aria al suo interno. È la configurazione più comune e la più efficiente per una singola ventola, perché l'aria arriva al radiatore già in pressione.

**Pull:** le ventole sono dietro al radiatore e ne **estraggono** l'aria. A livello prestazionale è leggermente inferiore al push, perché la ventola pesca anche dai bordi e il flusso è meno uniforme. Ha però un vantaggio pratico: **il radiatore resta accessibile e visibile** e la polvere si deposita sulla faccia esterna del radiatore invece che sulle ventole. In alcuni casi è l'unica configurazione che ci sta fisicamente.

**Push-pull:** ventole su entrambi i lati, che spingono da un lato ed estraggono dall'altro. Il beneficio è reale ma modesto: tipicamente 2–5 °C su un radiatore spesso e a fitte alette, meno di 2 °C su un radiatore sottile. Il costo è doppio in ventole, doppio in potenziale rumore (anche se, a parità di dissipazione, tutte le ventole possono essere tenute a regimi inferiori, il che *riduce* il rumore complessivo), e doppio in spessore occupato — un radiatore da 38 mm in push-pull con ventole da 25 mm occupa **88 mm**, che non stanno in molti case.

**Consiglio operativo:** il push-pull vale la pena su radiatori spessi (38 mm e oltre), su radiatori a elevata densità di alette, e quando l'obiettivo è il silenzio (perché quattro ventole a 800 RPM fanno meno rumore di due a 1.400 RPM a parità di dissipazione). Su un radiatore standard da 27 mm, in un sistema normale, il guadagno non giustifica la spesa.

### 8.7.3 Orientamento: capire da che parte soffia una ventola

Una domanda banale, e a cui si risponde costantemente in modo errato. Ci sono due regole, e sono infallibili: 1. **L'aria entra dal lato con l'adesivo/mozzo col**

**logo... no.** Attenzione: l'aria entra dal lato *aperto* (dove si vedono solo le pale e la cornice) ed esce dal lato dove si vedono i **raggi di supporto** (le quattro o cinque braccia che reggono il motore) e il retro del mozzo. In altre parole: **la ventola soffia verso il lato dove si vede la "griglia" strutturale**. 2. Praticamente tutte le ventole hanno **due piccole frecce stampate sulla cornice** (una indica la direzione del flusso, l'altra la direzione di rotazione). Guardate quelle e fidatevi.

Se si sbaglia, il sintomo è chiaro: temperature elevate e un flusso d'aria che, mettendoci la mano vicino, non va dove dovrebbe.

#### 8.7.4 Controllo: PWM, DC e curve

Le ventole si collegano alla scheda madre con connettori **3-pin (DC)** o **4-pin (PWM)**. Nel controllo **DC** (Direct Current), la scheda madre varia la tensione di alimentazione (da 12 V in giù) per rallentare la ventola; sotto una certa tensione (tipicamente 4–5 V), la ventola non parte affatto. Nel controllo **PWM** (Pulse Width Modulation), l'alimentazione resta a 12 V, e un quarto filo porta un segnale che accende e spegne rapidamente il motore, variando il **duty cycle** (la percentuale di tempo in cui è acceso). Il PWM permette un controllo più fine e velocità minime inferiori (spesso 200–300 RPM), ed è la scelta corretta per un sistema silenzioso.

La **curva della ventola** è impostata nel BIOS/UEFI o tramite software: associa una velocità a ogni temperatura. Due consigli concreti che valgono più di tanta costosa ferramenta:

- **\*\*Collegare le curve delle ventole del case alla temperatura della CPU è un errore comune\*\***, perché la CPU ha transitori di boost molto violenti (da 40 a 80 °C in mezzo secondo, poi giù) che fanno "pompare" le ventole in modo fastidioso. È meglio collegarle a un sensore più lento (la temperatura della scheda madre, o la temperatura del liquido se l'AIO la espone) o, se non possibile, impostare una generosa **\*\*isteresi / tempo di salita e discesa\*\*** (3-5 secondi) per smorzare le oscillazioni.
- **\*\*La pompa dell'AIO non va trattata come una ventola\*\***: si collega al connettore AIO\_PUMP e segue le istruzioni del produttore, che nella maggior parte dei casi sono "100% costante" o una curva molto piatta.

---

## 8.8 Riepilogo operativo — checklist decisionale per il raffreddamento

Da usare in ordine, prima di qualsiasi acquisto.

**1. Quantificare il carico termico effettivo.** ☐ Cercare il consumo energetico effettivo sotto carico pesante della propria CPU in recensioni indipendenti (non il TDP dichiarato: cercare MTP per Intel, PPT per AMD, o meglio ancora, misurazioni in Cinebench o Prime99). ☐ Aggiungere un margine del 15-20% se si prevede di usare PBO / overclock / limiti di potenza sbloccati.

**2. Decidere la tecnologia.** ☐ Sotto ~100 W → single tower economico. Fatto. ☐ 100–200 W → dual tower economico (Thermalright Peerless/Phantom, Arctic Freezer 36). Questa è la scelta predefinita per la stragrande maggioranza degli utenti. ☐ 200–280 W → dual tower di fascia alta o AIO 280/360. Scegliere aria se si privilegia affidabilità, costo, zero manutenzione. Scegliere liquido se si ha RAM alta, si desidera un'estetica pulita, o se il proprio case non ospita torri grandi. ☐ Oltre 280 W → AIO 360/420. Sotto questa soglia, si lasceranno prestazioni sul tavolo. ☐ Custom loop → solo se si vuole raffreddare anche la GPU, si cerca il silenzio assoluto, o lo si fa per hobby. Non è mai la scelta economicamente razionale.

**3. Verificare la compatibilità (tutte e tre, senza saltarne alcuna).** ☐ **Socket:** Il kit di montaggio include il proprio socket (LGA1700 / LGA1851 / AM4 / AM5)? Verificato sul sito del produttore del dissipatore, non sulla pagina prodotto del venditore. ☐ **Altezza (aria):** L'altezza del dissipatore è inferiore all'"altezza massima dissipatore CPU" del case, con almeno 3-5 mm di spazio? ☐ **RAM (aria):** L'altezza dei moduli di memoria è compatibile con lo spazio dichiarato? Se si ha già una torre grande, si è scelta RAM a basso profilo? ☐ **Radiatore (liquido):** Il case supporta quella lunghezza *in quella posizione*? Lo spessore (radiatore + ventole) rientra nello spazio dichiarato, senza toccare VRM o RAM? ☐ Nessun conflitto con il primo slot PCIe o i dissipatori M.2?

**4. Pianificare l'installazione.** ☐ (Liquido) Il radiatore è in **alto**, o sul **frontale con i tubi in basso**. **Mai** in basso. **Mai** frontale con tubi in alto. ☐ (Liquido) La pompa **non è il punto più alto del loop**. ☐ (Liquido) La pompa è collegata al connettore AIO\_PUMP con allarme velocità zero attivo. ☐ Le ventole sul radiatore sono a **pressione statica** ( $\geq \sim 2$  mm H<sub>2</sub>O), non ventole a puro flusso d'aria. ☐ La direzione delle ventole è verificata con le frecce sul telaio. ☐ (Intel LGA1700) Si è considerato un **contact frame** per compensare la deformazione dell'ILM? Vale 3-8 °C per 15-20 €.

**5. Pasta termica.** ☐ **Hai rimosso la pellicola protettiva** dalla base del nuovo dissipatore? (Sì, ricontrolla.) ☐ Se riusi un dissipatore: entrambe le superfici pulite



con **alcool isopropilico al 99%** e un panno che non lascia pelucchi. ☐ Quantità: un pisello al centro (AM4/AM5) o una linea/X (LGA1700/1851). Poca, non tanta. ☐ Viti serrate **a croce, progressivamente**, mai una alla volta fino in fondo. ☐ Dissipatore appoggiato **una volta sola**: se lo sollevi, pulisci e riapplica. ☐ Pasta scelta: MX-4 (default), NT-H2 (premium), PTM7950 (GPU/laptop, longevità), metallo liquido (solo se sai esattamente cosa stai facendo).

**6. Controllo post-installazione.** ☐ Stress test di almeno 15 minuti (Cinebench in loop, Prime95, OCCT) monitorando **simultaneamente** temperatura, frequenza sostenuta e consumo. ☐ Temperature entro i range della tabella in 8.1.4 — ricordando che 90–95 °C su un Ryzen 9 a pieno carico non è un difetto, è il comportamento previsto. ☐ Nessun rumore di gorgoglio dalla pompa dopo i primi giorni di rodaggio. ☐ Curva ventole impostata con adeguata isteresi, per evitare "pompaggio" acustico.

**7. Manutenzione programmata.** ☐ Rimozione polvere da fin stack / radiatore ogni 6–12 mesi. ☐ Repaste CPU ogni 3–5 anni (o prima, se le temperature peggiorano progressivamente a parità di carico). ☐ Repaste GPU dopo 3–5 anni, valutando PTM7950 e fotografando i pad prima dello smontaggio. ☐ (AIO) Prevedere la sostituzione dopo 5–7 anni. ☐ (Custom loop) Cambio liquido e flush ogni 12 mesi. Test di tenuta obbligatorio dopo ogni intervento.

---

*Prossimo capitolo: l'alimentatore e la distribuzione della potenza — ovvero, l'unico componente il cui guasto può portarsi dietro tutti gli altri.*

## Capitolo 9 - Assemblaggio PC, passo dopo passo

### Introduzione: perché questo capitolo è diverso da tutti gli altri

Fino a questo punto, il libro ha lavorato in astratto. Abbiamo studiato la CPU come architettura, la RAM come gerarchia di latenze, la GPU come motore di calcolo parallelo, l'alimentatore come convertitore di energia. Erano oggetti di conoscenza. Da questo capitolo in poi, diventano oggetti fisici: hanno un peso, hanno degli spigoli, hanno dei pin che si piegano, hanno dei connettori che entrano in un solo verso e che si fondono se li inserisci male. La differenza tra sapere cos'è un socket LGA e riuscire a chiudere una levetta di ritenzione senza tremare è la stessa che c'è tra leggere un manuale di volo e volare.

Va detto subito, per alleviare l'ansia: **assemblare un PC è meccanicamente facile**. Non richiede saldature, non richiede misurazioni con il multimetro, non richiede esperienza. È un gioco di incastri pensato apposta perché non si possano fare troppi errori, con connettori polarizzati (cioè, sagomati per entrare in un solo verso) e tacche di allineamento ovunque. Un adulto attento che segue le istruzioni finirà il lavoro in due o tre ore la prima volta, e in quaranta minuti la quinta volta.

Ma — ed ecco il punto — la facilità meccanica coesiste con **poche azioni irreversibili e costose**. Un pin della CPU piegato può significare una scheda madre da 300 euro da buttare. Un connettore ARGB 5V inserito in un header 12V distrugge la striscia LED e, a volte, il controller sulla scheda madre. Un cavo di alimentazione 12V-2×6 non completamente inserito può fondere il connettore della GPU sotto carico. Non c'è una lunga coda di errori medi: c'è un enorme insieme di errori innocui e una minuscola manciata di errori letali. L'intero capitolo è costruito attorno a questa distinzione. Ogni passaggio ti dirà: di cosa hai bisogno, come farlo fisicamente, **quanta forza applicare** (è la variabile che nessuno ti spiega mai), cosa non fare per nessun motivo e come verificare di averlo fatto correttamente prima di proseguire.

Un avvertimento finale sui dati: i nomi dei socket, i modelli dei connettori e gli acronimi dei chipset qui menzionati sono quelli in circolazione al momento della stesura. Sono la parte del libro che invecchia più rapidamente. Le **procedure fisiche** — leve, tacche, impostazioni di coppia, ordine dei passaggi — sono, tuttavia, straordinariamente stabili: chiunque abbia assemblato un PC nel 2015 riconoscerà ogni gesto di un assemblaggio del 2026. Quando i dati saranno volatili, lo indicherò esplicitamente.

---

## 0. Preparazione: il novanta per cento del lavoro è fatto prima di aprire le scatole

### 0.1 Gli attrezzi: pochi, ma quelli giusti

L'attrezzo di cui hai veramente bisogno è **uno**: un cacciavite **Phillips PH2**, magnetico, con un'asta lunga almeno 10-12 centimetri.

Chiariamo l'acronimo, perché è il primo esempio di come funziona questo lavoro. "Phillips" è il nome del tipo di testa della vite — la croce con i lati leggermente svasati — e **PH2** è la sua dimensione. PH0 e PH1 sono più piccoli, PH3 è più grande. Praticamente tutte le viti di un PC moderno (viti della scheda madre, viti dell'alimentatore, viti del pannello, viti delle staffe PCIe, viti delle ventole) usano la testa PH2. Le uniche eccezioni sono le micro-viti per gli SSD M.2, che richiedono un PH1 o addirittura un PH0, e che generalmente vengono fornite con il loro cacciavite nella scatola della scheda madre.

La ragione del **magnetico** merita una riga, perché è il punto che spaventa di più i principianti: no, un cacciavite magnetizzato **non danneggia** i componenti del PC. La paura nasce da un'analogia sbagliata con i vecchi hard disk meccanici e i floppy disk, e in ogni caso, il campo di un cacciavite magnetizzato è molto debole e si estende solo per pochi millimetri. Al contrario, il magnetismo ti salva la giornata: le viti si attaccano alla punta e non cadono all'interno del case, in quello spazio irraggiungibile sotto la scheda madre da cui possono essere recuperate solo capovolgendo tutto e scuotendo. Una vite persa in un case chiuso che viene poi acceso è, questo sì, una potenziale fonte di cortocircuito.

Intorno al cacciavite, poco altro è necessario:

**Fascette per cavi.** Ne avrai bisogno di una decina. Quelle in nylon usa e getta vanno benissimo (da tagliare con tronchesi, mai strappare); se prevedi di lavorare frequentemente all'interno del PC, le **fascette in velcro** sono preferibili, in quanto riutilizzabili e spesso incluse con l'alimentatore o il case.

**Una luce.** Il retro di un case, l'area degli header sul bordo inferiore della scheda madre, l'interno di un alloggiamento per hard disk: sono tutti luoghi bui. Una lampada da scrivania regolabile o una lampada frontale trasforma un'operazione goffa in una chiara. Usare la luce del telefono, tenuta con la mano sinistra mentre

la mano destra cerca di inserire un connettore F\_PANEL da tre millimetri, è una ricetta per la frustrazione.

**Una superficie ampia, piana, stabile e non tessile.** Un tavolo da pranzo sgombro è perfetto. Ti serve spazio per il case sdraiato, per la scatola della scheda madre (che ti farà da banco di lavoro, ci arriviamo), per i componenti in attesa di installazione e per le scatole vuote, che vanno conservate: contengono gli accessori, sono utili per eventuali resi, e la scatola della scheda madre è la superficie ideale per il pre-assemblaggio.

**Tronchesine o forbici** per le fascette, e opzionalmente un **contenitore per le viti** — una ciotola, un portauova, un tappo di barattolo. Le viti dei PC sono di almeno cinque tipi diversi, e mescolarle è un modo lento per perdere venti minuti.

Cosa **non** ti serve, nonostante quello che potresti sentirti dire: pinze (se ti servono le pinze, stai sbagliando qualcosa), pasta termica se il dissipatore ce l'ha già applicata, un tappetino antistatico professionale, un tester.

## 0.2 Elettricità Statica (ESD): la Paura Giusta, nella Giusta Misura

**ESD** sta per *ElectroStatic Discharge*, scarica elettrostatica. È il fenomeno per cui due materiali che sfregano tra loro si scambiano elettroni, e uno dei due si carica; quando quel corpo carico tocca un conduttore a potenziale diverso, la carica si scarica repentinamente, con una differenza di potenziale che può facilmente superare i **mille volt** e arrivare a decine di migliaia. È la scintilla che prendi toccando la maniglia della macchina d'inverno, ed è lo stesso fenomeno che ti fa "scoppiettare" quando ti togli un maglione di lana al buio.

Il punto delicato è questo: la soglia a cui **tu** percepisci una scossa è intorno ai 2.000-3.000 volt, ma i transistor moderni, con isolanti di gate spessi pochi nanometri, possono essere danneggiati da scariche di **poche centinaia di volt**. Questo significa che c'è un ampio intervallo in cui puoi distruggere un componente **senza accorgertene**. Peggio: il danno da ESD è spesso *latente*. Non uccide il chip subito; lo indebolisce. Il PC funziona, magari per settimane, e poi comincia a dare errori casuali, crash inspiegabili, corruzione di dati. È il tipo di guasto più difficile da diagnosticare.

Detto questo, va anche detto che le probabilità sono a tuo favore: i componenti moderni hanno diodi di protezione ESD sui loro ingressi, e milioni di persone assemblano PC ogni anno senza precauzioni e senza conseguenze. La strategia razionale non è la paranoia; è la **routine**. Poche semplici regole, sempre le stesse:

1. **Lavora su una superficie rigida, non su tappeti, moquette o divani.** I tessuti sono la fonte primaria di cariche statiche. Se il pavimento è in moquette, lavora su un tavolo e non strisciare i piedi. 2. **Scarica te stesso prima di toccare i componenti** toccando una grande superficie metallica appena verniciata — tipicamente lo **chassis del case del PC** — e ripeti questa azione ogni volta che ti sei alzato in piedi, hai camminato, o ti sei tolto o messo una felpa. 3. Se vuoi la soluzione tecnicamente corretta, usa un **cinturino antistatico da polso**: una cinghia conduttiva al polso, collegata tramite un cavo (che contiene una resistenza da 1 MΩ per la tua sicurezza) a una messa a terra. La messa a terra più comoda è lo chassis del case del PC. È bene sapere una cosa che quasi nessuno spiega: il cinturino da polso **non "scarica" i componenti**; serve a mantenere **te e il case allo stesso potenziale**, in modo che non ci sia mai un salto di tensione tra la tua mano e la scheda. Il PC non ha bisogno di essere collegato alla presa di corrente (anzi, non dovrebbe esserlo, ne parleremo tra un attimo). L'equipotenzialità è sufficiente. 4. **Conserva i componenti nelle loro buste antistatiche** (quelle grigie, metalliche che formano una gabbia di Faraday) finché non li usi. E non posizionare mai una scheda madre *sopra* la sua busta antistatica: la superficie esterna è leggermente conduttiva e può creare percorsi indesiderati. Posizionala **sopra la scatola di cartone**, che è l'isolante ideale. 5. **Maneggia le schede dai bordi.** Mai dai contatti dorati, mai dai chip.

Una nota che sfata un mito comune: **non** lasciare il PC "collegato con l'interruttore spento per avere la messa a terra". Questo era un consiglio degli anni Novanta, quando gli alimentatori ATX non sempre avevano tensioni attive. Oggi, un alimentatore collegato alla rete elettrica mantiene la linea **5 V standby (+5VSB)** attiva anche quando il PC è spento: se lavori all'interno del case con l'alimentatore collegato, ci sono parti sotto tensione. La regola moderna è: **cavo di alimentazione scollegato dalla parete, sempre, quando le mani sono all'interno del case.**

### 0.3 Il controllo finale di compatibilità: l'ultima uscita prima dell'autostrada

Aprire una scatola significa, in molti negozi, rinunciare al diritto di reso "per ripensamento" (il diritto di recesso rimane, ma un prodotto aperto e assemblato può essere contestato). Quindi, **prima di rompere il primo sigillo**, fai un controllo finale. È noioso e ti salverà una volta su cinque.

Prendi la scatola della scheda madre — è il fulcro di tutte le compatibilità — e controlla questi sei punti, uno per uno:

| # | Cosa controllare          | Come                                                                                                                                                                                           | Sintomo se errato                                                                                  |
|---|---------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------|
| 1 | <b>Socket</b>             | Il socket stampato sulla scatola della mobo (es. AM5, LGA1851, LGA1700) deve corrispondere <i>esattamente</i> al socket della CPU                                                              | La CPU non si inserisce fisicamente                                                                |
| 2 | <b>Supporto BIOS CPU</b>  | Sul sito del produttore della mobo, sezione "CPU Support List", trovare il <i>modello esatto</i> della propria CPU e leggere la versione minima del BIOS richiesta                             | La CPU è compatibile con il socket ma il PC non fa il POST: è necessario un aggiornamento del BIOS |
| 3 | <b>RAM: tipo e QVL</b>    | DDR4 e DDR5 <b>non</b> sono interscambiabili (posizione notch diversa, voltaggio diverso, pinout diverso). Controllare anche la QVL ( <i>Qualified Vendor List</i> , l'elenco dei kit testati) | RAM che non si inserisce, o si inserisce ma non tiene la frequenza dichiarata                      |
| 4 | <b>Spazio dissipatore</b> | Altezza massima dissipatore consentita dal case (in mm) $\geq$ altezza del proprio dissipatore. Per gli AIO: il case supporta un radiatore di quella lunghezza                                 | Il pannello laterale non si chiude                                                                 |

|   |                               |                                                                                                                                                                        |                                                       |
|---|-------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------|
|   |                               | <i>in quella posizione?</i>                                                                                                                                            |                                                       |
| 5 | <b>Lunghezza GPU</b>          | Lunghezza massima GPU consentita dal case $\geq$ lunghezza della propria GPU (nota: i cavi di alimentazione occupano altri 3-4 cm se escono lateralmente)              | La GPU non si inserisce, o urta i bay degli hard disk |
| 6 | <b>PSU: watt e connettori</b> | Potenza sufficiente (con margine) <b>e</b> presenza fisica dei connettori richiesti: quanti PCIe 8-pin richiede la GPU? Serve un 12V-2×6? Quanti EPS richiede la mobo? | Non si riesce ad alimentare tutto                     |

Il punto 2 merita un paragrafo a sé, in quanto è la trappola più insidiosa nel moderno PC building. Un socket ha una vita utile che abbraccia più generazioni di CPU: AM5, ad esempio, ospita CPU rilasciate a distanza di anni. Una scheda madre prodotta nel 2023 e rimasta in magazzino potrebbe avere un firmware che semplicemente **non riconosce** una CPU rilasciata nel 2025: il socket corrisponde, la CPU si installa, ma il PC non si avvia perché il BIOS non sa come inicializzarla. La soluzione esiste ed è ottima, ma va pianificata **in anticipo**: si chiama **BIOS Flashback** (nomi commerciali: *BIOS Flashback*, *Q-Flash Plus*, *Flash BIOS Button*), una funzionalità presente sulle schede madri di fascia media e alta che permette di aggiornare il BIOS **senza CPU, RAM o GPU installate**, semplicemente collegando l'alimentazione, inserendo una chiavetta USB formattata FAT32 con il file del BIOS rinominato come richiesto, e premendo un piccolo pulsante sul retro. Se la vostra CPU è nuova e la vostra scheda madre potrebbe essere di vecchio stock, **verificate che la scheda abbia il Flashback**: è la differenza tra un'ora di attesa e una settimana persa a cercare di farsi prestare una vecchia CPU.

#### 0.4 La Strategia: Pre-assemblaggio "a banco"

Ecco il consiglio che distingue chi ha assemblato dieci PC da chi sta assemblando il primo, e che nessuna guida illustrata sottolinea abbastanza: **non installare prima la scheda madre nel case.**

Il metodo corretto è il **pre-assemblaggio a banco** (detto anche *bench build* o *breadboarding*). Si posiziona la scheda madre **sopra la sua scatola di cartone** — non sulla busta antistatica, come detto — e su quella superficie comoda, ben illuminata e facilmente accessibile, si installano: **CPU, RAM, SSD M.2 e (se ad aria) il dissipatore**. Solo dopo si prende il blocco così assemblato e lo si cala nel case.

Ci sono tre solide ragioni per questo.

Il primo è **ergonomico**: installare una CPU dentro un case significa lavorare in verticale, con poca luce, e il rischio che il componente scivoli. Installarla su un tavolo significa lavorare in orizzontale, con la gravità che assiste invece di ostacolare, permettendo di vedere chiaramente i pin e le tacche. Lo stesso vale per la RAM, che va spinta con decisione: farlo con la scheda madre già avvitata nel case significa flettere il PCB (il *Printed Circuit Board*, il supporto in fibra di vetro su cui è costruita la scheda) contro i suoi punti di fissaggio; farlo su una superficie rigida significa che la forza viene assorbita dal tavolo.

Il secondo è **diagnostico**, ed è il più importante. Il pre-assemblaggio consente il **test POST fuori dal case**: installa la CPU, il dissipatore, un singolo stick di RAM, la GPU e l'alimentatore, collega un monitor e prova ad accenderlo cortocircuitando momentaneamente i due pin del Power Switch con la punta di un cacciavite (o usando il pulsante di accensione integrato, se la scheda ne ha uno). Se compare la schermata del BIOS, sei certo che i quattro componenti più costosi e difficili da sostituire **funzionano e sono compatibili tra loro**. Se il PC non si avvia, hai un sistema nudo con cinque cavi, dove isolare il problema è banale. Confronta questo con lo scenario alternativo: installi tutto nel case, con quaranta cavi, ventole, hard disk, e non si avvia. Ora il colpevole potrebbe essere qualsiasi cosa, e per indagare, devi smontare tutto. Il test POST richiede dieci minuti e li ripaga dieci volte nello scenario peggiore.

Il terzo è **pratico**: alcuni case rendono impossibile montare il backplate di certi dissipatori una volta avvitata la scheda madre, se il ritaglio posteriore del *motherboard tray* non è allineato con il socket. Meglio scoprirlo prima.



L'unica eccezione alla regola è il **radiatore di un AIO** (*All-In-One*, il sistema di raffreddamento a liquido chiuso e pre-assemblato). Il waterblock viene montato sulla CPU sul banco, ma il radiatore, che è collegato ad esso da tubi corti e rigidi, deve essere montato **dopo** che la scheda madre è nel case. Ne parleremo in dettaglio nei punti 4 e 8.

---

## 1. Installazione della CPU sulla scheda madre

È il primo e più temuto passo. Facciamolo bene.

### 1.1 Le due filosofie: LGA e PGA

Storicamente, ci sono stati due modi per collegare una CPU a una scheda madre.

**PGA** (*Pin Grid Array*): i pin — centinaia di sottili aghi metallici — sono **sulla CPU**, e il socket sulla scheda madre è una matrice di fori. Questo è lo schema usato da AMD fino al socket AM4 incluso. Il rischio è interamente sul processore: se lo fai cadere o lo posizioni in modo errato, pieghi i suoi pin, e i pin di una CPU possono (con pazienza, una lente d'ingrandimento e la punta di una lametta da barba) anche essere **raddrizzati**.

**LGA** (*Land Grid Array*): i pin si trovano **sul socket della scheda madre** — un migliaio o più di aghi elastici, sottilissimi, montati su una piastrina — e la CPU ha solo dei pad di contatto piatti e dorati (*lands*, appunto). È lo schema usato da Intel da vent'anni e, dal 2022, anche da AMD con il socket **AM5**. Il rischio si è spostato: la CPU è quasi indistruttibile, ma il socket della scheda madre è **estremamente fragile**. Un pin LGA piegato è largo qualche decina di micron; raddrizzarlo richiede un microscopio, mano ferma e un'incredibile fortuna, e nella maggior parte dei casi la scheda madre è da buttare — e le garanzie **non coprono** i danni meccanici al socket.

Conseguenza operativa, valida per **tutte** le piattaforme attuali (Intel LGA e AMD AM5):

***MAI, per nessun motivo, toccare i pin del socket. Non con le dita, non con un cacciavite, non con una spazzola, non con un panno. Se cade qualcosa nel socket, non "spazzolatelo via": soffiate delicatamente, o usate aria compressa da lontano.***

## 1.2 La Procedura, Passo per Passo

Il socket è coperto da un **coperchietto di plastica** (solitamente nero) protettivo. **Non toglietelo a mano.** Sui socket moderni si stacca da solo quando si chiude la levetta con la CPU dentro, oppure va rimosso solo dopo aver aperto il meccanismo. Strapparla via prematuramente è uno dei modi più comuni per danneggiare i pin. (Conservatelo: se un giorno doveste mandare la scheda madre in RMA — *Return Merchandise Authorization*, la procedura di reso in garanzia — va riattaccato, e alcuni produttori rifiutano i resi senza il coperchietto.)

**Passo 1 — Aprire il meccanismo di ritenzione.** Su AM5 e Intel LGA, il principio è lo stesso: una levetta metallica laterale, tenuta da un gancio. Premete la levetta **verso il basso e leggermente di lato** per sganciarla, quindi sollevatela fino in fondo (circa 90-100 gradi). Vedrete la piastra di ritenzione (*load plate*) sopra il socket sollevarsi. La levetta oppone una notevole resistenza in questa fase: è normale, è una molla precaricata.

**Passo 2 — Prendere la CPU.** Prendetela **dai bordi laterali**, con pollice e indice, come fareste con un CD. Mai dalle facce.

**Passo 3 — Allineare.** Questo è il passo cruciale, e va fatto **guardando**, non armeggiando. Ci sono due sistemi di allineamento ridondanti:

- Un **\*\*triangolo dorato\*\*** stampato su un angolo del package della CPU deve corrispondere a un **\*\*triangolino\*\*** (o una freccia, o un angolo smussato) stampato su un angolo del socket. Su AM5, il triangolo è ben visibile; su Intel LGA, lo troverete serigrafato sulla cornice.
- Delle **\*\*tacche\*\*** (mezze lune) sui lati corti del package si inseriscono in apposite **\*\*linguette\*\*** sul socket. Sono intenzionalmente asimmetriche: se la CPU è ruotata, non si appoggerà piatta.

**Passo 4 — Appoggiare, non premere.** Questa è la frase da ricordare: **la CPU si appoggia, non si inserisce.** Tenetela orizzontale, portatela sopra il socket e abbassatela **dritta dall'alto**, senza inclinarla, senza farla scivolare lateralmente sui pin. Deve **cadere nella sua sede con un movimento di un millimetro** e rimanere lì ferma. La forza da applicare in questo passo è **zero**. Se dovette premere, è sbagliato: sollevatela dritta e riprovate.

**Come verificare di aver fatto correttamente:** con un dito, date un leggerissimo colpetto laterale alla CPU. Dovrebbe avere un micropigiama (una frazione di millimetro) e tornare in posizione. Se non si muove *per niente*, potrebbe essere

incastrata storta; se dondola vistosamente, non è in sede. Poi guardate il profilo **da sopra e di lato**: la CPU deve essere perfettamente parallela al piano del socket, senza alcun angolo sollevato.

**Fase 5 — Chiudere.** Abbassate la piastra di carico e riportate la levetta in basso, re-ingaggiandola sotto il gancio. **Qui, la resistenza è forte, e questo spaventa tutti.** La forza necessaria per chiudere un moderno socket LGA è nell'ordine di **50-70 newton** (l'equivalente di cinque-sette chilogrammi di spinta): serve a premere la CPU contro oltre un migliaio di pin elastici, assicurando un contatto affidabile su ognuno. **È normale sentire una resistenza significativa e anche un piccolo scricchiolio.** Quello che *non* è normale è un **blocco duro**: se la levetta non scende con pressione progressiva e decisa, **fermatevi**, riaprite e ricontrollate l'allineamento. La resistenza è elastica e continua; l'ostacolo è duro e improvviso. Imparare a distinguere queste due sensazioni è, letteralmente, l'abilità chiave per questo passaggio.

Il cappuccio di plastica, sui socket Intel, salterà via da solo alla chiusura. Su AM5, va rimosso durante il processo secondo manuale.

### 1.3 Errori comuni

**Pin piegato.** Questo deriva quasi sempre da due azioni: far scivolare la CPU sul socket invece di appoggiarla, o forzare la levetta con la CPU storta. Se, dopo un errore, il PC non si avvia, o si avvia ma non vede metà della RAM (i pin dei canali di memoria passano dal socket!), sospettate un pin piegato. Ispezionatelo con una torcia radente e una lente d'ingrandimento: i pin devono formare file perfettamente regolari, come un campo di grano pettinato. Una fila che "ondeggia" indica un pin fuori posto.

**CPU montata storta ("a 90 gradi").** Impossibile su una piattaforma sana, perché la CPU non è quadrata nei suoi ancoraggi — ma è possibile forzandola. Se avete anche solo un dubbio, riaprite e guardate il piccolo triangolo.

**Toccare la superficie dorata (IHS).** L'*IHS* (*Integrated Heat Spreader*, il coperchio metallico che vedete sopra la CPU) va tenuto pulito: le impronte digitali lasciano unto, che è un pessimo conduttore termico. Se lo toccate, pulitelo con un panno in microfibra e alcool isopropilico.

**Non conservare la cover del socket.** Vedi sopra: può invalidare la garanzia.

---

## 2. Installazione della RAM

Questo sembra il passaggio più banale, ma è in realtà la causa numero uno di "il mio nuovo PC non si accende".

### 2.1 Perché non tutti gli slot sono uguali: dual channel

La memoria di sistema comunica con la CPU tramite l'**IMC** (Integrated Memory Controller, il controller di memoria che ora risiede **dentro** la CPU, non più nel chipset). L'IMC delle moderne CPU consumer è **dual channel**: espone due canali indipendenti alla RAM, ognuno con il proprio bus. Se populate un solo canale, dimezzate la banda disponibile. L'effetto è drammatico dove la banda conta — nelle **iGPU** (GPU integrate, la grafica integrata nella CPU, che usa la RAM di sistema come memoria video) può significare **il doppio dei frame**; nel gaming con GPU dedicata, parliamo comunque di percentuali a doppia cifra nei casi peggiori.

Ora: una scheda madre ATX standard ha **quattro** slot DIMM, ma ci sono **due** canali. Ogni canale ha due slot. La domanda diventa: se ho due banchi, dove li metto?

La risposta, quasi universalmente, è: **negli slot 2 e 4 a partire dalla CPU**, cioè quelli etichettati **A2 e B2** (o **DIMM\_A2 / DIMM\_B2**, o su alcune schede DDR5 con nomenclatura diversa). Sono i due slot **più lontani** dalla CPU tra quelli disponibili, ed è controintuitivo: si penserebbe che più vicino sia meglio.

La ragione è l'**integrità del segnale**. Le tracce che trasportano il bus di memoria dalla CPU agli slot sono linee ad altissima frequenza; uno slot vuoto lasciato "prima" di uno popolato crea uno **stub**, una sezione non terminata della linea che genera riflessioni del segnale. La topologia a *daisy-chain* usata dalla stragrande maggioranza delle schede consumer è progettata e ottimizzata affinché il segnale sia più pulito quando vengono popolati gli **slot terminali**. Su piattaforme AM5 e DDR5 in generale, dove le frequenze sono molto alte e il controller è già sotto stress, questo non è un dettaglio accademico: installare due banchi negli slot sbagliati può significare **non riuscire ad avviare il profilo EXPO/XMP**, o non fare il POST del tutto.

***La regola d'oro: apri il manuale della tua scheda madre alla pagina "Configurazione della memoria" e leggi la tabella. Trenta secondi ti separano dalla certezza. La tabella ti dice esattamente, per 1, 2 e 4 moduli,***

*quali slot popolare. Non tirare a indovinare, non affidarti alla memoria: alcuni modelli (rari, ma esistono) richiedono A1/B1.*

Una nota che vale il prezzo del capitolo: **due banchi sono meglio di quattro**. Con quattro moduli, l'IMC deve pilotare il doppio dei carichi elettrici, e la frequenza massima stabile **cala**, spesso in modo significativo (su DDR5, un kit che supporta 6000 MT/s con 2 moduli potrebbe faticare sopra i 4800 con 4 moduli). Se ti servono 32 GB, compra **2×16**, non 4×8. E soprattutto: **non mescolare kit diversi**. Due kit 2×16 comprati in momenti diversi, anche se identici sull'etichetta, potrebbero avere chip di produttori diversi e non funzionare insieme alla frequenza nominale. Un kit è testato *nel suo insieme*: se un giorno vuoi 64 GB, compra un nuovo kit 2×32.

## 2.2 La procedura

**Passo 1 — Apri le clip.** Le clip sono le levette di plastica alle estremità dello slot. Alcune schede hanno clip su **entrambi** i lati, mentre altre (sempre più comuni, per fare spazio alla GPU) hanno una clip su un solo **lato**, con l'altra estremità fissa. Guarda e apri quelle presenti, spingendole verso l'esterno finché non scattano.

**Passo 2 — Allinea la tacca.** Il modulo DIMM ha una **tacca** (un'indentazione) sul bordo dei contatti, **non centrata**: non è al centro. Lo slot ha una linguetta corrispondente. Ruota il modulo finché la tacca non si allinea. **Questa tacca è il motivo per cui non puoi installare DDR4 su una scheda DDR5**: è in una posizione diversa proprio per rendere gli errori fisicamente impossibili (le due generazioni hanno tensioni e pinout incompatibili, e un inserimento forzato distruggerebbe qualcosa).

**Passo 3 — Premi.** Questo è l'altro punto in cui devi superare la paura. Posiziona il modulo nello slot, assicurati che sia **perfettamente verticale e allineato**, quindi premi **con i pollici sulle due estremità superiori del modulo, una alla volta o insieme**, con **forza ferma e progressiva**. La forza necessaria è **notevole**: stiamo parlando di una spinta paragonabile a quella che useresti per chiudere una valigia piena. Non è un gesto delicato.

Il modulo scende, e le clip — spinte dalla forma del PCB — **si chiudono da sole con un CLICK udibile e distinto**. Se le clip sono su entrambi i lati, dovresti sentire **due click**. Da qui l'espressione che sentirai ovunque: *"premi fino al doppio click."*

**Come controllare di aver fatto correttamente:** guarda il modulo **di lato**, **all'altezza dello slot**, e verifica che la **linea dorata dei contatti sia completamente scomparsa** all'interno dello slot, **uniformemente per tutta la sua lunghezza**. Poi prova a tirare delicatamente il modulo verso l'alto: non dovrebbe muoversi di un millimetro. Infine, controlla che le clip siano **verticali e chiuse**, impegnate nelle tacche laterali del modulo.

### 2.3 L'errore che colpisce tutti: il modulo semi-inserito

È statisticamente **la causa numero uno** di "PC nuovo che non fa niente": il modulo è inserito, sembra dentro, la clip da un lato si è chiusa, ma **dall'altro lato è rimasto sollevato di un millimetro**. Il contatto elettrico è parziale o assente, il POST fallisce, il PC si accende (le ventole girano!) ma non dà segnale video, e il LED diagnostico **DRAM** rimane acceso.

Perché succede così spesso? Perché la forza necessaria è maggiore di quanto l'istinto suggerisca, e perché premendo con un solo pollice al centro il modulo tende a incastrarsi da un lato e rimanere alto dall'altro. **Premi alle estremità. Ascolta i click. Guarda i contatti.**

---

## 3. Installazione SSD M.2

### 3.1 Cos'è e quale slot scegliere

Un **SSD M.2** è un'unità a stato solido su una piccola scheda a circuito rettangolare (tipicamente 22 × 80 mm, da cui la designazione **2280**) che si collega direttamente a uno slot sulla scheda madre, senza cavi. Nella quasi totalità dei casi moderni, si tratta di unità **NVMe** (*Non-Volatile Memory Express*, il protocollo specificamente progettato per la memoria flash) che comunicano tramite il bus **PCIe** (*Peripheral Component Interconnect Express*, il bus seriale basato su lane che collega CPU e periferiche).

E qui sta la scelta importante: **non tutti gli slot M.2 su una scheda madre sono uguali**.

Una scheda madre moderna ha tipicamente 2, 3 o 4 slot M.2. Di questi, **solo uno** — quasi sempre quello **più vicino alla CPU**, tra il socket e il primo slot PCIe x16 — è collegato **direttamente alle lane PCIe della CPU**. Gli altri passano attraverso il **chipset**, il chip che funge da hub di espansione ed è collegato alla CPU tramite un link condiviso (DMI su Intel, un link PCIe dedicato su AMD).

Ci sono due conseguenze pratiche. La prima è la **larghezza di banda**: lo slot dalla CPU offre generalmente l'ultima generazione PCIe e x4 completo (quattro lane); gli slot dal chipset possono essere di una generazione più vecchia, e in ogni caso condividono la larghezza di banda del link chipset ↔ CPU con tutto il resto (USB, SATA, rete, schede di espansione). La seconda è la **latenza**: passare attraverso il chipset aggiunge un passaggio.

***Regola:** Il tuo SSD primario — quello con il sistema operativo — va nello **slot M.2 primario, quello collegato alla CPU**. Il manuale lo indica esplicitamente, spesso chiamandolo *M2\_1*, *M2A\_CPU*, o simili, e specifica sempre quali lane utilizza.*

C'è una seconda ragione per leggere il manuale: la **condivisione delle risorse**. Su molte schede, popolare un certo slot M.2 **disabilita** le porte SATA, o riduce lo slot PCIe x16 secondario da x4 a x2. Questi sono normali compromessi (le linee sono una risorsa finita), ma dovrebbero essere noti in anticipo, non scoperti dopo aver installato tre unità che non compaiono.

### 3.2 La procedura

**Fase 1 — Rimuovere il dissipatore M.2 della scheda madre.** Le schede madri moderne coprono gli slot M.2 con una piastra metallica (a volte un vero e proprio dissipatore alettato). Si svita con una o due piccole viti (PH1). Rimuoverlo e metterlo da parte con la sua vite.

**Fase 2 — Rimuovere la pellicola dal pad termico.** Questo è il passaggio che **quasi tutti dimenticano**, e vale la pena sottolinearlo: sotto il dissipatore c'è un **pad termico** (un cuscinetto di materiale gommoso conduttivo), e sopra il pad c'è una **pellicola protettiva trasparente. Deve essere rimossa**. Se la si lascia, si è inserito un isolante tra il chip e il dissipatore, e il vostro SSD subirà *thermal throttling* (riduzione automatica delle prestazioni a causa di temperatura eccessiva) sotto carico. La pellicola è spesso invisibile a uno sguardo casuale: passare un'unghia su un angolo per trovarne il bordo.

**Fase 3 — Regolare il distanziatore.** Lo slot M.2 accetta diverse lunghezze (2242, 2260, 2280, 22110: le ultime due cifre sono la lunghezza in millimetri). Il punto di montaggio deve essere spostato nel foro corrispondente alla lunghezza del vostro SSD — quasi sempre 2280, che di solito è l'impostazione predefinita. Molte schede recenti hanno sostituito la vite con una **clip a scatto** (nomi commerciali: *M.2 Q-Latch*, *EZ Latch*), che si ruota o si preme senza attrezzi: molto più comoda.



**Fase 4 — Inserire a 30 gradi.** L'SSD **non** entra dritto. Deve essere presentato allo slot con un'**angolazione di circa 20-30 gradi**, spinto finché i contatti non sono completamente inseriti (la tacca sui contatti, come per la RAM, assicura l'orientamento corretto), e **poi abbassato** in piano. La forza è modesta: sentirete il modulo scivolare e fermarsi. Quando lo rilasciate, l'SSD si solleverà di qualche grado — questo è normale, è la molla dei contatti.

**Fase 5 — Fissare.** Tenere l'SSD in piano con un dito e avvitare la micro-vite (o chiudere la clip). **Non stringere troppo:** si sta avvitando una vite M2 su un PCB sottile. "A mano più un soffio" è più che sufficiente; stringere di più rovinerà la filettatura o creperà l'SSD.

**Fase 6 — Rimettere il dissipatore** (con la pellicola rimossa!) e avvitarlo.

**Come controllare:** L'SSD dovrebbe essere piatto, senza gioco. Ma il vero controllo avviene al primo avvio, nel BIOS: se l'unità non compare nell'elenco dei dispositivi di archiviazione, spegnere e ricontrollare l'inserimento.

---

## 4. Installazione del dissipatore

Ecco la parte più delicata e più incompresa dell'intero assemblaggio: la pasta termica. Chiariamo prima il principio, poi le due procedure.

### 4.1 Il principio: perché esiste la pasta termica (e dovrebbe SEMPRE essere applicata)

L'IHS della CPU e la base del dissipatore (la *cold plate*) appaiono perfettamente lisce. Non lo sono. Al microscopio, entrambe le superfici sono catene montuose: rugosità di qualche micron, più eventuali deformazioni macroscopiche (molti IHS sono leggermente concavi o convessi). Se le appoggi una sull'altra, il contatto metallo-metallo avviene solo su una **piccola frazione della superficie** — il resto sono microscopiche sacche d'aria. E l'aria è uno dei **più efficaci isolanti termici** che si conoscano (è il motivo per cui funzionano i piumini d'oca e i doppi vetri).

La **pasta termica** (*TIM*, *Thermal Interface Material*) serve esclusivamente a **riempire quelle sacche d'aria**. Non è fatta per "condurre meglio del metallo" — anzi, la pasta conduce il calore **molto peggio** del rame. Serve per essere migliore **dell'aria che sostituisce**. Da questo discende immediatamente la regola d'oro dell'applicazione:



*La pasta termica va applicata nella quantità minima sufficiente a riempire gli interstizi. Di più non è meglio: è peggio, perché uno strato spesso di pasta è uno strato spesso di materiale mediocre che allontana i due metalli.*

E, altrettanto importante:

*La pasta termica va **SEMPRE** applicata tra la CPU e la cold plate. Sempre. Aria o liquido non fa differenza. Questa è una confusione che sento costantemente: la gente crede che nei sistemi a liquido "ci pensi il liquido". No. Il liquido lavora all'interno del waterblock; l'interfaccia tra l'IHS della CPU e il fondo del waterblock è **identica** a quella di un dissipatore ad aria, e ha esattamente la stessa necessità di pasta.*

**Quanta, e come.** Il metodo più affidabile e universale è il **chicco centrale**: una goccia al centro dell'IHS, del diametro di **un chicco di riso / un pisellino** (4-5 mm). La pressione di montaggio la sparge radialmente e uniformemente da sola, espellendo l'aria verso i bordi — che è esattamente quello che si vuole. Spalmare a mano con una spatolina sembra più "professionale" ma introduce facilmente bolle d'aria; la X diagonale e i cinque puntini sono variazioni accettabili, utili su IHS molto allungati (come quelli rettangolari di certe piattaforme HEDT o LGA1700, dove alcuni preferiscono una **sottile linea** lungo l'asse maggiore). Per i dettagli su conduttività, paste a metallo liquido, pump-out e longevità, si rimanda al capitolo sul raffreddamento; qui, il focus è sull'azione in sé.

Due avvertenze finali: **non spalmare col dito** (olio della pelle), e **non montare e smontare "per controllare"**. Se sollevi il dissipatore dopo averlo appoggiato, l'unico modo corretto di procedere è **pulire tutto con alcol isopropilico e riapplicare da capo**: il film si è rotto e ha inglobato aria.

Ultimo punto: **molti dissipatori arrivano con la pasta preapplicata** sulla cold plate (uno strato grigio, spesso con un pattern serigrafato). In quel caso, **non applicare altra pasta**. E, soprattutto, **controlla se c'è una pellicola di plastica sopra**: ci arriveremo, perché è l'errore più catastrofico di tutto il capitolo.

#### 4.2 CASO A — Dissipatore ad Aria

**Fase 1 — Il backplate.** La maggior parte dei dissipatori ad aria di qualità non usa il sistema di ritenzione di serie della scheda madre, ma uno proprio: una placca metallica o plastica (il **backplate**) che va posizionata sul **retro** della scheda madre, dietro il socket, e serve a distribuire la forte pressione di montaggio su

un'ampia area, impedendo alla PCB di flettersi. È esattamente per questo che il pre-assemblaggio su banchetto è comodo: la scheda è libera, la giri, metti il backplate, poi la rigiri. Sulle piattaforme AMD AM4/AM5, il backplate **è spesso già presente** sulla scheda madre e va **riutilizzato** (a volte va rimosso solo il *retention module*, la cornice di plastica nera attorno al socket). Leggi il manuale del *cooler*, che ti indicherà quale strada seguire.

**Fase 2 — Gli standoff.** Sopra la scheda madre, in corrispondenza dei quattro fori attorno al socket, si avvitano quattro perni filettati che sporgono dal backplate. Vanno stretti **a mano, fino a battuta, senza forzare**. Determinano l'altezza — e quindi la pressione — del dissipatore.

**Fase 3 — La pasta.** Come sopra: una quantità a chicco di pisello al centro dell'IHS pulito. (Se il dissipatore ha già la pasta preapplicata, salta questo passaggio.)

**Fase 4 — Posizionare il dissipatore.** Abbassalo **dritto, senza strisciare**, allineando le staffe sopra gli standoff. Non "atterrarlo" ad angolo.

**Fase 5 — Stringere a croce, in modo incrementale.** Questo è il passaggio tecnico. Le viti (di solito quattro, a volte due lunghe barre) **non vanno strette una alla volta fino in fondo**. Stringi **in diagonale** — 1, 3, 2, 4 — e a **mezzi giri**: due giri sulla prima, due sulla terza (quella opposta), due sulla seconda, due sulla quarta, e ripeti. La ragione è che il dissipatore deve scendere **parallelo** all'IHS: se stringi la vite 1 fino in fondo prima di toccare la 3, inclini la piastra fredda, e la pasta viene schiacciata da un lato e non dall'altro, con conseguente scarso contatto (e, nei casi peggiori, flessione della PCB). Stringi **finché le viti vanno a battuta e iniziano a girare a vuoto** o finché la molla è completamente compressa. La maggior parte dei kit moderni ha **viti prigioniere con molle precaricate**, progettate per rendere *impossibile* stringere troppo: quando la vite non avanza più, hai finito. **Non applicare ulteriore coppia "per sicurezza"**.

**Fase 6 — Collegare la ventola a CPU\_FAN.** Il connettore a 4 pin del dissipatore va nell'header etichettato **CPU\_FAN** (non CPU\_OPT, non SYS\_FAN). Ragione: la scheda madre **monitora quell'header**, e molti BIOS **rifiutano di avviare il sistema** (o mostrano un "CPU Fan Error") se non rilevano un segnale di rotazione lì. Il connettore ha una linguetta di guida su un lato: entra solo in un modo, e se hai un dissipatore con due ventole, il secondo cavo va in **CPU\_OPT**.

### 4.3 CASO B — AIO (raffreddamento a liquido)

Un **AIO** è un circuito chiuso pre-assemblato: un **waterblock** con **pompa** integrata che si monta sulla CPU, due **tubi**, un **radiatore** con le sue ventole. Non si riempie, non si spurgava, non si apre.

L'ordine dei passaggi qui è **diverso**, e sbagliarlo significa lavorare in condizioni impossibili:

**Fase 1 — Montare le staffe del socket sul waterblock**, *prima di tutto*, sul tavolo. Ogni AIO include kit di staffe diverse per AMD e Intel: scegli quelle giuste, e falle scorrere/avvitale sul blocco.

**Fase 2 — Backplate e standoff sulla scheda madre**, come per il raffreddamento ad aria.

**Fase 3 — LA PELLICOLA.** Stop. Guarda la **piastra fredda** dell'AIO, la piastra di rame o nichel sul fondo del waterblock. Nella stragrande maggioranza dei casi, il produttore ha applicato la pasta termica in fabbrica **e l'ha coperta con una pellicola di plastica trasparente o colorata**.

***RIMUOVI LA PELLICOLA.** Questo non è un dettaglio: è l'errore più costoso e più comune di questo capitolo. Una piastra fredda montata con la pellicola significa **zero trasferimento termico**: la CPU raggiunge la sua temperatura di sicurezza (**T-junction max**, tipicamente 95-100 °C) in **pochi secondi** dopo l'accensione, entra in throttling estremo e poi si spegne. Il PC "si spegne da solo dopo dieci secondi" è quasi sempre questo. Non danneggia la CPU (le protezioni funzionano), ma ti costa un pomeriggio.*

Se la piastra fredda è **nuda** (senza pasta pre-applicata), allora applica tu stesso la quantità a forma di pisello sull'IHS della CPU, come per il raffreddamento ad aria.

**Fase 4 — Fissa il waterblock.** Posizionalo dritto e stringi i dadi/viti **a croce e in modo incrementale**, esattamente come per il raffreddamento ad aria, fino a quando non è ben saldo.

**Fase 5 — Il radiatore: NON ORA.** Il radiatore rimane appeso ai suoi tubi, appoggiato sul tavolo. **Dovrebbe essere montato nel case dopo aver installato la scheda madre** (punto 8). Tentare di montare il radiatore e la scheda madre insieme, fuori dal case, significa dover calare un oggetto rigido e pesante vincolato da due tubi corti nel case: è il modo migliore per strappare qualcosa. Nel

frattempo, **appoggia delicatamente il radiatore** e non piegare i tubi ad angoli acuti.

**Fase 6 — Connessioni elettriche.** Un AIO generalmente ha due (o tre) cavi:

- il cavo della **\*\*pompa\*\***, che va in un header dedicato: **\*\*AIO\_PUMP\*\*** se esiste, altrimenti **\*\*CPU\_FAN\*\*** (l'header della pompa fornisce sempre il 100% della tensione, senza una curva di regolazione: è quello che vuoi, una pompa dovrebbe sempre funzionare al massimo o a una velocità fissa);
- il cavo (o i cavi) per le **\*\*ventole del radiatore\*\***, che vanno in **\*\*CPU\_FAN\*\*** e/o **\*\*CPU\_OPT\*\***, o — se il kit ha uno **\*\*splitter\*\*** o un hub — in un singolo header. Se colleghi la pompa a AIO\_PUMP e le ventole a CPU\_FAN, il BIOS è contento e puoi costruire una curva sensata.
- opzionalmente un cavo **\*\*ARGB/USB\*\*** per l'illuminazione e il monitoraggio (attenzione con ARGB: vedi punto 10).

---

## 5. Preparazione del case

Il blocco scheda madre + CPU + RAM + M.2 + dissipatore ad aria è pronto. Prima di calarlo, prepara il nido.

**Fase 1 — Apri tutto.** Rimuovi **entrambi** i pannelli laterali (quello in vetro/metallo e quello posteriore, dietro il *motherboard tray*: è qui che farai passare i cavi) e, se possibile, i pannelli anteriore e superiore, per accedere alle staffe delle ventole. Metti le viti dei pannelli in un contenitore separato.

**Fase 2 — Controlla i distanziali.** Questo passaggio è spesso trascurato ed è potenzialmente **distruittivo**. I **distanziali** del case sono piccoli pilastri esagonali filettati, avvitati nel *motherboard tray*, su cui poggerà la scheda madre. Hanno **due funzioni**: sollevare la scheda di pochi millimetri dal metallo, per evitare che i giunti di saldatura sul retro tocchino il telaio e **vadano in cortocircuito**; e definire i punti di ancoraggio.

I case vengono forniti con distanziali **pre-montati per il formato ATX**. Ma ci sono tre formati (e li elencheremo, perché la scelta è tua):

| Formato | Dimensioni tipiche | Fori di montaggio tipici | Slot PCIe | Slot RAM |
|---------|--------------------|--------------------------|-----------|----------|
| ATX     | 305 × 244 mm       | 9                        | fino a 7  | 4        |

|                         |              |     |          |     |
|-------------------------|--------------|-----|----------|-----|
| <b>Micro-ATX (mATX)</b> | 244 × 244 mm | 6-8 | fino a 4 | 2-4 |
| <b>Mini-ITX</b>         | 170 × 170 mm | 4   | 1        | 2   |

***Il controllo critico:** appoggiare (senza avvitare) la scheda madre nel case e controllare che **sotto ogni foro della scheda ci sia un distanziale, e — cosa più importante — che NON ci sia un distanziale dove la scheda NON ha un foro.** Un distanziale "orfano" che tocca il retro della scheda madre è un **cortocircuito**: il PC non si accenderà al primo avvio, e nel peggiore dei casi la scheda verrà danneggiata. È un errore classico di chi monta una scheda Micro-ATX in un case pensato per ATX. I distanziali in eccesso vanno svitati (a mano o con una chiave a bussola da 5 mm, spesso inclusa).*

Molti case hanno un **distanziale centrale rialzato e non filettato**: serve da appoggio e per il centraggio, non per le viti. Va benissimo che ci sia.

**Passo 3 — Lo I/O shield.** Lo **I/O shield** è la placca metallica rettangolare che copre le porte posteriori della scheda madre. Nelle schede madri odierne di fascia media e alta è **integrato** (già montato sulla scheda, spesso con una copertura in plastica sopra i VRM): in quel caso non dovete fare nulla e potete saltare questo passo. Se la vostra scheda ha uno I/O shield **separato** — una placca metallica nella scatola — va installato **ora**, perché dopo non potrete più farlo.

Si installa **dall'interno del case verso l'esterno**: lo si appoggia nell'apertura rettangolare posteriore, si controlla l'**orientamento** (le etichette delle porte devono essere leggibili dall'esterno, e la forma deve corrispondere alle porte della vostra scheda: guardate la scheda madre mentre lo fate) e si preme sui **quattro angoli** finché non scatta in posizione con un rumore metallico. È necessaria una notevole **forza**, e la lamiera ha bordi taglienti: fate attenzione alle dita. Uno I/O shield installato al contrario è uno dei ricordi più amari del PC building, perché ci si accorge solo dopo che la scheda madre è già avvitata. Una piccola avvertenza: alcuni I/O shield hanno delle **linguette metalliche elastiche** che sporgono verso l'interno. Devono premere **sopra** le porte (fanno da messa a terra), non **dentro** di esse: quando calate la scheda madre, controllate che nessuna linguetta sia entrata in una presa USB o Ethernet.

**Passo 4 — Pre-instradare i cavi frontali.** I cavi del pannello frontale (interruttore di accensione, USB, audio) e i cavi delle ventole del case preinstallate

sono **già lì**, penzolanti. Prima di installare la scheda madre, instradateli attraverso i **gommini più vicini** alla loro destinazione, in modo che siano già posizionati correttamente. Farlo dopo significa dover infilare la mano tra la scheda madre e lo chassis.

---

## 6. Installazione dell'alimentatore (PSU)

L'**alimentatore** (PSU - Power Supply Unit) si trova quasi sempre nella **parte inferiore** nei case moderni, in un vano separato (shroud), e questa è una buona cosa: aspira aria fresca dal basso e la espelle direttamente all'esterno, senza riscaldare il resto del sistema.

### 6.1 Orientamento della ventola: la domanda che tutti sbagliano

La ventola dell'alimentatore può essere rivolta **verso il basso** o **verso l'alto** (**all'interno del case**). La regola è semplice ma va compresa:

- Se il case ha **\*\*piedini alti e una griglia filtrata sotto l'alimentatore\*\*** (praticamente tutti i case moderni), la ventola dovrebbe essere rivolta **\*\*verso il basso\*\***. L'alimentatore aspira **\*\*aria fresca dall'esterno\*\***, la usa per raffreddarsi ed espelle l'aria calda dal retro. Questo è un circuito completamente indipendente dal flusso d'aria del case: eccellente.
- Se il case poggia direttamente sul pavimento senza flusso d'aria, o il fondo è **\*\*chiuso\*\*** (vecchi case, case desktop con l'alimentatore in alto), allora la ventola dovrebbe essere rivolta **\*\*verso l'interno\*\***: aspirerà aria calda dal case. Questo è subottimale, ma è meglio che non ricevere aria affatto. Una ventola rivolta verso un fondo chiuso **\*\*soffocherà\*\*** l'alimentatore, e un alimentatore surriscaldato invecchierà rapidamente o attiverà la protezione termica.

Se lo posizioni su un tappeto, i piedini non sono sufficienti: metti una tavola sotto il case.

### 6.2 La Procedura

**Passo 1 — Collega i cavi modulari PRIMA di inserire l'alimentatore.** Se il tuo PSU è **modulare** (cavi staccabili) o **semi-modulare** (24-pin e EPS fissi, il resto staccabile), questo è il momento di attaccare i cavi al **lato dell'alimentatore**, mentre lo tieni in mano e le porte sono accessibili. Una volta avvitato al fondo del case, dietro la copertura, quelle porte diventano scomode. Di quali cavi hai bisogno? Fai un inventario: **1× ATX 24-pin** (sempre), **1 o 2× EPS 8-pin** (per la CPU;

controlla quanti ne richiede la tua scheda madre), cavi **PCIe** per la GPU (quanti 8-pin? o un 12V-2×6?), 1× **SATA power** se hai SSD o hard disk da 2.5", e qualsiasi cavo per ventole/hub.

***AVVISO CRITICO, e questo non è un'esagerazione: i cavi modulari NON sono intercambiabili tra alimentatori diversi, anche dello stesso produttore. Il connettore lato PSU può essere fisicamente identico ma avere una piedinatura completamente diversa. Usare un cavo di un PSU su un altro è uno dei pochissimi modi per distruggere istantaneamente tutti i componenti collegati, inviando 12V a una linea che si aspetta 3.3V o mettendo la massa dove dovrebbe esserci tensione. Usa solo i cavi forniti nella scatola con quell'alimentatore. Se li hai persi, possono essere acquistati dal produttore, per quello specifico modello.***

**Passo 2 — Inserisci il PSU** nel suo alloggiamento (a volte dal retro, a volte dall'interno; alcuni case hanno una staffa rimovibile che si avvita prima al PSU e poi al case).

**Passo 3 — Avvita** le quattro viti sul retro del case. Queste sono viti a passo grosso (UNC 6-32): non forzarle.

**Passo 4 — Fai passare i cavi** dietro il vassoio della scheda madre, verso le loro destinazioni. Non collegarli ancora: la scheda madre va inserita per prima.

---

## 7. Installazione della Scheda Madre nel Case

**Passo 1 — Abbassa la scheda.** Tienila per i bordi (o per il dissipatore della CPU, se è un dissipatore ad aria, che ora è attaccato) e abbassala nel case con un movimento leggermente **obliquo**: prima le porte posteriori verso lo scudo I/O, poi la scheda piatta.

**Passo 2 — Allinea con lo scudo I/O.** La scheda dovrebbe essere **spinta verso il retro del case** finché le porte non sporgono attraverso i fori dello scudo I/O. Questo è il momento di controllare che nessuna linguetta metallica sia finita all'interno di una porta. Quando la scheda è in posizione, i **fori per i suoi punti di montaggio si allineano perfettamente con i distanziali**: se un foro è disallineato di due millimetri, non forzarlo — la scheda non è spinta abbastanza indietro, o un distanziale è nel posto sbagliato.

**Fase 3 — Avvitare.** Posiziona **la prima vite in un angolo, senza serrarla**, solo per tenere la posizione. Poi le altre. Poi torna indietro e stringile tutte, **lavorando a croce** (mai in cerchio) per evitare di mettere in tensione il PCB.

**Quanta forza?** Poca. La vite deve **appena fare contatto**: appena senti metallo toccare metallo, **fermati**. Stringere una vite della scheda madre "con forza" significa deformare il PCB attorno al foro e, a lungo andare, crepare le tracce di rame. Una scheda madre avvitata correttamente **non flette** se ci premi un dito sopra, ma le viti non sono strette come i dadi delle ruote di un'auto.

**Controllo:** conta le viti. Devono essere tante quanti sono i distanziali. Un distanziale senza vite è un punto di supporto non assicurato, e quando premerai la RAM o la GPU, la scheda fletterà in quel punto.

---

## 8. Installazione del radiatore AIO (se presente)

Ora che la scheda madre è dentro, il radiatore trova la sua casa.

### 8.1 Dove metterlo, e la regola dell'aria nella pompa

Le due posizioni sensate in un case ATX standard sono:

**Top exhaust (in alto, che espelle aria) — la scelta consigliata.** Il radiatore si trova sul tetto del case e spinge l'aria calda verso l'alto/fuori. Vantaggi: non riscalda il resto del sistema; la GPU riceve aria fresca dal davanti; l'aria calda va dove la fisica vuole già mandarla. Svantaggio: il liquido nel radiatore riceve aria già leggermente riscaldata dai componenti, quindi le temperature della CPU sono di qualche grado più alte rispetto alla configurazione front intake.

**Front intake (davanti, che immette aria) — massime prestazioni per la CPU.** Il radiatore si trova davanti e aspira aria fresca dall'esterno. La CPU ottiene le migliori temperature possibili, ma **tutta l'aria che entra nel case è stata preriscaldata dal radiatore**, e la GPU, i VRM (Voltage Regulator Module, gli stadi di alimentazione della CPU) e gli SSD ne pagano il prezzo.

C'è però un vincolo che **scavalca tutto**, ed è idraulico. La **pompa** dell'AIO deve essere **nel punto più basso del circuito**, o almeno **mai nel punto più alto**. Il motivo: in ogni AIO, col tempo, si accumula una piccola quantità d'aria (permeazione attraverso i tubi, aria residua di fabbrica). Quell'aria **galleggia** e va nel punto più alto del circuito. Se il punto più alto è il **radiatore**, l'aria si raccoglie lì e non fa danni. Se il punto più alto è la **pompa**, l'aria entra nella girante, la



pompa gira "a secco" — e inizia a fare un rumore inconfondibile, un gorgoglio/ronzio ciclico — e **perde efficienza, fino a grippare**.

***Regola pratica: i tubi del radiatore devono uscire dal LATO INFERIORE del radiatore (o almeno il waterblock deve essere sotto il livello della parte superiore del radiatore). In una configurazione top, monta il radiatore con i tubi verso il retro/basso. In una configurazione frontale, monta il radiatore in alto, con i tubi in basso, mai con i tubi in alto sopra la pompa.***

Una posizione da **evitare**: il radiatore montato **in alto con i tubi che puntano verso l'alto** e la pompa più in alto del radiatore stesso — una situazione tipica in alcuni case molto compatti. E il montaggio **posteriore** (120 mm sul retro) è adatto solo per AIO piccoli.

## 8.2 La procedura

**Fase 1 — Montare le ventole sul radiatore**, decidendo la direzione del flusso d'aria (le ventole hanno delle frecce stampate sull'alloggiamento: una indica la direzione dell'aria, l'altra la rotazione). In configurazione top exhaust, le ventole spingono l'aria **attraverso il radiatore verso l'esterno**; possono essere sotto (per spingere) o sopra (per tirare) — sotto è più comune per motivi di spazio.

**Fase 2 — Avvitare l'assemblaggio radiatore+ventole al case**. Le viti che attraversano il radiatore sono **lunghe e pericolose**: se sono troppo lunghe, la punta **perforerà le alette e il canale del liquido**, e l'AIO è morto. Usare **solo le viti fornite nel kit**, e distinguere tra quelle "corte" (radiatore avvitato direttamente al case) e quelle "lunghe" (radiatore + ventole insieme). In caso di dubbio, avvitare **a mano, contando i giri**, e fermarsi non appena incontrano resistenza.

**Fase 3 — Collegare le ventole** (a CPU\_FAN/CPU\_OPT o all'hub del kit) e assicurarsi che i tubi non premano contro la RAM o il dissipatore VRM.

---

## 9. Installazione della GPU

### 9.1 Quale slot, e perché non è banale

La scheda madre ha uno, due, a volte tre slot **PCIe x16** — fisicamente identici, lunghi. Sembrano intercambiabili. **Non lo sono**.

La GPU va nel **primo slot PCIe x16, quello più vicino alla CPU**. Ed ecco perché, che è la spiegazione che manca in nove guide su dieci.

Il bus **PCIe** opera su **lane**: ogni lane è una coppia differenziale punto-punto. Una CPU consumer moderna espone un numero **fisso e limitato** di lane PCIe — tipicamente **20-28** utilizzabili — di cui **16 sono riservate per la connessione grafica** e 4 (o 8) per l'SSD NVMe primario. Il resto della connettività (porte USB, SATA, rete, slot di espansione secondari) è gestito dal **chipset**, che si collega alla CPU tramite un unico link condiviso.

Questo significa che, su una scheda madre consumer:

- il **\*\*primo slot x16\*\*** è **\*\*elettricamente x16\*\*** ed è cablato **\*\*direttamente alla CPU\*\***;
- gli slot x16 successivi sono **\*\*fisicamente x16\*\*** (la lunghezza è la stessa), ma elettricamente sono **\*\*x4\*\*** o **\*\*x1\*\***, e spesso passano attraverso il **\*\*chipset\*\***.

Mettere una GPU moderna in uno slot x4 dal chipset significa **strangolarla**: la banda passante è drasticamente ridotta e la latenza aumenta, con perdite di prestazioni che possono raggiungere percentuali a doppia cifra nei giochi (e molto di più nei carichi di calcolo che trasferiscono continuamente dati tra RAM e VRAM). Questo non è un dettaglio per puristi: è il tipo di errore che ti fa comprare una GPU da 800 euro e ottenere le prestazioni di una da 500 euro.

Il manuale della scheda madre lo dichiara sempre, con annotazioni come **"PCIEX16\_1: x16 mode (CPU)"** e **"PCIEX16\_2: x4 mode (Chipset)"**. Leggetelo.

**Eccezioni**, che esistono e sono legittime:

- **\*\*Spazio per radiatore AIO o dissipatore.\*\*** Su alcuni case compatti, il primo slot è troppo vicino a qualcosa. In tal caso, uno slot x8 dalla CPU (se disponibile, su schede che supportano lo splitting x8/x8) è meglio di una GPU che non entra.
- Schede **\*\*Workstation/HEDT\*\*** (\*High-End Desktop\*, es. Threadripper): qui le lane della CPU sono 48, 64 o più, e tutti gli slot sono x16 elettrici. La regola non si applica.
- **\*\*Flusso d'aria.\*\*** Alcuni preferiscono il secondo slot per dare a una GPU spesso un po' di respiro. È un compromesso: qualche grado in meno, banda passante dimezzata. Quasi mai ne vale la pena.

## 9.2 La procedura

**Fase 1 — Rimuovere le staffe posteriori.** Contate quanti **slot di espansione** occupa la vostra GPU (le GPU moderne sono spesso 2, 2.5 o 3 slot) e rimuovete le corrispondenti **staffe metalliche** dal retro del case, svitandole (**non piegatele fino a romperle**: nei case economici sono a strappo, e una volta rotte non tornano più). Rimuovete quelle **corrette**: se la GPU va nel primo slot x16 e occupa 3 slot, dovrete rimuovere la staffa corrispondente e le due sottostanti.

**Fase 2 — Aprire la clip dello slot.** Alla fine dello slot PCIe, verso l'interno della scheda madre, c'è una **clip di ritenzione** in plastica. Deve essere abbassata/spostata di lato **prima** di inserire la GPU. Questo è un dettaglio che spesso viene trascurato, e forzare la GPU con la clip chiusa può rompere lo slot.

**Fase 3 — Inserire.** Allineate il **connettore dorato** della GPU con lo slot (la tacca sul connettore, come sempre, assicura l'orientamento corretto) e la **staffa** con i fori sul retro del case. Premete **dritti verso il basso, con forza uniforme su entrambe le estremità** della scheda (una sopra il connettore, una sull'estremità libera). La GPU scivola dentro e la clip **scatta in posizione con un CLICK**. Verifica: guardate il connettore di lato — i contatti dorati devono essere **completamente nascosti** nello slot, e la scheda deve essere **parallela** alla scheda madre.

**Fase 4 — Avvitare la staffa** al case (una o due viti). Non stringere eccessivamente.

## 9.3 Alimentazione GPU: il paragrafo che può salvare la vostra casa

Le GPU consumano più di quanto lo slot PCIe possa fornire (lo slot fornisce un massimo di 75 W), quindi prelevano energia direttamente dall'alimentatore. Esistono due famiglie di connettori.

**Famiglia classica: PCIe 6+2 pin (comunemente "8-pin").** Ogni connettore a 8 pin è certificato per **150 W**; quello a 6 pin per 75 W. Una GPU può averne uno, due o tre.

***La regola del daisy-chain.** Molti alimentatori forniscono cavi PCIe con **due connettori sullo stesso cavo** (uno all'estremità e uno "a metà cavo", chiamato piggyback o daisy-chain). Questi sono comodi ma **condividono gli stessi conduttori**. Su una GPU di fascia bassa (un solo ingresso di alimentazione, o due ingressi ma consumo energetico modesto), questo va perfettamente bene. Su una GPU potente — tipicamente **250 W e oltre**, o ogni*

*volta che la GPU richiede **due o più connettori** — **utilizzate cavi separati, uno per ogni ingresso della GPU, partendo da diverse uscite dell'alimentatore**. Un singolo cavo che trasporta 300 W su conduttori progettati per 150 W si surriscaldereà, si degraderà e, in casi documentati, **si scioglierà**.*

**Nuova famiglia: 12V-2×6 (evoluzione del 12VHPWR).** Questo è il connettore ad alta densità introdotto con lo standard **PCIe 5.0 / ATX 3.0**: dodici pin di alimentazione (sei per 12V, sei per la massa) più quattro pin di segnale (sideband), in grado di trasportare fino a **600 W** da un singolo cavo. Il "2×6" è la revisione che ha accorciato i pin di segnale rispetto all'originale 12VHPWR: se il connettore non è completamente inserito, i pin più corti perdono prima il contatto di rilevamento, quindi l'alimentatore interrompe l'erogazione a 0 W invece di consentire comunque fino a 150 W attraverso una connessione allentata — una correzione di sicurezza/rilevamento, non una barriera meccanica all'inserimento parziale.

***AVVISO DI SICUREZZA, il più grave di questo libro: il connettore 12V-2×6 va inserito FINO IN FONDO, finché non scatta la clip, e va verificato visivamente.***

*La ragione è fisica e inesorabile. Un connettore inserito **parzialmente** (anche di un solo millimetro) o **piegato con un angolo troppo acuto** subito dopo l'uscita ha una **resistenza di contatto elevata** su alcuni pin. La potenza dissipata in un contatto è  $P = R \times I^2$ : con correnti nell'ordine di 40-50 ampere, anche pochi milliohm di resistenza in eccesso producono decine di watt concentrati su un piccolo pezzo di plastica e ottone. Il risultato documentato, con abbondanti foto online, è la **fusione del connettore** — lato GPU, lato PSU, o entrambi — danneggiando la scheda video.*

***Le regole:*** (1) inserire **fino allo scatto**, verificando che l'**area dorata** dei terminali **non sia più visibile**; (2) **non piegare il cavo entro almeno 35 mm** dal connettore (è la distanza minima specificata dallo standard) — se il pannello laterale del case preme sul cavo forzando una piega acuta immediata, avete un problema di design e serve un cavo angolato o un adattatore a 90° certificato; (3) usare il **cavo nativo dell'alimentatore** se è ATX 3.x, o l'adattatore fornito con la GPU, mai adattatori generici di dubbia

provenienza; (4) **ricontrollare** il connettore dopo aver chiuso il case e dopo ogni spostamento del PC.

**Ultimo passo — Il supporto anti-sag.** Le GPU moderne possono pesare **fino a 2 chilogrammi** e sono sostenute da due punti: lo slot PCIe e la staffa. La conseguenza è il **sag**: la scheda si inclina verso il basso, flettendo permanentemente lo slot e il PCB della GPU. Se guardate la GPU montata **di lato** e vedete che l'estremità libera scende visibilmente rispetto allo slot, aggiungete un **supporto** (un piedistallo regolabile che si appoggia sul fondo del case, o una staffa retrattile: molte GPU e case ne includono uno). Non è solo estetica: una GPU pesante lasciata in flessione per due anni può sviluppare micro-fratture nelle saldature.

---

## 10. Cablaggio completo, uno per uno

Siamo alla parte che spaventa la gente perché "ci sono cinquanta cavi". In realtà, i tipi sono nove, e ognuno ha un solo posto dove andare. Procediamo in ordine, dall'alto verso il basso.

### 10.1 ATX 24-pin (alimentazione scheda madre)

Il connettore più grande, da **24 pin** (spesso in due pezzi separabili, 20+4). Va nell'unico posto dove può andare: il connettore lungo sul **bordo destro** della scheda madre. È polarizzato (i pin hanno forme diverse) e ha una **clip laterale** che deve **scattare in posizione**. **Forza**: considerevole. Il 24-pin richiede una spinta decisa, e i principianti spesso lo lasciano a metà. Spingete finché la clip non scatta in posizione. Verifica: provate a tirarlo; non deve uscire.

### 10.2 EPS 8-pin (alimentazione CPU) — il cavo più confuso di tutti

L'**EPS** è un connettore da **8 pin** che alimenta i VRM della CPU, e si trova in **alto a sinistra sulla scheda madre**, vicino al socket, spesso etichettato **CPU\_PWR1**, **ATX\_12V**, o **EPS12V**.

***Il rischio: EPS 8-pin e PCIe 8-pin sembrano identici.** Hanno lo stesso numero di pin, la stessa forma generale, lo stesso colore (nero). Ma la **piedinatura è diversa** (le posizioni 12 V e terra non corrispondono) e **la forma dei singoli pin è diversa**: alcuni sono quadrati, altri smussati, proprio per prevenire errori. **Non forzare mai un connettore a 8 pin.** Se non scorre agevolmente, hai il cavo sbagliato. Un PCIe forzato in un socket EPS può **distruggere la scheda madre**.*

***Come distinguerli sempre:*** I cavi dell'alimentatore sono **etichettati** — cerca **"CPU"** o **"EPS"** sul connettore stesso, rispetto a **"PCIe"** o **"VGA"**. Se le etichette mancano, guarda la separazione: PCIe è **6+2** (si divide in un blocco da 6 e uno da 2); EPS è **4+4** (si divide a metà). Questo è il metodo infallibile.

Le schede madri di fascia alta hanno **due** connettori EPS (8+8, o 8+4). Con le CPU consumer, **solo uno è quasi sempre sufficiente** per il normale funzionamento; il secondo è per overclock estremo e correnti molto elevate. Se ne hai due e l'alimentatore ha i cavi, collegali entrambi: non fa male.

**Avvertenza sull'accessibilità:** L'EPS si trova nell'angolo più scomodo del case, spesso già coperto dal dissipatore. **Collegalo prima** di montare il radiatore superiore, o anche prima di installare la scheda madre se il case è angusto.

### 10.3 PCIe / 12V-2×6 (alimentazione GPU)

Già trattato nella sezione 9.3. Riassumo la regola: **niente daisy-chain su GPU potenti; 12V-2×6 fino in fondo, senza curve strette entro 35 mm.**

### 10.4 Alimentazione SATA e dati SATA

Se hai un SSD da 2.5" o un disco rigido meccanico, hai bisogno di **due** cavi: uno **SATA power** (connettore piatto a L, largo, proveniente dall'alimentatore, con più spine sullo stesso cavo — qui il daisy-chaining va benissimo, il consumo energetico è minimo) e uno **SATA data** (piccolo, a forma di L, che va dall'unità a una porta **SATA** sulla scheda madre). Entrambi hanno una clip. Il cavo dati SATA è spesso incluso con la scheda madre. Se hai solo unità M.2, **non hai bisogno di nulla di tutto questo.**

### 10.5 Pannello frontale (F\_PANEL) — il puzzle dei pin

Questo è il set più odiato: **quattro o cinque cavi sottili, con connettori a due pin**, provenienti dalla parte anteriore del case, che vanno in un blocco di **9-10 pin** sul bordo **in basso a destra** della scheda madre, etichettato **F\_PANEL**, **PANEL1**, **JFP1**, o simili.

I cavi sono:

| Cavo                       | Funzione                                                 | Polarità                                |
|----------------------------|----------------------------------------------------------|-----------------------------------------|
| <b>POWER SW</b> (o PWR_SW) | Il pulsante di accensione: chiude un contatto momentaneo | <b>Indifferente</b> (è un interruttore) |

|                                                |                                        |                                                               |
|------------------------------------------------|----------------------------------------|---------------------------------------------------------------|
| <b>RESET SW</b>                                | Il pulsante di reset                   | <b>Indifferente</b>                                           |
| <b>POWER LED</b> (a volte in due pezzi, + e –) | Il LED di accensione                   | <b>Importa:</b> il polo positivo (filo colorato) va sul pin + |
| <b>HDD LED</b> (o H.D.D. LED)                  | Il LED di attività del disco           | <b>Importa</b>                                                |
| <b>SPEAKER</b> (se presente)                   | Il buzzer che emette i bip diagnostici | Indifferente in pratica                                       |

**Il punto chiave: non esiste uno standard universale per l'ordine dei pin.** Ogni produttore di schede madri utilizza un layout leggermente diverso. **L'unica fonte di verità è il diagramma nel manuale della scheda madre**, che mostra il blocco pin per pin. Aprilo, tienilo aperto e collegali uno per uno con l'aiuto di una torcia. Questa è l'unica parte dell'assemblaggio in cui non puoi affidarti all'intuizione.

Buone notizie: **fare un errore qui non romperà nulla**. Se inverti un LED, quel LED non si accenderà (e devi solo capovolgere il connettore). Se scambi alimentazione e reset, il pulsante di accensione eseguirà un reset. Nessun danno permanente. Alcune schede madri (specialmente ASUS) includono un adattatore **Q-Connector**: un blocco dove inserire comodamente i cavi **all'esterno** del case, e poi il tutto si collega alla scheda. Se c'è, usalo.

**Se il tuo case ha un pulsante di accensione ma non riesci a capire quale sia POWER SW:** ricorda che, per accendere un PC, basta **cortocircuitare i due pin POWER SW per un istante** con la punta di un cacciavite. Questo è esattamente ciò che fa il pulsante. Utile per test POST al banco.

## 10.6 Connettori dati del pannello frontale

**Connettore USB 3.0 / USB 3.2 Gen 1:** un connettore **blu, largo, a 19/20 pin**, con una tacca di guida. Si inserisce nell'apposito connettore sulla scheda madre.

**Attenzione:** è rigido e i pin sono sottili; si inserisce solo in un modo ma deve essere inserito dritto. Questo è il connettore che più spesso viene **danneggiato piegando i pin**, perché si trova sul bordo della scheda e in una posizione scomoda. Prenditi il tuo tempo.

**Connettore USB-C (USB 3.2 Gen 2 / Gen 2×2):** un piccolo connettore rettangolare, tipo "E-key", spesso etichettato **USB 20G** o **USB-C**. Si inserisce facilmente in un solo modo. Se la tua scheda madre **non ha** questo connettore, la porta USB-C frontale

del case **non funzionerà**: questa è una verifica di compatibilità da effettuare in fase di acquisto.

**Connettore USB 2.0**: 9 pin (uno mancante funge da chiave). Utilizzato per il cavo di controllo di molti AIO, per gli hub RGB, per alcuni lettori di schede.

**HD Audio (o AAFP / F\_AUDIO)**: un connettore a 9 pin, molto simile a USB 2.0 (**ma NON la stessa cosa**: guarda l'etichetta, "HD AUDIO"). Si inserisce nel connettore audio, che si trova quasi sempre nell'**angolo in basso a sinistra** della scheda madre, il più lontano possibile dai circuiti digitali (per ridurre le interferenze). Questo è il cavo per i jack frontali di cuffie/microfono.

### 10.7 Ventole: PWM vs DC

Ogni ventola ha un connettore a **3 o 4 pin**, con una linguetta di guida che ne assicura l'orientamento, e si collega a uno dei connettori **SYS\_FAN / CHA\_FAN** sulla scheda madre.

La differenza tra 3 e 4 pin è concettualmente importante:

|                                 | <b>3 pin (DC)</b>                                                                                                                 | <b>4 pin (PWM)</b>                                                                    |
|---------------------------------|-----------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|
| Pin                             | GND, 12V, Sense (tachimetro)                                                                                                      | GND, 12V, Sense, <b>PWM</b>                                                           |
| Come viene regolata la velocità | Variando la <b>tensione</b> (da 12V in giù)                                                                                       | Mantenendo 12V fisso e inviando un <b>segnale di controllo</b> a duty cycle variabile |
| Regolazione a bassa velocità    | Imprecisa; al di sotto di una certa tensione, la ventola <b>si ferma e non riparte</b>                                            | Precisa e stabile anche a bassi RPM                                                   |
| Compatibilità                   | Una ventola a 3 pin <b>funziona</b> su un connettore a 4 pin, ma solo se il connettore è impostato in <b>modalità DC</b> nel BIOS | Una ventola a 4 pin su un connettore a 3 pin <b>girerà sempre al 100%</b>             |

**Conseguenza pratica**: se hai ventole a 3 pin che girano sempre a piena velocità e fanno rumore, vai nel BIOS, trova la sezione delle ventole (Q-Fan, Smart Fan, Fan Control) e imposta quel connettore su **DC** invece di **PWM/Auto**. Questa è la soluzione a un problema che frustra molte persone.



Se hai più ventole rispetto alle intestazioni disponibili, usa uno **splitter** (un cavo che si sdoppia; il segnale tachimetrico proviene da una sola ventola) o un **hub PWM** alimentato direttamente dall'alimentatore con un connettore di alimentazione SATA (obbligatorio se colleghi più di 3-4 ventole: un'intestazione della scheda madre tipicamente fornisce **1 A / 12 W**, e superare questo limite può bruciare il circuito di controllo).

### 10.8 ARGB e RGB: il paragrafo salva-hardware

È qui che le cose si distruggono davvero, e la causa è che i due connettori sembrano simili.

|                      | RGB 12 V (4 pin)                               | ARGB 5 V (3 pin)                                                       |
|----------------------|------------------------------------------------|------------------------------------------------------------------------|
| Voltaggio            | <b>12 volt</b>                                 | <b>5 volt</b>                                                          |
| Pin                  | 4 (12V, G, R, B)                               | 3 (5V, Data, <b>vuoto</b> , GND)<br>— ha uno spazio vuoto!             |
| Cosa può fare        | L'intera striscia cambia colore <b>insieme</b> | Ogni LED è <b>indirizzabile individualmente</b> (effetti "arcobaleno") |
| Etichetta sulla mobo | RGB_HEADER, JRGB, 12V<br>G R B                 | ARGB_HEADER,<br>JRAINBOW,<br>ADD_HEADER, 5V D G                        |

**NON COLLEGARE MAI un dispositivo ARGB da 5V a un'intestazione RGB da 12V.** I connettori sono **fisicamente simili**, e su alcune intestazioni (che hanno 4 pin), è **possibile inserire accidentalmente** un connettore a 3 pin. Il risultato è che il dispositivo riceve **più del doppio della tensione per cui è progettato**: la striscia LED o la ventola **si brucia istantaneamente**, e con una certa probabilità, si porta dietro il **controller LED della scheda madre**, che non è riparabile.

**Come proteggersi:** l'intestazione ARGB a 3 pin ha una caratteristica inconfondibile: ci sono **4 posizioni ma un pin è MANCANTE** (c'è un buco). Il connettore ARGB ha un corrispondente foro cieco. Conta i pin, **leggi la serigrafia sulla scheda** (dice sempre "12V" o "5V" accanto all'intestazione), e in caso di dubbio, **non collegare nulla e consulta la pagina del manuale**. Questo è un caso in cui trenta secondi di lettura valgono cento euro di componenti.

## 10.9 Gestione dei cavi

Non è (solo) estetica. Un fascio di cavi che attraversa il case davanti al dissipatore o alla GPU **ostruisce il flusso d'aria**, aumenta le temperature e rende impossibile qualsiasi futura manutenzione.

Ci sono tre principi: 1. **Tutto ciò che può andare dietro il vassoio della scheda madre, va dietro.** I case moderni hanno un vano posteriore dedicato e passacavi in gomma in punti strategici. Il cavo esce dal passacavo più vicino alla sua destinazione, percorre pochi centimetri a vista e si collega. 2. **Raggruppa e fissa con fascette**, senza stringerle così tanto da schiacciare i cavi. Fissali ai punti di ancoraggio del case (occhielli, fessure). 3. **Non ostruire l'aspirazione delle ventole o lo scarico del dissipatore.** Nessun cavo dovrebbe passare *davanti* alla ventola anteriore o sopra il dissipatore della CPU.

Se il pannello posteriore non si chiude, hai troppa roba dietro: ridistribuisce, non forzare.

---

## 11. Primo Avvio

### 11.1 Lista di controllo pre-accensione

Prima di premere il pulsante, fermati. Cinque minuti qui valgono un'ora dopo. Rivedi ogni punto:

1. **La leva del socket della CPU è chiusa e bloccata?** 2. **Il dissipatore è fissato saldamente?** Prova a muoverlo: non dovrebbe ruotare o oscillare. (E: **hai rimosso la pellicola dalla piastra fredda?**) 3. **La ventola/pompa del dissipatore è collegata a CPU\_FAN / AIO\_PUMP?** 4. **La RAM è negli slot corretti (A2/B2) e TUTTI i fermi sono chiusi?** 5. **La GPU è nel primo slot x16, il fermo è scattato, la staffa è avvitata?** 6. **Tutti i cavi di alimentazione sono collegati?** 24-pin, EPS 8-pin (**non dimenticarlo: è di gran lunga l'errore più comune**), PCIe/12V-2×6 per la GPU, alimentazione SATA. 7. **Il 12V-2×6 è inserito FINO IN FONDO?** Guardalo. 8. **Non ci sono viti, fascette o attrezzi all'interno del case?** Capovolgi il case e scuotilo delicatamente: se senti rumori, cercali. 9. **Nessun distanziatore orfano sotto la scheda madre?** 10. **L'interruttore sul retro dell'alimentatore è impostato su "O"?** Tienilo spento finché non hai collegato il cavo di alimentazione.

## 11.2 Collegamento del Monitor: Alla GPU, Non alla Scheda Madre

Sembra ovvio e **una persona su tre** commette questo errore.

Se hai una **GPU dedicata**, il cavo del monitor (DisplayPort o HDMI) va nelle **porte della GPU**, che sono quelle **orizzontali, in basso, sulla staffa della scheda video**. Le porte video **sulla scheda madre** (verticali, in alto, nel cluster I/O posteriore) appartengono alla **iGPU** della CPU e, per impostazione predefinita, **sono disabilitate quando è presente una GPU dedicata**.

Sintomo dell'errore: il PC si accende, le ventole girano, i LED si illuminano, ma **il monitor dice "Nessun Segnale"**. Panico ingiustificato. Sposta il cavo.

(Corollario: se la tua CPU **non ha** grafica integrata — molti modelli AMD serie X e alcuni modelli Intel "F" — le porte video della scheda madre non funzionano mai, e una GPU dedicata è **assolutamente necessaria**.)

## 11.3 Il POST e Come Leggere le Diagnostiche

Accendilo: interruttore dell'alimentatore su "I", poi il pulsante di accensione del case.

Il **POST** (*Power-On Self-Test*) è la sequenza di autodiagnostica che il firmware esegue prima di cedere il controllo al sistema operativo. Inizializza, in ordine: **CPU → memoria → dispositivi PCIe/grafici → dispositivi di avvio**. Se qualcosa fallisce, il POST **si ferma lì**, e ti dice dove.

Come te lo dice dipende dalla scheda madre:

**LED di diagnostica (EZ Debug LED / Q-LED)**. Quattro LED sul bordo della scheda madre, etichettati **CPU, DRAM, VGA, BOOT**. Durante il POST, si illuminano in sequenza e si spengono man mano che ogni fase viene superata. **Il LED che rimane acceso indica la fase in cui il sistema si è bloccato**:

| LED acceso fisso | Significato                   | Cosa controllare, in ordine                                                                                                 |
|------------------|-------------------------------|-----------------------------------------------------------------------------------------------------------------------------|
| <b>CPU</b>       | CPU non è stata inizializzata | <b>EPS 8-pin collegato?</b><br>Poi: CPU correttamente inserita? BIOS aggiornato (CPU troppo nuova)? Pin del socket intatti? |
| <b>DRAM</b>      | La memoria non risponde       | RAM inserita fino al doppio click? Slot corretti (A2/B2)? Prova                                                             |

|             |                                             |                                                                                                                                                   |
|-------------|---------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------|
|             |                                             | <b>un solo modulo</b> , in A2.<br>Cancella CMOS.                                                                                                  |
| <b>VGA</b>  | Grafica non rilevata                        | GPU inserita fino al click? <b>Cavi PCIe collegati alla GPU?</b><br>Prova l'altro slot.                                                           |
| <b>BOOT</b> | Tutto OK, ma nessun disco avviabile trovato | <b>Normale</b> se non hai ancora installato il sistema operativo!<br>Altrimenti: SSD rilevato nel BIOS? Chiavetta USB di installazione collegata? |

Una nota di realismo che evita molti attacchi di panico: alla **prima accensione** con RAM DDR5, il sistema può impiegare **da 30 secondi a diversi minuti** per fare il POST, con il LED DRAM acceso e schermo nero, e magari uno o due riavvii automatici. Questo è il **memory training**: il controller sta calibrando decine di parametri elettrici per ogni modulo, e ne memorizza il risultato. **Questo è normale, e succede solo la prima volta (e dopo ogni cambio RAM o clear CMOS)**. Non spegnete tutto dopo venti secondi: **aspettate almeno cinque minuti** prima di dichiarare il fallimento.

**Display Q-Code / POST code.** Le schede madri di fascia alta hanno un piccolo display **esadecimale a due cifre** che mostra il codice della fase corrente. Il codice su cui **si blocca** identifica il problema con precisione chirurgica; la tabella completa è **nell'appendice del manuale**. Alcuni codici ricorrenti (variano tra produttori — consultare sempre il proprio manuale): i codici della serie **0d/19/53/55** indicano tipicamente problemi di memoria; **d6/d7** indicano assenza di dispositivo grafico; **A0/A2/AA** indicano che il POST è riuscito e il sistema sta procedendo al boot. Se il display mostra un **00** o **FF** fisso, in genere la CPU non sta eseguendo nulla: sospettare alimentazione CPU o CPU non riconosciuta.

**Beep code (buzzer).** Se avete collegato l'**altoparlantino**, un **singolo beep breve** significa "POST superato, tutto bene". Sequenze lunghe/ripetute indicano errori (tipicamente: beep ripetuti = RAM; un lungo e due brevi = grafica). Vale la pena collegarlo: non costa nulla e dà informazioni.

#### 11.4 Se non si avvia: la procedura sistematica

La regola d'oro della diagnostica: **cambiare una variabile alla volta, e iniziare dalla più semplice**. La tentazione di smontare tutto e rimontare a caso è forte e porta solo a confusione.

**Livello 0 — Le assurdità (davvero, controllatele).** L'interruttore dell'alimentatore è su ON? Il cavo è attaccato alla presa? La presa funziona? Il connettore del pulsante di accensione (POWER SW) è sui pin corretti? (Se il PC non dà **nessun** segno di vita — nemmeno un LED, nemmeno un accenno di ventola — il colpevole è quasi sempre qui, o è l'alimentatore.)

**Livello 1 — Reseating.** Spegnete, scollegate, **tenete premuto il pulsante di accensione per 10 secondi** (scarica i condensatori). Poi:

- **\*\*RAM:\*\*** Togliete tutti i moduli e reinsertene **\*\*solo uno\*\***, nello slot **\*\*A2\*\*** (il secondo dalla CPU). Provate. Se non parte, provate lo stesso modulo in **\*\*B2\*\***. Se non parte, provate **\*\*l'altro modulo\*\*** in A2. Questa matrice di quattro tentativi distingue un modulo difettoso da uno slot difettoso da un errore di inserimento, e risolve la stragrande maggioranza dei casi.
- **\*\*GPU:\*\*** Reinsertite, e ricontrollate i cavi di alimentazione.
- **\*\*EPS 8-pin:\*\*** Ricontrollatelo. Seramente. È l'errore più comune.

**Livello 2 — Cancella CMOS.** Il **CMOS** è la memoria (alimentata dalla batteria a bottone CR2033) dove il BIOS memorizza le impostazioni. Un'impostazione impossibile (tipicamente: un profilo XMP/EXPO troppo aggressivo che la tua CPU non può gestire) può impedire il POST. *Cancellare il CMOS* ripristina tutto alle impostazioni di fabbrica. Questo può essere fatto in tre modi, in ordine di comodità: 1. Premere il **pulsante "Clear CMOS" o "BIOS Reset"** sul pannello posteriore (le schede madri di fascia media/alta ce l'hanno); 2. Cortocircuitare i due **pin "CLR\_CMOS" / "JBAT1"** sulla scheda madre per 5-10 secondi (con un cacciavite o il ponticello incluso), **con il PC spento e scollegato dalla corrente**; 3. **Rimuovere la batteria CR2032** per un paio di minuti, sempre con il PC spento e scollegato. Dopo un clear CMOS, tutte le impostazioni (XMP, ordine di avvio, curve delle ventole) tornano ai valori predefiniti e devono essere riconfigurate. E l'addestramento della memoria riparte da zero: **sii paziente al successivo primo avvio**.

**Livello 3 — Breadboarding.** Se nulla ha funzionato, si torna al banco. **Rimuovi la scheda madre dal case** (sì, tutto) e riasssemblala nuda sulla sua scatola di cartone,

con il **minimo indispensabile**: CPU, dissipatore, **un** modulo RAM, GPU, alimentatore, monitor. Niente hard disk, niente ventole del case, niente USB frontali, niente strisce LED. Accendi cortocircuitando i pin POWER SW. Se **si avvia così**, il colpevole era nel case: quasi sempre un **distanziatore orfano** che causa un corto, o un cavo del pannello frontale mal collegato, o una periferica difettosa. Riasssembla **un pezzo alla volta**, testando ogni volta. Se **non si avvia così**, il colpevole è tra i cinque componenti rimanenti, e a quel punto sono necessari componenti di ricambio per le sostituzioni (la parte in cui un amico con un PC diventa prezioso).

---

## 12. Configurazione Iniziale

Il PC fa il POST e visualizza qualcosa. Non hai finito: hai terminato la **parte meccanica**. Ora arriva la parte in cui il computer diventa *tuo*, e in cui recuperi prestazioni che hai già pagato ma che, con le impostazioni di fabbrica, **non stai usando**.

### 12.1 Entrare nel BIOS/UEFI

Alla prima accensione, premi ripetutamente **CANC** — o **F2** su alcune schede madri — non appena il PC si avvia. Entrerai nell'**UEFI** (*Unified Extensible Firmware Interface*, il moderno successore del BIOS; i due termini sono ormai usati come sinonimi), l'interfaccia di configurazione del firmware.

**Primo controllo: c'è tutto?** La schermata iniziale (*EZ Mode*) ti mostra un riepilogo. Verifica:

- La **\*\*CPU\*\*** è riconosciuta con il nome corretto;
- La **\*\*quantità totale di RAM\*\*** corrisponde a quella che hai installato (se hai 32 GB e ne vede solo 16, un modulo non fa contatto: spegni e reinserisci);
- Tutti gli **\*\*SSD/hard disk\*\*** sono elencati;
- La **\*\*velocità delle ventole\*\*** è diversa da zero per la CPU;
- La **\*\*temperatura della CPU\*\*** è ragionevole (a riposo, sotto i 50-60 °C in un sistema ben assemblato; se vedi 80-90 °C a riposo, **\*\*spegni immediatamente\*\***: il dissipatore non fa contatto, e la prima cosa da controllare è **\*\*la pellicola\*\***).

### 12.2 Attivare XMP / EXPO: cinque secondi, dieci percento di prestazioni

Questa è l'unica azione con il miglior rapporto sforzo-beneficio nell'intero processo.

I moduli RAM, secondo le specifiche **JEDEC** (l'ente che standardizza i semiconduttori), partono sempre a una **frequenza base conservativa** — molto più bassa di quella per cui hai pagato. Il kit da 6000 MT/s che hai acquistato, una volta installato, funziona a 4800 MT/s con timing rilassati. **Le prestazioni per cui hai pagato ci sono, ma sono disattivate.**

Per attivarlo, c'è un profilo memorizzato nel chip **SPD** del modulo, che il BIOS può caricare con un click:

- **\*\*XMP\*\*** (\*Extreme Memory Profile\*) è il nome del profilo su piattaforme **\*\*Intel\*\***;
- **\*\*EXPO\*\*** (\*EXtended Profiles for Overclocking\*) è l'equivalente **\*\*AMD\*\***;
- alcune schede lo chiamano genericamente **\*\*D.O.C.P.\*\*** o **\*\*A-XMP\*\***.

Sono concettualmente la stessa cosa: un set predefinito di frequenza, timings e voltaggi, testato dal produttore delle memorie. **Trovate l'opzione (è in bella vista in EZ Mode) e attivatela.** Il PC si riavvierà ed effettuerà nuovamente il memory training (di nuovo: **pazienza, può richiedere minuti**).

**Tecnicamente è un overclock**, quindi: se dopo l'attivazione il sistema è instabile (crash, schermate blu, no POST), non è un difetto — è il vostro specifico IMC che non regge quel profilo. Soluzioni: provate il profilo XMP/EXPO **secondario** (spesso più conservativo), oppure riducete manualmente la frequenza di uno step. E se non fa più POST: **clear CMOS**, e si ricomincia.

### 12.3 Aggiornamento del BIOS

Se il PC funziona, è **consigliabile** aggiornare il BIOS all'ultima versione stabile: le revisioni successive al lancio di una piattaforma migliorano sostanzialmente la compatibilità e la stabilità delle memorie, correggono bug e talvolta aumentano le prestazioni.

**La procedura corretta** (i nomi commerciali variano: *EZ Flash*, *M-Flash*, *Q-Flash*):

1. Sul **sito del produttore della vostra scheda madre**, nella pagina **del vostro esatto modello** (attenzione alle varianti: una "B650 Gaming X" non è una "B650 Gaming X AX"), scaricate l'ultimo file BIOS stabile;
2. Copiatelo su una **chiavetta USB formattata in FAT32**, nella directory radice;
3. Entrate nel BIOS, aprite l'utility di aggiornamento **integrata nel BIOS stesso** (mai, mai usare utility di aggiornamento da Windows: sono la causa storica di BIOS "brickati"), selezionate il file;
4. **NON SPEGNETE, NON TOCCATE NULLA** per tutta la durata.

Un'interruzione di corrente durante il flash può rendere la scheda madre inutilizzabile (a meno che non abbia un dual BIOS o Flashback).

Dopo l'aggiornamento, le impostazioni verranno resettate: **rifate XMP/EXPO e curve delle ventole**.

#### 12.4 Curve delle ventole e Resizable BAR

**Curve delle ventole.** Nella sezione dedicata del BIOS (Q-Fan Control, Smart Fan, Fan Xpert), potete definire una **curva** per ogni header che lega la velocità (in % o RPM) a una temperatura di riferimento. Il default è quasi sempre troppo aggressivo (rumoroso) o troppo pigro. Una curva sensata per la CPU: silenziosa fino a ~50 °C, aumento graduale tra 50 e 75 °C, massimo oltre 80 °C. Importante: impostate un **tempo di risposta** (*step up/down time, hysteresis*) di qualche secondo, per evitare che la ventola "pompi" su e giù ad ogni picco di temperatura momentaneo — il fenomeno che rende un PC fastidioso anche quando è silenzioso in media. E ricordate: header su **DC** per ventole a 3 pin, **PWM** per ventole a 4 pin.

**Resizable BAR** (Re-Size BAR / Smart Access Memory su AMD). È una funzionalità PCIe che permette alla CPU di accedere all'**intera VRAM** della GPU in una volta sola, invece che a finestre da 256 MB alla volta. Il beneficio nei giochi va da nullo a **oltre il 10%** a seconda del titolo. Va abilitato **nel BIOS** (spesso servono due impostazioni: **Above 4G Decoding** su *Enabled* e **Re-Size BAR Support** su *Auto/Enabled*). È gratis: abilitatelo.

#### 12.5 Sistema operativo e installazione dei driver

**Preparazione dei media:** Su un altro PC, scarica lo strumento ufficiale per la creazione dei media (per Windows, il *Media Creation Tool* dal sito Microsoft; per Linux, la ISO della distribuzione scritta su una chiavetta USB con uno strumento come Rufus o balenaEtcher). Ti servirà una chiavetta USB di almeno 8 GB, che verrà **formattata**.

**Boot:** Inserisci la chiavetta USB in una **porta USB posteriore** (più affidabile delle porte frontali durante l'installazione), riavvia e seleziona la chiavetta USB dal **Boot Menu** (solitamente **F8**, **F11** o **F12** — la scheda madre te lo indica all'avvio) o impostala come primo dispositivo di avvio nel BIOS.

**Durante l'installazione,** quando ti chiede dove installare, seleziona il tuo **NVMe SSD** (identificabile dalla dimensione). Se ci sono partizioni preesistenti, eliminale e usa lo spazio non allocato.



**Dopo l'installazione, l'ordine dei driver è importante:** 1. **Driver del chipset** — prima, sempre. Scaricali dal sito della **scheda madre** (o direttamente da AMD/Intel, spesso più aggiornati). Insegnano al sistema operativo come comunicare con la piattaforma: gestione energetica, scheduling dei core, controller. 2. **Driver della GPU** — direttamente dal sito **NVIDIA / AMD / Intel**, **non** dal disco incluso nella scatola (è vecchio di mesi). 3. **Driver di rete, audio e altri** — Windows Update ne installa molti automaticamente; per il resto, controlla il sito della scheda madre.

## 12.6 Test: controllo temperature e stabilità

Non dare per scontato che un PC sia a posto solo perché si accende. Un PC che si accende può comunque avere un dissipatore montato male, una curva delle ventole sbagliata o un profilo di memoria instabile. I test sono la prova.

### Gli strumenti (tutti gratuiti):

- **\*\*HWiNFO64\*\*** (in modalità **\*Sensors only\***): la finestra della verità. Mostra temperature, frequenze, voltaggi e consumi di ogni componente, con valori **\*\*minimi/massimi/medi\*\***. Tienilo aperto durante ogni test.
- **\*\*Cinebench\*\*** (R23 o versioni successive): un benchmark che carica **\*\*tutti i core della CPU al 100%\*\*** per 10 minuti. È il test più immediato: ti dà un punteggio (confrontabile online con CPU identiche alla tua, per capire se la tua sta performando come dovrebbe) e porta la CPU alla sua temperatura di picco realistica.
- **\*\*OCCT\*\*** o **\*\*Prime95\*\***: stress test più severi. Utili per verificare la stabilità di un profilo XMP/EXPO (il test **\*Memory\*** di OCCT, per un'ora, è la validazione standard) e la tenuta dell'alimentatore.
- **\*\*FurMark\*\*** o **\*\*3DMark\*\***: carico della GPU.
- **\*\*MemTest86\*\*** (avviato da chiavetta USB, fuori dal sistema operativo): il test definitivo della RAM. Un passaggio completo, senza errori, certifica che la tua memoria è a posto.
- **\*\*CrystalDiskMark\*\*** o **\*\*CrystalDiskInfo\*\***: velocità e salute degli SSD.

### Cosa cercare, e cosa è normale:

| Componente | A riposo  | Sotto pieno carico                                         | Allarme                                               |
|------------|-----------|------------------------------------------------------------|-------------------------------------------------------|
| CPU        | ~30-50 °C | Fino a 85-95 °C è <b>normale</b> su molte CPU moderne, che | Se raggiunge il limite (95-100 °C) <b>entro pochi</b> |

|                  |           |                                                                |                                                                                                      |
|------------------|-----------|----------------------------------------------------------------|------------------------------------------------------------------------------------------------------|
|                  |           | sono progettate per operare al loro limite termico e regolarsi | <b>secondi</b> dall'inizio del test → <b>dissipatore montato male / pellicola non rimossa</b>        |
| <b>GPU</b>       | ~30-45 °C | 65-80 °C tipici (VRAM/hotspot possono essere più alti)         | > 85-90 °C sostenuti, o ventole costantemente al 100%                                                |
| <b>NVMe SSD</b>  | 35-50 °C  | Fino a ~70 °C in scrittura sostenuta                           | Throttling visibile (cali di velocità) → dissipatore/pellicola                                       |
| <b>Stabilità</b> | —         | Nessun crash, nessun errore, nessun riavvio                    | Anche <b>un singolo</b> errore in MemTest o un crash in OCCT = problema reale, quasi sempre XMP/EXPO |

Una precisazione importante, perché genera ansia inutile: **una CPU moderna che raggiunge i 90 °C sotto Cinebench non è "difettosa" né "montata male"**. Le CPU odierne utilizzano algoritmi di boost opportunistici che spingono frequenza e voltaggio **fino a saturare il budget termico disponibile**: se il dissipatore è buono, la CPU va più veloce e rimane comunque calda. Quello che conta non è il numero assoluto, ma **quanto tempo ci mette ad arrivarci** (secondi = male, minuti = normale), **se ci rimane senza calare, e che frequenza mantiene**. Un test di 10 minuti che finisce a 88 °C con frequenze piene è un sistema sano. Un test che arriva a 100 °C in cinque secondi e cala alle frequenze base è un sistema con un problema di montaggio.

---

## Riepilogo Operativo — la checklist di assemblaggio

Tieni questo aperto accanto al tuo tavolo. Non passare al passo successivo finché il precedente non è verificato.

### PRIMA DI APRIRE LE SCATOLE

- [ ] Cacciavite **PH2 magnetico**, fascette, luce, superficie ampia non tessile
- [ ] Controllo finale compatibilità: **socket** / **BIOS** che supporta la CPU (c'è il **Flashback**?) / **RAM DDR corretta** / **ingombro dissipatore** / **lunghezza GPU** / **PSU: wattaggio + connettori**
- [ ] Cavo di alimentazione **staccato dal muro** ad ogni fase del lavoro
- [ ] Scaricarsi toccando lo chassis del case (o braccialetto antistatico) e ripetere dopo ogni pausa

### **PRE-ASSEMBLAGGIO A BANCO (mobo sulla sua SCATOLA, non sul sacchetto antistatico)**

- [ ] **CPU:** levetta aperta → allineare triangolo → **appoggiata**, non premuta (forza = zero) → levetta chiusa (forza = alta, resistenza elastica **sì**, stop netto **no**)
- [ ] **RAM:** slot **A2/B2** (**leggere il manuale**) → allineare tacca → premere alle estremità fino al **doppio click** → contatti dorati **scomparsi**
- [ ] **M.2:** slot **primario (CPU)** → **PELLICOLA THERMAL PAD RIMOSSA** → inserito a 30° → vite senza forzare
- [ ] **Dissipatore:** backplate + standoff → **PASTA TERMICA sempre** (puntino a pisello al centro) → **AIO: RIMUOVERE PELLICOLA** da cold plate → stringere **a croce, gradualmente**, fino a battuta → ventola/pompa su **CPU\_FAN / AIO\_PUMP**
- [ ] **(Consigliato)** **Test POST a banco** prima di mettere tutto nel case

### **CASE**

- [ ] Standoff: **uno sotto ogni foro**, **nessuno standoff orfano** (rischio corto)
- [ ] **I/O shield** montato nell'orientamento corretto (se non integrato)
- [ ] Cavi frontali pre-instradati attraverso i gommini

### **PSU**

- [ ] Ventola **verso il basso** se c'è filtro grigliato, verso l'interno se il fondo è chiuso
- [ ] **Solo cavi originali di QUEL modello di PSU** (mai cavi di altri PSU!)
- [ ] Cavi modulari collegati **prima** di inserirlo nel case

### **MOBO E RADIATORE**

- [ ] Mobo allineata con I/O shield, avvitata **a croce**, **senza stringere troppo**
- [ ] Radiatore AIO: **scarico in alto** (o immissione frontale) con **tubi in basso** — **la pompa non deve mai essere il punto più alto**
- [ ] Usare solo viti del kit (viti troppo lunghe **bucano il radiatore**)

## GPU

- [ ] **Primo slot x16** (l'unico elettricamente x16 dalla CPU) — controllare manuale
- [ ] Staffe rimosse, clip aperta, inserita fino al **click**, avvitata
- [ ] **NO daisy-chaining** sui cavi PCIe per GPU potenti
- [ ] **12V-2x6 inserito FINO IN FONDO**, nessuna piega entro **35 mm** — **ricontrollare a case chiuso**
- [ ] Supporto anti-sag se la scheda flette

## CABLAGGIO

- [ ] **24-pin** (il fermo scatta) — **EPS 8-pin** (in alto a sinistra: **è "4+4"**, PCIe è "6+2") — **PCIe/12V-2x6** — **SATA power**
- [ ] **F\_PANEL** secondo lo **schema del manuale** (una connessione sbagliata non rompe nulla, ma non si avvia)
- [ ] Header **USB 3.0** (pin fragili!), **USB-C**, **USB 2.0**, **HD Audio** (non confondere con USB 2.0)
- [ ] Ventole: **CPU\_FAN** obbligatoria; 3 pin = **DC**, 4 pin = **PWM** (impostare nel BIOS)
- [ ] **ARGB 5V** (3 pin, con un buco)  $\neq$  **RGB 12V** (4 pin). MAI mescolarli: brucerà tutto.
- [ ] Cavi dietro il vassoio, fascette, **nessun cavo davanti a ventole o dissipatore**

## PRIMO AVVIO

- [ ] Lista di controllo pre-accensione (viti perse? attrezzi all'interno? EPS collegato?)
- [ ] **Monitor collegato alla GPU, NON alla scheda madre**
- [ ] POST: interpretare i **LED CPU / DRAM / VGA / BOOT** o il **Q-Code**
- [ ] **DDR5**: il primo POST può richiedere minuti (memory training). ASPETTARE.

- [ ] Se non si avvia: **una variabile alla volta** → reinserire la RAM → **solo un modulo in A2** → **cancellare il CMOS** → **breadboarding**

## CONFIGURAZIONE

- [ ] BIOS: tutto rilevato? (CPU, **RAM totale corretta**, drive, ventole, **temperature sane**)
- [ ] **Abilitare XMP / EXPO** (è performance che hai già pagato)
- [ ] Aggiornare il BIOS (**dall'utility interna, mai da Windows**) → rifare XMP e ventole
- [ ] **Resizable BAR** + **Above 4G Decoding** = Abilitato
- [ ] Curve delle ventole con isteresi; header DC/PWM corretti
- [ ] OS da USB → **driver del chipset PRIMA**, poi **driver della GPU dal sito del produttore**
- [ ] Test: **Cinebench + HWiNFO** (temperature CPU), **OCCT/MemTest86** (stabilità XMP), **FurMark/3DMark** (GPU)
- [ ] Temperature di picco elevate ≠ guasto. **Temperature di picco raggiunte in POCHI SECONDI = dissipatore montato male.**

---

*Nota sui dati: le designazioni dei socket, dei chipset e dei modelli di connettori menzionati riflettono lo stato del mercato al momento della stesura e sono la parte più volatile di questo capitolo; le procedure fisiche, le forze e gli ordini di assemblaggio, tuttavia, sono sostanzialmente stabili da oltre un decennio. Controlla sempre il manuale della tua specifica scheda madre: è l'unica fonte autorevole per il layout di slot, header e pin.*

## Capitolo 10 - CPU per Workstation AI e HEDT

### Introduzione: perché esiste questo capitolo

Nei capitoli precedenti abbiamo costruito, pezzo per pezzo, il modello mentale del PC consumer: una CPU al centro, una GPU attaccata allo slot principale, due moduli RAM, uno o due SSD NVMe, un alimentatore dimensionato con un ragionevole margine. In quel mondo, la domanda dominante è "quanti frame al secondo ottengo?" o "quanto tempo ci vuole per compilare?", e la risposta quasi sempre ruota attorno alla frequenza di clock e al numero di core.

Quando l'obiettivo diventa una **workstation AI/ML** — cioè, una macchina che addestra reti neurali, esegue il fine-tuning di modelli linguistici, fa inferenza locale su LLM quantizzati, processa stream video con modelli di rilevamento, o semplicemente serve da banco di prova per pipeline che poi gireranno nei datacenter — quel modello mentale non regge più. Non perché sia sbagliato, ma perché **la domanda cambia**. La domanda non è più "quanto è veloce la CPU", ma "quanto materiale posso spostare contemporaneamente tra memoria, drive, rete e acceleratori, senza che nulla aspetti".

Questo è il punto centrale dell'intero capitolo, ed è bene affermarlo brutalmente: **in una workstation AI, lo scopo principale della CPU è non essere un collo di bottiglia per tutto il resto**. Il calcolo pesante è fatto dalle GPU. La CPU deve garantire tre cose: (1) abbastanza corsie di comunicazione (PCIe lanes) affinché GPU e SSD comunichino a piena velocità, (2) abbastanza banda di memoria e abbastanza RAM affinché i dati raggiungano le GPU senza intoppi, (3) abbastanza core affinché la preparazione dei dati (decodifica immagini, augmentation, tokenization) non lasci le GPU inattive.

Da queste tre esigenze nasce un'intera categoria di prodotti — **HEDT e workstation/server** — che il mercato consumer non conosce e che ha regole, nomenclature, prezzi e insidie completamente diverse. HEDT sta per *High-End DeskTop*: è un segmento storico, nato per chi aveva bisogno di più di un desktop ma non voleva (o non poteva) gestire un server. Oggi, HEDT significa essenzialmente AMD Threadripper e, in parte, Intel Xeon W.

Il capitolo procede come segue: prima, capiamo *perché* una CPU consumer non è sufficiente (e, altrettanto importante, *quando è perfettamente sufficiente*), poi approfondiamo le piattaforme Threadripper, poi le piattaforme server (EPYC e Xeon), poi esploriamo il PCIe come infrastruttura, poi le schede madri per

workstation, poi il dimensionamento in base al carico di lavoro, e infine, gli errori tipici. Concludiamo con un riassunto operativo, che è di fatto una checklist per l'acquisto.

Una nota metodologica prima di iniziare. **I dati numerici in questo settore invecchiano molto rapidamente:** prezzi, disponibilità, generazioni, e persino la matrice di compatibilità tra CPU e chipset cambiano ad ogni aggiornamento firmware. Ogni volta che i dati sono volatili, lo indicherò esplicitamente con il tag *[dati volatili]*. Architetture e principi, tuttavia, rimangono validi molto più a lungo: sono questi che vale la pena imparare davvero.

---

## 1. Perché una CPU Consumer non è Sufficiente

### 1.1 Il Cambiamento di Prospettiva: La CPU come Nodo di Smistamento

In un PC consumer, la CPU è la protagonista: esegue il codice applicativo, e tutto il resto le ruota attorno. In una workstation AI, la protagonista è l'acceleratore (la GPU), e la CPU assume quello che potremmo definire un ruolo *infrastrutturale*. È il nodo di smistamento del traffico: legge i dati dal disco, li decodifica, li trasforma, li impacchetta e li invia alla GPU; poi raccoglie i risultati, li scrive, li sincronizza tra più GPU e li invia in rete.

Se anche uno solo di questi passaggi è un collo di bottiglia, la GPU — che costa quanto il resto del sistema messo insieme — rimane inattiva. Il parametro critico in una workstation AI si chiama **GPU utilization**: la percentuale di tempo in cui i core dell'acceleratore stanno effettivamente calcolando. Una workstation ben progettata mantiene le GPU sopra il 90-95% di utilizzo durante l'addestramento. Una workstation sbilanciata — CPU consumer con quattro GPU attaccate a corsie ridotte, dataset su un singolo SSD, poca RAM — può facilmente scendere al 40-50%, il che significa **metà del valore economico dell'hardware sprecato**.

Vediamo, una per una, le quattro risorse che i sistemi consumer non riescono a fornire.

### 1.2 PCIe Lanes: La Vera Moneta della Workstation

**PCIe** sta per *Peripheral Component Interconnect Express*: è il bus (cioè il sistema di connessione) attraverso il quale la CPU comunica con le periferiche ad alta velocità — schede grafiche, SSD NVMe, schede di rete, acceleratori dedicati, controller di storage.

PCIe è un bus **seriale e punto-punto**: non è una strada condivisa dove tutti si accalcano (come il vecchio PCI o ISA), ma un insieme di connessioni dedicate. L'unità elementare è chiamata **lane**. Una lane è, fisicamente, una coppia di connessioni differenziali: una per la trasmissione, una per la ricezione. Questo significa che PCIe è **full-duplex**: può trasmettere e ricevere simultaneamente alla piena velocità nominale in entrambe le direzioni.

Le lane sono aggregate: uno slot può essere x1, x4, x8, x16. Il numero indica quante lane sono cablate a quello slot. Più lane significano più larghezza di banda: la larghezza di banda cresce linearmente con il numero di lane.

La seconda variabile è la **generazione** (o *revisione*) di PCIe, che determina la velocità di ciascuna lane. Ecco la panoramica, che vale la pena memorizzare perché la useremo costantemente:

| Generazione | Anno Indicativo | Larghezza di Banda per Lane (per direzione) | Larghezza di Banda x4 | Larghezza di Banda x8 | Larghezza di Banda x16 |
|-------------|-----------------|---------------------------------------------|-----------------------|-----------------------|------------------------|
| PCIe 3.0    | 2010            | ~0.985 GB/s                                 | ~3.94 GB/s            | ~7.88 GB/s            | ~15.75 GB/s            |
| PCIe 4.0    | 2017            | ~1.97 GB/s                                  | ~7.88 GB/s            | ~15.75 GB/s           | ~31.5 GB/s             |
| PCIe 5.0    | 2019            | ~3.94 GB/s                                  | ~15.75 GB/s           | ~31.5 GB/s            | ~63 GB/s               |
| PCIe 6.0    | 2022 (spec)     | ~7.88 GB/s                                  | ~31.5 GB/s            | ~63 GB/s              | ~126 GB/s              |

Da leggere come segue: **ogni generazione raddoppia la larghezza di banda per lane**, a parità di numero di lane. Di conseguenza, uno slot PCIe 5.0 x8 ha la stessa larghezza di banda di uno slot PCIe 4.0 x16. Questa equivalenza è molto importante e si presenterà ripetutamente.

*[dati volatili]* PCIe 6.0 esiste come specifica ed è in fase di adozione nel mondo dei datacenter, ma sulle piattaforme workstation disponibili oggi, lo standard di riferimento è PCIe 5.0. PCIe 7.0 è già stato ratificato come specifica ma non ha ancora prodotti reali sul mercato delle workstation.

### **Perché le Lane Sono il Vero Collo di Bottiglia**

Una CPU ha un numero **finito** di lane PCIe, perché ogni lane richiede pin fisici sul package, transceiver, silicio dedicato e consumo energetico. È una risorsa costosa, e i produttori la razionano per segmentare il mercato.



Contiamo ciò di cui ha bisogno una seria workstation AI:

- **\*\*Una GPU PCIe 5.0 x16\*\***: 16 lane. Se ci sono quattro GPU, sono necessarie **\*\*64 lane\*\*** solo per gli acceleratori.
- **\*\*SSD NVMe\*\***: Ogni NVMe (\*Non-Volatile Memory express\*, il protocollo con cui gli SSD comunicano direttamente sul bus PCIe) occupa tipicamente 4 lane. Una workstation AI ne ha spesso 3-4: una per il sistema operativo, una o due per il dataset "caldo", una per i checkpoint. Sono **\*\*12-16 lane\*\***.
- **\*\*Scheda di rete\*\***: Una NIC (\*Network Interface Card\*) da 10 GbE occupa generalmente 4 lane PCIe 3.0/4.0; una da 25/100 GbE occupa 8-16 lane. Diciamo **\*\*4-16 lane\*\***.
- **\*\*Controller HBA/RAID\*\*** per l'archiviazione di massa (dataset di decine di TB): **\*\*8 lane\*\***.
- **\*\*Schede di acquisizione, acceleratori dedicati, schede di acquisizione\*\***: variabile.

Realisticamente, per una workstation a 4 GPU:  $64 + 16 + 8 + 8 = \mathbf{96 \text{ lane}}$ . Una CPU consumer ne ha circa venti. Il divario è di un fattore quattro o cinque, e nessuna ottimizzazione software può colmarlo.

### *Quante Lane Hanno Veramente le CPU Consumer*

Qui, bisogna prestare attenzione a un dettaglio che confonde molti acquirenti: le lane **della CPU** e le lane **del chipset** non sono la stessa cosa.

Il **chipset** (in AMD, è anche chiamato *PCH, Platform Controller Hub*, originariamente un termine Intel) è un chip separato sulla scheda madre che espande la connettività. Ma il chipset è collegato alla CPU tramite un link che è esso stesso limitato — tipicamente x4 PCIe 4.0. Tutto ciò che è collegato al chipset (slot secondari, alcune porte NVMe, USB, SATA, LAN integrata) **condivide quel singolo link x4**. È come avere una villa con dieci stanze ma un solo corridoio largo un metro per raggiungerle tutte.

Per questo motivo, quando si progetta una workstation, **contano solo le linee native della CPU**, quelle direttamente collegate. Le linee del chipset vanno bene per periferiche lente (audio, USB, rete gigabit, SSD di archivio) e dovrebbero essere evitate per GPU e unità NVMe ad alte prestazioni.

Ecco la panoramica consumer [*dati indicativi, verificare per modelli specifici*]:

- **\*\*AMD AM5 (Ryzen 7000/8000/9000)\*\***: 28 linee PCIe totali dalla CPU, di cui **\*\*24 effettivamente utilizzabili\*\*** (16 per la GPU + 4 per un NVMe + 4 per un secondo NVMe), più 4 linee dedicate alla connessione del chipset. Le versioni con grafica integrata potente (serie "G") ne hanno ancora meno.
- **\*\*Intel LGA1700 (12a–14a gen)\*\***: **\*\*20 linee\*\*** dalla CPU (16 PCIe 5.0 per la GPU + 4 PCIe 4.0 per un NVMe), più la connessione DMI al chipset.
- **\*\*Intel LGA1851 (Core Ultra 200 series "Arrow Lake")\*\***: **\*\*24 linee\*\*** dalla CPU (16 PCIe 5.0 + 4 PCIe 5.0 + 4 PCIe 4.0), più DMI.

*[dati volatili]* Questi numeri cambiano ad ogni nuova piattaforma; il principio (consumer = ~20–28 linee, e non di più) è stabile da oltre un decennio.

### 1.3 Tabella comparativa: linee per segmento di piattaforma

| Piattaforma                                 | Segmento          | Linee PCIe dalla CPU                                                                     | Generazione        | Note                        |
|---------------------------------------------|-------------------|------------------------------------------------------------------------------------------|--------------------|-----------------------------|
| Intel LGA1700 (Core 12a/13a/14a gen)        | Consumer          | 20                                                                                       | 5.0 (16) + 4.0 (4) | Singola GPU a x16           |
| Intel LGA1851 (Core Ultra 200S)             | Consumer          | 24                                                                                       | 5.0 (20) + 4.0 (4) | Una GPU + 2 NVMe            |
| AMD AM5 (Ryzen 7000/9000)                   | Consumer          | 24 utilizzabili (+4 chipset)                                                             | 5.0                | Una GPU + 2 NVMe            |
| AMD Threadripper 7000/9000 (TRX50)          | HEDT              | <b>48 PCIe 5.0</b> (+ ulteriori linee 4.0; AMD dichiara fino a ~92 linee di piattaforma) | 5.0 / 4.0          | 2 GPU a x16 complete + NVMe |
| AMD Threadripper PRO 7000WX/9000 WX (WRX90) | Workstation       | <b>128 PCIe 5.0</b>                                                                      | 5.0                | Fino a 7 slot x16           |
| Intel Xeon W-2400/2500 (W790)               | Workstation Entry | 64                                                                                       | 5.0                | 2 GPU a x16 + storage       |
| Intel Xeon W-3400/3500                      | Workstation       | 112                                                                                      | 5.0                | 4+ GPU                      |

|                            |        |                       |     |                                 |
|----------------------------|--------|-----------------------|-----|---------------------------------|
| (W790)                     |        |                       |     |                                 |
| AMD EPYC 9004/9005 (SP5)   | Server | <b>128 per socket</b> | 5.0 | 160 linee totali in dual-socket |
| Intel Xeon 6 (6700P/6900P) | Server | 88 / 96 per socket    | 5.0 | Dipende dalla SKU               |

*[dati volatili: controllare sempre il datasheet per la SKU precisa, poiché esistono varianti con conteggi diversi all'interno della stessa famiglia]*

Lettura pratica di questa tabella: il salto da consumer a HEDT **raddoppia o triplica** le linee; il salto da HEDT a workstation professionale **le raddoppia di nuovo**. Ed è per questo — non per il numero di core — che si sale di piattaforma.

#### 1.4 Canali di memoria: perché la larghezza di banda della RAM è importante

Il **controller di memoria** è il circuito che gestisce la comunicazione tra la CPU e la RAM. Da circa quindici anni, è integrato nella CPU stessa, e viene chiamato **IMC** (*Integrated Memory Controller*). In precedenza, era sul chipset (il famigerato "northbridge"), e la sua integrazione nella CPU è stata una delle maggiori innovazioni prestazionali degli anni 2000.

L'IMC comunica con la RAM attraverso uno o più **canali**. Un canale è un percorso indipendente verso i moduli di memoria: più canali significano più percorsi paralleli e quindi una maggiore larghezza di banda aggregata.

Facciamo i calcoli. Un modulo DDR5 (*Double Data Rate 5*, la quinta generazione di memoria SDRAM) a 5600 MT/s (*Mega Transfers per second*, ovvero milioni di trasferimenti al secondo) fornisce circa **44,8 GB/s per canale** ( $5600 \times 8$  byte). Da ciò:

| Configurazione | Canali | Larghezza di banda teorica (DDR5-5600) | Piattaforme                                    |
|----------------|--------|----------------------------------------|------------------------------------------------|
| Dual channel   | 2      | ~90 GB/s                               | Consumer AM5, LGA1700/1851                     |
| Quad channel   | 4      | ~180 GB/s                              | Threadripper non-PRO (TRX50), Xeon W-2400/2500 |
| Octa channel   | 8      | ~358 GB/s                              | Threadripper PRO (WRX90), Xeon W-3400/3500     |

|            |    |           |                                          |
|------------|----|-----------|------------------------------------------|
| 12-channel | 12 | ~537 GB/s | AMD EPYC 9004/9005, Intel Xeon 6 (6900P) |
|------------|----|-----------|------------------------------------------|

*[nota: le frequenze ufficialmente supportate variano; le piattaforme server tipicamente usano DDR5 registrata a 4800–6400 MT/s a seconda del numero di moduli per canale. Dati volatili.]*

### **Perché la larghezza di banda della RAM è importante in una workstation AI**

Ci sono tre ragioni, tutte concrete.

**Primo: caricamento dei dati.** Durante l'addestramento, il flusso è il seguente: i dati grezzi (immagini JPEG, file audio, testi) vengono letti dal disco, decodificati nella RAM, trasformati (ridimensionamento, normalizzazione, aumento), impacchettati in tensori e infine copiati nella memoria della GPU tramite PCIe. Tutti questi passaggi intermedi risiedono nella RAM di sistema. Con quattro GPU che richiedono, diciamo, 3–4 GB/s di dati ciascuna, e considerando che ogni byte viene toccato più volte (lettura, decodifica, trasformazione, copia in *pinned memory*), la RAM viene attraversata a decine di GB/s. Un dual channel a 90 GB/s teorici — che in pratica si traduce in 60–70 GB/s reali — diventa un collo di bottiglia.

**Secondo: inferenza CPU.** Quando si esegue un LLM (*Large Language Model*) direttamente sulla CPU — con `llama.cpp`, con backend ONNX Runtime, con oneDNN — la fase di **generazione token-by-token** è quasi interamente *memory-bound*, ovvero limitata dalla larghezza di banda della memoria, non dalla potenza computazionale. La ragione è che per generare ogni singolo token, **tutti i pesi del modello** devono essere letti dalla RAM. Un modello da 70 miliardi di parametri quantizzato a 4 bit occupa circa 40 GB. Per generare 10 token al secondo, devono essere letti 400 GB/s. Su una piattaforma dual-channel con 70 GB/s reali, ciò si traduce in circa 1,5–2 token/s: inutilizzabile per un uso interattivo. Su una piattaforma a 12 canali con oltre 400 GB/s, ciò si traduce in 8–10 token/s: lento ma utilizzabile. **Questo è il motivo per cui esiste una vera nicchia di persone che acquistano EPYC usati per l'inferenza LLM su CPU: non per i core, ma per la larghezza di banda.**

**Terzo: pre-elaborazione classica.** Pipeline Pandas/polars su dataset tabulari di decine di GB, operazioni di join, groupby, feature engineering: tutte operazioni

che spostano montagne di byte e scalano con la larghezza di banda della memoria più che con la frequenza di clock.

### 1.5 Capacità della RAM: i limiti reali e i moduli registrati

Oltre alla larghezza di banda, c'è la **capacità**. E qui il limite consumer è chiaro.

Una piattaforma consumer ha **quattro slot DIMM** (su due canali: due moduli per canale). Il limite pratico dipende dalla capacità massima dei moduli UDIMM disponibili:

*[dati volatili]* Su AM5 e LGA1851, con moduli UDIMM da 48 GB, si raggiungono 192 GB; con l'arrivo dei moduli da 64 GB e relativi aggiornamenti AGESA/BIOS, si raggiungono 256 GB. Oltre non è possibile, e già con 4 moduli le frequenze operative calano perché l'IMC fatica a pilotare due moduli per canale ad alta velocità.

Questo è il punto critico: **su una piattaforma consumer, riempire tutti e quattro gli slot degrada la frequenza della RAM**. Un kit DDR5-6000 con due moduli funziona a 6000; gli stessi quattro moduli spesso scendono a 3600–4400 MT/s. Si paga la capacità in cambio di banda — esattamente il compromesso che non si vuole fare in una workstation.

#### **UDIMM, RDIMM, LRDIMM**

Per superare questo limite, il mondo professionale usa moduli diversi.

- **\*\*UDIMM\*\* (\*Unbuffered DIMM\*)**: È il modulo consumer. I segnali di indirizzo e comando dall'IMC arrivano **\*\*direttamente\*\*** a tutti i chip di memoria sul modulo. Semplice, economico, bassa latenza — ma il carico elettrico sul controller aumenta con il numero di chip, il che limita quanti moduli possono essere posti per canale e a quale frequenza.
- **\*\*RDIMM\*\* (\*Registered DIMM\*)**: C'è un chip aggiuntivo sul modulo, il **\*\*RCD\*\* (\*Registering Clock Driver\*)**, che funge da buffer per i segnali di indirizzo e comando. L'IMC pilota un solo carico (il register) invece di decine di chip. Costo: un ciclo di clock aggiuntivo di latenza. Beneficio: si possono installare moduli molto più grandi (64, 96, 128 GB e oltre) e più moduli per canale mantenendo frequenze elevate. **\*\*Le piattaforme Threadripper PRO, EPYC e Xeon W/Scalable richiedono RDIMM: non accettano UDIMM.\*\***
- **\*\*LRDIMM\*\* (\*Load-Reduced DIMM\*)**: Questo bufferizza anche le linee dati, non solo indirizzi e comandi. Permette capacità estreme (fino a 256 GB per

modulo) a costo di latenza aggiuntiva. Usato in server con enormi requisiti di memoria.

- **\*\*MRDIMM\*\*** (\*Multiplexed Rank DIMM\*): La recente evoluzione, che multiplexa due rank per raddoppiare la banda effettiva. Supportato sulle ultime piattaforme server. \*[dati volatili, ecosistema in evoluzione]\*

#### *Limiti di Capacità per Piattaforma*

| Piattaforma                    | Slot DIMM tipici | Tipo di memoria                     | Capacità massima indicativa |
|--------------------------------|------------------|-------------------------------------|-----------------------------|
| Consumer AM5 / LGA1851         | 4                | UDIMM (ECC non ufficiale opzionale) | 192–256 GB [volatile]       |
| Threadripper 7000/9000 (TRX50) | 4                | RDIMM ECC (4 canali)                | ~1 TB                       |
| Threadripper PRO (WRX90)       | 8                | RDIMM ECC (8 canali)                | ~2 TB                       |
| Xeon W-3400/3500 (W790)        | 8                | RDIMM ECC (8 canali)                | ~2 TB                       |
| EPYC 9004/9005 (SP5)           | 12 o 24          | RDIMM ECC (12 canali)               | 6 TB e oltre per socket     |

*[dati volatili: le capacità massime aumentano con ogni nuovo modulo RDIMM sul mercato. Controllare la QVL — Qualified Vendor List — della scheda madre.]*

Il salto è di un ordine di grandezza. Ed è davvero necessario: caricare un intero dataset di immagini in RAM per eliminare l'I/O su disco, tenere un grafo enorme in memoria, fare inferenza CPU su un modello da 405 miliardi di parametri, eseguire simulazioni — sono tutti casi in cui 256 GB sono insufficienti.

#### **1.6 ECC: Cos'è e perché è irrinunciabile in ambito professionale**

**ECC** sta per *Error-Correcting Code*.

Il problema che risolve è fisico. Una cella di memoria DRAM memorizza un bit come una carica elettrica in un condensatore microscopico. Tale carica può essere alterata: da un raggio cosmico (un neutrone ad alta energia che attraversa il silicio), da particelle alfa emesse da impurità radioattive nei materiali del package, da interferenze elettromagnetiche o da instabilità termiche o di alimentazione. Il risultato è un **soft error**: un bit che si inverte, da 0 a 1 o viceversa, senza che nulla sia fisicamente rotto.

La frequenza è bassa ma non trascurabile. Studi sul campo (il più citato è quello di Google su decine di migliaia di server) indicano ordini di grandezza di **migliaia di errori correggibili per gigabyte all'anno** in condizioni reali. Su un desktop con 32 GB accessi otto ore al giorno, un errore occasionale: fastidioso, magari un crash, si riavvia. Su una workstation con **512 GB in funzione 24 ore su 24, 7 giorni su 7 per tre settimane** durante l'addestramento, la probabilità di almeno un'inversione di bit diventa **alta**.

### *Come funziona l'ECC*

L'implementazione classica si chiama **SECCDED**: *Single Error Correction, Double Error Detection*. Per ogni 64 bit di dati utili, vengono aggiunti 8 bit di codice di controllo (un codice Hamming esteso), il che significa che il modulo ha chip extra: un modulo ECC tipicamente ha 9 o 18 chip invece di 8 o 16. Quando la CPU legge quei 72 bit, ricalcola il codice: se un singolo bit è sbagliato, il sistema **capisce quale** e lo corregge al volo, in modo trasparente, registrando l'evento. Se due bit sono sbagliati, il sistema **rileva** l'errore ma non può correggerlo: genera un'eccezione della macchina e generalmente arresta il sistema, perché continuare significherebbe lavorare con dati corrotti.

Questo è il punto chiave: **senza ECC, un'inversione di bit è silenziosa**. Il computer non sa che i dati sono sbagliati. Continua semplicemente a funzionare.

### *Perché è essenziale in AI/ML*

Immaginiamo le conseguenze concrete di un'inversione di bit silenziosa in una workstation AI:

- Durante una sessione di addestramento di 72 ore, un bit si inverte nell'esponente di un numero in virgola mobile che rappresenta un peso. Il peso cambia da 0.003 a  $3 \times 10^{30}$ . Il gradiente esplode, la perdita diventa NaN (\*Not a Number\*), e il problema viene notato — nel migliore dei casi — ore dopo. **Tre giorni di GPU sprecati.**
- Peggio: l'inversione di bit si verifica in un punto che non causa alcuna esplosione, ma corrompe sottilmente un batch di dati o un peso. Il modello converge comunque, ma è **sottilmente sbagliato**, e nessuno lo noterà mai. Il risultato scientifico o il prodotto sono compromessi in modo non riproducibile e non diagnosticabile.
- Un'inversione di bit in un checkpoint scritto su disco corrompe il file, e viene notato solo settimane dopo quando si tenta di riprendere l'addestramento.

In un contesto professionale — ricerca pubblicabile, modelli che vanno in produzione, calcoli su cui vengono prese decisioni — la **non riproducibilità silenziosa è inaccettabile**. L'ECC costa il 10-15% in più per i moduli e circa un punto percentuale in termini di prestazioni. È l'assicurazione più economica per il sistema.

### *Attenzione a due confusioni comuni*

**Confusione 1: L'"on-die ECC" di DDR5 non è ECC di sistema.** Tutti i moduli DDR5, anche i più economici da gaming, hanno una forma di correzione degli errori *interna al chip* (on-die ECC), introdotta perché le densità delle celle sono diventate così elevate che gli errori interni sarebbero altrimenti insostenibili. Ma questa correzione protegge solo la cella; **non protegge il percorso tra il chip e la CPU**, non segnala errori al sistema operativo e non fornisce alcuna garanzia end-to-end. Vedere "DDR5 con on-die ECC" sulla confezione di un kit da gaming e pensare di avere una macchina ECC è un errore molto comune e molto costoso.

**Confusione 2: Supporto ECC su una piattaforma consumer.** Alcune CPU AM5 supportano tecnicamente moduli **UDIMM ECC**, e alcune schede madri (specialmente ASRock e alcune ASUS Pro) lo espongono nel BIOS. Questo è un supporto reale ma **non ufficialmente validato** per uso professionale, con disponibilità limitata di moduli e nessuna garanzia. Non è una scorciatoia per evitare la piattaforma workstation: è un "meglio di niente" per un homelab.

### *1.7 E se il consumer fosse sufficiente?*

Prima di procedere, è onesto dire una cosa che il resto del capitolo potrebbe farvi dimenticare: **per molti casi d'uso reali, una piattaforma consumer di fascia alta è la scelta giusta.**

Se il progetto è: una singola GPU (anche una RTX 5090 o una RTX PRO 6000), 128 GB di RAM, due unità NVMe, fine-tuning con LoRA, inferenza locale, sviluppo di prototipi — allora un Ryzen 9 9950X o un Core Ultra 9 285K su una piattaforma consumer **fa esattamente ciò che serve**, costa un quarto, ha frequenze single-thread più elevate (utili per il codice Python non parallelizzato) e non richiede raffreddamenti esotici.

Spendere 3.000 euro per una CPU Threadripper PRO + scheda madre per pilotare una singola GPU è, come vedremo nella sezione errori, l'errore più frequente e più costoso in questo settore. **Si aggiornano le piattaforme quando si supera un**



**confine preciso, non per prestigio.** Quel confine è: **due o più GPU a x16 elettrico**, o la necessità di più di 256 GB di RAM, o il requisito di ECC certificato.

---

## 2. AMD Threadripper: La Panoramica Completa

### 2.1 Cos'è Threadripper e dove si colloca

**Threadripper** è la linea di AMD lanciata nel 2017 per colmare il divario tra Ryzen (consumer) ed EPYC (server). Tecnicamente, non è un progetto separato: è **silicio EPYC riconfezionato** su un package e socket dedicati, con frequenze più elevate, meno canali di memoria (nelle versioni non-PRO) e un ecosistema di schede madri progettato per il desktop anziché per il rack.

Il posizionamento è preciso:

- **\*\*Ryzen\*\*** (AM5): 1 GPU, 2 canali RAM, ~24 lane. Frequenze massime, latenze minime, prezzo basso.
- **\*\*Threadripper\*\*** (sTR5/TRX50): 2 GPU a x16, 4 canali RAM RDIMM, 48 lane PCIe 5.0. Il "desktop estremo".
- **\*\*Threadripper PRO\*\*** (sTR5/WRX90): 4–7 GPU, 8 canali RAM RDIMM, 128 lane PCIe 5.0. La vera workstation.
- **\*\*EPYC\*\*** (SP5): 12 canali, 128 lane per socket, dual socket, ma frequenze più basse e nessun supporto "desktop".

È importante capire subito: **PRO e non-PRO condividono lo stesso socket fisico (sTR5) ma non le stesse piattaforme.** Questa è la principale fonte di confusione.

### 2.2 Threadripper non-PRO: Le Serie 7000X e 9000X

La generazione basata su Zen 4 (nome in codice *Storm Peak*, lanciata a fine 2023) include:

| Modello            | Core / Thread | Boost Max Indicativo | Cache L3 | TDP   |
|--------------------|---------------|----------------------|----------|-------|
| Threadripper 7960X | 24 / 48       | ~5.3 GHz             | 128 MB   | 350 W |
| Threadripper 7970X | 32 / 64       | ~5.3 GHz             | 128 MB   | 350 W |
| Threadripper 7980X | 64 / 128      | ~5.1 GHz             | 256 MB   | 350 W |

La prossima generazione, basata su **Zen 5** (nome in codice *Shimada Peak*, serie 9000, disponibile dal 2025), mantiene la stessa struttura:

| Modello            | Core / Thread | Note                         |
|--------------------|---------------|------------------------------|
| Threadripper 9960X | 24 / 48       | Successore diretto del 7960X |
| Threadripper 9970X | 32 / 64       | Successore del 7970X         |
| Threadripper 9980X | 64 / 128      | Successore del 7980X         |

*[dati volatili: frequenze, prezzi e disponibilità cambiano; la struttura core/lane è stabile]*

Caratteristiche della piattaforma dei non-PRO su chipset TRX50:

- **\*\*Memoria\*\***: **\*\*4 canali\*\*** DDR5 RDIMM ECC, 4 slot DIMM. Nota importante: anche i Threadripper non-PRO **\*\*richiedono RDIMM registrate\*\***, non UDIMM consumer. Non è possibile riutilizzare un kit da gaming.
- **\*\*PCIe\*\***: **\*\*48 lane PCIe 5.0\*\*** dalla CPU utilizzabili sulla piattaforma TRX50, più ulteriori lane PCIe 4.0 dal chipset e dalla CPU. AMD pubblicizza commercialmente un totale di piattaforma "fino a 92 lane" sommando tutto (CPU + chipset, generazioni miste). \*[Attenzione: questo è un numero di marketing. Ciò che conta per le GPU sono le 48 lane PCIe 5.0 native.]\*
- **\*\*TDP\*\***: **\*\*350 W\*\*** (\*Thermal Design Power\*, la potenza di dissipazione termica che il sistema di raffreddamento deve essere in grado di gestire in condizioni sostenute; il consumo di picco effettivo può superarlo).

**A cosa serve**: due GPU a pieno x16 PCIe 5.0, più 2-3 NVMe a x4, più una NIC. Questa è la configurazione tipica per una workstation AI di un ricercatore individuale serio, o di un piccolo team.

### 2.3 Threadripper PRO: Le serie 7000WX e 9000WX

Questa è una categoria diversa. La linea PRO è la workstation professionale di AMD, e la differenza non è nel numero di core (che pure aumenta) ma **nella piattaforma**.

| Modello                 | Core / Thread | Cache L3 | TDP   |
|-------------------------|---------------|----------|-------|
| Threadripper PRO 7955WX | 16 / 32       | 64 MB    | 350 W |
| Threadripper PRO 7965WX | 24 / 48       | 128 MB   | 350 W |

|                         |                 |        |       |
|-------------------------|-----------------|--------|-------|
| Threadripper PRO 7975WX | 32 / 64         | 128 MB | 350 W |
| Threadripper PRO 7985WX | 64 / 128        | 256 MB | 350 W |
| Threadripper PRO 7995WX | <b>96 / 192</b> | 384 MB | 350 W |

La generazione Zen 5 (serie 9000WX) replica la struttura, con il **9995WX** a 96 core al vertice, affiancato da 9985WX (64c), 9975WX (32c), 9965WX (24c), 9955WX (16c).  
*[dati volatili: verificare l'elenco SKU aggiornato]*

Caratteristiche della piattaforma PRO su chipset **WRX90**:

- **\*\*Memoria\*\***: **\*\*8 canali\*\*** DDR5 RDIMM ECC, 8 slot DIMM, fino a ~2 TB.
- **\*\*PCIe\*\***: **\*\*128 lane PCIe 5.0 native\*\***. Questo è il numero che giustifica l'intera esistenza della linea.
- **\*\*Funzionalità professionali\*\***: AMD PRO Manageability (gestione remota a livello enterprise), AMD PRO Security (Memory Guard, crittografia della memoria), garanzie e validazione ISV (\*Independent Software Vendor\*: certificazione che software professionali come CAD, simulatori e suite di rendering sono testati su quella piattaforma).

## 2.4 Il Confronto Che Conta Davvero

Ricapitoliamo, perché questa è **la tabella più importante dell'intero capitolo**:

| Caratteristica             | Threadripper (non-PRO) su TRX50 | Threadripper PRO su WRX90   |
|----------------------------|---------------------------------|-----------------------------|
| Socket                     | sTR5                            | sTR5 (stesso socket fisico) |
| Chipset                    | TRX50                           | WRX90                       |
| Linee PCIe 5.0 native      | <b>48</b>                       | <b>128</b>                  |
| Canali RAM                 | <b>4</b>                        | <b>8</b>                    |
| Slot DIMM                  | 4                               | 8                           |
| RAM massima                | ~1 TB                           | ~2 TB                       |
| Tipo di RAM                | RDIMM ECC                       | RDIMM ECC                   |
| Core massimi               | 64                              | <b>96</b>                   |
| GPU a x16 elettrico        | <b>2</b>                        | <b>fino a 7</b>             |
| Gestione remota (IPMI/BMC) | raramente                       | tipica                      |
| Costo piattaforma (CPU+MB) | Alto                            | Molto alto                  |

Un punto sottile che genera molta confusione: **una CPU Threadripper PRO può essere montata su una scheda madre TRX50**, perché il socket è lo stesso. Ma in quel caso, **opera con le limitazioni del TRX50**: 4 canali di memoria anziché 8, e un numero ridotto di linee esposte (le schede TRX50 non hanno il cablaggio per 128 linee). Il contrario **non è vero**: una CPU non-PRO **non funziona** su una scheda madre WRX90. WRX90 accetta solo PRO.

Questo apre un interessante scenario pratico: **acquistare una CPU PRO su una scheda TRX50** ha senso solo se si desidera accedere a un numero di core più elevato (ad esempio, il 7995WX a 96 core) senza la necessità di 128 linee. È un caso di nicchia — ma esiste, ad esempio, per carichi di lavoro di rendering o compilazione massiva con una singola GPU.

## 2.5 Decodifica della nomenclatura

Prendiamo il **7995WX** e analizziamolo:

- **\*\*7\*\***: generazione. La serie 7000 corrisponde a Zen 4; la serie 9000 a Zen 5.  
\*(Nota: AMD ha saltato la serie 8000 su Threadripper, allineandosi alla numerazione Ryzen.)\*
- **\*\*99\*\***: livello all'interno della generazione. Più alto = più core. 95 → 96 core, 85 → 64 core, 75 → 32 core, 65 → 24 core, 55 → 16 core. La logica a due cifre è "posizione nello stack", non una formula matematica.
- **\*\*5\*\***: cifra di segmento/revisione, praticamente costante nella linea.
- **\*\*WX\*\***: **\*\*il suffisso è la cosa più importante di tutte\*\***. **\*WX\*** = **\*WorkstationExtreme\***, cioè **\*\*PRO\*\***: 8 canali, 128 linee, WRX90.
- **\*\*X\*\*** (senza W): non-PRO. 4 canali, 48 linee, TRX50.

Quindi: **7970X ≠ 7975WX**. Il primo ha 32 core, 4 canali, 48 linee. Il secondo ha 32 core, 8 canali, 128 linee. **Stessi core, piattaforme completamente diverse, prezzo molto diverso**. Chi non conosce il significato di "WX" è molto probabile che acquisti il prodotto sbagliato.

## 2.6 Socket sTR5, Chipset TRX50 e WRX90

Il socket **sTR5** è un LGA (*Land Grid Array*: i pin sono sul socket, non sulla CPU) con **4844 pin**. È fisicamente enorme — un rettangolo di circa 76 × 58 mm — e questo ha conseguenze pratiche:

- **\*\*Montaggio\*\***: la CPU viene inserita in un *\*carrier\** di plastica arancione che scorre in una guida metallica; il coperchio si chiude con **\*\*tre viti Torx\*\*** da stringere **\*\*in ordine numerato (1, 2, 3)\*\*** e con **\*\*coppia controllata\*\***. AMD fornisce un cacciavite dinamometrico nella confezione. Questo non è un capriccio: stringere fuori ordine o con coppia errata su una superficie così grande può causare contatti mancanti o danni permanenti al package.
- **\*\*Raffreddamento\*\***: l'IHS (*\*Integrated Heat Spreader\**, il coperchio metallico della CPU) è molto più grande di quelli consumer. **\*\*Un dissipatore AM5 o LGA1700 non coprirà la superficie\*\*** e non ha il montaggio corretto. Sono necessari dissipatori sTR5 specifici.

Il **chipset**, come abbiamo visto, è il chip sulla scheda madre che espande la connettività. La scelta tra TRX50 e WRX90 è **la vera decisione architetturale**, e deve essere presa **prima** di scegliere la CPU:

| Domanda                                                                     | Se la risposta è... | Piattaforma                    |
|-----------------------------------------------------------------------------|---------------------|--------------------------------|
| Quante GPU a x16 elettrico?                                                 | 1 o 2               | <b>TRX50</b>                   |
| Quante GPU a x16 elettrico?                                                 | 3 o più             | <b>WRX90</b>                   |
| Hai bisogno di più di ~500 GB di RAM?                                       | Sì                  | <b>WRX90</b>                   |
| Hai bisogno della massima larghezza di banda della memoria (inferenza CPU)? | Sì                  | <b>WRX90</b> (8 canali)        |
| Hai bisogno di gestione remota IPMI/BMC?                                    | Sì                  | <b>WRX90</b> (o scheda server) |
| Il budget è il vincolo principale?                                          | Sì                  | <b>TRX50</b>                   |

## 2.7 Perché Threadripper PRO è *\*la\** piattaforma per le workstation AI

C'è solo un motivo, e risiede nelle 128 linee. Contiamo su una scheda **ASUS Pro WS WRX90E-SAGE SE**, che è il riferimento in questa categoria:

- **\*\*7 slot PCIe 5.0 x16\*\*** — tutti **\*\*veri x16 elettrici\*\***, tutti contemporaneamente.  $7 \times 16 = \textbf{**112 linee**}$ .
- Circa 16 linee rimangono per NVMe (spesso 4 slot M.2, alcuni tramite biforcazione) e per il resto.

Sette slot x16 completi significano che puoi installare **quattro GPU a doppio slot con spazio adeguato tra di esse** (usando gli slot 1, 3, 5, 7), o **sette schede a singolo slot**. Nessun'altra piattaforma derivata da desktop offre questo. È letteralmente il motivo per cui le workstation multi-GPU esistono sotto la scrivania invece che nei rack.

## 2.8 Confronto tra marchi e fasce di prezzo (Threadripper)

*[Tutti i prezzi sono indicativi e volatili; usali solo come ordini di grandezza.]*

| Configurazione         | CPU indicativa         | Scheda madre                             | Fascia di costo CPU+MB |
|------------------------|------------------------|------------------------------------------|------------------------|
| HEDT entry             | TR 7960X / 9960X (24c) | TRX50 (ASUS TRX50-SAGE, ASRock TRX50 WS) | ~2.000–2.800 €         |
| HEDT high              | TR 7970X / 9970X (32c) | TRX50                                    | ~3.000–4.000 €         |
| Workstation entry PRO  | TR PRO 7955WX (16c)    | WRX90 (ASUS WRX90E-SAGE SE)              | ~3.500–4.500 €         |
| Workstation medium PRO | TR PRO 7975WX (32c)    | WRX90                                    | ~5.500–7.000 €         |
| Workstation top PRO    | TR PRO 7995WX (96c)    | WRX90                                    | ~12.000–15.000 €       |

Il punto da notare: **la CPU PRO da 16 core 7955WX è la "budget"**, e per molte workstation AI, **è la scelta giusta**, perché la si acquista per le linee e i canali di memoria, non per i core. Sedici core Zen 4 sono più che sufficienti per gestire il caricamento dei dati per quattro GPU. Pagare tre volte tanto per 96 core che rimarranno al 15% di utilizzo è denaro sprecato — a meno che il carico di lavoro non sia anche intensivo per la CPU (rendering, simulazione, compilazione).

---

## 3. AMD EPYC e Intel Xeon: quando passare al server

### 3.1 AMD EPYC (Genoa, Bergamo, Turin)

**EPYC** è la linea di server di AMD. Le generazioni recenti, su socket **SP5** (LGA6096):

- **\*\*EPYC 9004 "Genoa"\*** (Zen 4, 2022): fino a **\*\*96 core\*\*** per socket.
- **\*\*EPYC 9004 "Bergamo"\*** (Zen 4c, core ottimizzati per la densità): fino a **\*\*128 core\*\***.

- **EPYC "Genoa-X"**: con **3D V-Cache**, cache L3 fino a oltre 1 GB. Utile per carichi di lavoro sensibili alla cache (simulazione CFD, EDA).
- **EPYC 9005 "Turin"** (Zen 5, 2024): fino a **128 core Zen 5**, o **192 core** nelle varianti Zen 5c.

Caratteristiche della piattaforma SP5:

- **128 linee PCIe 5.0 per socket.** In una configurazione **dual-socket**, alcune linee sono utilizzate per l'interconnessione tra processori (il collegamento inter-socket **Infinity Fabric**), quindi il totale utilizzabile non è 256 ma tipicamente **160 linee** (configurabile: più linee possono essere sacrificate per un collegamento inter-socket più ampio, o meno linee per averne di più libere).
- **12 canali DDR5 RDIMM per socket** → in dual socket, **24 canali**, con una larghezza di banda aggregata teorica di oltre **1 TB/s**. Questo è un numero a cui nessuna piattaforma desktop può avvicinarsi.
- **Enorme capacità RAM**: diversi TB per socket.
- **Frequenze più basse** rispetto a Threadripper (tipicamente 2.0–3.5 GHz base, boost fino a ~4.x GHz solo su SKU con pochi core), perché il budget termico è diviso tra molti più core e perché i server ottimizzano per l'efficienza, non per le prestazioni single-thread di picco.

**Il compromesso EPYC in una parola: si guadagna in parallelismo, larghezza di banda e connettività; si perde in prestazioni single-thread.** E questo è importante, perché molto codice Python di orchestrazione (il ciclo di training, il DataLoader di PyTorch prima che distribuisca ai worker, il codice di pre-elaborazione non vettorizzato) è **single-thread**. Una workstation EPYC con clock a 2.4 GHz può essere *più lenta* di un Ryzen 9 in tutte le parti "collanti" del codice.

### 3.2 Intel Xeon W e Xeon Scalable

Intel divide il mondo professionale in due:

**Xeon W** è la linea workstation, concettualmente equivalente a Threadripper PRO. Su socket **LGA4677** e chipset **W790**:

- **Xeon W-2400** (Sapphire Rapids, fino a 24 core): **4 canali** DDR5, **64 linee PCIe 5.0**.
- **Xeon W-3400** (fino a 56 core): **8 canali** DDR5, **112 linee PCIe 5.0**.
- **Xeon W-2500 / W-3500**: l'aggiornamento generazionale, con un numero di core leggermente superiore (fino a ~60 core sulla linea W-3500) e le stesse

caratteristiche della piattaforma. \*[dati volatili: controllare l'elenco SKU attuale]\*

**Xeon Scalable / Xeon 6** è la linea server, equivalente a EPYC:

- **\*\*Xeon 6 "Granite Rapids"\*** (P-core, alte prestazioni per core): serie 6900P fino a 128 core, **\*\*12 canali\*\*** DDR5/MRDIMM, ~96 linee PCIe 5.0; serie 6700P con 8 canali e ~88 linee.
- **\*\*Xeon 6 "Sierra Forest"\*** (E-core, ottimizzato per densità ed efficienza): conteggi di core molto elevati (fino a 288 E-core), ma **\*\*E-core senza AVX-512 e senza AMX\*\***, quindi meno adatti per l'inferenza CPU.

*[dati volatili: la roadmap di Intel è in rapida evoluzione]*

### **La contromossa di Intel: AMX**

C'è un asso nella manica di Intel che vale la pena conoscere, perché è specificamente rilevante per l'IA: **AMX (Advanced Matrix Extensions)**, introdotto con Sapphire Rapids. È un set di istruzioni che aggiunge **registri "tile" bidimensionali** e un'unità dedicata alla moltiplicazione di matrici alla CPU. In pratica, inserisce un piccolo core tensoriale all'interno di ogni core della CPU.

Il risultato è che l'inferenza CPU di modelli quantizzati (INT8, BF16) su Xeon con AMX può essere **da 3 a 8 volte più veloce** rispetto alla stessa CPU senza AMX, alla stessa frequenza e numero di core, quando il software lo supporta (oneDNN, OpenVINO, PyTorch con backend Intel). **Questo è l'argomento più forte a favore di Intel nel campo dell'IA su CPU**, e dovrebbe essere tenuto presente da coloro che fanno inferenza solo su CPU o ibrida.

### **3.3 Perché AMD domina oggi nel conteggio dei core e nelle linee**

È utile capire il *perché* strutturale, non solo osservare il fatto.

La ragione principale è **architetturale**, e si chiama **chiplet**. Dal 2017, AMD ha costruito le sue CPU server assemblando più piccoli die:

- **\*\*CCD\*\* (\*Core Complex Dies\*)**: piccoli die che contengono solo i core e la cache, prodotti sul nodo di produzione più avanzato disponibile (5 nm, poi 4 nm, poi 3 nm).
- Un **\*\*IOD\*\* (\*I/O Die\*)**: un die più grande che contiene i controller di memoria, i controller PCIe e l'infrastruttura di interconnessione, prodotto su un nodo più economico e maturo (dove i transistor di I/O non beneficiano comunque di un'estrema miniaturizzazione).



Il vantaggio è economico e statistico. La **resa di produzione** (la percentuale di die funzionanti su un wafer) diminuisce esponenzialmente con l'area del die, perché più è grande, più è probabile che un difetto casuale lo colpisca. Producendo **otto o dodici piccoli die** invece di **un unico die monolitico gigante**, AMD ottiene rese molto più elevate, può selezionare i die migliori e può scalare il numero di core semplicemente **aggiungendo CCD al package**.

Intel ha utilizzato die monolitici per anni, e quando ha voluto aumentare il numero di core, ha incontrato rese sempre peggiori e costi crescenti. Anche essa è passata a un approccio basato su tile (con Sapphire Rapids e successori), ma con un ritardo di diversi anni, esacerbato da note difficoltà nella transizione a nodi di produzione avanzati (la famosa stagnazione a 10 nm).

Lo stesso vale per le linee PCIe: la logica PCIe è nell'IOD, un die grande ed "economico", e AMD ha potuto permettersi di metterne molta lì. 128 linee native contro le ~96 di Intel non è una coincidenza: è una diretta conseguenza della scelta di packaging.

**Conclusione onesta:** AMD ha attualmente un vantaggio strutturale in core, linee e canali di memoria. Intel mantiene vantaggi in acceleratori integrati specifici (AMX), ecosistemi software ottimizzati (OpenVINO, oneAPI), alcune SKU a bassa latenza e talvolta nel prezzo delle piattaforme usate. *[Situazione volatile: il vantaggio competitivo tra i due può cambiare rapidamente.]*

### 3.4 Server o HEDT? La decisione per un ricercatore o un piccolo team

Ecco i criteri concreti, al di là del marketing.

#### **Scegli HEDT (Threadripper / Threadripper PRO) se:**

- Lavori sotto una scrivania, in un ufficio, e hai bisogno di **\*\*silenzio\*\*** (un server 2U con ventole da 15.000 rpm è insostenibile in un ambiente di lavoro).
- Desideri **\*\*alte frequenze\*\*** perché parte del carico di lavoro è single-threaded.
- Hai **\*\*1-4 GPU\*\***.
- Vuoi essere in grado di **\*\*assemblare tutto da solo\*\*** con componenti al dettaglio.
- Hai bisogno di certificazioni ISV per software professionali.

#### **Scegli server (EPYC / Xeon Scalable) se:**

- Hai bisogno di **\*\*più di 4 GPU\*\*** o dual-socket.

- Hai bisogno di **\*\*larghezza di banda di memoria estrema\*\*** (inferenza CPU su modelli enormi, HPC).
- Hai già un **\*\*rack\*\***, con alimentazione trifase, raffreddamento e rumore isolato.
- Hai bisogno di **\*\*RAM multi-terabyte\*\***.
- Vuoi **\*\*massimizzare il rapporto prezzo/prestazioni sul mercato dell'usato\*\***: i server datacenter dismessi (EPYC Rome/Milan, Xeon Scalable di prima e seconda generazione) possono essere trovati a frazioni del loro prezzo originale, e per coloro che hanno bisogno di linee e RAM più che di velocità di clock, possono essere ottimi affari. Questo è un percorso intrapreso da molti homelabber e piccoli laboratori. \*[Il mercato dei server usati è estremamente volatile nei prezzi.]\*

**Un'osservazione pratica che vale oro:** se hai bisogno di *molta* potenza *occasionalmente*, la risposta economicamente sensata è spesso **non comprare nulla** e noleggiare istanze cloud (o GPU on-demand da fornitori specializzati). Una workstation locale si giustifica quando l'utilizzo è **continuo** (mesi di training, uso quotidiano), quando i **dati non possono lasciare** l'organizzazione (privacy, GDPR, segreto industriale), o quando un rapido **ciclo iterativo** conta più della potenza di picco.

---

## 4. PCIe nelle Workstation: Approfondimento

### 4.1 Ripasso ed Estensione

Abbiamo già definito le lane e le generazioni. Aggiungiamo ora tre distinzioni che nel mondo consumer possono essere ignorate, ma nel mondo workstation sono decisive.

**Distinzione 1: slot fisico vs. slot elettrico.** Uno slot può essere **fisicamente** lungo x16 (cioè il connettore ha la lunghezza per ospitare una scheda x16) ma solo 4 o 8 lane sono cablate **elettricamente**. Questo è molto comune, e le schede madri lo indicano nella loro documentazione con notazioni come "PCIe 5.0 x16 (x8 mode)" o "x16 slot, x4 electrical". Una GPU inserita in uno slot fisico x16 ma elettrico x4 **funzionerà**, ma con un quarto della banda.

**Regola d'oro:** nel manuale della scheda madre, cerca **sempre** la "PCIe lane distribution table" o "block diagram". È l'unico documento che dice la verità. La descrizione commerciale sul sito web no.

**Distinzione 2: lane condivise.** Su molte schede madri, popolare un certo slot **disabilita o riduce** un altro slot o uno slot M.2. Il manuale contiene una tabella tipo "if PCIe\_2 slot is used, M.2\_3 slot is disabled." Sulle piattaforme workstation con 128 lane native, queste configurazioni condivise sono molto meno frequenti — ed è proprio uno dei benefici per cui si paga.

**Distinzione 3: negoziazione al ribasso.** PCIe negozia automaticamente sia la larghezza (numero di lane attive) che la velocità (generazione). Un segnale disturbato, un riser di bassa qualità, o un contatto sporco possono far sì che il link scenda a x8 invece di x16, o a Gen3 invece di Gen5, **senza alcun errore visibile**: il sistema funziona, solo più lentamente. Su Linux, questo si può controllare con ``lspci -vv`` cercando le righe ``LnkCap`` (capability) e ``LnkSta`` (current status); su NVIDIA, anche con ``nvidia-smi -q | grep -i pcie``. **Questo controllo dovrebbe essere sempre eseguito dopo ogni assemblaggio.**

#### 4.2 Perché 2-4 GPU hanno bisogno di vere lane elettriche x16

Qui dobbiamo essere precisi, perché c'è molta disinformazione che circola in entrambe le direzioni.

**Quando x16 NON è necessario.** Se il carico di lavoro è: una singola GPU, il dataset entra in VRAM o viene caricato una volta, e il training è puramente GPU-bound — allora la banda PCIe conta poco. Test noti su singola GPU mostrano differenze del 2-5% tra x8 e x16. In questo caso, spendere per una piattaforma workstation solo per avere x16 è irrazionale.

**Quando x16 è indispensabile.** Il quadro cambia completamente in tre scenari:

**Scenario A: addestramento distribuito multi-GPU.** Quando si utilizza il *data parallelism* (ogni GPU ha una copia del modello ed elabora un batch diverso), ad ogni passo di addestramento le GPU devono **sincronizzare i gradienti**.

L'operazione si chiama **all-reduce**: ogni GPU deve ricevere la somma dei gradienti da tutte le altre. Il volume di dati è pari alla dimensione del modello, **ad ogni singolo passo**. Per un modello da 1 miliardo di parametri in FP16, sono 2 GB per GPU per passo. Con 4 GPU e un passo ogni 100 ms, **decine di GB/s vengono continuamente spostati attraverso il bus PCIe**. A x8 Gen4 (15 GB/s) questo diventa **il collo di bottiglia dominante**: la GPU calcola in 60 ms e poi attende 150 ms che arrivino i gradienti. L'efficienza di scaling crolla: quattro GPU performano come due e mezzo.

**Scenario B: model parallelism / pipeline parallelism.** Quando il modello è troppo grande per una GPU e viene splittato tra più GPU, le **attivazioni** devono passare da una GPU all'altra ad ogni forward e backward pass. Il traffico è continuo e sensibile alla latenza. Qui, la banda PCIe è ancora più critica.

**Scenario C: offloading e streaming.** Tecniche come ZeRO-Offload o lo scaricamento di parte dei pesi nella RAM di sistema (usato quando la VRAM è insufficiente) trasferiscono continuamente pesi avanti e indietro via PCIe. La banda è tutto.

**Conclusione:** se hai **una** GPU, x8 va benissimo. Se ne hai **due o più e le usi insieme**, ogni lane conta.

#### 4.3 Switch PCIe (PLX / Broadcom): cosa sono e quando usarli

Uno **switch PCIe** è un chip che fa quello che fa uno switch di rete per Ethernet: prende un certo numero di lane in ingresso (*upstream*, verso la CPU) e le espande in un numero maggiore di lane in uscita (*downstream*, verso le periferiche), instradando dinamicamente i pacchetti.

I chip più noti sono quelli originariamente prodotti da **PLX Technology**, azienda poi acquisita da **Avago/Broadcom**. Per abitudine, quindi, si usa "PLX" per riferirsi a qualsiasi switch PCIe. La famiglia storica è **PEX 87xx/88xx** (Gen3/Gen4); le recenti generazioni Gen5 sono commercializzate da Broadcom con nomi come **Atlas 3 / PEX 89xxx**.

**Come funziona in pratica.** Immagina uno switch con 16 lane upstream verso la CPU e 32 lane downstream verso due GPU (x16 ciascuna). Le due GPU vedono ciascuna un link x16 e sono contente. Ma verso la CPU, c'è solo un x16 condiviso.

**Il vero, e spesso incompreso, beneficio:** lo switch **non crea banda dal nulla**. Se entrambe le GPU vogliono comunicare con la CPU simultaneamente a piena velocità, si contendono le 16 lane upstream. **Il beneficio è che le due GPU possono comunicare tra loro, attraverso lo switch, a piena velocità x16, senza mai disturbare la CPU.** Questa comunicazione locale **peer-to-peer** è esattamente ciò che serve nell'addestramento multi-GPU. Uno switch trasforma quattro GPU collegate a x4 ciascuna in un cluster dove le GPU si scambiano i gradienti a piena banda tra loro, usando l'uplink verso la CPU solo per caricare i dati.

**Quando uno switch ha senso:**

- Su schede madri consumer o entry-workstation, per far funzionare 4 GPU con un numero insufficiente di lane della CPU.
- Su schede madri server progettate per la densità di GPU (le classiche baseboard da 8 GPU).
- Su schede di espansione (backplane) che espandono uno slot x16 in più slot.

#### **Quando NON ha senso:**

- Se si dispone già di 128 lane native (Threadripper PRO, EPYC). Le **\*\*lane native sono sempre migliori\*\***: latenza inferiore, nessun punto di contesa, nessun costo, nessun consumo energetico aggiuntivo.
- Gli switch PCIe sono costosi (centinaia di dollari per chip), consumano 10-25 W e aggiungono latenza. È una tecnologia da usare per necessità, non per scelta.

#### **4.4 Biforcazione: dividere uno slot x16**

La **biforcazione** è la capacità della CPU e del BIOS di **dividere un singolo slot x16 in più link indipendenti**: tipicamente x8+x8, x8+x4+x4, o **x4+x4+x4+x4**.

È importante capire che la **biforcazione è passiva**. Non c'è un chip aggiuntivo: la CPU viene semplicemente istruita a trattare quelle 16 lane come quattro link separati da 4 lane. Il chip PCIe della CPU supporta nativamente questa configurazione; il BIOS espone l'opzione (solitamente nel menu "PCIe Bifurcation" o "PCIe Slot Configuration").

**L'applicazione principale nelle workstation AI: schede quad M.2.** Si tratta di schede di espansione PCIe x16 passive, senza alcun controller a bordo, che espongono quattro slot M.2. Ogni SSD NVMe utilizza 4 lane, e il totale è esattamente 16. Costano poche decine di euro (il PCB, i connettori e un dissipatore) e permettono di aggiungere **quattro SSD NVMe a piena velocità** utilizzando un singolo slot.

Esempi comuni: ASUS Hyper M.2 X16, Gigabyte AORUS Gen4 AIC, ASRock Hyper Quad M.2. Alcune schede madri per workstation includono già connettori dedicati (SlimSAS, MCIO) che espongono le lane in modo simile.

**Attenzione alla classica trappola:** se il BIOS **non supporta la biforcazione** su quello slot, una scheda quad M.2 passiva mostrerà **solo un SSD** (il primo), o nessuno. Questo non è un difetto della scheda: è la piattaforma che non può dividere le lane. Esistono anche schede quad M.2 **attive**, che contengono uno switch PCIe e funzionano ovunque — ma costano 5-10 volte tanto. **Prima di**

**acquistare una scheda quad M.2 passiva, controllate il manuale della scheda madre per assicurarvi che lo slot supporti la modalità x4x4x4x4.** Le piattaforme Threadripper/PRO e workstation quasi sempre la supportano; le piattaforme consumer spesso no, o solo su un singolo slot.

#### 4.5 P2P (peer-to-peer) su PCIe vs NVLink

Il **P2P** (peer-to-peer) è la capacità di due GPU di **scambiare dati direttamente**, senza instradare i dati attraverso la RAM di sistema. Senza P2P, una copia da GPU0 a GPU1 richiede: GPU0 → RAM di sistema → GPU1. Con P2P: GPU0 → GPU1, direttamente sul bus PCIe. I risparmi sono in larghezza di banda (una copia invece di due), latenza e utilizzo della CPU.

Questa capacità è la base delle librerie di comunicazione collettiva come **NCCL** (*NVIDIA Collective Communications Library*), che è ciò che PyTorch e ogni framework di training distribuito usano sotto il cofano per l'all-reduce dei gradienti.

**Il problema:** NVIDIA ha **disabilitato il P2P sulle GPU GeForce** a partire dalle generazioni recenti (dalla RTX 30 in poi, il supporto è stato progressivamente rimosso; sulle RTX 40 e 50, il P2P tramite driver ufficiali **non è disponibile**). Questa è una scelta di segmentazione commerciale, non tecnica: il silicio potrebbe farlo. La conseguenza è che su una workstation con quattro RTX 5090, NCCL è costretto a usare il percorso attraverso la RAM di sistema, con costi significativi in larghezza di banda e latenza.

*(Una curiosità ben nota nella comunità: esiste un driver modificato, sviluppato dal team tinygrad, che riabilita il P2P sulle RTX 4090. Funziona, ma non è supportato, è fragile rispetto agli aggiornamenti e non adatto a un ambiente di produzione.)*

**NVLink** è l'alternativa proprietaria di NVIDIA: un interconnettore **dedicato**, separato dal PCIe, con una larghezza di banda molto più elevata (nell'ordine di centinaia di GB/s per link, rispetto ai 63 GB/s di un x16 Gen5) e una latenza molto più bassa. Storicamente disponibile tramite un "bridge" fisico tra due schede su Quadro/RTX serie A, e tramite NVSwitch nelle configurazioni server (SXM).

**La situazione attuale, da ben comprendere [dato volatile]:** NVIDIA ha **rimosso il connettore NVLink dalle schede professionali in formato PCIe** a partire dalla generazione Ada Lovelace (le RTX 6000 Ada e successive non hanno il bridge). Oggi, il "vero" NVLink è riservato alle GPU in **formato SXM** (moduli

montati direttamente sulla baseboard in sistemi server come DGX/HGX) e alle piattaforme rack-scale.

**Conseguenza pratica**, ed è il messaggio che porta questa sezione nel capitolo CPU: **su una workstation con GPU in formato PCIe — che è ciò che la stragrande maggioranza di noi costruirà — la comunicazione inter-GPU passa attraverso il PCIe. Punto.** Non c'è NVLink a salvare una configurazione con corsie insufficienti. Ed è precisamente per questo che le corsie PCIe della CPU non sono un dettaglio della specifica: **sono l'interconnessione del cluster.** È la ragione tecnica ultima per cui esiste Threadripper PRO.

*(Approfondiremo NVLink, NVSwitch, i formati SXM e le topologie multi-GPU nel capitolo dedicato alle GPU.)*

---

## 5. Scelta della Scheda Madre della Workstation

La scheda madre, in questo segmento, non è un accessorio: è **il documento che definisce cosa la macchina sarà in grado di fare.** Ecco i criteri, in ordine di importanza.

### 5.1 Numero di Slot x16 Fisici E Elettrici

Già trattato, ma vale la pena ripeterlo perché è il criterio numero uno. Cercate nel manuale (non sul sito commerciale) il **diagramma a blocchi** e verificate quante corsie sono effettivamente cablate a ciascuno slot e in quale generazione. Una scheda con "5 slot PCIe x16" che in realtà ha due x16 elettrici, un x8 e due x4 è un prodotto diverso da uno con cinque veri slot x16.

### 5.2 Spaziatura degli Slot (il Criterio Più Sottovalutato)

Questo è, statisticamente, **l'errore più frequente in assoluto** per chi costruisce la sua prima workstation multi-GPU.

Le moderne GPU di fascia alta occupano **2, 2.5 o anche 3 slot di spessore** a causa dei dissipatori sovradimensionati. Una RTX 5090 custom può essere una scheda da 3.5 slot. Se la scheda madre ha slot x16 distanziati di **due slot**, e la GPU ne occupa **tre, la seconda GPU semplicemente non ci starà fisicamente.** Non è una questione di prestazioni: è una questione di geometria.

E anche quando ci stanno, ci sono due ulteriori problemi:



- **\*\*Soffocamento Termico\*\***: due GPU adiacenti con dissipatori a ventola aperta avranno l'aspirazione della seconda a un millimetro dal backplate della prima. Le temperature salgono di 15–25 °C, e le GPU vanno in *\*thermal throttling\** (riduzione automatica della frequenza per limitare la temperatura). Le prestazioni crollano, e il rumore esplode.
- **\*\*Peso e Flessione\*\***: una GPU moderna pesa 2 kg. Quattro GPU montate a sbalzo fletteranno la scheda madre e i PCB delle GPU stesse. Sono necessarie staffe di supporto.

**Come risolvere il problema:** 1. Scegliere schede madri progettate per più GPU: le schede WRX90 di riferimento hanno **7 slot con spaziatura calcolata** specificamente per ospitare 4 schede dual/triple-slot in slot alternati (1, 3, 5, 7). 2. Preferire GPU **blower-style** (a turbina, con aria espulsa fuori dal case) o in formato **2-slot** — questi sono i formati delle schede professionali (le serie RTX PRO/A sono progettate per essere impilate). 3. Utilizzare **riser PCIe** di qualità (certificati per la generazione corretta: un riser Gen3 su un link Gen5 causa un degrado silenzioso) per spostare le GPU in posizioni ventilate, con un **case da mining/open-frame** o un case workstation di grandi dimensioni.

**Regola pratica:** prima di acquistare, **misurare**. Prendere lo spessore della GPU (in millimetri, non "in slot") e la distanza tra gli slot sulla scheda madre. Uno slot PCIe standard ha un passo di **20.32 mm** (0.8 pollici).

### 5.3 Canali e Slot RDIMM

Verificare **quanti slot DIMM** ci sono e **come sono organizzati in canali**. Una scheda WRX90 con 8 slot DIMM su 8 canali offre un modulo per canale: massima frequenza, configurazione ideale. Alcune schede hanno più slot per canale (2 DIMM per canale, "2DPC"): consentono maggiore capacità ma spesso a frequenza ridotta.

**Punto critico che rovina molte build:** su piattaforme a 8 canali, **popolare solo 4 slot dimezza la larghezza di banda della memoria**. Se acquisti una WRX90 e inserisci 4 moduli da 32GB invece di 8 moduli da 16GB, hai la stessa capacità (128GB) ma **metà della larghezza di banda**. Hai pagato per 8 canali e ne stai usando solo 4. **Riempire sempre tutti i canali**. Questa singola regola è forse il consiglio più prezioso dell'intero capitolo, perché l'errore è invisibile: il sistema funziona, tutto sembra a posto, e semplicemente gira a metà velocità.



## 5.4 Rete: 10G Ethernet e oltre

Le schede madri per workstation di fascia alta integrano tipicamente **doppio 10 GbE** (10 gigabit al secondo). Perché è importante:

- **\*\*Dataset su NAS/storage di rete\*\***: Un dataset da 10 TB non entra su un SSD locale. Risiede su un server di storage. Con 1 GbE (~110 MB/s reali), il caricamento è impossibile. Con 10 GbE (~1.1 GB/s reali), diventa fattibile.
- **\*\*Addestramento distribuito tra macchine\*\***: Se hai due workstation e vuoi distribuire l'addestramento, la rete diventa l'interconnessione, ed è già molto lenta rispetto al PCIe. 10 GbE è il minimo; per lavori seri, sono necessari 25/100 GbE o **\*\*InfiniBand\*\*** (una tecnologia di rete a bassissima latenza dominante nell'HPC, che supporta **\*\*RDMA\*\*** — *\*Remote Direct Memory Access\** — cioè la capacità di scrivere direttamente nella memoria di un'altra macchina senza coinvolgere la CPU).

Se la scheda madre non ha 10 GbE integrato, ricorda che una NIC 10G occupa uno slot PCIe e 4 lane. Deve essere conteggiata nel budget delle lane.

## 5.5 IPMI / BMC: gestione remota

**BMC** sta per *Baseboard Management Controller*: è un **microcontrollore autonomo** saldato sulla scheda madre (il più comune è l'ASPEED AST2500/AST2600), con la sua CPU, la sua RAM, il suo firmware e **la sua porta Ethernet**. Funziona **anche quando la macchina è spenta**, purché l'alimentatore sia collegato alla rete elettrica.

**IPMI** (*Intelligent Platform Management Interface*) è il protocollo standard per la comunicazione.

Cosa ti permette di fare, da un browser, da qualsiasi parte del mondo:

- **\*\*Accendere, spegnere e riavviare\*\*** la macchina.
- Visualizzare il **\*\*video della console\*\*** come se fossi seduto davanti al monitor — **\*\*inclusi il BIOS e il POST\*\*** (*\*Power-On Self-Test\**, la sequenza diagnostica all'avvio). Questa funzione si chiama **\*\*KVM over IP\*\*** (*\*Keyboard, Video, Mouse over IP\**).
- **\*\*Montare un'immagine ISO remota\*\*** come se fosse una chiavetta USB inserita nella macchina: puoi quindi **\*\*reinstallare il sistema operativo da remoto\*\***.
- Leggere **\*\*tutti i sensori\*\***: temperature, voltaggi, velocità delle ventole, consumo energetico.

- Consultare i **\*\*log hardware\*\*** (SEL, \*System Event Log\*), inclusi gli **\*\*eventi ECC corretti\*\***.

**Perché è cruciale in una workstation AI:** perché una workstation AI è una macchina che lasci accesa per giorni, spesso in un'altra stanza, in cantina o in un piccolo rack. Quando il training si blocca alle tre del mattino e la macchina non risponde via SSH, senza BMC devi alzarci, andare fisicamente lì e collegare un monitor. Con BMC, apri il browser e vedi la schermata di kernel panic. **La prima volta che ti salva, il BMC si è ripagato.**

Il BMC è quasi sempre presente sulle schede **server** (Supermicro, ASRock Rack, Gigabyte, Tyan) e su alcune workstation di fascia alta (alcune WRX90). Non è presente sulle schede consumer o sulla maggior parte delle schede TRX50 "desktop".

## 5.6 Marche e Modelli di Riferimento

*[Modelli e disponibilità volatili]*

| Marca              | Posizionamento                         | Modelli Tipici                                                      | Note                                                                                                                          |
|--------------------|----------------------------------------|---------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------|
| <b>ASUS Pro WS</b> | Workstation<br>"desktop-friendly"      | Pro WS WRX90E-SAGE SE, Pro WS TRX50-SAGE WIFI, Pro WS W790E-SAGE SE | Punto di riferimento del settore per workstation multi-GPU. La WRX90E-SAGE SE con 7 slot x16 completi è di fatto lo standard. |
| <b>Supermicro</b>  | Server e workstation di livello server | M13SWA-TF (sTR5), serie H13/X13                                     | Qualità e affidabilità server, BMC/IPMI di serie, ma BIOS spartano e supporto orientato alle aziende, non ai singoli.         |
| <b>ASRock Rack</b> | Server, ottimo rapporto qualità-prezzo | WRX90D8-2T, TRX50D8-2L2T                                            | Form factor server (SSI-EEB o proprietario), IPMI, spesso più convenienti. Attenzione al                                      |

|                          |                     |                                |                                                         |
|--------------------------|---------------------|--------------------------------|---------------------------------------------------------|
|                          |                     |                                | form factor del case.                                   |
| <b>Gigabyte (Server)</b> | Server e barebone   | MZ73/MZ33 (EPYC), TRX50 AERO D | Buona gamma, dai barebone completi alle singole schede. |
| <b>Tyan</b>              | Server, nicchia HPC | Vari                           | Meno comune nella vendita al dettaglio in Europa.       |

**Consiglio pratico:** Se stai costruendo una workstation da tenere in ufficio e vuoi un'esperienza "desktop" (BIOS usabile, ventole silenziose, form factor ATX/E-ATX standard, supporto RMA consumer), scegli **ASUS Pro WS**. Se stai costruendo qualcosa che vivrà in un rack o in una sala tecnica e vuoi BMC e affidabilità 24/7, scegli **Supermicro** o **ASRock Rack**, ma preparati a un'esperienza più "industriale".

### 5.7 Alimentazione: EPS Multipli e PSU Server-Grade

Un aspetto che i costruttori alle prime armi sottovalutano sistematicamente.

Il **connettore EPS12V** (spesso chiamato semplicemente "EPS" o "CPU power") è il connettore a **8 pin** che fornisce 12 volt alla sezione **VRM** della CPU. **VRM** sta per *Voltage Regulator Module*: è il circuito sulla scheda madre che converte i 12 V dall'alimentatore nella tensione molto più bassa (circa 1.0–1.3 V) e nella corrente molto alta (centinaia di ampere) che la CPU richiede. Il VRM è composto da **fasi** (stadi di conversione paralleli): più fasi significano che può essere erogata più corrente con meno stress termico su ciascuna.

Una CPU Threadripper con un TDP di 350 W, durante i transitori, può assorbire ben oltre 400 W. Con un'efficienza VRM di circa il 90%, l'alimentatore deve fornire più di 450 W **solo sul rail della CPU**. Un singolo connettore EPS a 8 pin è specificato per circa **300 W**. **Questo non è sufficiente**. Questo è il motivo per cui le schede madri sTR5 hanno **due (o anche tre) connettori EPS a 8 pin**, e **devono essere tutti collegati**. Collegarne solo uno, nel migliore dei casi, comporterà l'accensione con avvisi e prestazioni limitate; nel peggiore dei casi, instabilità sotto carico o surriscaldamento dei connettori.

Il budget energetico complessivo di una workstation multi-GPU:

| Componente                                      | Consumo Indicativo                 |
|-------------------------------------------------|------------------------------------|
| CPU Threadripper PRO (350 W TDP)                | 400–450 W di picco                 |
| GPU di fascia alta (es. 450–600 W TDP ciascuna) | $4 \times 500 = \mathbf{2.000\ W}$ |
| RAM (8 moduli RDIMM)                            | ~50 W                              |
| NVMe (4)                                        | ~40 W                              |
| Ventole, pompe, scheda madre                    | ~100 W                             |
| <b>Picco Totale</b>                             | <b>~2.600 W</b>                    |

Con un margine del 20% per i transitori (le GPU moderne hanno picchi istantanei — *transient spikes* — che possono superare il consumo nominale del 50-100% per pochi millisecondi, e un alimentatore che non li assorbe farà scattare la protezione OCP/OPP e spegnerà la macchina), si raggiungono **3.000 W o più**.

Qui incontriamo due ostacoli:

**Muro 1: La presa elettrica.** In Italia, una presa domestica standard su un circuito da 16 A, 230 V fornisce teoricamente ~3.680 W, ma i circuiti domestici e i contratti di fornitura standard (3 kW o 4.5 kW) non possono gestire una macchina da 3 kW **più tutto il resto della casa**. È necessario un circuito dedicato, e spesso un aumento della potenza contrattuale. Nei paesi a 110 V (USA), il problema è ancora più grave: una presa da 15 A, 120 V fornisce 1.800 W teorici, ~1.440 W in uso continuo – **motivo per cui le workstation a 4 GPU negli USA richiedono quasi sempre due circuiti separati o una presa da 240 V**.

**Muro 2: L'alimentatore.** Gli alimentatori ATX consumer tipicamente raggiungono 1.600–2.000 W [*volatile*]. Per andare oltre, le opzioni sono:

- **\*\*Doppio alimentatore ATX\*\*** sincronizzato con un "add2psu" (un adattatore che accende il secondo PSU quando si accende il primo, ponticellando il segnale PS\_ON). Funziona, è comune negli ambienti di mining e homelab, ma deve essere fatto con attenzione: **\*\*non alimentare mai la stessa scheda da due PSU diversi\*\*** (ad esempio: slot PCIe da PSU 1 e connettori aggiuntivi GPU da PSU 2), perché i ground possono avere potenziali diversi e danneggiare l'hardware.
- **\*\*Alimentatori di livello server\*\*** (Delta, Murata, alimentatori HP/Dell "Common Slot") con breakout board, spesso con ingresso a 240 V, che possono raggiungere 2.400–3.000 W in un singolo modulo. Questa è la strada

professionale, ma richiede attenzione al rumore (le ventole di questi alimentatori sono progettate per un rack, non per un ufficio).

- **\*\*Ridurre il consumo via software\*\***: con `nvidia-smi -pl <watt>` è possibile impostare un limite di potenza per GPU. Ridurre una GPU da 500 W a 350 W (−30%) costa tipicamente solo il 5–10% in termini di prestazioni, perché la curva potenza/prestazioni è altamente non lineare nella fascia alta. **\*\*Su una workstation a 4 GPU, questa singola riga di comando può ridurre il consumo da 2.000 a 1.400 W praticamente a costo zero.\*\*** Questa è una tecnica standard nei laboratori seri, non un compromesso da poveri.

## 5.8 Raffreddamento del socket sTR5

Una nota che merita un suo spazio, perché è un errore da principiante con conseguenze immediate.

L'IHS di una CPU sTR5 è **molto più grande** di quello di una CPU AM5. Un dissipatore consumer, anche il migliore, ha una base progettata per coprire circa 40×40 mm. Su sTR5, lascerebbe gran parte della superficie scoperta, e – peggio ancora – con Threadripper, i die (i CCD) sono **distribuiti su tutta l'area del package**, non concentrati al centro. Un dissipatore che copre solo il centro lascia i CCD periferici a "cuocere".

**Sono necessarie soluzioni specifiche per sTR5:**

- **\*\*Raffreddamento ad aria\*\***: Noctua NH-U14S TR5-SP6 (e varianti), IceGiant ProSiphon. Si tratta di dissipatori con basi enormi e un gran numero di heatpipe distribuite.
- **\*\*Raffreddamento a liquido AIO\*\*** (\*All-In-One\*, il sistema chiuso pompa+radiatore): SilverStone XE360-TR5, Arctic Liquid Freezer per TR5 \*[disponibilità volatile]\*. **\*\*Cruciale\*\***: il \*cold plate\* (la piastra fredda a contatto con la CPU) deve essere **\*\*full-coverage size\*\*** per sTR5. Un AIO con un cold plate consumer, anche montato con adattatori, **\*\*non funzionerà\*\***.
- **\*\*Custom loop\*\***: con un waterblock dedicato sTR5.

E, lo ripeto perché è importante: il montaggio richiede il **cacciavite dinamometrico** fornito con la CPU e il **serraggio nell'ordine numerato** stampato sul socket. Non è una formalità.

---

## 6. Come dimensionare la CPU per il carico di lavoro AI

Arriviamo alla domanda pratica: **quale CPU devo comprare?** La risposta dipende da *cosa* fa la macchina.

### 6.1 Training GPU-bound: la CPU serve per il Data Loading

Nel tipico training di computer vision o di modelli con dataset ampi, il ciclo è:

1. Un **worker** (un processo separato, gestito in PyTorch da ``DataLoader`` con ``num_workers``) legge un file dal disco. 2. Lo **decodifica** (un JPEG va decompresso: è un'operazione CPU-intensive, e per un'immagine ad alta risoluzione può richiedere millisecondi). 3. Applica le **trasformazioni** (resize, crop, flip, color jitter, normalization): altro lavoro per la CPU. 4. Impacchetta il risultato in un tensore e lo copia in **pinned memory** (memoria non paginabile, "bloccata", da cui il DMA della GPU può leggere direttamente). 5. Il tensore viene trasferito alla GPU via PCIe.

Se i worker non tengono il passo, la GPU aspetta. Questo è **il bottleneck** più comune nelle workstation sbilanciate ed è facilmente diagnosticabile: ``nvidia-smi dmon`` che mostra l'utilizzo della GPU fluttuare tra 30% e 100% invece di rimanere piatto al 95% è il sintomo classico.

**La regola del pollice**, condivisa nella comunità e consistente con le configurazioni dei sistemi di riferimento (i sistemi NVIDIA DGX storicamente hanno circa 8 core fisici per GPU):

***4–8 core fisici per GPU**, a seconda dell'intensità della pipeline di preprocessing.*

- **\*\*Pipeline leggera\*\*** (dati già pre-processati, tensori binari, formato ``numpy`` o Arrow/WebDataset, nessuna decodifica): bastano **\*\*2–4 core per GPU\*\***.
- **\*\*Pipeline media\*\*** (JPEG standard, classiche augmentations): **\*\*4–6 core per GPU\*\***.
- **\*\*Pipeline pesante\*\*** (immagini ad altissima risoluzione, video, augmentations complesse, decodifica audio): **\*\*8+ core per GPU\*\***, oppure — soluzione migliore — **\*\*spostare il preprocessing sulla GPU\*\*** con librerie come NVIDIA DALI (che esegue la decodifica JPEG in hardware, sui decoder NVDEC/nvJPEG della GPU stessa) o con la decodifica video accelerata.

**Corollario importante:** se il tuo problema è il caricamento dei dati, la risposta migliore spesso non è comprare più core, ma **pre-elaborare il dataset una volta**

e salvarlo in un formato pronto all'uso (tensori, TFRecord, shard WebDataset). È gratuito e sposta il collo di bottiglia sul disco, dove un NVMe lo gestisce senza sforzo.

## 6.2 Quando i Core Contano Davvero

Ci sono carichi di lavoro in cui la CPU è il calcolo, non solo il supporto:

**Inferenza CPU.** Come discusso, questa è dominata dalla larghezza di banda della memoria durante la fase di generazione. Ma nella fase di **prefill** (elaborazione del prompt iniziale, che è una grande moltiplicazione di matrici), i core contano molto, e le istruzioni vettoriali (**AVX-512**, **AMX** su Intel) fanno un'enorme differenza. Una CPU con AMX può eseguire il prefill in una frazione del tempo. **Se l'inferenza CPU è centrale per il tuo flusso di lavoro, considera seriamente Intel Xeon con AMX o piattaforme AMD con molti canali di memoria.**

**Pre-elaborazione Classica e Feature Engineering.** Pipeline

Pandas/Polars/DuckDB su dataset di decine o centinaia di GB. Qui, i core scalano linearmente (se il codice è parallelizzato), e la larghezza di banda della memoria conta molto. Questo è il caso d'uso in cui un Threadripper a 32 o 64 core brilla davvero.

**Tokenizzazione.** Tokenizzare un corpus di centinaia di GB di testo per addestrare un modello linguistico è un'operazione **massivamente parallela e CPU-bound**. Con la libreria `tokenizers` di Hugging Face (scritta in Rust, che rilascia il GIL), 64 core possono fare in un'ora ciò che 8 core fanno in otto ore.

**Compilazione.** Se lavori su codice CUDA, kernel Triton, compilando PyTorch da sorgente, o compilando modelli con TensorRT: `make -j64` su un Threadripper è una rivelazione. La compilazione è forse il carico di lavoro che scala meglio con i core.

**Simulazione e elaborazione classica.** CFD, calcolo scientifico, rendering 3D per generare dataset sintetici, ottimizzazione combinatoria: tutti CPU-bound.

## 6.3 Configurazioni Tipiche per Fascia di Budget

Ecco il nocciolo operativo. *[Prezzi indicativi, volatili, riferiti al mercato europeo. Verificare sempre.]*

**Livello ENTRY — Workstation Single-GPU (~€2.500–€5.000)**

**Il messaggio più importante: qui il consumatore VINCE.**

| Componente    | Scelta                                                                                           |
|---------------|--------------------------------------------------------------------------------------------------|
| CPU           | AMD Ryzen 9 9950X (16c) o Intel Core Ultra 9 285K                                                |
| Scheda Madre  | X870E / Z890 di fascia alta                                                                      |
| RAM           | 64–128 GB DDR5 (2 moduli per evitare degrado di frequenza; 4 moduli se è necessaria la capacità) |
| GPU           | 1 × RTX 5090 (32 GB) o RTX PRO 4500/5000                                                         |
| Archiviazione | 2 × NVMe Gen4/Gen5 (1 TB sistema + 2–4 TB dataset)                                               |
| PSU           | 1.000–1.200 W                                                                                    |
| Note          | No ECC certificato. Se l'ECC è necessario, l'unica alternativa è aggiornare la piattaforma.      |

**Per chi è:** chi fa fine-tuning con LoRA/QLoRA, inferenza locale, prototipazione, computer vision su dataset medi, corsi e ricerca individuale. **Questo copre il 70–80% dei casi reali.** Non aggiornare la piattaforma se non hai un motivo.

#### *Livello MID — Workstation 2 GPU (~€7.000–€12.000)*

| Componente     | Scelta                                                        |
|----------------|---------------------------------------------------------------|
| CPU            | <b>AMD Threadripper 7960X / 9960X</b> (24 core)               |
| Scheda Madre   | TRX50 (ASUS Pro WS TRX50-SAGE WIFI, ASRock TRX50 WS)          |
| RAM            | 128–256 GB DDR5 RDIMM ECC, <b>4 moduli su 4 canali</b>        |
| GPU            | 2 × RTX 5090 o 2 × RTX PRO 6000 (a <b>full x16 PCIe 5.0</b> ) |
| Archiviazione  | 2–4 × NVMe Gen5                                               |
| PSU            | 1.600 W+ (o doppia PSU)                                       |
| Raffreddamento | AIO 360 mm specifico sTR5                                     |

**A chi è rivolto:** ricercatori seri, piccoli team, coloro che necessitano di ECC e due GPU che comunicano veramente. **24 core sono più che sufficienti:** 12 per GPU, ben al di sopra della regola pratica.

#### *Livello HIGH-END — Workstation con 4+ GPU (~€20.000–€50.000)*

| Componente | Scelta |
|------------|--------|
|------------|--------|



|               |                                                                                                                              |
|---------------|------------------------------------------------------------------------------------------------------------------------------|
| CPU           | <b>AMD Threadripper PRO 7955WX / 7965WX / 9955WX (16–24 core) — o 7975WX/7995WX se il carico di lavoro è anche CPU-bound</b> |
| Scheda madre  | <b>WRX90</b> (ASUS Pro WS WRX90E-SAGE SE, ASRock Rack WRX90D8-2T)                                                            |
| RAM           | 256 GB–1 TB DDR5 RDIMM ECC, <b>8 moduli su 8 canali — riempire tutti i canali!</b>                                           |
| GPU           | 4 × RTX PRO 6000 Blackwell (96 GB ciascuna) o 4 × RTX 5090                                                                   |
| Archiviazione | 4+ × NVMe Gen5 (uno per il sistema, un array per i dataset)                                                                  |
| Rete          | 10/25 GbE integrata o NIC dedicata                                                                                           |
| PSU           | 2 × 1.600 W, o PSU server-grade da 3.000 W su circuito dedicato                                                              |
| Case          | Chassis workstation grande o open-frame                                                                                      |
| Note          | <b>Verificare la spaziatura degli slot rispetto allo spessore delle GPU scelte.</b>                                          |

**Attenzione al punto centrale:** nel segmento high-end, **la CPU PRO si acquista per le sue 128 lane e 8 canali, non per i suoi core**. Un 7955WX da 16 core costa una frazione del 7995WX e fornisce **le stesse 128 lane e 8 canali**. Sedici core per quattro GPU = 4 core per GPU: al limite inferiore della regola pratica, ma sufficiente con una pipeline ben ottimizzata (dataset pre-processato, DALI). Se il pre-processing è pesante, passare al **7965WX (24c)** o **7975WX (32c)**. Il **7995WX (96c)** ha senso solo **se il carico di lavoro è genuinamente CPU-intensive** (rendering, simulazione, compilazione massiva) — altrimenti, sono ~€9.500–10.000+ di silicio inattivo.

#### **Livello EXTREME — Server (€50.000+)**

Qui, passiamo dalle workstation ai server: **EPYC 9004/9005** o **Xeon 6**, dual socket, 8 GPU sulla scheda madre, rack, alimentazione trifase, raffreddamento a liquido diretto. Questa è una categoria diversa, con fornitori diversi (Supermicro, Dell, HPE, Lenovo, Gigabyte) e logiche di acquisto diverse (si compra un sistema, non lo si assembla). Merita un capitolo a sé.

## 6.4 La regola di dimensionamento in tre righe

Se dovessi condensare tutta la sezione 6:

1. **Contare le GPU.** 1 → consumer. 2 → Threadripper. 3+ → Threadripper PRO. 8+ → server. 2. **Contare le lane necessarie.**  $\text{GPU} \times 16 + \text{NVMe} \times 4 + \text{NIC}$ . Se il totale supera le lane della CPU, aggiornare la piattaforma. 3. **Contare i core.** 4–8 per GPU. Se il risultato è inferiore ai core della CPU di cui hai bisogno per le lane, **non pagare per core extra**: prendi la SKU più economica per quella piattaforma.

---

## 7. Errori comuni

Li raccogliamo qui, in ordine di frequenza e gravità, perché ognuno costa denaro reale.

### Errore 1 — Acquistare Threadripper PRO per una singola GPU

**L'errore.** "Voglio una workstation AI seria, quindi prenderò un Threadripper PRO." Poi viene installata una sola GPU.

**Perché è un errore.** La piattaforma PRO costa €3.000–€5.000 in più (CPU + scheda madre + RAM RDIMM) e fornisce 128 lane, di cui ne userai 20. Inoltre, le frequenze single-thread di un Threadripper sono **inferiori** a quelle di un Ryzen 9 della stessa generazione, e il tuo codice Python di orchestrazione — che è single-thread — girerà **più lentamente**. Hai speso di più per andare più lento nella parte che usi ogni giorno.

**Cosa fare invece.** Prendi un Ryzen 9 9950X o un Core Ultra 9, investi la differenza in **una GPU migliore** o **più RAM**. Una singola RTX PRO 6000 con 96 GB di VRAM ti permette di addestrare modelli che quattro RTX 5090 da 32 GB non possono contenere senza complesse tecniche di partizionamento.

### Errore 2 — Ignorare la spaziatura degli slot

**L'errore.** Acquistare quattro GPU custom a triplo slot e una scheda madre con slot distanziati di due.

**Perché è un errore.** Le GPU **non ci staranno**. Oppure ci staranno ma si soffocheranno termicamente a vicenda e andranno in throttling. Il costo è: restituire le GPU (se possibile), o acquistare riser e un case diverso, o vivere con una riduzione delle prestazioni del 20-30%.

**Cosa fare invece. Misura in millimetri prima di acquistare.** Controlla il layout degli slot nel manuale della scheda madre. Preferisci GPU **blower** o professionali a 2 slot per configurazioni dense. Il passo standard di uno slot PCIe è di 20,32 mm.

### Errore 3 — RAM sbagliata

Questo errore ha tre varianti, tutte comuni.

**Variante A: UDIMM su una piattaforma RDIMM.** Acquistare un bel kit DDR5 da gaming solo per scoprire che la scheda TRX50/WRX90 **non fa nemmeno il POST**. Threadripper (anche non-PRO), Threadripper PRO, EPYC e Xeon W **richiedono ECC RDIMM**. Non è un'opzione, è un requisito.

**Variante B: Non riempire tutti i canali.** Acquistare 4 moduli da 64 GB (256 GB totali) per una WRX90 a 8 canali. Funziona, hai la capacità che volevi — **e metà della larghezza di banda della memoria**. Hai pagato per una piattaforma a 8 canali e ne stai usando solo 4. **Acquista sempre un numero di moduli pari al numero di canali** (o un multiplo).

**Variante C: Niente ECC dove è necessario.** Addestrare per tre giorni su una macchina senza ECC e non capire mai perché la loss occasionalmente va a NaN.

### Errore 4 — Sottovalutare l'alimentazione

**L'errore.** Collegare un solo connettore EPS su una scheda che ne ha due. Acquistare un alimentatore da 1.000 W per una macchina che consuma 2.000 W. Ignorare i picchi transitori della GPU. Collegare tutto a una presa domestica con un contratto da 3 kW.

**Perché è un errore.** I sintomi sono i peggiori possibili: **spegnimenti casuali sotto carico**, che si verificano dopo ore di addestramento, senza log, senza un pattern riproducibile. Si passano settimane a incolpare il software, i driver, il kernel. È l'alimentatore che va in protezione.

**Cosa fare invece.** Bilancia il budget di potenza con un margine del 25-30%. Collega **tutti** i connettori EPS. Considera seriamente il **power limiting** delle GPU (`nvidia-smi -pl`): il rapporto costo/beneficio è imbattibile. Controlla l'impianto elettrico della stanza.

### Errore 5 — Sottovalutare il raffreddamento sTR5

**L'errore.** Usare un dissipatore AM5 con un adattatore, o un AIO con una piastra fredda consumer.

**Perché è un errore.** Il package sTR5 è enorme e i CCD sono distribuiti. Una piccola piastra fredda raffredda il centro e lascia i die periferici a temperature di throttling. Risultato: una CPU da 5.000 € che funziona al 60% della sua frequenza.

**Cosa fare invece.** Dissipatore **specifico per sTR5**, con una base a copertura totale. Stringere con un **cacciavite dinamometrico**, nell'**ordine numerato**.

#### **Errore 6 — Fidarsi della descrizione commerciale degli slot**

**L'errore.** Acquistare una scheda madre perché "ha 4 slot PCIe x16" e scoprire che due sono x4 elettrici e collegati al chipset.

**Cosa fare invece.** Scarica il **manuale PDF** e cerca il **diagramma a blocchi** e la **tabella di distribuzione delle linee PCIe**. Se il produttore non li pubblica, è un campanello d'allarme.

#### **Errore 7 — Sopravvalutare le esigenze di core, sottovalutare le esigenze di RAM**

**L'errore.** Spesa per un 96-core e installazione di 128 GB di RAM.

**Perché è un errore.** I 96 core rimarranno al 10% durante l'addestramento. I 128 GB si esauriranno rapidamente, perché la regola generale è **RAM di sistema  $\geq 1,5-2 \times$  VRAM totale** (per contenere il dataset in cache, i buffer dei worker, la memoria bloccata e qualsiasi offloading). Con 4 GPU da 48 GB (192 GB VRAM), 128 GB di RAM sono **insufficienti**: sono necessari almeno 384 GB.

**Cosa fare invece.** SKU della CPU più economica della piattaforma giusta + più RAM.

#### **Errore 8 — Acquistare hardware quando era necessario il cloud**

**L'errore.** Spesa di 30.000 € per una workstation che verrà utilizzata a pieno carico due settimane all'anno.

**Cosa fare invece.** Effettuare una valutazione onesta delle ore/GPU necessarie all'anno e confrontarla con il costo delle istanze cloud o dei fornitori di GPU on-demand. Una workstation locale è giustificata per **uso continuo, dati sensibili che non possono lasciare la sede, o rapida iterazione quotidiana**. Non per prestigio.

---

## Riepilogo Operativo: Lista di Controllo per la Decisione della CPU della Workstation AI

Da utilizzare **in quest'ordine**. Ogni passaggio dipende dal precedente.

### FASE 1 — Definire il Carico di Lavoro (prima di guardare un singolo prodotto)

- ☐ **Quante GPU** installerò, oggi e realisticamente entro 2 anni? (Questa è la domanda determinante.)
- ☐ Il carico di lavoro è **GPU-bound** (addestramento/inferenza su GPU) o c'è una componente significativa **CPU-bound** (pre-elaborazione pesante, tokenizzazione, compilazione, simulazione, inferenza CPU)?
- ☐ Le GPU dovranno **comunicare tra loro** (addestramento distribuito) o lavoreranno indipendentemente (es. inferenza parallela su richieste diverse)? Se comunicano, le corsie sono critiche; se no, molto meno.
- ☐ Quanta **VRAM totale** avrò? → La RAM di sistema dovrebbe essere **1,5–2 volte** tale quantità.
- ☐ Il **dataset** è su disco locale o sulla rete? → Se sulla rete, è necessaria una 10 GbE o superiore.
- ☐ Ho davvero bisogno di hardware locale, o il **cloud** è più economico per il mio profilo di utilizzo?

### FASE 2 — Calcolare le Corsie PCIe Necessarie

- ☐  $\text{GPU} \times 16 = \text{_____ corsie}$
- ☐  $\text{NVMe} \times 4 = \text{_____ corsie}$
- ☐ NIC (4 per 10G, 8–16 per 25/100G) = \_\_\_\_\_ corsie
- ☐ Altre schede (HBA, acquisizione, acceleratori) = \_\_\_\_\_ corsie
- ☐ **Corsie TOTALI necessarie = \_\_\_\_\_**

### FASE 3 — Scegliere la Piattaforma in Base al Totale

| Corsie Necessarie | GPU | Piattaforma                                                          |
|-------------------|-----|----------------------------------------------------------------------|
| $\leq 24$         | 1   | <b>Consumer</b> (Ryzen 9 / Core Ultra) — ed è perfettamente adeguata |
| 25–48             | 2   | <b>Threadripper non-PRO su TRX50</b>                                 |
| 49–128            | 3–7 | <b>Threadripper PRO su WRX90</b>                                     |
| $> 128$           | 8+  | <b>EPYC / Xeon Scalable, server</b>                                  |

- [ ] È necessario **ECC certificato**? → Se sì, Threadripper minimo (RDIMM ECC obbligatorio).
- [ ] È necessaria **più di 256 GB di RAM**? → Se sì, Threadripper minimo.
- [ ] È necessaria la **massima larghezza di banda della memoria** (inferenza CPU su LLM di grandi dimensioni)? → 8 canali (WRX90) o 12 canali (EPYC).
- [ ] È necessaria la **gestione remota**? → Scheda madre con BMC/IPMI.

#### FASE 4 — Scegliere la SKU della CPU all'interno della Piattaforma

- [ ] Calcolare i core necessari: **4–8 core fisici per GPU**.
- [ ] Aggiungere core se il carico di lavoro ha una componente reale legata alla CPU (tokenizzazione, compilazione, simulazione, pre-elaborazione pesante non trasferibile alla GPU).
- [ ] **Se il risultato è inferiore ai core della SKU più economica su quella piattaforma, prendere la SKU più economica.** Non pagare per core che rimarranno inattivi. (Esempio: 4 GPU + pipeline leggera → **7955WX/9955WX** con 16 core su WRX90, non il 7995WX.)
- [ ] Controllare il **suffisso**: **WX = PRO** (8 canali, 128 linee). **X senza W = non-PRO** (4 canali, 48 linee). **Non confonderli.**
- [ ] Se l'inferenza della CPU è centrale → considerare **Intel Xeon con AMX**.

#### FASE 5 — Scegliere la scheda madre

- [ ] Scaricare il **manual PDF** e trovare il **diagramma a blocchi** / **tabella di distribuzione delle linee PCIe**. Non fidarsi della pagina del prodotto.
- [ ] Contare gli slot **ELETTRICI x16** (non solo fisici) e la loro generazione PCIe.
- [ ] **Misurare la spaziatura degli slot** (passo standard: 20.32 mm per slot) e confrontarla con lo **spessore in mm** delle GPU che si acquisteranno.
- [ ] Verificare il numero di **slot DIMM** e la loro organizzazione dei canali. Confermare che si acquisterà **un modulo per canale**.
- [ ] Verificare il supporto alla **biforcazione** (x4x4x4x4) se si prevede di utilizzare schede M.2 quad passive.
- [ ] Verificare la presenza di **10 GbE** integrato (o tenere conto delle linee per una NIC).
- [ ] Verificare la presenza di **BMC/IPMI** se la macchina non sarà a portata di mano.
- [ ] Contare i connettori **EPS 8-pin** richiesti e verificare che l'alimentatore li abbia tutti.

- [ ] Verificare il **fattore di forma** (E-ATX, SSI-EEB, proprietario) e la compatibilità con il case scelto.

### FASE 6 — Memoria

- [ ] Tipo: **RDIMM ECC** su tutte le piattaforme Threadripper/PRO/EPYC/Xeon W. Nessuna eccezione.
- [ ] Numero di moduli = **numero di canali** (4 su TRX50, 8 su WRX90, 12 su EPYC). **Non lasciare canali vuoti.**
- [ ] Capacità totale  $\geq 1.5-2 \times \text{VRAM totale}$ .
- [ ] Controllare la **QVL** (Qualified Vendor List) della scheda madre prima di acquistare i moduli.

### FASE 7 — Alimentazione e raffreddamento

- [ ] Budget di alimentazione: CPU + (GPU  $\times$  numero) + RAM + storage + ventole, **+25–30% di margine per i transitori.**
- [ ] Verificare che l'**impianto elettrico della stanza** possa gestirlo (in Italia: contratto e circuito dedicati per macchine sopra i ~2 kW).
- [ ] Considerare il **power limiting** per le GPU (`nvidia-smi -pl`): **–30% di consumo per –5/10% di prestazioni.**
- [ ] Collegare **tutti** i connettori EPS sulla scheda madre.
- [ ] **Dissipatore specifico per sTR5** con base a copertura totale. **Non usare mai adattatori AM5/LGA1700.**
- [ ] Montare la CPU con il **cacciavite dinamometrico in dotazione**, nell'**ordine numerato** stampato sul socket.

### FASE 8 — Verifica post-assemblaggio (non saltarla mai)

- [ ] `lspci -vv` → confrontare **LnkCap** (capacità) con **LnkSta** (stato attuale) per ogni GPU e NVMe. Se un link è negoziato a x8 invece di x16, o a Gen3 invece di Gen5, **c'è un problema hardware da risolvere subito**, non tra tre mesi.
- [ ] `nvidia-smi -q | grep -i pcie` → verificare larghezza e generazione del link GPU.
- [ ] Verificare in BIOS/OS che l'**ECC** sia attivo e riporti eventi (su Linux: `edac-util`, `dmidecode -t memory`, il log SEL del BMC).
- [ ] Eseguire uno **stress test combinato** (CPU + tutte le GPU al 100% simultaneamente) per almeno un'ora e monitorare temperature, clock (per verificare l'assenza di throttling) e stabilità dell'alimentazione.

- [ ] Verificare la **\*\*reale banda passante della memoria\*\*** con un benchmark (STREAM, `mlc` di Intel): se è la metà di quanto previsto, i canali sono stati popolati in modo errato.
- [ ] Eseguire un **\*\*training reale\*\*** e osservare l'**\*\*utilizzo della GPU\*\***: se non è stabilmente superiore al 90%, c'è un collo di bottiglia da diagnosticare (quasi sempre: caricamento dei dati o link PCIe negoziato al ribasso).

---

*Una nota finale sulla volatilità dei dati: prezzi, disponibilità, generazioni di CPU e matrici di compatibilità cambiano rapidamente in questo settore. Tutti i modelli, i prezzi e i conteggi SKU citati devono essere verificati rispetto alla documentazione ufficiale del produttore al momento dell'acquisto. I principi architetturali — corsie come valuta, canali come banda passante, ECC come assicurazione, spaziatura come vincolo fisico — sono stabili, tuttavia, e rimarranno validi anche al cambiare dei nomi dei prodotti.*

---

*Nel prossimo capitolo, discuteremo le GPU per l'AI: architetture, VRAM, tensor core, NVLink e NVSwitch, fattori di forma SXM versus PCIe e come scegliere l'acceleratore giusto per il proprio carico di lavoro.*



## Capitolo 11 - GPU Nvidia per l'AI: Dalla Workstation al Datacenter

### Nota metodologica preliminare

Questo capitolo tratta un settore in cui i dati invecchiano più velocemente di quanto un libro possa essere stampato. Tutte le informazioni riportate sono aggiornate a metà 2026, ma tre categorie di dati devono essere considerate **per loro natura volatili** e sempre verificate alla fonte prima di prendere una decisione di acquisto:

1. **Prezzi.** Le GPU per datacenter non hanno un listino pubblico stabile: vengono acquistate tramite OEM (Original Equipment Manufacturers, ovvero produttori di server come Dell, Supermicro, HPE, Lenovo) o integratori di sistemi, con prezzi che dipendono dal volume, dal contratto e dal momento storico. Le cifre che troverete qui sono ordini di grandezza documentati dalla stampa di settore, non listini prezzi. 2. **Disponibilità.** Nel 2024–2026, la domanda ha costantemente superato l'offerta: un prodotto "annunciato" può avere un tempo di attesa reale di 6–12 mesi. 3. **L'ultima generazione.** Nvidia ha adottato una cadenza architeturale annuale. Ciò che è "l'ultima" al momento della stesura sarà la penultima entro dodici mesi.

Contrassegnerò esplicitamente con **[DATI VOLATILI]** ogni punto in cui questo problema è particolarmente acuto.

---

### 1. La gerarchia completa di Nvidia

#### 1.1 Perché non esiste "la GPU Nvidia", ma tre mondi separati

Chi si avvicina all'hardware per intelligenza artificiale quasi sempre commette lo stesso errore concettuale: pensa che esista una scala continua di prodotti, dalla scheda grafica economica alla scheda grafica costosa, e che l'unica differenza sia "quanto è veloce". Non è così. Nvidia produce tre linee di prodotti che condividono l'architettura di base ma sono **prodotti diversi, con mercati diversi, accordi di licenza diversi e vincoli fisici diversi**. Confonderli porta ad acquisti sbagliati che costano decine di migliaia di euro.

Innanzitutto, definiamo il termine **GPU**: *Graphics Processing Unit*. Nasce negli anni '90 come acceleratore per il rendering 3D nei videogiochi, ovvero per un compito molto specifico: applicare la stessa operazione matematica (una

moltiplicazione di matrici, una trasformazione di coordinate, un calcolo di illuminazione) a milioni di elementi indipendenti, tutti in una volta. Questa è la definizione di **calcolo massivo parallelo**. Il fatto storicamente decisivo è che l'addestramento delle reti neurali richiede esattamente la stessa cosa: moltiplicare matrici enormi, ripetute miliardi di volte. La GPU non è stata "adattata" per l'IA; si è trovata nel posto giusto al momento giusto, e Nvidia ha avuto la lungimiranza di costruire un ecosistema software su di essa (CUDA, di cui parleremo nella sezione 7) dieci anni prima che fosse veramente necessario.

Le tre famiglie sono:

**GeForce (consumer).** Schede da gioco: RTX 4090, RTX 5090, RTX 5080 e le loro sorelle minori. Vendute al dettaglio, installate in PC desktop, con dissipatori ad aria e ventole. L'acronimo **RTX** = *Ray Tracing Texel eXtreme*, introdotto con la generazione Turing (2018) per indicare la presenza di unità hardware dedicate al ray tracing. Ai fini dell'IA, il ray tracing è irrilevante; ciò che conta è che queste stesse schede hanno anche i **Tensor Cores** (unità dedicate alla moltiplicazione di matrici a bassa precisione), ed è per questo che una GeForce è una macchina AI perfettamente valida — entro limiti molto precisi.

**RTX PRO / workstation professionale (ex Quadro).** La linea storicamente chiamata *Quadro*, poi rinominata prima "RTX A" (Ampere: A4000, A5000, A6000), poi "RTX Ada" (Ada Lovelace: RTX 5000 Ada, RTX 6000 Ada), e dal 2025 **RTX PRO Blackwell** (RTX PRO 4000/5000/6000 Blackwell). Queste schede sono destinate a workstation professionali: CAD, rendering, simulazione, visualizzazione medica e, sempre più spesso, sviluppo locale di IA. Costano 3-5 volte una GeForce con silicio equivalente.

**Datacenter (ex Tesla).** A100, H100, H200, B100, B200, GB200 e la nuova generazione Rubin. Non hanno uscite video (nella maggior parte dei casi), non hanno ventole nella variante SXM e non possono essere acquistate su Amazon. Sono componenti server, progettati per funzionare al 100% del carico per anni.

## 1.2 Le sette differenze che giustificano tre linee

Vediamole una per una, perché ognuna ha conseguenze pratiche.

**(1) VRAM. Video RAM:** la memoria montata sulla scheda, fisicamente separata dalla RAM di sistema. È **il vincolo numero uno** nell'IA. Una RTX 5090 ha 32 GB; una RTX PRO 6000 Blackwell ha 96 GB; una H200 ha 141 GB; una B200 ha 192 GB. La differenza non è "più veloce/più lenta": è **puoi eseguire il modello o no**. Un

modello che non rientra nella VRAM semplicemente non si avvierà, o funzionerà a velocità ridicole appoggiandosi alla RAM di sistema.

**(2) Tipo di memoria.** Le schede consumer utilizzano **GDDR** (*Graphics Double Data Rate*, attualmente GDDR7): chip di memoria saldati attorno alla GPU sul PCB. Le schede datacenter utilizzano **HBM** (*High Bandwidth Memory*): stack di die di memoria impilati verticalmente e collegati alla GPU tramite un *interposer* di silicio, con un bus molto ampio (migliaia di bit contro le centinaia per GDDR). HBM costa enormemente di più ma offre una larghezza di banda 3-5 volte superiore. Vedremo nella sezione 8 perché la larghezza di banda è quasi altrettanto importante quanto la capacità.

**(3) ECC. Error Correcting Code:** memoria in grado di rilevare e correggere errori a singolo bit. In un PC da gaming, un bit flip dovuto a un raggio cosmico o a una cella di memoria marginale produce un artefatto grafico per un frame, e nessuno se ne accorge. In una sessione di training di tre settimane su 1.000 GPU, produce un NaN (*Not a Number*) che corrompe i gradienti e spreca giorni di calcolo. Le schede Datacenter e RTX PRO hanno ECC; le schede GeForce no (o ne hanno forme parziali e non certificate).

**(4) Driver Certificati.** Nvidia distribuisce driver *Game Ready* per le schede GeForce (ottimizzati per i giochi appena rilasciati, aggiornati ogni due settimane) e driver **enterprise/production branch** per le schede professionali e datacenter: raramente aggiornati, testati per mesi, garantiti stabili con software specifici certificati e con supporto a lungo termine. Se il vostro cluster deve funzionare per due anni senza sorprese, questa differenza vale denaro.

**(5) Fattore di forma e raffreddamento.** Una RTX 5090 è larga tre slot e ha tre ventole che soffiano aria all'interno del case. Metterne quattro in un server è impossibile: si soffocherebbero a vicenda. Le schede datacenter sono disponibili in due formati: **PCIe** (una scheda a doppio slot, *passiva*, cioè senza ventole proprie: si affida al fortissimo flusso d'aria generato dalle ventole dello chassis del server) e **SXM** (un modulo proprietario, senza connettore PCIe, che si avvita direttamente su una scheda madre dedicata e consente TDP e interconnessioni molto più elevate). Torneremo su SXM nella sezione 3.

**(6) Licenza d'uso per Datacenter.** Questo è il punto che quasi nessuno conosce e che causa i problemi peggiori. L'**EULA** (*End User License Agreement*) per i driver Nvidia GeForce proibisce esplicitamente il *datacenter deployment* delle schede

GeForce, con un'eccezione storica per il mining di blockchain e per l'uso accademico/di ricerca. In pratica: **non è possibile costruire legalmente un servizio cloud commerciale basato su RTX 4090/5090**. È possibile usarle nella propria azienda, sulla propria workstation, per il proprio prodotto interno; non è possibile affittarle a terzi come capacità di calcolo, né installarle in un datacenter come infrastruttura di servizio. È una clausola contrattuale, non un blocco tecnico: la scheda funziona perfettamente. Ma se siete una startup che vuole vendere inferenza, questo è un rischio legale reale. **[DATI VOLATILI: il testo dell'EULA è cambiato più volte; verificarlo sempre alla data di acquisto.]**

**(7) NVLink.** L'interconnessione ad alta velocità tra GPU. Presente sulle schede datacenter, **assente sull'intera linea consumer RTX 40 e RTX 50** e sulla maggior parte delle schede RTX PRO più recenti. Questa singola scelta di prodotto è ciò che impedisce di costruire l'equivalente economico di un nodo datacenter con schede consumer. È l'argomento della sezione 4, ed è probabilmente il concetto più importante dell'intero capitolo.

### 1.3 Come leggere le nomenclature

Le tre linee hanno tre logiche di denominazione completamente diverse, e questo di per sé è una fonte di confusione.

| Linea       | Schema                                            | Esempio                          | Come leggere                                                                                                                                                           |
|-------------|---------------------------------------------------|----------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| GeForce     | RTX +<br>[generazione]<br>[livello]               | RTX 5090                         | "50" = serie 50 (Blackwell consumer); "90" = livello più alto. 80 = alto, 70 = medio, 60 = entry                                                                       |
| Workstation | RTX PRO +<br>[numero livello] +<br>[architettura] | RTX PRO 6000<br><b>Blackwell</b> | 6000 = top-tier; 5000/4000/2000 = livelli inferiori. L'architettura è nel nome per distinguerla da precedenti modelli omonimi (RTX 6000 Ada ≠ RTX PRO 6000 Blackwell!) |
| Datacenter  | [Lettera architettura] +                          | <b>H100, B200</b>                | A = Ampere, H = Hopper, B =                                                                                                                                            |

|  |          |  |                                                                                                                                                                                  |
|--|----------|--|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|  | [numero] |  | Blackwell, R = Rubin. Il numero aumenta con il posizionamento. Suffissi: GB200 = con CPU Grace; NVL = configurazione NVLink; il numero dopo NVL indica la dimensione del dominio |
|--|----------|--|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

**Classica trappola di nomenclatura:** esiste una "RTX 6000 Ada" e una "RTX PRO 6000 Blackwell". Sono due schede diverse, distanti due generazioni, con 48 GB e 96 GB rispettivamente. Vengono spesso confuse nelle liste dei rivenditori. Leggere sempre l'architettura, mai solo il numero.

---

## 2. Architetture: Cosa cambia veramente tra le generazioni

### 2.1 Il concetto di "architettura" e "processo produttivo"

Due termini vanno nettamente separati.

L'**architettura** è il design logico del chip: quante unità di calcolo, come sono organizzate, che tipi di operazioni possono eseguire, come è strutturata la gerarchia della cache, come è connessa la memoria. Nvidia nomina ogni architettura con il nome di uno scienziato: Pascal (2016), Volta (2017), Turing (2018), Ampere (2020), Hopper (2022), Ada Lovelace (2022, solo consumer/pro), Blackwell (2024), Rubin (2026).

Il **processo produttivo** (o *nodo*) è la tecnologia di fonderia con cui il chip viene fisicamente fabbricato: "4 nanometri", "3 nanometri". Attenzione: questi numeri **non corrispondono più a nessuna dimensione fisica reale** da almeno un decennio. Sono nomi commerciali. Il "4N" di TSMC usato per Hopper e Blackwell è un derivato del nodo a 5 nm ottimizzato per Nvidia. Ciò che conta veramente è la **densità di transistor** e l'efficienza energetica per operazione. Un nodo più avanzato permette di mettere più transistor nella stessa area e consuma meno per

operazione — motivo per cui l'industria continua a pagare cifre esorbitanti per accedervi.

## 2.2 Ampere (2020) — A100

Ampere ha introdotto, sul fronte datacenter, tre cose che oggi diamo per scontate.

La prima è la **terza generazione di Tensor Core con supporto TF32**. Un **Tensor Core** è un'unità di calcolo che non esegue una moltiplicazione alla volta, ma esegue in un colpo solo una piccola moltiplicazione matrice-matrice con accumulo (tipicamente 4x4 o simile), che è l'operazione elementare di ogni rete neurale. **TF32** (*TensorFloat-32*) è un formato numerico intelligente: ha lo stesso range dinamico (gli 8 bit di esponente) del classico FP32 ma solo 10 bit di mantissa come FP16. Risultato: i modelli scritti in FP32 giravano più veloci **senza modificare una riga di codice**, perché il Tensor Core convertiva silenziosamente. Fu un enorme acceleratore di adozione.

La seconda è la **memoria HBM2e** con bandwidth attorno ai 2 TB/s nella versione da 80 GB — in confronto, una GPU consumer di quegli anni stava sotto 1 TB/s.

La terza è **MIG** (*Multi-Instance GPU*): la capacità di dividere una singola A100 in fino a sette GPU logiche hardware-isolate, ognuna con la sua fetta di memoria, cache e unità di calcolo. Questo è utile nel cloud, dove un cliente che fa inferenza su un modello piccolo non deve occupare (e pagare) un'intera GPU.

L'A100 esiste nelle versioni da 40 GB e 80 GB, PCIe e SXM4. **[DATI VOLATILI]** Nel 2026, è tecnicamente obsoleto ma commercialmente molto attivo nel mercato dell'usato e sui cloud a basso costo, a prezzi che sono una frazione dell'originale. Per molti carichi di lavoro di inferenza e per il fine-tuning di modelli medi, è ancora l'opzione con il miglior rapporto prezzo/prestazioni sul mercato secondario.

## 2.3 Hopper (2022) — H100 e H200

Hopper è la generazione che ha coinciso con l'esplosione degli LLM (*Large Language Models*) ed è, di fatto, il cavallo di battaglia su cui sono stati addestrati la maggior parte dei modelli famosi.

Innovazioni chiave:

**Il Transformer Engine e il formato FP8**. Il Transformer Engine è un blocco hardware+software che analizza dinamicamente, strato per

**FP4 e il Transformer Engine di seconda generazione.** Se FP8 dimezzava i bit rispetto a FP16, Blackwell li dimezza ancora con **FP4** (nello specifico il formato proprietario **NVFP4**, che usa fattori di scala a livello di blocco per contenere la perdita di precisione). Quattro bit per numero significano **sedici possibili valori in totale**. Sembra assurdo, e per il training lo è quasi sempre; ma per l'**inferenza**, dove il modello è già addestrato e deve solo essere eseguito, la ricerca ha dimostrato che con le giuste tecniche di quantizzazione il degrado di qualità è minimale. Il guadagno è duplice: raddoppio del throughput e dimezzamento della memoria occupata dai pesi.

**Le "sottogenerazioni": B100, B200 e GB200.** Qui un punto di confusione va chiarito. B100 e B200 **usano lo stesso identico silicio**. La differenza è la configurazione: TDP (*Thermal Design Power*, la potenza termica che il sistema di raffreddamento deve dissipare, usata come proxy per il consumo) e frequenze.

- **\*\*B100\*\***: ~700 W. Progettato per essere un *\*drop-in replacement\** in rack progettati per H100, che erano già dimensionati per 700 W. Nessuna modifica infrastrutturale, prestazioni superiori. Ha avuto una vita commerciale breve e un ruolo marginale: Nvidia ha spinto tutti verso B200.
- **\*\*B200\*\***: ~1000–1200 W a seconda della configurazione. Stesso chip, sbloccato. Prestazioni significativamente più elevate, ma richiede nuovi rack e raffreddamento.
- **\*\*GB200\*\***: **\*\*non è una GPU\*\***. È un *\*superchip\**: **\*\*una CPU Grace + due GPU B200\*\*** su un singolo modulo, connesse da **\*\*NVLink-C2C\*\*** (*\*Chip-to-Chip\**) a 900 GB/s. Non è un semplice "pacchetto commerciale": la connessione CPU-GPU via NVLink-C2C, invece che via PCIe, è circa sette volte più veloce ed è **\*\*cache-coherent\*\***, il che significa che CPU e GPU vedono lo stesso spazio di memoria senza copie esplicite. Questo cambia il modo in cui il codice viene scritto: pesi o KV-cache possono essere *\*offloadati\** alla memoria LPDDR della CPU (centinaia di GB) senza pagare il prezzo devastante di un trasferimento PCIe.

**Blackwell Ultra (B300 / GB300).** Come H200 era per H100, B300 è per B200: stessa architettura, memoria HBM3e aumentata (fino a ~288 GB per package) e ottimizzazioni per l'inferenza a bassa precisione, con circa 208 miliardi di transistor. Questa è la "metà generazione" che copre il 2025–2026.

## 2.5 Rubin (2026) — la generazione attuale

**[DATI VOLATILI — questa sezione descrive un prodotto in fase di lancio: verificare tutto.]**

Rubin è l'architettura che succede a Blackwell. Nvidia ha annunciato la sua piena produzione all'inizio del 2026, con disponibilità per partner e fornitori di cloud nella seconda metà dell'anno. I punti chiave, come pubblicamente noti a metà 2026:

- **Rubin GPU** (spesso indicata come R100/R200): nodo TSMC 3nm, design **dual-die** come Blackwell ma con circa **336 miliardi di transistor** (~1.6× Blackwell).
- **Memoria HBM4**: circa **288 GB** per package con una larghezza di banda dichiarata fino a circa **22 TB/s** — quasi il triplo di Blackwell. Il salto deriva principalmente dal raddoppio della larghezza del bus per stack.
- **Compute**: nell'ordine di **50 PFLOPS in NVFP4** per package (rispetto a ~20 per Blackwell).
- **Vera CPU**: sostituisce Grace. CPU ARM personalizzata con 88 core "Olympus", fino a 1.5 TB di LPDDR5X, collegata alle GPU tramite NVLink-C2C a 1.8 TB/s.
- **NVLink 6**: circa 3.6 TB/s per GPU, il doppio della generazione Blackwell.
- **Sistema**: il rack di riferimento è il **VR200 NVL72** (72 package GPU), con un consumo energetico nell'ordine di 190–230 kW per rack — rispetto a ~120–130 kW per il GB200 NVL72. Il raffreddamento a liquido è **obbligatorio**: non esistono configurazioni raffreddate ad aria.

La roadmap dichiarata prosegue con **Rubin Ultra** (2027, rack "Kyber" a ~600 kW) e **Feynman** (2028). Il messaggio strategico è chiaro e deve essere compreso da chiunque pianifichi infrastrutture: **Nvidia ha adottato una cadenza annuale in cui non solo il chip ma l'intero involucro fisico cambia** — alimentazione, raffreddamento, rete. Chiunque costruisca un data center oggi lo sta costruendo per hardware che, entro due cicli, non sarà più compatibile.

2.6 Tabella riassuntiva generazionale

|      | Ampere (A100) | Hopper (H100) | Hopper (H200) | Blackwel l (B200)        | Blackwel l Ultra (B300) | Rubin (R100) |
|------|---------------|---------------|---------------|--------------------------|-------------------------|--------------|
| Anno | 2020          | 2022          | 2023–24       | 2024–25                  | 2025–26                 | 2026 (ramp)  |
| Nodo | TSMC 7N       | TSMC 4N       | TSMC 4N       | TSMC 4NP                 | TSMC 4NP                | TSMC 3nm     |
| Die  | singolo       | singolo       | singolo       | <b>dual-die (NV-HBI)</b> | dual-die                | dual-die     |



|                    |                     |                     |                 |                        |                  |                             |
|--------------------|---------------------|---------------------|-----------------|------------------------|------------------|-----------------------------|
| Transistor         | 54 mld              | 80 mld              | 80 mld          | 208 mld                | ~208 mld         | ~336 mld                    |
| Memoria            | HBM2e<br>40/80 GB   | HBM3 80<br>GB       | HBM3e<br>141 GB | HBM3e<br>192 GB        | HBM3e<br>~288 GB | <b>HBM4<br/>~288 GB</b>     |
| Larghezza di banda | ~2.0 TB/s           | ~3.35<br>TB/s       | ~4.8 TB/s       | ~8 TB/s                | ~8 TB/s          | ~ <b>22 TB/s</b>            |
| Precisione minima  | FP16/<br>BF16       | <b>FP8</b>          | FP8             | <b>FP4<br/>(NVFP4)</b> | FP4              | FP4/FP6                     |
| NVLink             | 4a gen,<br>600 GB/s | 4a gen,<br>900 GB/s | 900 GB/s        | 5a gen,<br>1.8 TB/s    | 1.8 TB/s         | <b>6a gen,<br/>3.6 TB/s</b> |
| TDP (SXM)          | 400 W               | 700 W               | 700 W           | ~1000–<br>1200 W       | ~1400 W          | ~1800–<br>2300 W            |

*Tutti i valori sono indicativi e si riferiscono alle varianti SXM di fascia alta. Le versioni PCIe hanno sempre TDP e larghezza di banda NVLink inferiori.*

### 3. Schede per data center, una per una

#### 3.1 Premessa: SXM contro PCIe

Prima di esaminare i singoli prodotti, è importante comprendere questa distinzione, poiché è la prima domanda che qualsiasi venditore vi porrà.

**PCIe** (*Peripheral Component Interconnect Express*) è il bus standard con cui qualsiasi scheda si collega alla scheda madre di qualsiasi computer. Una GPU per data center in formato PCIe assomiglia a una scheda video molto lunga, a doppio slot, **senza ventole**: è *passiva* e si affida al forte flusso d'aria che le ventole del server spingono attraverso lo chassis. Vantaggi: si monta in un server standard, costa meno e può essere acquistata una alla volta. Svantaggi: il **TDP è limitato** (tipicamente 300–600 W, perché il connettore e lo slot non possono gestire di più) e, in modo critico, **l'interconnessione tra le GPU è limitata** — al massimo un singolo bridge NVLink tra due schede, o nulla del tutto nelle generazioni recenti.

**SXM** è un formato proprietario Nvidia. Il modulo non ha un connettore PCIe: si avvita su una **baseboard** dedicata (tipicamente HGX, la scheda a 4 o 8 GPU che Nvidia vende agli OEM). La baseboard fornisce alimentazione (fino a 700–1400 W per modulo) e linee NVLink agli NVSwitch. Vantaggi: TDP molto più elevato (quindi frequenze più alte, quindi maggiori prestazioni dallo stesso silicio), e

**NVLink a piena larghezza di banda tra tutte le GPU nel nodo.** Svantaggi: può essere acquistato solo come sistema completo a 4 o 8 GPU, è molto costoso e richiede un server appositamente progettato.

**La regola pratica:** se stai eseguendo un *training* distribuito su più GPU, hai bisogno di SXM. Se stai eseguendo *inferenza* con modelli che rientrano in una singola GPU, PCIe è più che sufficiente — e molto più economico.

### 3.2 A100 (40 GB / 80 GB)

- **\*\*VRAM:\*\*** 40 GB o 80 GB HBM2e
- **\*\*Larghezza di banda:\*\*** ~1.55 TB/s (40 GB) / ~2.0 TB/s (80 GB SXM)
- **\*\*TDP:\*\*** 250–300 W (PCIe) / 400 W (SXM4)
- **\*\*Fattore di forma:\*\*** PCIe e SXM4
- **\*\*Prestazioni indicative:\*\*** ~312 TFLOPS in FP16 con sparsità, ~19.5 TFLOPS FP32
- **\*\*Prezzo [DATI VOLATILI]:\*\*** fuori produzione da tempo; sul mercato dell'usato e ricondizionato, si possono trovare a una frazione del prezzo originale (che era di circa \$10.000–\$15.000 per la 80 GB). Sui cloud, è tra le opzioni più economiche disponibili.
- **\*\*Casi d'uso:\*\*** inferenza di modelli fino a ~30–70 miliardi di parametri quantizzati, fine-tuning, ricerca accademica, carichi di lavoro HPC classici (simulazione, CFD). **\*\*Non\*\*** ha FP8: per l'inferenza LLM moderna, che si basa su FP8/FP4, questa è una seria limitazione architetturale.
- **\*\*Chi dovrebbe acquistarla:\*\*** chi ha un budget limitato, un carico di lavoro noto e l'esperienza per gestire hardware usato. È l'"opzione usata sicura" nel settore.

### 3.3 H100

- **\*\*VRAM:\*\*** 80 GB HBM3 (esiste anche una H100 NVL con 94 GB, una variante a doppia scheda)
- **\*\*Larghezza di banda:\*\*** ~3.35 TB/s (SXM5) / ~2.0 TB/s (PCIe)
- **\*\*TDP:\*\*** 700 W (SXM5) / 350 W (PCIe)
- **\*\*Prestazioni:\*\*** ~1.979 TFLOPS FP8 con sparsità (SXM5). La versione PCIe ha prestazioni **\*\*circa il 20–30% inferiori\*\*** a causa del TDP dimezzato e della minore larghezza di banda.
- **\*\*Prezzo [DATI VOLATILI]:\*\*** l'ordine di grandezza riportato pubblicamente è di \$25.000–\$40.000 per scheda; un nodo HGX H100 a 8 GPU è nella fascia \$250.000–\$400.000.

- **Casi d'uso:** è stata la GPU del boom degli LLM. Training di modelli fino a decine di miliardi di parametri (in cluster), inferenza ad alta produttività, fine-tuning serio.

**Errore comune:** acquistare la H100 PCIe pensando che sia "una H100 leggermente più economica". Non lo è: è una GPU significativamente più lenta, con NVLink limitato o assente, che può avere prestazioni dimezzate in un carico di lavoro multi-GPU. Se il tuo carico di lavoro è multi-GPU, la PCIe è quasi sempre un falso risparmio.

### 3.4 H200

- **VRAM:** 141 GB HBM3e
- **Larghezza di banda:** ~4.8 TB/s
- **TDP:** 700 W (SXM5), lo stesso del suo predecessore
- **Chip di calcolo:** identico all'H100. Nessun aumento di TFLOPS.
- **Prezzo [DATI VOLATILI]:** superiore all'H100, nell'ordine di \$30.000–\$40.000.
- **Casi d'uso:** inferenza LLM. Qui il guadagno è drammatico — spesso 1.5–2x rispetto all'H100 sullo stesso modello — non perché calcola di più, ma perché l'inferenza autoregressiva è limitata dalla larghezza di banda della memoria. Ogni token generato richiede la riletture di tutti i pesi del modello dalla VRAM. Più larghezza di banda = più token al secondo, punto.

Questo è il momento di affermare chiaramente qualcosa che ricorrerà in tutto il capitolo: **nell'inferenza LLM, la larghezza di banda della memoria è più importante dei TFLOPS**. Chiunque confronti le GPU guardando solo i TFLOPS sta guardando la metrica sbagliata.

### 3.5 B100, B200, GB200

- **B100:** ~192 GB HBM3e, ~8 TB/s, 700 W. Compatibile con l'infrastruttura H100. Prodotto di transizione, non ampiamente adottato.
- **B200:** ~192 GB HBM3e, ~8 TB/s, ~1000–1200 W. Circa 20 PFLOPS in FP4 denso. Questa è la vera GPU Blackwell per datacenter, disponibile su schede madri HGX B200 a 8 GPU.
- **GB200:** 1 CPU Grace + 2 GPU B200 su un superchip. ~384 GB di HBM3e (2×192) più fino a 480 GB di LPDDR5X sulla Grace. Consumo energetico del modulo intorno ai 2700 W. **Richiede raffreddamento a liquido.**

- **\*\*Prezzo [DATI VOLATILI]:\*\*** una singola B200 è nell'ordine di \$30.000–\$40.000; un sistema GB200 NVL72 completo è stato stimato dalla stampa specializzata a circa \$3 milioni.

### 3.6 GB200 NVL72: quando l'unità di calcolo diventa il rack

Questo è il concetto più importante di questa sezione e segna la fine di un'era.

Fino a Hopper, l'unità di calcolo era **il nodo**: un server con 8 GPU connesse tramite NVLink, e i nodi stessi connessi tramite rete (InfiniBand). Il divario di larghezza di banda tra "all'interno del nodo" (900 GB/s) e "all'esterno del nodo" (50–100 GB/s) era di un ordine di grandezza, e l'intera teoria dell'addestramento distribuito era costruita attorno a questa disparità.

Il **GB200 NVL72** riscrive la regola. È un rack che contiene **36 superchip GB200**, il che significa **72 GPU B200 + 36 CPU Grace, tutti connessi da un singolo dominio NVLink** tramite 9 vassoi NVSwitch. Le 72 GPU vedono uno spazio di memoria condiviso di circa 13,5 TB di HBM3e, con una larghezza di banda NVLink aggregata nell'ordine di 130 TB/s. Dal punto di vista software, **l'intero rack si comporta come una gigantesca GPU**.

Perché è importante? Perché un modello con centinaia di miliardi o trilioni di parametri, che in precedenza doveva essere suddiviso tra molti nodi pagando la penalità di rete ad ogni livello, ora vive all'interno di un singolo dominio ad altissima larghezza di banda. Per i modelli **MoE** (*Mixture of Experts*) (architetture in cui ogni token attiva solo un sottoinsieme di "esperti" e quindi genera molto traffico di routing tra le GPU), il guadagno è enorme.

Il prezzo da pagare è fisico: ~120–130 kW per rack, raffreddamento a liquido obbligatorio e un'infrastruttura elettrica che la maggior parte dei datacenter esistenti nel mondo **semplicemente non possiede**. Un rack tradizionale consuma 5–15 kW.

### 3.7 Grace: perché ARM nel datacenter

**Grace** è la CPU progettata da Nvidia sull'architettura **ARM** (specificamente core Neoverse V2), con 72 core, memoria **LPDDR5X** saldata sul package (fino a 480 GB, ~500 GB/s di larghezza di banda) e — questo è il punto chiave — una connessione **NVLink-C2C** alla GPU a 900 GB/s, **cache-coherent**.

Perché ARM e non x86? Tre ragioni, in ordine di importanza reale:

1. **La connessione.** Nvidia non poteva inserire NVLink-C2C in un processore Intel o AMD: non controlla quei progetti. Per avere un percorso CPU-GPU sette volte più veloce del PCIe, ha dovuto creare la propria CPU. ARM le ha concesso una licenza architetturale su cui basarsi. **La CPU Grace esiste principalmente per essere il socket giusto accanto alla GPU**, non perché sia una CPU rivoluzionaria di per sé.

2. **Efficienza energetica.** In un rack da 130 kW, ogni watt speso dalla CPU è un watt sottratto alle GPU. I core ARM con memoria LPDDR (memoria a basso consumo, come nei telefoni, saldata e non espandibile) offrono un eccellente rapporto prestazioni-per-watt per il ruolo che devono svolgere qui: alimentare i dati alle GPU, gestire l'I/O, orchestrare.

3. **Controllo verticale.** Nvidia vuole vendere il sistema completo, non solo un componente. Grace fa parte di questa strategia.

Con Rubin, Grace viene sostituita da **Vera**, con core ARM interamente personalizzati.

**Implicazione pratica per lo sviluppatore:** un sistema Grace è una macchina **aarch64**, non x86\_64. Il tuo container Docker, il tuo wheel Python compilato, il tuo binario proprietario devono esistere per ARM. Nell'ecosistema AI mainstream (PyTorch, CUDA, container NGC di Nvidia) questo problema è ormai risolto. Nel software aziendale legacy, spesso no. **È il primo controllo da fare prima dell'acquisto.**

---

## 4. NVLink e Interconnessioni

### 4.1 Perché PCIe non è sufficiente

Immagina di addestrare un modello su 8 GPU con **parallelismo dei dati**: ogni GPU riceve una fetta diversa dei dati, calcola i suoi gradienti (le derivate della funzione di perdita rispetto a ciascun parametro), e poi tutte devono **fare la media dei gradienti tra loro** prima di aggiornare i pesi. Questa operazione si chiama **all-reduce** e deve essere eseguita **ad ogni singolo passo di addestramento**, cioè decine di migliaia di volte.

Quanti dati vengono scambiati? Tanti quanti i parametri del modello, moltiplicati per la dimensione in byte di ciascuno. Per un modello da 7 miliardi di parametri in BF16, sono 14 GB, e all-reduce ne sposta circa il doppio.

Ora facciamo i conti. **PCIe 5.0 x16** offre circa **64 GB/s** per direzione. **NVLink 4** offre **900 GB/s**. Il rapporto è di 14 a 1. In uno scenario di addestramento reale, questo significa che con PCIe, le GPU trascorrono una frazione enorme del tempo **inattive, in attesa dei dati dai loro compagni**. L'utilizzo effettivo crolla, e otto GPU si comportano come tre o quattro.

Poi c'è la **latenza**, che è un problema distinto dalla larghezza di banda: PCIe passa attraverso il *root complex* della CPU, con overhead di protocollo. NVLink è una connessione diretta punto-punto tra GPU, con una latenza di un ordine di grandezza inferiore. Nei modelli **tensor-parallel** (dove un singolo strato è diviso tra più GPU e ogni GPU deve scambiare attivazioni **all'interno del forward pass**, decine di volte per token), la latenza è più critica della larghezza di banda. Con PCIe, il parallelismo tensoriale è semplicemente **impraticabile**.

#### 4.2 NVLink: Generazioni

**NVLink** è l'interconnessione proprietaria di Nvidia introdotta nel 2016 con Pascal. Non è un bus: è un insieme di **collegamenti seriali punto-punto** (chiamati *bricks* o *links*) che possono essere aggregati. Ogni generazione ha aumentato la velocità per link e il numero di link per GPU.

| Generazione | Anno | Architettura           | Larghezza di banda bidirezionale per GPU      |
|-------------|------|------------------------|-----------------------------------------------|
| NVLink 1    | 2016 | Pascal (P100)          | 160 GB/s                                      |
| NVLink 2    | 2017 | Volta (V100)           | 300 GB/s                                      |
| NVLink 3    | 2020 | Ampere (A100)          | 600 GB/s                                      |
| NVLink 4    | 2022 | Hopper (H100/H200)     | 900 GB/s                                      |
| NVLink 5    | 2024 | Blackwell (B200/GB200) | 1.800 GB/s (1.8 TB/s)                         |
| NVLink 6    | 2026 | Rubin                  | ~3.600 GB/s (3.6 TB/s) <b>[DATI VOLATILI]</b> |

**NVSwitch.** Connettere 8 GPU "all-to-all" direttamente richiederebbe 28 collegamenti fisici, e non è scalabile. L'NVSwitch è un **chip switch** dedicato: ogni GPU si connette allo switch, e lo switch instrada il traffico. Il risultato è che **ogni GPU parla con ogni altra GPU a piena larghezza di banda**, simultaneamente,

senza colli di bottiglia. Nel GB200 NVL72, gli NVSwitch si spostano fuori dal server e diventano vassoi dedicati nel rack, estendendo il dominio NVLink a 72 GPU. Questo è esattamente il salto che ha reso possibile "il rack come unità di calcolo".

#### 4.3 La rimozione di NVLink dalle schede consumer e professionali

Questo paragrafo è probabilmente **il più importante del capitolo per chiunque stia costruendo una workstation.**

- La RTX 3090 (Ampere) aveva NVLink: due schede potevano essere accoppiate con un bridge.
- **\*\*La RTX 4090 (Ada) e la RTX 5090 (Blackwell consumer) NON hanno NVLink.\*\*** Nessun bridge, nessuna opzione.
- Anche nella linea professionale, il supporto si è drasticamente ridotto: la RTX 6000 Ada non aveva NVLink; le schede RTX PRO Blackwell nemmeno.

#### Le implicazioni concrete:

1. **Non è possibile sommare la VRAM.** Due RTX 5090 non creano una GPU da 64 GB. Creano due GPU separate da 32 GB. Un modello che non entra in 32 GB non entra, punto — a meno di dividerlo manualmente su PCIe, con le penalità discusse sopra. 2. **Il parallelismo tensoriale è fuori discussione.** Si può fare *parallelismo di pipeline* (mettere i layer 1–20 sulla GPU A e 21–40 sulla GPU B, con un solo scambio al confine): questo funziona anche su PCIe perché il traffico è molto inferiore. Ma la velocità sarà mediocre. 3. **Il multi-GPU consumer è principalmente per carichi di lavoro indipendenti:** quattro lavori diversi su quattro GPU, quattro modelli in inferenza, quattro esperimenti in parallelo. Questo funziona perfettamente. L'addestramento distribuito di un singolo modello grande, no.

Non è una limitazione tecnica: è una **decisione commerciale**. Nvidia non vuole che le persone costruiscano nodi di addestramento economici con schede da gioco. Saperlo vi eviterà di spendere 10.000 € per una workstation che non farà ciò che sperate.

#### 4.4 Oltre il nodo: InfiniBand ed Ethernet/RoCE

Quando si va oltre le GPU di un singolo nodo (o di un singolo rack NVL72), è necessario passare alla **rete**.

**InfiniBand** è una tecnologia di rete progettata per l'HPC (*High Performance Computing*), acquisita da Nvidia con Mellanox. La sua caratteristica distintiva è il

**RDMA** (*Remote Direct Memory Access*): una GPU può scrivere direttamente nella memoria di una GPU su un altro server **senza coinvolgere le CPU o i sistemi operativi**. Il risultato è una latenza molto bassa (~1 microsecondo) e un controllo della congestione affidabile. Le generazioni attuali sono NDR (400 Gb/s) e XDR (800 Gb/s). È la scelta classica per i grandi cluster di addestramento.

**Ethernet con RoCE** (*RDMA over Converged Ethernet*) porta RDMA all'Ethernet standard. Vantaggi: costo inferiore, utilizza l'esperienza e le attrezzature aziendali esistenti, evita il vendor lock-in. Svantaggi: Ethernet è intrinsecamente *lossy* (può perdere pacchetti in caso di congestione) e l'IA richiede la configurazione di meccanismi di rete lossless (PFC, ECN) che sono notoriamente difficili da mettere a punto. Nvidia vende la propria piattaforma Ethernet ottimizzata per l'IA (**Spectrum-X**) proprio per colmare questa lacuna.

**Regola generale:** al di sotto di ~64 GPU, la rete è raramente il principale collo di bottiglia e l'Ethernet va bene. Al di sopra di migliaia di GPU, la qualità dell'interconnessione determina la scalabilità dell'intero investimento, e ogni punto percentuale di efficienza vale milioni.

---

## 5. Workstation e Sistemi Pre-assemblati

### 5.1 La Linea DGX

**DGX** è la linea di sistemi "chiavi in mano" di Nvidia: server completi, progettati, assemblati e supportati da Nvidia, con stack software preinstallato. Non si acquistano GPU: si acquista **un sistema garantito funzionante**, con supporto enterprise, e si risparmiano mesi di sforzi di integrazione.

- **\*\*DGX H100:\*\*** 8× H100 SXM5 (640 GB HBM3), 2 CPU Intel Xeon, ~10 kW.  
**\*\*[DATI VOLATILI]\*\*** Prezzo di listino storicamente riportato intorno a \$300.000–\$400.000.
- **\*\*DGX B200:\*\*** 8× B200 (1.440 GB HBM3e), raffreddato ad aria (l'ultimo DGX a permetterlo), ~14,3 kW. Ordine di grandezza: \$500.000.
- **\*\*DGX GB200 / GB200 NVL72:\*\*** il rack completo descritto nella sezione 3.6. Milioni di dollari.
- **\*\*DGX SuperPOD:\*\*** l'aggregazione di molte unità DGX in un supercomputer chiavi in mano, con networking, storage e software di gestione. Si parla di decine di milioni.



**A chi è destinata la linea DGX?** Organizzazioni in cui il costo del tempo di ingegneria supera il premio hardware: laboratori di ricerca finanziati, aziende Fortune 500, fornitori di cloud. Se stai calcolando quanto risparmiaresti acquistando i componenti separatamente, **non sei il cliente DGX** — e va benissimo così.

## 5.2 DGX Spark (precedentemente Project DIGITS)

Questo prodotto merita attenzione perché è il primo serio tentativo di Nvidia di portare l'architettura dei datacenter sul desktop a un prezzo non assurdo, e perché è **profondamente incompreso**.

**Cos'è:** una scatola delle dimensioni di un piccolo Mac Mini, basata sul superchip **GB10 Grace Blackwell**: una CPU ARM (20 core, in collaborazione con MediaTek) e una GPU Blackwell in un unico package, con **128 GB di memoria LPDDR5X unificata** condivisa tra CPU e GPU. Circa **1 PFLOP di calcolo FP4**. Consumo energetico di circa 240 W: alimentato da una presa domestica standard. **[DATI VOLATILI]** Prezzo di lancio intorno a \$3.000–\$4.000.

**A cosa serve realmente.** La cosa straordinaria è la **capacità di memoria**: 128 GB accessibili alla GPU significano poter caricare modelli che non entrerebbero mai su nessuna GPU consumer. Nvidia parla di modelli fino a ~200 miliardi di parametri (quantizzati) su una singola unità, e fino a ~400 miliardi collegandone due. Per uno sviluppatore che ha bisogno di **prototipare, sperimentare, testare pipeline, eseguire inferenze locali su modelli di grandi dimensioni**, è un oggetto impareggiabile a quel prezzo.

**Il limite, e va detto con brutale chiarezza: la larghezza di banda della memoria.** L'LPDDR5X del GB10 offre nell'ordine di **270 GB/s**. Si confronti con i ~1.800 GB/s di una RTX 5090 o i 4.800 GB/s di un H200. È **6–18 volte più lento**. E abbiamo già stabilito che **l'inferenza LLM è limitata dalla larghezza di banda della memoria**. Conseguenza pratica: sulla DGX Spark, un modello grande **ci sta**, ma genera token lentamente. Non è una macchina da produzione, non è una macchina da benchmark di throughput.

**Il posizionamento corretto è questo:** la DGX Spark è una **macchina di sviluppo**. Serve a scrivere e validare codice che poi girerà su una vera DGX o in cloud, con lo **stesso identico stack software e la stessa architettura ARM+Blackwell**. Il valore è nella fedeltà dell'ambiente, non nella velocità. Chi la compra aspettandosi

una GPU da inferenza veloce rimarrà deluso, e la colpa è di un marketing ambiguo, non del prodotto.

### 5.3 DGX Station (GB300)

**[DATI VOLATILI]** La DGX Station di nuova generazione è una workstation desktop (formato tower) basata sul superchip **GB300 Grace Blackwell Ultra**, con circa **784 GB di memoria coerente totale** (HBM3e sulla GPU + LPDDR5X sulla CPU), NIC ConnectX ad alta velocità integrata e alimentazione da presa a muro standard. È l'anello mancante tra la DGX Spark e il rack: una macchina da datacenter **vera**, con vera banda HBM, in un formato che sta a fianco di una scrivania. Prezzo previsto: nell'ordine di decine di migliaia di dollari, lontano dalla Spark e ben al di sotto di un rack.

### 5.4 L'alternativa: costruirsi la propria workstation

Ha senso? Facciamo un confronto onesto.

| Configurazione            | VRAM Totale             | Banda per GPU | NVLink | Costo Indicativo [VOLATILE] | Adatta per                                                          |
|---------------------------|-------------------------|---------------|--------|-----------------------------|---------------------------------------------------------------------|
| 2× RTX 5090               | 2×32 GB (non sommabili) | ~1.8 TB/s     | ✗      | ~€7.000–9.000               | Inferenza modelli medi, LoRA, Stable Diffusion, job paralleli       |
| 4× RTX 5090               | 4×32 GB                 | ~1.8 TB/s     | ✗      | ~€15.000–20.000             | Come sopra ×2; potenza e raffreddamento diventano un problema serio |
| 2× RTX PRO 6000 Blackwell | 2×96 GB                 | ~1.8 TB/s     | ✗      | ~€20.000–25.000             | Inferenza modelli grandi; fine-tuning serio; uso                    |

|                      |                  |            |            |                   |                                                   |
|----------------------|------------------|------------|------------|-------------------|---------------------------------------------------|
|                      |                  |            |            |                   | commerciale legittimo                             |
| DGX Spark            | 128 GB unificati | ~0.27 TB/s | —          | ~€4.000           | Sviluppo, prototipazione, modelli enormi ma lenti |
| 1× H100 PCIe (usata) | 80 GB            | ~2.0 TB/s  | limitato   | ~€20.000–25.000   | Inferenza professionale, uso datacenter legittimo |
| HGX 8× H100 Node     | 640 GB           | ~3.35 TB/s | ✅ 900 GB/s | ~€250.000–400.000 | Vero training distribuito                         |

**Nota fondamentale sulla potenza domestica.** Quattro RTX 5090 da sole assorbono 2.300 W di picco, più CPU, ventole e perdite dell'alimentatore: si superano agevolmente i 3.000 W. Una presa domestica standard italiana eroga 3.000–3.300 W **per tutto l'appartamento**. Questo non è un dettaglio: è un vincolo che chiude fisicamente la discussione. Oltre due schede di fascia alta, serve una linea dedicata e una seria considerazione per l'estrazione del calore da una stanza in cui si stanno scaricando l'equivalente termico di tre stufette.

## 6. GPU consumer per AI: quando bastano

### 6.1 RTX 4090 e RTX 5090

**RTX 4090** (Ada, 2022): 24 GB GDDR6X, ~1.008 GB/s di banda, 450 W. **RTX 5090** (Blackwell, 2025): 32 GB GDDR7, ~1.792 GB/s di banda, 575 W. **[DATI VOLATILI: MSRP ~ \$2.000, prezzo di mercato storicamente molto più alto.]**

Il salto della 5090 è significativo per l'AI **soprattutto per la banda** (+78%) e per il supporto nativo FP4, non tanto per i 32 GB — che sono ancora pochi.

\*\*C

CUDA è un linguaggio (un'estensione di C/C++), un compilatore, un runtime, un modello di programmazione. Ma **il vero vantaggio competitivo non è CUDA in sé: è ciò che è cresciuto al di sopra di esso.**

- **cuDNN** (\*CUDA Deep Neural Network library\*): Kernel ottimizzati a mano, per ogni architettura GPU, per convoluzioni, normalizzazioni, funzioni di attivazione. Ogni framework di deep learning al mondo si affida ad esso.
- **cuBLAS**: Algebra lineare (moltiplicazioni di matrici) alla massima performance ottenibile dal silicio.
- **NCCL** (\*NVIDIA Collective Communications Library\*): Primitive di comunicazione multi-GPU (all-reduce, all-gather, broadcast) ottimizzate per NVLink e InfiniBand. Senza NCCL, l'addestramento distribuito dovrebbe essere scritto a mano.
- **TensorRT** e **TensorRT-LLM**: Compilatori di inferenza che prendono un modello addestrato e lo trasformano in un motore ottimizzato per una specifica GPU (fusione di kernel, quantizzazione, selezione automatica dei migliori algoritmi). Il guadagno rispetto all'esecuzione ingenua è spesso 2-5×.
- **Triton Inference Server**, **NeMo**, container **NGC**: L'intera pila di produzione.

## 7.2 Cosa significa in pratica quando si sceglie l'hardware

Significa che quando si confronta una GPU Nvidia con un'alternativa (AMD Instinct MI300X/MI355X, Intel Gaudi, Google TPU, acceleratori di startup) **non si stanno confrontando due chip. Si stanno confrontando due ecosistemi.** E il confronto deve essere fatto onestamente su tre livelli:

**Livello 1 — Funziona?** Su Nvidia: `pip install torch`, il codice gira, fatto. Sulle alternative: dipende dalla maturità dello stack (ROCm di AMD è migliorato enormemente ma rimane più fragile), dalla versione, dal modello.

**Livello 2 — Funziona velocemente?** L'ottimizzazione di basso livello (kernel fusi, attenzione ottimizzata come FlashAttention, quantizzazione) esce prima e meglio su CUDA. Un nuovo modello su Nvidia gira ottimizzato dal primo giorno; sulle alternative, spesso mesi dopo, o mai.

**Livello 3 — Funziona quando si rompe?** Quando un addestramento si blocca alle tre del mattino, la probabilità che qualcuno abbia già visto quell'errore e lo abbia risolto su Stack Overflow, GitHub o un forum è enormemente più alta su

CUDA. **Questo è il vero vantaggio competitivo**, ed è fatto di persone, non di silicio.

**La conseguenza pratica per l'acquisto:** il costo totale di proprietà di un'alternativa più economica include il tempo dei vostri ingegneri. Se un ingegnere costa 400€/giorno e l'alternativa vi fa perdere venti giorni di integrazione, avete bruciato 8.000€ — spesso più del risparmio. Le alternative hanno senso in due condizioni: **su larga scala** (dove il risparmio unitario si moltiplica per migliaia di unità e ci si può permettere un team dedicato) o **per un carico di lavoro ristretto e stabile** (un singolo modello, in inferenza, che si valida una volta e non si tocca più). Nel mezzo, Nvidia vince per ragioni che non hanno nulla a che fare con i TFLOPS.

---

## 8. Come valutare una GPU per l'AI: criteri espliciti

### 8.1 Criterio #1: VRAM

**Sempre, in ogni caso, prima di ogni altra cosa.** Una GPU super-veloce con poca memoria è inutile; una GPU lenta con abbastanza memoria porta comunque a termine il lavoro.

Il calcolo deve essere fatto sommando **tre voci**:

**(a) Pesì del modello.** Numero di parametri  $\times$  byte per parametro:

- FP32 (32 bit) = 4 byte  $\rightarrow$  un modello da 7B occupa 28 GB
- FP16/BF16 (16 bit) = 2 byte  $\rightarrow$  14 GB
- FP8 (8 bit) = 1 byte  $\rightarrow$  7 GB
- INT4/FP4 (4 bit) = 0.5 byte  $\rightarrow$  3.5 GB

**(b) Stato dell'ottimizzatore, se si sta addestrando.** Con Adam (l'ottimizzatore standard), sono necessari **due stati aggiuntivi per parametro** (momentum e varianza) più i gradienti. Regola pratica: **l'addestramento in mixed precision costa circa 16–20 byte per parametro**, che è **8–10 volte** il costo della sola inferenza in FP16. Un modello da 7B che occupa 14 GB per l'inferenza richiede **oltre 100 GB** per il fine-tuning completo. Questo è il motivo per cui esiste LoRA.

**(c) Attivazioni e KV-cache.** Le attivazioni sono i risultati intermedi di ogni strato e crescono **linearmente con la dimensione del batch**. La **KV-cache** (*Key-Value cache*) è la memoria che, durante la generazione di testo, memorizza le chiavi e i

valori di attenzione già calcolati per evitare di ricalcolarli per ogni token: cresce **linearmente con la lunghezza del contesto e il numero di richieste concorrenti**. In un servizio di inferenza con contesti lunghi e molti utenti, **la KV-cache può superare le dimensioni del modello stesso**. Questo è l'elemento che tutti dimenticano di calcolare, ed è ciò che fa esplodere i server di produzione.

## 8.2 Criterio #2: Larghezza di banda della memoria

Come ripetutamente affermato: **l'inferenza autoregressiva di LLM è memory-bound**. Per generare **ogni singolo token**, la GPU deve leggere **tutti i pesi del modello** dalla VRAM. Il limite superiore teorico di token al secondo è quindi, in prima approssimazione:

$$\text{token/s} \approx \text{larghezza di banda della memoria (GB/s)} \div \text{dimensione del modello in memoria (GB)}$$

Esempio: un modello da 14 GB su una scheda con 1.800 GB/s produce un limite massimo di circa 128 token/s (in pratica, si raggiunge il 60–80% di questo valore). La stessa scheda con il doppio della larghezza di banda produrrebbe il doppio dei token. **I TFLOPS non compaiono in questa formula**. Questo è il motivo per cui H200 batte H100 pur avendo lo stesso chip.

Nota: la formula si applica alla **generazione** (la fase di *decode*). La fase di **prefill** (elaborazione del prompt di input, che è parallelizzabile su tutti i token insieme) è invece **compute-bound**: lì, i TFLOPS contano molto. Un carico di lavoro con prompt molto lunghi e risposte brevi ha un profilo completamente diverso da un chatbot conversazionale.

## 8.3 Criterio #3: Precisione numerica

Questo deve essere ben compreso, perché i produttori dichiarano i TFLOPS nella precisione che li fa apparire al meglio.

| Formato | Bit | Struttura                          | Uso tipico                                                                                                         |
|---------|-----|------------------------------------|--------------------------------------------------------------------------------------------------------------------|
| FP64    | 64  | 1 segno, 11 esponente, 52 mantissa | Simulazione scientifica.<br><b>Irrilevante per l'IA</b> — ma le GPU per datacenter ce l'hanno e le GPU consumer no |
| FP32    | 32  | 1+8+23                             | Precisione "completa" storica                                                                                      |

|                    |                                    |               |                                                                                                                                    |
|--------------------|------------------------------------|---------------|------------------------------------------------------------------------------------------------------------------------------------|
|                    |                                    |               | per il deep learning                                                                                                               |
| <b>TF32</b>        | 19 usati (in contenitore a 32 bit) | 1+8+10        | Formato Nvidia: range FP32, mantissa FP16. Accelerazione trasparente                                                               |
| <b>FP16</b>        | 16                                 | 1+5+10        | Classica mixed precision. Range dinamico ristretto → rischio di overflow/underflow, richiede loss scaling                          |
| <b>BF16</b>        | 16                                 | 1+8+7         | <i>Brain Float</i> : stesso range di FP32, meno mantissa. <b>Più robusto di FP16 nell'addestramento</b> , ora lo standard de facto |
| <b>FP8</b>         | 8                                  | E4M3 o E5M2   | Inferenza e (con cautela) addestramento su Hopper/Blackwell. Raddoppia il throughput e dimezza la memoria                          |
| <b>FP4 / NVFP4</b> | 4                                  | block scaling | Solo inferenza, su Blackwell e successivi. Raddoppia di nuovo. Richiede una quantizzazione accurata                                |

**La regola d'oro quando si leggono le schede tecniche:** un numero TFLOPS senza precisione specificata **non significa nulla**. E se leggete "con sparsity",

sappiate che questo numero è il **doppio** del numero reale in condizioni normali: presuppone una struttura di sparsity 2:4 nei pesi che la maggior parte dei modelli reali non ha. Nvidia lo dichiara sempre, in una piccola nota. **Dividete per due.**

#### 8.4 Criterio #4: Interconnessione

Se il carico di lavoro è **multi-GPU su un singolo modello**, l'interconnessione non è un dettaglio: è la differenza tra funzionare e non funzionare. Rivedere la sezione 4. Se il carico di lavoro è **multi-GPU con lavori indipendenti**, l'interconnessione è irrilevante e potete ignorarla completamente.

#### 8.5 Criterio #5: TDP, Potenza e Raffreddamento

Il **TDP** è la potenza di progetto termico. Deve essere moltiplicato per il numero di schede e aggiunto al resto del sistema; poi deve essere aggiunto un margine del 20-30% per i picchi transitori (le GPU moderne hanno picchi istantanei molto più alti del TDP nominale, e gli alimentatori sottodimensionati si spengono bruscamente). Poi deve essere risolto il problema di **dove va a finire quel calore**: una workstation con due 5090 sotto carico riscalda una stanza in un modo che nessuno che non l'abbia sperimentato può immaginare. E infine, deve essere calcolato il **costo dell'energia**:  $2 \text{ kW} \times 8 \text{ ore/giorno} \times 250 \text{ giorni} \times \text{€}0,30/\text{kWh} \approx \text{€}1.200/\text{anno}$  solo per l'elettricità, senza contare l'aria condizionata.

#### 8.6 Criterio #6: Costo per GB di VRAM

Una metrica grezza ma utile per un confronto iniziale. **[TUTTI I DATI VOLATILI]**

| Scheda                 | VRAM   | Prezzo Indicativo | €/GB                        |
|------------------------|--------|-------------------|-----------------------------|
| RTX 5090               | 32 GB  | ~€2.500           | ~€78/GB                     |
| RTX PRO 6000 Blackwell | 96 GB  | ~€9.000           | ~€94/GB                     |
| DGX Spark              | 128 GB | ~€4.000           | ~€31/GB (ma 6× meno banda!) |
| H100 PCIe              | 80 GB  | ~€25.000          | ~€310/GB                    |
| H200 SXM               | 141 GB | ~€35.000          | ~€250/GB                    |

Questa tabella dice due cose. Primo: **la DGX Spark è imbattibile per euro/GB, e terribile per euro/(GB/s)** — a conferma che è una macchina di sviluppo, non di produzione. Secondo: **le schede per datacenter costano 3-4 volte di più per GB rispetto alle schede professionali**, e si paga per ECC, HBM, NVLink, licenze e supporto. Se non si usa nessuna di queste quattro cose, **si paga per niente.**



### 8.7 Criterio #7: Comprare o Noleggiare?

Questa domanda dovrebbe essere posta prima di ogni altra, e la risposta dipende da un solo numero: **il fattore di utilizzo**.

Una GPU cloud costa (ordine di grandezza, **[VOLATILE]**) \$2–4/ora per una H100. In un anno di uso continuo, sono circa \$25.000 — che è **il prezzo di acquisto della scheda**. Quindi:

- **\*\*Utilizzo inferiore al 30-40%:\*\*** Noleggio. Punto. Comprare hardware che sta inattivo è bruciare capitale.
- **\*\*Utilizzo superiore al 60-70%, per almeno 18-24 mesi:\*\*** Comprare è conveniente, a condizione di poter gestire l'infrastruttura (e il costo include spazio, elettricità, raffreddamento, rete, manutenzione e il tempo di un amministratore di sistema).
- **\*\*Picchi imprevedibili:\*\*** Ibrido — hardware locale per la base, cloud per i picchi.
- **\*\*Dati sensibili / vincoli normativi (sanità, difesa, GDPR rigoroso):\*\*** L'hardware locale può essere obbligatorio indipendentemente dalla convenienza economica.

Un errore molto comune nelle piccole imprese: comprare una workstation da €20.000 per un progetto che dura due settimane al mese. Sarebbe costato €800 nel cloud.

### 8.8 Tabella decisionale: carico di lavoro → GPU consigliata

| Carico di lavoro                           | VRAM minima | Raccomandazioni                      | Alternativa economica                                       |
|--------------------------------------------|-------------|--------------------------------------|-------------------------------------------------------------|
| Apprendimento, corsi, tutorial             | 8–12 GB     | RTX 4060 Ti 16GB / RTX 5070          | Google Colab gratuito                                       |
| Stable Diffusion / generazione di immagini | 12–24 GB    | RTX 4090 / 5090                      | RTX 4070 Ti Super 16GB                                      |
| Inferenza LLM 7–14B quantizzata            | 8–16 GB     | RTX 4090 / 5090                      | Mac con Apple Silicon (memoria unificata)                   |
| Inferenza LLM 30–70B quantizzata           | 40–80 GB    | <b>RTX PRO 6000 Blackwell (96GB)</b> | 2× RTX 5090 con parallelismo di pipeline; DGX Spark (lento) |
| Fine-tuning LoRA/QLoRA su 7–               | 24–32 GB    | RTX 5090                             | RTX 4090 usata                                              |

|                                             |                |                                             |                                                                 |
|---------------------------------------------|----------------|---------------------------------------------|-----------------------------------------------------------------|
| 13B                                         |                |                                             |                                                                 |
| Fine-tuning LoRA su 70B                     | 80+ GB         | RTX PRO 6000 / H100                         | Cloud a ore                                                     |
| Fine-tuning completo 7B                     | 100+ GB        | H100 / H200 (o multi-GPU)                   | Cloud, sempre                                                   |
| Inferenza in produzione, throughput elevato | dipende        | <b>H200</b> (la larghezza di banda è tutto) | H100 se il budget è limitato                                    |
| Addestramento di un modello grande da zero  | migliaia di GB | HGX B200 / GB200 NVL72                      | Cloud. Sempre e solo cloud, a meno che non siate un hyperscaler |
| Sviluppo e prototipazione su modelli enormi | 128+ GB        | <b>DGX Spark</b>                            | Cloud a ore                                                     |
| Visione artificiale, YOLO, ASR, embedding   | 8–24 GB        | RTX 4090 / 5090                             | Qualsiasi RTX recente 12–16 GB                                  |
| Servizio di inferenza commerciale per terzi | dipende        | Qualsiasi <b>datacenter o RTX PRO</b>       | Nessuna: le GeForce sono escluse dall'EULA                      |

## 9. Errori tipici dell'acquirente

Li elenchiamo qui perché sono i più costosi e si ripresentano con impressionante regolarità.

**1. Acquistare due GPU pensando di poter sommare la VRAM.** Non succede.

Senza NVLink (e le schede consumer non ce l'hanno), due schede da 32 GB non fanno 64 GB per un singolo modello.

**2. Guardare i TFLOPS invece della VRAM e della larghezza di banda.** I TFLOPS sono il numero che il marketing vuole che tu guardi. Per l'inferenza LLM, sono quasi irrilevanti.

**3. Non rendersi conto che il numero dichiarato è "con sparsità".** Dimezzalo.

**4. Confondere H100 PCIe e H100 SXM.** Stesso nome, prestazioni molto diverse.

5. **Dimenticare la KV-cache nel dimensionamento.** Il modello si adatta, il servizio va in produzione, e al decimo utente concorrente, il server esplode.
  6. **Acquistare hardware per un utilizzo del 15%.** Il cloud esisteva.
  7. **Ignorare l'EULA sul datacenter.** Costruire un prodotto commerciale su GeForce è un rischio legale che nessun investitore serio accetterà durante la due diligence.
  8. **Sottovalutare potenza e calore.** Il progetto di workstation a 4 GPU quasi sempre muore al contatore elettrico, non sul budget.
  9. **Acquistare il DGX Spark aspettandosi velocità.** È una macchina di sviluppo. La larghezza di banda è di 270 GB/s. Rileggi la sezione 5.2.
  10. **Non considerare l'architettura ARM.** Se acquisti un sistema Grace/Vera, verifica che il tuo stack esista per aarch64 **prima** di firmare.
  11. **Acquistare "l'ultima generazione" per principio.** Se il tuo carico di lavoro è l'inferenza su modelli medi, una A100 usata o una H100 di seconda mano ti daranno un rapporto prezzo/prestazioni che nessuna nuova scheda può avvicinare.
- 

## Riepilogo Operativo — Lista di Controllo per la Scelta di una GPU AI

Segui l'ordine. Non saltare i passaggi: ognuno può chiudere la decisione da solo.

### Passaggio 1 — Definisci il carico di lavoro, per iscritto.

- ☐ Solo addestramento, fine-tuning o inferenza?
- ☐ Quale modello, quanti parametri, a quale precisione?
- ☐ Quale lunghezza del contesto e quante richieste concorrenti al picco?
- ☐ È un progetto una tantum o un servizio continuo?

### Fase 2 — Calcolare la VRAM necessaria.

- ☐  $\text{Pesi} = \text{parametri} \times \text{byte/parametro} (4 / 2 / 1 / 0.5)$
- ☐ Se in addestramento:  $\times 8\text{--}10$  per ottimizzatore e gradienti (o usare LoRA/QLoRA)

- [ ] Aggiungere attivazioni ( $\propto$  dimensione del batch) e KV-cache ( $\propto$  contesto  $\times$  concorrenza)
- [ ] Aggiungere un **margine del 20%**
- [ ]  $\rightarrow$  Questo numero è il **filtro eliminatorio**. Tutto ciò che è inferiore è escluso.

### **Fase 3 — Decidere se acquistare o noleggiare.**

- [ ] Utilizzo previsto inferiore al 40%  $\rightarrow$  **cloud**, fine della discussione
- [ ] Vincoli di privacy/regolamentari che proibiscono il cloud  $\rightarrow$  **on-premises**, a qualsiasi costo
- [ ] Utilizzo superiore al 60% per più di 18 mesi  $\rightarrow$  valutare l'acquisto, includendo elettricità, spazio, raffreddamento e ore-uomo nel TCO

### **Fase 4 — Verificare se è necessaria una configurazione multi-GPU su un singolo modello.**

- [ ] Se **sì** (parallelismo tensoriale, addestramento distribuito)  $\rightarrow$  è necessario **NVLink**  $\rightarrow$  si è nel mondo SXM/datacenter. Le schede consumer sono escluse.
- [ ] Se **no** (lavori indipendenti, un modello per GPU)  $\rightarrow$  si può rimanere su PCIe e schede consumer/pro, risparmiando un ordine di grandezza.

### **Fase 5 — Verificare il vincolo di licenza.**

- [ ] Il calcolo sarà venduto o noleggiato a terzi?  $\rightarrow$  **GeForce esclusa**. È necessaria una RTX PRO o datacenter.
- [ ] Uso interno o ricerca?  $\rightarrow$  GeForce consentita.

### **Fase 6 — Verificare la larghezza di banda, non solo la capacità.**

- [ ] Il carico di lavoro è inferenza generativa?  $\rightarrow$  la **larghezza di banda della memoria** è il predittore delle prestazioni. Stima:  $\text{token/s} \approx \text{larghezza di banda} \div \text{dimensione del modello}$ .
- [ ] Il carico di lavoro è prefill lungo o addestramento?  $\rightarrow$  allora i **TFLOPS** (alla giusta precisione!) contano davvero.

### **Fase 7 — Verificare la compatibilità del sistema.**

- [ ] Alimentatore: TDP totale + 30% di margine

- [ ] Sufficienti linee PCIe CPU/chipset per il numero di schede (x16 o almeno x8 per scheda)
- [ ] Spazio fisico nel case e flusso d'aria effettivo
- [ ] Linea elettrica: sopra i 2 kW continui, in Italia è necessaria una seria considerazione del contatore
- [ ] Architettura della CPU: se Grace/Vera, il tuo software esiste per **\*\*aarch64\*\***?

### **Fase 8 — Scegliere per fascia di prezzo.**

- [ ] **\*\*Entry (< €3.000):\*\*** RTX 5070 Ti / 5080, o RTX 4090 usata. Per apprendimento, visione artificiale, LLM piccoli. In alternativa: **\*\*nessun hardware e €500 di cloud.\*\***
- [ ] **\*\*Mid (€3.000–12.000):\*\*** RTX 5090 (una o due), o DGX Spark se il vincolo è la capacità e non la velocità. Copre il 90% delle reali esigenze di un professionista o di una PMI.
- [ ] **\*\*High-end (€15.000–30.000):\*\*** RTX PRO 6000 Blackwell (una o due, per 96/192 GB), o una H100/H200 PCIe se sono necessarie licenza datacenter e larghezza di banda HBM. Questa è la fascia in cui una PMI può fare seria AI in-house.
- [ ] **\*\*Datacenter (€100.000 +):\*\*** nodo HGX H200/B200. A questo punto, si ha un team dedicato e un ufficio acquisti, e questo capitolo serve solo a porre le domande giuste al proprio fornitore.

### **Fase 9 — Prima di firmare.**

- [ ] Hai controllato i prezzi **\*\*oggi\*\***, e non su questa pagina?
- [ ] Hai controllato i tempi di consegna effettivi (non quelli dichiarati)?
- [ ] Hai testato il tuo carico di lavoro esatto su quella GPU **\*\*nel cloud, per un'ora\*\***, prima di acquistarla? Questo è l'unico consiglio con il miglior rapporto valore/costo in tutto il capitolo: **\*\*€20 di cloud possono farti risparmiare €20.000 di errore.\*\***

---

*Nota finale sulla volatilità dei dati: architetture, prezzi e disponibilità in questo settore cambiano su base trimestrale. Le architetture, i principi di dimensionamento e i criteri di selezione descritti in questo capitolo rimangono validi; i numeri specifici devono essere riverificati alla data della decisione.*

## Capitolo 12 - GPU AMD Instinct per l'AI e il confronto Nvidia vs. AMD nel Datacenter

***Nota sui Dati.** Questo capitolo tocca il segmento hardware più volatile dell'intera industria IT. Le architetture si succedono annualmente, i prezzi non hanno un listino pubblico e sono negoziati contratto per contratto, e le roadmap vengono riscritte ogni sei mesi. Tutti i numeri riportati sono aggiornati a metà 2026, e laddove il dato è intrinsecamente instabile (prezzi, disponibilità, generazioni non ancora spedite in volume), lo marco esplicitamente con la dicitura **[DATO VOLATILE]**. Al momento della stesura: MI300X e MI325X sono prodotti maturi e ampiamente disponibili; la serie MI350 (MI350X/MI355X) è in produzione da metà 2025; e la serie MI400 con la piattaforma rack-scale "Helios" è stata svelata al CES di gennaio 2026, con volumi attesi nella seconda metà del 2026. Lato Nvidia, Blackwell (B200/GB200) e Blackwell Ultra (B300/GB300) sono sul campo, mentre Vera Rubin (VR200) è entrata in produzione con spedizioni in volume attese nella seconda metà del 2026. Il metodo di ragionamento, tuttavia – come leggere un datasheet, come valutare un acceleratore, quali errori evitare – rimarrà valido molto più a lungo dei numeri.*

---

### 1. La Linea AMD Instinct

#### 1.1 Cos'è, in termini elementari

Quando parliamo di "GPU" (Graphics Processing Unit), la nostra mente va subito alla scheda video infilata nello slot PCIe del PC, con le ventole e un'uscita HDMI. Le AMD Instinct non sono quello. Sono processori acceleratori che condividono il DNA architetturale con le schede video – migliaia di unità di calcolo parallele che eseguono la stessa istruzione su molti dati diversi – ma hanno dismesso tutto ciò che serve a disegnare pixel: non hanno uscite video, non hanno unità di rasterizzazione, e (nelle generazioni recenti) non hanno motori di ray tracing. Sono macchine da moltiplicazione matriciale, e nient'altro.

La linea Instinct è stata lanciata nel 2016 come risposta di AMD alla linea Tesla di Nvidia (poi semplicemente ribattezzata "Data Center GPU"). Per molti anni, è stata una risposta debole: hardware onesto, software inutilizzabile, quota di mercato irrilevante. La svolta è arrivata nel 2023-2024, quando la scarsità globale di acceleratori per l'AI generativa ha improvvisamente reso interessante il secondo

fornitore – e AMD si è trovata, per la prima volta, con un prodotto (MI300X) che, su una metrica cruciale, la memoria di bordo, batteva il campione del mondo.

**Definizione di due acronimi che useremo continuamente.** *HBM* (High Bandwidth Memory) è DRAM impilata verticalmente in torri di più die, saldata sullo stesso substrato del processore e connessa ad esso con bus molto ampi (migliaia di tracce). È molto costosa, consuma molta energia, ma offre una banda passante di un ordine di grandezza superiore rispetto alle GDDR delle schede da gaming. *TDP* (Thermal Design Power) è la potenza in watt che il sistema di raffreddamento deve essere in grado di dissipare continuamente; AMD nel datacenter usa più spesso il termine *TBP* (Total Board Power), che include l'intera scheda, memoria inclusa. Nel resto del capitolo, li tratterò come sinonimi pratici, perché su questi prodotti quasi sempre coincidono.

## 1.2 Posizionamento: Perché AMD Esiste in Questo Mercato

La posizione di Instinct può essere spiegata con una sola frase: **nessun acquirente razionale vuole un unico fornitore per la voce di spesa più grande del proprio budget**. Nel 2024-2026, un cluster di addestramento AI costa più dell'immobile che lo ospita, e Nvidia detiene una quota di mercato che, a seconda di come vengono contate le TPU di Google, varia tra l'80% e il 90%. Hyperscaler (Microsoft, Meta, Oracle, Amazon), laboratori di frontiera e governi hanno un enorme interesse strategico nell'esistenza di un secondo fornitore credibile: non necessariamente per acquistare in blocco, ma per **avere potere negoziale** ed evitare di essere ostaggi di un listino prezzi e di un programma di consegna decisi da terzi.

AMD sta giocando esattamente questa partita, e la sta giocando su tre leve:

1. **Più memoria per GPU.** Questa è la leva principale, quella su cui AMD ha costruito la sua intera narrazione dal 2023. Se un modello con 70 miliardi di parametri entra in una singola GPU invece di due, l'architettura del servizio si semplifica, il costo di comunicazione tra le due GPU scompare, e il costo per token servito crolla.
2. **Prezzo inferiore per unità di memoria e per FLOP.** AMD non può permettersi il premium di Nvidia, perché il software è inferiore: deve scontare. Questo sconto ha un nome preciso — *ecosystem discount* — e lo analizzeremo nella sezione 4.
3. **Standard aperti.** Dove Nvidia ha NVLink (proprietario), AMD spinge UALink (consorzio); dove Nvidia ha InfiniBand, AMD spinge Ultra Ethernet; dove Nvidia ha CUDA (proprietario), AMD ha ROCm (open source). Questa è solo apparentemente una scelta ideologica: è la classica strategia

dello sfidante che cerca di rendere una commodity il terreno su cui il leader ha costruito il suo fossato.

### 1.3 CDNA vs. RDNA: Perché Due Architetture Separate

Fino al 2018, AMD aveva una sola architettura GPU, GCN (Graphics Core Next), utilizzata sia per il gaming che per il calcolo. Era un compromesso e, come tutti i compromessi, non eccelleva in nessun campo: portava silicio dedicato alla grafica nel datacenter che nessuno usava, e portava un'enfasi sul calcolo in doppia precisione nel gaming che nessun videogioco ha mai richiesto.

Nel 2019, AMD ha fatto la scelta strutturale che ancora oggi definisce il suo portfolio: **biforcare l'architettura**.

- **\*\*RDNA\*\*** (Radeon DNA) è la linea *\*consumer/grafica\**. Ottimizzata per la latenza, il rendering in tempo reale, il ray tracing e il consumo energetico entro i 350-600 W di una scheda desktop. Utilizza memoria GDDR. Questo è ciò che si trova nelle serie Radeon RX 7000/9000.
- **\*\*CDNA\*\*** (Compute DNA) è la linea *\*datacenter/calcolo\**. Ottimizzata per il throughput puro, piena di unità matriciali (i *\*Matrix Cores\**, l'equivalente funzionale dei Tensor Cores di Nvidia), affamata di larghezza di banda della memoria, alimentata da HBM, progettata per essere inserita in uno chassis server raffreddato da aria in ingresso a 40 °C o liquido.

**Perché è la scelta giusta.** Un die di silicio è un budget di area finito. Ogni millimetro quadrato speso in unità di rasterizzazione è un millimetro quadrato non speso in Matrix Cores. Per un cliente che acquista 8.192 acceleratori per addestrare un modello linguistico, ogni transistor dedicato alla grafica è denaro bruciato e watt sprecati. Nvidia fa esattamente la stessa cosa, meno esplicitamente: il die GB100 del datacenter Blackwell e il die GB202 della GeForce RTX 5090 sono chip completamente diversi, con la stessa etichetta commerciale "Blackwell".

**Conseguenza pratica per il lettore.** Una Radeon RX 7900 XTX e una Instinct MI300X non sono "la stessa cosa in due taglie". Sono parenti lontane. Il codice ottimizzato per una non è automaticamente veloce sull'altra, le funzionalità di basso livello differiscono (RDNA ha wavefront a 32 thread, CDNA a 64), e persino il supporto ROCm segue tempistiche diverse. **Errore tipico dell'acquirente: pensare "provo ROCm sulla mia Radeon e poi scalo su Instinct"**. Il codice è portabile, ma le performance e i kernel ottimizzati no.



## 1.4 Come leggere la nomenclatura Instinct

L'acronimo è più semplice di quello Nvidia. Prendiamo `MI355X`:

| Elemento            | Significato                                                                                                                                       |
|---------------------|---------------------------------------------------------------------------------------------------------------------------------------------------|
| `MI`                | "Machine Intelligence." Marchio di famiglia, invariato dal 2016.                                                                                  |
| `3` (prima cifra)   | <b>Generazione/serie.</b> MI100 → CDNA1, MI200 → CDNA2, MI300 → CDNA3, MI350 → CDNA4, MI400 → CDNA5.                                              |
| `5` (seconda cifra) | <b>Posizione nella serie.</b> MI300 è il capostipite, MI325 e MI350 sono i "refresh" incrementali (tipicamente più memoria o memoria più veloce). |
| `5` (terza cifra)   | Variante di prodotto all'interno della stessa famiglia (MI350X vs MI355X: stesso silicio, diverso envelope termico e raffreddamento).             |
| `X` (suffisso)      | Variante di fascia alta, tipicamente <b>solo GPU</b> , per carichi di lavoro AI/HPC.                                                              |
| `A` (suffisso)      | Variante <b>APU</b> : core CPU x86 e core GPU con memoria unificata coesistono sullo stesso package (es. MI300A).                                 |

Il suffisso è la parte più confusionaria: `X` = acceleratore puramente GPU; `A` = ibrido CPU+GPU. Nella serie MI400, AMD ha introdotto una terza dimensione di specializzazione, non più solo termica ma **funzionale** (vedi §2.6): MI430X per HPC ad alta precisione, MI440X/MI455X per AI a bassa precisione.

---

## 2. Le schede, una per una

Prima di entrare nel dettaglio, tre definizioni che verranno usate in ogni descrizione di scheda.

**OAM** (OCP Accelerator Module) è il formato fisico standardizzato dall'Open Compute Project per gli acceleratori da datacenter: un modulo rettangolare, senza dissipatore proprio, senza connettori di alimentazione a cavo, che si avvita su una baseboard (UBB, Universal Baseboard) tipicamente capace di ospitare otto di essi. È l'equivalente aperto del formato proprietario SXM di Nvidia. Un modulo OAM **non si può comprare e installare in un PC**: si compra all'interno di un server, punto.

**PCIe** (Peripheral Component Interconnect Express) è il bus di sistema standard. Esistono versioni PCIe delle GPU da datacenter, sotto forma di scheda add-in a doppio slot, ma sono sempre versioni depotenziate (meno watt, meno banda tra GPU) e servono casi di nicchia, non cluster seri.

**FLOPS** (Floating Point Operations Per Second) è la metrica di calcolo grezzo. Va sempre letta in congiunzione con: (a) la **precisione** (FP64, FP32, FP16, BF16, FP8, FP6, FP4 — meno bit, più operazioni al secondo, meno accuratezza numerica); (b) se il numero è **denso** o **sparso** (con la sparsità strutturata, i produttori raddoppiano il numero dichiarato: due numeri di "PFLOPS" possono differire di 2× solo per questo, ed è il trucco di marketing più comune nel settore).

## 2.1 MI250X (CDNA2, 2021) — il capitolo storico

**Descrizione e funzione.** La MI250X è la scheda che ha dato ad AMD la sua prima vera vittoria simbolica nel supercomputing. Architettura CDNA2, prodotta a 6 nm da TSMC, adotta un design **MCM** (Multi-Chip Module): due die GPU completi — chiamati GCD, Graphics Compute Die — affiancati sullo stesso package e connessi tramite Infinity Fabric.

| Specifiche           | Valore                             |
|----------------------|------------------------------------|
| Architettura         | CDNA2, TSMC 6 nm                   |
| Configurazione       | 2 GCD × 110 CU = 220 Compute Units |
| Memoria              | 128 GB HBM2e                       |
| Larghezza di banda   | ~3.2 TB/s                          |
| Vettore/Matrice FP64 | ~47.9 / ~95.7 TFLOPS               |
| Matrice FP16         | ~383 TFLOPS                        |
| TBP                  | 500-560 W                          |
| Fattore di forma     | OAM                                |

**La debolezza architetturale, ed è didatticamente importante.** I due GCD **non erano visti dal software come una singola GPU**: il sistema operativo vedeva due dispositivi distinti. I programmatori dovevano gestire esplicitamente la partizione del lavoro tra le due metà. Questo è esattamente il problema che AMD risolverà con MI300X, dove il design a chiplet diventa trasparente al programmatore. Ricordate questa distinzione: *chiplet visibile* vs *chiplet trasparente* è una delle differenze concettuali più importanti tra CDNA2 e CDNA3.

**Caso d'uso storico: Frontier.** Il supercomputer Frontier presso l'Oak Ridge National Laboratory (USA), operativo dal 2022, è stata la prima macchina al

mondo a superare ufficialmente gli exaFLOPS in doppia precisione ( $10^{18}$  operazioni al secondo in FP64). È costruito con oltre 37.000 MI250X accoppiati a CPU EPYC. Frontier è la prova che AMD era già in grado di realizzare hardware HPC di prima classe *prima* dell'ondata dell'IA: il problema di AMD non è mai stato il silicio, è sempre stato il software (§4).

**Prezzo indicativo. [DATI VOLATILI]** Fuori produzione per il nuovo mercato; i moduli si possono trovare sul mercato dell'usato/dismissione per qualche migliaio di euro. **Non compratelo.** 128 GB di HBM2e sembrano molti, ma senza il supporto FP8 e con uno stack software di quella generazione, è un vicolo cieco per l'IA moderna.

## 2.2 MI300X (CDNA3, fine 2023) — la scheda che ha cambiato la conversazione

Questa è la scheda che ha reso AMD rilevante nell'IA, e merita la discussione più lunga.

**Il design a chiplet 3.5D.** L'MI300X è, dal punto di vista dell'ingegneria del packaging, uno dei chip più complessi mai prodotti. Non è un die monolitico: è una torre.

- Alla base ci sono **4 IOD** (I/O Die, prodotti a 6 nm): contengono i controller di memoria, la cache condivisa (256 MB di "Infinity Cache") e il fabric di interconnessione interno.
- Sopra gli IOD, saldati con tecnologia di **hybrid bonding** (connessione diretta rame-rame, senza microbump, che consente una densità di connessione e latenze molto migliori), ci sono **8 XCD** (Accelerator Complex Die, a 5 nm), per un totale di **304 Compute Units attive**.
- Intorno a essi, su un interposer, **8 stack HBM3** per un totale di **192 GB**.
- Tutto questo per circa **153 miliardi di transistor**.

La parola chiave è "3.5D": stacking verticale (3D, XCD sopra IOD) combinato con posizionamento orizzontale affiancato su un interposer (2.5D, stack HBM accanto al complesso logico).

**Perché è importante.** A differenza dell'MI250X, qui i chiplet sono **trasparenti al software**: PyTorch vede *una* GPU con 192 GB. Il costo di questa trasparenza è pagato nell'hardware, dall'Infinity Fabric interno e dalla cache condivisa.

| Specifiche   | MI300X                            |
|--------------|-----------------------------------|
| Architettura | CDNA3 (XCD da 5 nm + IOD da 6 nm) |

|                    |                                                                 |
|--------------------|-----------------------------------------------------------------|
| Compute Units      | 304                                                             |
| Memoria            | <b>192 GB HBM3</b>                                              |
| Larghezza di banda | <b>5.3 TB/s</b>                                                 |
| FP16/BF16 (denso)  | ~1.3 PFLOPS                                                     |
| FP8 (denso)        | ~2.6 PFLOPS                                                     |
| Matrice FP64       | ~163 TFLOPS                                                     |
| TBP                | 750 W                                                           |
| Fattore di forma   | OAM (piattaforma a 8 GPU); esiste anche una nicchia MI300X PCIe |

**Il vantaggio della VRAM su H100: cosa significa realmente.** L'H100 SXM di Nvidia, suo diretto contemporaneo, ha 80 GB di HBM3 con 3,35 TB/s. Il MI300X ha **192 GB con 5,3 TB/s**: 2,4 volte la capacità, 1,6 volte la banda. Tradotto in pratica:

- Un modello da 70 miliardi di parametri in FP16 occupa ~140 GB solo per i pesi. Su H100, sono necessarie **\*\*due\*\*** GPU (con tutte le complicazioni del *\*tensor parallelism\**, cioè lo splitting delle matrici tra GPU, che introduce comunicazione ad ogni layer). Su MI300X, **\*\*una\*\*** è sufficiente, e rimangono ~50 GB per la KV cache (la key-value cache, che è la memoria del contesto già processato, che cresce linearmente con lunghezza del contesto × numero di richieste concorrenti).
- Una piattaforma 8-MI300X offre **\*\*1,5 TB di HBM aggregata\*\*** contro i 640 GB di un nodo 8-H100. Per l'inferenza di modelli enormi (un DeepSeek o un Llama 405B in FP8), questa è la differenza tra "ci sta in un nodo" e "devo distribuirlo su due nodi via rete", che è un salto significativo in complessità e latenza.
- **\*\*L'inferenza di LLM durante la generazione è \*memory-bound\*, non \*compute-bound\*.** Questa frase andrebbe memorizzata. Per generare un token, la GPU deve leggere *\*tutti\** i pesi del modello dalla memoria. Il collo di bottiglia è la banda di memoria, non le unità di calcolo, che rimangono in gran parte inattive. Ne consegue che **\*\*la banda HBM predice la velocità di generazione meglio dei TFLOPS di picco\*\***. Ed è proprio questa l'area in cui AMD è competitiva.

**Prezzo indicativo. [DATI VOLATILI]** AMD non pubblica listini. Le stime di mercato per il MI300X in volume sono state nell'ordine di **\$10.000-\$15.000 per modulo** rispetto ai \$25.000-\$40.000 chiesti per un H100 SXM al picco della scarsità. Sul cloud, il noleggio orario di un MI300X è stato **15-40% inferiore** a

quello di un H100 comparabile. Consideratelo un ordine di grandezza, non un prezzo.

**Casi d'uso.** Inferenza LLM ad alto volume; fine-tuning di modelli medio-grandi; HPC misto (forte in FP64). Meno adatto per: ricerca che dipende da custom CUDA kernel di terze parti (\$4).

### 2.3 MI300A (l'APU) ed El Capitan

Il MI300A è la variante concettualmente più interessante e commercialmente più di nicchia. Prende il MI300X, rimuove due XCD (lasciando 6 XCD, 228 CU) e al loro posto mette **tre chiplet CCD con 24 core Zen 4** (la stessa CPU di EPYC). Aggiunge **128 GB di HBM3 condivisa in modo coerente tra CPU e GPU**.

**Cosa significa "coherent unified memory" e perché è un grosso problema.** Nel modello classico, la CPU ha la sua RAM e la GPU ha la sua VRAM. Per calcolare sulla GPU, i dati devono essere *copiati* dalla RAM alla VRAM tramite il bus PCIe, il calcolo eseguito, e poi copiati indietro. Nei carichi di lavoro HPC con molte fasi CPU/GPU alternate, questa copia domina il tempo di esecuzione ed è la fonte più comune di codice lento. Nel MI300A, **non c'è copia**: CPU e GPU vedono gli stessi indirizzi fisici sulla stessa HBM, con la coerenza mantenuta dall'hardware. Un'intera classe di ottimizzazioni (e bug) viene eliminata.

**TBP:** ~550 W nominali, fino a 760 W in configurazione boost. **Fattore di forma:** socket/OAM in nodi dedicati.

**El Capitan.** Il supercomputer del Lawrence Livermore National Laboratory, operativo da fine 2024, costruito su MI300A, è diventato il sistema più veloce al mondo nella lista TOP500, superando 1,7 exaFLOPS FP64 (**[DATI VOLATILI]**: le classifiche cambiano ogni sei mesi). È la seconda dimostrazione, dopo Frontier, che nel calcolo scientifico "vero", AMD non è il secondo vendor: è *il* vendor.

**Errore tipico.** Guardare la MI300A e pensare "128 GB unificati, perfetti per l'AI". No: per l'AI pura, la MI300X con 192 GB di memoria solo GPU è quasi sempre la scelta migliore. La MI300A eccelle nei codici HPC misti CPU/GPU (fluidodinamica, simulazione nucleare, meteo), dove la coerenza della memoria è più preziosa della capacità.

## 2.4 MI325X (aggiornamento CDNA3, fine 2024/2025)

Questa non è una nuova architettura: è **lo stesso silicio CDNA3 della MI300X con memoria migliore**. È un classico "aggiornamento di metà ciclo" e dovrebbe essere inteso come tale.

| Specifiche         | MI325X              | (per confronto) MI300X |
|--------------------|---------------------|------------------------|
| Architettura       | CDNA3               | CDNA3                  |
| Memoria            | <b>256 GB HBM3e</b> | 192 GB HBM3            |
| Larghezza di banda | <b>~6.0 TB/s</b>    | 5.3 TB/s               |
| Calcolo (FP8/FP16) | invariato           | —                      |
| TBP                | <b>1.000 W</b>      | 750 W                  |

**Posizionamento rispetto a H200.** L'H200 è, analogamente, l'H100 con HBM3e: **141 GB a 4.8 TB/s**, 700 W. Il confronto è quindi 256 GB vs 141 GB e 6.0 vs 4.8 TB/s: AMD mantiene il vantaggio di capacità (1.8×) e aggiunge un vantaggio di larghezza di banda (1.25×), pagando con 300 W in più per modulo.

**Il punto chiave.** Il salto MI300X → MI325X è **+33% di memoria e +13% di larghezza di banda con +33% di potenza, senza alcun guadagno computazionale**. Questo è un aggiornamento che ha senso *solo* se il tuo collo di bottiglia è la memoria — cioè, ancora una volta, se stai facendo inferenza LLM. Se stai addestrando, la MI325X ti offre quasi nulla in più rispetto alla MI300X. **Errore tipico: acquistare l'aggiornamento perché il numero è più grande, senza aver profilato il proprio carico di lavoro.**

## 2.5 MI350X / MI355X (CDNA4, metà 2025)

Qui AMD cambia veramente architettura. CDNA4 su un processo a 3 nm, e soprattutto: **supporto nativo per FP6 e FP4**.

**Cosa sono FP8, FP6, FP4 e perché sono la novità.** Questi sono formati di numeri in virgola mobile a bassissima precisione: rispettivamente 8, 6 e 4 bit per numero, rispetto a 16 per FP16/BF16. Meno bit significano contemporaneamente tre cose: (1) il modello occupa meno memoria (un modello da 70B in FP4 pesa ~35 GB invece di 140); (2) meno byte da leggere dalla memoria per token generato, quindi **inferenza più veloce sul percorso limitato dalla memoria**; (3) le unità di matrice completano più operazioni per ciclo. Il costo è una perdita di accuratezza numerica, che può essere mitigata con sofisticate tecniche di quantizzazione (scale a blocchi, calibrazione, formati di "microscaling" come MXFP4/MXFP6). Il

punto è che dal 2025 in poi, **la valuta dell'inferenza è FP4**, motivo per cui sia AMD (CDNA4) che Nvidia (Blackwell) hanno costruito silicio dedicato.

| Specifiche         | MI350X                | MI355X                            |
|--------------------|-----------------------|-----------------------------------|
| Architettura       | CDNA4, TSMC 3 nm      | CDNA4, TSMC 3 nm                  |
| Memoria            | 288 GB HBM3e          | 288 GB HBM3e                      |
| Larghezza di banda | ~8 TB/s               | ~8 TB/s                           |
| FP8 (denso)        | ~5 PFLOPS             | ~5 PFLOPS                         |
| FP4/FP6 (denso)    | ~9-10 PFLOPS          | ~10 PFLOPS                        |
| FP64               | ~72 TFLOPS            | ~79 TFLOPS                        |
| TBP                | <b>1.000 W (aria)</b> | <b>1.400 W (liquido)</b>          |
| Raffreddamento     | raffreddato ad aria   | <b>solo raffreddato a liquido</b> |

**La differenza MI350X/MI355X è, essenzialmente, il raffreddamento.** Stesso silicio: la MI350X si adatta a un involucro raffreddato ad aria da 1.000 W e si inserisce nei data center esistenti; la MI355X spinge a 1.400 W ma **richiede raffreddamento a liquido** e quindi un data center attrezzato. Chi ha piastre fredde ottiene la MI355X e guadagna frequenze e throughput; chi ha solo aria ottiene la MI350X. **Questa è la prima volta in questo libro che il vincolo della \*struttura\* — non il chip — determina quale prodotto si può acquistare.** D'ora in poi, sarà sempre così.

**Confronto dichiarato con Blackwell.** AMD posiziona MI355X contro B200/B300 di Nvidia. I 288GB di HBM3e del MI355X corrispondono esattamente ai 288GB del B300 (Blackwell Ultra), e la larghezza di banda è equivalente (~8 TB/s). Il vantaggio di capacità che AMD aveva contro H100 è **svanito**: Nvidia ha risposto. Sui FLOPS FP4, il B300 dichiara ~15 PFLOPS densi contro i ~10 del MI355X: Nvidia è in vantaggio sulla potenza di calcolo grezza. **[DATI VOLATILI]** Nei benchmark MLPerf Inference indipendenti pubblicati nella primavera del 2026, il MI355X ha ottenuto il miglior risultato di sempre per AMD, posizionandosi a pochi punti percentuali dal B200 nei carichi di lavoro di inferenza server — un risultato che sarebbe stato impensabile due anni prima.

**Prezzo indicativo. [DATI VOLATILI]** Ordine di grandezza \$25.000-\$35.000 per modulo in volume, tipicamente venduto solo come piattaforma a 8 GPU. Un nodo completo a 8-MI355X con CPU EPYC, rete e chassis è nell'ordine di **centinaia di migliaia di euro**.

## 2.6 La serie MI400 e la piattaforma Helios (2026)

[SEZIONE INTERAMENTE VOLATILE — dati dagli annunci del CES 2026, prodotto non ancora spedito in volume al momento della stesura.]

Questo è il salto generazionale più ambizioso mai tentato da AMD, e cambia la natura stessa del prodotto: **AMD smette di vendere GPU e inizia a vendere rack.**

**La serie MI400 (CDNA 5, TSMC 2 nm)** per la prima volta presenta varianti *funzionalmente* diverse:

| Modello | Obiettivo                                | Caratteristica distintiva                                                                                                                                                                                                                 |
|---------|------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| MI455X  | Addestramento e inferenza su larga scala | Il fiore all'occhiello. ~320 miliardi di transistor, <b>432 GB HBM4</b> , ~19.6 TB/s, ~40 PFLOPS FP4 / ~20 PFLOPS FP8. Ottimizzato per bassa precisione (FP4/FP8/BF16).                                                                   |
| MI440X  | Enterprise on-premise                    | Progettato per il server "normale" a 8 GPU da collocare in un rack aziendale esistente, non per la scala di rack.                                                                                                                         |
| MI430X  | HPC e "AI sovrana"                       | <b>Mantiene FP32/FP64 completi.</b> Questa è la variante per il calcolo scientifico e per gli stati che desiderano i dati all'interno dei propri confini. Destinato a supercomputer come Discovery (Oak Ridge) e Alice Recoque (Francia). |

**La logica della specializzazione deve essere ben compresa**, perché è una tendenza generale nel settore: separando la variante AI (che non necessita di FP64) dalla variante HPC (che ne ha disperatamente bisogno), AMD **elimina la logica ridondante dal die** e migliora la sua efficienza energetica e il costo. Nvidia



sta facendo la stessa cosa in un modo diverso (con il Rubin CPX specializzato nel *prefill*). L'era della "GPU generalista che fa tutto bene" sta finendo.

**Helios.** Questo è il rack. Non è un server: è un cabinet a doppia larghezza, integrato, raffreddato a liquido che AMD vende come unità di calcolo indivisibile:

- **72 acceleratori MI455X** + CPU **EPYC "Venice"** (Zen 6) + NIC (Network Interface Card) Pensando "Vulcano" da 800G;
- **31 TB di HBM4 aggregata**, con **1.4 PB/s** di larghezza di banda di memoria totale;
- **~2.9 exaFLOPS FP4** per l'inferenza e **~1.4 exaFLOPS FP8** per l'addestramento per rack;
- i requisiti di consumo energetico e di raffreddamento rendono necessario un datacenter di nuova generazione (nell'ordine di **centinaia di kW per rack**).

**Perché AMD ha dovuto costruire un rack.** Perché Nvidia lo ha fatto per prima (GB200 NVL72) e ha spostato il campo di battaglia. Quando 72 GPU sono cablate in un unico dominio di memoria coerente, il cliente non confronta più "GPU contro GPU": confronta "rack contro rack", e chi non ha un rack non è in gara. La roadmap continua con la **serie MI500 su CDNA 6 e HBM4E annunciata per il 2027**.

---

### 3. L'interconnessione AMD

#### 3.1 Il problema, prima della soluzione

Una singola GPU non può addestrare un modello di frontiera. Ne servono migliaia, e devono scambiarsi continuamente dati: in ogni passo di addestramento distribuito, alla fine del calcolo dei gradienti, tutte le GPU devono sommare i propri gradienti con quelli di tutte le altre (un'operazione che si chiama *all-reduce*). Se questo scambio è lento, le GPU restano inattive ad aspettare, e tu stai pagando 40.000 € a scheda per farle riposare.

Da qui la distinzione fondamentale, che vale per entrambi i produttori:

- **Scale-up** (interconnessione "verticale", all'interno del nodo o all'interno del rack): pochi dispositivi, latenza bassissima, banda enorme, memoria condivisa in modo coerente. Questo è il dominio di NVLink e Infinity Fabric.

- **\*\*Scale-out\*\*** (interconnessione "orizzontale", tra nodi e tra rack): tanti dispositivi, usando una vera e propria rete (InfiniBand o Ethernet). La banda è un ordine di grandezza inferiore, la latenza è più alta.

La regola universale di progettazione: **mantenere il traffico più intenso all'interno del dominio scale-up e uscire in scale-out il meno possibile.**

### 3.2 Infinity Fabric e la piattaforma OAM a 8 GPU

**Infinity Fabric** (IF) è il *fabric* di interconnessione proprietario di AMD, nato nel 2017 con Zen per connettere i *chiplet* della CPU e poi esteso a ogni cosa: *chiplet-to-chiplet* all'interno del *package*, CPU-to-GPU sul *socket*, GPU-to-GPU sulla *baseboard*.

Nella piattaforma Instinct standard — **8 moduli OAM su una UBB** — le 8 GPU sono connesse tra loro da link Infinity Fabric in una topologia **all-to-all**: ogni GPU ha una connessione diretta con ognuna delle altre sette. Questo è architettonicamente elegante e ha un vantaggio pratico: **non serve un chip switch dedicato**. Nvidia, per ottenere lo stesso risultato, usa **NVSwitch**, chip di switching aggiuntivi.

- **\*\*Il vantaggio AMD:\*\*** meno silicio, meno costi, meno consumo energetico, topologia semplice.
- **\*\*La limitazione AMD:\*\*** un *\*all-to-all\** non scala. Funziona perfettamente con 8 GPU. Con 72, il numero di connessioni dirette esplode ( $n \cdot (n-1)/2$ ) e diventa impossibile. **\*\*È proprio per questo che Nvidia, con NVSwitch, ha potuto costruire il GB200 NVL72 — 72 GPU in un singolo dominio NVLink — mentre AMD è rimasta ferma a 8 per un'intera generazione.\*\*** Se ricordate una sola frase da questo capitolo, ricordate questa: *\*il vantaggio strutturale di Nvidia nel 2024-2025 non era la GPU, era lo switch.\**

### 3.3 NVLink: Cosa AMD deve battere

**NVLink** è l'interconnessione proprietaria di Nvidia. Nella generazione Blackwell, offre ~1.8 TB/s bidirezionali per GPU; nella generazione Rubin, aumenta a ~3.6 TB/s. Combinato con NVSwitch, crea un **dominio di memoria coerente attraverso 72 GPU**: dal punto di vista del programmatore, il rack NVL72 si comporta come una GPU gigante con memoria condivisa. È un profondo fossato tecnologico, e Nvidia lo difende: NVLink è chiuso, non concesso in licenza a terzi.

### 3.4 UALink: lo standard aperto anti-NVLink

**UALink** (Ultra Accelerator Link) è la risposta collettiva dell'industria. È un consorzio che riunisce AMD, Intel, Google, Meta, Microsoft, Broadcom, Cisco, HPE

e altri, con un obiettivo dichiarato: **definire uno standard aperto per l'interconnessione acceleratore-acceleratore in scale-up**, in modo che un rack possa contenere acceleratori di diversi fornitori e switch di diversi fornitori, come già avviene con Ethernet nel networking.

**La situazione reale nel 2026, senza retorica.** Gli acceleratori MI400 saranno i primi a supportare UALink insieme a Infinity Fabric. Ma uno standard di interconnessione senza **silicio per switch** è una specifica, non un prodotto: affinché UALink funzioni veramente, sono necessari chip switch, attesi da fornitori come Adera Labs, Broadcom, Enfabrica e altri. Fino a quando non arriveranno in volume, i primi sistemi Helios utilizzeranno **UALink-over-Ethernet** — una soluzione funzionale ma non ciò per cui UALink è stato progettato. **Traduzione per l'acquirente: UALink è una promessa credibile con tempistiche incerte. Non basare un piano di acquisto su di essa oggi.**

**Ultra Ethernet** è il fratello sul lato scale-out: un consorzio parallelo che estende Ethernet con le funzionalità di latenza e affidabilità richieste dai cluster AI, per sostituire InfiniBand (proprietario di Nvidia dopo l'acquisizione di Mellanox). Qui, la posizione di AMD è più forte, perché Ethernet esiste già e le schede di rete (Pensando Pollara 400G, Vulcano 800G) sono prodotti reali.

---

## 4. Il punto debole: il software

Se hai letto le sezioni precedenti pensando "ma allora AMD è competitiva, perché nessuno la compra?", la risposta è tutta qui.

### 4.1 CUDA: capire il fossato prima di capire il ponte

**CUDA** (Compute Unified Device Architecture) non è il "driver di Nvidia". È uno stack completo accumulato in **quasi vent'anni**: un linguaggio, un compilatore, un runtime e soprattutto una **piramide di librerie** (cuBLAS per l'algebra lineare, cuDNN per le reti neurali, NCCL per la comunicazione multi-GPU, TensorRT-LLM per l'inferenza ottimizzata, CUTLASS per i kernel di matrice) su cui poggia *tutto* il software AI del mondo. E sopra a questo: milioni di righe di codice di ricerca, tutorial, risposte di Stack Overflow, tesi di dottorato, container pre-confezionati e un'intera generazione di ingegneri che ha imparato a programmare in questo modo.

Il fossato non è tecnico. È **sociale e cumulativo**. Ed è per questo che non può essere colmato con un chip più veloce.

## 4.2 ROCm: cos'è e dove si trova realmente

**ROCm** (Radeon Open Compute platform) è la risposta di AMD: uno stack open-source, funzionalmente equivalente a CUDA. A partire dal 2026, la linea attuale è la **7.x** (ROCm 7 ha introdotto miglioramenti dichiarati di oltre 3-4× sull'inferenza e l'addestramento rispetto a ROCm 6.0), con rilasci regolari e supporto Linux di prim'ordine.

**Dove ROCm funziona bene, oggi — e questo è cambiato molto negli ultimi 18 mesi:**

- **PyTorch**: Supporto ufficiale e upstream con build pronte all'uso. Nella stragrande maggioranza dei casi, un modello PyTorch in esecuzione su CUDA funziona su ROCm con zero modifiche al codice: `torch.cuda` continua a essere chiamato così anche su AMD (è un alias, per compatibilità).
- **vLLM e SGLang**: I due motori di inferenza LLM più utilizzati in produzione hanno un supporto ROCm ufficiale e maturo. AMD ha investito molto in questo, con kernel proprietari ottimizzati (la libreria **AITER**) che apportano molteplici miglioramenti al throughput nei backend di attenzione rispetto ai percorsi generici. Nel 2026, ROCm è entrato nella CI (Continuous Integration) ufficiale di vLLM: ogni commit viene testato su silicio AMD, il che significa che le regressioni vengono individuate prima di raggiungere l'utente. Questo è un enorme cambiamento di status, da "un porting della comunità" a "una piattaforma di prima classe".
- **Inferenza LLM standard**: Su carichi di lavoro PyTorch + vLLM senza kernel personalizzati, misurazioni indipendenti collocano ROCm su MI300X/MI355X **intorno al 90-95% del throughput della controparte Nvidia** — e con batch grandi, il divario si restringe ulteriormente. **[DATI VOLATILI]**
- **llama.cpp / Ollama**: Funzionano, anche su schede consumer.

**Dove ROCm soffre ancora, ed è onesto dirlo:**

- **Kernel CUDA personalizzati di terze parti.** Questo è **il** problema, quello che causa il fallimento delle migrazioni. Molto codice di ricerca — e non poche librerie di produzione — distribuisce kernel CUDA scritti a mano, a volte con assembly PTX o intrinsics specifici di Nvidia. Quel codice **non si porta automaticamente**. Ci si trova a scegliere tra: cercare un fork compatibile, riscrivere il kernel o aspettare che la comunità lo faccia. Se il vostro progetto

dipende da una libreria di nicchia con kernel personalizzati, **la migrazione ad AMD può bloccarsi su un singolo file `.cu`**.

- **TensorRT-LLM e l'ecosistema di ottimizzazione Nvidia** non hanno un equivalente ROCm completo. Con batch molto piccoli (inferenza a bassa latenza, un utente alla volta), dove TensorRT-LLM offre le migliori prestazioni, Nvidia mantiene un significativo vantaggio di throughput.
- **FlashAttention**: Esistono porting ROCm che funzionano, ma tendono a rimanere indietro rispetto alla versione CUDA di settimane o mesi. Se avete bisogno delle ultime funzionalità per l'addestramento, aspettatevi attriti.
- **Documentazione e casi limite**. Molto migliorata, ma la densità di risposte pronte su Internet rimane di un ordine di grandezza inferiore. Quando si ha un errore CUDA oscuro, lo si cerca su Google e si trovano tre persone che lo hanno già risolto nel 2022. Su ROCm, spesso, si trova un problema aperto su GitHub. **Questo si traduce in ore-uomo, e le ore-uomo hanno un costo.**
- **Windows e macOS**: Per un lavoro serio di ML, **solo Linux**. Ubuntu LTS o RHEL. Senza qualificazioni.

#### 4.3 HIP: Il Ponte

**HIP** (Heterogeneous-Compute Interface for Portability) è il livello di compatibilità. Sintatticamente è quasi un clone di CUDA: `cudaMalloc` diventa `hipMalloc`, `__global__` rimane `__global__`, i concetti (griglia, blocco, thread, memoria condivisa) sono gli stessi. AMD fornisce **hipify**, uno strumento di traduzione automatica da sorgente a sorgente che converte il codice CUDA in codice HIP.

##### Come funziona, realisticamente:

- Per il codice CUDA "idiomatico" che utilizza API standard: **la conversione automatica riesce nella stragrande maggioranza dei casi.**
- Per il codice che utilizza intrinsics architetturali specifici di Nvidia, warp shuffle con ipotesi sulla dimensione del warp (32 su Nvidia, 64 su CDNA!), assembly PTX inline o le ultime API di Tensor Core: **la conversione fallisce, o peggio, riesce ma produce codice corretto ma estremamente lento.**

Il punto sottile, e cruciale: **HIP garantisce la portabilità, non le prestazioni**. Un kernel tradotto meccanicamente funzionerà. Un kernel *veloce* su CDNA deve essere riscritto tenendo conto di CDNA. Chiunque venda la migrazione ad AMD come "basta eseguire hipify" vi sta vendendo un'illusione.

#### 4.4 Lo "sconto ecosistema": perché l'hardware AMD costa meno

Ora possiamo chiudere il cerchio economico. Perché una MI300X con 192 GB costa meno di una H100 con 80 GB?

**Perché il prezzo di un acceleratore non è il prezzo del silicio: è il prezzo del silicio più il valore dell'ecosistema, meno il costo del rischio.** AMD deve compensare, nel prezzo, tutto ciò che il cliente dovrà spendere in più:

- ore di ingegneria per portare e ottimizzare il codice;
- rischio di rimanere bloccati su una dipendenza non supportata;
- rischio di consegna, driver, regressioni;
- mercato dell'usato meno liquido e valore residuo inferiore;
- pool di talenti più piccolo (trovare un ingegnere in grado di ottimizzare i kernel HIP è più difficile che trovarne uno in grado di ottimizzare CUDA, e costa di più).

**Questo sconto è reale e dovrebbe essere accettato solo se si dispone dell'organizzazione per farlo.** Uno sconto del 25% sull'hardware è un ottimo affare per un hyperscaler con un team di 40 ingegneri di sistema che ottimizzano i kernel. È un cattivo affare per una PMI con due data scientist, perché quei due passeranno tre mesi a combattere con i driver, e quei tre mesi costano più dello sconto. **Regola: lo sconto ecosistema vale quanto la vostra capacità interna di assorbirlo.**

---

## 5. Nvidia vs. AMD nel datacenter: battono o non battono?

Facciamo un confronto onesto, criterio per criterio, senza pregiudizi.

### 5.1 VRAM per GPU — **\*\*AMD vince\*\***, storicamente

Su questo, AMD ha avuto un vantaggio strutturale continuo. 192 GB vs. 80 (MI300X vs. H100), 256 vs. 141 (MI325X vs. H200). **Attenzione, però:** con Blackwell Ultra (B300, 288 GB), Nvidia ha **eguagliato** la MI355X. Il vantaggio si riapre con MI455X (432 GB HBM4) vs. Rubin VR200 (288 GB HBM4). **Il modello storico è chiaro: AMD apre il vantaggio, Nvidia lo chiude nella generazione successiva.** Non date per scontato che durerà.

## 5.2 Larghezza di banda della memoria — **\*\*sostanzialmente alla pari, con testa a testa generazionale\*\***

5.3 vs. 3.35 TB/s (MI300X vs. H100: AMD vince). 8 vs. 8 (MI355X vs. B300: parità). 19.6 vs. 22 TB/s (MI455X vs. VR200: **Nvidia vince**, che con HBM4 a oltre 11 Gbps per pin ha spinto la frequenza più in alto). Questa è la metrica più importante per l'inferenza, ed è il fronte più conteso.

## 5.3 Prestazioni di training — **\*\*Nvidia vince, e non di poco\*\***

Non tanto per il silicio, ma per: (a) FLOPS di picco più elevati in bassa precisione; (b) NCCL e l'intero stack di comunicazione collettiva, maturo e ottimizzato da anni; (c) il dominio NVLink a 72 GPU, che per l'addestramento di modelli enormi è un vantaggio architetturale, non incrementale; (d) FlashAttention, Transformer Engine, Megatron/NeMo e l'intero toolkit di training su larga scala, nato su CUDA. **Se dovete addestrare un modello all'avanguardia da zero, nel 2026 acquistate Nvidia.** Questa è la conclusione, per quanto scomoda.

## 5.4 Prestazioni di inferenza — **\*\*AMD è competitiva, e in alcuni scenari vince\*\***

Poiché l'inferenza durante la generazione è limitata dalla memoria, e la memoria è il territorio di AMD. Più VRAM per GPU elimina interi assi di parallelismo, semplifica la distribuzione e serve un modello di grandi dimensioni su meno GPU. Su PyTorch + vLLM/SGLang, con grandi batch, il divario si riduce a percentuali a una cifra. **Se la tua attività consiste nel servire token in volume, AMD merita seria considerazione.**

## 5.5 TCO e Prezzo — **\*\*AMD vince sul prezzo di acquisto; il TCO dipende da te\*\***

Il TCO (Total Cost of Ownership) è la somma di: acquisto + energia + raffreddamento + spazio + personale + software + costo del rischio. AMD vince chiaramente sul primo punto. Tipicamente perde sull'energia (TDP più elevati per la stessa generazione) e sul personale (§4.4). Il verdetto **dipende interamente dalla scala e dalla maturità del tuo team.**

## 5.6 Software — **\*\*Nvidia vince, chiaramente\*\***

Vedi §4. Non c'è altro da aggiungere. È il motivo per cui questo capitolo non si conclude con "compra AMD".

## 5.7 Disponibilità — **\*\*la variabile impazzita\*\***

In tempi di estrema scarsità, la domanda non è "quale è migliore", ma "cosa posso ottenere". Una MI355X consegnata in otto settimane batte una B300 consegnata in dieci mesi, indipendentemente dai benchmark. **[DATI VOLATILI ed**

**estremamente variabili.]** Questo è, storicamente, il motivo principale per cui AMD ha venduto Instinct.

5.8 Chi compra AMD, e perché

1. **Hyperscaler.** Microsoft, Meta, Oracle. Hanno i team per assorbire il costo del software, acquistano in volumi che giustificano ottimizzazioni dedicate e hanno un interesse strategico esistenziale a non dipendere da un unico fornitore. Comprano AMD **anche per avere qualcosa da mostrare a Nvidia durante le negoziazioni.** È una leva negoziale, ancora più che tecnologia. 2. **Fattorie di inferenza.** Aziende il cui prodotto è servire token (fornitori di API, motori di inferenza cloud). Carico limitato dalla memoria, stack software standardizzato (vLLM), estrema sensibilità al costo per token. Il profilo ideale per AMD. 3. **HPC e settore pubblico.** Frontier, El Capitan, sistemi exascale europei. AMD è il campione qui, non lo sfidante — forte FP64, memoria unificata e nessun lock-in. 4. **"AI Sovrana."** Stati che vogliono la propria infrastruttura, spesso con un esplicito mandato politico a favore di standard aperti e contro il monopolio.

Chi **non** compra AMD: la startup con sei ingegneri e diciotto mesi di autonomia, che non può permettersi di perdere tre settimane su un kernel. E giustamente.

5.9 Tabella Comparativa Finale

**[TUTTI I DATI IN QUESTA TABELLA SONO VOLATILI.]** FLOPS in valori *densi*, non sparsi. Prezzi di mercato indicativi, non prezzi di listino.

|              | H100<br>SXM | H200<br>SXM  | B200             | B300 /<br>GB300 | VR200<br>(Rubin) | MI300X      | MI325X       | MI355X       | MI455X      |
|--------------|-------------|--------------|------------------|-----------------|------------------|-------------|--------------|--------------|-------------|
| Produttore   | Nvidia      | Nvidia       | Nvidia           | Nvidia          | Nvidia           | AMD         | AMD          | AMD          | AMD         |
| Architettura | Hopper      | Hopper       | Blackwell        | Blackwell Ultra | Rubin            | CDNA 3      | CDNA 3       | CDNA 4       | CDNA 5      |
| Anno         | 2022        | 2023         | 2024-25          | 2025-26         | H2 2026          | 2023        | 2024-25      | 2025         | H2 2026     |
| Memoria      | 80 GB HBM3  | 141 GB HBM3e | 180-192 GB HBM3e | 288 GB HBM3e    | 288 GB HBM4      | 192 GB HBM3 | 256 GB HBM3e | 288 GB HBM3e | 432 GB HBM4 |
| Larghezza    | 3.35        | 4.8          | 8 TB/s           | 8 TB/s          | ~22              | 5.3         | 6.0          | 8 TB/s       | ~19.6       |



|                              |                             |                      |                        |                             |                                   |                                       |               |                     |                              |
|------------------------------|-----------------------------|----------------------|------------------------|-----------------------------|-----------------------------------|---------------------------------------|---------------|---------------------|------------------------------|
| ezza<br>di<br>band<br>a      | TB/s                        | TB/s                 |                        |                             | <b>TB/s</b>                       | TB/s                                  | TB/s          |                     | TB/s                         |
| FP8<br>(dens<br>o)           | ~2 PF                       | ~2 PF                | ~4.5<br>PF             | ~5 PF                       | ~35<br>PF<br>(NVF<br>P4<br>train) | ~2.6<br>PF                            | ~2.6<br>PF    | ~5 PF               | ~20<br>PF                    |
| FP4<br>(dens<br>o)           | —                           | —                    | ~9 PF                  | ~15<br>PF                   | <b>~50<br/>PF</b>                 | —                                     | —             | ~10<br>PF           | ~40<br>PF                    |
| FP64                         | 34 TF                       | 34 TF                | ~40<br>TF              | ridott<br>o                 | ridott<br>o                       | 163<br>TF                             | 163<br>TF     | 79 TF               | (MI43<br>OX)                 |
| TDP/<br>TBP                  | 700<br>W                    | 700<br>W             | 1.000<br>W             | ~1.40<br>0 W                | ~1.80<br>0-<br>2.300<br>W         | 750<br>W                              | 1.000<br>W    | 1.400<br>W          | ~2.30<br>0+ W                |
| Raffre<br>ddam<br>ento       | aria/<br>liquid<br>o        | aria/<br>liquid<br>o | aria/<br>liquid<br>o   | <b>liqui<br/>do</b>         | <b>solo<br/>liqui<br/>do</b>      | aria                                  | aria          | <b>liqui<br/>do</b> | <b>solo<br/>liqui<br/>do</b> |
| Scala<br>bilità              | NVLi<br>nk 4                | NVLi<br>nk 4         | NVLi<br>nk 5           | NVLi<br>nk 5<br>(NVL<br>72) | NVLi<br>nk 6<br>(NVL<br>72)       | Infini<br>ty<br>Fabri<br>c (8<br>GPU) | IF (8)        | IF (8)              | IF +<br><b>UALi<br/>nk</b>   |
| Rack-<br>scale               | HGX<br>8×                   | HGX<br>8×            | GB20<br>0<br>NVL7<br>2 | GB30<br>0<br>NVL7<br>2      | VR20<br>0<br>NVL7<br>2            | —                                     | —             | —                   | <b>Helio<br/>s (72)</b>      |
| Prezz<br>o<br>indic<br>ativo | \$25-<br>30k                | \$30-<br>35k         | \$30-<br>40k           | \$40k+                      | n.d.                              | \$10-<br>15k                          | \$15-<br>25k  | \$25-<br>35k        | ~\$30k<br>(stim<br>e)        |
| Softw<br>are                 | CUDA<br>★★<br>★★<br>★★<br>★ | ★★<br>★★<br>★        | ★★<br>★★<br>★          | ★★<br>★★<br>★               | ★★<br>★★<br>★                     | ROC<br>m<br>★★<br>★★<br>★<br>☆        | ★★<br>★☆<br>☆ | ★★<br>★★<br>☆       | ★★<br>★★<br>☆                |

**Come leggere questa tabella.** Guarda le ultime tre righe. Prezzo e software raccontano tutta la storia: AMD offre più memoria per dollaro, Nvidia offre meno attrito per dollaro. La scelta è in ultima analisi una scommessa su **quale delle due risorse—denaro o tempo dei tuoi ingegneri—è più scarsa nella tua organizzazione.**

---

## 6. Guida alla Decisione Finale per una Build AI (Parte Workstation)

Concludiamo scendendo dalle nuvole del datacenter al desktop, perché è lì che il 99% dei lettori di questo libro dovrà prendere una decisione reale. I prezzi sono **[DATI VOLATILI]** e nel 2026 sono stati ulteriormente distorti dalla scarsità di memoria: considerali ordini di grandezza.

### 6.1 La Domanda Zero: Comprare o Noleggiare?

Prima di scegliere un livello, poniti questa domanda. **Il cloud è conveniente quando l'utilizzo è basso, variabile o incerto. L'acquisto è conveniente quando l'utilizzo è alto, costante e prevedibile.**

Il calcolo è semplice: prendi il costo orario dell'istanza cloud equivalente (**[DATI VOLATILI]** — approssimativamente, nel 2026, pochi euro all'ora per una GPU di classe H100/H200 su provider specializzati, di più sui grandi cloud generalisti), moltiplicalo per le ore che *effettivamente* utilizzerai al mese, e confrontalo con (prezzo hardware / 36 mesi) + elettricità + il tuo tempo di amministrazione.

Il risultato tipico è che **il punto di pareggio si aggira intorno al 30-50% di utilizzo continuo.** Se la tua GPU rimanesse accesa e carica meno di 8 ore al giorno, il cloud quasi sempre vince. Se la tieni al 90% per due anni, l'acquisto vince chiaramente.

Ma ci sono tre ragioni **non economiche** per comprare che sono spesso decisive: **data privacy** (se i dati dei clienti non possono uscire dai vostri locali — spesso il caso in Italia sotto GDPR — il public cloud è precluso o estremamente complicato); **latenza e disponibilità** (la vostra GPU è vostra, sempre, senza code o quote); e **apprendimento** (assemblare, configurare, rompere e riparare un sistema insegna cose che affittare un'istanza non farà mai).

## 6.2 Livello A — sotto i €3.000: il PC consumer di fascia alta

**Chi siete:** uno sviluppatore, un ricercatore, uno studente. Volete fare il fine-tuning di piccoli modelli, eseguire inferenze locali, sviluppare e prototipare, e magari giocare la sera.

**Cosa comprate:** una singola GPU consumer di fascia alta (RTX 5090 con 32 GB, o una RTX 4090 usata con 24 GB), una CPU consumer (Ryzen 7/9 o Core i7/i9), **64-128 GB di RAM di sistema** — regola empirica: RAM di sistema  $\geq 2 \times$  VRAM totale, perché è necessaria per il caricamento, la quantizzazione e la pre-elaborazione — e un NVMe da 2 TB.

**Cosa potete fare:** inferenza di modelli fino a ~30 B in quantizzazione a 4 bit; fine-tuning **LoRA** (Low-Rank Adaptation: solo un piccolo insieme di matrici aggiuntive vengono addestrate invece di tutti i pesi, riducendo drasticamente i requisiti di memoria) su modelli fino a 7-13 B; tutta la computer vision che volete; sviluppo di pipeline che poi verranno eseguite altrove.

**Cosa NON potete fare:** addestrare da zero; fine-tuning completo di modelli grandi; servire in produzione con vera concorrenza.

**Errore comune:** comprare due GPU consumer da 16 GB e aspettarsi di ottenere 32 GB. La **VRAM non si somma** se il modello non è progettato per essere partizionato. Per l'inferenza LLM, una singola GPU da 24 GB quasi sempre batte due GPU da 12 GB. **Massimizzate la VRAM di un singolo chip, non il numero di chip.**

## 6.3 Livello B — €5.000-€15.000: La Workstation Threadripper con 2 GPU

**Chi siete:** Un consulente, un piccolo team, una startup pre-seed. Avete bisogno di una macchina che possa gestire carichi di lavoro seri e funzionare per una settimana di fila.

**Cosa comprate:** Un **Threadripper** (non un Ryzen) o uno Xeon W. Perché? Per le **lane PCIe** (le "corsie" del bus: ogni GPU idealmente vuole x16 lane; una CPU consumer offre ~24-28 lane utilizzabili in totale, il che significa che con due GPU si scende a x8 ciascuna e il collo di bottiglia si sposta sul bus quando le GPU devono comunicare). Un Threadripper offre 48-92, un Threadripper PRO fino a 128. Poi: 2 GPU (2 $\times$  RTX 5090, o 1-2 RTX PRO Blackwell 48-96 GB se il budget lo permette), 128-256 GB di RAM ECC, un alimentatore da 1.600 W, un case full-tower con un serio flusso d'aria.

**Errore comune:** installare due GPU consumer *open-air* (con ventole aperte, cioè la stragrande maggioranza dei modelli da gaming) adiacenti l'una all'altra. **Vedi §6.5: questo è l'errore più costoso e più comune in tutto questo livello.**

#### 6.4 Livello C — €15.000-€50.000: La Workstation Professionale

**Chi siete:** Un'azienda che fa AI seria ma senza ancora un datacenter.

**Cosa comprate:** Threadripper PRO o EPYC single-socket, e **2-4 RTX PRO 6000 Blackwell (96 GB ciascuna)**. Quattro di queste vi danno **384 GB di VRAM su una singola macchina**, con raffreddamento a blower specificamente progettato per l'installazione affiancata, ECC, driver certificati e — un dettaglio non trascurabile — una licenza che permette l'uso in datacenter, che le schede GeForce **non hanno** (i termini di licenza di Nvidia proibiscono l'uso delle schede GeForce nei datacenter, con limitate eccezioni: se fornite servizi a clienti, consultate un avvocato).

**L'alternativa specializzata:** Sistemi desktop basati su superchip (DGX Spark, DGX Station e derivati OEM), che offrono grandi quantità di **memoria unificata coerente** (fino a centinaia di GB) su un singolo chip ARM+GPU. Sono

**3. Alimentatore (PSU) — e calcolo dei transitori.** Sommare i TDP e aggiungere **almeno il 30-40% di margine**. Non per generica prudenza, ma perché le GPU moderne hanno dei **picchi transitori** (spike di microsecondi) che possono raggiungere il doppio del TDP nominale e far scattare la protezione di sovracorrente (OCP) di un alimentatore sottodimensionato — con conseguente riavvio inaspettato, di solito nel bel mezzo di una sessione di training di trenta ore. Due RTX 5090 ( $2 \times 575\text{ W}$ ) più un Threadripper (350 W) più il resto richiedono **1.600 W minimo**. Sopra i ~1.600-2.000 W, si entra nel territorio dei **doppi PSU**: due alimentatori sincronizzati con un "add2psu" o una scheda madre server preconfigurata. Regola non negoziabile: **una singola GPU non deve mai essere alimentata da due PSU diversi** (differenze di potenziale sui riferimenti di massa → danni). Una GPU, un alimentatore. E, per i connettori: **12VHPWR/12V-2x6 va inserito fino in fondo, con un click, e non va piegato entro 35 mm dal connettore**. I casi di fusione del connettore sono, nella quasi totalità dei casi, casi di inserimento incompleto.

**4. Raffreddamento — blower vs. open-air, l'errore da 3.000 €.** Questa è la differenza più importante e meno conosciuta di tutta la sezione.

- Una GPU **open-air** (il design a 2-3 ventole di quasi tutte le schede gaming) aspira aria dal basso e la **soffia lateralmente dentro il case**. Progettata per una singola GPU in un case ben ventilato.
- Una GPU **blower** (ventola radiale) aspira aria e la **espelle interamente fuori dal case attraverso la staffa posteriore**. Progettata per essere affiancata ad altre.

Se installate **due GPU open-air adiacenti**, la scheda superiore aspira l'aria calda espulsa da quella inferiore. Il risultato non è un guasto: è il **thermal throttling**, cioè la riduzione automatica delle frequenze per non superare i limiti di temperatura. La scheda superiore girerà stabilmente 15-25 °C più calda e perderà una frazione significativa di prestazioni, **silenziosamente e permanentemente**. Avrete pagato due GPU e ne otterrete una e mezza, senza alcun avviso.

#### **Soluzioni, in ordine di preferenza:**

- comprare **GPU professionali con dissipatori blower** (le RTX PRO sono progettate esattamente per questo — è uno dei motivi per cui costano di più, e per cui in setup multi-GPU sono spesso più economiche a parità di prestazioni ottenute);
- **raffreddamento a liquido** con blocchi dedicati (blocco su ogni GPU, radiatori generosi): efficace, costoso, e introduce un punto di fallimento idraulico;
- **distanziare fisicamente** le schede con riser, in un case molto grande, con ventole di scarico dedicate;
- **limitare la potenza** (`nvidia-smi -pl`): controintuitivo, ma limitare una GPU all'80% del suo TDP costa tipicamente solo il 5-10% in prestazioni e riduce drasticamente il calore. In setup multi-GPU, è quasi sempre la scelta razionale.

**5. L'impianto elettrico domestico — il limite dei 3 kW in Italia.** E qui arriviamo al vincolo più concreto e più ignorato, che nessun sito americano vi menzionerà mai.

Il contratto di fornitura elettrica domestica standard in Italia è di **3 kW** (con una tolleranza tipica del 10%, quindi ~3.3 kW prima che scatti il limitatore). Una presa Schuko su un circuito da 16 A, 230 V gestisce nominalmente ~3.6 kW.

Fai i conti: una workstation con **due RTX 5090** a pieno carico assorbe realisticamente **1.400-1.800 W dalla presa** (l'assorbimento a monte è maggiore dell'output a valle perché l'alimentatore ha un'efficienza dell'88-92%). Aggiungi il

monitor, e sei a ~1.900 W. **Questo lascia ~1.100 W per tutto il resto della casa.** Il forno elettrico richiede 2.000. La lavatrice durante il riscaldamento, 2.000. L'aria condizionata, 1.000-1.500. L'asciugacapelli, 1.800.

**Conclusione operativa: con un contratto da 3 kW, una workstation multi-GPU di fascia media farà scattare il tuo interruttore ogni volta che qualcuno in casa accende qualcosa.** E non scatterà a mezzogiorno: scatterà alle tre del mattino, nel bel mezzo di un fine-tuning, perché si è acceso lo scaldabagno.

#### **Cosa fare, in ordine:**

- **\*\*Aumentare la potenza contrattuale\*\*** a 4,5 o 6 kW. Questo si fa richiedendolo al proprio fornitore, comporta un adeguamento degli oneri fissi in bolletta, e ha senso a partire dalla fascia B.
- **\*\*Controllare il circuito\*\***: una workstation da 1.800 W dovrebbe essere su un **\*\*circuito dedicato\*\***, non condiviso con la cucina. Se il tuo sistema ha un unico circuito da 16 A per metà dell'appartamento, chiama un elettricista.
- **\*\*Considerare un gruppo di continuità (UPS)\*\*** con adeguata potenza *\*reale\**: tieni presente che gli UPS sono venduti in VA (volt-ampere), non watt. Un UPS da "1.500 VA" tipicamente eroga ~900-1.000 W reali. Dimensionarlo in base ai watt.
- **\*\*Oltre ~3 kW per la macchina, la workstation smette di essere un elettrodomestico\*\***: è necessaria una linea industriale, e a quel punto, hai implicitamente risposto alla domanda "comprare o cloud".

**6. Carico termico nella stanza.** Ultimo punto, e il più sottovalutato: **tutta la potenza elettrica assorbita da un computer viene convertita in calore.** Non "quasi tutta": tutta. Una workstation da 1.800 W è, da una prospettiva termodinamica, **una stufa da 1.800 W costantemente accesa.** In una stanza di 15 m<sup>2</sup> senza aria condizionata, in estate, questo è fisicamente insostenibile — per la macchina e per te. Metti in conto un condizionatore d'aria, e ricorda che anche quello consuma dal tuo contratto da 3 kW.

---

## **7. Riepilogo Operativo — Lista di Controllo Decisionale**

### **A) Scelta tra Nvidia e AMD nel datacenter**

**1. Il mio carico di lavoro è di training o inferenza?** → *Training all'avanguardia* → **Nvidia**, senza discussioni. → *Inferenza di volume* → AMD è in lizza. Procedi. **2. Il**

**mio stack dipende da kernel CUDA personalizzati, TensorRT-LLM o librerie di nicchia?** → Sì → Nvidia. Lo sconto AMD non compenserà il porting. → No, uso PyTorch standard + vLLM/SGLang → AMD è una scelta seria. Procedi. 3. **Ho ingegneri di sistema in grado di risolvere autonomamente un problema di driver o un kernel lento?** → No → Nvidia. Lo sconto sull'ecosistema si realizza solo con competenze interne. → Sì → Procedi. 4. **Il mio collo di bottiglia è la capacità della memoria GPU?** → Sì (il modello non ci sta, o ci sta a malapena) → questo è il caso d'uso ideale per AMD. 5. **Ho fatto un benchmark del MIO modello, con la MIA lunghezza di contesto e il MIO batch?** → No → Fermati e fallo. Nessun numero in questo capitolo sostituisce una misurazione sul tuo carico di lavoro. Quasi tutti i cloud offrono MI300X/MI355X a ore: **spendi 200€ per il noleggio prima di spendere 200.000€ per l'hardware.** 6. **Ho verificato la disponibilità effettiva e i tempi di consegna?** → La migliore GPU è quella che arriva. 7. **Ho considerato il potere negoziale?** → Un preventivo AMD in mano cambia il preventivo Nvidia. Questa è, per molte aziende, la ragione principale di questo intero capitolo.

## B) Lista di controllo della compatibilità per una workstation multi-GPU

- [ ] **\*\*Corsie PCIe\*\***: somma le corsie richieste (GPU + NVMe + rete) e confrontale con le corsie *\*effettive\** della CPU. Leggi il diagramma di allocazione degli slot nel manuale della scheda madre.
- [ ] **\*\*Spaziatura fisica\*\***: verifica che ci sia aria tra le GPU. Misurato, non stimato.
- [ ] **\*\*Dissipatori\*\***: **\*\*blower\*\*** (o liquido) se le GPU sono adiacenti. Mai due dissipatori open-air attaccati.
- [ ] **\*\*PSU\*\***: somma dei TDP + 30-40% di margine. Cavi 12VHPWR completamente inseriti, non piegati vicino al connettore.
- [ ] **\*\*Doppio PSU\*\*** (se >1.600 W): una GPU = un alimentatore. Mai a cavallo.
- [ ] **\*\*RAM di sistema\*\***  $\geq 2 \times$  VRAM totale. ECC se la macchina deve funzionare per giorni.
- [ ] **\*\*Limite di potenza\*\*** impostato all'80% in multi-GPU: perdi 5-10%, guadagni stabilità e silenzio.
- [ ] **\*\*Contratto elettrico\*\***: 3 kW **\*\*non bastano\*\*** oltre la fascia A. Richiedi un aumento a 4.5-6 kW.
- [ ] **\*\*Circuito dedicato\*\*** per la workstation, verificato da un elettricista.
- [ ] **\*\*UPS\*\*** dimensionato in **\*\*watt\*\***, non in VA.
- [ ] **\*\*Aria condizionata della stanza\*\***: la macchina è un riscaldatore. Trattala come tale.

- [ ] **\*\*Sistema operativo\*\***: Linux. Ubuntu LTS. Sia su Nvidia che (soprattutto) su AMD.
- [ ] **\*\*Piano di uscita\*\***: se tra 18 mesi avrai bisogno di 4× questa potenza, questa macchina è un investimento o un vicolo cieco? Se è un vicolo cieco, considera il cloud.

---

*Fine del capitolo.*